

FDU 数据同化 1. 单参数模型

本文参考以下教材:

- A First Course in Bayesian Statistical Methods (P. Hoff) Chapter 1, 2, 3, 4
- 《数理统计讲义》(郑明, 陈子毅, 汪嘉冈) 第 1 章

欢迎批评指正!

All models are wrong, but some are useful. — Box & Draper

1.1 基础知识

1.1.1 Bayes 法则

从某种意义上说, 概率 (probability) 是信念 (belief) 的数学表示, 而 Bayes 法则提供了一种在获得新信息后对信念进行更新的方法. 通过 Bayes 法则进行归纳学习的过程称为 **Bayes 推断** (Bayesian inference).

设总体特征可通过参数 θ 来表示.

记所有可能的参数值所构成的集合为 Θ , 称为**参数空间** (parameter space).

对于任意 $\theta \in \Theta$, 记**先验分布** (prior distribution) 的概率 (密度) 为 $p(\theta)$, 代表我们在观测之前对 " θ 是总体的真实参数" 这一命题的信念.

记所有可能的样本集合所构成的集合为 $\mathcal{Y}$, 称为**样本空间** (sample space).

对于任意 $\theta \in \Theta$ 和 $y \in \mathcal{Y}$, 记**采样分布** (sampling distribution) 的概率 (密度) 为 $p(y | \theta)$, 代表我们在已知 θ 为总体的真实参数的条件下, 对 "观测到 y " 这一命题的信念, 同时也代表我们在已观测到样本集合 y 的条件下, 对当前参数值 θ 进行更新的依据. 在后一种意义下, 我们通常将 $p(y | \theta)$ 称为**似然** (likelihood).

给定样本集合 y , 我们便可计算**后验分布** (posterior distribution) 的概率 (密度):

$$\begin{aligned}\text{posterior} &= p(\theta | y) \\ &= \frac{p(y | \theta)p(\theta)}{p(y)} \\ &= \frac{p(y | \theta)p(\theta)}{\int_{\Theta} p(y | \tilde{\theta})p(\tilde{\theta})d\tilde{\theta}} \\ &\propto \text{likelihood} \times \text{prior},\end{aligned}$$

它代表我们在已观测到样本集合 y 的条件下, 对 " θ 是总体的真实参数" 这一命题的信念.

值得注意的是, Bayes 法则并不会告诉我们最初的信念应该是什么;

它所揭示的是, 当我们获得新的信息之后, 这些信念应该如何更新.

Cox 和 Savage 证明了, 如果先验 $p(\theta)$ 和似然 $p(y | \theta)$ 均来源于一个理性个体的信念, 那么在给定新的信息 y 的情况下, Bayes 法则则是更新该个体关于 θ 的信念的最优方法.

然而, 在实际的数据分析中, 先验 $p(\theta)$ 通常根据经验选取, 或出于计算便利而加以设计.

那么问题来了: 当先验 $p(\theta)$ 可能并不恰当时, Bayes 推断是否依然合理?

事实上, 后面我们会说明, 只要样本量足够大, 先验的影响便可忽略不计.

1.1.2 可交换性

记随机变量 $Y_1, \dots, Y_n$ 的联合概率密度为 $p(y_1, \dots, y_n)$.

若对于 $\{1, \dots, n\}$ 的任意排列 $\pi = (\pi_1, \dots, \pi_n)$,

我们都有 $p(y_{\pi_1}, \dots, y_{\pi_n}) = p(y_1, \dots, y_n)$ 成立,

则我们称 $Y_1, \dots, Y_n$ 是**可交换的** (exchangeable),

换言之, 下标所标识的顺序不包含关于结果的任何信息.

当标签不代表时间、空间等信息时, 假设样本具有可交换性是合理的.

进一步, 我们称序列 $\{Y_n\}_{n=1}^{\infty}$ 是可交换的,

如果其有限维联合分布对任意有限个指标的排列都保持不变.

(de Finetti 定理)

当且仅当 $\theta \in \Theta$ 服从某个先验分布 $p(\theta)$,

且在给定 $\theta \in \Theta$ 的条件下, 随机变量序列 $\{Y_n\}$ 条件独立同分布时,

(在不再以 θ 为条件的情况下) $\{Y_n\}$ 是可交换的.

- 充分性证明:

设 $\theta \in \Theta$ 服从某个先验分布 $p(\theta)$,

且在给定 $\theta \in \Theta$ 的条件下, 随机变量序列 $\{Y_n\}$ 条件独立同分布,

则对于任意正整数 $n \geq 2$ 和 $\pi \in S_n$ (其中 S_n 代表所有 $\{1, \dots, n\}$ 的排列群), 我们都有:

$$\begin{aligned} p(y_{\pi_1}, \dots, y_{\pi_n}) &= \int_{\Theta} p(y_{\pi_1}, \dots, y_{\pi_n} \mid \theta) d\theta \quad (\text{definition of marginal probability}) \\ &= \int_{\Theta} \left\{ \prod_{i=1}^n p(y_{\pi_i} \mid \theta) \right\} d\theta \quad (Y_1, \dots, Y_n \text{ are conditionally i.i.d.}) \\ &= \int_{\Theta} \left\{ \prod_{i=1}^n p(y_i \mid \theta) \right\} d\theta \quad (\text{the commutative law of multiplication}) \\ &= p(y_1, \dots, y_n). \end{aligned}$$

因此随机变量序列 $\{Y_n\}$ 是可交换的.

- 简单起见, 我们这里并不给出必要性证明, 详见 [An Elementary Proof Of de Finetti's Theorem](#).

特殊地, 独立同分布的随机变量序列一定是可交换的.

1.1.3 常用分布

Bernoulli 分布 $\text{Binomial}(1, p)$, 即 0, 1 两点分布, 满足:

$$\begin{aligned} P\{X = k\} &= p^k(1-p)^{1-k} \quad (k = 0, 1) \\ M_X(t) &= pe^t + (1-p) \\ \varphi_X(t) &= pe^{it} + (1-p) \\ \mathbb{E}[X^k] &= p \quad (\forall k = 1, 2, \dots) \\ \text{Var}[X] &= p(1-p) \end{aligned}$$

二项分布 $\text{Binomial}(n, p)$ 可由 n 个独立同分布的 Bernoulli 随机变量的加和得到, 它满足:

$$\begin{aligned} P\{X = k\} &= \binom{n}{k} p^k (1-p)^{n-k} \quad (k = 0, 1, \dots, n) \\ M_X(t) &= (pe^t + (1-p))^n \\ \varphi_X(t) &= (pe^{it} + (1-p))^n \\ \mathbb{E}[X] &= np \\ \text{Var}[X] &= np(1-p) \end{aligned}$$

Poisson 分布 $\text{Poisson}(\lambda)$ 是二项分布 $B(n, p)$ 在 n 很大而 p 很小时的近似分布, 参数 $\lambda \approx np > 0$. 它满足:

$$\begin{aligned} P\{X = k\} &= \frac{\lambda^k}{k!} e^{-\lambda}, \quad k = 0, 1, \dots \\ M_X(t) &= e^{\lambda(e^t - 1)} \\ \varphi_X(t) &= e^{\lambda(e^{it} - 1)} \\ \mathbb{E}[X] &= \lambda \\ \text{Var}[X] &= \lambda \end{aligned}$$

正态分布 $\mathcal{N}(\mu, \sigma^2)$ 满足:

$$\begin{aligned} P\{X = x\} &= \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right) \\ M_X(t) &= \exp\left(\frac{\sigma^2 t^2}{2} + \mu t\right) \\ \varphi_X(t) &= \exp\left(-\frac{\sigma^2 t^2}{2} + i\mu t\right) \\ \mathbb{E}[X] &= \mu \\ \text{Var}[X] &= \sigma^2 \end{aligned}$$

定义 **Gamma 函数** 为:

$$\begin{cases} \Gamma(\alpha) = \int_0^{+\infty} e^{-t} t^{\alpha-1} dt \\ \text{dom}(\Gamma) = \{\alpha \in \mathbb{C} : \text{Re}(\alpha) > 0\}. \end{cases}$$

特殊地, 对于任意整数 n 有 $\Gamma(n) = (n-1)!$ 成立,
实际上 Γ 函数是阶乘函数在实数域和复数域上的推广.
它还具有如下性质:

$$\begin{cases} \Gamma(1/2) = \sqrt{\pi} \\ \Gamma(1) = 1 \\ \Gamma(\alpha + 1) = \alpha \Gamma(\alpha) \quad (\forall \alpha \in \text{dom}(\Gamma)). \end{cases}$$

Gamma 分布 $\text{Gamma}(\alpha, \lambda)$ 满足:

$$\begin{aligned}
P\{X = x\} &= \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x} \mathbb{1}_{(0, \infty)}(x) \\
M_X(t) &= \left(\frac{\lambda}{\lambda - t}\right)^\alpha \quad (t < \lambda) \\
\varphi_X(t) &= \left(\frac{\lambda}{\lambda - it}\right)^\alpha \\
\mathbb{E}[X^k] &= \frac{\Gamma(\alpha + k)}{\lambda^k \Gamma(\alpha)} \quad (\forall k = 1, 2, \dots) \\
\mathbb{E}[X] &= \frac{\alpha}{\lambda} \\
\text{Var}[X] &= \frac{\alpha}{\lambda^2}
\end{aligned}$$

定义 **Beta 函数** 为:

$$\begin{cases} B(a, b) = \int_0^1 x^{a-1} (1-x)^{b-1} dx = \frac{\Gamma(a)\Gamma(b)}{\Gamma(a+b)} \\ \text{dom}(B) = \{a, b \in \mathbb{C} : \text{Re}(a) > 0, \text{Re}(b) > 0\} \end{cases}$$

(第一类) Beta 分布 $\text{Beta}(a, b)$ 满足:

$$\begin{aligned}
M_X(t) &= \sum_{k=0}^{\infty} \frac{B(a+k, b)}{B(a, b)} \frac{t^k}{k!} = \frac{\Gamma(a+b)}{\Gamma(a)} \sum_{k=0}^{\infty} \frac{\Gamma(a+k)}{\Gamma(a+b+k)} \frac{t^k}{k!} \\
\varphi_X(t) &= \sum_{k=0}^{\infty} \frac{B(a+k, b)}{B(a, b)} \frac{(it)^k}{k!} = \frac{\Gamma(a+b)}{\Gamma(a)} \sum_{k=0}^{\infty} \frac{\Gamma(a+k)}{\Gamma(a+b+k)} \frac{(it)^k}{k!} \\
\mathbb{E}[X^k] &= \frac{B(a+k, b)}{B(a, b)} = \frac{\Gamma(a+b)}{\Gamma(a)} \frac{\Gamma(a+k)}{\Gamma(a+b+k)} \\
\mathbb{E}[X] &= \frac{a}{a+b} \\
\mathbb{E}[X^2] &= \frac{a(a+1)}{(a+b)(a+b+1)} \\
\text{Var}[X] &= \frac{ab}{(a+b)^2(a+b+1)}
\end{aligned}$$

特殊地, $\text{Beta}(1, 1)$ 即为标准均匀分布 $\text{Uniform}(0, 1)$.

考虑含参数 θ 的分布族 $\mathcal{F}_X = \{F_X(\theta) : \theta \in \Theta\}$.

若其概率质量函数 (或概率密度函数) 可表示为:

$$p(x; \theta) = C(\theta) \exp \left\{ \sum_{i=1}^k Q_i(\theta) T_i(x) \right\} h(x) \quad (\forall \theta \in \Theta),$$

其中 $\{T_i(x)\}_{i=1}^k$ 和 $h(x)$ 仅为 x 的函数, 而 $C(\theta)$ 和 $\{Q_i(\theta)\}_{i=1}^k$ 仅为 θ 的函数, 则我们称分布族 $\mathcal{F}_X$ 为**指数型分布族** (简称指数族).

特殊地, 如果 $Q_i(\theta) = \theta_i$, $1 \leq i \leq k$, 则称其为**指数族的标准形式**.

二项分布、Poisson 分布、正态分布和 (第一类) Beta 分布都是指数型分布.

可以证明:

$$\mathbb{E}(T_i(X)) = -\frac{\partial}{\partial \theta_i} \log(C(\theta)), \quad 1 \leq i \leq k,$$

$$\text{Cov}(T_i(X), T_j(X)) = -\frac{\partial^2}{\partial \theta_i \partial \theta_j} \log(C(\theta)), \quad 1 \leq i, j \leq k.$$

1.1.4 充分统计量

设样本 X 的可能分布族为 $\mathcal{F}_X = \{F_X(\theta) : \theta \in \Theta\}$.

若 X 关于 $T(X)$ 的条件分布与 θ 无关,

则我们称 $T(X)$ 为 (分布族 $\mathcal{F}_X$) 关于 θ 的**充分统计量**.

(因子化定理, 数理统计讲义 命题 1.5.6)

设样本的可能分布族为 $\mathcal{F}_X = \{f_X(x; \theta) : \theta \in \Theta\}$,

其中 $f_X(x; \theta)$ 为分布密度或离散的概率分布,

则统计量 $T = T(X)$ 为分布族 $\mathcal{F}_X$ 参数 θ 的**充分统计量**的**充要条件**是:

对于任意 $\theta \in \Theta$, $f_X(x; \theta)$ 都可分解为 $g(T(x); \theta) \cdot h(x)$, 其中 $h(x)$ 是与 θ 无关的**非负函数**.

- **(数理统计讲义 例 1.5.2)**

设 $X = (X_1, X_2, \dots, X_n)$ 为取自 Bernoulli 分布族 $\{B(1, p) : p \in (0, 1)\}$ 总体的简单随机样本,
则样本均值 $\bar{X}_n = \sum_{i=1}^n X_i/n$ 是参数 p 的充分统计量.

- **(数理统计讲义 例 1.5.7)**

设 $X = (X_1, \dots, X_n)$ 为取自 **Poisson 分布族** $\{\text{Poisson}(\lambda) : \lambda > 0\}$ 总体的简单随机样本,
则样本均值 $\bar{X}_n = \sum_{i=1}^n X_i/n$ 是参数 λ 的充分统计量.

- **(数理统计讲义 例 1.5.8)**

设 $X = (X_1, \dots, X_n)$ 为取自**正态分布族** $\{\mathcal{N}(\mu, \sigma^2) : \mu \in \mathbb{R}, \sigma^2 > 0\}$ 的简单随机样本,
则 $T(X) = (\bar{X}_n, S_n^{*2})$ 是参数 (μ, σ^2) 的充分统计量,
其中 $S_n^{*2} = \sum_{i=1}^n (X_i - \bar{X}_n)^2/(n-1)$ 是已修偏的样本方差.

- **(数理统计讲义 例 1.5.10)**

设 $X = (X_1, \dots, X_n)$ 为取自**指数型分布族** $\{p(x; \theta), \theta \in \Theta\}$ 的简单随机样本,
其中:

$$p(x; \theta) = C(\theta) \exp \left\{ \sum_{j=1}^k Q_j(\theta) T_j(x) \right\} h(x) \quad (\forall \theta \in \Theta),$$

则 $T(X) = (\sum_{i=1}^n T_1(X_i), \dots, \sum_{i=1}^n T_k(X_i))$ 是参数 θ 的充分统计量.

1.1.5 先验

在 Bayes 统计推断中, 我们需要为参数 θ 指定一个先验分布,

用以表达在观察到样本数据之前对参数 θ 的认识或信念.

若先验分布是**正规的** (proper), 即在参数空间上的积分等于 1, 则后验分布必然是正规的.

若先验分布不是正规的, 则需要验证由 Bayes 公式导出的后验分布是否正规.

信息先验 (informative prior) 用于明确表达对参数取值范围的主观信念, 通常基于历史数据构建.

非信息先验 (noninformative prior) 旨在尽可能少地引入主观信念, 使后验主要由样本数据所主导.

值得注意的是, 非信息先验在实践中往往是非正规的.

Jeffreys 提出了一种构造非信息先验的方法，其核心思想是先验分布应当在参数的——变换下保持不变。换言之，如果我们对参数 θ 和其变换 $\phi = h(\theta)$ 进行建模，所得到的先验在变换前后应当是等价的，而不应依赖于参数化方式的选择。

设似然函数为 $p(y | \theta)$ ，对数似然为 $l(\theta) = \log p(y | \theta)$ 。

定义 **Fisher 信息矩阵**:

- 单参数情形: (Fisher 信息量)

$$I(\theta) = \mathbb{E} \left[\left(\frac{\partial}{\partial \theta} \log p(y | \theta) \right)^2 \right] = -\mathbb{E} \left[\frac{\partial^2}{\partial \theta^2} \log p(y | \theta) \right]$$

- 多参数情形:

$$I(\theta)_{ij} = -\mathbb{E} \left[\frac{\partial^2 l(\theta)}{\partial \theta_i \partial \theta_j} \right]$$

定义 **Jeffreys 先验**为:

$$p(\theta) \propto \sqrt{\det(I(\theta))}$$

(Jeffreys 不变性准则)

设参数变换为可微双射 $\phi = h(\theta)$ 。

若对参数 θ 采用 Jeffreys 先验

$$p(\theta) \propto \sqrt{\det(I(\theta))},$$

则由变量变换公式得到的 $p(\phi)$ 与直接基于参数 ϕ 的似然函数构造得到的 Jeffreys 先验一致。

证明:

设对数似然为 $l(\theta) = \log p(y | \theta)$ 。

在参数变换 $\phi = h(\theta)$ 下,

$$l(\phi) = \log p(y | \phi) = \log p(y | \theta = h^{-1}(\phi)).$$

Fisher 信息

$$\begin{aligned} I(\phi) &= \mathbb{E} \left[\left(\frac{\partial l(\phi)}{\partial \phi} \right)^2 \right] \\ &= \mathbb{E} \left[\left(\frac{\partial l(\theta)}{\partial \theta} \frac{d\theta}{d\phi} \right)^2 \right] \\ &= I(\theta) \left(\frac{d\theta}{d\phi} \right)^2. \end{aligned}$$

因此，根据 Jeffreys 先验的定义，我们有

$$p(\phi) \propto \sqrt{I(\phi)} = \sqrt{I(\theta)} \left| \frac{d\theta}{d\phi} \right|.$$

另一方面，由变量变换公式，

$$p(\phi) = p(\theta) \left| \frac{d\theta}{d\phi} \right| \propto \sqrt{I(\theta)} \left| \frac{d\theta}{d\phi} \right|.$$

两种方式得到的 $p(\phi)$ 完全一致.

1.2 共轭先验

设 $\mathcal{P}$ 是参数 θ 的一类先验分布族.

给定采样分布 $p(y | \theta)$.

若对于任意先验分布 $p(\theta) \in \mathcal{P}$, 我们都有后验分布 $p(\theta | y) \in \mathcal{P}$,

则我们称 $\mathcal{P}$ 是采样分布 $p(y | \theta)$ 的**共轭先验族** (conjugate family).

尽管共轭先验不一定能真实反映我们对参数的先验认知, 但它可以极大地简化后验分布的计算.

不过, **共轭先验分布的混合形式** (mixtures of conjugate priors) 通常具有很强的灵活性,

既可以较好地刻画复杂的先验信息, 又能保证计算的便利性,

参见 *A First Course in Bayesian Statistical Methods* 练习 3.4 & 3.5.

1.2.1 二项模型

设参数 θ 的取值范围为 $(0, 1)$, 先验分布为 $p(\theta)$.

设在任意给定参数 θ 的条件下, $Y_1, \dots, Y_n$ 条件独立同分布, 且分布为 $\text{Binomial}(1, \theta)$, 即

$$Y_1, \dots, Y_n | \theta \stackrel{\text{i.i.d.}}{\sim} \text{Binomial}(1, \theta), \quad \theta \in (0, 1),$$

并记 $\bar{Y} := \sum_{i=1}^n Y_i/n$, $\bar{y} := \sum_{i=1}^n y_i/n$,

则根据 Bayes 法则可知后验分布为:

$$\begin{aligned} p(\theta | y_1, \dots, y_n) &= \frac{p(y_1, \dots, y_n | \theta)p(\theta)}{p(y_1, \dots, y_n)} \\ &= \frac{(\prod_{i=1}^n p(y_i | \theta)) \cdot p(\theta)}{p(y_1, \dots, y_n)} \\ &= \frac{(\prod_{i=1}^n \theta^{y_i} (1 - \theta)^{1-y_i}) \cdot p(\theta)}{p(y_1, \dots, y_n)} \\ &= \frac{\theta^{\sum_{i=1}^n y_i} (1 - \theta)^{n - \sum_{i=1}^n y_i} p(\theta)}{p(y_1, \dots, y_n)} \\ &= \frac{\theta^{n\bar{y}} (1 - \theta)^{n(1-\bar{y})} p(\theta)}{p(y_1, \dots, y_n)} \\ &\propto \theta^{n\bar{y}} (1 - \theta)^{n(1-\bar{y})} p(\theta), \end{aligned}$$

其中

$$\begin{aligned} p(y_1, \dots, y_n) &= \int_0^1 p(y_1, \dots, y_n | \tilde{\theta}) p(\tilde{\theta}) d\tilde{\theta} \\ &= \int_0^1 \tilde{\theta}^{n\bar{y}} (1 - \tilde{\theta})^{n(1-\bar{y})} p(\tilde{\theta}) d\tilde{\theta}. \end{aligned}$$

为了使后验分布与先验分布属于同一分布族,

先验密度 $p(\theta)$ 必须与似然函数 $p(y_1, \dots, y_n | \theta)$ 在 θ 上具有相同的函数形式, 即

$$p(\theta) \propto \theta^{a-1} (1 - \theta)^{b-1}, \quad a > 0, b > 0.$$

这正是 Beta 分布的密度函数的核 (kernel).

为验证上述推测，我们令参数 $\theta \sim \text{Beta}(a, b)$ ，即先验分布

$$p(\theta) = \frac{1}{B(a, b)} \theta^{a-1} (1 - \theta)^{b-1}, \quad 0 < \theta < 1,$$

其中 Beta 函数

$$B(a, b) = \int_0^1 t^{a-1} (1 - t)^{b-1} dt.$$

将 Beta 先验代入后验密度，有

$$\begin{aligned} p(\theta | y_1, \dots, y_n) &\propto \theta^{n\bar{y}} (1 - \theta)^{n(1-\bar{y})} \cdot \theta^{a-1} (1 - \theta)^{b-1} \\ &= \theta^{a+n\bar{y}-1} (1 - \theta)^{b+n(1-\bar{y})-1}. \end{aligned}$$

这仍然是 Beta 分布的核，因此

$$\theta | y_1, \dots, y_n \sim \text{Beta}(a + n\bar{y}, b + n(1 - \bar{y})).$$

设 $\tilde{Y}$ 是在相同条件下、但独立于已观测样本的新观测，即

$$\tilde{Y} | \theta \sim \text{Binomial}(1, \theta), \quad \tilde{Y} \perp (Y_1, \dots, Y_n) | \theta.$$

根据全期望公式可知， $\tilde{Y}$ 的后验均值为

$$\begin{aligned} \mathbb{E}(\tilde{Y} | y_1, \dots, y_n) &= \mathbb{E}(\mathbb{E}(\tilde{Y} | \theta) | y_1, \dots, y_n) \\ &= \mathbb{E}(\theta | y_1, \dots, y_n) \\ &= \mathbb{E}(\text{Beta}(a + n\bar{y}, b + n(1 - \bar{y}))) \\ &= \frac{a + n\bar{y}}{a + n\bar{y} + b + n(1 - \bar{y})} \\ &= \frac{a + n\bar{y}}{a + b + n} \\ &= \frac{a + b}{a + b + n} \cdot \frac{a}{a + b} + \frac{n}{a + b + n} \cdot \bar{y} \\ &= w_{\text{prior}} \cdot \mathbb{E}_{\text{prior}}(\tilde{Y}) + w_{\text{sample}} \cdot \bar{y}. \end{aligned}$$

换言之，我们有

$$\mathbb{E}(\tilde{Y} | y_1, \dots, y_n) = w_{\text{prior}} \cdot \mathbb{E}_{\text{prior}}(\tilde{Y}) + w_{\text{sample}} \cdot \bar{Y},$$

其中

$$w_{\text{prior}} = \frac{a + b}{a + b + n}, \quad w_{\text{sample}} = \frac{n}{a + b + n}, \quad w_{\text{prior}} + w_{\text{sample}} = 1.$$

- $\mathbb{E}_{\text{prior}}(\tilde{Y}) = \mathbb{E}_{\text{prior}}(\mathbb{E}(\tilde{Y} | \theta)) = \mathbb{E}_{\text{prior}}(\theta) = a/(a + b)$ 表示先验分布的均值
- $\bar{Y} = \sum_{i=1}^n Y_i / n$ 表示样本均值
- $a + b$ 可解释为先验所对应的 "等效样本量"
- n 为真实样本量

这表明后验均值 (即后验预测成功概率) 是先验均值与样本均值的加权平均，权重由样本量决定。

- 当 $n \ll a + b$ 时， $\mathbb{E}(\tilde{Y} | Y_1, \dots, Y_n) \approx \mathbb{E}_{\text{prior}}(\tilde{Y})$.

这意味着当样本量较小时，先验对后验预测起主导作用。

- 当 $n \gg a + b$ 时， $\mathbb{E}(\tilde{Y} | Y_1, \dots, Y_n) \approx \bar{Y}$ 。

这意味着当样本量足够大时，后验预测几乎只由样本决定，与先验选择无关。

1.2.2 Poisson 模型

设参数 θ 的取值范围为 $(0, \infty)$ ，先验分布为 $p(\theta)$ 。

设在任意给定参数 θ 的条件下， $Y_1, \dots, Y_n$ 条件独立同分布，且分布为 $\text{Poisson}(\theta)$ ，即

$$Y_1, \dots, Y_n | \theta \stackrel{\text{i.i.d.}}{\sim} \text{Poisson}(\theta), \quad \theta \in (0, \infty),$$

并记 $\bar{Y} := \sum_{i=1}^n Y_i / n$ ， $\bar{y} := \sum_{i=1}^n y_i / n$ ，

则根据 Bayes 法则可知后验分布为：

$$\begin{aligned} p(\theta | y_1, \dots, y_n) &= \frac{p(y_1, \dots, y_n | \theta)p(\theta)}{p(y_1, \dots, y_n)} \\ &= \frac{(\prod_{i=1}^n p(y_i | \theta)) \cdot p(\theta)}{p(y_1, \dots, y_n)} \\ &= \frac{(\prod_{i=1}^n e^{-\theta} \theta^{y_i} / y_i!) \cdot p(\theta)}{p(y_1, \dots, y_n)} \\ &= \frac{\theta^{\sum_{i=1}^n y_i} e^{-n\theta} p(\theta)}{p(y_1, \dots, y_n) \cdot \prod_{i=1}^n y_i!} \\ &= \frac{\theta^{n\bar{y}} e^{-n\theta} p(\theta)}{p(y_1, \dots, y_n) \cdot \prod_{i=1}^n y_i!} \\ &\propto \theta^{n\bar{y}} e^{-n\theta} p(\theta), \end{aligned}$$

其中

$$\begin{aligned} p(y_1, \dots, y_n) &= \int_0^\infty p(y_1, \dots, y_n | \tilde{\theta}) p(\tilde{\theta}) d\tilde{\theta} \\ &= \frac{1}{\prod_{i=1}^n y_i!} \int_0^\infty \tilde{\theta}^{n\bar{y}} e^{-n\tilde{\theta}} p(\tilde{\theta}) d\tilde{\theta}. \end{aligned}$$

为了使后验分布与先验分布属于同一分布族，

先验密度 $p(\theta)$ 必须与似然函数 $p(y_1, \dots, y_n | \theta)$ 在 θ 上具有相同的函数形式，即

$$p(\theta) \propto \theta^{a-1} e^{-b\theta}, \quad a > 0, b > 0.$$

这正是 Gamma 分布的密度函数的核 (kernel)。

为验证上述推测，我们令参数 $\theta \sim \text{Gamma}(a, b)$ ，即先验分布

$$p(\theta) = \frac{b^a}{\Gamma(a)} \theta^{a-1} e^{-b\theta}, \quad \theta > 0,$$

其中 Gamma 函数

$$\Gamma(a) = \int_0^\infty t^{a-1} e^{-t} dt.$$

将 Gamma 先验代入后验密度，有

$$\begin{aligned} p(\theta | y_1, \dots, y_n) &\propto \theta^{n\bar{y}} e^{-n\theta} \cdot \theta^{a-1} e^{-b\theta} \\ &= \theta^{a+n\bar{y}-1} e^{-(b+n)\theta}. \end{aligned}$$

这仍然是 Gamma 分布的核，因此

$$\theta | y_1, \dots, y_n \sim \text{Gamma}(a + n\bar{y}, b + n).$$

设 $\tilde{Y}$ 是在相同条件下、但独立于已观测样本的新观测，即

$$\tilde{Y} | \theta \sim \text{Poisson}(\theta), \quad \tilde{Y} \perp (Y_1, \dots, Y_n) | \theta.$$

根据全期望公式可知， $\tilde{Y}$ 的后验均值为

$$\begin{aligned} \mathbb{E}(\tilde{Y} | y_1, \dots, y_n) &= \mathbb{E}(\mathbb{E}(\tilde{Y} | \theta) | y_1, \dots, y_n) \\ &= \mathbb{E}(\theta | y_1, \dots, y_n) \\ &= \mathbb{E}(\text{Gamma}(a + n\bar{y}, b + n)) \\ &= \frac{a + n\bar{y}}{b + n} \\ &= \frac{b}{b + n} \cdot \frac{a}{b} + \frac{n}{b + n} \cdot \bar{y} \\ &= w_{\text{prior}} \cdot \mathbb{E}_{\text{prior}}(\tilde{Y}) + w_{\text{sample}} \cdot \bar{y}. \end{aligned}$$

换言之，我们有

$$\mathbb{E}(\theta | Y_1, \dots, Y_n) = w_{\text{prior}} \cdot \mathbb{E}_{\text{prior}}(\tilde{Y}) + w_{\text{sample}} \cdot \bar{Y},$$

其中

$$w_{\text{prior}} = \frac{b}{b + n}, \quad w_{\text{sample}} = \frac{n}{b + n}, \quad w_{\text{prior}} + w_{\text{sample}} = 1.$$

- $\mathbb{E}_{\text{prior}}(\tilde{Y}) = \mathbb{E}_{\text{prior}}(\mathbb{E}(\tilde{Y} | \theta)) = \mathbb{E}_{\text{prior}}(\theta) = a/b$ 表示先验分布的均值
- $\bar{Y} = \sum_{i=1}^n Y_i / n$ 表示样本均值
- b 可解释为先验所对应的 "等效样本量"
- n 为真实样本量

这表明后验均值是先验均值与样本均值的加权平均，权重由样本量决定。

- 当 $n \ll b$ 时， $\mathbb{E}(\tilde{Y} | Y_1, \dots, Y_n) \approx \mathbb{E}_{\text{prior}}(\tilde{Y})$.
这意味着当样本量较小时，先验对后验预测起主导作用。
- 当 $n \gg b$ 时， $\mathbb{E}(\tilde{Y} | Y_1, \dots, Y_n) \approx \bar{Y}$.
这意味着当样本量足够大时，后验预测几乎只由样本决定，与先验选择无关。

1.2.3 指数型分布族

设在任意给定参数 θ 的条件下, $Y_1, \dots, Y_n$ 条件独立同分布, 且分布为标准形式的指数型分布:

$$Y_1, \dots, Y_n \mid \theta \stackrel{\text{i.i.d.}}{\sim} p(y \mid \theta) = C(\theta) \exp(\theta T(y)) h(y), \quad \theta \in \Theta \subseteq \mathbb{R},$$

其中

- θ 为自然参数, 先验分布为 $p(\theta)$
- $C(\theta)$ 为配分函数
- $T(y)$ 为充分统计量
- $h(y)$ 为与 θ 无关的函数.

可以证明, $\mathbb{E}(T(Y) \mid \theta) = -\frac{d}{d\theta} \log(C(\theta)) = -C'(\theta)/C(\theta)$.

记 $\bar{T} := \sum_{i=1}^n T(Y_i)/n$, $\bar{t} := \sum_{i=1}^n T(y_i)/n$,

则根据 Bayes 法则可知后验分布为:

$$\begin{aligned} p(\theta \mid y_1, \dots, y_n) &= \frac{p(y_1, \dots, y_n \mid \theta) p(\theta)}{p(y_1, \dots, y_n)} \\ &= \frac{(\prod_{i=1}^n p(y_i \mid \theta)) \cdot p(\theta)}{p(y_1, \dots, y_n)} \\ &= \frac{(\prod_{i=1}^n C(\theta) \exp(\theta T(y_i)) h(y_i)) \cdot p(\theta)}{p(y_1, \dots, y_n)} \\ &= \frac{(C(\theta))^n \exp(\theta \sum_{i=1}^n T(y_i)) p(\theta)}{p(y_1, \dots, y_n)} \cdot \prod_{i=1}^n h(y_i) \\ &= \frac{(C(\theta))^n \exp(n\bar{t}\theta) p(\theta)}{p(y_1, \dots, y_n)} \cdot \prod_{i=1}^n h(y_i) \\ &\propto (C(\theta))^n \exp(n\bar{t}\theta) p(\theta), \end{aligned}$$

其中

$$\begin{aligned} p(y_1, \dots, y_n) &= \int_0^\infty p(y_1, \dots, y_n \mid \tilde{\theta}) p(\tilde{\theta}) d\tilde{\theta} \\ &= \prod_{i=1}^n h(y_i) \int_0^\infty (C(\tilde{\theta}))^n \exp(n\tilde{t}\tilde{\theta}) p(\tilde{\theta}) d\tilde{\theta}. \end{aligned}$$

为了使后验分布与先验分布属于同一分布族,

先验密度 $p(\theta)$ 必须与似然函数 $p(y_1, \dots, y_n \mid \theta)$ 在 θ 上具有相同的函数形式, 即

$$p(\theta) \propto (C(\theta))^{n_0} \exp(t_0 \theta),$$

其中

- t_0 是 "伪充分统计量"
- n_0 是 "等效样本量"

Poisson-Gamma 正是一个特例:

$$C(\theta) = e^{-\theta}, \quad T(y) = y, \quad (t_0, n_0) = (a - 1, b).$$

为验证上述推测，我们令自然参数 θ 的先验分布

$$p(\theta) = \frac{1}{C(t_0, n_0)} \cdot (C(\theta))^{n_0} \exp(t_0 \theta),$$

其中

$$C(t_0, n_0) = \int_{\Theta} (C(\theta))^{n_0} \exp(t_0 \tilde{\theta}) d\tilde{\theta}.$$

将上述先验代入后验密度，有

$$\begin{aligned} p(\theta | y_1, \dots, y_n) &\propto (C(\theta))^n \exp(n\bar{t}\theta) \cdot (C(\theta))^{n_0} \exp(t_0 \theta) \\ &= (C(\theta))^{n_0+n} \exp((t_0 + n\bar{t})\theta). \end{aligned}$$

这表明后验分布和先验分布具有相同类型的核。

1.3 Monte Carlo 近似

1.3.1 后验推断

当先验与似然构成共轭结构时，后验分布往往具有解析形式，从而可以直接计算后验均值、方差等统计量。

然而，在实际 Bayes 分析中，我们常常关心更为复杂的后验量，例如：

- 后验概率 $P(\theta \in A | y_1, \dots, y_n)$
- 参数函数的后验期望或方差 (如 $g(\theta)$)
- 缺失数据或未来观测的预测分布
- 多参数函数的后验分布，例如 $|\theta_1 - \theta_2|$ 、 θ_1/θ_2 、 $\max\{\theta_1, \dots, \theta_m\}$

这些量通常涉及高维积分，其解析计算往往非常困难甚至不可行。

Monte Carlo 方法提供了一种统一而通用的数值近似思路：

只要能够从后验分布中生成随机样本，就可以对几乎所有感兴趣的后验量进行任意精度的近似。

设 θ 为参数， $y_1, \dots, y_n$ 为观测数据，后验分布为 $p(\theta | y_1, \dots, y_n)$ 。

假设我们能够生成 S 个来自后验分布的独立同分布样本

$$\theta^{(1)}, \dots, \theta^{(S)} \stackrel{\text{i.i.d.}}{\sim} p(\theta | y_1, \dots, y_n).$$

设 $g(\theta)$ 为任意可积函数，根据**大数定律**，

$$\frac{1}{S} \sum_{s=1}^S g(\theta^{(s)}) \xrightarrow{\text{a.s.}} \mathbb{E}[g(\theta) | y_1, \dots, y_n] = \int g(\theta) p(\theta | y_1, \dots, y_n) d\theta, \quad S \rightarrow \infty.$$

由此可得以下常用近似结果：

- **后验均值：**

$$\bar{\theta} = \frac{1}{S} \sum_{s=1}^S \theta^{(s)} \xrightarrow{\text{a.s.}} \mathbb{E}[\theta | y_1, \dots, y_n], \quad S \rightarrow \infty.$$

- **后验方差：**

$$\hat{\sigma}^2 = \frac{1}{S-1} \sum_{s=1}^S (\theta^{(s)} - \bar{\theta})^2 \xrightarrow{\text{a.s.}} \text{Var}(\theta | y_1, \dots, y_n), \quad S \rightarrow \infty.$$

- **后验概率:**

$$\frac{1}{S} \#\{\theta^{(s)} \leq c\} \xrightarrow{\text{a.s.}} \text{P}(\theta \leq c | y), \quad S \rightarrow \infty.$$

- **后验分位数:**

样本的经验分位数近似对应的后验分位数

- **后验分布本身:**

Monte Carlo 样本的经验分布近似 $p(\theta | y)$

因此, 只要 Monte Carlo 样本量 S 足够大, 几乎所有感兴趣的后验量都可以被任意精度地近似.

1.3.2 后验预测

预测分布描述的是未来或未观测随机变量 $\tilde{Y}$ 的不确定性.

在尚未观察任何数据之前, 预测分布定义为:

$$p(\tilde{y}) = \int p(\tilde{y} | \theta) p(\theta) d\theta.$$

该分布不依赖观测数据, 只依赖于先验分布 $p(\theta)$, 常用于先验合理性检验.

例如在 Poisson-Gamma 共轭模型中, 若 $\tilde{Y} | \theta \sim \text{Poisson}(\theta)$, $\theta \sim \text{Gamma}(a, b)$, 则先验预测分布为 $\tilde{Y} \sim \text{Negative Binomial}(a, b)$.

在观察到样本 $(Y_1, \dots, Y_n) = (y_1, \dots, y_n)$ 后, 新观测 $\tilde{Y}$ 的预测分布为:

$$p(\tilde{y} | y_1, \dots, y_n) = \int p(\tilde{y} | \theta) p(\theta | y_1, \dots, y_n) d\theta.$$

例如在 Poisson-Gamma 共轭模型中,

后验预测分布为 $\tilde{Y} | y \sim \text{Negative Binomial}(a + \sum_{i=1}^n y_i, b + n)$.

在复杂模型中, 后验分布 $p(\theta | y)$ 以及条件分布 $p(\tilde{y} | \theta)$ 往往可以解析计算,

或至少能够通过数值方法进行有效采样,

但后验预测分布 $p(\tilde{y} | y) = \int p(\tilde{y} | \theta) p(\theta | y) d\theta$ 通常难以直接解析求解或直接采样.

此时, Monte Carlo 方法提供了一种**间接但通用**的解决方案,

通过随机模拟将参数不确定性自然传播到预测变量中.

对 $s = 1, \dots, S$ 重复以下步骤:

- ① **参数采样:** $\theta^{(s)} \sim p(\theta | y_1, \dots, y_n)$
- ② **条件预测采样:** $\tilde{y}^{(s)} \sim p(\tilde{y} | \theta^{(s)})$

最终得到后验预测分布 $p(\tilde{Y} | y)$ 的 Monte Carlo 样本 $\{\tilde{y}^{(1)}, \dots, \tilde{y}^{(S)}\}$.

当 $S \rightarrow \infty$ 时, 这些样本可用于一致地近似后验预测分布的各类特征.

例如，设女性群体按学历分为两组，组 $g = 0$ 代表低学历，组 $g = 1$ 代表高学历。

对每一组 g ，观测到样本 $\mathcal{D}_g = \{Y_{g,1}, \dots, Y_{g,n_g}\}$ ，

其中 $Y_{g,i}$ 代表第 i 位学历为 g 的女性终生生育的子女个数。

分别为两组人群指定先验 (以共轭 Gamma 为例):

$$\Theta_g \sim \text{Gamma}(a_g, b_g), \quad g \in \{0, 1\},$$

并假设两组人群的先验独立。

在观测数据 $\mathcal{D}_g$ 后，后验分布为

$$\Theta_g \mid \mathcal{D}_g \sim \text{Gamma}\left(a_g + \sum_{i=1}^{n_g} Y_{g,i}, b_g + n_g\right), \quad g \in \{0, 1\}.$$

分别生成样本量为 S 的 Monte Carlo 样本:

$$\tilde{y}_g^{(s)} \sim p(\tilde{Y}_g \mid \theta_g^{(s)}), \quad \theta_g^{(s)} \sim p(\Theta_g \mid \mathcal{D}_g), \quad s = 1, \dots, S, \quad g \in \{0, 1\}.$$

得到联合后验分布 $p(\Theta_0, \Theta_1 \mid \mathcal{D}_0, \mathcal{D}_1)$ 的 Monte Carlo 样本 $\{(\theta_0^{(s)}, \theta_1^{(s)})\}_{s=1}^S$ ，

同时也得到联合后验预测分布 $p(\tilde{Y}_0, \tilde{Y}_1 \mid \mathcal{D}_0, \mathcal{D}_1)$ 的 Monte Carlo 样本 $\{(y_0^{(s)}, y_1^{(s)})\}_{s=1}^S$ 。

基于这些 Monte Carlo 样本，我们可以做各种事情，

例如近似计算 $P(\Theta_0 > \Theta_1 \mid \mathcal{D}_0, \mathcal{D}_1)$ 和 $P(\tilde{Y}_0 > \tilde{Y}_1 \mid \mathcal{D}_0, \mathcal{D}_1)$ ，

从而分别刻画学历差异在参数层面和预测层面对生育水平的影响。

The End