

FDU 数据同化 1. 单参数模型

本文参考以下教材:

- A First Course in Bayesian Statistical Methods (P. Hoff) Chapter 1, 2, 3, 4
- 《数理统计讲义》(郑明, 陈子毅, 汪嘉冈) 第 1 章

欢迎批评指正!

All models are wrong, but some are useful. — Box & Draper

1.1 基础知识

1.1.1 Bayes 法则

从某种意义上说, 概率 (probability) 是信念 (belief) 的数学表示, 而 Bayes 法则提供了一种在获得新信息后对信念进行更新的方法. 通过 Bayes 法则进行归纳学习的过程称为 **Bayes 推断** (Bayesian inference).

设总体特征可通过参数 θ 来表示.

记所有可能的参数值所构成的集合为 Θ , 称为**参数空间** (parameter space).

对于任意 $\theta \in \Theta$, 记**先验分布** (prior distribution) 的概率 (密度) 为 $p(\theta)$, 代表我们在观测之前对 " θ 是总体的真实参数" 这一命题的信念.

记所有可能的样本集合所构成的集合为 $\mathcal{Y}$, 称为**样本空间** (sample space).

对于任意 $\theta \in \Theta$ 和 $y \in \mathcal{Y}$, 记**采样分布** (sampling distribution) 的概率 (密度) 为 $p(y | \theta)$, 代表我们在已知 θ 为总体的真实参数的条件下, 对 "观测到 y " 这一命题的信念, 同时也代表我们在已观测到样本集合 y 的条件下, 对当前参数值 θ 进行更新的依据. 在后一种意义下, 我们通常将 $p(y | \theta)$ 称为**似然** (likelihood).

给定样本集合 y , 我们便可计算**后验分布** (posterior distribution) 的概率 (密度):

$$\begin{aligned} \text{posterior} &= p(\theta | y) \\ &= \frac{p(y | \theta)p(\theta)}{p(y)} \\ &= \frac{p(y | \theta)p(\theta)}{\int_{\Theta} p(y | \tilde{\theta})p(\tilde{\theta})d\tilde{\theta}} \\ &\propto \text{likelihood} \times \text{prior}, \end{aligned}$$

它代表我们在已观测到样本集合 y 的条件下, 对 " θ 是总体的真实参数" 这一命题的信念.

值得注意的是, Bayes 法则并不会告诉我们最初的信念应该是什么;

它所揭示的是, 当我们获得新的信息之后, 这些信念应该如何更新.

Cox 和 Savage 证明了, 如果先验 $p(\theta)$ 和似然 $p(y | \theta)$ 均来源于一个理性个体的信念, 那么在给定新的信息 y 的情况下, Bayes 法则是更新该个体关于 θ 的信念的最优方法.

然而, 在实际的数据分析中, 先验 $p(\theta)$ 通常根据经验选取, 或出于计算便利而加以设计.

那么问题来了: 当先验 $p(\theta)$ 可能并不恰当时, Bayes 推断是否依然合理?

事实上, 后面我们会说明, 只要样本量足够大, 先验的影响便可忽略不计.

1.1.2 可交换性

记随机变量 $Y_1, \dots, Y_n$ 的联合概率密度为 $p(y_1, \dots, y_n)$.

若对于 $\{1, \dots, n\}$ 的任意排列 $\pi = (\pi_1, \dots, \pi_n)$,

我们都有 $p(y_{\pi_1}, \dots, y_{\pi_n}) = p(y_1, \dots, y_n)$ 成立,

则我们称 $Y_1, \dots, Y_n$ 是**可交换的** (exchangeable),

换言之, 下标所标识的顺序不包含关于结果的任何信息.

当标签不代表时间、空间等信息时, 假设样本具有可交换性是合理的.

进一步, 我们称序列 $\{Y_n\}_{n=1}^{\infty}$ 是可交换的,

如果其有限维联合分布对任意有限个指标的排列都保持不变.

(de Finetti 定理)

当且仅当 $\theta \in \Theta$ 服从某个先验分布 $p(\theta)$,

且在给定 $\theta \in \Theta$ 的条件下, 随机变量序列 $\{Y_n\}$ 条件独立同分布时,

(在不再以 θ 为条件的情况下) $\{Y_n\}$ 是可交换的.

- 充分性证明:

设 $\theta \in \Theta$ 服从某个先验分布 $p(\theta)$,

且在给定 $\theta \in \Theta$ 的条件下, 随机变量序列 $\{Y_n\}$ 条件独立同分布,

则对于任意正整数 $n \geq 2$ 和 $\pi \in S_n$ (其中 S_n 代表所有 $\{1, \dots, n\}$ 的排列群), 我们都有:

$$\begin{aligned} p(y_{\pi_1}, \dots, y_{\pi_n}) &= \int_{\Theta} p(y_{\pi_1}, \dots, y_{\pi_n} \mid \theta) d\theta \quad (\text{definition of marginal probability}) \\ &= \int_{\Theta} \left\{ \prod_{i=1}^n p(y_{\pi_i} \mid \theta) \right\} d\theta \quad (Y_1, \dots, Y_n \text{ are conditionally i.i.d.}) \\ &= \int_{\Theta} \left\{ \prod_{i=1}^n p(y_i \mid \theta) \right\} d\theta \quad (\text{the commutative law of multiplication}) \\ &= p(y_1, \dots, y_n). \end{aligned}$$

因此随机变量序列 $\{Y_n\}$ 是可交换的.

- 简单起见, 我们这里并不给出必要性证明, 详见 [An Elementary Proof Of de Finetti's Theorem](#).

特殊地, 独立同分布的随机变量序列一定是可交换的.

1.1.3 常用分布

Bernoulli 分布 Bernoulli($1, p$), 即 0, 1 两点分布, 满足:

$$\begin{aligned} P\{X = k\} &= p^k(1-p)^{1-k} \quad (k = 0, 1) \\ M_X(t) &= pe^t + (1-p) \\ \varphi_X(t) &= pe^{it} + (1-p) \\ \mathbb{E}[X^k] &= p \quad (\forall k = 1, 2, \dots) \\ \text{Var}[X] &= p(1-p) \end{aligned}$$

二项分布 Bernoulli(n, p) 可由 n 个独立同分布的 Bernoulli 随机变量的加和得到, 它满足:

$$P\{X = k\} = \binom{n}{k} p^k (1-p)^{n-k} \quad (k = 0, 1, \dots, n)$$

$$M_X(t) = (pe^t + (1-p))^n$$

$$\varphi_X(t) = (pe^{it} + (1-p))^n$$

$$\mathbb{E}[X] = np$$

$$\text{Var}[X] = np(1-p)$$

Poisson 分布 $\text{Poisson}(\lambda)$ 是二项分布 $B(n, p)$ 在 n 很大而 p 很小时的近似分布, 参数 $\lambda \approx np > 0$. 它满足:

$$P\{X = k\} = \frac{\lambda^k}{k!} e^{-\lambda}, \quad k = 0, 1, \dots$$

$$M_X(t) = e^{\lambda(e^t - 1)}$$

$$\varphi_X(t) = e^{\lambda(e^{it} - 1)}$$

$$\mathbb{E}[X] = \lambda$$

$$\text{Var}[X] = \lambda$$

正态分布 $\mathcal{N}(\mu, \sigma^2)$ 满足:

$$P\{X = x\} = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

$$M_X(t) = \exp\left(\frac{\sigma^2 t^2}{2} + \mu t\right)$$

$$\varphi_X(t) = \exp\left(-\frac{\sigma^2 t^2}{2} + i\mu t\right)$$

$$\mathbb{E}[X] = \mu$$

$$\text{Var}[X] = \sigma^2$$

定义 **Gamma 函数** 为:

$$\begin{cases} \Gamma(\alpha) = \int_0^{+\infty} e^{-t} t^{\alpha-1} dt \\ \text{dom}(\Gamma) = \{\alpha \in \mathbb{C} : \text{Re}(\alpha) > 0\}. \end{cases}$$

特殊地, 对于任意整数 n 有 $\Gamma(n) = (n-1)!$ 成立,
实际上 Γ 函数是阶乘函数在实数域和复数域上的推广.
它还具有如下性质:

$$\begin{cases} \Gamma(1/2) = \sqrt{\pi} \\ \Gamma(1) = 1 \\ \Gamma(\alpha + 1) = \alpha \Gamma(\alpha) \quad (\forall \alpha \in \text{dom}(\Gamma)). \end{cases}$$

Gamma 分布 $\text{Gamma}(\alpha, \lambda)$ 满足:

$$\begin{aligned}
P\{X = x\} &= \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x} \mathbb{1}_{(0, \infty)}(x) \\
M_X(t) &= \left(\frac{\lambda}{\lambda - t}\right)^\alpha \quad (t < \lambda) \\
\varphi_X(t) &= \left(\frac{\lambda}{\lambda - it}\right)^\alpha \\
\mathbb{E}[X^k] &= \frac{\Gamma(\alpha + k)}{\lambda^k \Gamma(\alpha)} \quad (\forall k = 1, 2, \dots) \\
\mathbb{E}[X] &= \frac{\alpha}{\lambda} \\
\text{Var}[X] &= \frac{\alpha}{\lambda^2}
\end{aligned}$$

定义 **Beta 函数**为:

$$\begin{cases} B(a, b) = \int_0^1 x^{a-1} (1-x)^{b-1} dx = \frac{\Gamma(a)\Gamma(b)}{\Gamma(a+b)} \\ \text{dom}(B) = \{a, b \in \mathbb{C} : \text{Re}(a) > 0, \text{Re}(b) > 0\} \end{cases}$$

(第一类) **Beta 分布** $\text{Beta}(a, b)$ 满足:

$$\begin{aligned}
M_X(t) &= \sum_{k=0}^{\infty} \frac{B(a+k, b)}{B(a, b)} \frac{t^k}{k!} = \frac{\Gamma(a+b)}{\Gamma(a)} \sum_{k=0}^{\infty} \frac{\Gamma(a+k)}{\Gamma(a+b+k)} \frac{t^k}{k!} \\
\varphi_X(t) &= \sum_{k=0}^{\infty} \frac{B(a+k, b)}{B(a, b)} \frac{(it)^k}{k!} = \frac{\Gamma(a+b)}{\Gamma(a)} \sum_{k=0}^{\infty} \frac{\Gamma(a+k)}{\Gamma(a+b+k)} \frac{(it)^k}{k!} \\
\mathbb{E}[X^k] &= \frac{B(a+k, b)}{B(a, b)} = \frac{\Gamma(a+b)}{\Gamma(a)} \frac{\Gamma(a+k)}{\Gamma(a+b+k)} \\
\mathbb{E}[X] &= \frac{a}{a+b} \\
\mathbb{E}[X^2] &= \frac{a(a+1)}{(a+b)(a+b+1)} \\
\text{Var}[X] &= \frac{ab}{(a+b)^2(a+b+1)}
\end{aligned}$$

特殊地, $\text{Beta}(1, 1)$ 即为标准均匀分布 $\text{Uniform}(0, 1)$.

考虑含参数 θ 的分布族 $\mathcal{F}_X = \{F_X(\theta) : \theta \in \Theta\}$.

若其概率质量函数 (或概率密度函数) 可表示为:

$$p(x; \theta) = C(\theta) \exp \left\{ \sum_{i=1}^k Q_i(\theta) T_i(x) \right\} h(x) \quad (\forall \theta \in \Theta),$$

其中 $\{T_i(x)\}_{i=1}^k$ 和 $h(x)$ 仅为 x 的函数, 而 $C(\theta)$ 和 $\{Q_i(\theta)\}_{i=1}^k$ 仅为 θ 的函数, 则我们称分布族 $\mathcal{F}_X$ 为**指数型分布族** (简称指数族).

特殊地, 如果 $Q_i(\theta) = \theta_i$, $1 \leq i \leq k$, 则称其为**指数族的标准形式**.

二项分布、Poisson 分布、正态分布和 (第一类) Beta 分布都是指数型分布.

1.1.4 充分统计量

设样本 X 的可能分布族为 $\mathcal{F}_X = \{F_X(\theta) : \theta \in \Theta\}$.

若 X 关于 $T(X)$ 的条件分布与 θ 无关,

则我们称 $T(X)$ 为 (分布族 $\mathcal{F}_X$) 关于 θ 的**充分统计量**.

(因子化定理, 数理统计讲义 命题 1.5.6)

设样本的可能分布族为 $\mathcal{F}_X = \{f_X(x; \theta) : \theta \in \Theta\}$,

其中 $f_X(x; \theta)$ 为分布密度或离散的概率分布,

则统计量 $T = T(X)$ 为分布族 $\mathcal{F}_X$ 参数 θ 的**充分统计量**的**充要条件**是:

对于任意 $\theta \in \Theta$, $f_X(x; \theta)$ 都可分解为 $g(T(x); \theta) \cdot h(x)$, 其中 $h(x)$ 是与 θ 无关的**非负函数**.

- (数理统计讲义 例 1.5.2)

设 $X = (X_1, X_2, \dots, X_n)$ 为取自 Bernoulli 分布族 $\{B(1, p) : p \in (0, 1)\}$ 总体的简单随机样本,
则样本均值 $\bar{X}_n = \sum_{i=1}^n X_i/n$ 是参数 p 的充分统计量.

- (数理统计讲义 例 1.5.7)

设 $X = (X_1, \dots, X_n)$ 为取自 Poisson 分布族 $\{\text{Poisson}(\lambda) : \lambda > 0\}$ 总体的简单随机样本,
则样本均值 $\bar{X}_n = \sum_{i=1}^n X_i/n$ 是参数 λ 的充分统计量.

- (数理统计讲义 例 1.5.8)

设 $X = (X_1, \dots, X_n)$ 为取自正态分布族 $\{\mathcal{N}(\mu, \sigma^2) : \mu \in \mathbb{R}, \sigma^2 > 0\}$ 的简单随机样本,
则 $T(X) = (\bar{X}_n, S_n^{*2})$ 是参数 (μ, σ^2) 的充分统计量,
其中 $S_n^{*2} = \sum_{i=1}^n (X_i - \bar{X}_n)^2 / (n - 1)$ 是已修偏的样本方差.

- (数理统计讲义 例 1.5.10)

设 $X = (X_1, \dots, X_n)$ 为取自指数型分布族 $\{p(x; \theta), \theta \in \Theta\}$ 的简单随机样本,
其中:

$$p(x; \theta) = C(\theta) \exp \left\{ \sum_{j=1}^k Q_j(\theta) T_j(x) \right\} h(x) \quad (\forall \theta \in \Theta),$$

则 $T(X) = (\sum_{i=1}^n T_1(X_i), \dots, \sum_{i=1}^n T_k(X_i))$ 是参数 θ 的充分统计量.

1.2 共轭先验

设 $\mathcal{P}$ 是参数 θ 的一类先验分布族.

给定采样分布 $p(y | \theta)$.

若对于任意先验分布 $p(\theta) \in \mathcal{P}$, 我们都有后验分布 $p(\theta | y) \in \mathcal{P}$,

则我们称 $\mathcal{P}$ 是采样分布 $p(y | \theta)$ 的**共轭先验族** (conjugate family).

尽管共轭先验不一定能真实反映我们对参数的先验认知, 但它可以极大地简化后验分布的计算.

不过, **共轭先验分布的混合形式** (mixtures of conjugate priors) 通常具有很强的灵活性,

既可以较好地刻画复杂的先验信息, 又能保证计算的便利性,

参见 *A First Course in Bayesian Statistical Methods* 练习 3.4 & 3.5.

1.2.1 二项模型

设参数 θ 的取值范围为 $(0, 1)$, 先验分布为 $p(\theta)$.

设在任意给定参数 θ 的条件下, $Y_1, \dots, Y_n$ 条件独立同分布, 且分布为 $\text{Bernoulli}(1, \theta)$, 即

$$Y_1, \dots, Y_n \mid \theta \stackrel{\text{i.i.d.}}{\sim} \text{Bernoulli}(\theta), \quad \theta \in (0, 1),$$

并记 $\bar{Y} := \sum_{i=1}^n Y_i/n$, $\bar{y} := \sum_{i=1}^n y_i/n$,

则根据 Bayes 法则可知后验分布为:

$$\begin{aligned} p(\theta \mid y_1, \dots, y_n) &= \frac{p(y_1, \dots, y_n \mid \theta)p(\theta)}{p(y_1, \dots, y_n)} \\ &= \frac{\theta^{\sum_{i=1}^n y_i} (1 - \theta)^{n - \sum_{i=1}^n y_i} p(\theta)}{p(y_1, \dots, y_n)} \\ &= \frac{\theta^{n\bar{y}} (1 - \theta)^{n(1-\bar{y})} p(\theta)}{p(y_1, \dots, y_n)} \\ &\propto \theta^{n\bar{y}} (1 - \theta)^{n(1-\bar{y})} p(\theta), \end{aligned}$$

其中

$$\begin{aligned} p(y_1, \dots, y_n) &= \int_0^1 p(y_1, \dots, y_n \mid \tilde{\theta}) p(\tilde{\theta}) d\tilde{\theta} \\ &= \int_0^1 \tilde{\theta}^{\sum_{i=1}^n y_i} (1 - \tilde{\theta})^{n - \sum_{i=1}^n y_i} p(\tilde{\theta}) d\tilde{\theta} \\ &= \int_0^1 \tilde{\theta}^{n\bar{y}} (1 - \tilde{\theta})^{n(1-\bar{y})} p(\tilde{\theta}) d\tilde{\theta}. \end{aligned}$$

为了使后验分布与先验分布属于同一分布族,

先验密度 $p(\theta)$ 必须与似然函数 $p(y_1, \dots, y_n \mid \theta)$ 在 θ 上具有相同的函数形式, 即

$$p(\theta) \propto \theta^{a-1} (1 - \theta)^{b-1}, \quad a > 0, b > 0.$$

这正是 Beta 分布的密度函数的核 (kernel).

为验证上述推测, 我们令参数 $\theta \sim \text{Beta}(a, b)$, 即先验分布

$$p(\theta) = \frac{1}{B(a, b)} \theta^{a-1} (1 - \theta)^{b-1}, \quad 0 < \theta < 1,$$

其中 Beta 函数

$$B(a, b) = \int_0^1 t^{a-1} (1 - t)^{b-1} dt.$$

将 Beta 先验代入后验密度, 有

$$\begin{aligned} p(\theta \mid y_1, \dots, y_n) &\propto \theta^{n\bar{y}} (1 - \theta)^{n(1-\bar{y})} \cdot \theta^{a-1} (1 - \theta)^{b-1} \\ &= \theta^{a+n\bar{y}-1} (1 - \theta)^{b+n(1-\bar{y})-1}. \end{aligned}$$

这仍然是 Beta 分布的核, 因此

$$\theta \mid y_1, \dots, y_n \sim \text{Beta}(a + n\bar{y}, b + n(1 - \bar{y})).$$

设 $\tilde{Y}$ 是在相同条件下、但独立于已观测样本的新观测，即

$$\tilde{Y} \mid \theta \sim \text{Bernoulli}(\theta), \quad \tilde{Y} \perp (Y_1, \dots, Y_n) \mid \theta.$$

根据全概率公式，后验预测成功概率为

$$\begin{aligned} P(\tilde{Y} = 1 \mid y_1, \dots, y_n) &= \int_0^1 P(\tilde{Y} = 1 \mid \theta) p(\theta \mid y_1, \dots, y_n) d\theta \\ &= \int_0^1 \theta p(\theta \mid y_1, \dots, y_n) d\theta \\ &= \mathbb{E}(\theta \mid y_1, \dots, y_n) \\ &= \mathbb{E}(\text{Beta}(a + n\bar{y}, b + n(1 - \bar{y}))) \\ &= \frac{a + n\bar{y}}{a + n\bar{y} + b + n(1 - \bar{y})} \\ &= \frac{a + n\bar{y}}{a + b + n} \\ &= \frac{a + b}{a + b + n} \cdot \frac{a}{a + b} + \frac{n}{a + b + n} \cdot \bar{y} \\ &= w_{\text{prior}} \cdot \mathbb{E}(\theta) + w_{\text{sample}} \cdot \bar{y}. \end{aligned}$$

换言之，我们有

$$\mathbb{P}(\tilde{Y} = 1 \mid Y_1, \dots, Y_n) = w_{\text{prior}} \cdot \mathbb{E}(\theta) + w_{\text{sample}} \cdot \bar{Y},$$

其中

$$w_{\text{prior}} = \frac{a + b}{a + b + n}, \quad w_{\text{sample}} = \frac{n}{a + b + n}, \quad w_{\text{prior}} + w_{\text{sample}} = 1.$$

- $\mathbb{E}(\theta) = a/(a + b)$ 表示先验分布的均值
- $\bar{Y} = \sum_{i=1}^n Y_i/n$ 表示样本均值
- $a + b$ 可解释为先验所对应的 "等效样本量"
- n 为真实样本量

这表明后验预测成功概率 (即后验均值) 是先验均值与样本均值的加权平均，权重由样本量决定。

- 当 $n \ll a + b$ 时, $P(\tilde{Y} = 1 \mid Y_1, \dots, Y_n) \approx \mathbb{E}(\theta)$.
这意味着当样本量较小时，先验对后验预测起主导作用。
- 当 $n \rightarrow \infty$ 时, $P(\tilde{Y} = 1 \mid Y_1, \dots, Y_n) \approx \bar{Y}$.
这意味着当样本量足够大时，后验预测几乎只由样本决定，与先验选择无关。

1.2.2 Poisson 模型

1.2.3 指数型分布族

1.3 Monte Carlo 近似
