

FDU 数值算法 2. 插值与拟合

本文根据邵美悦老师课堂笔记整理而成，并参考以下教材：

- 数值逼近 (蒋尔雄 & 赵风光 & 苏仰峰, 第 2 版) 第 2, 3, 4 章
- 数值分析 (李庆扬 & 王能超 & 易大义, 第 5 版) 第 2, 3 章

欢迎批评指正!

2.1 多项式插值

设有未知函数 $f(x)$

我们只知道其在 $n+1$ 个不同的点 $x_0, \dots, x_n$ 上的值为 $y_i := f(x_i)$ ($i = 0, \dots, n$)

给定 $z \neq x_0, \dots, x_n$, 我们可使用插值的方法计算 $f(z)$ 的近似值.

即找一个简单的已知解析表达式的函数 $P(\cdot)$ 使得:

- $P(x_i) = f(x_i) = y_i$ ($i = 0, \dots, n$)
- $P(z)$ 容易计算

我们称 $x_0, \dots, x_n$ 为**节点** (knote), 称 $P(\cdot)$ 为**插值函数**, 称 $f(\cdot)$ 为**被插函数**.

若限制 $P(\cdot)$ 为 n 次多项式, 则我们称 $P(\cdot)$ 为 $f(\cdot)$ 的 n 次插值多项式.

(多项式插值函数的优势在于它计算方便, 高阶导数简单, 且任何光滑函数都可通过多项式函数序列一致逼近)

2.1.1 理论分析

(数值逼近 定理 2.1)

由 $n+1$ 个不同的点及其取值 $(x_0, y_0), \dots, (x_n, y_n)$ 可唯一确定一个 n 次多项式 $P(\cdot)$

满足 $P(x_i) = y_i$ ($i = 0, \dots, n$)

- 值得注意的是, 存在无穷多个高于 n 次的多项式 $P(\cdot)$ 使得 $P(x_i) = y_i$ ($i = 0, \dots, n$)
因为如果 n 次多项式 $P_*(\cdot)$ 满足 $P_*(x_i) = y_i$ ($i = 0, \dots, n$),
那么对于任意多项式 $Q(\cdot)$, $P(x) = P_*(x) + Q(x) \prod_{i=0}^n (x - x_i)$ 也满足 $P_*(x_i) = y_i$ ($i = 0, \dots, n$)
Occam 剃刀原理告诉我们: "同等拟合程度的条件下, 简单的模型泛化能力更好".
因此我们希望多项式 $P(\cdot)$ 的次数不要太高, 不然高阶项可能会搞破坏的.
- 非齐次线性方程组 $Ax = b$ 并不总是通过系数矩阵的行列式为零 (即 $\det(A) = 0$) 来证明存在唯一解.
如果其齐次版本 $Ax = 0_n$ 是零解, 则也可以说明非齐次线性方程组 $Ax = b$
- **Proof:**
定义 n 次多项式 $P(\cdot)$:

$$P(x) := \sum_{k=0}^n a_k x^k \quad (a_n \neq 0)$$

代入 $P(x_i) = y_i$ ($i = 0, \dots, n$) 就有如下线性方程组:

$$\begin{aligned} P(x_i) &= \sum_{k=0}^n a_k x_i^k = y_i \quad (i = 0, \dots, n) \\ &\Updownarrow \\ Va &= \begin{bmatrix} 1 & x_0 & x_0^2 & \cdots & x_0^n \\ 1 & x_1 & x_1^2 & \cdots & x_1^n \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & x_n & x_n^2 & \cdots & x_n^n \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_n \end{bmatrix} = \begin{bmatrix} y_0 \\ y_1 \\ \vdots \\ y_n \end{bmatrix} = y \end{aligned}$$

其中未知量为 $a_0, a_1, \dots, a_n$.

其中 $\det(V)$ 为 Vandermonde 行列式:

(注意 $x_0, \dots, x_n$ 是 $n+1$ 个不同的点)

$$\det(V) = \begin{vmatrix} 1 & x_0 & x_0^2 & \cdots & x_0^n \\ 1 & x_1 & x_1^2 & \cdots & x_1^n \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & x_n^2 & \cdots & x_n^n \end{vmatrix} = \prod_{0 \leq i < j \leq n} (x_j - x_i) \neq 0$$

因此线性方程组 $Va = y$ 具有唯一解 $a_* = [a_*^{(0)}, a_*^{(1)}, \dots, a_*^{(n)}]^T$,

即根据样本点 $(x_0, y_0), \dots, (x_n, y_n)$ 可唯一确定一个 n 次多项式.

根据 Cramer 法则我们可以给出解的数学形式:

$$a_*^{(k)} := \frac{d_k}{\det(V)} \text{ where } d_k := \begin{vmatrix} 1 & x_0 & x_0^2 & \cdots & x_0^{k-1} & y_0 & x_0^{k+1} & \cdots & x_0^n \\ 1 & x_1 & x_1^2 & \cdots & x_1^{k-1} & y_1 & x_1^{k+1} & \cdots & x_1^n \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & x_n^2 & \cdots & x_n^{k-1} & y_n & x_n^{k+1} & \cdots & x_n^n \end{vmatrix} \quad (k = 0, \dots, n)$$

然而计算行列式的代价较高, 且 Vandermonde 矩阵比较病态, 因此舍入误差较高.

(使用 Gauss 消元法计算一个行列式的计算复杂度为 $O(n^3)$, 计算 $n+1$ 个解的计算复杂度为 $O(n^4)$)

因此在实际应用中我们使用更巧妙的方法确定多项式插值函数 $P(\cdot)$

2.1.2 Lagrange 途径

给定 $n+1$ 个不同的点及其取值 $(x_0, y_0), \dots, (x_n, y_n)$

定义 $\omega_n(x) := \prod_{i=0}^n (x - x_i)$

其导数为 $\omega'_n(x) := \sum_{i=0}^n \prod_{j \neq i} (x - x_j)$

我们构造:

$$\begin{aligned} l_k(x) &:= \frac{\omega_n(x)}{(x - x_k)\omega'_n(x_k)} \\ &= \frac{\prod_{i=0}^n (x - x_i)}{(x - x_k) \sum_{i=0}^n \prod_{j \neq i} (x_k - x_j)} \\ &= \prod_{i \neq k} \frac{x - x_i}{x_k - x_i} \end{aligned}$$

它满足:

$$l_k(x_i) = \begin{cases} 1, & i = k \\ 0, & i \neq k \end{cases}$$

粗略来说, $\{q_0(x), \dots, q_n(x)\}$ 就是 n 次多项式函数空间的一组基, 且在 $x_0, \dots, x_n$ 上有很多零.

可以验证以下多项式函数 $P(\cdot)$ 满足 $P(x_i) = y_i$ ($i = 0, \dots, n$):

$$\begin{aligned} P(x) &:= \sum_{k=0}^n y_k l_k(x) \\ &= \sum_{k=0}^n y_k \prod_{i \neq k} \frac{x - x_i}{x_k - x_i} \end{aligned}$$

我们称之为 **Lagrange 插值多项式**, 计算复杂度为 $O(n^2)$.

- 若事先以 $O(n^2)$ 的代价计算所有分母 $\prod_{j \neq k} \frac{1}{x_k - x_j}$ 并存储下来, 则后续每次计算一个函数值 $f(x)$ 只需 $O(n)$ 的代价.

(具体来说, 如果是已知点就直接返回其函数值, 如果是未知点就只需 $O(n)$ 的代价)

(重心坐标插值公式)

$$P(x) = \omega_n(x) \sum_{i=0}^n \frac{\lambda_i y_i}{x - x_i}$$

$$\text{where } \omega_n(x) = \prod_{i=0}^n (x - x_i) \text{ and } \lambda_i = \left(\prod_{j \neq i} (x_i - x_j) \right)^{-1}$$

Complexity: $O(n^2)$ for preparation + $O(n)$ for evaluation

- 病态的 Vandermonde 线性方程组也可以用 Lagrange 途径求解.


(数值笔记 例 2.1)

给定 $x_0 = 1, x_1 = 2, x_2 = 4$ 和 $y_0 = f(x_0) = 8, y_1 = f(x_1) = 1, y_2 = f(x_2) = 5$

则 2 次 Lagrange 插值多项式为:

$$\begin{aligned} P(x) &= \sum_{k=0}^2 y_k \prod_{j \neq k} \frac{x - x_j}{x_k - x_j} \\ &= y_0 \frac{(x - x_1)(x - x_2)}{(x_0 - x_1)(x_0 - x_2)} + y_1 \frac{(x - x_0)(x - x_2)}{(x_1 - x_0)(x_1 - x_2)} + y_2 \frac{(x - x_0)(x - x_1)}{(x_2 - x_0)(x_2 - x_1)} \\ &= 8 \cdot \frac{(x - 2)(x - 4)}{(1 - 2)(1 - 4)} + 1 \cdot \frac{(x - 1)(x - 4)}{(2 - 1)(2 - 4)} + 5 \cdot \frac{(x - 1)(x - 2)}{(4 - 1)(4 - 2)} \\ &= 3x^2 - 16x + 21 \end{aligned}$$

(插值多项式的应用: 证明 Hayashi 不等式)



在复平面上的插值公式为:

$$\begin{aligned} f(x) &= (x - P)(x - Q) \\ &= f(A) \frac{(x - B)(x - C)}{(A - B)(A - C)} + f(B) \frac{(x - A)(x - C)}{(B - A)(B - C)} + f(C) \frac{(x - A)(x - B)}{(C - A)(C - B)} \end{aligned}$$


注意到 $f(x) = (x - P)(x - Q)$ 的首项系数为 1, 于是我们有:

$$\begin{aligned}
& \frac{f(A)}{(A-B)(A-C)} + \frac{f(B)}{(B-A)(B-C)} + \frac{f(C)}{(C-A)(C-B)} = 1 \\
& \Downarrow \\
1 & \leq \left| \frac{f(A)}{cb} \right| + \left| \frac{f(B)}{ca} \right| + \left| \frac{f(C)}{ba} \right| \\
& = \frac{(A-P)(A-Q)}{bc} + \frac{(B-P)(B-Q)}{ac} + \frac{(C-P)(C-Q)}{ab} \\
& = \frac{a_1 a_2}{bc} + \frac{b_1 b_2}{ac} + \frac{c_1 c_2}{ab} \\
& \Downarrow \\
& abc \leq aa_1 a_2 + bb_1 b_2 + cc_1 c_2
\end{aligned}$$

2.1.3 Neville 途径

Neville 途径是一种用两个 $n-1$ 次插值多项式构造一个 n 次插值多项式的方法.

以 $x_0 = 1, x_1 = 2, x_2 = 4$ 和 $y_0 = f(x_0) = 8, y_1 = f(x_1) = 1, y_2 = f(x_2) = 5$ 为例:



给定 $n+1$ 个不同的点及其取值 $(x_0, y_0), \dots, (x_n, y_n)$

记 $P_{0,\dots,n-1}(\cdot)$ 为 $f(\cdot)$ 在 $x_0, x_1, \dots, x_{n-1}$ 上的插值多项式,

记 $P_{1,\dots,n}(\cdot)$ 为 $f(\cdot)$ 在 $x_1, x_2, \dots, x_n$ 上的插值多项式.

则 $f(\cdot)$ 在 $x_0, x_1, \dots, x_{n-1}, x_n$ 上的插值多项式为:

$$\begin{aligned}
P_{0,1,\dots,n-1,n}(x) &:= \frac{1}{x_n - x_0} \begin{vmatrix} x - x_0 & P_{0,\dots,n-1}(x) \\ x - x_n & P_{1,\dots,n}(x) \end{vmatrix} \\
&= \frac{x_n - x}{x_n - x_0} P_{0,\dots,n-1}(x) + \frac{x_0 - x}{x_0 - x_n} P_{1,\dots,n}(x)
\end{aligned}$$

显然 $P_{0,1,\dots,n-1,n}(x)$ 是 $P_{0,\dots,n-1}(x)$ 与 $P_{1,\dots,n}(x)$ 的仿射组合.

计算复杂度为 $O(n^2)$, 在关心内部的数值稳定性时会使用 (误差不那么容易放大)

- 特别地, 若 $x_0 \leq x_1 \leq \dots \leq x_n$, 且 $x_0 \leq x \leq x_n$,
则 $P_{0,1,\dots,n-1,n}(x)$ 是 $P_{0,\dots,n-1}(x)$ 与 $P_{1,\dots,n}(x)$ 的凸组合.
进一步, 这表明误差也是凸组合, 因此数值是比较稳定的.
- Neville 法的计算过程可以列表进行:

表 2.1

x	$f(x)$	$5-x$	
2	-8	3	$\frac{1}{4-2} \begin{vmatrix} 3 & -8 \\ 1 & 0 \end{vmatrix} = 4$
4	0	1	$\frac{1}{6-2} \begin{vmatrix} 3 & 4 \\ -1 & 4 \end{vmatrix} = 4$
			$\frac{1}{6-4} \begin{vmatrix} 1 & 0 \\ -1 & 8 \end{vmatrix} = 4$
6	8	-1	$\frac{1}{8-2} \begin{vmatrix} 3 & 4 \\ -3 & -2 \end{vmatrix} = 1$
			$\frac{1}{8-4} \begin{vmatrix} 1 & 4 \\ -3 & -2 \end{vmatrix} = -2$
8	64	-3	$\frac{1}{8-6} \begin{vmatrix} -1 & 8 \\ -3 & 64 \end{vmatrix} = -20$

2.1.4 Newton 途径

给定 $n+1$ 个不同的点及其取值 $(x_0, y_0), \dots, (x_n, y_n)$

考虑 n 次多项式:

$$P(x) = c_0 + c_1(x-x_0) + c_2(x-x_0)(x-x_1) + \dots + c_n(x-x_0)(x-x_1)\dots(x-x_{n-1})$$

令其满足 $P(x_i) = f(x_i) = y_i$ ($i = 0, \dots, n$), 则我们有:

$$y_0 = P(x_0) = c_0$$

$$y_1 = P(x_1) = c_0 + c_1(x_1 - x_0)$$

$\vdots$

$$y_{n-1} = P(x_{n-1}) = c_0 + c_1(x_{n-1} - x_0) + c_2(x_{n-1} - x_0)(x_{n-1} - x_1) + \dots + c_{n-1}(x_{n-1} - x_0)(x_{n-1} - x_1)\dots(x_{n-1} - x_{n-2})$$

$$y_n = P(x_n) = c_0 + c_1(x_n - x_0) + c_2(x_n - x_0)(x_n - x_1) + \dots + c_n(x_n - x_0)(x_n - x_1)\dots(x_n - x_{n-1})$$

我们从上至下可以依次求出 $c_0, c_1, \dots, c_n$, 十分方便.

• (一个简单的例子)

给定 $x_0 = 1, x_1 = 2, x_2 = 4$ 和 $y_0 = f(x_0) = 8, y_1 = f(x_1) = 1, y_2 = f(x_2) = 5$

定义 $P(x) = c_0 + c_1(x-x_0) + c_2(x-x_0)(x-x_1)$, 则我们有:

$$8 = y_0 = P(x_0) = c_0$$

$$1 = y_1 = P(x_1) = c_0 + c_1(x_1 - x_0) = c_0 + c_1$$

$$5 = y_2 = P(x_2) = c_0 + c_1(x_2 - x_0) + c_2(x_2 - x_0)(x_2 - x_1) = c_0 + 2c_1 + 6c_2$$

我们可以依次解得 $c_0 = 8, c_1 = -7, c_2 = 3$

因此 $P(x) = 8 - 7(x-1) + 3(x-1)(x-2)$

从上述计算过程中我们可以看出:

c_0 是 x_0 上零次插值的首项系数;

c_1 是 x_0, x_1 上一次插值的首项系数;

c_2 是 x_0, x_1, x_2 上二次插值的首项系数;

总之, c_k 是 $x_0, x_1, \dots, x_k$ 上 k 次插值的首项系数.

我们定义 $f[x_0, x_1, \dots, x_k] := c_k$ 是 $f(\cdot)$ 在 $x_0, x_1, \dots, x_k$ 上的 k 阶差商,

即 $x_0, x_1, \dots, x_k$ 上 k 次插值的首项系数.

根据 Lagrange 插值公式可知:

$$\begin{aligned}
P_{0,\dots,k}(x) &= \sum_{i=0}^k y_i \prod_{j \neq i} \frac{x - x_j}{x_i - x_j} \\
&= \sum_{i=0}^k y_i \frac{(x - x_0) \cdots (x - x_{i-1})(x - x_{i+1}) \cdots (x - x_k)}{(x_i - x_0) \cdots (x_i - x_{i-1})(x_i - x_{i+1}) \cdots (x_i - x_k)} \\
&\quad \bigg/ c_k = f[x_0, x_1, \dots, x_k] \\
&= \sum_{i=0}^k \frac{y_i}{(x_i - x_0) \cdots (x_i - x_{i-1})(x_i - x_{i+1}) \cdots (x_i - x_k)} \\
&= \sum_{i=0}^k y_i \prod_{j \neq i} \frac{1}{x_i - x_j}
\end{aligned}$$

- **(对称性)** $f(\cdot)$ 在 $x_0, \dots, x_k$ 上的 k 阶差商与 $x_0, \dots, x_k$ 的排列顺序无关。
- 若 $f(\cdot)$ 和 $g(\cdot)$ 在 $x_0, \dots, x_k$ 上的 k 阶差商为 $f[x_0, \dots, x_k]$ 和 $g[x_0, \dots, x_k]$, 则其线性组合 $\alpha f(\cdot) + \beta g(\cdot)$ 在 $x_0, \dots, x_k$ 上的差商即为 $\alpha f[x_0, \dots, x_k] + \beta g[x_0, \dots, x_k]$
- **(数值逼近 定理 2.2)**
 $f(\cdot)$ 在 $x_0, \dots, x_k$ 上的 k 阶差商为:

$$f[x_0, \dots, x_k] = \frac{f[x_1, \dots, x_k] - f[x_0, \dots, x_{k-1}]}{x_k - x_0}$$

我们可以从 $f[x_k] = f(x_k) = y_k$ 出发递归地求解 $f[x_0, \dots, x_k]$

有了差商的定义后, 我们就可将 **Newton 插值公式** 写为如下形式:

$$\begin{aligned}
P(x) &= f(x_0) + \sum_{k=1}^n f[x_0, x_1, \dots, x_k] \prod_{i=0}^{k-1} (x - x_i) \\
&= f(x_0) + f[x_0, x_1](x - x_0) + \cdots + f[x_0, x_1, \dots, x_n](x - x_0)(x - x_1) \cdots (x - x_{n-1}) \\
\text{where } f[x_0, x_1, \dots, x_k] &:= \sum_{i=0}^k y_i \prod_{j \neq i} \frac{1}{x_i - x_j}
\end{aligned}$$

实际计算时, 差商不是直接通过 $f[x_0, x_1, \dots, x_k] := \sum_{i=0}^k y_i \prod_{j \neq i} \frac{1}{x_i - x_j}$ 计算的 (否则就是 Lagrange 插值了) 它是从 $f[x_k] = f(x_k) = y_k$ 出发递归地求解 $f[x_0, \dots, x_k]$:

$$f[x_0, \dots, x_k] = \frac{f[x_1, \dots, x_k] - f[x_0, \dots, x_{k-1}]}{x_k - x_0}$$

所有差商的结果可以填入一个上三角阵 (按行填入不同阶的差商), 代价是 $O(n^2)$

因此本质上这是一个上三角线性方程组, 使用回代法求解的代价是 $O(n)$

因此 Newton 插值与 Lagrange 插值的重心形式具有相同的复杂度:

Complexity: $O(n^2)$ for preparation + $O(n)$ for evaluation

- **(递推形式)**

Newton 插值相对于 Lagrange 插值的优势是可以很方便地不断加入新数据点进行拟合。

$$\begin{aligned}
P_{0,\dots,n-1,n}(x) &= P_{0,\dots,n-1}(x) + f[x_0, x_1, \dots, x_n](x - x_0)(x - x_1) \cdots (x - x_{n-1}) \\
&= P_{0,\dots,n-1}(x) + \left(\sum_{i=0}^n y_i \prod_{j \neq i} \frac{1}{x_i - x_j} \right) \prod_{i=0}^{n-1} (x - x_i)
\end{aligned}$$

- **(一个简单的例子)**

给定 $x_0 = 1, x_1 = 2, x_2 = 4$ 和 $y_0 = f(x_0) = 8, y_1 = f(x_1) = 1, y_2 = f(x_2) = 5$

则各阶差商见下表: (图中编号是从 1 开始的, 与我们的约定有区别)

表 2.2

x_1	$f(x_1)$	$f(x_1, x_2)$	$f(x_1, x_2, x_3)$	$f(x_1, x_2, x_3, x_4)$	$f(x_1, x_2, x_3, x_4, x_5)$
x_2	$f(x_2)$	$f(x_2, x_3)$	$f(x_2, x_3, x_4)$	$f(x_2, x_3, x_4, x_5)$	
x_3	$f(x_3)$	$f(x_3, x_4)$	$f(x_3, x_4, x_5)$		
x_4	$f(x_4)$				
x_5	$f(x_5)$				

譬如: $x_1 = 1, x_2 = 2, x_3 = 4, f(x_1) = 8, f(x_2) = 1, f(x_3) = 5$.
各阶差商见表 2.3.

表 2.3

1	8		
2	1	-7	
4	5	2	3

即得 3 个点的 Newton 插值多项式

$$P(x) = 8 - 7(x - 1) + 3(x - 1)(x - 2).$$

于是 x_0, x_1, x_2 上的 2 次插值多项式为:

$$\begin{aligned} P(x) &= f(x_0) + f[x_0, x_1](x - x_0) + f[x_0, x_1, x_2](x - x_0)(x - x_1) \\ &= 8 - 7(x - 1) + 3(x - 1)(x - 2) \end{aligned}$$

2.1.5 A Higher View

我们之所以不用多项式基函数 $\{1, x, x^2, \dots, x^n\}$ 构造插值多项式是因为它的性质不好.

因此我们发展了 Lagrange 基函数和 Newton 基函数.

选取合适的节点和基函数是较好解决插值问题的关键.

Problem Setting: (Interpolation with a General Basis)

给定插值节点 $(x_1, y_1), \dots, (x_n, y_n) \in \mathbb{R}^d \times \mathbb{R}$ (其中 $x_1, \dots, x_n$ 互不相同)

考虑 $\mathbb{R}^d \mapsto \mathbb{R}$ 上的基函数 $\phi_1, \dots, \phi_n$

我们的目标是找到一个插值函数 $\phi(x) \in \text{span}\{\phi_1(x), \dots, \phi_n(x)\}$ 满足插值条件 $\phi(x_i) = y_i$ ($i = 1, \dots, n$)

Solution:

记 $\phi(x) = c_1\phi_1(x) + c_2\phi_2(x) + \dots + c_n\phi_n(x)$, 则根据插值条件我们有以下线性方程组:

$$\begin{bmatrix} \phi(x_1) \\ \phi(x_2) \\ \vdots \\ \phi(x_n) \end{bmatrix} = \begin{bmatrix} \phi_1(x_1) & \phi_2(x_1) & \cdots & \phi_n(x_1) \\ \phi_1(x_2) & \phi_2(x_2) & \cdots & \phi_n(x_2) \\ \vdots & \vdots & \ddots & \vdots \\ \phi_1(x_n) & \phi_2(x_n) & \cdots & \phi_n(x_n) \end{bmatrix} \begin{bmatrix} c_1 \\ c_2 \\ \vdots \\ c_n \end{bmatrix} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$$

在特定的节点和基函数下, 上述方程组可能存在特解.

常用的基函数如下:

- 多项式基函数
- 分段多项式基函数 (在某一段上是多项式, 在其他段上是零)
- 有理函数 (例如 Runge 函数 $y = (1 + 25x^2)^{-1}$, 在远端是代数衰减)
- (Homework 05 Problem 03)
径向基函数 (例如 Gauss 径向基函数 $y = \exp(-\|x\|_2^2)$ ($\forall x \in \mathbb{R}^d$), 在远端是指数衰减)

- 三角函数 (典型应用是 Fourier 插值)
- 小波函数 (wavelet functions)
例如 Haar 小波:

$$y = \begin{cases} 1, & 0 \leq x < \frac{1}{2} \\ -1, & \frac{1}{2} \leq x < 1 \\ 0, & \text{otherwise} \end{cases}$$

又例如窗口化 sinc 小波:

$$y = \text{sinc}(x)e^{-x^2}$$

$$\text{where } \text{sinc}(x) := \frac{\sin(\pi x)}{\pi x}$$

2.2 节点的选取

2.2.1 等距节点插值

若 $x_0, x_1, \dots, x_n$ 满足 $x_{i+1} - x_i = h$ ($i = 0, \dots, n-1$), 则我们称这些节点为**等距节点**, 称 h 为**步长**.

假设 $x_0 < x_1 < \dots < x_n$, 因此可记 $x_i = x_0 + ih$ ($i = 0, \dots, n$)

在等距节点的情况下, Newton 插值公式中的差商可用差分来代替, 以节省计算量:

(简单起见, 我们记 $\Delta^k f(x_i)$ 为 $\Delta^k f_i$)

- 一阶差分: $\Delta f_i = f_{i+1} - f_i$ ($i = 0, \dots, n-1$)
- 二阶差分: $\Delta^2 f_i = \Delta f_{i+1} - \Delta f_i$ ($i = 0, \dots, n-2$)

$$\begin{aligned} \Delta^2 f_i &= \Delta f_{i+1} - \Delta f_i \\ &= (f_{i+2} - f_{i+1}) - (f_{i+1} - f_i) \\ &= f_{i+2} - 2f_{i+1} + f_i \end{aligned}$$

- 三阶差分: $\Delta^3 f_i = \Delta^2 f_{i+1} - \Delta^2 f_i$ ($i = 0, \dots, n-3$)

$$\begin{aligned} \Delta^3 f_i &= \Delta^2 f_{i+1} - \Delta^2 f_i \\ &= (f_{i+3} - 2f_{i+2} + f_{i+1}) - (f_{i+2} - 2f_{i+1} + f_i) \\ &= f_{i+3} - 3f_{i+2} + 3f_{i+1} - f_i \end{aligned}$$

- k 阶差分: $\Delta^k f_i = \Delta^{k-1} f_{i+1} - \Delta^{k-1} f_i$ ($i = 0, \dots, n-k$)

用数学归纳法易证:

$$\begin{aligned} \Delta^k f_i &= f_{i+k} - \binom{k}{1} f_{i+k-1} + \binom{k}{2} f_{i+k-2} - \binom{k}{3} f_{i+k-3} + \dots + (-1)^{k-1} \binom{k}{k-1} f_{i+1} + (-1)^k f_i \\ &= \sum_{j=0}^k (-1)^j \binom{k}{j} f_{i+k-j} \end{aligned}$$

(数值逼近 定理 2.5)

在等距节点的情况下, 差商和差分的关系为:

$$f[x_0, x_1, \dots, x_k] = \frac{\Delta^k f_0}{h^k k!}$$

在等距节点的情况下, 我们用差分表代替差商表: (图中编号是从 1 开始的, 与我们的约定有区别)

表 2.6

x_1	f_1	Δf_1	$\Delta^2 f_1$	$\Delta^3 f_1$
$x_1 + h$	f_2	Δf_2	$\Delta^2 f_2$	
$x_1 + 2h$	f_3	Δf_3		
$x_1 + 3h$	f_4			

差分的计算不需要除法, 因而更加方便.

设 $x_0 < x_1 < \dots < x_n$

因此可记 $x_i = x_0 + ih$ ($i = 0, \dots, n$) 或 $x_i = x_n - (n - i)h$

利用差商和差分的关系, 我们可以将 Newton 插值公式重写为:

- ① 表初公式: (用于计算最小节点 x_0 附近的插值)

设 $x = x_0 + ph$, 于是 $x - x_i = (p - i)h$

$$\begin{aligned}
 P(x) &= f(x_0) + f[x_0, x_1](x - x_0) + \dots + f[x_0, x_1, \dots, x_k](x - x_0)(x - x_1) \dots (x - x_{k-1}) \\
 &\quad (\text{note that } f[x_0, x_1, \dots, x_k] = \frac{\Delta^k f_0}{h^k k!}) \\
 &= f_0 + \frac{\Delta f_0}{h} \cdot ph + \frac{\Delta^2 f_0}{h^2 2!} \cdot ph \cdot (p - 1)h + \dots + \frac{\Delta^k f_0}{h^k k!} \cdot ph \cdot (p - 1)h \dots (p - k + 1)h \\
 &= \binom{p}{0} f_0 + \binom{p}{1} \Delta f_0 + \binom{p}{2} \Delta^2 f_0 + \dots + \binom{p}{k} \Delta^k f_0 \\
 &= \sum_{i=0}^k \binom{p}{i} \Delta^i f_0 \\
 &\quad \text{where } \binom{p}{i} := \frac{p(p-1) \dots (p-i+1)}{i!}
 \end{aligned}$$

- ② 表末公式: (用于计算最大节点 x_n 附近的插值)

设 $x = x_n - ph$, 于是 $x - x_i = (p - i + n)h$

$$\begin{aligned}
 P(x) &= f(x_n) + f[x_n, x_{n-1}](x - x_n) + \dots + f[x_n, x_{n-1}, \dots, x_{n-k}](x - x_n)(x - x_{n-1}) \dots (x - x_{n-k+1}) \\
 &\quad (\text{note that } f[x_n, x_{n-1}, \dots, x_{n-k}] = \frac{\Delta^k f_{n-k}}{h^k k!}) \\
 &= f_n + \frac{\Delta f_{n-1}}{h} (-ph) + \frac{\Delta^2 f_{n-2}}{h^2 2!} \cdot (-ph) \cdot [-(p-1)h] + \dots + \frac{\Delta^k f_{n-k}}{h^k k!} (-ph) \cdot [-(p-1)h] \dots [-(p-k+1)h] \\
 &= \binom{p}{0} f_n - \binom{p}{1} \Delta f_{n-1} + \binom{p}{2} \Delta^2 f_{n-2} + \dots + (-1)^k \binom{p}{k} \Delta^k f_{n-k} \\
 &= \sum_{i=0}^k (-1)^i \binom{p}{i} \Delta^i f_{n-i} \\
 &\quad \text{where } \binom{p}{i} := \frac{p(p-1) \dots (p-i+1)}{i!}
 \end{aligned}$$

- ③ Stirling 公式: (用于计算中间节点 x_m 附近的插值)

设 $x = x_m + ph$ ([Stirling Interpolation Formula](#))

$$P(x) = f_m + \frac{p}{2}(\Delta f_m + \Delta f_{m-1}) + \frac{p^2}{2} \Delta^2 f_{m-1} + \frac{(p-1)p(p+1)}{6} \left(\frac{\Delta^3 f_{m-1} + \Delta^3 f_{m-2}}{2} \right) + \dots$$

2.2.2 Runge 现象

下面的定理给出了函数 $f(\cdot)$ 与其 n 次插值多项式 $P_n(\cdot)$ 之差的数学表示.

(数值逼近 定理 2.3)

给定 $n+1$ 个不同的点及其取值 $(x_0, y_0), \dots, (x_n, y_n)$

其中 $y_i = f(x_i)$ ($i = 0, \dots, n$), 且 $f(\cdot)$ 在 $x_0, \dots, x_n$ 附近连续.

则对于任意 x , 都有:

$$\begin{aligned} f(x) &= f(x_0) + f[x_0, x_1](x - x_0) + \dots + f[x_0, x_1, \dots, x_n] \prod_{i=0}^{n-1} (x - x_i) + f[x_0, x_1, \dots, x_n, x] \prod_{i=0}^n (x - x_i) \\ &= P_n(x) + f[x_0, x_1, \dots, x_n, x] \prod_{i=0}^n (x - x_i) \end{aligned}$$

$$\text{where } f[x_0, x_1, \dots, x_k] := \sum_{i=0}^k y_i \prod_{j \neq i} \frac{1}{x_i - x_j}$$

其中 $P_n(x) = f(x_0) + f[x_0, x_1](x - x_0) + \dots + f[x_0, x_1, \dots, x_n] \prod_{i=0}^{n-1} (x - x_i)$ 是 n 次插值多项式.

此公式可视为 Taylor 级数的推广:

Taylor 级数是 $f(x)$ 在一个点上的展开, 而插值多项式是 $f(x)$ 在多个点上的展开.

下面的定理给出了函数 $f(\cdot)$ 的差商与导数的关系.

(数值逼近 定理 2.4)

给定 $n+1$ 个不同的点及其取值 $(x_0, y_0), \dots, (x_n, y_n)$

记 $a := \min\{x_i : i = 0, \dots, n\}$ 和 $b := \max\{x_i : i = 0, \dots, n\}$

若 $f(x)$ 在 $[a, b]$ 上连续, 且在 (a, b) 上 n 阶可导, 则存在 $\xi \in (a, b)$ 使得:

$$f[x_0, x_1, \dots, x_n] = \frac{f^{(n)}(\xi)}{n!}$$

• **(数值逼近 定理 2.6, Homework 03 Problem 02)**

给定 $n+1$ 个不同的点及其取值 $(x_0, y_0), \dots, (x_n, y_n)$

若 $f(\cdot)$ 在 x_* 处 n 阶可导, 则我们有:

$$\lim_{(x_0, \dots, x_n) \rightarrow (x_*, \dots, x_*)} f[x_0, x_1, \dots, x_n] = \frac{f^{(n)}(x_*)}{n!}$$

• **(数值逼近 推论 2.3)**

给定 $n+1$ 个不同的点及其取值 $(x_0, y_0), \dots, (x_n, y_n)$

若 $f(x)$ 是 k 次多项式, 且 $n > k$, 则它的 n 阶差商 $f[x_0, x_1, \dots, x_n] = 0$

利用上述定理可将 **(数值逼近 定理 2.3)** 改进为:

给定 $n+1$ 个不同的点及其取值 $(x_0, y_0), \dots, (x_n, y_n)$

记 $a := \min\{x_i : i = 0, \dots, n\}$ 和 $b := \max\{x_i : i = 0, \dots, n\}$

若 $f(x)$ 在 $[a, b]$ 上连续, 且在 (a, b) 上 $n+1$ 阶可导, 则我们有:

$$\begin{aligned} f(x) &= f(x_0) + f[x_0, x_1](x - x_0) + \dots + f[x_0, x_1, \dots, x_n] \prod_{i=0}^{n-1} (x - x_i) + f[x_0, x_1, \dots, x_n, x] \prod_{i=0}^n (x - x_i) \\ &= P_n(x) + f[x_0, x_1, \dots, x_n, x] \prod_{i=0}^n (x - x_i) \quad (\text{where } f[x_0, x_1, \dots, x_k] := \sum_{i=0}^k y_i \prod_{j \neq i} \frac{1}{x_i - x_j}) \\ &= P_n(x) + \frac{f^{(n+1)}(\xi_x)}{(n+1)!} \prod_{i=0}^n (x - x_i) \text{ for some } \xi_x \in (a, b) \end{aligned}$$

因此 n 次插值多项式在 $[a, b]$ 区间上有如下的截断误差上界:

$$\begin{aligned}
|f(x) - P_n(x)| &= \left| \frac{f^{(n+1)}(\xi_x)}{(n+1)!} \prod_{i=0}^n (x - x_i) \right| \\
&\leq \frac{\sup_{t \in [a,b]} |f^{(n+1)}(t)|}{(n+1)!} \prod_{i=0}^n |x - x_i| \\
&= \frac{\|f^{(n+1)}\|_\infty}{(n+1)!} \prod_{i=0}^n |x - x_i| \quad (\forall x \in [a, b]) \\
\|f - P_n\|_\infty &= \sup_{x \in [a,b]} |f(x) - P_n(x)| \\
&\leq \frac{\|f^{(n+1)}\|_\infty}{(n+1)!} \left\| \prod_{i=0}^n |x - x_i| \right\|_\infty
\end{aligned}$$

其中 $\|\cdot\|_\infty$ 为连续函数空间 $C([a, b])$ 上的无穷范数 (又称 Chebyshev 范数)

换言之, n 次插值多项式 $P_n(x)$ 逼近原函数 $f(x)$ 的程度是由函数性质 (即 $\|f^{(n+1)}\|_\infty$ 的大小)

和节点性质 (即 $\|\prod_{i=1}^n |x - x_i|\|_\infty$ 的大小) 决定的.

(Runge 现象)

在 **Homework 03 Problem 04** 中我们可视化了插值多项式对 $\sin(x)$ 和 $f(x) = \frac{1}{1+25x^2}$ 的逼近程度:

- 设采样区间为 $[0, 2\pi]$

对于 $\sin(x)$ 我们发现随着采样个数 n 增大, $n-1$ 次插值多项式 $P_{n-1}(x)$ 的逼近效果是单调变好的.


这是因为 $\sin^{(n)}(x) = \sin(x + \frac{n\pi}{2})$, 在 $[0, 2\pi]$ 上有界, 有 $\|\sin^{(n)}(x)\|_\infty = 1$

于是我们有:

$$\begin{aligned}
\|\sin(x) - P_{n-1}(x)\|_\infty &\leq \frac{\|\sin^{(n)}(x)\|_\infty}{n!} \left\| \prod_{i=1}^n |x - x_i| \right\|_\infty \\
&= \frac{1}{n!} \left\| \prod_{i=1}^n |x - x_i| \right\|_\infty \\
&\leq \frac{(2\pi)^n}{n!} \\
&\rightarrow 0 \quad (n \rightarrow \infty)
\end{aligned}$$

因此截断误差随着 n 的增大而单调变小.

于是在不考虑舍入误差的情况下, 逼近效果随着 n 的增大而单调变好.



- 设采样区间为 $[-1, 0) \cup (0, 1]$


对于 $f(x) = \frac{1}{1+25x^2}$ 我们发现随着采样个数 n 增大, $n-1$ 次插值多项式 $P_{n-1}(x)$ 的逼近效果反而会变差. 这被称为 **Runge 现象**.

原因在于 $f(x) = \frac{1}{1+25x^2}$ 虽然是 $\mathbb{R}$ 上任意阶可导的光滑函数,

但它在复平面上不完全解析, 有 $\pm i/5$ 两个奇点,

因此 Taylor 展开的收敛半径非常小, 仅为 $1/5$, 这代表它有很大的高阶导数 (随 n 的增大快速增长),

使其截断误差上界随着 n 的增大而增大.



我们发现在 $x = 0$ 附近插值效果是好的, 即截断误差较小;

但在 $x = \pm 1$ 附近插值效果非常糟糕, 即截断误差非常大.

- (Bernstein 定理, 数值逼近 定理 3.1)

函数 $f(x) = |x|$ 在 $[-1, 1]$ 上取 $n+1$ 个等距节点 $-1 = x_0 < x_1 < \dots < x_n = 1$

当 n 增大时, n 阶插值多项式 $P_n(\cdot)$ 构成的序列 $\{P_n(x)\}$

仅在 $x = -1, 0, 1$ 三点处逐点收敛于 $f(x)$, 而在其他点处发散.

Runge 现象说明了等距节点的局限性, 那有没有某种最优的节点取法呢?

有的兄弟, 有的, 我们可以选取第一类 Chebyshev 多项式的根作为节点.

在这些节点上采样计算得到的插值多项式就是**最佳一致逼近多项式**.

2.2.3 第一类 Chebyshev 多项式

第一类 Chebyshev 多项式:


$$T_n(x) := \cos[n \arccos(x)] \quad (-1 \leq x \leq 1)$$

它具有如下性质:

- ① 根据定义可知:
 - 对于任意 $x \in [-1, 1]$ 都有 $|T_n(x)| \leq 1$ (此不等号可以取等)
因此我们有 $\|T_n\|_\infty = \max_{-1 \leq x \leq 1} |T_n(x)| = 1$
 - $T_n(x)$ 在 $(-1, 1)$ 上有 n 个不同的实根: $\cos(\frac{2k-1}{2n}\pi)$ ($k = 1, \dots, n$)
 - $T_n(x)$ 在 $[-1, 1]$ 上的一个极大交错点组是 $\cos(\frac{k\pi}{n})$ ($k = 0, \dots, n$)
它们满足 $T_n(\cos(\frac{k\pi}{n})) = \cos(n \cdot \frac{k\pi}{n}) = \cos(k\pi) = (-1)^k$ ($k = 0, 1, \dots, n$)

- 可以证明 $T_n(-x) = (-1)^n T_n(x)$:

$$\begin{aligned}
 T_n(-x) &= \cos[n \arccos(-x)] \quad (\text{note that } \cos(\pi - \theta) = -\cos(\theta)) \\
 &= \cos[n(\pi - \arccos(x))] \\
 &= \cos[n\pi - n \arccos(x)] \\
 &= (-1)^n \cos[-n \arccos(x)] \quad (\text{note that } \cos(-\theta) = \cos(\theta)) \\
 &= (-1)^n \cos[n \arccos(x)] \\
 &= (-1)^n T_n(x)
 \end{aligned}$$



- ② 递推关系:

$$\begin{aligned}
 T_0(x) &\equiv 1 \\
 T_1(x) &= x \\
 T_2(x) &= 2x^2 - 1 \\
 T_3(x) &= 4x^3 - 3x \\
 &\dots \\
 T_n(x) &= 2xT_{n-1}(x) - T_{n-2}(x) = 2^{n-1}x^n + \dots
 \end{aligned}$$

归纳可知 $T_n(x)$ 是最高次项系数为 2^{n-1} 的 n 次多项式.

具体来说, 我们有以下通式:

(通过特征方程得到, 参见 Homework 5 Problem 8)

$$T_n(x) = \frac{(x + \sqrt{x^2 - 1})^n + (x - \sqrt{x^2 - 1})^n}{2}$$

Proof:

$$\begin{aligned}
 \cos(n\theta) &= \cos[(n-1)\theta] \cos(\theta) - \sin[(n-1)\theta] \sin(\theta) \\
 \cos[(n-2)\theta] &= \cos[(n-1)\theta] \cos(\theta) + \sin[(n-1)\theta] \sin(\theta) \\
 &\Updownarrow \\
 \cos(n\theta) &= 2 \cos[(n-1)\theta] \cos(\theta) - \cos[(n-2)\theta] \\
 &\Updownarrow (\text{Let } x := \cos(\theta)) \\
 \cos[n \arccos(x)] &= 2 \cos[(n-1) \arccos(x)] \cos[\arccos(x)] - \cos[(n-2) \arccos(x)] \\
 &\Updownarrow \\
 T_n(x) &= 2xT_{n-1}(x) - T_{n-2}(x)
 \end{aligned}$$

- ③ 正交性:

$$\begin{aligned}
& \int_{-1}^1 \frac{T_m(x)T_n(x)}{\sqrt{1-x^2}} dx \\
&= \int_{-1}^1 \cos[m \arccos(x)] \cos[n \arccos(x)] d \arccos(x) \quad (\text{denote } \theta := \arccos(x)) \\
&= \int_0^\pi \cos(m\theta) \cos(n\theta) d\theta \\
&= \frac{1}{2} \int_0^\pi \cos((m-n)\theta) d\theta + \frac{1}{2} \int_0^\pi \cos((m+n)\theta) d\theta \quad \left(\text{note that } \int_0^\pi \cos(k\pi) d\theta = \begin{cases} \pi, & k=0 \\ 0, & k \neq 0 \end{cases} \right) \\
&= \begin{cases} \pi, & m=n=0 \\ \frac{\pi}{2}, & m=n \neq 0 \\ 0, & m \neq n \end{cases}
\end{aligned}$$

(最小零偏差定理, 数值逼近 定理 4.5)

在 $[-1, 1]$ 上的所有 n 次首一多项式中,

由 n 次 Chebyshev 多项式 $T_n(x)$ 构建的首一多项式 $2^{1-n}T_n(x)$ 对零的偏差最小,

即对于任意 n 次首一多项式 $p(x) = x^n + a_{n-1}x^{n-1} + \dots + a_1x + a_0$ 我们都有:

$$\begin{aligned}
\|p\|_\infty &\geq 2^{1-n} \|T_n\|_\infty = 2^{1-n} \\
\text{where } \|p\|_\infty &:= \max_{-1 \leq x \leq 1} |p(x)|
\end{aligned}$$

当且仅当 $p(x) = 2^{1-n}T_n(x)$ 时取等.

(不能是 $p(x) = -2^{1-n}T_n(x)$, 因为我们限制了 $p(x)$ 是首一多项式, 而 $p(x) = -2^{1-n}T_n(x)$ 是首负一多项式)

换言之, n 次 Chebyshev 多项式的根 $\cos(\frac{2k-1}{2n}\pi)$ ($k = 1, \dots, n$) 是以下优化问题的唯一解:

$$\begin{aligned}
& \min_{x_1, \dots, x_n \in [-1, 1]} \left\| \prod_{k=1}^n |x - x_k| \right\|_\infty \\
& \quad \Updownarrow \\
& \min_{x_1, \dots, x_n \in [-1, 1]} \left\{ \max_{-1 \leq x \leq 1} \prod_{k=1}^n |x - x_k| \right\}
\end{aligned}$$

且上述优化问题的最优值为 2^{1-n} .

- 这说明如果原函数 $f(x)$ 的插值区间为 $[-1, 1]$,
则以 n 次 Chebyshev 多项式的根 $x_k = \cos(\frac{2k-1}{2n}\pi)$ ($k = 1, \dots, n$) 为取样节点
得到的 $n-1$ 次插值多项式 $P_{n-1}(x)$ 是原函数 $f(x)$ 的最佳一致逼近多项式.
其截断误差上界是最小的:

$$\|f - P_{n-1}\|_\infty = \max_{-1 \leq x \leq 1} |f(x) - P_{n-1}(x)| \leq \frac{\|f^{(n)}\|_\infty}{n!} \cdot 2^{1-n}$$

- 一般地, 如果原函数 $f(x)$ 的插值区间为 $[a, b]$,
则取 Chebyshev 节点 $x_k = \frac{a+b}{2} + \frac{b-a}{2} \cos \frac{(2k-1)\pi}{2n}$ ($k = 1, \dots, n$)
得到的 $n-1$ 次插值多项式 $P_{n-1}(x)$ 是原函数 $f(x)$ 的最佳一致逼近多项式.
其截断误差上界是最小的:

$$\|f - P_{n-1}\|_\infty = \max_{a \leq x \leq b} |f(x) - P_{n-1}(x)| \leq \frac{\|f^{(n)}\|_\infty}{n!} \cdot 2^{1-n} \left(\frac{b-a}{2} \right)^n$$

• Proof:

(反证法) 假设存在某个 n 次首一多项式 $p(x) \neq 2^{1-n}T_n(x)$ 使得 $\|p\|_\infty \leq 2^{1-n} \|T_n\|_\infty$

由于 $p(x)$ 和 $2^{1-n}T_n(x)$ 都是 n 次首一多项式,

故 $r(x) = 2^{1-n}T_n(x) - p(x)$ 是一个至多 $n-1$ 次的多项式.

注意到 n 次 Chebyshev 多项式 $T_n(x)$ 在 $[-1, 1]$ 上的一个极大交错点组为 $y_k = \cos(\frac{k\pi}{n})$ ($k = 0, 1, \dots, n$)

它们满足 $T_n(y_k) = \cos(n \arccos(y_k)) = \cos(n \cdot \frac{k\pi}{n}) = \cos(k\pi) = (-1)^k$ ($k = 0, 1, \dots, n$)

根据 $\|p\|_\infty \leq 2^{1-n}\|T_n\|_\infty$ 的假设可知 $|p(y_k)| \leq 2^{1-n}|T_n(y_k)|$ ($k = 0, 1, \dots, n$)

因此 $r(y_k) = 2^{1-n}T_n(y_k) - p(y_k)$ 要么与 $2^{1-n}T_n(y_k)$ 同号, 要么为零.

现考虑序列 $r(y_k)$ ($k = 0, 1, \dots, n$):

○ ① 对于 $k = 0, 1, \dots, n-1$

若 $r(y_k)$ 和 $r(y_{k+1})$ 非零且异号 (即 $r(y_k)r(y_{k+1}) < 0$), 则 $r(x)$ 在 (y_k, y_{k+1}) 区间内至少有一个根.

○ ② 对于 $k = 1, \dots, n-1$

若 $r(y_k) = 0$, 则 $r(y_{k-1})$ 和 $r(y_{k+1})$ 一定非零且同号 (即 $r(y_{k-1})r(y_{k+1}) > 0$)


(否则 $r(x)$ 会在某个区间上恒为零, 与 $p(x) \neq 2^{1-n}T_n(x)$ 的假设相矛盾)

这表明 y_k 是 $r(x)$ 在区间 (y_{k-1}, y_{k+1}) 内的一个二重根 (因此根的数量没有损失)

于是 $r(x)$ 在 $(-1, 1)$ 上至少有 n 个根, 与 " $r(x)$ 是一个至多 $n-1$ 次的多项式" 相矛盾.

因此不存在某个 n 次首一多项式 $p(x) \neq 2^{1-n}T_n(x)$ 使得 $\|p\|_\infty \leq 2^{1-n}\|T_n\|_\infty$

使用 Chebyshev 节点构建 Runge 函数 $f(x) = \frac{1}{1+25x^2}$ 的 9 次最佳逼近插值多项式:



我们可以发现 Chebyshev 节点呈现 "中间稀, 两边密" 的特征.

这与我们的直觉相悖——我们可能直观上更愿意为变化率较大的中间部分赋予更多的节点.

2.3 分段多项式插值

等距节点除了可以用 Chebyshev 节点替代, 还可以通过分段插值进行挽救.

它不但降低了多项式的次数, 还缩小了插值区间.

2.3.1 差商的修正

我们复述数值逼近定理 2.6 的内容:

(数值逼近 定理 2.6, Homework 03 Problem 02)

给定 $n+1$ 个不同的点及其取值 $(x_0, y_0), \dots, (x_n, y_n)$

若 $f(\cdot)$ 在 x_* 处 n 阶可导, 则我们有:

$$\lim_{(x_0, \dots, x_n) \rightarrow (x_*, \dots, x_*)} f[x_0, x_1, \dots, x_n] = \frac{f^{(n)}(x_*)}{n!}$$

在差商的定义 $f[x_0, x_1, \dots, x_k] := \sum_{i=0}^k y_i \prod_{j \neq i} \frac{1}{x_i - x_j}$ 中 $x_0, x_1, \dots, x_k$ 需要互不相同。

我们现对上述定义进行一个补充：

若 $f(x)$ 在 x_* 的某个邻域内 n 阶连续可导，则我们定义 n 重节点差商为：

$$f[\underbrace{x_*, x_*, \dots, x_*}_{n+1}] := \lim_{(x_0, \dots, x_n) \rightarrow (x_*, \dots, x_*)} f[x_0, x_1, \dots, x_n] = \frac{f^{(n)}(x_*)}{n!}$$

更一般地，我们可以定义：

$$f[\underbrace{x_1, \dots, x_1}_{m_1}, \dots, \underbrace{x_s, \dots, x_s}_{m_s}] = \det \begin{bmatrix} B_1 \\ \vdots \\ B_s \end{bmatrix} \bigg/ \det \begin{bmatrix} A_1 \\ \vdots \\ A_s \end{bmatrix}$$

其中 $x_1, \dots, x_s$ 互不相同，且有：

$$n+1 = m_1 + \dots + m_s$$

$$l_k(x) := x^k$$

$$A_i = \begin{bmatrix} 1 & l_1(x_i) & \dots & l_{m_i-1}(x_i) & \dots & l_{n-1}(x_i) & l_n(x_i) \\ l_1^{(1)}(x_i)/1! & \dots & l_{m_i-1}^{(1)}(x_i)/1! & \dots & l_{n-1}^{(1)}(x_i)/1! & l_n^{(1)}(x_i)/1! \\ & \ddots & \vdots & & \vdots & \vdots \\ & & l_{m_i-1}^{(m_i-1)}(x_i)/(m_i-1)! & \dots & l_{n-1}^{(m_i-1)}(x_i)/(m_i-1)! & l_n^{(m_i-1)}(x_i)/(m_i-1)! \end{bmatrix} \in \mathbb{R}^{m_i \times (n+1)}$$

$$B_i = \begin{bmatrix} 1 & l_1(x_i) & \dots & l_{m_i-1}(x_i) & \dots & l_{n-1}(x_i) & f(x_i) \\ l_1^{(1)}(x_i)/1! & \dots & l_{m_i-1}^{(1)}(x_i)/1! & \dots & l_{n-1}^{(1)}(x_i)/1! & f^{(1)}(x_i)/1! \\ & \ddots & \vdots & & \vdots & \vdots \\ & & l_{m_i-1}^{(m_i-1)}(x_i)/(m_i-1)! & \dots & l_{n-1}^{(m_i-1)}(x_i)/(m_i-1)! & f^{(m_i-1)}(x_i)/(m_i-1)! \end{bmatrix} \in \mathbb{R}^{m_i \times (n+1)}$$

2.3.2 Hermite 插值

在某些应用中，我们不仅关心函数在特定点的函数值，还需要利用额外的导数信息。

例如在公路设计中，我们不仅要求道路交汇，还需保证道路交汇的平滑性 (即控制曲线的斜率和曲率)

Hermite 插值考虑的就是这样一个场景。

给定以下样本：

$$x_1, f(x_1), f'(x_1), \dots, f^{(m_1-1)}(x_1)$$

$$x_2, f(x_2), f'(x_2), \dots, f^{(m_2-1)}(x_2)$$

...

$$x_s, f(x_s), f'(x_s), \dots, f^{(m_s-1)}(x_s)$$

$$\text{where } m_1 + m_2 + \dots + m_s = n+1$$

我们要求 n 次插值多项式 $P(\cdot)$ 满足以下条件：

$$P(x_1) = f(x_1), P'(x_1) = f'(x_1), \dots, P^{(m_1-1)}(x_1) = f^{(m_1-1)}(x_1)$$

$$P(x_2) = f(x_2), P'(x_2) = f'(x_2), \dots, P^{(m_2-1)}(x_2) = f^{(m_2-1)}(x_2)$$

...

$$P(x_s) = f(x_s), P'(x_s) = f'(x_s), \dots, P^{(m_s-1)}(x_s) = f^{(m_s-1)}(x_s)$$

从某种意义上说, Hermite 插值是小扰动的 Newton 插值的极限情况.

考虑一个简单的例子:

给定 5 个点: (假设 $x_1 \neq x_2$ 且 $\varepsilon > 0$ 是一个足够小的正数)

$$(x_1, f(x_1)), (x_1 + \varepsilon, f(x_1 + \varepsilon)), (x_1 + 2\varepsilon, f(x_1 + 2\varepsilon)) \\ (x_2, f(x_2)), (x_2 + \varepsilon, f(x_2 + \varepsilon))$$

其差商表为:

x_1	$x_1 + \varepsilon$	$x_1 + 2\varepsilon$	x_2	$x_2 + \varepsilon$
$f(x_1)$	$f(x_1 + \varepsilon)$	$f(x_1 + 2\varepsilon)$	$f(x_2)$	$f(x_2 + \varepsilon)$
	$f[x_1, x_1 + \varepsilon]$	$f[x_1 + \varepsilon, x_1 + 2\varepsilon]$	$f[x_1 + 2\varepsilon, x_2]$	$f[x_2, x_2 + \varepsilon]$
		$f[x_1, x_1 + \varepsilon, x_1 + 2\varepsilon]$	$f[x_1 + \varepsilon, x_1 + 2\varepsilon, x_2]$	$f[x_1 + 2\varepsilon, x_2, x_2 + \varepsilon]$
			$f[x_1, x_1 + \varepsilon, x_1 + 2\varepsilon, x_2]$	$f[x_1 + \varepsilon, x_1 + 2\varepsilon, x_2, x_2 + \varepsilon]$
				$f[x_1, x_1 + \varepsilon, x_1 + 2\varepsilon, x_2, x_2 + \varepsilon]$

对应的 Newton 插值公式即为:

$$P_\varepsilon(x) := f(x_1) + f[x_1, x_1 + \varepsilon](x - x_1) + f[x_1, x_1 + \varepsilon, x_1 + 2\varepsilon](x - x_1)(x - x_1 - \varepsilon) \\ + f[x_1, x_1 + \varepsilon, x_1 + 2\varepsilon, x_2](x - x_1)(x - x_1 - \varepsilon)(x - x_1 - 2\varepsilon) \\ + f[x_1, x_1 + \varepsilon, x_1 + 2\varepsilon, x_2, x_2 + \varepsilon](x - x_1)(x - x_1 - \varepsilon)(x - x_1 - 2\varepsilon)(x - x_2)$$

当 $\varepsilon \rightarrow 0$ 时, 给定的 5 个点就变为 2 个点, 前者有 0, 1, 2 阶导数信息, 后者有 0, 1 阶导数信息:

$$(x_1, f(x_1)), (x_1, f'(x_1)), (x_1, f''(x_1)) \\ (x_2, f(x_2)), (x_2, f'(x_2))$$

在差商表中, 节点一样的就补导数, 节点不一样的写为差商 (仍用 2.1.4 节所述的递推公式计算)

于是我们有:

x_1	x_1	x_1	x_2	x_2
$f(x_1)$	$f(x_1)$	$f(x_1)$	$f(x_2)$	$f(x_2)$
	$f'(x_1)/1!$	$f'(x_1)/1!$	$f[x_1, x_2]$	$f'(x_2)/1!$
		$f''(x_1)/2!$	$f[x_1, x_1, x_2]$	$f[x_1, x_2, x_2]$
			$f[x_1, x_1, x_1, x_2]$	$f[x_1, x_1, x_2, x_2]$
				$f[x_1, x_1, x_1, x_2, x_2]$

对应的 Hermite 插值公式即为:

$$P(x) := f(x_1) + f'(x_1)(x - x_1) + \frac{f''(x_1)}{2!}(x - x_1)^2 \\ + f[x_1, x_1, x_1, x_2](x - x_1)^3 \\ + f[x_1, x_1, x_1, x_2, x_2](x - x_1)^3(x - x_2)$$

严谨的数学论述参见《数值逼近》2.3 节,

不过从上述示例中理解到 Hermite 插值的本质才是最重要的.

考虑最基础的 Hermite 三次插值多项式:

给定 2 个点的 0, 1 阶导数信息:

$$(x_1, f(x_1)), (x_1, f'(x_1)) \\ (x_2, f(x_2)), (x_2, f'(x_2))$$

其差商表为:

$$\begin{array}{c|cc} x_1 & x_1 & x_2 & x_2 \\ \hline f(x_1) & f(x_1) & f(x_2) & f(x_2) \\ & f'(x_1)/1! & f[x_1, x_2] & f'(x_2)/1! \\ & & f[x_1, x_1, x_2] & f[x_1, x_2, x_2] \\ & & & f[x_1, x_1, x_2, x_2] \end{array}$$

对应的 Hermite 插值公式为:

$$\begin{aligned} P(x) &:= f(x_1) + f'(x_1)(x - x_1) + f[x_1, x_1, x_2](x - x_1)^2 + f[x_1, x_1, x_2, x_2](x - x_1)^2(x - x_2) \\ f[x_1, x_2] &= \frac{f(x_2) - f(x_1)}{x_2 - x_1} \\ f[x_1, x_1, x_2] &= \frac{f[x_1, x_2] - f'(x_1)}{x_2 - x_1} \\ f[x_1, x_2, x_2] &= \frac{f'(x_2) - f[x_1, x_2]}{x_2 - x_1} \\ f[x_1, x_1, x_2, x_2] &= \frac{f[x_1, x_2, x_2] - f[x_1, x_1, x_2]}{x_2 - x_1} \end{aligned}$$

但我们很难一下子从中看出什么来, 还是沿用邵老师的方法吧, 构造以下函数:

$$\begin{aligned} \phi(x) &:= 3x^2 - 2x^3 \\ \varphi(x) &:= x^3 - x^2 \end{aligned}$$

容易验证:

$$\begin{aligned} \phi(0) &= \phi'(0) = 0 \\ \phi(1) &= 1, \phi'(1) = 0 \\ \varphi(0) &= \varphi'(0) = 0 \\ \varphi(1) &= 0, \varphi'(1) = 1 \end{aligned}$$

于是 Hermite 插值多项式具有如下形式:

$$\begin{aligned} P(x) &:= f(x_1)\phi\left(\frac{x - x_2}{x_1 - x_2}\right) + f(x_2)\phi\left(\frac{x - x_1}{x_2 - x_1}\right) \\ &\quad + f'(x_1)(x_1 - x_2)\varphi\left(\frac{x - x_2}{x_1 - x_2}\right) + f'(x_2)(x_2 - x_1)\varphi\left(\frac{x - x_1}{x_2 - x_1}\right) \\ P(x_1) &= f(x_1)\phi(1) + f(x_2)\phi(0) + f'(x_1)(x_1 - x_2)\varphi(1) + f'(x_2)(x_2 - x_1)\varphi(0) \\ &= f(x_1) \\ P(x_2) &= f(x_1)\phi(0) + f(x_2)\phi(1) + f'(x_1)(x_1 - x_2)\varphi(0) + f'(x_2)(x_2 - x_1)\varphi(1) \\ &= f(x_2) \\ P'(x) &:= \frac{f(x_1)}{x_1 - x_2}\phi'\left(\frac{x - x_2}{x_1 - x_2}\right) + \frac{f(x_2)}{x_2 - x_1}\phi'\left(\frac{x - x_1}{x_2 - x_1}\right) \\ &\quad + f'(x_1)\varphi'\left(\frac{x - x_2}{x_1 - x_2}\right) + f'(x_2)\varphi'\left(\frac{x - x_1}{x_2 - x_1}\right) \\ P'(x_1) &= \frac{f(x_1)}{x_1 - x_2}\phi'(1) + \frac{f(x_2)}{x_2 - x_1}\phi'(0) + f'(x_1)\varphi'(1) + f'(x_2)\varphi'(0) \\ &= f'(x_1) \\ P'(x_2) &= \frac{f(x_1)}{x_1 - x_2}\phi'(0) + \frac{f(x_2)}{x_2 - x_1}\phi'(1) + f'(x_1)\varphi'(0) + f'(x_2)\varphi'(1) \\ &= f'(x_2) \end{aligned}$$

这种 Hermite 分段三次多项式作为插值函数, 一般来说已有很好的逼近性, 而且一阶导数也有很好的逼近性.


当然其二阶导数在内部节点 x_i 上是不存在的 (因为左右二阶导数可能不相同)

如果还要提高光滑性, 则一种方法是提供二阶导数的信息, 同时使用 Hermite 分段五次多项式, 但高次多项式是不可取的.

另一种方法是下一节的三次样条插值, 将两个一阶导数信息替换为 "一阶导数连续" 和 "二阶导数连续" 两个条件.

(拓展: 平面运动轨迹的 Hermite 插值)

假设有一条平面运动轨迹, 我们记录了它的一些位置和该位置上的速度:



此时我们可以使用弧长 t 作为参数, 设曲线的参数方程为:

$$\begin{cases} x = x(t) \\ y = y(t) \end{cases} \quad (t \in \mathbb{R}_+)$$

我们可以将速度也拆分为 x, y 两个方向的分速度, 分别在 x, y 两个方向进行 Hermite 插值:

$$\begin{cases} x = p_x(t) \\ y = p_y(t) \end{cases} \quad (t \in \mathbb{R}_+)$$

不过本课程主要研究的是对单变量函数的插值.

2.3.3 三次样条插值

样条的概念来自船体所用的木制长条.

其曲线要求通过某些点 (称为型值点), 且在那些点处比较光滑.

具体来说, 其一阶导数和二阶导数在型值点处是连续的.

设样条 $s(x)$ 在区间 $[a, b]$ 上, 型值点 (x_i, y_i) ($i = 0, \dots, n$) 的横坐标为 $a = x_0 < x_1 < \dots < x_n = b$

假设 $s(x)$ 在相邻型值点之间为三次多项式, 即 $s(x)$ 在区间 $[x_i, x_{i+1}]$ 上的表达式为:

$$s_i(x) := a_i + b_i x + c_i x^2 + d_i x^3 \quad (i = 0, \dots, n-1)$$

因此 $s(x)$ 在整个 $[a, b]$ 区间中有 $4n$ 个待定系数.

它至少要满足以下条件:

- ① 通过型值点: (共 $2n$ 个方程)

$$\begin{cases} s_i(x_i) = y_i \\ s_i(x_{i+1}) = y_{i+1} \end{cases} \quad (i = 0, \dots, n-1)$$

- ② 在型值点处的一阶导数连续: (共 $n-1$ 个方程)

$$s'_i(x_{i+1}) = s'_{i+1}(x_{i+1}) \quad (i = 0, \dots, n-2)$$

- ③ 在型值点处的二阶导数连续: (共 $n-1$ 个方程)

$$s_i''(x_{i+1}) = s_{i+1}''(x_{i+1}) \quad (i = 0, \dots, n-2)$$

上面只列出了 $4n - 2$ 个方程，而总共有 $4n$ 个待定系数。

为使 $s(x)$ 能够被唯一确定，我们通常会补充边界条件。

以下是四种典型的边界条件：

- ① **完全样条 (Complete Spline):**

假设已知样条在边界点 x_0, x_n 处的切线斜率值分别为 k_0, k_n 。

$$\begin{aligned} s_0'(x_0) &= k_0 \\ s_{n-1}'(x_n) &= k_n \end{aligned}$$

- ② **自然样条 (Natural Spline):**

假设样条在边界点 x_0, x_n 处自然延伸，不施加外力：

(事实上，二阶导数可以视为某种意义上的弹性势能)

$$s_0''(x_0) = s_{n-1}''(x_n) = 0$$

- ③ **周期样条 (Periodic Spline):**

假设样条的周期为 $b - a = x_n - x_0$ ，要求边界点 x_0 和 x_n 处的衔接是光滑的：(例如心电图)

$$\begin{aligned} s_0'(x_0) &= s_{n-1}'(x_n) \\ s_0''(x_0) &= s_{n-1}''(x_n) \end{aligned}$$

- ④ **Not-a-knot 样条:**

消除样条在 x_1 和 x_{n-1} 处的“结”，即要求三阶导数在 x_1 和 x_{n-1} 处连续。

换言之，我们要求 $[x_0, x_1]$ 上的三次多项式 $s_0(x)$ 和 $[x_1, x_2]$ 上的三次多项式 $s_1(x)$ 相同，

同时要求 $[x_{n-2}, x_{n-1}]$ 上的三次多项式 $s_{n-2}(x)$ 和 $[x_{n-1}, x_n]$ 上的三次多项式 $s_{n-1}(x)$ 相同。

$$\begin{aligned} s_0'''(x_1) &= s_1'''(x_1) \\ s_{n-2}'''(x_{n-1}) &= s_{n-1}'''(x_{n-1}) \end{aligned}$$

解的唯一性解决了，但求解 $4n$ 阶线性方程组的代价 $O(n^3)$ 还是太大了。

我们需要想办法将 $4n$ 阶线性方程组变为低阶线性方程组。

2.3.4 矩阵形式

注意到我们有 $n + 1$ 个导数值 $s'(x_0), \dots, s'(x_n)$ 未知。

我们可以利用它们进行三次 Hermite 插值。

定义：

$$\begin{aligned} k_i &:= s'(x_i) & (i = 0, 1, \dots, n) \\ h_i &:= x_{i+1} - x_i & (i = 0, 1, \dots, n) \\ \phi(x) &:= 3x^2 - 2x^3 \\ \varphi(x) &:= x^3 - x^2 \end{aligned}$$

其中 $k_0, k_1, \dots, k_{n-1}, k_n$ 都是未知的。

于是根据插值条件 $\begin{cases} s_i(x_i) = y_i \\ s_i(x_{i+1}) = y_{i+1} \\ s_i'(x_i) = k_i \\ s_i'(x_{i+1}) = k_{i+1} \end{cases}$ 和 2.3.2 节的结论可得 $s_i(x)$ 的表达式为：

$$\begin{aligned}
s_i(x) &= y_i \phi\left(\frac{x_{i+1}-x}{h_i}\right) + y_{i+1} \phi\left(\frac{x-x_i}{h_i}\right) - k_i h_i \varphi\left(\frac{x_{i+1}-x}{h_i}\right) + k_{i+1} h_i \varphi\left(\frac{x-x_i}{h_i}\right) \\
s'_i(x) &= -\frac{y_i}{h_i} \phi'\left(\frac{x_{i+1}-x}{h_i}\right) + \frac{y_{i+1}}{h_i} \phi'\left(\frac{x-x_i}{h_i}\right) + k_i \varphi'\left(\frac{x_{i+1}-x}{h_i}\right) + k_{i+1} \varphi'\left(\frac{x-x_i}{h_i}\right) \\
s''_i(x) &= \frac{y_i}{h_i^2} \phi''\left(\frac{x_{i+1}-x}{h_i}\right) + \frac{y_{i+1}}{h_i^2} \phi''\left(\frac{x-x_i}{h_i}\right) - \frac{k_i}{h_i} \varphi''\left(\frac{x_{i+1}-x}{h_i}\right) + \frac{k_{i+1}}{h_i} \varphi''\left(\frac{x-x_i}{h_i}\right) \\
s'''_i(x) &= -\frac{y_i}{h_i^3} \phi'''\left(\frac{x_{i+1}-x}{h_i}\right) + \frac{y_{i+1}}{h_i^3} \phi'''\left(\frac{x-x_i}{h_i}\right) + \frac{k_i}{h_i^2} \varphi'''\left(\frac{x_{i+1}-x}{h_i}\right) + \frac{k_{i+1}}{h_i^2} \varphi'''\left(\frac{x-x_i}{h_i}\right) \\
&\equiv 12 \frac{y_i - y_{i+1}}{h_i^3} + 6 \frac{k_i + k_{i+1}}{h_i^2} \quad (i = 0, 1, \dots, n-1) \\
&= -4\beta_i \eta_i + 6\beta_i^2 (k_i + k_{i+1})
\end{aligned}$$

$$\begin{aligned}
\text{where } \phi(x) &= 3x^2 - 2x^3, \quad \varphi(x) = x^3 - x^2 \\
\phi'(x) &= 6x - 6x^2, \quad \varphi'(x) = 3x^2 - 2x \\
\phi''(x) &= 6 - 12x, \quad \varphi''(x) = 6x - 2 \\
\phi'''(x) &\equiv -12, \quad \varphi'''(x) \equiv 6 \\
\beta_i &= \frac{1}{h_i}, \quad \eta_i = 3 \frac{y_{i+1} - y_i}{h_i^2}
\end{aligned}$$

现考虑二阶导的插值条件 $s''_i(x_{i+1}) = s''_{i+1}(x_{i+1})$:

$$\begin{aligned}
s''_i(x_{i+1}) &= \frac{y_i}{h_i^2} \phi''(0) + \frac{y_{i+1}}{h_i^2} \phi''(1) - \frac{k_i}{h_i} \varphi''(0) + \frac{k_{i+1}}{h_i} \varphi''(1) \\
&= 6 \frac{y_i}{h_i^2} - 6 \frac{y_{i+1}}{h_i^2} + 2 \frac{k_i}{h_i} + 4 \frac{k_{i+1}}{h_i} \\
s''_{i+1}(x_{i+1}) &= \frac{y_{i+1}}{h_{i+1}^2} \phi''(1) + \frac{y_{i+2}}{h_{i+1}^2} \phi''(0) - \frac{k_{i+1}}{h_{i+1}} \varphi''(1) + \frac{k_{i+2}}{h_{i+1}} \varphi''(0) \\
&= -6 \frac{y_{i+1}}{h_{i+1}^2} + 6 \frac{y_{i+2}}{h_{i+1}^2} - 4 \frac{k_{i+1}}{h_{i+1}} - 2 \frac{k_{i+2}}{h_{i+1}} \\
\hline
s''_i(x_{i+1}) &= s''_{i+1}(x_{i+1}) \\
&\Updownarrow \\
6 \frac{y_i}{h_i^2} - 6 \frac{y_{i+1}}{h_i^2} + 2 \frac{k_i}{h_i} + 4 \frac{k_{i+1}}{h_i} &= -6 \frac{y_{i+1}}{h_{i+1}^2} + 6 \frac{y_{i+2}}{h_{i+1}^2} - 4 \frac{k_{i+1}}{h_{i+1}} - 2 \frac{k_{i+2}}{h_{i+1}} \\
&\Updownarrow \\
\beta_i k_i + \alpha_{i+1} k_{i+1} + \beta_{i+1} k_{i+2} &= \eta_i + \eta_{i+1} \\
\text{where } \begin{cases} h_i = x_{i+1} - x_i & (i = 0, \dots, n-1) \\ \beta_i = \frac{1}{h_i} & (i = 0, \dots, n-1) \\ \alpha_{i+1} = 2(\beta_i + \beta_{i+1}) & (i = 0, \dots, n-2) \\ \eta_i = 3 \frac{y_{i+1} - y_i}{h_i^2} & (i = 0, \dots, n-1) \end{cases}
\end{aligned}$$

• ① 完全样条 (Complete Spline):

假设已知样条在边界点 x_0, x_n 处的切线斜率值分别为 k_0, k_n .

$$\begin{aligned}
s'_0(x_0) &= k_0 \\
s'_{n-1}(x_n) &= k_n
\end{aligned}$$

于是方程组为:

$$\begin{cases} \alpha_1 k_1 + \beta_1 k_2 = \eta_0 + \eta_1 - \beta_0 k_0 & (\text{case of } i = 0) \\ \beta_i k_i + \alpha_{i+1} k_{i+1} + \beta_{i+1} k_{i+2} = \eta_i + \eta_{i+1} & (i = 1, \dots, n-3) \\ \beta_{n-2} k_{n-2} + \alpha_{n-1} k_{n-1} = \eta_{n-2} + \eta_{n-1} - \beta_{n-1} k_n & (\text{case of } i = n-2) \end{cases}$$

$$\Leftrightarrow \begin{bmatrix} \alpha_1 & \beta_1 & & & \\ \beta_1 & \alpha_2 & \beta_2 & & \\ & \beta_2 & \ddots & \ddots & \\ & & \ddots & \alpha_{n-2} & \beta_{n-2} \\ & & & \beta_{n-2} & \alpha_{n-1} \end{bmatrix} \begin{bmatrix} k_1 \\ k_2 \\ \vdots \\ k_{n-2} \\ k_{n-1} \end{bmatrix} = \begin{bmatrix} \eta_0 + \eta_1 - \beta_0 k_0 \\ \eta_1 + \eta_2 \\ \vdots \\ \eta_{n-3} + \eta_{n-2} \\ \eta_{n-2} + \eta_{n-1} - \beta_{n-1} k_n \end{bmatrix}$$

这是一个严格对角占优的 $n-1$ 阶三对角阵，使用 Gauss 消去法求解的代价为 $O(n)$

严格对角占优意味着 Gauss 消去法不用选主元
于是三对角阵的 LU 分解为：

$$\begin{bmatrix} \times & \times & & & \\ \times & \times & \times & & \\ & \times & \times & \times & \\ & & \times & \times & \times \\ & & & \times & \times \end{bmatrix} = \begin{bmatrix} \times & & & & \\ \times & \times & & & \\ & \times & \times & & \\ & & \times & \times & \\ & & & \times & \times \end{bmatrix} \begin{bmatrix} \times & \times & & & \\ & \times & \times & & \\ & & \times & \times & \\ & & & \times & \times \\ & & & & \times \end{bmatrix}$$

每列只消一次行消元， $O(1)$ 级别代价

Gauss 消元法总代价 $O(n)$

回代法和前代法各自代价为 $O(n)$

因此求解严格对角占优的 $n-1$ 阶三对角阵的代价为 $O(n)$

• ② 自然样条 (Natural Spline):

假设样条在边界点 x_0, x_n 处自然延伸，不施加外力：

(事实上，二阶导数可以视为某种意义上的弹性势能)

$$s_0''(x_0) = s_{n-1}''(x_n) = 0$$

$\Leftrightarrow$

$$\begin{aligned} s_0''(x_0) &= -6 \frac{y_0}{h_0^2} + 6 \frac{y_1}{h_0^2} - 4 \frac{k_0}{h_0} - 2 \frac{k_1}{h_0} \\ &= 2(\eta_0 - 2\beta_0 k_0 - \beta_0 k_1) \\ &= 0 \end{aligned}$$

$$\begin{aligned} s_{n-1}''(x_n) &= 6 \frac{y_{n-1}}{h_{n-1}^2} - 6 \frac{y_n}{h_{n-1}^2} + 2 \frac{k_{n-1}}{h_{n-1}} + 4 \frac{k_n}{h_{n-1}} \\ &= 2(-\eta_{n-1} + \beta_{n-1} k_{n-1} + 2\beta_{n-1} k_n) \\ &= 0 \end{aligned}$$

于是方程组为：

$$\begin{cases} 2\beta_0 k_0 + \beta_0 k_1 = \eta_0 & (\text{additional condition}) \\ \beta_i k_i + \alpha_{i+1} k_{i+1} + \beta_{i+1} k_{i+2} = \eta_i + \eta_{i+1} & (i = 0, \dots, n-2) \\ \beta_{n-1} k_{n-1} + 2\beta_{n-1} k_n = \eta_{n-1} & (\text{additional condition}) \end{cases}$$

$\Downarrow$

$$\begin{bmatrix} 2\beta_0 & \beta_0 & & & & \\ \beta_0 & \alpha_1 & \beta_1 & & & \\ & \beta_1 & \alpha_2 & \beta_2 & & \\ & & \beta_2 & \ddots & \ddots & \\ & & & \ddots & \alpha_{n-2} & \beta_{n-2} \\ & & & & \beta_{n-2} & \alpha_{n-1} & \beta_{n-1} \\ & & & & & \beta_{n-1} & 2\beta_{n-1} \end{bmatrix} \begin{bmatrix} k_0 \\ k_1 \\ k_2 \\ \vdots \\ k_{n-2} \\ k_{n-1} \\ k_n \end{bmatrix} = \begin{bmatrix} \eta_0 \\ \eta_0 + \eta_1 \\ \eta_1 + \eta_2 \\ \vdots \\ \eta_{n-3} + \eta_{n-2} \\ \eta_{n-2} + \eta_{n-1} \\ \eta_{n-1} \end{bmatrix}$$

这是一个严格对角占优的 $n+1$ 阶三对角阵，使用 Gauss 消去法求解的代价为 $O(n)$

• ③ 周期样条 (Periodic Spline):

假设样条的周期为 $b-a = x_n - x_0$ ，要求边界点 x_0 和 x_n 处的衔接是光滑的:

$$s'_0(x_0) = s'_{n-1}(x_n)$$

$$s''_0(x_0) = s''_{n-1}(x_n)$$

$\Downarrow$

$$k_0 = s'_0(x_0) = s'_{n-1}(x_n) = k_n$$

$$2(\eta_0 - 2\beta_0 k_0 - \beta_0 k_1) = s''_0(x_0) = s''_{n-1}(x_n) = 2(-\eta_{n-1} + \beta_{n-1} k_{n-1} + 2\beta_{n-1} k_n)$$

$\Downarrow$

$$2(\beta_0 + \beta_{n-1})k_0 + \beta_0 k_1 + \beta_{n-1} k_{n-1} = \eta_{n-1} + \eta_0$$

若额外定义 $\alpha_0 = 2(\beta_0 + \beta_{n-1})$ ，则我们有 $\alpha_0 k_0 + \beta_0 k_1 + \beta_{n-1} k_{n-1} = \eta_{n-1} + \eta_0$

此外，在 $\beta_{n-2} k_{n-2} + \alpha_{n-1} k_{n-1} + \beta_{n-1} k_n = \eta_{n-2} + \eta_{n-1}$ 中代入 $k_n = k_0$

即可得到 $\beta_{n-1} k_0 + \beta_{n-2} k_{n-2} + \alpha_{n-1} k_{n-1} = \eta_{n-2} + \eta_{n-1}$

于是方程组为:

$$\begin{cases} \alpha_0 k_0 + \beta_0 k_1 + \beta_{n-1} k_{n-1} = \eta_{n-1} + \eta_0 & (\text{additional condition}) \\ \beta_i k_i + \alpha_{i+1} k_{i+1} + \beta_{i+1} k_{i+2} = \eta_i + \eta_{i+1} & (i = 0, \dots, n-2) \\ \beta_{n-1} k_0 + \beta_{n-2} k_{n-2} + \alpha_{n-1} k_{n-1} = \eta_{n-2} + \eta_{n-1} & (\text{additional condition}) \end{cases}$$

$\Downarrow$

$$\begin{bmatrix} \alpha_0 & \beta_0 & & & \beta_{n-1} \\ \beta_0 & \alpha_1 & \beta_1 & & \\ & \beta_1 & \alpha_2 & \beta_2 & \\ & & \ddots & \ddots & \ddots \\ & & & \beta_{n-3} & \alpha_{n-2} & \beta_{n-2} \\ \beta_{n-1} & & & \beta_{n-2} & \alpha_{n-1} \end{bmatrix} \begin{bmatrix} k_0 \\ k_1 \\ k_2 \\ \vdots \\ k_{n-2} \\ k_{n-1} \end{bmatrix} = \begin{bmatrix} \eta_{n-1} + \eta_0 \\ \eta_0 + \eta_1 \\ \eta_1 + \eta_2 \\ \vdots \\ \eta_{n-3} + \eta_{n-2} \\ \eta_{n-2} + \eta_{n-1} \end{bmatrix}$$

这是一个严格对角占优的 n 阶循环三对角阵，使用 Gauss 消去法求解的代价为 $O(n)$

严格对角占优意味着 Gauss 消去法不用选主元
于是循环三对角矩阵的 LU 分解为:

$$\begin{bmatrix} \times & \times & & \times \\ \times & \times & \times & \\ & \times & \times & \times \\ \times & & \times & \times & \times \end{bmatrix} = \begin{bmatrix} \times & & & \\ \times & \times & & \\ & \times & \times & \\ \times & \times & \times & \times & \times \end{bmatrix} \begin{bmatrix} \times & \times & & \times \\ & \times & \times & \times \\ & & \times & \times & \times \\ & & & \times & \times \\ & & & & \times \end{bmatrix}$$



每列只需两次行消元, $O(n)$ 级别代价

Gauss 消元法总代价 $O(n)$

回代法和前代法各自代价为 $O(n)$

因此求解严格对角占优的 n 阶循环三对角阵的代价为 $O(n)$

• ④ Not-a-knot 样条: (Homework 04 Problem 03)

消除样条在 x_1 和 x_{n-1} 处的 "结", 即要求三阶导数在 x_1 和 x_{n-1} 处连续.

换言之, 我们要求 $[x_0, x_1]$ 上的三次多项式 $s_0(x)$ 和 $[x_1, x_2]$ 上的三次多项式 $s_1(x)$ 相同,

同时要求 $[x_{n-2}, x_{n-1}]$ 上的三次多项式 $s_{n-2}(x)$ 和 $[x_{n-1}, x_n]$ 上的三次多项式 $s_{n-1}(x)$ 相同.

$$\begin{aligned} s_0'''(x_1) &= s_1'''(x_1) \\ s_{n-2}'''(x_{n-1}) &= s_{n-1}'''(x_{n-1}) \\ \Downarrow \\ -4\beta_0\eta_0 + 6\beta_0^2(k_0 + k_1) &= s_0'''(x_1) = s_1'''(x_1) = -4\beta_1\eta_1 + 6\beta_1^2(k_1 + k_2) \\ -4\beta_{n-2}\eta_{n-2} + 6\beta_{n-2}^2(k_{n-2} + k_{n-1}) &= s_{n-2}'''(x_{n-1}) = s_{n-1}'''(x_{n-1}) = -4\beta_{n-1}\eta_{n-1} + 6\beta_{n-1}^2(k_{n-1} + k_n) \\ \Downarrow \\ 3\beta_0^2k_0 + 3(\beta_0^2 - \beta_1^2)k_1 - 3\beta_1^2k_2 &= 2(\beta_0\eta_0 - \beta_1\eta_1) \\ 3\beta_{n-2}^2k_{n-2} + 3(\beta_{n-2}^2 - \beta_{n-1}^2)k_{n-1} - 3\beta_{n-1}^2k_n &= 2(\beta_{n-2}\eta_{n-2} - \beta_{n-1}\eta_{n-1}) \\ \Downarrow \\ 3\beta_0k_0 + 3(\beta_0 - \frac{\beta_1^2}{\beta_0})k_1 - 3\frac{\beta_1^2}{\beta_0}k_2 &= 2(\eta_0 - \frac{\beta_1}{\beta_0}\eta_1) \\ 3\beta_{n-2}k_{n-2} + 3(\beta_{n-2} - \frac{\beta_{n-1}^2}{\beta_{n-2}})k_{n-1} - 3\frac{\beta_{n-1}^2}{\beta_{n-2}}k_n &= 2(\eta_{n-2} - \frac{\beta_{n-1}}{\beta_{n-2}}\eta_{n-1}) \end{aligned}$$

于是方程组为:

$$\begin{cases} 3\beta_0k_0 + 3(\beta_0 - \frac{\beta_1^2}{\beta_0})k_1 - 3\frac{\beta_1^2}{\beta_0}k_2 = 2(\eta_0 - \frac{\beta_1}{\beta_0}\eta_1) & \text{(additional condition)} \\ \beta_ik_i + \alpha_{i+1}k_{i+1} + \beta_{i+1}k_{i+2} = \eta_i + \eta_{i+1} & (i = 0, \dots, n-2) \\ 3\beta_{n-2}k_{n-2} + 3(\beta_{n-2} - \frac{\beta_{n-1}^2}{\beta_{n-2}})k_{n-1} - 3\frac{\beta_{n-1}^2}{\beta_{n-2}}k_n = 2(\eta_{n-2} - \frac{\beta_{n-1}}{\beta_{n-2}}\eta_{n-1}) & \text{(additional condition)} \end{cases}$$

$\Downarrow$

$$\begin{bmatrix} 3\beta_0 & 3(\beta_0 - \frac{\beta_1^2}{\beta_0}) & -3\frac{\beta_1^2}{\beta_0} & & & \\ \beta_0 & \alpha_1 & \beta_1 & & & \\ & \beta_1 & \alpha_2 & \beta_2 & & \\ & & \beta_2 & \ddots & \ddots & \\ & & & \ddots & \alpha_{n-2} & \beta_{n-2} \\ & & & & \beta_{n-2} & \alpha_{n-1} & \beta_{n-1} \\ & & & & & 3\beta_{n-2} & 3(\beta_{n-2} - \frac{\beta_{n-1}^2}{\beta_{n-2}}) & -3\frac{\beta_{n-1}^2}{\beta_{n-2}} \end{bmatrix} \begin{bmatrix} k_0 \\ k_1 \\ k_2 \\ \vdots \\ k_{n-2} \\ k_{n-1} \\ k_n \end{bmatrix} = \begin{bmatrix} 2(\eta_0 - \frac{\beta_1}{\beta_0}\eta_1) \\ \eta_0 + \eta_1 \\ \eta_1 + \eta_2 \\ \vdots \\ \eta_{n-3} + \eta_{n-2} \\ \eta_{n-2} + \eta_{n-1} \\ 2(\eta_{n-2} - \frac{\beta_{n-1}}{\beta_{n-2}}\eta_{n-1}) \end{bmatrix}$$

尽管这并不是一个严格对角占优的 $n+1$ 阶稀疏矩阵，但使用 Gauss 消去法求解的代价仍为 $O(n)$

假设其能进行不选主元的 Gauss 消元，则其 LU 分解为：

$$\begin{bmatrix} \times & \times & \boxed{\times} \\ \times & \times & \times \\ & \times & \times & \times \\ & & \times & \times & \times \\ & & & \boxed{\times} & \times & \times \end{bmatrix} = \begin{bmatrix} \times & & & & \\ \times & \times & & & \\ & \times & \times & & \\ & & \times & \times & \\ & & & \times & \times & \times \end{bmatrix} \begin{bmatrix} \times & \times & \boxed{\times} \\ & \times & \times & & \\ & & \times & \times & \times \\ & & & \times & \times & \times \\ & & & & \times & \times & \times \end{bmatrix}$$

大部分列只而一次行消元， $O(1)$ 级别代价

Gauss 消元法总代价 $O(n)$

回代法和前代法各自代价为 $O(n)$

因此求解该稀疏线性系统的总代价为 $O(n)$

完全样条和自然样条的误差估计：

(可以认为是等距采样，如果不是等距采样就取最大的 h_i 为 h)

- $\|s(x) - f(x)\|_{\infty} \leq \|f^{(4)}(x)\|_{\infty} \cdot h^4/16$
- $\|s'(x) - f'(x)\|_{\infty} \leq \|f^{(4)}(x)\|_{\infty} \cdot h^3/2$
- $\|s''(x) - f''(x)\|_{\infty} \leq \|f^{(4)}(x)\|_{\infty} \cdot h^2/2$
- $\|s^{(j)}(x) - f^{(j)}(x)\|_{\infty} \leq \|f^{(4)}(x)\|_{\infty} \cdot O(h^{4-j}) \quad (j = 0, 1, 2)$

量纲分析表明，上述结论中 h 阶数是合理的：

$$f(x) = f(x_0) + f'(x_0)(x - x_0) + \frac{f''(x_0)}{2}(x - x_0)^2 + \frac{f'''(x_0)}{6}(x - x_0)^3 + \dots$$

而且它们的系数是最优的，因为可以举出例子取到这些上界。

2.3.5 弹性势能最小化

三次样条能够最小化数学上的弹性势能 $\|s''(x)\|_2^2 := \int_a^b (s''(x))^2 dx$

具体来说，对于任意给定的光滑函数 $f: \mathbb{R} \mapsto \mathbb{R}$ ，定义以下线性空间：

$$\begin{aligned} \mathcal{W}_0 &:= \{g \in C^2([a, b]) : g(x_i) = f(x_i) \text{ for } i = 1, \dots, n\} \\ \mathcal{W}_1 &:= \{g \in \mathcal{W}_0 : g'(x_0) = f'(x_0), g'(x_n) = f'(x_n)\} \subset \mathcal{W}_0 \\ &\text{where } a = x_0 < x_1 < \dots < x_n = b \end{aligned}$$

可以证明：

- ① 若 $s(x)$ 是 $f(x)$ 的三次自然样条 (注意 $s(x)$ 也属于 $\mathcal{W}_0$)，则对于任意 $g \in \mathcal{W}_0$ 都有 $\|s''(x)\|_2 \leq \|g''(x)\|_2$ (这表明在没有额外边界约束的情况下，三次自然样条的弹性势能最小)
- ② 若 $s(x)$ 是 $f(x)$ 的三次完全样条 (注意 $s(x)$ 也属于 $\mathcal{W}_1$)，则对于任意 $g \in \mathcal{W}_1$ 都有 $\|s''(x)\|_2 \leq \|g''(x)\|_2$ (这表明在有额外的边界点导数约束的情况下，三次完全样条的弹性势能最小)

证明思路：

记泛函 $F[g] := \|g''\|_2^2 = \int_a^b (g''(x))^2 dx$

一种方法是说明第一变分 δF 在 $g(x) \equiv s(x)$ 时为零，但简单起见还是不引入变分的概念吧。

另一种方法是多元最值问题转化为一元最值问题。

任意给定 $u(x)$ ，我们都有：

$$\begin{aligned}
F[s + tu] &= \|s'' + tu''\|_2^2 \\
&= \|s''\|_2^2 + 2t\langle s'', u'' \rangle_2 + t^2\|u''\|_2^2 \\
&= F[s] + 2t \int_a^b s''(x)u''(x)dx + t^2 F[u]
\end{aligned}$$

那么对于第一个命题来说,

要证明 $F[s] \leq F[g]$ 对任意 $g \in \mathcal{W}_0$ 都成立,

即要证明 $F[s + tu] \geq F[s]$ 对于任意 $u \in \mathcal{W}_0$ (注意 $\mathcal{W}_0$ 是线性空间, s 也属于 $\mathcal{W}_0$) 和 $t \in \mathbb{R}$ 都成立,

即要证明 $\int_a^b s''(x)u''(x)dx = 0$ 对于任意 $u \in \mathcal{W}_0$ 都成立.

第二个命题的证明逻辑也是类似的.

任意给定二阶可导函数 $u \in C^2([a, b])$ 和三次样条函数 $s(x)$

我们要对积分 $\int_a^b s''(x)u''(x)dx$ 进行分段处理,

这是因为三次样条函数 $s(x)$ 是 "分段光滑的",

具体来说, 它的三阶导数和四阶导数在插值点 $x_1, \dots, x_{n-1}$ 处不一定存在.

每段积分 $\int_{x_i}^{x_{i+1}} s''(x)u''(x)dx$ 可以使用分部积分公式进行变形处理:

$$\begin{aligned}
\int_a^b s''(x)u''(x)dx &= \sum_{i=0}^{n-1} \int_{x_i}^{x_{i+1}} s''(x)u''(x)dx \\
&= \sum_{i=0}^{n-1} \left[s''(x)u'(x) \Big|_{x_i}^{x_{i+1}} - \int_{x_i}^{x_{i+1}} s'''(x)u'(x)dx \right] \\
&= \sum_{i=0}^{n-1} \left[(s''(x)u'(x) - s'''(x)u(x)) \Big|_{x_i}^{x_{i+1}} + \int_{x_i}^{x_{i+1}} s^{(4)}(x)u(x)dx \right] \\
&= [s''(b)u'(b) - s'''(b)u(b)] - [s''(a)u'(a) - s'''(a)u(a)] + \sum_{i=0}^{n-1} \int_{x_i}^{x_{i+1}} s^{(4)}(x)u(x)dx \\
&\quad (\text{note that } s^{(4)}(x) = 0 \text{ for } x \in (x_i, x_{i+1}) \text{ where } i = 0, 1, \dots, n-1) \\
&= [s''(b)u'(b) - s''(a)u'(a)] - [s'''(b)u(b) - s'''(a)u(a)]
\end{aligned}$$

• 对于第一个命题:

设 $s(x)$ 是三次自然样条, 则其边界条件为 $s''(a) = s''(b) = 0$

任意给定 $g \in \mathcal{W}_0$, 取 $u(x) = g(x) - s(x)$, 则根据插值条件有 $u(a) = u(b) = 0$

于是我们有:

$$\begin{aligned}
\int_a^b s''(x)u''(x)dx &= [s''(b)u'(b) - s''(a)u'(a)] - [s'''(b)u(b) - s'''(a)u(a)] \\
&= [0 \cdot u'(b) - 0 \cdot u'(a)] - [s'''(b) \cdot 0 - s'''(a) \cdot 0] \\
&= 0
\end{aligned}$$

根据 "证明思路" 中的推理可知对于任意 $g \in \mathcal{W}_0$ 我们都有 $\|s''\|_2 \leq \|g''\|_2$ 成立.

• 对于第二个命题:

设 $s(x)$ 是三次完全样条, 则其边界条件为 $s'(a) = f'(a)$ 和 $s'(b) = f'(b)$

任意给定 $g \in \mathcal{W}_1$, 取 $u(x) = g(x) - s(x)$, 则根据插值条件有 $u(a) = u(b) = 0$

同时根据 $\mathcal{W}_1$ 的定义有 $u'(a) = u'(b) = 0$

于是我们有:

$$\begin{aligned}
\int_a^b s''(x)u''(x)dx &= [s''(b)u'(b) - s''(a)u'(a)] - [s'''(b)u(b) - s'''(a)u(a)] \\
&= [s''(b) \cdot 0 - s''(a) \cdot 0] - [s'''(b) \cdot 0 - s'''(a) \cdot 0] \\
&= 0
\end{aligned}$$

根据 "证明思路" 中的推理可知对于任意 $g \in \mathcal{W}_1$ 我们都有 $\|s''\|_2 \leq \|g''\|_2$ 成立.

2.4 二维插值

2.4.1 二维 Lagrange 插值

Theorem:

设 $\mathcal{P}$ 为二元多项式函数构成的 n 维线性空间.

二维多项式插值问题是定义良好的,

当且仅当插值节点 $(x_1, y_1), \dots, (x_n, y_n)$ 不落在 $\mathcal{P}$ 中的某个低维代数曲线上.

这表明二维多项式插值问题并不总是定义良好的 (即存在唯一解)

矩形网格节点下的二维 Lagrange 插值:

当插值节点分布在一个矩形网格上时, 我们可以利用张量积结构构造 2D Lagrange 插值多项式.

设在 x 方向有 $n + 1$ 个互不相同的节点 $x_0, x_1, \dots, x_n$,

在 y 方向上有 $m + 1$ 个互不相同的节点 $y_0, y_1, \dots, y_m$.

总的网格节点为:

$$\{(x_i, y_j) : i = 0, \dots, n, j = 0, \dots, m\}$$

给定二元函数 $f(x, y)$

我们的目标是构造一个多项式 $P(x, y)$ 使得 $P(x_i, y_j) = f(x_i, y_j)$ ($i = 0, \dots, n, j = 0, \dots, m$)

二维 Lagrange 基函数的构造基于一维 Lagrange 基函数:

$$\begin{aligned} N_i(x) &:= \prod_{k \neq i}^n \frac{x - x_k}{x_i - x_k} \quad (i = 0, \dots, n) \\ M_j(y) &:= \prod_{k \neq j}^m \frac{y - y_k}{y_j - y_k} \quad (j = 0, \dots, m) \\ \hline L_{ij}(x, y) &:= N_i(x)M_j(y) \\ \text{where } i &= 0, \dots, n \text{ and } j = 0, \dots, m \end{aligned}$$

容易验证它们满足:

$$L_{ij}(x_{i'}, y_{j'}) = N_i(x_{i'})M_j(y_{j'}) = \begin{cases} 1, & \text{if } i' = i \text{ and } j' = j \\ 0, & \text{otherwise} \end{cases}$$

于是我们可以这样构造二维 Lagrange 插值多项式:

$$\begin{aligned} P(x, y) &:= \sum_{i=0}^n \sum_{j=0}^m f(x_i, y_j) L_{ij}(x, y) \\ &= \sum_{i=0}^n \sum_{j=0}^m f(x_i, y_j) N_i(x) M_j(y) \end{aligned}$$

其次数在 x 方向为 n 次, 在 y 方向为 m 次, 满足:

$$\begin{aligned} P(x_i, y_j) &= f(x_i, y_j) \\ \text{where } i &= 0, \dots, n \text{ and } j = 0, \dots, m \end{aligned}$$

- 矩形网格上的二维 Lagrange 插值可以用一维情况的重心坐标插值公式 (参见 2.1.2 节) 进行改进.
- **(Homework 05 Problem 01)**
可以证明矩形网格上的二维 Lagrange 插值总是定义良好的 (即具有唯一解), 只要这个矩形网格上没有重节点.

2.4.2 二维 Bernstein 插值

三角网格节点下的二维 Bernstein 插值:

在三角形区域内进行多项式插值通常不采用张量积结构,
而是借助**重心坐标** (barycentric coordinates) 进行构造.

考虑三角形 $\triangle ABC$

设其顶点坐标为 $A = (x_A, y_A), B = (x_B, y_B), C = (x_C, y_C)$

三角形 $\triangle ABC$ 上的任意一点 $Q = (x, y)$ 都可用重心坐标表示:

$$\begin{aligned} Q &= \alpha A + \beta B + \gamma C \\ &\Updownarrow \\ \begin{bmatrix} x \\ y \\ 1 \end{bmatrix} &= \begin{bmatrix} x_A & x_B & x_C \\ y_A & y_B & y_C \\ 1 & 1 & 1 \end{bmatrix} \begin{bmatrix} \alpha \\ \beta \\ \gamma \end{bmatrix} \\ \text{where } &\begin{cases} \alpha, \beta, \gamma \geq 0 \\ \alpha + \beta + \gamma = 1 \end{cases} \end{aligned}$$

记 A, B, C 的重心坐标为 $(1, 0, 0), (0, 1, 0), (0, 0, 1)$

给定多项式次数 d

若我们在三角形 $\triangle ABC$ 按重心坐标等距取点:

$$\begin{aligned} Q_{i,j,k} &= \left(\frac{i}{d}, \frac{j}{d}, \frac{k}{d} \right) \\ \text{where } &\begin{cases} 0 \leq i, j, k \leq d \\ i + j + k = d \end{cases} \\ f(Q_{i,j,k}) &= f\left(\frac{i}{d}x_A + \frac{j}{d}x_B + \frac{k}{d}x_C, \frac{i}{d}y_A + \frac{j}{d}y_B + \frac{k}{d}y_C \right) \end{aligned}$$

则 $Q = (\alpha, \beta, \gamma)$ 的 d 次多项式插值为:

$$\begin{aligned} P(Q) &= P(\alpha, \beta, \gamma) \\ &= \sum_{\substack{0 \leq i, j, k \leq d \\ i + j + k = d}} f(Q_{i,j,k}) B_{i,j,k}(Q) \\ &= \sum_{\substack{0 \leq i, j, k \leq d \\ i + j + k = d}} f(Q_{i,j,k}) B_{i,j,k}(\alpha, \beta, \gamma) \end{aligned}$$

其中 Bernstein 多项式的定义如下:

$$\begin{aligned} B_{i,j,k}(\alpha, \beta, \gamma) &= \frac{d!}{i!j!k!} \alpha^i \beta^j \gamma^k \\ \text{where } &\begin{cases} 0 \leq i, j, k \leq d \\ i + j + k = d \end{cases} \end{aligned}$$

特殊地, $d = 1$ 时就是线性插值:

$$\begin{aligned} B_{1,0,0}(\alpha, \beta, \gamma) &= \alpha \\ B_{0,1,0}(\alpha, \beta, \gamma) &= \beta \\ B_{0,0,1}(\alpha, \beta, \gamma) &= \gamma \\ \hline P(Q) &= P(\alpha, \beta, \gamma) \\ &= \alpha f(A) + \beta f(B) + \gamma f(C) \\ &= \alpha f(x_A, y_A) + \beta f(x_B, y_B) + \gamma f(x_C, y_C) \end{aligned}$$

待补充:

- Delaunay triangulation——dual of Voronoi diagram
(目标: 尽量让划分出来的三角形趋近于正三角形)
- More general approach: NURBS (Non-Uniform Rational B-Spline)
(这种方法可以应用到矩形网格和三角网格上)

2.4.3 Shepard 插值

考虑最简单的情况:

给定向量 x_1, x_2 , 定义以下函数:

$$w_1(x) := \frac{1}{\|x - x_1\|}$$

$$w_2(x) := \frac{1}{\|x - x_2\|}$$

我们发现 $\begin{cases} w_1(x_1) = \infty \\ w_1(x_2) = \|x_2 - x_1\|^{-1} \end{cases}$ 和 $\begin{cases} w_2(x_1) = \|x_2 - x_1\|^{-1} \\ w_2(x_2) = \infty \end{cases}$

基于对无穷大归一化的思想, 我们构造:

$$\phi_1(x) := \frac{w_1(x)}{w_1(x) + w_2(x)} = \frac{\|x - x_1\|^{-1}}{\|x - x_1\|^{-1} + \|x - x_2\|^{-1}}$$

$$\phi_2(x) := \frac{w_2(x)}{w_1(x) + w_2(x)} = \frac{\|x - x_2\|^{-1}}{\|x - x_1\|^{-1} + \|x - x_2\|^{-1}}$$

此时就有 $\begin{cases} \phi_1(x_1) = \frac{\infty}{\infty + \|x_2 - x_1\|^{-1}} = 1 \\ \phi_1(x_2) = \frac{\|x_2 - x_1\|^{-1}}{\infty + \|x_2 - x_1\|^{-1}} = 0 \end{cases}$ 和 $\begin{cases} \phi_2(x_1) = \frac{\|x_2 - x_1\|^{-1}}{\infty + \|x_2 - x_1\|^{-1}} = 0 \\ \phi_2(x_2) = \frac{\infty}{\infty + \|x_2 - x_1\|^{-1}} = 1 \end{cases}$

(不过在程序中不能出现 $\frac{\infty}{\infty}$ 的计算, 只需在已知点上直接赋 1 或 0 即可)

Shepard 插值:

给定插值节点 $x_1, \dots, x_n \in \mathbb{R}^d$, 其 Shepard 插值多项式为:

$$\phi(x) := \sum_{i=1}^n f(x_i) \phi_i(x)$$

$$\text{where } \phi_i(x) := \frac{\|x - x_i\|^{-p}}{\sum_{k=1}^n \|x - x_k\|^{-p}} \quad (i = 1, \dots, n)$$

其中 $\|\cdot\|$ 可以是 $\mathbb{R}^d$ 上的任意范数, 常数 $p \geq 1$

在编程时, 我们直接进行以下赋值, 以避免 ∞/∞ 的现象:

$$\phi_i(x_k) = \begin{cases} 1, & \text{if } k = i \\ 0, & \text{otherwise} \end{cases}$$

2.5 最佳平方逼近

2.5.1 线性最小二乘

给定 n 个不同的点及其取值 $(x_1, y_1), \dots, (x_n, y_n) \in \mathbb{R}^2$

给定 m 阶实多项式空间的一组基 $\{\phi_0(x), \phi_1(x), \dots, \phi_m(x)\}$

我们希望确定一个至多 m 次的实系数多项式 $p(x; \beta) = \sum_{i=0}^m \beta_i \phi_i(x)$ 使得 $\sum_{i=1}^n |y_i - p(x_i; \beta)|^2$ 最小化.

这个目标是可变的, 例如变为 "使得 $\sum_{i=1}^n |y_i - p(x_i; \beta)|$ 最小化"

只不过求解起来会更加复杂, 因为需要分类讨论将绝对值打开.

上述问题等价于求解一个线性最小二乘问题:

$$\min_{\beta \in \mathbb{R}^{m+1}} \left\| \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} - \begin{bmatrix} \phi_0(x_1) & \phi_1(x_1) & \cdots & \phi_m(x_1) \\ \phi_0(x_2) & \phi_1(x_2) & \cdots & \phi_m(x_2) \\ \vdots & \vdots & \ddots & \vdots \\ \phi_0(x_n) & \phi_1(x_n) & \cdots & \phi_m(x_n) \end{bmatrix} \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_m \end{bmatrix} \right\|_2$$

- 通常来说目标函数都是残差的 2-范数, 也可以使用 3-范数之类的其他范数, 但求解难度更大, 而且效果与 2-范数相近.
- 我们还可以根据数据点 $(x_1, y_1), \dots, (x_n, y_n)$ 的重要程度对它们赋予权重, 变为加权最小二乘问题.
- 代数最小二乘问题中只有 y 被视为有噪声的, 可通过设计矩阵 X 的 QR 分解求解:

$$\min_{y + \Delta y = X\beta} \|\Delta y\|_2$$

几何最小二乘问题中 X, y 都被视为有噪声的, 可通过增广矩阵 $[X, y]$ 的 SVD 分解求解:

$$\min_{y + \Delta y = (X + \Delta X)\beta} \|[\Delta X, \Delta y]\|_F$$

更多内容可参考 "FDU 高等线性代数 4. Hermite 特征值" 和 "FDU 数值算法 2. 稠密线性最小二乘问题的解法"

(一个有趣的例子)

考虑计算机通讯代价的 α - β 模型.

对于长度为 n 字节的消息, 其通讯所需的时间大致为 $\text{Time}(n) := \alpha + \beta n$

其中 α 是延迟 (latency), 而 β 是每字节的传输时间 (即 $\beta = 1/\text{bandwidth}$)

通常来说 $\alpha \gg \beta \gg 1/\text{time_per_operation}$

我们可以通过编写 MRI 程序进行内部通讯, 获取样本来做线性回归.

- 一种方法是直接对所有样本进行线性回归.
- 另一种方法是先对最小的几个 n 对应的样本进行插值或线性回归, 得到 α , 再对最大的几个 n 对应的样本进行插值或线性回归, 得到 β

有趣的是, 后者取得的效果要比前者好 (因为前者的问题比较病态), 这说明有时走野路子也不一定是坏事.

2.5.2 非线性最小二乘

给定 n 个不同的点及其取值 $(x_1, y_1), \dots, (x_n, y_n) \in \mathbb{R}^2$

我们希望确定一个含参函数 $g(x; \beta)$ 使得 $\sum_{i=1}^n |y_i - g(x_i; \beta)|^2$ 最小化.

关键在于 $g(x; \beta)$ 关于参数 β 可能不是线性的.

一种方法是对其进行某种变换, 使得它关于参数 β 是线性的.


例如 $g(x; \beta) = \beta_1 \exp(\beta_2 x)$ 可以变换为 $\log(g(x; \beta)) = \log(\beta_1) + \beta_2 x$

此时目标变为确定参数 β 使得 $\sum_{i=1}^n |\log(y_i) - \log(g(x_i; \beta))|^2$ 最小化.

(同时我们也需要考虑这样的变换对于问题本身是否适用, 例如上述变换的目标函数中 y_i 变为 $\log(y_i)$)

但许多情况下我们很难将其转化为线性最小二乘问题来求解.

例如使用混合 Gauss 函数 $g(x; \beta) = \beta_1 e^{-(x-\beta_2)^2} + \beta_3 e^{-(x-\beta_4)^2}$ 来拟合如下数据点:



此时一种通用的方法是 Gauss-Newton 法.

考虑非线性最小二乘问题:

$$\min_{\beta \in \mathbb{R}^m} \|r(x, y; \beta)\|_2 := \left\| \begin{bmatrix} y_1 - \phi(x_1; \beta) \\ y_2 - \phi(x_2; \beta) \\ \vdots \\ y_n - \phi(x_n; \beta) \end{bmatrix} \right\|_2$$

Gauss-Newton 法的迭代格式为:

Given initial point $\beta^{(0)} \in \mathbb{R}^m$ ($m < n$)

$k = 0$

for $k = 0 : \text{max_iter}$

$$J^{(k)} = \nabla_{\beta} r(x, y; \beta^{(k)}) = - \begin{bmatrix} \nabla_{\beta} \phi(x_1; \beta^{(k)})^T \\ \nabla_{\beta} \phi(x_2; \beta^{(k)})^T \\ \vdots \\ \nabla_{\beta} \phi(x_n; \beta^{(k)})^T \end{bmatrix} \in \mathbb{R}^{n \times m}$$

solve least squares problem $\Delta \beta^{(k)} := \arg \min_{z \in \mathbb{R}^m} \|r(x, y; \beta^{(k)}) - J^{(k)} z\|_2 = (J^{(k)})^{\dagger} r(x, y; \beta^{(k)})$

$$\beta^{(k+1)} = \beta^{(k)} - \Delta \beta^{(k)}$$

if convergence criteria is reached

break

end

end

其想法与割线法类似, 每步都对残差向量 $r(x, y; \beta^{(k)})$ 关于 Jacobi 矩阵 $J^{(k)}$ 做线性最小二乘, 得到参数向量 $\beta^{(k)}$ 的增量 $\Delta \beta^{(k)} := \arg \min_{z \in \mathbb{R}^m} \|r(x, y; \beta^{(k)}) - J^{(k)} z\|_2 = (J^{(k)})^{\dagger} r(x, y; \beta^{(k)})$ 来更新 $\beta^{(k)}$.

其中 $(J^{(k)})^{\dagger} \in \mathbb{R}^{m \times n}$ 代表 $J^{(k)} \in \mathbb{R}^{n \times m}$ 的 Moore-Penrose 伪逆.

(特别地, 如果 $J^{(k)} \in \mathbb{R}^{n \times m}$ 列满秩, 则 $(J^{(k)})^{\dagger} = ((J^{(k)})^T J^{(k)})^{-1} (J^{(k)})^T \in \mathbb{R}^{m \times n}$)

- 经典的 Gauss-Newton 迭代格式不保证全局收敛性, 但它对很多非线性最小二乘问题都具有局部二次收敛性, 因此初值 $\beta^{(0)}$ 的选取至关重要.

- (阻尼 Gauss-Newton 法)

与割线法类似, Gauss-Newton 法全局不收敛有时是因为一步走得太远了.

我们可以使用 Wolfe 准则选取合适的步长, 控制每一步迭代的跨度.

find suitable stepsize $t_k > 0$ using Wolfe criteria

$$\beta^{(k+1)} = \beta^{(k)} - t_k \Delta \beta^{(k)}$$

- (Levenberg-Marquardt 法)

有时子问题 $\Delta \beta^{(k)} := \arg \min_{z \in \mathbb{R}^m} \|r(x, y; \beta^{(k)}) - J^{(k)} z\|_2 = (J^{(k)})^\dagger r(x, y; \beta^{(k)})$ 较为病态.

我们可以对子问题进行正则化 (即将线性回归变为 Ridge 回归):

$$\begin{aligned} \Delta \beta^{(k)} &:= \arg \min_{z \in \mathbb{R}^m} \|r(x, y; \beta^{(k)}) - J^{(k)} z\|_2^2 + \lambda \|Dz\|_2^2 \\ &= ((J^{(k)})^T J^{(k)} + \lambda D)^{-1} (J^{(k)})^T r(x, y; \beta^{(k)}) \end{aligned}$$

其中 $\lambda > 0$ 为 Tikhonov 正则化系数, $D \in \mathbb{R}^{m \times m}$ 是正定对角阵, 它们均可在迭代过程中动态调整.

一种选择是 $D = I_m$, 即加绝对量; 另一种更常见的选择是 $D = \text{diag}((J^{(k)})^T J^{(k)})$, 即加相对量.

- 与割线法类似, 我们也可使用类似 Broyden 的秩一更新思想对 Jacobi 矩阵 $J^{(k)}$ 进行近似.
- `gnuplot` 是一个基于 Gauss-Newton 法及其变体的拟合工具.

2.5.3 正交多项式

逼近问题的好坏与基 $\{\phi_0(x), \phi_1(x), \dots, \phi_m(x)\}$ 的选取有关, 我们通常选取:

- 正交多项式基 (orthogonal polynomials)
- 三角函数基 (trigonometric functions) (Fourier 变换)
- 球谐函数基 (spherical harmonics)

标准正交基可以极大简化问题的求解, 考虑以下逼近问题:

$$\min_{\phi \in \mathcal{V}} \|f(x) - \phi(x)\|$$

设线性子空间 $\mathcal{V}$ 的标准正交基是 $\{\phi_0(x), \phi_1(x), \dots, \phi_m(x)\}$

上述问题的最优解 ϕ_* 满足: $f(x) = \phi_*(x) + r(x) = c_0 \phi_0(x) + c_1 \phi_1(x) + \dots + c_m \phi_m(x) + r(x)$

其中残差函数 $r \perp \mathcal{V}$, 而 ϕ_* 可视为 f 在线性子空间 $\mathcal{V}$ 上的正交投影.

根据标准正交性我们有:

$$\begin{aligned} \langle f, \phi_i \rangle &= \langle c_0 \phi_0 + c_1 \phi_1 + \dots + c_m \phi_m + r, \phi_i \rangle \\ &= c_0 \langle \phi_0, \phi_i \rangle + c_1 \langle \phi_1, \phi_i \rangle + \dots + c_m \langle \phi_m, \phi_i \rangle + \langle r, \phi_i \rangle \\ &\quad \left(\text{note that } \langle \phi_i, \phi_j \rangle = \delta_{i,j} = \begin{cases} 1, & \text{if } i = j \\ 0, & \text{otherwise} \end{cases} \right) \\ &= c_i \quad (\forall i = 0, 1, \dots, m) \end{aligned}$$

因此我们有:

$$\begin{aligned} \phi_*(x) &= c_0 \phi_0(x) + c_1 \phi_1(x) + \dots + c_m \phi_m(x) \\ &= \langle f, \phi_0 \rangle \phi_0(x) + \langle f, \phi_1 \rangle \phi_1(x) + \dots + \langle f, \phi_m \rangle \phi_m(x) \end{aligned}$$

正交多项式基 $\{p_n(x)\}_{n=0}^\infty$ 满足:

- ① $\deg(p_n) = n$ (这个要求可以锁死正交多项式基的顺序)
- ② $\langle p_m, p_n \rangle = 0 \quad (\forall m \neq n)$

其中 $\langle \cdot, \cdot \rangle$ 是多项式函数空间上的内积:

$$\begin{aligned}
\langle f, g \rangle &:= \int_{-\infty}^{\infty} \tilde{\rho}(x) f(x) \overline{g(x)} dx \\
&= \int_a^b \rho(x) f(x) \overline{g(x)} dx \\
\text{where } \tilde{\rho}(x) &:= \begin{cases} \rho(x), & \text{if } x \in (a, b) \\ 0, & \text{otherwise} \end{cases} \\
&\text{and } \rho(x) \text{ is a nonnegative weight function}
\end{aligned}$$

不同权重函数 $\rho(x)$ 定义的内积可以导出不同的正交多项式基.

可以证明正交多项式基一定有三项递推:

$$\begin{aligned}
x \cdot p_n(x) &= \beta_{n-1} p_{n-1}(x) + \alpha_n p_n(x) + \beta_n p_{n+1}(x) \quad (\forall n \in \mathbb{Z}_+) \\
&\text{for some real constants } \{\alpha_n\}, \{\beta_n\}
\end{aligned}$$

这是因为线性算子 $F[p](x) := x \cdot p(x)$ ($\forall x \in \mathbb{R}$) 是自伴的:

$$\begin{aligned}
\langle F[p], q \rangle &= \int_{-\infty}^{\infty} \rho(x) F[p](x) \overline{q(x)} dx \\
&= \int_{-\infty}^{\infty} \rho(x) \cdot x p(x) \cdot \overline{q(x)} dx \\
&= \int_{-\infty}^{\infty} \rho(x) \cdot p(x) \cdot \overline{x q(x)} dx \\
&= \int_{-\infty}^{\infty} \rho(x) p(x) \overline{F[q](x)} dx \\
&= \langle p, F[q] \rangle
\end{aligned}$$

其中 $p(x), q(x)$ 可以是 $\mathbb{R}$ 上任意的两个复系数多项式.

因此生成正交多项式基的过程是一个 Lanczos 过程:

```

Given polynomial function  $p_0(x)$  of degree zero such that  $\|p_0\| = 1$ 
 $k = -1; \beta_{-1} = 1; p_{-1} \equiv 0; r_{-1} = p_0$ 
while  $\beta_k \neq 0$ 
     $p_{k+1} = \frac{r_k}{\beta_k}$ 
     $k = k + 1$ 
     $\alpha_k = \langle F[p_k], p_k \rangle$ 
     $r_k = F[p_k] - \alpha_k p_k - \beta_{k-1} p_{k-1}$ 
     $\beta_k = \|r_k\|$ 
end

```

其中 $\{p_k\}$ 和 $\{r_k\}$ 均是多项式序列, $\langle \cdot, \cdot \rangle$ 和 $\|\cdot\|$ 是函数空间上的内积和范数.

于是对于任意 $k \in \mathbb{Z}_+$ 我们都有:

$$\begin{aligned}
F[P_k] &= F[p_0, p_1, \dots, p_k] \\
&= [p_0, p_1, \dots, p_k, p_{k+1}] \begin{bmatrix} \alpha_0 & \beta_0 & & & \\ \beta_0 & \alpha_1 & & & \\ & & \ddots & & \\ & & & \ddots & \\ & & & & \beta_{k-1} & \alpha_k \\ & & & & & \beta_k \end{bmatrix}_{(k+2) \times (k+1)} \\
&= P_{k+1} \tilde{T}_{k+1} \\
&= [P_k, p_{k+1}] \begin{bmatrix} T_{k+1} \\ \beta_k e_{k+1}^T \end{bmatrix} \\
&= P_k T_{k+1} + \beta_k p_{k+1} \\
&= P_k T_{k+1} + r_k
\end{aligned}$$

其中 e_{k+1} 是 $\mathbb{R}^{k+1}$ 空间的第 $k+1$ 个标准正交基向量。

这样我们就得到了三项递推关系：

$$\begin{aligned}
F[p_k] &= \beta_{k-1} p_{k-1} + \alpha_k p_k + \beta_k p_{k+1} \\
\text{where } F[p_k](x) &= x \cdot p_k(x)
\end{aligned}$$

注意到 k 次多项式 $p_k(x)$ 一定不属于 $p_0(x), \dots, p_k(x)$ 张成的 Krylov 子空间中。

因此上述 Lanczos 过程理论上可以无限进行下去。

注意到次对角线序列 $\{\beta_k\}$ 是残差归一化产生的范数值，而残差恒不为全零函数，故 $\{\beta_k\}$ 是正实数列。

因此系数矩阵 T_k 是 k 维不可约对称三对角阵。

(Gaussian Quadrature and the Eigenvalue Problem by John A. Gubner)

下面我们证明 $p_n(x)$ 有 n 个不同的根，且它们是 T_{n-1} 的特征值。

设 λ 是 $p_n(x)$ 的一个根。

根据前面的结论我们有：

$$\begin{aligned}
\lambda[p_0(\lambda), p_1(\lambda), \dots, p_{n-1}(\lambda)] &= [\lambda p_0(\lambda), \lambda p_1(\lambda), \dots, \lambda p_{n-1}(\lambda)] \\
&= [F[p_0](\lambda), F[p_1](\lambda), \dots, F[p_{n-1}](\lambda)] \\
&= F[p_0, p_1, \dots, p_{n-1}](\lambda) \\
&= [p_0(\lambda), p_1(\lambda), \dots, p_{n-1}(\lambda), p_n(\lambda)] \begin{bmatrix} \alpha_0 & \beta_0 & & & \\ \beta_0 & \alpha_1 & & & \\ & & \ddots & & \\ & & & \ddots & \\ & & & & \beta_{n-2} & \alpha_{n-1} \\ & & & & & \beta_{n-1} \end{bmatrix}_{(n+1) \times n} \quad (\text{note that } p_n(\lambda) = 0) \\
&= [p_0(\lambda), p_1(\lambda), \dots, p_{n-1}(\lambda), 0] \begin{bmatrix} T_n \\ \beta_{n-1} e_n^T \end{bmatrix} \\
&= [p_0(\lambda), p_1(\lambda), \dots, p_{n-1}(\lambda)] T_n
\end{aligned}$$

由于 $p_0(x)$ 是满足 $\|p_0\| = 1$ 的零次多项式，故它一定是某个非零的常数函数。

因此我们有 $p_0(\lambda) \neq 0$ ，于是 $[p_0(\lambda), p_1(\lambda), \dots, p_{n-1}(\lambda)]$ 一定是非零向量。

这说明 λ 是不可约对称三对角阵 T_n 的特征值，而 $[p_0(\lambda), p_1(\lambda), \dots, p_{n-1}(\lambda)]$ 是对应的左特征向量。

在 "FDU 数值算法 6. 对称特征值问题的解法" 中，我们学习过不可约对称三对角阵的性质。

其中一条就是**不可约对称三对角阵 T_n 具有 n 个互不相同的实特征值**。

此外，在矩阵序列 $\{T_n\}$ 中， T_n 的特征值严格交错分隔 T_{n+1} 的特征值。

(数值线性代数, 定理 7.4.1)

设 T 为不可约对称三对角阵 (即有 $\beta_i \neq 0$ ($i = 1, \dots, n-1$))

记 $T - \lambda I$ 的第 i 阶顺序主子式为 $p_i(\lambda)$ ($i = 1, \dots, n$)，它们满足以下三项递推公式：

$$\begin{aligned}
p_0(\lambda) &\equiv 1 \\
p_1(\lambda) &= \alpha_1 - \lambda \\
p_i(\lambda) &= (\alpha_i - \lambda)p_{i-1}(\lambda) - \beta_{i-1}^2 p_{i-2}(\lambda) \quad (i = 2, \dots, n)
\end{aligned}$$

并且成立:

- ① 存在正数 $M > 0$ 使得当 $\lambda > M$ 时, $p_i(\lambda)$ 的符号为 $(-1)^i$, 而 $p_i(-\lambda)$ 的符号为正.
- ② 相邻两个多项式没有公共根
- ③ 对于任意 $i = 1, \dots, n-1$, 若 $p_i(\mu) = 0$, 则 $p_{i-1}(\mu)p_{i+1}(\mu) < 0$
- ④ $p_i(\lambda)$ 的根都是单重实根,
且对于任意 $i = 1, \dots, n-1$, $p_i(\lambda)$ 的根严格交错分隔 $p_{i+1}(\lambda)$ 的根.

值得注意的是, 根据 $p_n(\lambda) = \det(T - \lambda I)$ 具有 n 个单重实根可知:
不可约对称三对角阵 T 具有 n 个互不相同的实特征值.

因此我们知道:

- ① 第 n 个正交多项式 $p_n(x)$ 具有 n 个不同的实根
- ② 相邻正交多项式的实根之间是严格交错的:

$$\text{Denote } p_n(x) = c_n \prod_{i=1}^n (x - \lambda_i) \text{ and } p_{n+1}(x) = c_{n+1} \prod_{i=1}^n (x - \mu_i)$$

$$\text{Then } \mu_1 < \lambda_1 < \mu_2 < \dots < \mu_n < \lambda_n < \mu_{n+1}$$

其中 $\{c_n\}$ 是 $\{p_n(x)\}$ 的首项系数, 用于归一化范数 $\|p_n\|$.

第 ② 条性质也可以直接从 Hermite 阵特征值的 Cauchy 交错定理得到:

(Cauchy 交错定理, Matrix Analysis 定理 4.3.17)

给定 Hermite 阵 $A \in \mathbb{C}^{n \times n}$, 特征值按非减的次序排列: $\lambda_1(A) \leq \dots \leq \lambda_n(A)$

考虑 A 的 $n-1$ 主子阵 $B = A_{(1:n-1, 1:n-1)} \in \mathbb{C}^{(n-1) \times (n-1)}$, 并记 $A = \begin{bmatrix} B & y \\ y^H & a \end{bmatrix}$

特征值按非减的次序排列: $\lambda_1(B) \leq \dots \leq \lambda_{n-1}(B)$

则我们有如下的交错性质:

$$\begin{aligned}
\lambda_1(A) &\leq \lambda_1(B) \leq \lambda_2(A) \leq \dots \leq \lambda_{n-1}(A) \leq \lambda_{n-1}(B) \leq \lambda_n(A) \\
&\Leftrightarrow \\
\lambda_i(A) &\leq \lambda_i(B) \leq \lambda_{i+1}(A) \quad (\forall i = 1, \dots, n-1)
\end{aligned}$$

其中 $\lambda_i(A) = \lambda_i(B)$ 成立当且仅当存在非零向量 $z \in \mathbb{C}^{n-1}$ 使得 $\begin{cases} Bz = z\lambda_i(B) \\ Bz = z\lambda_i(A) \\ y^H z = 0 \end{cases}$

而 $\lambda_i(B) = \lambda_{i+1}(A)$ 成立当且仅当存在非零向量 $z \in \mathbb{C}^{n-1}$ 使得 $\begin{cases} Bz = z\lambda_i(B) \\ Bz = z\lambda_{i+1}(A) \\ y^H z = 0 \end{cases}$

若 B 没有与 y 正交的特征向量, 则上述不等式均为严格不等式.

假设正交多项式基 $\{p_n(x)\}_{n=0}^\infty$ 由内积 $\langle f, g \rangle := \int_{-\infty}^\infty \tilde{\rho}(x) f(x) g(x) dx$ 导出.

可以证明 n 次正交多项式 $p_n(x)$ 的 n 个实根一定落在权重函数 $\tilde{\rho}(x)$ 的支撑集的凸包中.

值得注意的是, 权重函数 $\tilde{\rho}(x)$ 的支撑集可能是若干个不相交的闭区间,

此时 n 次正交多项式 $p_n(x)$ 的 n 个实根就不一定落在这些小区间上, 而是落在它们的凸包上.

简单起见, 我们假设权重函数的支撑集是单个闭区间 $[a, b]$:

$$\tilde{\rho}(x) := \begin{cases} \rho(x), & \text{if } x \in [a, b] \\ 0, & \text{otherwise} \end{cases}$$

where $\rho(x)$ is a nonnegative weight function

记 $p_n(x)$ 的 n 个实根为 $\lambda_1, \dots, \lambda_n$


(反证法) 不失一般性, 假设 $\lambda_n \notin (a, b)$

定义 $n-1$ 次多项式 $q_n(x) := \prod_{\lambda_i \in (a, b)} (x - \lambda_i) = \prod_{i=1}^{n-1} (x - \lambda_i)$


注意到 $p_n(x)$ 和 $q_n(x)$ 落在区间 (a, b) 中的根是相同的, 而且没有重根.

于是只有两种情况:

- ① 在各个小区间内同号:



- ② 在各个小区间内异号:



无论是哪种情况, $p_n(x)$ 和 $q_n(x)$ 在内积 $\langle \cdot, \cdot \rangle$ 的意义下一定不是正交的:

$$\begin{aligned} \langle p_n, q_n \rangle &= \int_{-\infty}^{\infty} \tilde{\rho}(x) p_n(x) q_n(x) dx \\ &= \int_a^b \rho(x) p_n(x) q_n(x) dx \\ &\neq 0 \end{aligned}$$

注意到 $n-1$ 次多项式 $q_n \in \text{span}\{p_0, p_1, \dots, p_{n-1}\}$

而根据定义, p_n 与 $\text{span}\{p_0, p_1, \dots, p_{n-1}\}$ 正交, 这就与 " p_n 和 q_n 不正交" 的结论相矛盾.

因此逆命题成立, 即 $p_n(x)$ 的 n 个实根都落在区间 (a, b) 中.

(1) Legendre 多项式

Legendre (/lə'ʒɑːndrə/) 多项式是一类在区间 $[-1, 1]$ 上关于权重函数 1 正交的多项式序列:

$$P_n(x) := \frac{((x^2 - 1)^n)^{(n)}}{2^n n!}$$
$$\int_{-1}^1 P_m(x) P_n(x) dx = \begin{cases} 0, & \text{if } m \neq n \\ \frac{2}{2n+1}, & \text{if } m = n \end{cases}$$

三项递推公式:

$$\begin{aligned} P_0(x) &\equiv 1 \\ P_1(x) &= x \\ P_2(x) &= \frac{3x^2 - 1}{2} \\ P_3(x) &= \frac{5x^3 - 3x}{2} \end{aligned}$$

$$(n+1)P_{n+1}(x) = (2n+1)xP_n(x) - nP_{n-1}(x)$$
$$\Updownarrow$$
$$\varphi_{n+1}(x) = (x-0)\varphi_n(x) - \frac{n^2}{4n^2-1}\varphi_{n-1}(x)$$
$$\text{where } \varphi_n(x) := \frac{2^n (n!)^2}{(2n)!} P_n(x)$$

(note that the leading coefficient of $P_n(x)$ is $\frac{(2n)!}{2^n (n!)^2}$)

对应的 Lanczos 系统的系数为: (参见 Homework 06 Problem 5)

$$\begin{aligned} \alpha_k &= 0 \text{ for all } k \geq 0 \\ \beta_k &= \frac{k+1}{\sqrt{(2k+1)(2k+3)}} \text{ for all } k \geq 0 \end{aligned}$$

$$\text{Lanczos matrix: } \begin{bmatrix} \alpha_0 & \beta_0 & & \\ \beta_0 & \alpha_1 & \ddots & \\ & \ddots & \ddots & \beta_{n-2} \\ & & \beta_{n-2} & \alpha_{n-1} \end{bmatrix} = \begin{bmatrix} 0 & \frac{1}{\sqrt{3}} & & \\ \frac{1}{\sqrt{3}} & 0 & \ddots & \\ & \ddots & \ddots & \frac{n-1}{\sqrt{(2n-3)(2n-1)}} \\ & & \frac{n-1}{\sqrt{(2n-3)(2n-1)}} & 0 \end{bmatrix}$$

生成函数:

$$G(x, t) := \sum_{n=0}^{\infty} P_n(x) t^n$$
$$= \frac{1}{\sqrt{1 - 2xt + t^2}}$$

生成函数是将离散量连续化的重要手段。
首先考虑 Fibonacci 数列通项的生成函数:

$$\begin{aligned}
F_0 &= 0 \\
F_1 &= 1 \\
F_n &= F_{n-1} + F_{n-2} \\
\text{Denote } G(x) &:= \sum_{n=0}^{\infty} F_n x^n
\end{aligned}$$

$$\begin{aligned}
G(x) - 0 - x &= \sum_{n=2}^{\infty} F_n x^n = F_2 x^2 + F_3 x^3 + \dots \\
xG(x) - 0 \cdot x &= x \sum_{n=1}^{\infty} F_n x^n = F_1 x^2 + F_2 x^3 + \dots \\
x^2 G(x) &= x^2 \sum_{n=0}^{\infty} F_n x^n = F_0 x^2 + F_1 x^3 + \dots
\end{aligned}$$

根据递推公式 $F_n = F_{n-1} + F_{n-2}$ 我们有:

$$\begin{aligned}
[G(x) - 0 - x] &= [xG(x) - 0 \cdot x] + x^2 G(x) \\
&\Downarrow \\
(1 - x - x^2)G(x) &= x \\
&\Downarrow \\
G(x) &= \frac{x}{1 - x - x^2}
\end{aligned}$$

一般地, 通过分析生成函数 $G(x) := \sum_{n=0}^{\infty} a_n x^n$ 的解析性质 (如收敛半径、奇点位置), 可以反推 $\{a_n\}$ 的渐近行为或递推关系.

其次我们知道 Gamma 函数 $\Gamma(z) := \int_0^{\infty} t^{z-1} e^{-t} dt$ (where $\text{Re}(z) > 0$) 是阶乘 $n!$ 的离散化.

具体来说, $\Gamma(n) = (n-1)!$

此外, Gamma 函数满足递推关系 $\Gamma(z+1) = z\Gamma(z)$

在此基础上, 我们还可以定义广义二次项系数:

$$\begin{aligned}
\binom{z}{w} &:= \frac{\Gamma(z+1)}{\Gamma(w+1)\Gamma(z-w+1)} \\
&\text{where } \text{Re}(z), \text{Re}(w) > 0
\end{aligned}$$

通过将离散量连续化, 我们可以使用连续场景下的诸多手段来处理离散量, 这非常有用.

(2) Laguerre 多项式

Laguerre (/lə'ɡɛr/) 多项式是一类在区间 $[0, \infty)$ 上关于权重函数 e^{-x} 正交的多项式序列:

$$\begin{aligned}
L_n(x) &:= e^x \frac{(x^n e^{-x})^{(n)}}{n!} = \sum_{k=0}^n \binom{n}{k} \frac{(-1)^k}{k!} x^k \\
\int_0^{\infty} e^{-x} L_m(x) L_n(x) dx &= \delta_{m,n} = \begin{cases} 0, & \text{if } m \neq n \\ 1, & \text{if } m = n \end{cases}
\end{aligned}$$

三项递推公式:

$$\begin{aligned}
L_0(x) &\equiv 1 \\
L_1(x) &= 1 - x \\
L_2(x) &= \frac{1}{2}(x^2 - 4x + 2) \\
L_3(x) &= \frac{1}{6}(-x^3 + 9x^2 - 18x + 6) \\
\hline
(n+1)L_{n+1}(x) &= (2n+1-x)L_n(x) - nL_{n-1}(x) \\
&\Updownarrow \\
\varphi_{n+1}(x) &= (x - (2n+1))\varphi_n(x) - n^2\varphi_{n-1}(x) \\
\text{where } \varphi_n(x) &:= \frac{n!}{(-1)^n} L_n(x) \\
&\text{(note that the leading coefficient of } L_n(x) \text{ is } \frac{(-1)^n}{n!})
\end{aligned}$$

对应的 Lanczos 系统的系数为: [\(reference\)](#)

$$\begin{aligned}
\alpha_k &= 2k + 1 \text{ for all } k \geq 0 \\
\beta_k &= k + 1 \text{ for all } k \geq 0
\end{aligned}$$

$$\text{Lanczos matrix: } \begin{bmatrix} \alpha_0 & \beta_0 & & \\ \beta_0 & \alpha_1 & \ddots & \\ & \ddots & \ddots & \beta_{n-2} \\ & & \beta_{n-2} & \alpha_{n-1} \end{bmatrix} = \begin{bmatrix} 1 & 1 & & \\ & 1 & 3 & \ddots \\ & & \ddots & \ddots & n-1 \\ & & & n-1 & 2n-1 \end{bmatrix}$$

生成函数:

$$\begin{aligned}
G(x, t) &= \sum_{n=0}^{\infty} L_n(x) t^n \\
&= \frac{1}{1-t} e^{-xt/(1-t)}
\end{aligned}$$

(3) Hermite 多项式

Hermite 多项式是一类在区间 $(-\infty, \infty)$ 上关于权重函数 e^{-x^2} 正交的多项式序列:

$$\begin{aligned}
H_n(x) &:= (-1)^n e^{x^2} (e^{-x^2})^{(n)} = n! \sum_{k=0}^{\lfloor n/2 \rfloor} \frac{(-1)^k (2x)^{n-2k}}{k!(n-2k)!} \\
\int_{-\infty}^{\infty} e^{-x^2} H_m(x) H_n(x) dx &= \begin{cases} 0, & \text{if } m \neq n \\ \sqrt{n} 2^n n!, & \text{if } m = n \end{cases}
\end{aligned}$$

三项递推公式:

$$\begin{aligned}
H_0(x) &\equiv 1 \\
H_1(x) &= 2x \\
H_2(x) &= 4x^2 - 2 \\
H_3(x) &= 8x^3 - 12x \\
\hline
H_{n+1}(x) &= 2xH_n(x) - 2nH_{n-1}(x) \\
&\Updownarrow \\
\varphi_{n+1}(x) &= (x - 0)\varphi_n(x) - \frac{n}{2}\varphi_{n-1}(x) \\
\text{where } \varphi_n(x) &:= \frac{1}{2^n} H_n(x) \\
&\text{(note that the leading coefficient of } H_n(x) \text{ is } 2^n)
\end{aligned}$$

对应的 Lanczos 系统的系数为: [\(reference\)](#)

$$\alpha_k = 0 \text{ for all } k \geq 0$$
$$\beta_k = \sqrt{\frac{k+1}{2}} \text{ for all } k \geq 0$$

Lanczos matrix:

$$\begin{bmatrix} \alpha_0 & \beta_0 & & \\ \beta_0 & \alpha_1 & \ddots & \\ & \ddots & \ddots & \beta_{n-2} \\ & & \beta_{n-2} & \alpha_{n-1} \end{bmatrix} = \begin{bmatrix} 0 & \sqrt{\frac{1}{2}} & & \\ \sqrt{\frac{1}{2}} & 0 & \ddots & \\ & \ddots & \ddots & \sqrt{\frac{n-1}{2}} \\ & & \sqrt{\frac{n-1}{2}} & 0 \end{bmatrix}$$

生成函数:

$$G(x,t) := \sum_{n=0}^{\infty} \frac{H_n(x)}{n!} t^n$$
$$= 2^{2xt-t^2}$$

(4) 第一类 Chebyshev 多项式

第一类 Chebyshev 多项式是一类在区间 $[-1, 1]$ 上关于权重函数 $1/\sqrt{1-x^2}$ 正交的多项式序列:

$$T_n(x) := \cos[n \arccos(x)] = \frac{(x + \sqrt{x^2 - 1})^n + (x - \sqrt{x^2 - 1})^n}{2}$$

$$\int_{-1}^1 \frac{1}{\sqrt{1-x^2}} T_m(x) T_n(x) dx = \begin{cases} 0, & m \neq n \\ \frac{\pi}{2}, & m = n \neq 0 \\ \pi, & m = n = 0 \end{cases}$$

三项递推公式:

$$T_0(x) \equiv 1$$
$$T_1(x) = x$$
$$T_2(x) = 2x^2 - 1$$
$$T_3(x) = 4x^3 - 3x$$

$$T_n(x) = 2xT_{n-1}(x) - T_{n-2}(x) = 2^{n-1}x^n + \dots$$

对应的 Lanczos 系统的系数为: [\(reference\)](#)

$$\alpha_k = 0 \text{ for all } k \geq 0$$
$$\beta_0 = \frac{1}{\sqrt{2}}$$
$$\beta_k = \frac{1}{2} \text{ for all } k \geq 1$$

Note that the eigenvalues of Lanczos matrix

$$\frac{1}{2} \begin{bmatrix} 0 & \sqrt{2} & & \\ \sqrt{2} & 0 & 1 & \\ & 1 & \ddots & \ddots \\ & & \ddots & 0 & 1 \\ & & & 1 & 0 \end{bmatrix}$$

are $\cos(\frac{2k-1}{2n}\pi) \ (k = 1, 2, \dots, n)$

生成函数:

$$G(x, t) := \sum_{n=0}^{\infty} T_n(x) t^n$$

$$= \frac{1 - tx}{1 - 2tx + t^2}$$

(5) 第二类 Chebyshev 多项式

第二类 Chebyshev 多项式是一类在区间 $[-1, 1]$ 上关于权重函数 $\sqrt{1 - x^2}$ 正交的多项式序列:

$$U_n(x) = \frac{\sin[(n+1)\arccos(x)]}{\sqrt{1-x^2}} = \frac{(x + \sqrt{x^2-1})^{n+1} - (x - \sqrt{x^2-1})^{n+1}}{2\sqrt{x^2-1}}$$

$$\int_{-1}^1 \sqrt{1-x^2} U_m(x) U_n(x) dx = \begin{cases} 0, & \text{if } m \neq n \\ \frac{\pi}{2}, & \text{if } m = n \end{cases}$$

三项递推公式:

$$U_0(x) \equiv 1$$

$$U_1(x) = 2x$$

$$U_2(x) = 4x^2 - 1$$

$$U_3(x) = 8x^3 - 4x$$

$$U_{n+1}(x) = 2xU_n(x) - U_{n-1}(x) = 2^n x^n + \dots$$

对应的 Lanczos 系统的系数为: [\(reference\)](#)

$$\alpha_k = 0 \text{ for all } k \geq 0$$

$$\beta_k = \frac{1}{2} \text{ for all } k \geq 0$$

Note that the eigenvalues of Lanczos matrix $\frac{1}{2} \begin{bmatrix} 0 & 1 & & & \\ 1 & 0 & & & \\ & & \ddots & \ddots & \ddots \\ & & & 1 & 0 & 1 \\ & & & & 1 & 0 \end{bmatrix}$ are $\cos(\frac{k}{n+1}\pi)$ ($k = 1, 2, \dots, n$)

生成函数:

$$G(x, t) := \sum_{n=0}^{\infty} U_n(x) t^n$$

$$= \frac{1}{1 - 2tx + t^2}$$

2.6 最佳一致逼近

2.6.1 Weierstrass 定理

记 $[a, b]$ 上所有连续函数的全体构成的无限维线性空间为 $C([a, b])$

在 $C([a, b])$ 上定义 Chebyshev 范数 $\|\cdot\|_{\infty}$ 为:

$$\|f\|_{\infty} := \max_{x \in [a, b]} |f(x)| \quad (\forall f \in C([a, b]))$$

(Weierstrass 第一定理, 数值逼近, 定理 4.1)

任意给定 $f \in C([a, b])$ 和 $\varepsilon > 0$

都存在代数多项式 $p(x)$ 满足 $\|f - p\|_{\infty} < \varepsilon$

换言之, 任意给定 $f \in C([a, b])$,

都存在多项式序列 $\{p_n\}_{n=1}^{\infty}$ 一致收敛 (即依范数 $\|\cdot\|_{\infty}$ 收敛) 于 f :

$$\lim_{n \rightarrow \infty} \|f - p_n\|_{\infty} = 0$$

- (构造性的证明)

不失一般性, 令 $[a, b] = [0, 1]$

任意给定 $f \in C([0, 1])$ 我们都可以构造 Bernstein 多项式序列:

$$B_n(x) := \sum_{i=0}^n \binom{n}{i} x^i (1-x)^{n-i} f\left(\frac{i}{n}\right) \quad (n = 1, 2, \dots)$$

可以证明 $\{B_n\}_{n=1}^{\infty}$ 一致收敛于 f (即 $\lim_{n \rightarrow \infty} \|f - B_n\|_{\infty} = 0$)

此外, 若 f 在 $[0, 1]$ 上的各阶导数存在, 则可证明 $\{B_n\}_{n=1}^{\infty}$ 的各阶导数也一致收敛于 f 的相应导数.

值得注意的是, Bernstein 多项式的理论性质很好, 但数值计算是不稳定的.

- 无穷区间上的多项式逼近问题是比较困难的.

例如考虑 $f(x) := e^x$ 在 $\mathbb{R}$ 上的多项式逼近, 则对于任意多项式 $p(x)$ 都有 $\|f - p\|_{\infty} = \infty$

例如考虑 $f(x) := \arctan(x)$ 在 $\mathbb{R}$ 上的多项式逼近, 其最佳一致逼近总是 $p(x) \equiv 0$

因此我们通常在闭区间 $[a, b]$ 上考虑多项式逼近问题.

我们自然提出这样的问题:

能否在所有次数不超过 n 的代数多项式集合上,

找到一个对给定函数 $f \in C([a, b])$ 整体上逼近的尽可能好的多项式, 即 Chebyshev 逼近?

记所有至多 n 次的代数多项式全体构成的集合为 $\mathbb{R}_n[x] := \text{span}\{1, x, \dots, x^n\}$

显然 $\mathbb{R}_n[x]$ 是 $C([a, b])$ 上的 $n+1$ 维线性子空间.

我们的任务就是求解:

$$\inf_{p \in \mathbb{R}_n[x]} \|f - p\|_{\infty}$$

可以证明这个优化问题的解存在且唯一, 称为 Chebyshev 最佳一致逼近多项式.

我们这里仅说明存在性:

定义函数 $F(a) := \|f(x) - \sum_{k=0}^n a_k x^k\|_{\infty}$

只要 $a = [a_0, a_1, \dots, a_n]^T$ 的某个分量足够大, $F(a)$ 的值就会爆掉.

对于任意使得 $F(a^{(0)}) \leq F(0_n) = \|f\|_{\infty}$ 的 $a^{(0)} \in \mathbb{R}^n$,

要使得关于 t 的单变量函数 $F(ta^{(0)}) \leq F(0_n)$, t 就必须有界.

于是我们可将 $F(a)$ 的定义域限制在紧集 $K = \{a \in \mathbb{R}^{n+1} : F(a) \leq F(0_n) = \|f\|_{\infty}\}$ 上,

而在完备赋范空间中 (有限维赋范空间一定完备), 紧集上的连续函数一定存在最小值.

因此存在 a_* 使得 $F(a_*) = \min_{a \in K} F(a)$, 即最佳一致逼近多项式一定存在.

2.6.2 交错点组

(偏差集)

定义 $f \in C([a, b])$ 的正偏差集、负偏差集和偏差集为:

$$E^+(f) := \{x \in [a, b] : f(x) = \|f\|_{\infty}\}$$

$$E^-(f) := \{x \in [a, b] : f(x) = -\|f\|_{\infty}\}$$

$$E(f) := \{x \in [a, b] : |f(x)| = \|f\|_{\infty}\} = E^+(f) \cup E^-(f)$$




图 4.1

利用 f 的连续性可知 $E^+(f)$, $E^-(f)$, $E(f)$ 都是有界闭集.

当且仅当 $f \equiv 0$ 时 $E^-(f)$ 和 $E^+(f)$ 相交且为 $[a, b]$

由紧集上连续函数的最值原理可知 $E(f)$ 非空, 但 $E^+(f)$ 和 $E^-(f)$ 其中之一可能为空集.

(交错点组, 数值逼近, 定义 1)

若偏差集 $E(f) := \{x \in [a, b] : |f(x)| = \|f\|_\infty\}$ 上的点集 $\{x_1, \dots, x_k\}$ 满足:

$$\begin{aligned} a \leq x_1 < x_2 < \dots < x_k \leq b \\ f(x_j) = -f(x_{j+1}) \quad (j = 1, 2, \dots, k-1) \end{aligned}$$

则我们称 $\{x_1, \dots, x_k\}$ 为 f 在 $[a, b]$ 上的 **Chebyshev 交错点组**, 简称交错点组.

由 k 个点形成的交错点组称为是极大的, 如果不存在由 k 个以上点组成的交错点组.

• (构造方法)

假设 f 在 $[a, b]$ 上的正负偏差集 $E^+(f)$ 和 $E^-(f)$

记 $S_1 := E^+(f) \cup E^-(f)$, 并按下式递归构造 x_k :

for $k = 1, 2, \dots$, do:

$$x_k := \min S_k$$

$$S_{k+1} := \begin{cases} E^-(f) \cap [x_k, b], & x_k \in E^+(f) \\ E^+(f) \cap [x_k, b], & x_k \in E^-(f) \end{cases}$$

until $S_{k+1} = \emptyset$

注意到 S_k 是有界闭集, 故其一定存在下确界 (于是我们用 $\min$ 代替 $\inf$ 记号)

根据 S_k 的构造可以看出, x_{k+1} 是 $[x_k, b]$ 中与 x_k 符号相反的最小的偏差点,

因此上述构造产生的点列 $x_1, x_2, \dots, x_k$ 是交错且严格单调递增的.

进一步可证明, 若 $f \not\equiv 0$, 则上述构造的交错点组是极大且有限的 (证明从略)





图 4.2

假设已根据上述方法构造出极大交错点组 $x_1, x_2, \dots, x_k$, 我们进而定义:

$$\begin{cases} \xi_0 := a \\ \xi_i := \sup\{x \in [x_i, x_{i+1}] : f(x) = 0\} & i = 1, 2, \dots, k-1 \\ \xi_k := b \end{cases}$$

我们称 $[\xi_{i-1}, \xi_i]$ ($i = 1, 2, \dots, k$) 是 $[a, b]$ 的一个分割.

其中 ξ_i ($i = 1, 2, \dots, k-1$) 的存在性是由介值定理保证的, 它是 $[x_i, x_{i+1}]$ 中的最靠近 x_{i+1} 的零点.



- 一个泛化的概念是非均匀交错点组:

若 $[a, b]$ 上的点集 $\{x_1, \dots, x_k\}$ 满足:

$$\begin{aligned} a &\leq x_1 < x_2 < \dots < x_k \leq b \\ f(x_j)f(x_{j+1}) &< 0 \quad (j = 0, 1, \dots, k-1) \end{aligned}$$

则我们称其为非均匀交错点组, 这里的 "非均匀" 是针对 y 轴而言的, 而不是 x 轴.

(数值逼近, 引理 5.1)

设 $f \in C([a, b])$ 满足 $f \not\equiv 0$, $\{x_1, x_2, \dots, x_k\}$ 是按下式构造的交错点组:

$$\begin{aligned}
& S_1 := E^+(f) \cup E^-(f) \\
& \text{for } k = 1, 2, \dots, \text{ do:} \\
& \quad x_k := \min S_k \\
& \quad S_{k+1} := \begin{cases} E^-(f) \cap [x_k, b], & x_k \in E^+(f) \\ E^+(f) \cap [x_k, b], & x_k \in E^-(f) \end{cases} \\
& \text{until } S_{k+1} = \emptyset
\end{aligned} \tag{1}$$


而 $\{\xi_0, \xi_1, \dots, \xi_k\}$ 是按下式构造的点列:

$$\begin{cases} \xi_0 := a \\ \xi_i := \sup\{x \in [x_i, x_{i+1}] : f(x) = 0\} \quad i = 1, 2, \dots, k-1 \\ \xi_k := b \end{cases} \tag{2}$$

则存在 $0 < \mu_i \leq \|f\|_\infty$ ($i = 1, 2, \dots, k$) 使得对于任意 $x \in [\xi_{i-1}, \xi_i]$ 都有下式成立:

$$\begin{cases} -\|f\|_\infty + \mu_i \leq f(x) \leq \|f\|_\infty, & \text{if } x_i \in E^+(f) \\ -\|f\|_\infty \leq f(x) \leq \|f\|_\infty - \mu_i, & \text{if } x_i \in E^-(f) \end{cases} \tag{3}$$

这个结论是显然的:



(Chebyshev 定理的必要性, 数值逼近, 定理 4.2)

设 $f \in C([a, b])$, 且 $f \notin \mathbb{R}_n[x]$ (其中 $\mathbb{R}_n[x] := \text{span}\{1, x, \dots, x^n\}$)

若 $p(x)$ 是 $f(x)$ 在 $[a, b]$ 上的最佳一致逼近多项式,

则 $f - p$ 有至少 $n + 2$ 个点组成的交错点组.

• 证明:

$f \notin \mathbb{R}_n[x]$ 表明, 对于任意 $p \in \mathbb{R}_n[x]$ 都有 $f - p \not\equiv 0$

于是我们可根据 (1) 构造出 $f - p$ 的一个极大交错点组 $\{x_1, x_2, \dots, x_k\}$

进而可根据 (2) 式可构造 $[a, b]$ 上的一个分割 $[\xi_{i-1}, \xi_i]$ ($i = 1, 2, \dots, k$)


根据数值逼近引理 5.1 可知存在 $0 < \mu_i \leq \|f\|_\infty$ ($i = 1, 2, \dots, k$) 使得对于任意 $x \in [\xi_{i-1}, \xi_i]$ 都有下式成立:

$$\begin{cases} -\|f-p\|_{\infty} + \mu_i \leq f(x) - p(x) \leq \|f-p\|_{\infty}, & \text{if } x_i \in E^+(f-p) \\ -\|f-p\|_{\infty} \leq f(x) - p(x) \leq \|f-p\|_{\infty} - \mu_i, & \text{if } x_i \in E^-(f-p) \end{cases}$$

(下图中我们绘制了最简单的情况, 其中 $\mu_1 = \dots = \mu_k = \|f-p\|_{\infty}$)

(反证法) 假设 $k \leq n+1$

现构造 $k-1$ 次多项式 $\phi(x) := \delta(x - \xi_1)(x - \xi_2) \cdots (x - \xi_{k-1})$



只要 δ 的符号合适而且 $|\delta|$ 足够小, 即满足:

$$\phi(x_1)(f(x_1) - p(x_1)) > 0$$

$$\|\phi\|_{\infty} \leq \frac{1}{2} \min_{1 \leq i \leq k} \mu_i$$

这可以保证 ϕ 在每个小区间 (ξ_{i-1}, ξ_i) 上与 $f-p$ 同号,

同时保证 $\{x_1, x_2, \dots, x_k\}$ 仍是 $(f-p) - \phi$ 的极大交错点组:

(其中系数 $\frac{1}{2}$ 是为了保证 $f-p$ 内部的非偏差点 "晋升" 成为偏差点, 从而保持 "极大性")

- ① 若 x_i 是 $f-p$ 的正偏差点, 则 $\phi(x) > 0$ ($\forall x \in (\xi_{i-1}, \xi_i)$)

于是对于任意 $x \in (\xi_{i-1}, \xi_i)$ 我们有:

$$\begin{aligned} f(x) - p(x) - \phi(x) &\leq \|f-p\|_{\infty} - \phi(x) \quad (\text{note that } \phi(x) > 0) \\ &< \|f-p\|_{\infty} \end{aligned}$$

$$\begin{aligned} f(x) - p(x) - \phi(x) &\geq -\|f-p\|_{\infty} + \mu_i - \phi(x) \quad (\text{note that } \|\phi\|_{\infty} \leq \frac{1}{2} \min_{1 \leq i \leq k} \mu_i) \\ &\geq -\|f-p\|_{\infty} + \mu_i - \frac{\mu_i}{2} \\ &> -\|f-p\|_{\infty} \end{aligned}$$

因此 $|f(x) - p(x) - \phi(x)| < \|f-p\|_{\infty}$ ($\forall x \in (\xi_{i-1}, \xi_i)$)

注意到 $|f(\xi_{i-1}) - p(\xi_{i-1}) - \phi(\xi_{i-1})| = |f(\xi_i) - p(\xi_i) - \phi(\xi_i)| = 0 < \|f-p\|_{\infty}$ 自然成立,

于是我们有 $|f(x) - p(x) - \phi(x)| < \|f-p\|_{\infty}$ ($\forall x \in [\xi_{i-1}, \xi_i]$)

- ② 若 x_i 是 $f-p$ 的负偏差点, 则只需对 $-(f-p)$ 应用 ① 的结论, 得到:

$$\begin{aligned} |-(f(x) - p(x)) - (-\phi(x))| &< \|-(f-p)\|_{\infty} \quad (\forall x \in [\xi_{i-1}, \xi_i]) \\ &\Updownarrow \\ |f(x) - p(x) - \phi(x)| &< \|f-p\|_{\infty} \quad (\forall x \in [\xi_{i-1}, \xi_i]) \end{aligned}$$

综合 ①② 可知 $|f(x) - p(x) - \phi(x)| < \|f-p\|_{\infty}$ ($\forall x \in [a, b]$)

因此我们有 $\|f-p-\phi\|_{\infty} < \|f-p\|_{\infty}$

这说明 $p+\phi \in \mathbb{R}_n[x]$ 是比 $p \in \mathbb{R}_n[x]$ 更好的关于 $f \in C([a, b])$ 的逼近多项式.

这与 " p 是 f 在 $[a, b]$ 上的最佳一致逼近多项式" 的假设相矛盾.
因此我们有 $k \geq n + 2$ 成立, 原命题得证.

2.6.3 Chebyshev 定理

一个关于最小偏差的下界估值定理:

(Vallée-Poisson 定理, 数值逼近, 定理 4.3)

假设 $f \in C([a, b])$

若存在多项式 $p \in \mathbb{R}_n[x]$ 使得 $f - p$ 在 $[a, b]$ 上存在由 $n + 2$ 个点构成的非均匀交错点组 $\{x_1, \dots, x_{n+2}\}$,
则我们有:

$$\min_{p \in \mathbb{R}_n[x]} \|f - p\|_\infty \geq \min_{1 \leq i \leq n+2} |f(x_i) - p(x_i)|$$

- 多项式相关的证明, 导出矛盾的主要方法之一就是让多项式的根 "过多".

- 反证法:

设 $p_\star \in \mathbb{R}_n[x]$ 为 f 的最佳一致逼近多项式.

假设 $\|f - p_\star\|_\infty = \min_{p \in \mathbb{R}_n[x]} \|f - p\|_\infty < \min_{1 \leq i \leq n+2} |f(x_i) - p(x_i)|$

于是对于任意 $i = 1, 2, \dots, n + 2$ 我们都有:

$$\begin{aligned} |f(x_i) - p_\star(x_i)| &\leq \|f - p_\star\|_\infty < \min_{1 \leq i \leq n+2} |f(x_i) - p(x_i)| \leq |f(x_i) - p(x_i)| \\ &\Updownarrow \\ \text{sgn}(p_\star(x_i) - p(x_i)) &= \text{sgn}(f(x_i) - p(x_i) - (f(x_i) - p_\star(x_i))) = \text{sgn}(f(x_i) - p_\star) \end{aligned}$$

这表明 $p_\star - p$ 在 x_i 处取值的符号完全由 $f - p$ 在 x_i 处取值的符号所决定,

即 $p_\star - p$ 在 $x_1, x_2, \dots, x_{n+2}$ 处正负交错取值.

于是根据介值定理可知 $p_\star - p$ 在 (x_1, x_{n+2}) 上至少有 $n + 1$ 个零点.

注意到 $p_\star - p$ 是至多 n 次的多项式, 故必有 $p_\star - p \equiv 0$, 即 $p \equiv p_\star$

因此我们有:

$$\begin{aligned} \|f - p_\star\|_\infty &= \|f - p\|_\infty \\ &= \max_{a \leq x \leq b} |f(x) - p(x)| \\ &\geq \min_{1 \leq i \leq n+2} |f(x_i) - p(x_i)| \end{aligned}$$

这与我们的假设相矛盾, 因此原命题得证.

(Chebyshev 定理, 数值逼近, 定理 4.4)

记 $C([a, b])$ 为 $[a, b]$ 上的连续函数空间, $\mathbb{R}_n[x]$ 是至多 n 次的实系数多项式空间.

任意给定 $f \in C([a, b])$

若 $f \notin \mathbb{R}_n[x]$, 则 p 是 f 的最佳一致逼近多项式 (即 $p := \arg \min_{q \in \mathbb{R}_n[x]} \|f - q\|_\infty$) 的充要条件

是 $f - p$ 在 $[a, b]$ 上存在由至多 $n + 2$ 个点组成的交错点组 (称为 Chebyshev 交错点组)

(值得注意的是, Chebyshev 交错点组不一定是唯一的, 点的个数也可以超过 $n + 2$)

- 必要性证明 (已由数值逼近, 定理 4.2 给出)

- 充分性证明:

若 $f - p$ 在 $[a, b]$ 上存在由至多 $n + 2$ 个点组成的交错点组, 则我们有:

$$\begin{aligned} \|f - p\|_\infty &\geq \min_{q \in \mathbb{R}_n[x]} \|f - q\|_\infty \quad (\text{utilize Vallée-Poisson Theorem}) \\ &\geq \min_{1 \leq i \leq n+2} |f(x_i) - p(x_i)| \quad (\text{note that } \{x_1, x_2, \dots, x_{n+2}\} \text{ is a Chebyshev alteration set}) \\ &= \|f - p\|_\infty \end{aligned}$$

因此上式中的 $\geq$ 均取等, 表明 $\|f - p\|_\infty = \min_{q \in \mathbb{R}_n[x]} \|f - q\|_\infty$

这说明 p 是 f 的最佳一致逼近多项式.

(最佳一致逼近多项式的唯一性, 数值逼近, 推论 4.1)

若 $f \in C([a, b])$, 则在 $\mathbb{R}_n[x]$ 中存在唯一的元素为 f 的最佳一致逼近多项式.

- **证明:** 存在性我们在 2.6.1 节的末尾已经说明过了, 这里只证唯一性.

假设 p_1 和 p_2 都是 f 的至多 n 次最佳一致逼近多项式.

容易证明它们的凸组合 $s(x) := \alpha p_1(x) + (1 - \alpha)p_2(x)$ ($\forall \alpha \in [0, 1]$) 也是至多 n 次最佳一致逼近多项式:

$$\begin{aligned} \|f - s\|_\infty &\geq \min_{p \in \mathbb{R}_n[x]} \|f - p\|_\infty \\ \|f - s\|_\infty &= \|\alpha(f - p_1) + (1 - \alpha)(f - p_2)\|_\infty \\ &\leq \alpha\|f - p_1\|_\infty + (1 - \alpha)\|f - p_2\|_\infty \Rightarrow \|f - s\|_\infty = \min_{p \in \mathbb{R}_n[x]} \|f - p\|_\infty \\ &= \alpha \min_{p \in \mathbb{R}_n[x]} \|f - p\|_\infty + (1 - \alpha) \min_{p \in \mathbb{R}_n[x]} \|f - p\|_\infty \\ &= \min_{p \in \mathbb{R}_n[x]} \|f - p\|_\infty \end{aligned}$$

(鉴于任意 $\alpha \in [0, 1]$ 对于后续证明的效果都是一样的, 我们现在默认 $\alpha \in [0, 1]$ 是固定的值)

根据 Chebyshev 定理可知, 存在 $f - s$ 的 Chebyshev 交错组 $x_0, x_1, \dots, x_{n+1}$

记 $E := \min_{p \in \mathbb{R}_n[x]} \|f - p\|_\infty$

对于任意 $i = 0, 1, \dots, n + 1$ 我们都有:

$$\begin{aligned} E &= |f(x_i) - s(x_i)| \\ &= |\alpha[f(x_i) - p_1(x_i)] + (1 - \alpha)[f(x_i) - p_2(x_i)]| \\ &\leq \alpha|f(x_i) - p_1(x_i)| + (1 - \alpha)|f(x_i) - p_2(x_i)| \\ &\leq \alpha E + (1 - \alpha)E \\ &= E \end{aligned}$$

注意到左右式都是 E , 故上式中的不等号都取等:

$$\begin{cases} \operatorname{sgn}(f(x_i) - p_1(x_i)) = \operatorname{sgn}(f(x_i) - p_2(x_i)) \\ |f(x_i) - p_1(x_i)| = |f(x_i) - p_2(x_i)| = E \end{cases} \quad (i = 0, 1, \dots, n + 1)$$

因此 $x_0, x_1, \dots, x_{n+1}$ 也是 $f - p_1$ 和 $f - p_2$ 的 Chebyshev 交错组,

而且 $f - p_1$ 和 $f - p_2$ 在 $x_0, x_1, \dots, x_{n+1}$ 上的符号是相同的.

这意味着 $f - p_1$ 和 $f - p_2$ 在 $x_0, x_1, \dots, x_{n+1}$ 上相等,

进而意味着 p_1 和 p_2 在 $x_0, x_1, \dots, x_{n+1}$ 上相等,

即 $p_1 - p_2$ 至少有 $x_0, x_1, \dots, x_{n+1}$ 这 $n + 2$ 个根.

由于 $p_1 - p_2$ 是至多 n 次的多项式, 故 $p_1 - p_2 \equiv 0$,

这表明 n 次最佳一致逼近多项式 p_1 和 p_2 是完全相同的多项式.

唯一性得证.

Chebyshev 交错组往往是不唯一的.

然而在个别情况下, Chebyshev 交错组不仅唯一, 而且其中部分点可以被很快确定.

(数值逼近, 推论 4.2)

设 $f \notin \mathbb{R}_n[x]$, p 是 f 的 n 次最佳一致逼近多项式 (即 $p := \arg \min_{q \in \mathbb{R}_n[x]} \|f - q\|_\infty$)

若 f 在 $[a, b]$ 上有 $n + 1$ 阶导数, 且 $f^{(n+1)}$ 在区间 (a, b) 上保号 (恒正或恒负),

则 Chebyshev 交错组唯一 (点的个数为 $n + 2$), 且区间 $[a, b]$ 的端点属于 Chebyshev 交错组.

- **证明:**

若存在两个具有 $n + 2$ 个点的 Chebyshev 交错组,

或存在一个超过 $n + 2$ 个点的 Chebyshev 交错组,

又或者 a, b 其中一点不属于 Chebyshev 交错组,

则 $f - p$ 在 (a, b) 上将至少有 $n + 1$ 个极值点 (而且是极小值点、极大值点、极小值点这样交错的),

即存在 $n + 1$ 个点 $\xi_i \in (a, b)$ ($i = 0, 1, \dots, n$) 使得:

$$f'(\xi_i) - p'(\xi_i) = 0 \quad (i = 0, 1, \dots, n)$$

反复利用 Roole 定理可知存在 $\eta \in (a, b)$ 使得:

$$f^{(n+1)}(\eta) - p^{(n+1)}(\eta) = f^{(n+1)}(\eta) = 0$$

这与 $f^{(n+1)}(x)$ 在 (a, b) 上保号的假设相矛盾.

因此 Chebyshev 交错组的点的个数为 $n + 2$, 且区间 $[a, b]$ 的端点属于 Chebyshev 交错组.

(数值逼近, 例 4.1)

试在线性函数类中求 e^x 在 $[0, 1]$ 上的最佳一致逼近多项式.

• 证明:

假设 e^x 的 1 次最佳一致逼近多项式为 $p(x) := a_1x + a_0$

由于 e^x 的二阶导数在 $[0, 1]$ 上保号,

故根据数值逼近推论 4.2 可知 Chebyshev 交错组唯一 (点的个数为 3),

且区间端点 0, 1 属于 Chebyshev 交错组.

记 Chebyshev 交错组为 $\{x_0, x_1, x_2\}$, 其中 $x_0 = 0, x_2 = 1$, 而 x_1 满足:

$$\frac{d}{dx}\{e^x - a_1x - a_0\}\Big|_{x=x_1} = e^{x_1} - a_1 = 0$$

根据交错性质我们有:

$$\begin{cases} e^0 - a_1 \cdot 0 - a_0 = \mu \\ e^{x_1} - a_1 \cdot x_1 - a_0 = -\mu \\ e^1 - a_1 \cdot 1 - a_0 = \mu \end{cases}$$

解得:

$$\begin{cases} a_1 = e - 1 \\ x_1 = \log(e - 1) \\ a_0 = \frac{1}{2}[e - (e - 1)\log(e - 1)] \\ \mu = 1 - \frac{1}{2}[e - (e - 1)\log(e - 1)] \end{cases}$$

因此 e^x 在 $[0, 1]$ 上的 1 次最佳一致逼近多项式为:

$$y = (e - 1)x + \frac{1}{2}[e - (e - 1)\log(e - 1)]$$

2.6.4 Remez 算法

Remez 采用逐次逼近的思想, 提出了求 $C([a, b])$ 上最佳一致逼近多项式的近似算法.

设 $f \in C([a, b])$, n 次最佳一致逼近多项式 $p_*(x) := \sum_{k=0}^n a_k x^k$

根据 Chebyshev 定理可知, 问题的关键在于确定一个具有 $n + 2$ 个点的 Chebyshev 交错点组 $\{x_0, \dots, x_{n+1}\}$

如果这个点组找到了, 则我们有:

$$f(x_i) - p_*(x_i) = f(x_i) - \sum_{k=0}^n a_k x_i^k = (-1)^i \mu$$

$$(i = 0, 1, \dots, n+1)$$

$$\text{where } \mu = -\min_{q \in \mathbb{R}_n[x]} \|f - p\|_\infty \text{ or } \min_{q \in \mathbb{R}_n[x]} \|f - p\|_\infty$$

$$\Updownarrow$$

$$\begin{bmatrix} 1 & x_0 & \cdots & x_0^n & (-1)^0 \\ 1 & x_1 & \cdots & x_1^n & (-1)^1 \\ \vdots & \vdots & & \vdots & \vdots \\ 1 & x_n & \cdots & x_n^n & (-1)^n \\ 1 & x_{n+1} & \cdots & x_{n+1}^n & (-1)^{n+1} \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_n \\ \mu \end{bmatrix} = \begin{bmatrix} f(x_0) \\ f(x_1) \\ \vdots \\ f(x_n) \\ f(x_{n+1}) \end{bmatrix}$$

这是一个类 Vandermonde 线性系统.

• (Homework 07 Problem 02)

可以证明该系数矩阵非奇异, 因此具有唯一解, 从而有唯一的 n 次最佳逼近多项式 $p_*(x)$ 和最优值 $|\mu|$.

• (Homework 07 Problem 06)

求解这个线性系统等价于求解多项式插值问题 (可以显著提高解的精度)

寻找 Chebyshev 交错点组并不是一件容易的事.

为此, Remez 提出了一种近似算法, 它由以下 3 步构成:

- ① 在 $[a, b]$ 上选 $n+2$ 个由小到大的初始点列 $\{x_0, x_1, \dots, x_{n+1}\}$ 作为近似交错组, 并设置精度 $\varepsilon > 0$
- ② 求解线性系统:

$$\begin{bmatrix} 1 & x_0 & \cdots & x_0^n & (-1)^0 \\ 1 & x_1 & \cdots & x_1^n & (-1)^1 \\ \vdots & \vdots & & \vdots & \vdots \\ 1 & x_n & \cdots & x_n^n & (-1)^n \\ 1 & x_{n+1} & \cdots & x_{n+1}^n & (-1)^{n+1} \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_n \\ \mu \end{bmatrix} = \begin{bmatrix} f(x_0) \\ f(x_1) \\ \vdots \\ f(x_n) \\ f(x_{n+1}) \end{bmatrix}$$

得到近似多项式 $p(x) := a_n x^n + \cdots + a_1 x + a_0$ 和近似偏差 $|\mu|$

- ③ 若 $\|f - p\|_\infty - |\eta| \leq \varepsilon$, 则迭代终止;
否则用偏差集 $E(f - p)$ 中的点取代 $\{x_0, x_1, \dots, x_{n+1}\}$ 中的点,
构成新的近似交错点组, 使 $f - p$ 在新点组上正负相间, 跳转至 ②

构造新的近似交错点组的方法如下:

设 x_{new} 为偏差集 $E(f - p)$ 中的一点.

(它可通过对 $f - p$ 使用当前某个交错点为初值的 Newton 迭代来寻找, 即用局部最优代替全局最优)

- 当 $x_{\text{new}} \in [a, x_0)$ 时:
若 $f(x_{\text{new}}) - p(x_{\text{new}})$ 与 $f(x_0) - p(x_0)$ 同号, 则用 x_{new} 取代 x_0 , 得到 $\{x_{\text{new}}, x_1, \dots, x_{n+1}\}$
否则将 x_{new} 插在 x_0 之前, 并挤出 x_{n+1} , 得到 $\{x_{\text{new}}, x_0, \dots, x_n\}$
- 当 $x_{\text{new}} \in (x_{n+1}, b]$ 时:
若 $f(x_{\text{new}}) - p(x_{\text{new}})$ 与 $f(x_{n+1}) - p(x_{n+1})$ 同号, 则用 x_{new} 取代 x_{n+1} , 得到 $\{x_0, \dots, x_n, x_{\text{new}}\}$
否则将 x_{new} 插在 x_{n+1} 之后, 并挤出 x_0 , 得到 $\{x_1, \dots, x_{n+1}, x_{\text{new}}\}$
- 当 $x_{\text{new}} \in (x_i, x_{i+1})$ 时:
若 $f(x_{\text{new}}) - p(x_{\text{new}})$ 与 $f(x_i) - p(x_i)$ 同号, 则用 x_{new} 取代 x_i ;
否则取代 x_{i+1}

我们可以用 $E(f - p)$ 中的多个点按上述法则依次取代 $\{x_0, x_1, \dots, x_{n+1}\}$ 中的点.

下图展示了 $n = 1$ 时的交换情况:

- 对于图 (a), 新的近似交错组为 $\{x_{\text{new}}, x_0, x_1\}$
- 对于图 (b), 新的近似交错组为 $\{x_0, x_1, x_{\text{new}}\}$
- 对于图 (c), 新的近似交错组为 $\{x_0, x_{\text{new}}, x_2\}$
- 对于图 (d), 若使用同时交换法, 则新的近似交错组为 $\{a, x_{\text{new}}, b\}$




图 4.4

2.6.5 三角多项式

- 三角多项式 $\sum_{n=-k}^k c_n e^{inx}$ 在 $[-\pi, \pi]$ 中也只有有限个点.
 这是可以通过构造 $[-\pi, \pi]$ 上的双射 $z := e^{ix}$ 将三角多项式 $\sum_{n=-k}^k c_n e^{inx}$ 变为 $\sum_{n=-k}^k c_n z^n$
 因此其根的个数和多项式 $\sum_{n=-k}^k c_n z^{n+k}$ 一样, 都是有限个.
 (三角多项式插值参见 FDU 数值算法 4. 快速 Fourier 变换)
- 代数数是整系数多项式 $\sum_{k=0}^n a_k x^k$ 的根, 其中 $a_k \in \mathbb{Z}$
 代数函数是由变量 t 的系数多项式所定义的多项式方程 $\sum_{k=0}^n a_k(t)(x(t))^k$ 的根,
 其中 $a_k \in \mathbb{C}[t]$ 为复系数多项式.
 例如 $x(t) := \sqrt{t}$ 就是代数函数, 它是方程 $(x(t))^2 - t = 0$ 的根.
 代数函数同样只有有限个根.

2.7 其他逼近

2.7.1 Taylor 逼近

假设 $f(x)$ 在 $x = 0$ 处充分光滑, 则其在 $x = 0$ 处的 n 阶 Taylor 展开式为:

$$\begin{aligned}
f(x) &= \sum_{k=0}^{\infty} \frac{f^{(k)}(0)}{k!} x^k \\
&= \sum_{k=0}^n \frac{f^{(k)}(0)}{k!} x^k + \frac{f^{(n+1)}(\xi)}{(n+1)!} x^{n+1} \quad (\text{where } \xi \in (0, x)) \\
&= \sum_{k=0}^n \frac{f^{(k)}(0)}{k!} x^k + O(x^{n+1})
\end{aligned}$$

常用函数在 $x = 0$ 处的 Taylor 级数:

$$\begin{aligned}
\exp(x) &= \sum_{k=0}^{\infty} \frac{x^k}{k!} \\
\cos(x) &= \sum_{k=0}^{\infty} (-1)^k \frac{x^{2k}}{(2k)!} \\
\sin(x) &= \sum_{k=0}^{\infty} (-1)^k \frac{x^{2k+1}}{(2k+1)!} \\
\log(1-x) &= \sum_{k=1}^{\infty} \frac{x^k}{k} \quad (x < 1) \\
\frac{1}{1-x} &= \sum_{k=0}^{\infty} x^k \quad (x < 1) \\
\sqrt{x} &= 1 - \sum_{k=1}^{\infty} \frac{(1-x)^k}{2^k} \quad (x > 0) \\
\frac{e^x - 1}{x} &= \sum_{k=0}^{\infty} \frac{x^k}{(k+1)!}
\end{aligned}$$

2.7.2 Padé 逼近

设 $f \in C^{n+1}([-a, a])$, $n = p + q$

若有理函数 $R_{p,q}(x) = \frac{P(x)}{Q(x)}$ 满足:

- ① $\deg(P) \leq p$, $\deg(Q) \leq q$, 即 $R_{p,q}(x)$ 形如 $R_{p,q}(x) = \frac{a_p x^p + \dots + a_1 x + a_0}{b_q x^q + \dots + b_1 x + b_0}$
- ② 公因式 $\gcd(P, Q) = 1$
- ③ $Q(0) = 1$ (即要求 $b_0 = 1$)
- ④ 第 $0, 1, \dots, p+q$ 阶导数相同, 即对于 $k = 0, 1, \dots, p+q$ 都有:

$$R_{p,q}^{(k)}(0) = f^{(k)}(0) = T_{p+q}^{(k)}(0)$$

$$\text{where } T_{p+q}(x) = \sum_{s=0}^{p+q} \frac{f^{(s)}(0)}{s!} x^s$$

$$\Downarrow$$

$$h^{(k)}(0) = 0$$

$$\text{where } h(x) := Q(x)(T_{p+q}(x) - R_{p,q}(x)) = Q(x)T_{p+q}(x) - P(x)$$

则我们称 $R_{p,q}$ 为 f 的 $[p/q]$ 阶 **Padé 逼近**.

- 绝大多数情况下, 给定阶数的 Padé 逼近存在且唯一.
我们通常使用对角 Padé 逼近, 即 $p = q$ 的情形.
- $[p/q]$ 阶 Padé 逼近的误差阶与 $p+q$ 阶 Taylor 逼近的误差阶相同:

$$\text{Taylor: } f(x) = \sum_{k=0}^{p+q} \frac{f^{(k)}(0)}{k!} x^k + O(x^{p+q+1})$$

$$\text{Pade: } f(x) = R_{p,q}(x) + O(x^{p+q+1})$$

事实上, 当 $q = 0$ 时 Padé 逼近退化为 Taylor 逼近.

我们可以通过求解线性方程组来获得 Padé 逼近 $R_{p,q}(x)$ 的系数.

根据定义我们有:

$$\begin{aligned} h^{(k)}(0) &= 0 \text{ for all } k = 0, 1, \dots, p+q \\ \text{where } \begin{cases} R_{p,q}(x) &:= \frac{P(x)}{Q(x)} = \frac{a_p x^p + \dots + a_1 x + a_0}{b_q x^q + \dots + b_1 x + b_0} \\ T_{p+q}(x) &= \sum_{s=0}^{p+q} \frac{f^{(s)}(0)}{s!} x^s \\ h(x) &:= Q(x)(T_{p+q}(x) - R_{p,q}(x)) = Q(x)T_{p+q}(x) - P(x) \end{cases} \end{aligned}$$

于是我们有:

$$\begin{aligned} h^{(k)}(0) &= \frac{d^k}{dx^k} \{T_{p+q}(x)Q(x) - P(x)\} \Big|_{x=0} \quad (\text{utilize Leibniz formula}) \\ &= \sum_{j=0}^k \binom{k}{j} T_{p+q}^{(j)}(0) Q^{(k-j)}(0) - P^{(k)}(0) \\ &= \sum_{j=0}^k \left\{ \frac{k!}{j!(k-j)!} \cdot \left(j! \cdot \frac{f^{(j)}(0)}{j!} \right) \cdot ((k-j)! \cdot b_{k-j}) \right\} - k! \cdot a_k \\ &= k! \sum_{j=0}^k \frac{f^{(j)}(0)}{j!} b_{k-j} - k! \cdot a_k \\ &= 0 \end{aligned}$$

$$a_k = \sum_{j=0}^k c_j b_{k-j}$$

$$\text{where } c_j := \frac{f^{(j)}(0)}{j!} \text{ and } k = 0, 1, \dots, p+q$$

注意到 $b_0 = 1$, $b_m = 0$ ($\forall m > q$), $a_m = 0$ ($\forall m > p$)

于是我们有:

$$\begin{cases} c_{p-q+1}b_q + \dots + c_p b_1 = -c_{p+1} \\ c_{p-q+2}b_q + \dots + c_{p+1}b_1 = -c_{p+2} \\ \dots \\ c_p b_q + \dots + c_{p+q-1}b_1 = -c_{p+q} \end{cases}$$

$$\text{and } a_k = \sum_{j=0}^{k-1} c_j b_{k-j} + c_k \text{ for } k = 0, 1, \dots, p$$

其中我们约定序号为负的 c_j 为零, 即 $c_j = 0$ ($\forall j < 0$), 而序号为正的 $c_j = f^{(j)}(0)/j!$

因此问题的关键是求解这样一个线性方程组:

$$\begin{bmatrix} c_{p-q+1} & c_{p-q+2} & \dots & c_{p-1} & c_p \\ c_{p-q+2} & c_{p-q+3} & \dots & c_p & c_{p+1} \\ \vdots & \vdots & & \vdots & \vdots \\ c_{p-1} & c_p & \dots & c_{p+q-3} & c_{p+q-2} \\ c_p & c_{p+1} & \dots & c_{p+q-2} & c_{p+q-1} \end{bmatrix} \begin{bmatrix} b_q \\ b_{q-1} \\ \vdots \\ b_2 \\ b_1 \end{bmatrix} = \begin{bmatrix} -c_{p+1} \\ -c_{p+2} \\ \vdots \\ -c_{p+q-1} \\ -c_{p+q} \end{bmatrix}$$

得到 $b_1, b_2, \dots, b_q$ 后用 $a_k = \sum_{j=0}^{k-1} c_j b_{k-j} + c_k$ 计算出 $a_0, a_1, \dots, a_p$

最终得到 $[p/q]$ 阶 Padé 逼近:

$$R_{p,q}(x) := \frac{a_p x^p + \cdots + a_1 x + a_0}{b_q x^q + \cdots + b_1 x + b_0} \text{ where } b_0 = 1$$

例如指数函数 e^x 的 Padé 逼近为:

$$R_{p,q}(x) := (D_{p,q}(x))^{-1} N_{p,q}(x)$$

其中:

$$N_{p,q}(x) = \sum_{k=0}^p \frac{(p+q-k)!}{(p+q)!} \binom{p}{k} x^k = \sum_{k=0}^p \frac{(p+q-k)! p!}{(p+q)! k! (p-k)!} x^k$$

$$D_{p,q}(x) = \sum_{k=0}^q \frac{(p+q-k)!}{(p+q)!} \binom{q}{k} (-x)^k = \sum_{k=0}^q \frac{(p+q-k)! q!}{(p+q)! k! (q-k)!} (-x)^k$$

下面列举一些低阶情形:

$$R_{1,1}(x) := \frac{1 + \frac{1}{2}x}{1 - \frac{1}{2}x}$$

$$R_{1,2}(x) := \frac{1 + \frac{1}{3}x}{1 - \frac{2}{3}x + \frac{1}{6}x^2}$$

$$R_{2,1}(x) := \frac{1 + \frac{2}{3}x + \frac{1}{6}x^2}{1 - \frac{1}{3}x}$$

$$R_{2,2}(x) := \frac{1 + \frac{1}{2}x + \frac{1}{12}x^2}{1 - \frac{1}{2}x + \frac{1}{12}x^2}$$

特殊地, 当 $q = 0$ 时即为 p 阶 Taylor 多项式:

$$R_{p,0}(x) = \sum_{k=0}^p \frac{x^k}{k!}$$

2.7.3 Bézier 曲线

给定一条已知曲线, 要求构造一条由简单函数表示的曲线, 跟它拟合得比较好, 这就是曲线拟合问题.

一种方法是在该曲线上选择一些型值点来插值, 但拟合的好坏与型值点的取法有关.

要找好的型值点就得不断计算插值, 工作量是很大的.

另一种方法是选取一些控制点, 曲线不一定要通过这些控制点, 但通过调整控制点使构造的曲线变动, 达到拟合目标曲线的要求.

(Bézier Curves, 数值逼近, 定义 3.2)


不失一般性, 设 $P_i = [x_i, y_i]^T$ ($i = 0, 1, \dots, n$) 是平面上由左到右排列的 $n+1$ 个控制点.

定义 $[0, 1]$ 上的 n 次 Bernstein 多项式的 $n+1$ 个基函数为:

$$B_{i,n}(t) := \binom{n}{i} t^i (1-t)^{n-i} \quad (i = 0, 1, \dots, n)$$

则我们定义由 $P_0, P_1, \dots, P_n$ 定义的 n 次 **Bézier 曲线**为:

$$\begin{bmatrix} x(t) \\ y(t) \end{bmatrix} = B(t) = \sum_{i=0}^n B_{i,n}(t) P_i = \sum_{i=0}^n B_{i,n}(t) \begin{bmatrix} x_i \\ y_i \end{bmatrix}$$



容易验证, n 次 Bernstein 多项式的 $n + 1$ 个基函数具有以下性质:

- ① $B_{i,n}(t) \geq 0 \ (t \in [0, 1])$
- ② $\sum_{i=0}^n B_{i,n}(t) = \sum_{i=0}^n \binom{n}{i} t^i (1-t)^{n-i} = (t + (1-t))^n \equiv 1$
将控制点 $P_0, P_1, \dots, P_n$ 依次相连, 终点 P_n 与始点 P_0 再相连, 得到**特征多边形**.
结合 ① 和 ② 可知 Bézier 曲线上的点都是控制点的**凸组合**.
(数值逼近, 定理 3.8) 当特征多边形是凸多边形时, Bézier 曲线也是凸的, 且落在这个凸包之内.
- ③ $B_{i,n}(t) = B_{n-i,n}(1-t)$
- ④ $B'_{i,n}(t) = n[B_{i-1,n-1}(t) - B_{i,n-1}(t)]$
其中我们定义 $B_{-1,n-1}(t) \equiv 0$
- ⑤ $B_{i,n}(t) = (1-t)B_{i,n-1}(t) + tB_{i-1,n-1}(t)$
其中我们定义 $B_{-1,n-1}(t) \equiv 0$
- ⑥ $B_{i,n}(t)$ 在 $t = i/n$ 时达到最大值

Bézier 曲线不但经过 P_0 和 P_n , 而且还与线段 $\overline{P_0P_1}$ 和 $\overline{P_{n-1}P_n}$ 相切:

$$B(0) = \sum_{i=0}^n B_{i,n}(0)P_i = P_0$$

$$B(1) = \sum_{i=0}^n B_{i,n}(1)P_i = P_n$$

$$\begin{aligned} B'(t) &= \sum_{i=0}^n B'_{i,n}(t)P_i \\ &= \sum_{i=0}^n n[B_{i-1,n-1}(t) - B_{i,n-1}(t)] \cdot P_i \quad (\text{note that } B_{-1,n-1}(t) \equiv 0) \\ &= n \sum_{i=0}^n (P_{i+1} - P_i)B_{i,n-1}(t) \end{aligned}$$

$$B'(0) = n \sum_{i=0}^n (P_{i+1} - P_i)B_{i,n-1}(0) = n(P_1 - P_0)$$

$$B'(1) = n \sum_{i=0}^n (P_{i+1} - P_i)B_{i,n-1}(1) = n(P_n - P_{n-1})$$

(Casteljau 作图定理, 数值逼近, 定理 3.6)

设 $P_i = [x_i, y_i]^T$ ($i = 0, 1, \dots, n$) 是平面上由左到右排列的 $n + 1$ 个控制点.

定义 $P_{i,0} := P_i$ ($i = 0, 1, \dots, n$)

对于任意 $t \in (0, 1)$, 依次构造:

$$\begin{aligned} P_{i,1} &:= (1-t)P_{i,0} + tP_{i+1,0} & i = 0, 1, \dots, n-1 \\ P_{i,2} &:= (1-t)P_{i,1} + tP_{i+1,1} & i = 0, 1, \dots, n-2 \\ &\dots & \\ P_{i,k} &:= (1-t)P_{i,k-1} + tP_{i+1,k-1} & i = 0, 1, \dots, n-k \\ &\dots & \\ P_{i,n-1} &:= (1-t)P_{i,n-2} + tP_{i+1,n-2} & i = 0, 1 \\ P_{0,n} &:= (1-t)P_{0,n-1} + tP_{1,n-1} \end{aligned}$$

可以证明 Bézier 曲线上的点 $B(t) = P_{0,n}$ 且 $B'(t) = n(P_{1,n-1} - P_{0,n-1})$.

换言之, 对于任意 $t \in (0, 1)$, $B(t)$ 的位置可以这样得到:




图 3.2

在作图定理中, 当 $P_{0,0}, P_{1,0}, \dots, P_{n,0}$ 取定后, $P_{i,k}$ ($i = 0, 1, \dots, n-k$) 是由 t 唯一确定的.

我们将 $P_{i,k}$ ($i = 0, 1, \dots, n-k$) 记为 $P_{i,k}(t)$ ($i = 0, 1, \dots, n-k$).

给定 $t = w$, 考虑两组点 $P_{0,0}, P_{0,1}(w), P_{0,2}(w), \dots, P_{0,n}(w)$ 和 $P_{0,n}(w), P_{1,n-1}(w), \dots, P_{n-1,1}(w), P_{n,0}$, 每组点都构成一个特征多边形, 也可以构造出以它们为控制点的两条 Bézier 曲线.

这样构造出的 Bézier 曲线跟原来的, 即以 $P_{0,0}, P_{1,0}, \dots, P_{n,0}$ 的 Bézier 曲线有什么关系?

(分解定理, 数值逼近, 定理 3.7)

任意给定 $0 \leq w \leq 1$ 都有:

$$B_{P_{0,0}, P_{1,0}, \dots, P_{n,0}}(t) = \begin{cases} B_{P_{0,0}, P_{0,1}(w), P_{0,2}(w), \dots, P_{0,n}(w)}\left(\frac{t}{w}\right), & 0 \leq t \leq w \\ B_{P_{0,n}(w), P_{1,n-1}(w), \dots, P_{n-1,1}(w), P_{n,0}}\left(\frac{t-w}{1-w}\right), & w < t \leq 1 \end{cases}$$

The End