

FDU 回归分析 1. 简单线性回归

本文根据王勤文老师课堂笔记整理而成，并参考以下教材：

- Statistical Inference (2nd Edition, G. Casella) Chapter 11
- 统计推断 (第 2 版, G. Casella) 第 11 章
- All of Statistics (L. Wasserman)
- 统计学完全教程 (L. Wasserman)
- 应用回归分析 (第 5 版, 何晓群, 刘文卿) 第 2 章
- 数理统计讲义 (郑明, 陈子毅, 汪嘉冈) 第 1 章

欢迎批评指正!

1.1 简单线性回归模型

给定随机变量 (X, Y) 的 n 个观测 $(x_1, y_1), \dots, (x_n, y_n)$, 我们希望推断 X, Y 之间的关系. 在通常的应用中我们通常把 X 称为**自变量** (independent variable) 或**解释变量** (predictor) 而把 Y 称为**因变量** (dependent variable) 或**响应变量** (response variable)

具体来说, 在简单线性回归中我们假设 X, Y 有如下关系:

$$Y = \alpha + \beta X + \varepsilon,$$

其中 α, β 是固定的未知参数, 分别称为回归方程的**截距** (intercept) 和**斜率** (slope). 我们通常假设 ε 为零均值随机噪音 (若其均值非零, 则我们可将其均值并入 α), 因此我们有:

$$\mathbb{E}(Y|X) = \alpha + \beta X.$$

值得注意的是, 线性回归中的 "线性" 一词是指**对于参数是线性的**.

因此 $\mathbb{E}(Y|X) = \alpha + \beta X^2$ 和 $\mathbb{E}(\log(Y)|X) = \alpha + \beta \frac{1}{X}$ 也都是线性回归.

1.1.1 基础模型

设观测样本是 n 个数据对 $(x_1, y_1), \dots, (x_n, y_n)$, 其中 $x_1, \dots, x_n$ 为随机变量 $X_1, \dots, X_n$ 的实现 (但暂时视其为已知的固定常数), 而 $y_1, \dots, y_n$ 是随机变量 $Y_1, \dots, Y_n$ 的观测值. 我们假设:

$$\mathbb{E}(Y_i|X = x_i) = \alpha + \beta x_i \quad (i = 1, \dots, n).$$

这个模型也可等价表示为:

$$Y_i = \alpha + \beta x_i + \varepsilon_i \quad (i = 1, \dots, n),$$

其中 $\varepsilon_1, \dots, \varepsilon_n$ 是零均值随机变量 (我们暂且不对它们的相关性或分布做任何假设). 基于观测样本 $(x_1, y_1), \dots, (x_n, y_n)$, 我们定义下面的量:

$$\begin{aligned}
\bar{x} &= \frac{1}{n} \sum_{i=1}^n x_i = \frac{1}{n} \mathbf{1}_n^T \mathbf{x} \\
\bar{y} &= \frac{1}{n} \sum_{i=1}^n y_i = \frac{1}{n} \mathbf{1}_n^T \mathbf{y} \\
\hline
S_{xx} &= \sum_{i=1}^n (x_i - \bar{x})^2 \\
&= (\mathbf{x} - \bar{x} \mathbf{1}_n)^T (\mathbf{x} - \bar{x} \mathbf{1}_n) \\
&= \mathbf{x}^T \mathbf{x} - 2\bar{x} \mathbf{1}_n^T \mathbf{x} + \bar{x}^2 \mathbf{1}_n^T \mathbf{1}_n \\
&= \mathbf{x}^T \mathbf{x} - 2n\bar{x}^2 + n\bar{x}^2 \\
&= \mathbf{x}^T \mathbf{x} - n\bar{x}^2 \\
S_{yy} &= \sum_{i=1}^n (y_i - \bar{y})^2 \\
&= (\mathbf{y} - \bar{y} \mathbf{1}_n)^T (\mathbf{y} - \bar{y} \mathbf{1}_n) \\
&= \mathbf{y}^T \mathbf{y} - 2\bar{y} \mathbf{1}_n^T \mathbf{y} + \bar{y}^2 \mathbf{1}_n^T \mathbf{1}_n \\
&= \mathbf{y}^T \mathbf{y} - 2n\bar{y}^2 + n\bar{y}^2 \\
&= \mathbf{y}^T \mathbf{y} - n\bar{y}^2 \\
S_{xy} &= \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \\
&= (\mathbf{x} - \bar{x} \mathbf{1}_n)^T (\mathbf{y} - \bar{y} \mathbf{1}_n) \\
&= \mathbf{x}^T \mathbf{y} - \bar{x} \mathbf{1}_n^T \mathbf{y} - \bar{y} \mathbf{1}_n^T \mathbf{x} + \bar{x} \bar{y} \mathbf{1}_n^T \mathbf{1}_n \\
&= \mathbf{x}^T \mathbf{y} - n\bar{x} \bar{y}
\end{aligned}$$

1.1.2 条件正态模型

条件正态模型 (conditional normal model) 是最常用的简单线性回归模型，也是最容易分析的模型。

设观测样本是 n 个数据对 $(x_1, y_1), \dots, (x_n, y_n)$,

其中 $x_1, \dots, x_n$ 为随机变量 $X_1, \dots, X_n$ 的实现 (但暂时视其为已知的固定常数),

而 $y_1, \dots, y_n$ 是独立随机变量 $Y_1, \dots, Y_n$ 的观测值。

进一步, 我们假定 $Y_1, \dots, Y_n$ 服从正态分布 (结合独立性可知它们联合正态) 且具有相同方差:

$$\begin{aligned}
Y_i &\sim \mathcal{N}(\alpha + \beta x_i, \sigma^2) \quad (i = 1, \dots, n) \\
\begin{bmatrix} Y_1 \\ \vdots \\ Y_n \end{bmatrix} &\sim \mathcal{N} \left(\begin{bmatrix} \alpha + \beta x_1 \\ \vdots \\ \alpha + \beta x_n \end{bmatrix}, \sigma^2 I_n \right)
\end{aligned}$$

由此可知总体回归函数为 $\mathbb{E}(Y|X = x) = \alpha + \beta x$.

具体来说, 条件分布 $(Y|X = x) \sim \mathcal{N}(\alpha + \beta x, \sigma^2)$.

条件正态模型还具有如下等价形式:

$$Y_i = \alpha + \beta x_i + \varepsilon_i \quad (i = 1, \dots, n) \text{ where } \varepsilon_1, \dots, \varepsilon_n \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma^2),$$

它相当于基础模型额外加上了 $\varepsilon_1, \dots, \varepsilon_n \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma^2)$ 的假设。

1.1.3 二元正态模型

在之前的模型中, 我们都将随机变量 $X_1, \dots, X_n$ 的实现 $x_1, \dots, x_n$ 视其为已知的固定常数。

现在我们感到有必要在模型中考虑 $X_1, \dots, X_n$ 的随机性, 二元正态模型就是一个相对简单的这种模型。

我们将观测样本 $(x_1, y_1), \dots, (x_n, y_n)$ 视为独立的二元正态随机变量 $(X_1, Y_1), \dots, (X_n, Y_n)$ 的实现。

具体来说, 我们假定:

$$(X_i, Y_i) \sim \text{bivariate normal}(\mu_X, \mu_Y, \sigma_X^2, \sigma_Y^2, \rho) = \mathcal{N} \left(\begin{bmatrix} \mu_X \\ \mu_Y \end{bmatrix}, \begin{bmatrix} \sigma_X^2 & \rho\sigma_X\sigma_Y \\ \rho\sigma_X\sigma_Y & \sigma_Y^2 \end{bmatrix} \right).$$

对于二元正态分布，给定 $X = x$ 时 Y 的条件分布是正态分布。

具体来说，其总体回归函数为：

$$\mathbb{E}(Y|X = x) = \mu_Y + \rho \frac{\sigma_Y}{\sigma_X} (x - \mu_X) = \left(\mu_Y - \rho \frac{\sigma_Y}{\sigma_X} \mu_X \right) + \left(\rho \frac{\sigma_Y}{\sigma_X} \right) x = \alpha + \beta x,$$

其中：

$$\begin{cases} \alpha = \mu_Y - (\rho\sigma_Y/\sigma_X)\mu_X = \mu_Y - \beta\mu_X \\ \beta = \rho\sigma_Y/\sigma_X. \end{cases}$$

证明过程：

$$\begin{aligned} \frac{X - \mu_X}{\sigma_X} &:= Z_1 \sim \mathcal{N}(0, 1) \\ \frac{Y - \mu_Y}{\sigma_Y} &:= \rho Z_1 + \sqrt{1 - \rho^2} Z_2 \quad (\text{where } Z_1 \perp Z_2 \text{ and } Z_2 \sim \mathcal{N}(0, 1)) \\ \mathbb{E}\left(\frac{Y - \mu_Y}{\sigma_Y} \middle| X = x\right) &= \rho \cdot \frac{x - \mu_X}{\sigma_X} + 0 = \rho \cdot \frac{x - \mu_X}{\sigma_X} \\ &\Downarrow \\ \mathbb{E}(Y|X = x) &= \mu_Y + \rho \frac{x - \mu_X}{\sigma_X} \sigma_Y \\ &= \left(\mu_Y - \rho \frac{\sigma_Y}{\sigma_X} \mu_X \right) + \left(\rho \frac{\sigma_Y}{\sigma_X} \right) x \end{aligned}$$

换言之，二元正态模型的假设自然保证了总体回归 $\mathbb{E}(Y|X = x)$ 是 x 的线性函数，我们不需要像在前面的模型中那样假定这一点。

值得注意的是，线性回归分析几乎总是可以用给定 $X_1 = x_1, \dots, X_n = x_n$ 时 $(Y_1, \dots, Y_n)$ 的条件分布来进行，而不是用 $(X_1, Y_1), \dots, (X_n, Y_n)$ 的无条件分布来进行，这就和条件正态模型别无二致了。

如果我们仅考虑给定 $X_1 = x_1, \dots, X_n = x_n$ 时 $(Y_1, \dots, Y_n)$ 的条件分布，那么 $x_1, \dots, x_n$ 作为随机变量的观测值这一点就无关紧要了，此时我们便可以将其视为已知的固定常数（我们在基础模型和条件正态模型中就是这么做的）。

事实上，二元正态性这个假定除了自然地保证了条件分布的线性性以外，就对后续的推断没有什么作用了。在基于点估计、区间估计和假设检验的推断中， (X, Y) 中 X 的边缘分布什么也不影响。在线性回归中，正是条件分布起关键作用。

1.2 参数的点估计

参数 α, β 的最常见的估计 $\hat{\alpha}, \hat{\beta}$ 为：

$$\begin{cases} \hat{\beta} = S_{xy}/S_{xx} = (x^T y - n\bar{x}\bar{y})/(x^T x - n\bar{x}^2) \\ \hat{\alpha} = \bar{y} - \hat{\beta}\bar{x}. \end{cases}$$

我们将在各种模型下证明这个估计的表达式。

1.2.1 最小二乘估计

首先我们从基础模型开始：

设观测样本是 n 个数据对 $(x_1, y_1), \dots, (x_n, y_n)$ ，其中 $x_1, \dots, x_n$ 为随机变量 $X_1, \dots, X_n$ 的实现（但暂时视其为已知的固定常数），而 $y_1, \dots, y_n$ 是随机变量 $Y_1, \dots, Y_n$ 的观测值。我们假设：

$$\mathbb{E}(Y_i|X = x_i) = \alpha + \beta x_i \quad (i = 1, \dots, n).$$

这个模型也可等价表示为：

$$Y_i = \alpha + \beta x_i + \varepsilon_i \quad (i = 1, \dots, n),$$

其中 $\varepsilon_1, \dots, \varepsilon_n$ 是零均值随机变量（我们暂且不对它们的相关性或分布做任何假设）。

我们定义 $(x_1, y_1), \dots, (x_n, y_n)$ 关于直线 $\mathbb{E}(Y|X = x) = \alpha + \beta x$ 的**残差平方和** (residual sum of squares) 为:

$$\text{RSS}(\alpha, \beta) := \sum_{i=1}^n (y_i - (\alpha + \beta x_i))^2 = \|y - \alpha \mathbf{1}_n - \beta x\|_2^2.$$

最小二乘的观点表明:

$$(\hat{\alpha}, \hat{\beta}) = \arg \min_{\alpha, \beta} \text{RSS}(\alpha, \beta) = \arg \min_{\alpha, \beta} \|y - \alpha \mathbf{1}_n - \beta x\|_2^2.$$

注意到目标函数 $\|y - \alpha \mathbf{1}_n - \beta x\|_2^2$ 是关于 α, β 的严格凸函数, 因此上述优化问题的最优解是唯一的. 计算目标函数关于 α, β 的偏导数:

$$\begin{aligned} \frac{\partial}{\partial \alpha} \|y - \alpha \mathbf{1}_n - \beta x\|_2^2 &= \mathbf{1}_n^T \cdot 2(y - \alpha \mathbf{1}_n - \beta x) \\ &= 2(\mathbf{1}_n^T y - \alpha \mathbf{1}_n^T \mathbf{1}_n - \beta \mathbf{1}_n^T x) \\ &= 2(n\bar{y} - \alpha n - \beta n\bar{x}) \\ &= 2n(\bar{y} - \alpha - \beta\bar{x}) \\ \frac{\partial}{\partial \beta} \|y - \alpha \mathbf{1}_n - \beta x\|_2^2 &= x^T \cdot 2(y - \alpha \mathbf{1}_n - \beta x) \\ &= 2(x^T y - \alpha x^T \mathbf{1}_n - \beta x^T x) \\ &= 2(x^T y - \alpha n\bar{x} - \beta x^T x). \end{aligned}$$

令上述偏导数等于零, 我们便得到方程组:

$$\begin{cases} \frac{\partial}{\partial \alpha} \|y - \alpha \mathbf{1}_n - \beta x\|_2^2 = 2n(\bar{y} - \alpha - \beta\bar{x}) = 0 \\ \frac{\partial}{\partial \beta} \|y - \alpha \mathbf{1}_n - \beta x\|_2^2 = 2(x^T y - \alpha n\bar{x} - \beta x^T x) = 0. \end{cases}$$

根据第一个等式我们得到 $\alpha = \bar{y} - \beta\bar{x}$, 代入第二个等式我们有:

$$\begin{aligned} x^T y - (\bar{y} - \beta\bar{x})n\bar{x} - \beta x^T x &= 0 \\ \Downarrow \\ x^T y - n\bar{x}\bar{y} &= \beta(x^T x - n\bar{x}^2) \\ \Downarrow \\ \beta &= \frac{x^T y - n\bar{x}\bar{y}}{x^T x - n\bar{x}^2} = \frac{S_{xy}}{S_{xx}} \end{aligned}$$

综上所述, 最小二乘问题 $(\hat{\alpha}, \hat{\beta}) = \arg \min_{\alpha, \beta} \|y - \alpha \mathbf{1}_n - \beta x\|_2^2$ 的解为:

$$\begin{cases} \hat{\beta} = S_{xy}/S_{xx} = (x^T y - n\bar{x}\bar{y})/(x^T x - n\bar{x}^2) \\ \hat{\alpha} = \bar{y} - \hat{\beta}\bar{x}. \end{cases}$$

下面我们证明最小二乘估计量 $\hat{\alpha}, \hat{\beta}$ 可以写成 $y_1, \dots, y_n$ 的线性组合,

并且 $\hat{\alpha} - \alpha$ 和 $\hat{\beta} - \beta$ 可以写成 $\varepsilon_1, \dots, \varepsilon_n$ 的线性组合:

$$\begin{aligned}
\hat{\beta} &= \frac{S_{xy}}{S_{xx}} \\
&= \frac{x^T y - n\bar{x}\bar{y}}{S_{xx}} \\
&= \frac{(x - \bar{x}1_n)^T y}{S_{xx}} \\
&= \frac{(x - \bar{x}1_n)^T (\alpha 1_n + \beta x + \varepsilon)}{S_{xx}} \\
&= \frac{1}{S_{xx}} (\alpha (x^T 1_n - \bar{x} 1_n^T 1_n) + \beta (x^T x - \bar{x} 1_n^T x) + (x - \bar{x}1_n)^T \varepsilon) \\
&= \frac{1}{S_{xx}} (\alpha (n\bar{x} - n\bar{x}) + \beta (x^T x - n\bar{x}^2) + (x - \bar{x}1_n)^T \varepsilon) \\
&= \frac{1}{S_{xx}} (\alpha \cdot 0 + \beta \cdot S_{xx} + (x - \bar{x}1_n)^T \varepsilon) \\
&= \beta + \frac{(x - \bar{x}1_n)^T \varepsilon}{S_{xx}} \\
\hline
\hat{\alpha} &= \bar{y} - \hat{\beta}\bar{x} \\
&= \frac{1}{n} 1_n^T y - \left(\beta + \frac{(x - \bar{x}1_n)^T \varepsilon}{S_{xx}} \right) \bar{x} \\
&= \frac{1}{n} 1_n^T (\alpha 1_n + \beta x + \varepsilon) - \beta \bar{x} - \frac{(x - \bar{x}1_n)^T \varepsilon}{S_{xx}} \bar{x} \\
&= \alpha \left(\frac{1}{n} 1_n^T 1_n \right) + \beta \left(\frac{1}{n} 1_n^T x - \bar{x} \right) + \frac{1}{n} 1_n^T \varepsilon - \frac{\bar{x} (x - \bar{x}1_n)^T \varepsilon}{S_{xx}} \\
&= \alpha + \left(\frac{1}{n} 1_n - \frac{\bar{x} (x - \bar{x}1_n)}{S_{xx}} \right)^T \varepsilon.
\end{aligned}$$

因此 $\hat{\alpha} - \alpha$ 和 $\hat{\beta} - \beta$ 可以写成 $\varepsilon_1, \dots, \varepsilon_n$ 的线性组合:

$$\begin{aligned}
\hat{\alpha} - \alpha &= \left(\frac{1}{n} 1_n - \frac{\bar{x} (x - \bar{x}1_n)}{S_{xx}} \right)^T \varepsilon \\
\hat{\beta} - \beta &= \frac{(x - \bar{x}1_n)^T}{S_{xx}} \varepsilon.
\end{aligned}$$

如果我们额外假设:

$$\begin{cases} \mathbb{E}(\varepsilon) = 0_n \\ \text{Var}(\varepsilon) = \sigma^2 I_n, \end{cases}$$

即零均值、互不相关且方差相同, 则我们有:

$$\begin{aligned}
\mathbb{E}(\hat{\alpha}) &= \mathbb{E} \left(\alpha + \left(\frac{1}{n} \mathbf{1}_n - \frac{\bar{x}(x - \bar{x} \mathbf{1}_n)}{S_{xx}} \right)^T \varepsilon \right) \\
&= \alpha + \left(\frac{1}{n} \mathbf{1}_n - \frac{\bar{x}(x - \bar{x} \mathbf{1}_n)}{S_{xx}} \right)^T \mathbb{E}(\varepsilon) \\
&= \alpha + \left(\frac{1}{n} \mathbf{1}_n - \frac{\bar{x}(x - \bar{x} \mathbf{1}_n)}{S_{xx}} \right)^T \mathbf{0}_n \\
&= \alpha
\end{aligned}$$

$$\begin{aligned}
\mathbb{E}(\hat{\beta}) &= \mathbb{E} \left(\beta + \frac{(x - \bar{x} \mathbf{1}_n)^T \varepsilon}{S_{xx}} \right) \\
&= \beta + \frac{(x - \bar{x} \mathbf{1}_n)^T \mathbb{E}(\varepsilon)}{S_{xx}} \\
&= \beta + \frac{(x - \bar{x} \mathbf{1}_n)^T \mathbf{0}_n}{S_{xx}} \\
&= \beta
\end{aligned}$$

$$\begin{aligned}
\text{Var}(\hat{\alpha}) &= \text{Var} \left(\alpha + \left(\frac{1}{n} \mathbf{1}_n - \frac{\bar{x}(x - \bar{x} \mathbf{1}_n)}{S_{xx}} \right)^T \varepsilon \right) \\
&= \left(\frac{1}{n} \mathbf{1}_n - \frac{\bar{x}(x - \bar{x} \mathbf{1}_n)}{S_{xx}} \right)^T \text{Var}(\varepsilon) \left(\frac{1}{n} \mathbf{1}_n - \frac{\bar{x}(x - \bar{x} \mathbf{1}_n)}{S_{xx}} \right) \\
&= \left(\frac{1}{n} \mathbf{1}_n - \frac{\bar{x}(x - \bar{x} \mathbf{1}_n)}{S_{xx}} \right)^T \sigma^2 I_n \left(\frac{1}{n} \mathbf{1}_n - \frac{\bar{x}(x - \bar{x} \mathbf{1}_n)}{S_{xx}} \right) \\
&= \left(\frac{1}{n^2} \mathbf{1}_n^T \mathbf{1}_n - 2 \frac{\bar{x}}{n S_{xx}} (x - \bar{x} \mathbf{1}_n)^T \mathbf{1}_n + \frac{\bar{x}^2}{S_{xx}^2} (x - \bar{x} \mathbf{1}_n)^T (x - \bar{x} \mathbf{1}_n) \right) \sigma^2 \\
&= \left(\frac{1}{n} - 2 \frac{\bar{x}}{n S_{xx}} (n\bar{x} - n\bar{x} \mathbf{1}_n) + \frac{\bar{x}^2}{S_{xx}^2} S_{xx} \right) \sigma^2 \\
&= \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right) \sigma^2 \\
&= \frac{x^T x}{n S_{xx}} \sigma^2
\end{aligned}$$

$$\begin{aligned}
\text{Var}(\hat{\beta}) &= \text{Var} \left(\beta + \frac{(x - \bar{x} \mathbf{1}_n)^T \varepsilon}{S_{xx}} \right) \\
&= \frac{(x - \bar{x} \mathbf{1}_n)^T}{S_{xx}} \text{Var}(\varepsilon) \frac{x - \bar{x} \mathbf{1}_n}{S_{xx}} \\
&= \frac{(x - \bar{x} \mathbf{1}_n)^T}{S_{xx}} \sigma^2 I_n \frac{x - \bar{x} \mathbf{1}_n}{S_{xx}} \\
&= \frac{S_{xx}}{S_{xx}^2} \sigma^2 \\
&= \frac{1}{S_{xx}} \sigma^2
\end{aligned}$$

$$\begin{aligned}
\text{Cov}(\hat{\alpha}, \hat{\beta}) &= \text{Cov} \left(\alpha + \left(\frac{1}{n} \mathbf{1}_n - \frac{\bar{x}(x - \bar{x} \mathbf{1}_n)}{S_{xx}} \right)^T \varepsilon, \beta + \frac{(x - \bar{x} \mathbf{1}_n)^T \varepsilon}{S_{xx}} \right) \\
&= \left(\frac{1}{n} \mathbf{1}_n - \frac{\bar{x}(x - \bar{x} \mathbf{1}_n)}{S_{xx}} \right)^T \text{Var}(\varepsilon) \frac{x - \bar{x} \mathbf{1}_n}{S_{xx}} \\
&= \left(\frac{1}{n} \mathbf{1}_n - \frac{\bar{x}(x - \bar{x} \mathbf{1}_n)}{S_{xx}} \right)^T \sigma^2 I_n \frac{x - \bar{x} \mathbf{1}_n}{S_{xx}} \\
&= \left(\frac{\frac{1}{n} \mathbf{1}_n^T (x - \bar{x} \mathbf{1}_n)}{S_{xx}} - \frac{\bar{x}(x - \bar{x} \mathbf{1}_n)^T (x - \bar{x} \mathbf{1}_n)}{S_{xx}^2} \right) \sigma^2 \\
&= \left(\frac{\bar{x} - \bar{x}}{S_{xx}} - \frac{\bar{x} S_{xx}}{S_{xx}^2} \right) \sigma^2 \\
&= -\frac{\bar{x}}{S_{xx}} \sigma^2
\end{aligned}$$

1.2.1 最佳线性无偏估计

现在我们在基础模型添加假设:

$$\begin{cases} \mathbb{E}(\varepsilon) = 0_n \\ \text{Var}(\varepsilon) = \sigma^2 I_n, \end{cases}$$

即零均值、互不相关和方差相同, 则我们有:

$$\begin{cases} \mathbb{E}(Y|X=x) = \alpha 1_n + \beta x \\ \text{Var}(Y|X=x) = \sigma^2 I_n. \end{cases}$$

本节中我们不需指明随机噪音 ε 的分布.

我们将证明最小二乘估计量

$$\begin{cases} \hat{\beta} = S_{xy}/S_{xx} = (x^T y - n\bar{x}\bar{y})/(x^T x - n\bar{x}^2) \\ \hat{\alpha} = \bar{y} - \hat{\beta}\bar{x} \end{cases}$$

是 (α, β) 的线性无偏估计类中最优的估计量.

我们先对 β 进行分析:

- 首先, β 的一个线性估计量具有形式 $\hat{\beta} = c^T y$ (其中 $c \in \mathbb{R}^n$ 是已知且固定的向量).
- 其次, β 的一个线性无偏估计量还满足 $\mathbb{E}(\hat{\beta}) = \beta$, 也就是说:

$$\begin{aligned} \mathbb{E}(\hat{\beta}) &= \mathbb{E}(c^T y) \\ &= \mathbb{E}(c^T (\alpha 1_n + \beta x + \varepsilon)) \\ &= \alpha(c^T 1_n) + \beta(c^T x) + c^T \mathbb{E}(\varepsilon) \quad (\text{note that } \mathbb{E}(\varepsilon) = 0_n) \\ &= (1_n^T c)\alpha + (c^T x)\beta \\ &= \beta. \end{aligned}$$

根据 $(1_n^T c)\alpha + (c^T x)\beta = \beta$ 可知 c 满足:

$$\begin{cases} 1_n^T c = 0 \\ c^T x = 1. \end{cases}$$

- 最后, β 的最佳线性无偏估计量还满足:

$$\text{Var}(\hat{\beta}) = \min_{\substack{1_n^T c = 0 \\ c^T x = 1}} \text{Var}(c^T y).$$

注意到目标函数可进行如下化简:

$$\begin{aligned} \text{Var}(c^T y) &= \text{Var}(c^T (\alpha 1_n + \beta x + \varepsilon)) \\ &= c^T \text{Var}(\varepsilon) c \\ &= c^T \sigma^2 I_n c \\ &= \sigma^2 \|c\|_2^2. \end{aligned}$$

因此问题变为求解最优化问题:

$$\hat{c} = \arg \min_{\substack{1_n^T c = 0 \\ c^T x = 1}} \|c\|_2^2$$

定义 Lagrange 函数为:

$$L(c, \lambda_1, \lambda_2) = \|c\|_2^2 + \lambda_1(1_n^T c - 0) + \lambda_2(c^T x - 1).$$

注意到目标函数是凸函数, 因此其 KKT 点就对应其最优解.

其 KKT 条件为:

$$\begin{cases} \nabla_c L(c, \lambda_1, \lambda_2) = 2c + \lambda_1 1_n + \lambda_2 x = 0_n \\ \frac{\partial}{\partial \lambda_1} L(c, \lambda_1, \lambda_2) = 1_n^T c = 0 \\ \frac{\partial}{\partial \lambda_2} L(c, \lambda_1, \lambda_2) = c^T x - 1 = 0. \end{cases}$$

分别对第一个等式左乘 1_n^T 和 x^T , 并代入第二个和第三个等式就可以得到 (只有一个 KKT 点):

$$\begin{cases} n\lambda_1 + n\bar{x}\lambda_2 = 0 \\ 2 + n\bar{x}\lambda_1 + x^T x \lambda_2 = 0 \end{cases} \Rightarrow \begin{cases} \lambda_1 = -\bar{x}\lambda_2 = 2\bar{x}/S_{xx} \\ \lambda_2 = -2/(x^T x - n\bar{x}^2) = -2/S_{xx}. \end{cases}$$

于是唯一的最优解为:

$$\hat{c} = -\frac{1}{2}(\lambda_1 1_n + \lambda_2 x) = \frac{x - \bar{x} 1_n}{S_{xx}}.$$

因此最佳线性无偏估计量为:

$$\begin{aligned} \hat{\beta} &= \hat{c}^T y \\ &= \left(\frac{x - \bar{x} 1_n}{S_{xx}} \right)^T y \\ &= \frac{x^T y - \bar{x} 1_n^T y}{S_{xx}} \\ &= \frac{x^T y - n\bar{x}\bar{y}}{S_{xx}} \\ &= \frac{S_{xy}}{S_{xx}}. \end{aligned}$$

其方差为 β 的线性无偏估计量所能具有的最小方差 (因而 $\hat{\beta}$ 是最稳定的线性无偏估计量):

$$\begin{aligned} \text{Var}(\hat{\beta}) &= \sigma^2 \|\hat{c}\|_2^2 \\ &= \sigma^2 \left(\frac{x - \bar{x} 1_n}{S_{xx}} \right)^T \left(\frac{x - \bar{x} 1_n}{S_{xx}} \right) \\ &= \sigma^2 \frac{S_{xx}}{S_{xx}^2} \\ &= \frac{\sigma^2}{S_{xx}}. \end{aligned}$$

我们对 α 进行类似的分析:

- 首先, α 的一个线性估计量具有形式 $\hat{\alpha} = c^T y$ (其中 $c \in \mathbb{R}^n$ 是已知且固定的向量)
- 其次, α 的一个线性无偏估计量还满足 $\mathbb{E}(\hat{\alpha}) = \alpha$, 也就是说:

$$\begin{aligned} \mathbb{E}(\hat{\alpha}) &= \mathbb{E}(c^T y) \\ &= \mathbb{E}(c^T (\alpha 1_n + \beta x + \varepsilon)) \\ &= \alpha(c^T 1_n) + \beta(c^T x) + c^T \mathbb{E}(\varepsilon) \quad (\text{note that } \mathbb{E}(\varepsilon) = 0_n) \\ &= (1_n^T c)\alpha + (c^T x)\beta \\ &= \alpha. \end{aligned}$$

根据 $(1_n^T c)\alpha + (c^T x)\beta = \alpha$ 可知 c 满足:

$$\begin{cases} 1_n^T c = 1 \\ c^T x = 0. \end{cases}$$

- 最后, α 的一个最佳线性无偏估计量还满足:

$$\text{Var}(\hat{\alpha}) = \min_{\substack{1_n^T c=1 \\ c^T x=0}} \text{Var}(c^T y).$$

注意到目标函数可进行如下化简:

$$\begin{aligned} \text{Var}(c^T y) &= \text{Var}(c^T (\alpha 1_n + \beta x + \varepsilon)) \\ &= c^T \text{Var}(\varepsilon) c \\ &= c^T \sigma^2 I_n c \\ &= \sigma^2 \|c\|_2^2. \end{aligned}$$

因此问题变为求解最优化问题:

$$\hat{c} = \arg \min_{\substack{1_n^T c = 1 \\ c^T x = 0}} \|c\|_2^2.$$

定义 Lagrange 函数为:

$$L(c, \lambda_1, \lambda_2) = \|c\|_2^2 + \lambda_1(1_n^T c - 1) + \lambda_2(c^T x - 0).$$

注意到目标函数是凸函数, 因此其 KKT 点就对应其最优解.

其 KKT 条件为:

$$\begin{cases} \nabla_c L(c, \lambda_1, \lambda_2) = 2c + \lambda_1 1_n + \lambda_2 x = 0_n \\ \frac{\partial}{\partial \lambda_1} L(c, \lambda_1, \lambda_2) = 1_n^T c - 1 = 0 \\ \frac{\partial}{\partial \lambda_2} L(c, \lambda_1, \lambda_2) = c^T x = 0. \end{cases}$$

分别对第一个等式左乘 1_n^T 和 x^T , 并代入第二个和第三个等式就可以得到 (只有一个 KKT 点):

$$\begin{cases} 2 + n\lambda_1 + n\bar{x}\lambda_2 = 0 \\ n\bar{x}\lambda_1 + x^T x \lambda_2 = 0 \end{cases} \Rightarrow \begin{cases} \lambda_1 = -2/(n - \frac{n^2 \bar{x}^2}{x^T x}) = -2x^T x / (nS_{xx}) \\ \lambda_2 = -(n\bar{x}/(x^T x)) \cdot \lambda_1 = 2\bar{x}/S_{xx}. \end{cases}$$

于是唯一的最优解为:

$$\begin{aligned} \hat{c} &= -\frac{1}{2}(\lambda_1 1_n + \lambda_2 x) \\ &= \frac{x^T x 1_n}{nS_{xx}} - \frac{\bar{x}x}{S_{xx}} \\ &= \frac{1}{n} 1_n - \frac{\bar{x}x - \bar{x}^2 1_n}{S_{xx}}. \end{aligned}$$

因此唯一的最佳线性无偏估计量为:

$$\begin{aligned} \hat{\alpha} &= \hat{c}^T y \\ &= \left(\frac{1}{n} 1_n - \frac{\bar{x}x - \bar{x}^2 1_n}{S_{xx}} \right)^T y \\ &= \frac{1}{n} 1_n^T y - \frac{x^T y - n\bar{x}\bar{y}}{S_{xx}} \bar{x} \\ &= \bar{y} - \frac{S_{xy}}{S_{xx}} \bar{x} \\ &= \bar{y} - \hat{\beta} \bar{x}. \end{aligned}$$

其方差为 α 的线性无偏估计量所能具有的最小方差 (因而 $\hat{\alpha}$ 是最稳定的线性无偏估计量):

$$\begin{aligned} \text{Var}(\hat{\alpha}) &= \sigma^2 \|\hat{c}\|_2^2 \\ &= \sigma^2 \left(\frac{1}{n} 1_n - \frac{\bar{x}x - \bar{x}^2 1_n}{S_{xx}} \right)^T \left(\frac{1}{n} 1_n - \frac{\bar{x}x - \bar{x}^2 1_n}{S_{xx}} \right) \\ &= \sigma^2 \left(\frac{1}{n^2} 1_n^T 1_n - 2 \frac{1}{n} 1_n^T \left(\frac{\bar{x}x - \bar{x}^2 1_n}{S_{xx}} \right) + \frac{(\bar{x}x - \bar{x}^2 1_n)^T (\bar{x}x - \bar{x}^2 1_n)}{S_{xx}^2} \right) \\ &= \sigma^2 \left(\frac{1}{n} - 2 \frac{\bar{x}^2 - \bar{x}^2}{S_{xx}} + \bar{x}^2 \frac{(x - \bar{x} 1_n)^T (x - \bar{x} 1_n)}{S_{xx}^2} \right) \\ &= \sigma^2 \left(\frac{1}{n} - 0 + \bar{x}^2 \frac{S_{xx}}{S_{xx}^2} \right) \\ &= \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right) \\ &= \sigma^2 \frac{(x^T x - n\bar{x}^2) + n\bar{x}^2}{nS_{xx}} \\ &= \frac{\sigma^2 x^T x}{nS_{xx}}. \end{aligned}$$

(简单线性回归中的 Gauss-Markov 定理, Statistical Inference 第 11.3.2 节)

给定数据点 $(x_1, y_1), \dots, (x_n, y_n)$ 和简单线性回归模型 $Y = \alpha + \beta X + \varepsilon$

若 $\mathbb{E}(\varepsilon) = 0_n$ 且 $\text{Var}(\varepsilon) = \sigma^2 I_n$ (零均值和互不相关, 无需给出分布上的假设),

则最小二乘估计量

$$\begin{cases} \hat{\beta} = S_{xy}/S_{xx} = (x^T y - n\bar{x}\bar{y})/(x^T x - n\bar{x}^2) \\ \hat{\alpha} = \bar{y} - \hat{\beta}\bar{x} \end{cases}$$

是参数 (α, β) 的**最佳线性无偏估计量** (Best Linear Unbiased Estimator, BLUE):

$$\mathbb{E}(\hat{\alpha}) = \alpha$$

$$\mathbb{E}(\hat{\beta}) = \beta$$

$$\text{Var}(\hat{\alpha}) = \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right) \sigma^2 = \frac{x^T x}{n S_{xx}} \sigma^2$$

$$\text{Var}(\hat{\beta}) = \frac{1}{S_{xx}} \sigma^2$$

$$\text{Cov}(\hat{\alpha}, \hat{\beta}) = -\frac{\bar{x}}{S_{xx}} \sigma^2.$$

1.2.3 极大似然估计

现在我们考虑条件正态模型:

条件正态模型 (conditional normal model) 是最常用的简单线性回归模型, 也是最容易分析的模型.

设观测样本是 n 个数据对 $(x_1, y_1), \dots, (x_n, y_n)$,

其中 $x_1, \dots, x_n$ 为随机变量 $X_1, \dots, X_n$ 的实现 (但暂时视其为已知的固定常数),

而 $y_1, \dots, y_n$ 是独立随机变量 $Y_1, \dots, Y_n$ 的观测值.

进一步, 我们假定 $Y_1, \dots, Y_n$ 服从正态分布 (结合独立性可知它们联合正态) 且具有相同方差:

$$Y_i \sim \mathcal{N}(\alpha + \beta x_i, \sigma^2) \quad (i = 1, \dots, n)$$
$$\begin{bmatrix} Y_1 \\ \vdots \\ Y_n \end{bmatrix} \sim \mathcal{N} \left(\begin{bmatrix} \alpha + \beta x_1 \\ \vdots \\ \alpha + \beta x_n \end{bmatrix}, \sigma^2 I_n \right)$$

由此可知总体回归函数为 $\mathbb{E}(Y|X = x) = \alpha + \beta x$.

具体来说, 条件分布 $(Y|X = x) \sim \mathcal{N}(\alpha + \beta x, \sigma^2)$.

条件正态模型还具有如下等价形式:

$$Y_i = \alpha + \beta x_i + \varepsilon_i \quad (i = 1, \dots, n) \text{ where } \varepsilon_1, \dots, \varepsilon_n \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma^2),$$

它相当于基础模型额外加上了 $\varepsilon_1, \dots, \varepsilon_n \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma^2)$ 的假设.

(1) 似然解

下面我们求解三个参数 α, β, σ^2 的极大似然估计量.

首先我们证明对于任意固定的 σ^2 , (α, β) 的极大似然估计量正是最小二乘估计量:

$$\begin{cases} \hat{\beta} = S_{xy}/S_{xx} = (x^T y - n\bar{x}\bar{y})/(x^T x - n\bar{x}^2) \\ \hat{\alpha} = \bar{y} - \hat{\beta}\bar{x}. \end{cases}$$

注意到 $(Y_1, \dots, Y_n)$ 服从 n 元正态分布 $\mathcal{N}(\mu, \Sigma)$, 其中 $\mu = \alpha 1_n + \beta x$ 而 $\Sigma = \sigma^2 I_n$.

于是似然函数 $\mathcal{L}(\alpha, \beta, \sigma^2|x, y)$ 为:

$$\begin{aligned}
\mathcal{L}(\alpha, \beta, \sigma^2 | x, y) &:= P(Y_1 = y_1, \dots, Y_n = y_n) \\
&= P(\mathcal{N}(\mu, \Sigma) = y) \\
&= \frac{1}{\sqrt{(2\pi)^n \det(\Sigma)}} \exp\left(-\frac{1}{2}(y - \mu)^T \Sigma^{-1}(y - \mu)\right) \\
&= \frac{1}{\sqrt{(2\pi)^n (\sigma^2)^n}} \exp\left(-\frac{1}{2\sigma^2} \|y - \alpha \mathbf{1}_n - \beta x\|_2^2\right).
\end{aligned}$$

因此对数似然函数 $\log \mathcal{L}(\alpha, \beta, \sigma^2 | x, y)$ 为:

$$\log \mathcal{L}(\alpha, \beta, \sigma^2 | x, y) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \|y - \alpha \mathbf{1}_n - \beta x\|_2^2.$$

注意到对于任意固定的 σ^2 , 对数似然函数 $\log \mathcal{L}(\alpha, \beta, \sigma^2 | x, y)$ 作为 α, β 的函数最大化的问题, 就等价于残差平方和 $\text{RSS}(\alpha, \beta) = \|y - \alpha \mathbf{1}_n - \beta x\|_2^2$ 作为 α, β 的函数最小化的问题. 因此对于任意固定的 σ^2 , (α, β) 的极大似然估计量正是最小二乘估计量:

$$\begin{cases} \hat{\beta} = S_{xy}/S_{xx} = (x^T y - n\bar{x}\bar{y})/(x^T x - n\bar{x}^2) \\ \hat{\alpha} = \bar{y} - \hat{\beta}\bar{x}. \end{cases}$$

由于 $\hat{\alpha}, \hat{\beta}$ 可以表示为联合正态随机变量 $y_1, \dots, y_n$ 的线性组合, 故它们也是联合正态的:

$$\begin{bmatrix} \hat{\alpha} \\ \hat{\beta} \end{bmatrix} \sim \mathcal{N}\left(\begin{bmatrix} \alpha \\ \beta \end{bmatrix}, \frac{\sigma^2}{S_{xx}} \begin{bmatrix} x^T x/n & -\bar{x} \\ -\bar{x} & 1 \end{bmatrix}\right) = \mathcal{N}\left(\begin{bmatrix} \alpha \\ \beta \end{bmatrix}, \sigma^2 (X^T X)^{-1}\right),$$

其中 $X = [\mathbf{1}_n, x] \in \mathbb{R}^{n \times 2}$.

回忆起:

$$\begin{aligned}
\text{Var}(\hat{\alpha}) &= \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}\right) \sigma^2 = \frac{x^T x}{n S_{xx}} \sigma^2 \\
\text{Var}(\hat{\beta}) &= \frac{1}{S_{xx}} \sigma^2 \\
\text{Cov}(\hat{\alpha}, \hat{\beta}) &= -\frac{\bar{x}}{S_{xx}} \sigma^2.
\end{aligned}$$

现在我们将最小二乘估计量

$$\begin{cases} \hat{\beta} = S_{xy}/S_{xx} = (x^T y - n\bar{x}\bar{y})/(x^T x - n\bar{x}^2) \\ \hat{\alpha} = \bar{y} - \hat{\beta}\bar{x} \end{cases}$$

代入对数似然函数 $\log \mathcal{L}(\alpha, \beta, \sigma^2 | x, y)$ 以求得 σ^2 的极大似然估计量.

注意到对数似然函数 $\log \mathcal{L}(\hat{\alpha}, \hat{\beta}, \sigma^2 | x, y)$ 关于 σ^2 是严格凹函数, 因此其最大值点唯一且为驻点. 我们令:

$$\frac{\partial}{\partial \sigma^2} \log \mathcal{L}(\alpha, \beta, \sigma^2 | x, y) = -\frac{n}{2\sigma^2} + \frac{1}{2} \|y - \hat{\alpha} \mathbf{1}_n - \hat{\beta} x\|_2^2 \frac{1}{\sigma^4} = 0,$$

解得:

$$\hat{\sigma}^2 = \frac{1}{n} \|y - \hat{\alpha} \mathbf{1}_n - \hat{\beta} x\|_2^2 = \frac{1}{n} \text{RSS}(\hat{\alpha}, \hat{\beta}),$$

即为在最小二乘线 $y = \hat{\alpha} + \hat{\beta}x$ 处算得的残差平方和 $\text{RSS}(\hat{\alpha}, \hat{\beta})$ 除以样本量 n .

$$\begin{aligned}
\hat{\sigma}^2 &= \frac{1}{n} \|y - \hat{\alpha}1_n - \hat{\beta}x\|_2^2 \\
&= \frac{1}{n} \|(\alpha 1_n + \beta x + \varepsilon) - \hat{\alpha}1_n - \hat{\beta}x\|_2^2 \\
&= \frac{1}{n} \|\varepsilon - (\hat{\alpha} - \alpha)1_n - (\hat{\beta} - \beta)x\|_2^2 \quad \left(\text{recall that } \begin{cases} \hat{\alpha} - \alpha = \left(\frac{1}{n}1_n - \frac{\bar{x}(x - \bar{x}1_n)}{S_{xx}} \right)^T \varepsilon \\ \hat{\beta} - \beta = \frac{(x - \bar{x}1_n)^T}{S_{xx}} \varepsilon \end{cases} \right) \\
&= \frac{1}{n} \left\| \varepsilon - \left(\frac{1}{n}1_n - \frac{\bar{x}(x - \bar{x}1_n)}{S_{xx}} \right)^T \varepsilon 1_n - \frac{(x - \bar{x}1_n)^T}{S_{xx}} \varepsilon x \right\|_2^2 \\
&= \frac{1}{n} \left\| \varepsilon - \frac{1}{n}1_n 1_n^T \varepsilon - \frac{(x - \bar{x}1_n)(x - \bar{x}1_n)^T}{S_{xx}} \varepsilon \right\|_2^2 \\
&= \frac{1}{n} \left\| \left(I_n - \frac{1}{n}1_n 1_n^T - \frac{(x - \bar{x}1_n)(x - \bar{x}1_n)^T}{S_{xx}} \right) \varepsilon \right\|_2^2 \\
&= \frac{1}{n} \|(I_n - H)\varepsilon\|_2^2 \quad \left(\text{note that } H := \frac{1}{n}1_n 1_n^T + \frac{(x - \bar{x}1_n)(x - \bar{x}1_n)^T}{S_{xx}} \text{ is symmetric and idempotent} \right) \\
&= \frac{1}{n} \varepsilon^T (I_n - H)^T (I_n - H) \varepsilon \\
&= \frac{1}{n} \varepsilon^T (I_n - H)^2 \varepsilon \\
&= \frac{1}{n} \varepsilon^T (I_n - 2H + H^2) \varepsilon \\
&= \frac{1}{n} \varepsilon^T (I_n - 2H + H) \varepsilon \\
&= \frac{1}{n} \varepsilon^T (I_n - H) \varepsilon
\end{aligned}$$

其中投影矩阵 $H \in \mathbb{R}^{n \times n}$ 的定义为:

$$H := \frac{1}{n}1_n 1_n^T + \frac{(x - \bar{x}1_n)(x - \bar{x}1_n)^T}{S_{xx}}.$$

(2) 纠偏

下面我们证明 σ^2 的极大似然估计量 $\hat{\sigma}^2 = \frac{1}{n} \|y - \hat{\alpha}1_n - \hat{\beta}x\|_2^2 = \frac{1}{n} \varepsilon^T (I_n - H) \varepsilon$ 不是无偏的.

$$\begin{aligned}
\mathbb{E}(\hat{\sigma}^2) &= \mathbb{E}\left(\frac{1}{n} \varepsilon^T (I_n - H) \varepsilon\right) \\
&= \frac{1}{n} \mathbb{E}(\text{tr}(\varepsilon^T (I_n - H) \varepsilon)) \\
&= \frac{1}{n} \mathbb{E}(\text{tr}((I_n - H) \varepsilon \varepsilon^T)) \\
&= \frac{1}{n} \text{tr}(\mathbb{E}((I_n - H) \varepsilon \varepsilon^T)) \\
&= \frac{1}{n} \text{tr}((I_n - H) \mathbb{E}(\varepsilon \varepsilon^T)) \\
&= \frac{1}{n} \text{tr}((I_n - H) \sigma^2 I_n) \\
&= \frac{1}{n} \sigma^2 (n - \text{tr}(H))
\end{aligned}$$

注意到:

$$\begin{aligned}
\text{tr}(H) &= \text{tr}\left(\frac{1}{n}1_n 1_n^T + \frac{(x - \bar{x}1_n)(x - \bar{x}1_n)^T}{S_{xx}}\right) \\
&= \frac{1}{n} \cdot n + \frac{(x - \bar{x}1_n)^T (x - \bar{x}1_n)}{S_{xx}} \\
&= 1 + 1 \\
&= 2,
\end{aligned}$$

于是我们有:

$$\begin{aligned}\mathbb{E}(\hat{\sigma}^2) &= \frac{1}{n}\sigma^2(n - \text{tr}(H)) \\ &= \frac{1}{n}\sigma^2(n - 2) \\ &= \frac{n-2}{n}\sigma^2.\end{aligned}$$

因此我们可以构造 σ^2 的无偏估计量为:

$$s^2 := \frac{n}{n-2}\hat{\sigma}^2 = \frac{1}{n-2}\|y - \hat{\alpha}1_n - \hat{\beta}x\|_2^2.$$

(3) 分布

在 1.2.3(1) 中我们已经说明了最小二乘估计量

$$\begin{cases} \hat{\beta} = S_{xy}/S_{xx} = (x^T y - n\bar{x}\bar{y})/(x^T x - n\bar{x}^2) \\ \hat{\alpha} = \bar{y} - \hat{\beta}\bar{x} \end{cases}$$

服从联合正态分布:

$$\begin{bmatrix} \hat{\alpha} \\ \hat{\beta} \end{bmatrix} \sim \mathcal{N}\left(\begin{bmatrix} \alpha \\ \beta \end{bmatrix}, \frac{\sigma^2}{S_{xx}} \begin{bmatrix} x^T x/n & -\bar{x} \\ -\bar{x} & 1 \end{bmatrix}\right) = \mathcal{N}\left(\begin{bmatrix} \alpha \\ \beta \end{bmatrix}, \sigma^2(X^T X)^{-1}\right),$$

其中 $X = [1_n, x] \in \mathbb{R}^{n \times 2}$.

下面我们证明 $\hat{\sigma}^2 = \frac{1}{n}\|y - \hat{\alpha}1_n - \hat{\beta}x\|_2^2 = \frac{1}{n}\varepsilon^T(I_n - H)\varepsilon$ 与 $(\hat{\alpha}, \hat{\beta})$ 独立.

在证明之前我们先给出两个有用的引理.

(Statistical Inference 引理 11.3.2)

设 $Y_1, \dots, Y_n$ 是互不相关的随机变量, $\text{Var}(Y_i) = \sigma_i^2$ ($i = 1, \dots, n$), $a, b \in \mathbb{R}^n$ 为常数向量. 若记 $Y = (Y_1, \dots, Y_n)^T$, $\Sigma = \text{Cov}(Y) = \text{diag}(\sigma_1^2, \dots, \sigma_n^2)$, 则我们有:

$$\begin{aligned}\text{Cov}(a^T Y, b^T Y) &= \text{Cov}\left(\sum_{i=1}^n a_i Y_i, \sum_{j=1}^n b_j Y_j\right) \\ &= \sum_{i=1}^n \sum_{j=1}^n a_i b_j \text{Cov}(Y_i, Y_j) \quad \left(\text{note that } \text{Cov}(Y_i, Y_j) = \begin{cases} \sigma_i^2, & \text{if } i = j \\ 0, & \text{otherwise} \end{cases}\right) \\ &= \sum_{i=1}^n a_i b_i \sigma_i^2 \\ &= a^T \Sigma b\end{aligned}$$

(Statistical Inference 引理 5.3.3)

设 $X_i \sim \mathcal{N}(\mu_i, \sigma_i^2)$ ($i = 1, \dots, n$) 相互独立, $k + m \leq n$, 记:

$$\begin{aligned}X &= \begin{bmatrix} X_1 \\ \vdots \\ X_n \end{bmatrix}, \quad U = \begin{bmatrix} U_1 \\ \vdots \\ U_k \end{bmatrix}, \quad V = \begin{bmatrix} V_1 \\ \vdots \\ V_m \end{bmatrix} \\ A &= (a_1, \dots, a_k) \in \mathbb{R}^{n \times k}, \quad B = (b_1, \dots, b_m) \in \mathbb{R}^{n \times m} \\ U &= A^T X = \begin{bmatrix} a_1^T X \\ \vdots \\ a_k^T X \end{bmatrix}, \quad V = B^T X = \begin{bmatrix} b_1^T X \\ \vdots \\ b_m^T X \end{bmatrix} \\ \Sigma &= \text{Cov}(X) = \text{diag}(\sigma_1^2, \dots, \sigma_n^2)\end{aligned}$$

则我们有:

- U_i 和 V_j 相互独立当且仅当 $\text{Cov}(U_i, V_j) = \text{Cov}(a_i^T X, b_j^T X) = a_i^T \Sigma b_j = 0$, 其中 $i = 1, \dots, k$ 而 $j = 1, \dots, m$.
- U 和 V 相互独立当且仅当对于任意 $i = 1, \dots, k$ 和 $j = 1, \dots, m$ 都有 $\text{Cov}(U_i, V_j) = 0$, 即当且仅当 $\text{Cov}(U, V) = \text{Cov}(A^T X, B^T X) = A^T \Sigma B = 0_{k \times m}$.

回忆起 $\hat{\alpha} - \alpha, \hat{\beta} - \beta$ 可以写成 ε 的线性组合:

$$\begin{aligned}\hat{\alpha} - \alpha &= \left(\frac{1}{n} \mathbf{1}_n - \frac{\bar{x}(x - \bar{x}\mathbf{1}_n)}{S_{xx}} \right)^T \varepsilon \\ \hat{\beta} - \beta &= \frac{(x - \bar{x}\mathbf{1}_n)^T}{S_{xx}} \varepsilon.\end{aligned}$$

要证明 $\hat{\sigma}^2 = \frac{1}{n} \|(I_n - H)\varepsilon\|_2^2$ 与 $(\hat{\alpha}, \hat{\beta})$ 独立,

只需证明 $(I_n - H)\varepsilon$ 与 $(\hat{\alpha}, \hat{\beta})$ 独立即可.

根据 **Statistical Inference 引理 5.3.3** 可知,

只需证明 $\text{Cov}((I_n - H)\varepsilon, \hat{\alpha}) = 0_n$ 和 $\text{Cov}((I_n - H)\varepsilon, \hat{\beta}) = 0_n$ 即可.

$$\begin{aligned}\text{Cov}((I_n - H)\varepsilon, \hat{\alpha}) &= \text{Cov}((I_n - H)\varepsilon, \hat{\alpha} - \alpha) \\ &= \text{Cov} \left((I_n - H)\varepsilon, \left(\frac{1}{n} \mathbf{1}_n - \frac{\bar{x}(x - \bar{x}\mathbf{1}_n)}{S_{xx}} \right)^T \varepsilon \right) \\ &= (I_n - H) \cdot \sigma^2 I_n \cdot \left(\frac{1}{n} \mathbf{1}_n - \frac{\bar{x}(x - \bar{x}\mathbf{1}_n)}{S_{xx}} \right) \\ &= \sigma^2 \left(\left(I_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^T - \frac{(x - \bar{x}\mathbf{1}_n)(x - \bar{x}\mathbf{1}_n)^T}{S_{xx}} \right) \left(\frac{1}{n} \mathbf{1}_n - \frac{\bar{x}(x - \bar{x}\mathbf{1}_n)}{S_{xx}} \right) \right) \\ &= \sigma^2 \left(\frac{1}{n} \mathbf{1}_n - \frac{\bar{x}(x - \bar{x}\mathbf{1}_n)}{S_{xx}} - \frac{1}{n} \mathbf{1}_n + 0_n + 0_n + \frac{\bar{x}(x - \bar{x}\mathbf{1}_n)}{S_{xx}} \right) \\ &= 0_n\end{aligned}$$

$$\begin{aligned}\text{Cov}((I_n - H)\varepsilon, \hat{\beta}) &= \text{Cov}((I_n - H)\varepsilon, \hat{\beta} - \beta) \\ &= \text{Cov} \left((I_n - H)\varepsilon, \frac{(x - \bar{x}\mathbf{1}_n)^T}{S_{xx}} \varepsilon \right) \\ &= (I_n - H) \cdot \sigma^2 I_n \cdot \frac{(x - \bar{x}\mathbf{1}_n)}{S_{xx}} \\ &= \sigma^2 \left(\left(I_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^T - \frac{(x - \bar{x}\mathbf{1}_n)(x - \bar{x}\mathbf{1}_n)^T}{S_{xx}} \right) \frac{(x - \bar{x}\mathbf{1}_n)}{S_{xx}} \right) \\ &= \sigma^2 \left(\frac{(x - \bar{x}\mathbf{1}_n)}{S_{xx}} - 0_n - \frac{(x - \bar{x}\mathbf{1}_n)}{S_{xx}} \right) \\ &= 0_n\end{aligned}$$

根据 $\hat{\sigma}^2 \perp (\hat{\alpha}, \hat{\beta})$ 可知 $s^2 = \frac{n}{n-2} \hat{\sigma}^2 \perp (\hat{\alpha}, \hat{\beta})$.

下面我们证明 $n\hat{\sigma}^2/\sigma^2 = \varepsilon^T(I_n - H)\varepsilon/\sigma^2$ 服从自由度为 $n - 2$ 的 χ^2 分布:

在前面的证明中, 我们说明了矩阵 H 的几个性质:

- H 对称且幂等
- $\text{tr}(H) = 2$

因此 H 的 n 个特征值中, 有 2 个是 1, 其余 $n - 2$ 个是 0.

进而可知 $I_n - H$ 的 n 个特征值中, 有 2 个是 0, 其余 $n - 2$ 个是 1.

设 $I_n - H$ 的谱分解 (实对称阵一定具有谱分解) 为:

$$U^T(I_n - H)U = \Lambda = \text{diag}(\underbrace{1, \dots, 1}_{n-2}, 0, 0).$$

记 $\eta := U^T \varepsilon / \sigma$, 根据 $\varepsilon \sim \mathcal{N}(0_n, \sigma^2 I_n)$ 可知:

$$\eta = \frac{1}{\sigma} U^T \varepsilon \sim \mathcal{N} \left(\frac{1}{\sigma} U^T 0_n, \frac{1}{\sigma^2} U^T \sigma^2 I_n U \right) = \mathcal{N}(0_n, I_n).$$

这表明 $\eta = (\eta_1, \dots, \eta_n)^T$ 的分量是独立同分布的标准正态随机变量.

于是我们有:

$$\begin{aligned}
\frac{n}{\sigma^2} \hat{\sigma}^2 &= \frac{1}{\sigma^2} \varepsilon^T (I_n - H) \varepsilon \\
&= \frac{1}{\sigma^2} \varepsilon^T U \Lambda U^T \varepsilon \\
&= \eta^T \Lambda \eta \\
&= \sum_{i=1}^{n-2} \eta_i^2 \sim \chi_{(n-2)}^2 \quad (\text{note that } \Lambda = \text{diag}(\underbrace{1, \dots, 1}_{n-2}, 0, 0))
\end{aligned}$$

即得证 $n\hat{\sigma}^2/\sigma^2 = \varepsilon^T(I_n - H)\varepsilon/\sigma^2$ 服从自由度为 $n - 2$ 的 χ^2 分布。
 据此我们也可以自然地得到:

$$\begin{aligned}
(n-2)s^2 &= n\hat{\sigma}^2 \sim \sigma^2 \chi_{(n-2)}^2 \\
\mathbb{E}(\hat{\sigma}^2) &= \frac{\sigma^2}{n} (n-2) = \frac{n-2}{n} \sigma^2 \Rightarrow \mathbb{E}(s^2) = \sigma^2 \\
\text{Var}(\hat{\sigma}^2) &= \frac{\sigma^4}{n^2} 2(n-2) = \frac{2(n-2)}{n^2} \sigma^4 \Rightarrow \text{Var}(s^2) = \frac{2}{n-2} \sigma^4
\end{aligned}$$

总之我们有如下定理:

(Statistical Inference 定理 11.3.2)

在条件正态模型下, $\hat{\alpha}, \hat{\beta}, s^2$ 分别是 α, β, σ^2 的无偏估计量, 它们满足:

$$\begin{aligned}
&\begin{cases} \hat{\alpha} = \bar{y} - \hat{\beta}\bar{x} \\ \hat{\beta} = S_{xy}/S_{xx} = (x^T y - n\bar{x}\bar{y})/(x^T x - n\bar{x}^2) \end{cases} \Rightarrow \begin{bmatrix} \hat{\alpha} \\ \hat{\beta} \end{bmatrix} = (X^T X)^{-1} X^T y \\
&s^2 = \frac{1}{n-2} \|y - \hat{\alpha}1_n - \hat{\beta}x\|_2^2 = \frac{1}{n-2} \varepsilon^T (I_n - H) \varepsilon \\
&\frac{\begin{bmatrix} \hat{\alpha} \\ \hat{\beta} \end{bmatrix} \sim \mathcal{N}\left(\begin{bmatrix} \alpha \\ \beta \end{bmatrix}, \frac{\sigma^2}{S_{xx}} \begin{bmatrix} x^T x/n & -\bar{x} \\ -\bar{x} & 1 \end{bmatrix}\right) = \mathcal{N}\left(\begin{bmatrix} \alpha \\ \beta \end{bmatrix}, \sigma^2 (X^T X)^{-1}\right)}{\text{SSE} = (n-2)s^2 \sim \sigma^2 \chi_{(n-2)}^2} \\
&\frac{\mathbb{E}(s^2) = \sigma^2}{\text{Var}(s^2) = \frac{2}{n-2} \sigma^4}
\end{aligned}$$

其中设计矩阵 X 和投影矩阵 H 的定义为:

$$\begin{aligned}
X &:= [1_n, x] \in \mathbb{R}^{n \times 2} \\
H &:= \frac{1}{n} 1_n 1_n^T + \frac{(x - \bar{x}1_n)(x - \bar{x}1_n)^T}{S_{xx}} = X(X^T X)^{-1} X^T \in \mathbb{R}^{n \times n}.
\end{aligned}$$

1.3 假设检验

1.3.1 $\beta = 0$ 的检验

关于参数 α 和 β 的推断通常基于下面两个 t 分布:

$$\begin{aligned}
\frac{\hat{\alpha} - \alpha}{s\sqrt{x^T x/(nS_{xx})}} &= \frac{(\hat{\alpha} - \alpha)/(\sigma\sqrt{x^T x/(nS_{xx})})}{s/\sigma} \sim \frac{\mathcal{N}(0, 1)}{\sqrt{\chi_{(n-2)}^2/(n-2)}} = t_{n-2} \\
\frac{\hat{\beta} - \beta}{s\sqrt{1/S_{xx}}} &= \frac{(\hat{\beta} - \beta)/(\sigma\sqrt{1/S_{xx}})}{s/\sigma} \sim \frac{\mathcal{N}(0, 1)}{\sqrt{\chi_{(n-2)}^2/(n-2)}} = t_{n-2}
\end{aligned}$$

事实上这两个量 (注意它们并不是统计量, 而是枢轴量) 的联合分布是二变量 t 分布,

它们可用来对 α, β 进行同时推断.

然而在实际应用中我们习惯每次只对一个参数进行推断, 其中我们通常对参数 β 更感兴趣.

参数 $\alpha = \mathbb{E}(Y|X = 0)$ 是否值得推断取决于具体的问题.

参数 β 是 $\mathbb{E}(Y|X = x)$ 作为 x 的函数的变化率, 它包含了 Y 与 X 之间线性关系的信息.

(Statistical Inference 习题 11.33)

在二元正态模型的假设下, $\beta = 0$ 当且仅当 $\rho = 0$.

此外, 当 $\beta = 0$ 时, 枢轴量 $\frac{\hat{\beta} - \beta}{s\sqrt{1/S_{xx}}} = \frac{\sqrt{n-2}r}{\sqrt{1-r^2}}$ (可用于检验 $\beta = 0$),

其中 $r = S_{xy}/\sqrt{S_{xx}S_{yy}}$ 为样本相关系数, 可以证明 r 为 ρ 的极大似然估计量.

(回顾二元正态模型)

我们将观测样本 $(x_1, y_1), \dots, (x_n, y_n)$ 视为独立的二元正态随机变量 $(X_1, Y_1), \dots, (X_n, Y_n)$ 的实现. 具体来说, 我们假定:

$$(X_i, Y_i) \sim \text{bivariate normal}(\mu_X, \mu_Y, \sigma_X^2, \sigma_Y^2, \rho) = \mathcal{N}\left(\begin{bmatrix} \mu_X \\ \mu_Y \end{bmatrix}, \begin{bmatrix} \sigma_X^2 & \rho\sigma_X\sigma_Y \\ \rho\sigma_X\sigma_Y & \sigma_Y^2 \end{bmatrix}\right).$$

对于二元正态分布, 给定 $X = x$ 时 Y 的条件分布是正态分布.

具体来说, 其总体回归函数为:

$$\mathbb{E}(Y|X = x) = \mu_Y + \rho \frac{\sigma_Y}{\sigma_X}(x - \mu_X) = \left(\mu_Y - \rho \frac{\sigma_Y}{\sigma_X} \mu_X\right) + \left(\rho \frac{\sigma_Y}{\sigma_X}\right)x = \alpha + \beta x,$$

其中:

$$\begin{cases} \alpha = \mu_Y - (\rho\sigma_Y/\sigma_X)\mu_X = \mu_Y - \beta\mu_X \\ \beta = \rho\sigma_Y/\sigma_X. \end{cases}$$

换言之, 二元正态模型的假设自然保证了总体回归 $\mathbb{E}(Y|X = x)$ 是 x 的线性函数, 我们不需要像在前面的模型中那样假定这一点.

(1) 基本记号

考虑第一类错误概率界限为 α 的检验问题 $H_0: \beta = 0 \leftrightarrow H_1: \beta \neq 0$.

① 总平方和 (Total Sum of Squares)

$$\begin{aligned} \text{SST} &= S_{yy} \\ &= \|y - \bar{y}1_n\|_2^2 \\ &= (y - \bar{y}1_n)^T (y - \bar{y}1_n) \\ &= y^T y - n\bar{y}^2 \\ &= y^T y - n\left(\frac{1}{n}1_n^T y\right)^2 \\ &= y^T \left(I_n - \frac{1}{n}1_n 1_n^T\right) y \end{aligned}$$

显然 SST 只与样本有关, 与模型无关.

当零假设 $H_0: \beta = 0$ 成立时, 我们有:

$$\begin{aligned} \text{SST} &= y^T \left(I_n - \frac{1}{n}1_n 1_n^T\right) y \\ &\stackrel{H_0}{=} (\alpha 1_n + \varepsilon)^T \left(I_n - \frac{1}{n}1_n 1_n^T\right) (\alpha 1_n + \varepsilon) \\ &= \varepsilon^T \left(I_n - \frac{1}{n}1_n 1_n^T\right) \varepsilon \end{aligned}$$

注意到 $I_n - \frac{1}{n}1_n 1_n^T$ 对称、幂等且 $\text{tr}\left(I_n - \frac{1}{n}1_n 1_n^T\right) = n - 1$.

因此它存在谱分解, 且有 $n - 1$ 个特征值是 1, 1 个特征值是 0.

我们可设其谱分解为:

$$U^T \left(I_n - \frac{1}{n}1_n 1_n^T\right) U = \Lambda = \text{diag}(\underbrace{1, \dots, 1}_{n-1}, 0).$$

记 $\eta := U^T \varepsilon / \sigma$, 根据 $\varepsilon \sim \mathcal{N}(0_n, \sigma^2 I_n)$ 可知:

$$\eta = \frac{1}{\sigma} U^T \varepsilon \sim \mathcal{N}\left(\frac{1}{\sigma} U^T 0_n, \frac{1}{\sigma^2} U^T \sigma^2 I_n U\right) = \mathcal{N}(0_n, I_n).$$

这表明 $\eta = (\eta_1, \dots, \eta_n)^\top$ 的分量是独立同分布的标准正态随机变量。
于是我们有：

$$\begin{aligned}\frac{1}{\sigma^2} \text{SST} &= \frac{1}{\sigma^2} \|y - \bar{y} \mathbf{1}_n\|_2^2 \\ &\stackrel{H_0}{=} \frac{1}{\sigma^2} \varepsilon^\top \left(I_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top \right) \varepsilon \\ &= \frac{1}{\sigma^2} \varepsilon^\top U \Lambda U^\top \varepsilon \\ &= \eta^\top \Lambda \eta \\ &= \sum_{i=1}^{n-1} \eta_i^2 \sim \chi_{(n-1)}^2 \quad (\text{note that } \Lambda = \text{diag}(\underbrace{1, \dots, 1}_{n-1}, 0))\end{aligned}$$

此时我们定义**总均方和** (Total Mean Squares) 为：

$$\text{MST} = \frac{\text{SST}}{\text{df}_T} = \frac{\text{SST}}{n-1} = \frac{1}{n-1} S_{yy},$$

则我们有：

$$\begin{aligned}\text{SST} &= S_{yy} \stackrel{H_0}{\sim} \sigma^2 \chi_{(n-1)}^2 \\ \text{MST} &= \frac{1}{n-1} S_{yy} \stackrel{H_0}{\sim} \sigma^2 \frac{\chi_{(n-1)}^2}{n-1}.\end{aligned}$$

② 回归平方和 (Regression Sum of Squares)

$$\begin{aligned}\text{SSR} &= \|\hat{y} - \bar{y} \mathbf{1}_n\|_2^2 \\ &= \|\hat{\alpha} \mathbf{1}_n + \hat{\beta} x - \bar{y} \mathbf{1}_n\|_2^2 \\ &= \|(\bar{y} - \hat{\beta} \bar{x}) \mathbf{1}_n + \hat{\beta} x - \bar{y} \mathbf{1}_n\|_2^2 \\ &= \|\hat{\beta}(x - \bar{x} \mathbf{1}_n)\|_2^2 \\ &= \hat{\beta}^2 S_{xx} \\ &= \left(\frac{S_{xy}}{S_{xx}} \right)^2 S_{xx} \\ &= \frac{S_{xy}^2}{S_{xx}}\end{aligned}$$

当零假设 $H_0 : \beta = 0$ 成立时，我们有：

$$\begin{aligned}\frac{1}{\sigma^2} \text{SSR} &= \frac{1}{\sigma^2} \hat{\beta}^2 S_{xx} \\ &= \left(\frac{\hat{\beta}}{\frac{\sigma}{\sqrt{S_{xx}}}} \right)^2 \stackrel{H_0}{\sim} (\mathcal{N}(0, 1))^2 = \chi_{(1)}^2 \\ &(\text{note that } \hat{\beta} \sim \mathcal{N}(\beta, \frac{\sigma^2}{S_{xx}}) \stackrel{H_0}{=} \mathcal{N}(0, \frac{\sigma^2}{S_{xx}}))\end{aligned}$$

此时我们定义**回归均方和** (Regression Mean Squares) 为：

$$\text{MSR} = \frac{\text{SSR}}{\text{df}_R} = \frac{\text{SSR}}{1} = \frac{S_{xy}^2}{S_{xx}},$$

则我们有：

$$\text{MSR} = \text{SSR} = \frac{S_{xy}^2}{S_{xx}} \stackrel{H_0}{\sim} \sigma^2 \chi_{(1)}^2.$$

③ 误差平方和 (Sum of Squared Errors)

$$\begin{aligned}
\text{SSE} &= \text{RSS}(\hat{\alpha}, \hat{\beta}) \\
&= \|y - \hat{y}\|_2^2 \\
&= \|y - \hat{\alpha}1_n - \hat{\beta}x\|_2^2 \\
&= (n-2)s^2 \sim \sigma^2 \chi_{(n-2)}^2
\end{aligned}$$

值得注意的是 $\text{SSE} \sim \sigma^2 \chi_{(n-2)}^2$ 并不依赖于零假设 $H_0: \beta = 0$ 成立.

可以证明 $\text{SSE} = \text{SST} - \text{SSR}$:

$$\begin{aligned}
\text{SSE} &= \|y - \hat{\alpha}1_n - \hat{\beta}x\|_2^2 \\
&= \|y - (\bar{y} - \hat{\beta}\bar{x})1_n - \hat{\beta}x\|_2^2 \\
&= \|(y - \bar{y}1_n) - \hat{\beta}(x - \bar{x}1_n)\|_2^2 \\
&= (y - \bar{y}1_n)^T(y - \bar{y}1_n) - 2\hat{\beta}(y - \bar{y}1_n)^T(x - \bar{x}1_n) + \hat{\beta}^2(x - \bar{x}1_n)^T(x - \bar{x}1_n) \\
&= S_{yy} - 2\hat{\beta}S_{xy} + \hat{\beta}^2S_{xx} \\
&= S_{yy} - 2\frac{S_{xy}}{S_{xx}}S_{xy} + \left(\frac{S_{xy}}{S_{xx}}\right)^2 S_{xx} \\
&= S_{yy} - \frac{S_{xy}^2}{S_{xx}} \\
&= \text{SST} - \text{SSR}
\end{aligned}$$

此时我们定义**均方误差** (Mean Square Error) 为:

$$\text{MSE} = \frac{\text{SSE}}{\text{df}_E} = \frac{\text{SSE}}{n-2} = \frac{1}{n-2} \left(S_{yy} - \frac{S_{xy}^2}{S_{xx}} \right),$$

则我们有:

$$\begin{aligned}
\text{SSE} &= S_{yy} - \frac{S_{xy}^2}{S_{xx}} \sim \sigma^2 \chi_{(n-2)}^2 \\
\text{MSE} &= \frac{1}{n-2} \left(S_{yy} - \frac{S_{xy}^2}{S_{xx}} \right) \sim \sigma^2 \frac{\chi_{(n-2)}^2}{n-2}.
\end{aligned}$$

总结如下:

$$\left\{ \begin{array}{ll} H_0: \beta = 0 \\ \text{SST} = \|y - \bar{y}1_n\|_2^2 = S_{yy} \stackrel{H_0}{\sim} \sigma^2 \chi_{(n-1)}^2 & \text{MST} = \frac{\text{SST}}{\text{df}_T} = \frac{1}{n-1} S_{yy} \stackrel{H_0}{\sim} \sigma^2 \frac{\chi_{(n-1)}^2}{n-1} \\ \text{SSR} = \|\hat{y} - \bar{y}1_n\|_2^2 = \frac{S_{xy}^2}{S_{xx}} \stackrel{H_0}{\sim} \sigma^2 \chi_{(1)}^2 & \text{MSR} = \frac{\text{SSR}}{\text{df}_R} = \frac{S_{xy}^2}{S_{xx}} \stackrel{H_0}{\sim} \sigma^2 \chi_{(1)}^2 \\ \text{SSE} = \|y - \hat{y}\|_2^2 = (S_{yy} - \frac{S_{xy}^2}{S_{xx}}) \sim \sigma^2 \chi_{(n-2)}^2 & \text{MSE} = \frac{\text{SSE}}{\text{df}_E} = \frac{1}{n-2} (S_{yy} - \frac{S_{xy}^2}{S_{xx}}) \sim \sigma^2 \frac{\chi_{(n-2)}^2}{n-2} \\ \left\{ \begin{array}{l} \text{SST} = \text{SSR} + \text{SSE} \\ \text{df}_T = \text{df}_R + \text{df}_E \\ \text{SSR} \perp \text{SSE} \end{array} \right. \end{array} \right.$$

(2) 检验法

考虑第一类错误概率界限为 α 的检验问题 $H_0: \beta = 0 \leftrightarrow H_1: \beta \neq 0$

我们使用如下的 t 统计量或等价的 F 统计量:

$$\begin{aligned}
\frac{\hat{\beta}}{s/\sqrt{S_{xx}}} &\stackrel{H_0}{\sim} t_{n-2} \\
\frac{\hat{\beta}^2}{s^2/S_{xx}} &\stackrel{H_0}{\sim} F_{1,n-2}
\end{aligned}$$

我们记 $t_{n-2, \frac{\alpha}{2}}$ 为 t_{n-2} 分布的 $1 - \frac{\alpha}{2}$ (右尾) 分位数, $F_{1,n-2, \alpha}$ 为 $F_{1,n-2}$ 分布的 $1 - \alpha$ 分位数. 根据定义我们知道 $F_{1,n-2} = (t_{n-2})^2$, 因而有 $F_{1,n-2, \alpha} = (t_{n-2, \frac{\alpha}{2}})^2$.

值得注意的是, F 统计量的表达式可以写为:

$$\frac{\hat{\beta}^2}{s^2/S_{xx}} = \frac{\hat{\beta}^2 S_{xx}}{s^2} = \frac{\text{MSR}}{\text{MSE}} \stackrel{H_0}{\sim} F_{1,n-2} \text{ where } \begin{cases} \text{MSR} = \hat{\beta}^2 S_{xx} = S_{xy}^2/S_{xx} \stackrel{H_0}{\sim} \sigma^2 \chi_{(1)}^2 \\ \text{MSE} = s^2 = \frac{1}{n-2}(S_{yy} - S_{xy}^2/S_{xx}) \sim \sigma^2 \chi_{(n-2)}^2 \end{cases}$$

$$\Downarrow$$

$$\frac{\text{MSR}}{\text{MSE}} = \frac{S_{xy}^2/S_{xx}}{\frac{1}{n-2}(S_{yy} - S_{xy}^2/S_{xx})} = \frac{(n-2)S_{xy}^2}{S_{xx}S_{yy} - S_{xy}^2}$$

其中 $\text{MSE} = s^2 \perp \text{MSR} = \hat{\beta}^2 S_{xx}$ 由 **Statistical Inference 定理 11.3.2** 中的 $s^2 \perp \hat{\beta}^2$ 保证。

因此 F -检验法和等价的 t -检验法为:

- (F -检验法) 若 $\frac{\text{MSR}}{\text{MSE}} = \frac{(n-2)S_{xy}^2}{S_{xx}S_{yy} - S_{xy}^2} > F_{1,n-2,\alpha}$, 则我们拒绝零假设 $H_0: \beta = 0$.
- (t -检验法) 若 $\sqrt{\frac{\text{MSR}}{\text{MSE}}} = \sqrt{\frac{(n-2)S_{xy}^2}{S_{xx}S_{yy} - S_{xy}^2}} > t_{n-2, \frac{\alpha}{2}}$, 则我们拒绝零假设 $H_0: \beta = 0$.

(3) 推广: $\beta = \beta_0$ 的检验

考虑第一类错误概率界限为 α 的检验问题 $H_0: \beta = \beta_0 \leftrightarrow H_1: \beta \neq \beta_0$.

注意到:

$$\frac{\hat{\beta} - \beta_0}{s\sqrt{1/S_{xx}}} = \frac{(\hat{\beta} - \beta_0)/(\sigma\sqrt{1/S_{xx}})}{s/\sigma} \stackrel{H_0}{\sim} \frac{\mathcal{N}(0,1)}{\sqrt{\chi_{(n-2)}^2/(n-2)}} = t_{n-2}$$

$$\left(\text{note that } \hat{\beta} \sim \mathcal{N}\left(\beta, \frac{\sigma^2}{S_{xx}}\right) \stackrel{H_0}{=} \mathcal{N}\left(\beta_0, \frac{\sigma^2}{S_{xx}}\right) \right)$$

因此我们可以使用如下的 t 统计量或等价的 F 统计量:

$$\frac{\hat{\beta} - \beta_0}{s/\sqrt{S_{xx}}} \stackrel{H_0}{\sim} t_{n-2}$$

$$\frac{(\hat{\beta} - \beta_0)^2}{s^2/S_{xx}} \stackrel{H_0}{\sim} F_{1,n-2}$$

值得注意的是, F 统计量的表达式可以写为:

$$\frac{(\hat{\beta} - \beta_0)^2}{s^2/S_{xx}} = \frac{(S_{xy}/S_{xx} - \beta_0)^2 S_{xx}}{\frac{1}{n-2}(S_{yy} - S_{xy}^2/S_{xx})} = \frac{(n-2)(S_{xy} - \beta_0 S_{xx})^2}{S_{xx}S_{yy} - S_{xy}^2}.$$

因此 F -检验法和等价的 t -检验法为:

- (F -检验法) 若 $\frac{(\hat{\beta} - \beta_0)^2}{s^2/S_{xx}} = \frac{(n-2)(S_{xy} - \beta_0 S_{xx})^2}{S_{xx}S_{yy} - S_{xy}^2} > F_{1,n-2,\alpha}$, 则我们拒绝零假设 $H_0: \beta = \beta_0$
- (t -检验法) 若 $\sqrt{\frac{(\hat{\beta} - \beta_0)^2}{s^2/S_{xx}}} = \sqrt{\frac{(n-2)(S_{xy} - \beta_0 S_{xx})^2}{S_{xx}S_{yy} - S_{xy}^2}} > t_{n-2, \frac{\alpha}{2}}$, 则我们拒绝零假设 $H_0: \beta = \beta_0$

1.3.2 响应的估计

(1) 平均响应

考虑条件正态模型 $(Y|X = x) \sim \mathcal{N}(\alpha + \beta x, \sigma^2)$.

关于预测变量的一个给定值 $x = x_0$ 有一个 Y 值的总体,

在条件正态模型的假设下我们有 $(Y|X = x_0) \sim \mathcal{N}(\alpha + \beta x_0, \sigma^2)$.

在观测到数据 $(x_1, y_1), \dots, (x_n, y_n)$ 并得到 α, β, σ^2 的估计量 $\hat{\alpha}, \hat{\beta}, s^2$ 之后,

试验者可能要设置 $x = x_0$ 来得到一个新的观测值 y_0 , 它是随机变量 $Y_0 \sim \mathcal{N}(\alpha + \beta x_0, \sigma^2)$ 的一个实现.

平均响应 $\mu = \mathbb{E}(Y|X = x_0) = \alpha + \beta x_0$ 点估计的一个显然的选择就是 $\hat{\mu} = \hat{\alpha} + \hat{\beta} x_0$, 因为它无偏的.

$$\begin{aligned}\mathbb{E}(\hat{\mu}) &= \mathbb{E}(\hat{\alpha} + \hat{\beta}x_0) \\ &= \mathbb{E}(\hat{\alpha}) + \mathbb{E}(\hat{\beta})x_0 \\ &= \alpha + \beta x_0\end{aligned}$$

$$\begin{aligned}\text{Var}(\hat{\mu}) &= \text{Var}(\hat{\alpha} + \hat{\beta}x_0) \\ &= \text{Var}(\hat{\alpha}) + 2x_0\text{Cov}(\hat{\alpha}, \hat{\beta}) + x_0^2\text{Var}(\hat{\beta}) \\ &= \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}\right)\sigma^2 + 2x_0 \cdot \left(-\frac{\bar{x}\sigma^2}{S_{xx}}\right) + x_0^2 \frac{\sigma^2}{S_{xx}} \\ &= \sigma^2 \left(\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}\right).\end{aligned}$$

回忆起:

$$\begin{aligned}\text{Var}(\hat{\alpha}) &= \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}\right)\sigma^2 = \frac{x^T x}{nS_{xx}}\sigma^2 \\ \text{Var}(\hat{\beta}) &= \frac{1}{S_{xx}}\sigma^2 \\ \text{Cov}(\hat{\alpha}, \hat{\beta}) &= -\frac{\bar{x}}{S_{xx}}\sigma^2.\end{aligned}$$

由于 $(\hat{\alpha}, \hat{\beta})$ 联合正态, 故 $\hat{\mu} = \hat{\alpha} + \hat{\beta}x_0$ 也服从正态分布:

$$\hat{\mu} = \hat{\alpha} + \hat{\beta}x_0 \sim \mathcal{N}\left(\alpha + \beta x_0, \sigma^2 \left(\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}\right)\right)$$

由于 s^2 与 $(\hat{\alpha}, \hat{\beta})$ 独立, 故 s^2 也与 $\hat{\mu} = \hat{\alpha} + \hat{\beta}x_0$ 独立, 因此我们有:

$$\frac{\hat{\alpha} + \hat{\beta}x_0 - (\alpha + \beta x_0)}{s\sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}}} = \frac{\frac{\hat{\alpha} + \hat{\beta}x_0 - (\alpha + \beta x_0)}{\sigma\sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}}}}{\frac{s}{\sigma}} \sim \frac{\mathcal{N}(0, 1)}{\sqrt{\chi_{(n-2)}^2/(n-2)}} = t_{n-2}.$$

根据这个枢轴量便可得到平均响应 $\mu = \alpha + \beta x_0$ 的 $(1 - \alpha)$ 置信区间:

$$\alpha + \beta x_0 \in \left(\hat{\alpha} + \hat{\beta}x_0 \pm s\sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}}t_{n-2, \frac{\alpha}{2}}\right)$$

其中 $t_{n-2, \frac{\alpha}{2}}$ 为 t_{n-2} 分布的 $1 - \frac{\alpha}{2}$ (右尾) 分位数.

(2) 个体响应

现在我们考虑个体响应 $Y_0 \sim \mathcal{N}(\alpha + \beta x_0, \sigma^2)$ 的估计.

- (预测区间)

未观测随机变量 Y 的一个基于样本 X 的 $(1 - \alpha)$ 预测区间是一个随机区间 $(L(X), U(X))$, 满足:

$$P_{\theta}(L(X) \leq Y \leq U(X)) \geq 1 - \alpha \quad (\forall \theta \in \Theta).$$

预测区间的定义与置信区间是相似的, 区别在于预测区间是针对随机变量的, 而不是针对参数的.

直观上, 由于随机变量与参数 (常数) 相比具有变异性, 故预测区间会比相同水平的置信区间更宽.

由于估计量 $\hat{\alpha}, \hat{\beta}, s^2$ 是根据以前的数据计算出来的, 故 Y_0 与 $\hat{\alpha}, \hat{\beta}, s^2$ 独立.

$$\begin{aligned}&\begin{cases} Y_0 \sim \mathcal{N}(\alpha + \beta x_0, \sigma^2) \\ \hat{\alpha} + \hat{\beta}x_0 \sim \mathcal{N}(\alpha + \beta x_0, \sigma^2(\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}})) \end{cases} \\ &\quad \Downarrow \\ &Y_0 - (\hat{\alpha} + \hat{\beta}x_0) \sim \mathcal{N}\left(\alpha + \beta x_0 - \alpha - \beta x_0, \sigma^2 + \sigma^2 \left(\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}\right)\right) \\ &= \mathcal{N}\left(0, \sigma^2 \left(1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}\right)\right)\end{aligned}$$

利用 s^2 与 $Y_0 - (\hat{\alpha} + \hat{\beta}x_0)$ 的独立性, 我们有:

$$\frac{Y_0 - (\hat{\alpha} + \hat{\beta}x_0)}{s\sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}}} = \frac{\frac{Y_0 - (\hat{\alpha} + \hat{\beta}x_0)}{\sigma\sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}}}}{\frac{s}{\sigma}} \sim \frac{\mathcal{N}(0, 1)}{\sqrt{\frac{1}{n-2}\chi_{(n-2)}^2}} = t_{n-2}.$$

于是我们得到个体响应 $Y_0 \sim \mathcal{N}(\alpha + \beta x_0, \sigma^2)$ 的 $(1 - \alpha)$ 预测区间:

$$Y_0 \in \left(\hat{\alpha} + \hat{\beta}x_0 \pm s\sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}} t_{n-2, \frac{\alpha}{2}} \right)$$

其中 $t_{n-2, \frac{\alpha}{2}}$ 为 t_{n-2} 分布的 $1 - \frac{\alpha}{2}$ (右尾) 分位数.

(3) 同时估计

在 1.3.2(1) 中我们已经看到, 与 x_0 相联系的总体 $Y_0 \sim \mathcal{N}(\alpha + \beta x_0, \sigma^2)$ 的均值, 即平均响应 $\mu = \mathbb{E}(Y|X = x_0) = \alpha + \beta x_0$ 的 $(1 - \alpha)$ 置信区间为:

$$\alpha + \beta x_0 \in \left(\hat{\alpha} + \hat{\beta}x_0 \pm s\sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}} t_{n-2, \frac{\alpha}{2}} \right) \text{ where } \begin{cases} \hat{\beta} = \frac{S_{xy}}{S_{xx}} \\ \hat{\alpha} = \bar{y} - \hat{\beta}\bar{x} \\ s^2 = \frac{1}{n-2} (S_{yy} - \frac{S_{xy}^2}{S_{xx}}) \end{cases}$$

现假定我们要在若干点处对于 Y 总体的均值进行推断.

具体来说, 我们要求包含 $\mu_i = \mathbb{E}(Y|X = x_0^{(i)}) = \alpha + \beta x_0^{(i)}$ ($i = 1, \dots, m$) 的区间.

如果按上面的方法分别给出 μ_i ($i = 1, \dots, m$) 的 $(1 - \alpha)$ 置信区间,

那么合并得到的区间的置信水平将不是 $1 - \alpha$.

一个简单且有用的处理方式是应用 Bonferroni 不等式.

当事件交的概率难以 (甚至无法) 计算, 而我们只需知道其大致范围时, Bonferroni 不等式非常有用.

(Bonferroni 不等式, Statistical Inference 例 1.2.10)

设 A, B 是两个事件, 则我们有 $P(A \cap B) \geq P(A) + P(B) - 1$.

注意: 若 A, B 发生概率不足够大, 则 Bonferroni 下界可能是一个毫无用处 (尽管仍然正确) 的负数.

由 Bonferroni 不等式可知, 我们有:

$$\begin{aligned} & P \left(\alpha + \beta x_0^{(i)} \in \left(\hat{\alpha} + \hat{\beta}x_0^{(i)} \pm s\sqrt{\frac{1}{n} + \frac{(x_0^{(i)} - \bar{x})^2}{S_{xx}}} t_{n-2, \frac{\alpha}{2m}} \right) \text{ for all } i = 1, \dots, m \right) \\ & \geq \sum_{i=1}^m P \left(\alpha + \beta x_0^{(i)} \in \left(\hat{\alpha} + \hat{\beta}x_0^{(i)} \pm s\sqrt{\frac{1}{n} + \frac{(x_0^{(i)} - \bar{x})^2}{S_{xx}}} t_{n-2, \frac{\alpha}{2m}} \right) \right) - (m - 1) \\ & = m \cdot \left(1 - \frac{\alpha}{m} \right) - (m - 1) \\ & = 1 - \alpha \end{aligned}$$

换言之, 我们至少以概率 $1 - \alpha$ 有事件 $\alpha + \beta x_0^{(i)} \in \left(\hat{\alpha} + \hat{\beta}x_0^{(i)} \pm s\sqrt{\frac{1}{n} + \frac{(x_0^{(i)} - \bar{x})^2}{S_{xx}}} t_{n-2, \frac{\alpha}{2m}} \right)$ ($\forall i = 1, \dots, m$) 发生.

(结合 1.3.2(2) 的内容, 我们可以通过类似的方法给出 $Y_0^{(i)} \sim \mathcal{N}(\alpha + \beta x_0^{(i)}, \sigma^2)$ ($i = 1, \dots, m$) 的同时预测区间)

我们还可进一步对所有 x 进行同时推断.

(Scheffe 置信带, Statistical Inference 定理 11.3.6)

在条件正态模型 $(Y|X = x) \sim \mathcal{N}(\alpha + \beta x, \sigma^2)$ 下, 我们至少以概率 $1 - \tau$ 对所有 x 同时成立:

$$\alpha + \beta x \in \left(\hat{\alpha} + \hat{\beta}x \pm s\sqrt{\frac{1}{n} + \frac{(x - \bar{x})^2}{S_{xx}}} M_\tau \right) \text{ where } M_\tau = \sqrt{2F_{2, n-2, \alpha}}.$$


• 注解:

由于上式至少以概率 $1 - \tau$ 对所有 x 成立

故它给出的是整条总体回归线 $\mathbb{E}(Y|X = x) = \alpha + \beta x$ 的一个 $(1 - \tau)$ 置信带 (称为 **Scheffe 带**).

就像一个置信区间覆盖一个参数一样, 这个置信带覆盖了整条总体回归线.

下图给出了一个 Scheffe 带的例子, 同时给出了两个 Bonferroni 区间和一个 t 区间:



实际上 Bonferroni 区间有可能比 Scheffe 带更宽 (尽管图中没有给出这样的例子)

因此即使只对少数几个 x 感兴趣, 我们仍更倾向于选择 Scheffe 带而不是 Bonferroni 区间.

这是由于 Bonferroni 区间是通用的界 (而且实际覆盖率要比 $1 - \tau$ 高), 而 Scheffe 带是问题的精确解.

此外, 理论上我们可以用类似方法得到针对所有 x 的**同时预测区间**, 但导出的统计量没有特别好的分布.

证明:

上述问题等价于寻找一个常数 M_α 使得:

$$P \left(\frac{((\hat{\alpha} + \hat{\beta}x) - (\alpha + \beta x))^2}{s^2 \left(\frac{1}{n} + \frac{(x - \bar{x})^2}{S_{xx}} \right)} \leq M_\tau^2 \text{ for all } x \right) = 1 - \tau,$$

即等价于使得:

$$P \left(\max_x \frac{((\hat{\alpha} + \hat{\beta}x) - (\alpha + \beta x))^2}{s^2 \left(\frac{1}{n} + \frac{(x - \bar{x})^2}{S_{xx}} \right)} \leq M_\tau^2 \right) = 1 - \tau.$$

(Statistical Inference 习题 11.40)

若 a, b, c, d 为常数且 $c, d > 0$, 则我们有:

$$\max_t \frac{(a + bt)^2}{c + dt^2} = \frac{a^2}{c} + \frac{b^2}{d}.$$

这个结论是下面引理的直接推论.

Lemma: (广义 Rayleigh 商)

若 $b \in \mathbb{R}^n$ 为给定向量且 $A \in \mathbb{R}^{n \times n}$ 正定, 则我们有:

$$\max_{x \neq 0_n \in \mathbb{R}^n} \frac{(b^T x)^2}{x^T A x} = b^T A^{-1} b.$$

证明:

$$\begin{aligned}
\max_{x \neq 0_n \in \mathbb{R}^n} \frac{(b^T x)^2}{x^T A x} &= \max_{y \neq 0_n \in \mathbb{R}^n} \frac{(b^T A^{-\frac{1}{2}} y)^2}{y^T y} \quad (y := A^{\frac{1}{2}} x) \\
&= \max_{y \neq 0_n \in \mathbb{R}^n} \frac{y^T (A^{-\frac{1}{2}} b b^T A^{-\frac{1}{2}}) y}{y^T y} \quad (\text{Rayleigh theorem}) \\
&= \lambda_{\max}(A^{-\frac{1}{2}} b b^T A^{-\frac{1}{2}}) \quad (\text{note that } A \text{ is positive definite, hence symmetric}) \\
&= \lambda_{\max}((A^{-\frac{1}{2}} b)(A^{-\frac{1}{2}} b)^T) \quad (\text{note that rank-one matrix } z z^T \text{'s only non-zero eigenvalue is } \|z\|_2^2) \\
&= \|A^{-\frac{1}{2}} b\|_2^2 \\
&= b^T A^{-1} b
\end{aligned}$$

其中最大值可以在 $x = \alpha A^{-1} b$ ($\forall \alpha \neq 0 \in \mathbb{R}$) 取到.

$$\begin{aligned}
\max_x \frac{((\hat{\alpha} + \hat{\beta}x) - (\alpha + \beta x))^2}{s^2(\frac{1}{n} + \frac{(x-\bar{x})^2}{S_{xx}})} &= \frac{1}{s^2} \max_x \frac{((\bar{y} - \hat{\beta}\bar{x} + \hat{\beta}x) - (\alpha + \beta\bar{x} - \beta\bar{x} + \beta x))^2}{\frac{1}{n} + \frac{(x-\bar{x})^2}{S_{xx}}} \\
&= \frac{1}{s^2} \max_x \frac{((\bar{y} - \alpha - \beta\bar{x}) + (\hat{\beta} - \beta)(x - \bar{x}))^2}{\frac{1}{n} + \frac{1}{S_{xx}}(x - \bar{x})^2} \quad (\text{denote } t = x - \bar{x}) \\
&= \frac{1}{s^2} \max_t \frac{((\bar{y} - \alpha - \beta\bar{x}) + (\hat{\beta} - \beta)t)^2}{\frac{1}{n} + \frac{1}{S_{xx}}t^2} \quad (\text{use lemma}) \\
&= \frac{1}{s^2} \left(\frac{(\bar{y} - \alpha - \beta\bar{x})^2}{\frac{1}{n}} + \frac{(\hat{\beta} - \beta)^2}{\frac{1}{S_{xx}}} \right) \\
&= \frac{\frac{(\bar{y} - \alpha - \beta\bar{x})^2}{\sigma^2/n} + \frac{(\hat{\beta} - \beta)^2}{\sigma^2/S_{xx}}}{s^2/\sigma^2} \\
&\quad (\text{note that } \begin{cases} \bar{y} \sim \mathcal{N}(\alpha + \beta\bar{x}, \frac{\sigma^2}{n}) \\ \hat{\beta} \sim \mathcal{N}(\beta, \frac{\sigma^2}{S_{xx}}) \\ s^2 \sim \frac{1}{n-2} \sigma^2 \chi_{(n-2)}^2 \end{cases} \text{ and they are independent}) \\
&\sim \frac{\chi_{(2)}^2}{\chi_{(n-2)}^2/(n-2)} \\
&= 2 \frac{\chi_{(2)}^2/2}{\chi_{(n-2)}^2/(n-2)} \\
&= 2F_{2,n-2}
\end{aligned}$$

因此 $M_\tau^2 = 2F_{2,n-2,\tau}$, 即 $M_\tau = \sqrt{2F_{2,n-2,\tau}}$.
命题得证.

The End