

FDU 回归分析 2. 多元线性回归

本文根据王勤文老师课堂笔记整理而成，并参考以下教材：

- 应用回归分析 (第 5 版, 何晓群, 刘文卿) 第 3 章
- Statistical Inference (2nd Edition, G. Casella) Chapter 12
- 统计推断 (第 2 版, G. Casella) 第 12 章
- 数理统计讲义 (郑明, 陈子毅, 汪嘉冈) 第 1 章
- Introduction to Probability Models: Applied Stochastic Processes (S. Ross) Chapter 2
- 应用随机过程: 概率模型导论 (S. Ross) 第 2 章

欢迎批评指正!

2.1 多元线性回归模型

我们势必要将简单线性回归模型推广至多元线性回归模型，以解决更多实际问题。

2.1.1 一般形式

设随机变量 Y 与一般变量 $x_1, \dots, x_p$ 具有如下关系：

$$Y = \beta^T x + \varepsilon = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p + \varepsilon$$
$$E[Y|x] = \beta^T x,$$

其中：

$$\begin{cases} x = [1, x_1, \dots, x_p]^T \in \mathbb{R}^{p+1} \\ \beta = [\beta_0, \beta_1, \dots, \beta_p]^T \in \mathbb{R}^{p+1} \\ E[\varepsilon] = 0 \\ \text{Var}[\varepsilon] = \sigma^2. \end{cases}$$

设观测数据为 $(x^{(1)}, y_1), \dots, (x^{(n)}, y_n)$,

其中 $x^{(i)} = [1, x_1^{(i)}, \dots, x_p^{(i)}]^T \in \mathbb{R}^{p+1}$ ($i = 1, \dots, n$).

若以它们为行向量构造 $X = [x^{(1)}, \dots, x^{(n)}]^T \in \mathbb{R}^{n \times (p+1)}$, 则我们有：

$$\begin{cases} y_1 = \beta^T x^{(1)} + \varepsilon_1 \\ \vdots \\ y_n = \beta^T x^{(n)} + \varepsilon_n \end{cases} \Leftrightarrow y = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} (x^{(1)})^T \\ \vdots \\ (x^{(n)})^T \end{bmatrix} \beta + \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix} = X\beta + \varepsilon.$$

我们称 X 称为**设计矩阵** (design matrix).

2.1.2 基本假定

为方便对模型进行估计，我们做如下基本假定：

- ① 解释变量 $x_1, \dots, x_p$ 是确定性变量，不是随机变量，且与随机误差 ε 无关。
- ② $X \in \mathbb{R}^{n \times (p+1)}$ 是扁平的列满秩矩阵，即 $\text{rank}(X) = p + 1 < n$ (这保证 $X^T X$ 正定，因而可逆) 这表明设计矩阵 X 的自变量列之间不线性相关，且样本量 n 大于参数个数 $p + 1$
- ③ (Gauss-Markov 条件) 随机误差项 $\varepsilon_1, \dots, \varepsilon_n$ 零均值、不相关且方差相等，即 $\begin{cases} E[\varepsilon] = 0_n \\ \text{Cov}[\varepsilon] = \sigma^2 I_n \end{cases}$
- ④ (正态假设) 随机误差 $\varepsilon_1, \dots, \varepsilon_n$ 服从正态分布

结合 ③ 的假设, 我们可以统一记为 $\varepsilon \sim N(0_n, \sigma^2 I_n)$

满足上述所有假设的模型 $y = X\beta + \varepsilon$ 便称为条件正态模型, 它可写为 $y \sim N(X\beta, \sigma^2 I_n)$

2.2 参数的点估计

2.2.1 最小二乘: 数学解

(注意: 本节我们不对随机误差 $\varepsilon_1, \dots, \varepsilon_n$ 做任何统计上的假设)

我们定义观测数据 $(x^{(1)}, y_1), \dots, (x^{(n)}, y_n)$ 关于直线 $E[Y|x] = \beta^T x$ 的**残差平方和** (residual sum of squares) 为:

$$\begin{aligned}\text{RSS}(\beta) &:= \sum_{i=1}^n [y_i - \beta^T x^{(i)}]^2 = \|y - X\beta\|_2^2 \\ \nabla_{\beta} \text{RSS}(\beta) &= -2X^T(y - X\beta) \\ \nabla_{\beta}^2 \text{RSS}(\beta) &= 2X^T X \succ 0\end{aligned}$$

最小二乘的观点表明:

$$\hat{\beta} = \arg \min_{\beta} \text{RSS}(\beta) = \arg \min_{\beta} \|y - X\beta\|_2^2$$

注意到目标函数 $\text{RSS}(\beta) = \|y - X\beta\|_2^2$ 是关于 β 的严格凸函数

因此上述优化问题的最优解是唯一的, 且为驻点 (即使得梯度为零的点)

令 $\nabla_{\beta} \text{RSS}(\beta) = -2X^T(y - X\beta) = 0_{p+1}$ 解得最小二乘解为 $\hat{\beta} = (X^T X)^{-1} X^T y$

(1) 无偏性

下面我们证明 $\hat{\beta} - \beta$ 可以写成 ε 的线性组合:

$$\begin{aligned}\hat{\beta} - \beta &= (X^T X)^{-1} X^T y - \beta \\ &= (X^T X)^{-1} X^T (X\beta + \varepsilon) - \beta \\ &= \beta + (X^T X)^{-1} X^T \varepsilon - \beta \\ &= (X^T X)^{-1} X^T \varepsilon\end{aligned}$$

因此在 $\begin{cases} E[\varepsilon] = 0_n \\ \text{Cov}[\varepsilon] = \sigma^2 I_n \end{cases}$ 的假设下我们有:

$$\begin{aligned}E[\hat{\beta}] &= E[\beta + (X^T X)^{-1} X^T \varepsilon] \\ &= \beta + (X^T X)^{-1} X^T E[\varepsilon] \\ &= \beta + (X^T X)^{-1} X^T 0_n \\ &= \beta \\ \hline \text{Cov}[\hat{\beta}] &= \text{Cov}[\beta + (X^T X)^{-1} X^T \varepsilon] \\ &= (X^T X)^{-1} X^T \text{Cov}[\varepsilon] ((X^T X)^{-1} X^T)^T \\ &= (X^T X)^{-1} X^T \cdot \sigma^2 I_n \cdot X (X^T X)^{-1} \\ &= \sigma^2 (X^T X)^{-1}\end{aligned}$$

进一步, 在 $\varepsilon \sim N(0_n, \sigma^2 I_n)$ 的假设下我们有:

$$\hat{\beta} \sim N(\beta, \sigma^2 (X^T X)^{-1})$$

(2) 投影矩阵

根据最小二乘估计量 $\hat{\beta}$ 得到的预测值 $\hat{y} = X\hat{\beta} = X(X^T X)^{-1} X^T y$


结合最小二乘解的几何意义我们知道: $\hat{y}$ 是 $y \in \mathbb{R}^n$ 在 X 的列空间 $\text{span}\{X\}$ 的正交投影。

我们记正交投影矩阵 $H = X(X^T X)^{-1} X^T$, 容易验证它具有以下性质:

- ① 对称: $H^T = H$ (进而有 $(I_n - H)^T = I_n - H$)
这保证了 H 的 n 个特征值均为实数 (进而 $I_n - H$ 的 n 个特征值也均为实数)
- ② 幂等: $H^2 = H$ (进而有 $(I_n - H)^2 = I_n - H$)
这保证了 H 的特征值只能是 0 或 1 (进而 $I_n - H$ 的 n 个特征值也只能是 0 或 1)
- ③ 迹与特征值: $\text{tr}(H) = p + 1$ (进而有 $\text{tr}(I_n - H) = n - p - 1$)
这保证了 H 的特征值为 $n - p - 1$ 个 0 和 $p + 1$ 个 1 (进而 $I_n - H$ 的特征值为 $n - p - 1$ 个 1 和 $p + 1$ 个 0)
- ④ 映射公式:
由于 H 是 $\mathbb{R}^n$ 空间投影至 $\text{span}\{X\}$ 的正交投影矩阵 (且注意到 X 的第 1 列为 1_n), 因此我们有:

$$\begin{aligned} Hy = \hat{y} &\Rightarrow (I_n - H)y = y - \hat{y} \\ HX = X &\Rightarrow (I_n - H)X = 0_{n \times (p+1)} \\ H1_n = 1_n &\Rightarrow (I_n - H)1_n = 0_n \end{aligned}$$

以简单线性回归为例展示最小二乘的几何意义:



2.2.2 最佳线性无偏估计: 统计解

现在给定 $\begin{cases} E[\varepsilon] = 0_n \\ \text{Cov}[\varepsilon] = \sigma^2 I_n \end{cases}$ 的假设 (但我们不对 ε 的分布进行假设)

下面我们证明最小二乘估计量 $\hat{\beta}_{\text{LSE}} = (X^T X)^{-1} X^T y$ 是 β 的线性无偏估计类中最优的估计量。

- 首先, β 的一个线性估计量具有形式 $\hat{\beta} = C^T y$ (其中 $C \in \mathbb{R}^{n \times (d+1)}$ 是已知且固定的矩阵)
- 其次, β 的一个线性无偏估计量还满足 $E[\hat{\beta}] = \beta$, 也就是说:

$$\begin{aligned}
\mathbb{E}[\hat{\beta}] &= \mathbb{E}[C^T y] \\
&= \mathbb{E}[C^T (X\beta + \varepsilon)] \\
&= C^T X\beta + C^T \mathbb{E}[\varepsilon] \quad (\text{note that } \mathbb{E}[\varepsilon] = 0_n) \\
&= C^T X\beta \\
&= \beta
\end{aligned}$$

根据 $C^T X\beta = \beta$ 可知 $C \in \mathbb{R}^{n \times (d+1)}$ 满足 $C^T X = I_{d+1}$

- 最后, β 的最佳线性无偏估计量还满足 $\text{tr}(\text{Cov}[\hat{\beta}]) = \min_{C^T X = I_{d+1}} \text{tr}(\text{Cov}[C^T y])$

注意到目标函数可以化为:

$$\begin{aligned}
\text{tr}(\text{Cov}[C^T y]) &= \text{tr}(C^T \text{Cov}[y] C) \\
&= \text{tr}(C^T \text{Cov}[X\beta + \varepsilon] C) \\
&= \text{tr}(C^T \text{Cov}[\varepsilon] C) \\
&= \text{tr}(C^T \cdot \sigma^2 I_n \cdot C) \\
&= \sigma^2 \text{tr}(C^T C)
\end{aligned}$$

因此问题变为求解最优化问题:

$$\hat{C} = \arg \min_{C^T X = I_{d+1}} \text{tr}(C^T C) = \arg \min_{C^T X = I_{d+1}} \|C\|_F^2$$

其中 $\|C\|_F$ 代表矩阵 $C \in \mathbb{R}^{n \times (d+1)}$ 的 Frobenius 范数.

注意到目标函数是 (严格) 凸函数 (因为可以验证 $\nabla_C^2 \{\text{tr}(C^T C)\} = 2I_n \succ 0 \ (\forall C \in \mathbb{R}^{n \times (d+1)})$)

因此其 KKT 点就对应其最优解.

定义 Lagrange 函数为 $L(C, \Lambda) = \text{tr}(C^T C) - \text{tr}(\Lambda(C^T X - I_{d+1}))$,

其中对称正定阵 $\Lambda \in \mathbb{R}^{(d+1) \times (d+1)}$ 是约束条件 $C^T X = I_{d+1}$ 对应的 Lagrange 乘子.

回忆起高等线性代数中的一些求导结论:

$$\begin{aligned}
\nabla_X \text{tr}(AX) &= \nabla_X \text{tr}(XA) = \nabla_X \text{tr}(A^T X^T) = \nabla_X \text{tr}(X^T A^T) = A^T \quad (\text{特殊地我们有 } \nabla_X \text{tr}(X) = I) \\
\nabla_X \|X\|_F^2 &= \nabla_X \text{tr}(X^T X) = \nabla_X \text{tr}(XX^T) = 2X
\end{aligned}$$

我们计算其关于 $C \in \mathbb{R}^{n \times (d+1)}$ 的梯度:

$$\begin{aligned}
\nabla_C L(C, \Lambda) &= \nabla_C \{\text{tr}(C^T C) - \text{tr}(\Lambda(C^T X - I_{d+1}))\} \\
&= \nabla_C \{\text{tr}(C^T C)\} - \nabla_C \{\text{tr}(C^T X \Lambda)\} \\
&= 2C - X\Lambda
\end{aligned}$$

其 KKT 条件如下:

$$\begin{cases} \nabla_C L(C, \Lambda) = 2C - X\Lambda = 0_{n \times (d+1)} \\ C^T X = I_{d+1} \end{cases}$$

$$\text{可解得 } \begin{cases} \hat{\Lambda} = 2(X^T X)^{-1} \\ \hat{C} = \frac{1}{2} X \hat{\Lambda} = X(X^T X)^{-1} \end{cases}$$

因此最佳线性无偏估计量为:

$$\hat{\beta} = \hat{C}^T y = [X(X^T X)^{-1}]^T y = (X^T X)^{-1} X^T y$$

其协方差矩阵的迹为 β 的线性无偏估计量所能具有的协方差矩阵的迹的最小值 (因而 $\hat{\beta}$ 是最稳定的线性无偏估计量):

$$\begin{aligned}
\text{tr}(\text{Cov}[\hat{\beta}]) &= \min_{C^T X = I_{d+1}} \{\text{tr}(\text{Cov}[C^T y])\} \\
&= \min_{C^T X = I_{d+1}} \{\sigma^2 \text{tr}(C^T C)\} \\
&= \sigma^2 \text{tr}(\hat{C}^T \hat{C}) \\
&= \sigma^2 \text{tr}\{[X(X^T X)^{-1}]^T [X(X^T X)^{-1}]\} \\
&= \sigma^2 \text{tr}[(X^T X)^{-1}] \\
\hline
\text{Cov}[\hat{\beta}] &= \sigma^2 (X^T X)^{-1}
\end{aligned}$$

(多元线性回归中的 Gauss-Markov 定理)

给定数据点 $(x^{(1)}, y_1), \dots, (x^{(n)}, y_n)$ 和多元线性回归模型 $Y = \beta^T x + \varepsilon$ (其中 $\beta \in \mathbb{R}^{p+1}$ 为参数向量, ε 为随机噪声) 记样本关系为 $y = X\beta + \varepsilon$ (其中 $X = [x^{(1)}, \dots, x^{(n)}]^T \in \mathbb{R}^{n \times (p+1)}$ 为设计矩阵, $\varepsilon \in \mathbb{R}^n$ 为随机误差构成的列向量)

若 $\begin{cases} \mathbb{E}[\varepsilon] = 0_n \\ \text{Var}[\varepsilon] = \sigma^2 I_n \end{cases}$ (零均值和互不相关, 无需给出分布上的假设),

则最小二乘估计量 $\hat{\beta} = (X^T X)^{-1} X^T y$ 是参数向量 β 的最佳线性无偏估计量 (Best Linear Unbiased Estimator, BLUE)

$$\begin{aligned}
\mathbb{E}[\hat{\beta}] &= \beta \\
\text{Cov}[\hat{\beta}] &= \sigma^2 (X^T X)^{-1}
\end{aligned}$$

2.2.3 极大似然估计

现在我们考虑正态假设 $\varepsilon \sim N(0_n, \sigma^2 I_n)$ 下的多元线性回归模型 $y = X\beta + \varepsilon$ (可等价写作 $y \sim N(X\beta, \sigma^2 I_n)$) 这称为条件正态模型。

(1) 似然解

下面求解 β 和 σ^2 的极大似然估计量:

$y \sim N(X\beta, \sigma^2 I_n)$ 的概率密度函数为:

$$\begin{aligned}
f(y) &= \frac{1}{(\sqrt{2\pi})^n |\sigma^2 I_n|^{\frac{1}{2}}} \exp\left\{-\frac{1}{2}(y - X\beta)^T (\sigma^2 I_n)^{-1} (y - X\beta)\right\} \\
&= \frac{1}{(\sqrt{2\pi}\sigma)^n} \exp\left\{-\frac{1}{2\sigma^2}(y - X\beta)^T (y - X\beta)\right\}
\end{aligned}$$

似然函数 $L(\beta, \sigma^2 | X, y)$ 和对数似然函数 $\log L(\beta, \sigma^2 | X, y)$ 为:

$$\begin{aligned}
L(\beta, \sigma^2 | X, y) &= f(y) = \frac{1}{(\sqrt{2\pi}\sigma)^n} \exp\left\{-\frac{1}{2\sigma^2}(y - X\beta)^T (y - X\beta)\right\} \\
\log L(\beta, \sigma^2 | X, y) &= -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} (y - X\beta)^T (y - X\beta)
\end{aligned}$$

注意到对于任意固定的 σ^2 , 对数似然函数 $\log L(\beta, \sigma^2 | X, y)$ 作为 β 的函数最大化的问题, 就等价于残差平方和 $\text{RSS}(\beta) = \|y - X\beta\|_2^2$ 作为 β 的函数最小化的问题。

因此对于任意固定的 σ^2 , β 的极大似然估计量正是最小二乘估计量 $\hat{\beta} = (X^T X)^{-1} X^T y$

由于 $y \sim N(X\beta, \sigma^2 I_n)$, 结合 $\begin{cases} \mathbb{E}[\hat{\beta}] = \beta \\ \text{Var}[\hat{\beta}] = \sigma^2 (X^T X)^{-1} \end{cases}$ 的结论可知 $\beta \sim N(\beta, \sigma^2 (X^T X)^{-1})$

(正态随机变量只需确定均值和方差便能确定它的分布)

现在我们将 $\hat{\beta} = (X^T X)^{-1} X^T y$ 代入对数似然函数 $\log L(\beta, \sigma^2 | X, y)$ 以求得 σ^2 的极大似然估计量。

注意到对数似然函数 $\log L(\hat{\beta}, \sigma^2 | X, y)$ 关于 σ^2 是严格凹函数, 因此其最大值点唯一且为驻点. 我们令:

$$\frac{\partial}{\partial \sigma^2} L(\hat{\beta}, \sigma^2 | X, y) = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} (y - X\hat{\beta})^T (y - X\hat{\beta}) = 0$$

解得 $\hat{\sigma}^2 = \frac{1}{n} \|y - X\hat{\beta}\|_2^2 = \frac{1}{n} \text{RSS}(\hat{\beta}) = \frac{1}{n} \text{SSE}$

即为在最小二乘线 $y = \hat{\beta}^T x$ 处算得的残差平方和 $\text{RSS}(\hat{\beta})$ 除以样本量 n

$$\begin{aligned} \hat{\sigma}^2 &= \frac{1}{n} \text{RSS}(\hat{\beta}) \\ &= \frac{1}{n} \|y - X\hat{\beta}\|_2^2 \quad (\text{recall that } \hat{y} = X\hat{\beta} = Hy \text{ where } H = X(X^T X)^{-1} X^T) \\ &= \frac{1}{n} \|y - Hy\|_2^2 \\ &= \frac{1}{n} y^T (I_n - H)^T (I_n - H) y \quad (\text{note that } H \text{ is symmetric and idempotent}) \\ &= \frac{1}{n} y^T (I_n - H) y \quad (\text{note that } y = X\beta + \varepsilon) \\ &= \frac{1}{n} (X\beta + \varepsilon)^T (I_n - H) (X\beta + \varepsilon) \quad (\text{note that } HX = X \text{ so that } (I_n - H)X = 0_{n \times (p+1)}) \\ &= \frac{1}{n} \varepsilon^T (I_n - H) \varepsilon \end{aligned}$$

(2) 纠偏

下面我们证明 σ^2 的极大似然估计量 $\hat{\sigma}^2 = \frac{1}{n} \|y - X\hat{\beta}\|_2^2 = \frac{1}{n} \varepsilon^T (I_n - H) \varepsilon$ 不是无偏的.

$$\begin{aligned} E[\hat{\sigma}^2] &= E\left[\frac{1}{n} \varepsilon^T (I_n - H) \varepsilon\right] \\ &= \frac{1}{n} E\{\text{tr}[\varepsilon^T (I_n - H) \varepsilon]\} \\ &= \frac{1}{n} E\{\text{tr}[(I_n - H) \varepsilon \varepsilon^T]\} \\ &= \frac{1}{n} \text{tr}\{E[(I_n - H) \varepsilon \varepsilon^T]\} \\ &= \frac{1}{n} \text{tr}\{(I_n - H) E[\varepsilon \varepsilon^T]\} \\ &= \frac{1}{n} \text{tr}\{(I_n - H) \text{Cov}(\varepsilon)\} \\ &= \frac{1}{n} \text{tr}\{(I_n - H) \sigma^2 I_n\} \\ &= \frac{1}{n} \sigma^2 \cdot \text{tr}(I_n - H) \quad (\text{note that } \text{tr}(I_n - H) = n - \text{tr}(H) = n - p - 1) \\ &= \frac{n - p - 1}{n} \sigma^2 \end{aligned}$$

因此 $\hat{\sigma}^2$ 不是 σ^2 的无偏估计量

我们可以构造 σ^2 的无偏估计量为 $s^2 = \frac{n}{n-p-1} \hat{\sigma}^2 = \frac{1}{n-p-1} \|y - X\hat{\beta}\|_2^2 = \frac{1}{n-p-1} \varepsilon^T (I_n - H) \varepsilon$

(3) 分布

在 2.2.3(1) 中我们已经说明了最小二乘估计量 $\hat{\beta} = (X^T X)^{-1} X^T y$ 服从正态分布:

$$\hat{\beta} \sim N(\beta, \sigma^2 (X^T X)^{-1})$$

下面我们证明 $s^2 = \frac{1}{n-p-1} \|y - X\hat{\beta}\|_2^2 = \frac{1}{n-p-1} \varepsilon^T (I_n - H) \varepsilon$ 与 $\hat{\beta}$ 独立:

在证明之前我们先给出两个有用的引理:

(Statistical Inference 引理 11.3.2)

设 $Y_1, \dots, Y_n$ 是互不相关的随机变量, $\text{Var}(Y_i) = \sigma_i^2$ ($i = 1, \dots, n$), $a, b \in \mathbb{R}^n$ 为常数向量. 若记 $Y = [Y_1, \dots, Y_n]^T$, $\Sigma = \text{Cov}(Y) = \text{diag}\{\sigma_1^2, \dots, \sigma_n^2\}$, 则我们有:

$$\text{Cov}(a^T Y, b^T Y) = \text{Cov}\left(\sum_{i=1}^n a_i Y_i, \sum_{i=1}^n b_i Y_i\right) = \sum_{i=1}^n a_i b_i \sigma_i^2 = a^T \Sigma b$$

(Statistical Inference 引理 5.3.3)

设 $X_i \sim N(\mu_i, \sigma_i^2)$ ($i = 1, \dots, n$) 相互独立, 记:

$$\begin{aligned} X &= \begin{bmatrix} X_1 \\ \vdots \\ X_n \end{bmatrix} & U &= \begin{bmatrix} U_1 \\ \vdots \\ U_k \end{bmatrix} & V &= \begin{bmatrix} V_1 \\ \vdots \\ V_m \end{bmatrix} \quad (\text{where } k + m \leq n) \\ A &= [a_1, \dots, a_k] \in \mathbb{R}^{n \times k} & B &= [b_1, \dots, b_m] \in \mathbb{R}^{n \times m} \\ U &= A^T X = \begin{bmatrix} a_1^T X \\ \vdots \\ a_k^T X \end{bmatrix} & V &= B^T X = \begin{bmatrix} b_1^T X \\ \vdots \\ b_m^T X \end{bmatrix} \\ \Sigma &= \text{Cov}(X) = \text{diag}\{\sigma_1^2, \dots, \sigma_n^2\} \end{aligned}$$

则我们有:

- U_i 和 V_j 相互独立当且仅当 $\text{Cov}(U_i, V_j) = \text{Cov}(a_i^T X, b_j^T X) = a_i^T \Sigma b_j = 0$
其中 $i = 1, \dots, k$ 而 $j = 1, \dots, m$
- U 和 V 相互独立当且仅当对于任意 $i = 1, \dots, k$ 和 $j = 1, \dots, m$ 都有 $\text{Cov}(U_i, V_j) = 0$
即当且仅当 $\text{Cov}(U, V) = \text{Cov}(A^T X, B^T X) = A^T \Sigma B = 0_{k \times m}$

要证明 $s^2 = \frac{1}{n-p-1} \|(I_n - H)\varepsilon\|_2^2$ 与 $\hat{\beta}$ 独立, 只需证明 $(I_n - H)\varepsilon$ 与 $\hat{\beta}$ 独立即可

根据 **Statistical Inference 引理 5.3.3** 可知只需证明 $\text{Cov}((I_n - H)\varepsilon, \hat{\beta}) = 0_{n \times (p+1)}$ 即可.

回忆起 $\hat{\beta} - \beta$ 可以写成 ε 的线性组合: $\hat{\beta} - \beta = (X^T X)^{-1} X^T \varepsilon$, 故我们有:

$$\begin{aligned} \text{Cov}((I_n - H)\varepsilon, \hat{\beta}) &= \text{Cov}((I_n - H)\varepsilon, \hat{\beta} - \beta) \\ &= \text{Cov}((I_n - H)\varepsilon, (X^T X)^{-1} X^T \varepsilon) \\ &= (I_n - H) \text{Cov}(\varepsilon) [(X^T X)^{-1} X^T]^T \\ &= (I_n - H) \cdot \sigma^2 I_n \cdot X (X^T X)^{-1} \\ &= \sigma^2 (I_n - H) X (X^T X)^{-1} \quad (\text{recall that } (I_n - H)X = 0_{n \times (p+1)}) \\ &= \sigma^2 \cdot 0_{n \times (p+1)} \cdot (X^T X)^{-1} \\ &= 0_{n \times (p+1)} \end{aligned}$$

因此 s^2 与 $\hat{\beta}$ 相互独立.

下面我们证明 $\frac{n-p-1}{\sigma^2} s^2 = \frac{1}{\sigma^2} \varepsilon^T (I_n - H) \varepsilon$ 服从自由度为 $n - p - 1$ 的卡方分布 $\chi_{(n-p-1)}^2$

在 2.2.1(2) 节我们说明了投影矩阵 $H = X(X^T X)^{-1} X^T$ 的几个性质:

- ① 对称: $H^T = H$ (进而有 $(I_n - H)^T = I_n - H$)
这保证了 H 的 n 个特征值均为实数 (进而 $I_n - H$ 的 n 个特征值也均为实数)
- ② 幂等: $H^2 = H$ (进而有 $(I_n - H)^2 = I_n - H$)
这保证了 H 的特征值只能是 0 或 1 (进而 $I_n - H$ 的 n 个特征值也只能是 0 或 1)
- ③ 迹与特征值: $\text{tr}(H) = p + 1$ (进而有 $\text{tr}(I_n - H) = n - p - 1$)
这保证了 H 的特征值为 $n - p - 1$ 个 0 和 $p + 1$ 个 1 (进而 $I_n - H$ 的特征值为 $n - p - 1$ 个 1 和 $p + 1$ 个 0)

设 $I_n - H$ 的谱分解 (实对称阵一定具有谱分解) 为:

$$U^T(I_n - H)U = \Lambda = \text{diag}\{\underbrace{1, \dots, 1}_{n-p-1}, \underbrace{0, \dots, 0}_{p+1}\}$$

记 $\eta := \frac{1}{\sigma}U^T\varepsilon$, 根据 $\varepsilon \sim N(0_n, \sigma^2 I_n)$ 可知 $\eta = \frac{1}{\sigma}U^T\varepsilon \sim N(\frac{1}{\sigma}U^T 0_n, \frac{1}{\sigma^2}U^T \sigma^2 I_n U) = N(0_n, I_n)$.

这表明 $\eta = [\eta_1, \dots, \eta_n]^T$ 的分量是独立同分布的标准正态随机变量.

于是我们有:

$$\begin{aligned} \frac{n-p-1}{\sigma^2}s^2 &= \frac{1}{\sigma^2}\varepsilon^T(I_n - H)\varepsilon \\ &= \frac{1}{\sigma^2}\varepsilon^T U \Lambda U^T \varepsilon \\ &= \eta^T \Lambda \eta \\ &= \sum_{i=1}^{n-p-1} \eta_i^2 \sim \chi_{(n-p-1)}^2 \quad (\text{note that } \Lambda = \text{diag}\{\underbrace{1, \dots, 1}_{n-p-1}, \underbrace{0, \dots, 0}_{p+1}\}) \end{aligned}$$

这样我们就证明了 $\frac{n-p-1}{\sigma^2}s^2 = \frac{1}{\sigma^2}\varepsilon^T(I_n - H)\varepsilon$ 服从自由度为 $n-p-1$ 的卡方分布 $\chi_{(n-p-1)}^2$

据此我们也可以自然地得到:

$$\begin{aligned} (n-p-1)s^2 &= n\hat{\sigma}^2 \sim \sigma^2 \chi_{(n-p-1)}^2 \\ \mathbb{E}[\hat{\sigma}^2] &= \frac{\sigma^2}{n}(n-p-1) = \frac{n-p-1}{n}\sigma^2 \Rightarrow \mathbb{E}[s^2] = \sigma^2 \\ \text{Var}[\hat{\sigma}^2] &= \frac{\sigma^4}{n^2}2(n-p-1) = \frac{2(n-p-1)}{n^2}\sigma^4 \Rightarrow \text{Var}[s^2] = \frac{2}{n-p-1}\sigma^4 \end{aligned}$$

总之我们有如下定理:

在条件正态模型下, $\hat{\beta}, s^2$ 分别是 α, β, σ^2 的无偏估计量, 它们满足:

$$\begin{aligned} \hat{\beta} &= (X^T X)^{-1} X^T y \\ s^2 &= \frac{1}{n-p-1} \|y - X\hat{\beta}\|_2^2 = \frac{1}{n-p-1} \varepsilon^T (I_n - H) \varepsilon \text{ where } H = X(X^T X)^{-1} X^T \\ \hline \hat{\beta} &\sim N(\beta, \sigma^2 (X^T X)^{-1}) \\ \frac{(n-p-1)s^2}{\sigma^2} &\sim \chi_{(n-p-1)}^2 \\ \hline \text{Var}[s^2] &= \frac{2}{n-p-1} \sigma^4 \end{aligned}$$

2.3 假设检验

2.3.1 常用分布

(本节内容取自 FDU 数理统计 1. 基础知识)

(1) Gamma 分布 $\text{Gamma}(\alpha, \lambda)$

定义 **Gamma 函数** 为 $\begin{cases} \Gamma(\alpha) = \int_0^{+\infty} e^{-t} t^{\alpha-1} dt \\ \text{dom}(\Gamma) = \{\alpha \in \mathbb{C} : \text{Re}(\alpha) > 0\} \end{cases}$

特殊地, 对于任意整数 n 有 $\Gamma(n) = (n-1)!$ 成立,
实际上 Γ 函数是阶乘函数在实数域和复数域上的推广.

它还具有性质 $\begin{cases} \Gamma(\frac{1}{2}) = \sqrt{\pi} \\ \Gamma(1) = 1 \\ \Gamma(\alpha+1) = \alpha\Gamma(\alpha) \end{cases}$

若对于某对 $\begin{cases} \alpha > 0 \\ \lambda > 0 \end{cases}$ 有 $f(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x} I_{(0,\infty)}(x) = \begin{cases} \frac{\lambda e^{-\lambda x} (\lambda x)^{\alpha-1}}{\Gamma(\alpha)}, & x > 0 \\ 0, & \text{otherwise} \end{cases}$ 成立

则称 X 为具有参数 (α, λ) 的 **Gamma 随机变量**, 记为 $X \sim \text{Gamma}(\alpha, \lambda)$

它没有解析形式的累积分布函数.

它满足 $\begin{cases} M_X(t) = (\frac{\lambda}{\lambda-t})^\alpha & (t < \lambda) \\ \varphi_X(t) = (\frac{\lambda}{\lambda-it})^\alpha \\ E[X^k] = \frac{\Gamma(\alpha+k)}{\lambda^k \Gamma(\alpha)} & (\forall k = 1, 2, \dots) \\ E[X] = \frac{\alpha}{\lambda} \\ E[X^2] = \frac{\alpha(\alpha+1)}{\lambda^2} \\ \mu_2 = \text{Var}[X] = \frac{\alpha}{\lambda^2} \\ \mu_3 = E[(X - E[X])^3] = \frac{2\alpha}{\lambda^3} \\ \mu_4 = E[(X - E[X])^4] = \frac{3\alpha^2 + 6\alpha}{\lambda^4} \end{cases}$

Gamma 分布具有**再生性**:

即对于任意 $\begin{cases} X_1 \sim \text{Gamma}(\alpha_1, \lambda) \\ X_2 \sim \text{Gamma}(\alpha_2, \lambda) \\ X_1 \perp X_2 \end{cases}$ 都有 $X_1 + X_2 \sim \text{Gamma}(\alpha_1 + \alpha_2, \lambda)$

我们在后面会证明这个性质 (**定理1.2.1**)

特殊地, 指数分布 $\exp(\lambda) \stackrel{\Delta}{=} \text{Gamma}(1, \lambda)$




图 1.3-1 $\Gamma(\alpha, \lambda)$ 分布密度函数图

(2) 卡方分布 $\chi^2(k)$

若 $X \sim N(0, 1)$ (即 $f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\{-\frac{x^2}{2\sigma^2}\}$)

则 $Y = g(X) = X^2$ 的概率密度函数为:

(我们记 $x = h(y) = \sqrt{y}$, 注意这只相当于 "一半的反函数", 所以要乘 2; 而 $J(x) = \frac{\partial}{\partial x} g(x) = 2x$)

$$\begin{aligned} f_Y(y) &= 2 \cdot f_X(h(y)) |J(h(y))|^{-1} \\ &= 2 f_X(\sqrt{y}) \cdot |2\sqrt{y}|^{-1} \\ &= 2 \frac{1}{\sqrt{2\pi}} \exp\left\{-\frac{(\sqrt{y})^2}{2}\right\} \cdot \frac{1}{2\sqrt{y}} \\ &= \frac{1}{\sqrt{2\pi y}} \exp\left\{-\frac{y}{2}\right\} \\ &= \frac{(\frac{1}{2})^{\frac{1}{2}}}{\Gamma(\frac{1}{2})} y^{\frac{1}{2}-1} e^{-\frac{1}{2}y} \\ &= P\{\text{Gamma}(\frac{1}{2}, \frac{1}{2}) = y\} \quad (y \geq 0) \end{aligned}$$

于是我们可以知道: $Y = X^2 \sim \text{Gamma}(\frac{1}{2}, \frac{1}{2}) \stackrel{\Delta}{=} \chi^2(1)$

我们称 Y 服从自由度为 1 的卡方分布 $\chi^2(1)$.

根据 Gamma 分布的再生性 (定理1.2.2):

若 $X_1, \dots, X_k \stackrel{iid}{\sim} N(0, 1)$,

记 $Y_i = X_i^2 \sim \text{Gamma}(\frac{1}{2}, \frac{1}{2}) \stackrel{\Delta}{=} \chi^2(1) \quad (\forall i = 1, \dots, k)$

则 $Z = \sum_{i=1}^k Y_i \sim \text{Gamma}(\frac{k}{2}, \frac{1}{2}) \stackrel{\Delta}{=} \chi^2(k)$

也就是说, k 个相互独立的标准正态随机变量的平方和 Z 服从自由度为 k 的卡方分布 $\chi^2(k)$

卡方随机变量 $X \sim \chi^2(n) = \text{Gamma}(\frac{n}{2}, \frac{1}{2})$ 满足


$$\begin{cases} f_X(x) = \frac{x^{n/2-1}}{2^{n/2}\Gamma(n/2)} e^{-\frac{1}{2}x} I_{(0,\infty)} \\ E[X^k] = \frac{\Gamma(\frac{n}{2}+k)}{(\frac{1}{2})^k \Gamma(\frac{n}{2})} \\ E[X] = n \\ E[X^2] = n(n+2) \\ \text{Var}[X] = 2n \end{cases}$$


图 1.3-3 $\chi^2(k)$ 分布密度函数图

(3) F 分布 $F(k_1, k_2)$

若 $\begin{cases} X_1 \sim \chi^2(k_1) \\ X_2 \sim \chi^2(k_2) \\ X_1 \perp X_2 \end{cases}$, 则称 $Y = \frac{X_1/k_1}{X_2/k_2}$ 的分布为 **F 分布**, 记为 $F(k_1, k_2)$

其中 k_1 称为**分子自由度** (ndf, numerator degrees of freedom)

而 k_2 称为**分母自由度** (ddf, denominator degrees of freedom).

根据定理 1.4 可知:

若 $\begin{cases} X_1 \sim \chi^2(k_1) = \text{Gamma}(\frac{k_1}{2}, \frac{1}{2}) \\ X_2 \sim \chi^2(k_2) = \text{Gamma}(\frac{k_2}{2}, \frac{1}{2}) \\ X_1 \perp X_2 \end{cases}$, 则 $\frac{X_1}{X_2} \sim \text{Beta Prime}(\frac{k_1}{2}, \frac{k_2}{2})$

因此我们知道 $F(k_1, k_2) \stackrel{d}{=} \frac{k_2}{k_1} \text{Beta Prime}(\frac{k_1}{2}, \frac{k_2}{2})$

$$F \text{ 随机变量 } X \sim F(k_1, k_2) \text{ 满足: } \begin{cases} f_X(x) = \frac{(k_1/k_2)^{k_1/2}}{\beta(k_1/2, k_2/2)} \frac{x^{k_1/2-1}}{(1+(k_1/k_2)x)^{(k_1+k_2)/2}} I_{(0,\infty)}(x) \\ = \frac{k_1^{k_1/2} k_2^{k_2/2}}{\beta(k_1/2, k_2/2)} \frac{x^{k_1/2-1}}{(k_2+k_1x)^{(k_1+k_2)/2}} I_{(0,\infty)}(x) \\ E[X] = \frac{k_2}{k_2-2} \quad (k_2 > 2) \\ \text{Var}[X] = \frac{2k_2^2(k_1+k_2-2)}{k_1(k_2-2)^2(k_2-4)} \quad (k_2 > 4) \end{cases}$$




图 1.3-4 $F(m, n)$ 分布密度函数图

(4) t 分布 $t(k)$

若 $\begin{cases} Z \sim N(0, 1) \\ X \sim \chi^2(k) \\ Z \perp X \end{cases}$, 则称 $Y = \frac{Z}{\sqrt{X/k}}$ 的分布为自由度为 k 的 t 分布, 记为 $t(k)$

容易验证: $(t(k))^2 \stackrel{d}{=} F(1, k)$

非中心 t 分布:

若 $\begin{cases} Z \sim N(\mu, 1) \\ X \sim \chi^2(k) \\ Z \perp X \end{cases}$, 则记 $Y = \frac{Z}{\sqrt{X/k}} \sim t(k, \mu)$

其中 μ 为位置参数, 显然 $t(k) \stackrel{d}{=} t(k, 0)$

$$t \text{ 分布随机变量 } X \sim t(k) \text{ 满足 } \left\{ \begin{aligned} f_X(x) &= \frac{1}{2} \cdot P\{F(1, k) = y\} \cdot \left| \frac{\partial y}{\partial x} \right| \\ &= \frac{1}{2} \cdot \frac{1^{1/2} k^{k/2}}{\beta(1/2, k/2)} \frac{y^{1/2-1}}{(k+y)^{(1+k)/2}} I_{(0, \infty)}(y) \cdot 2|x| \\ &= \frac{1}{2} \cdot k^{k/2} \cdot \frac{\Gamma(\frac{k+1}{2})}{\Gamma(\frac{1}{2})\Gamma(\frac{k}{2})} \cdot \frac{(x^2)^{-1/2}}{(k+x^2)^{(k+1)/2}} I_{(0, \infty)}(x^2) \cdot 2|x| \\ &= \frac{\Gamma(\frac{k+1}{2})}{\sqrt{\pi}\Gamma(\frac{k}{2})} \cdot \frac{k^{k/2}}{(k+x^2)^{(k+1)/2}} \\ &= \frac{\Gamma(\frac{k+1}{2})}{\sqrt{k\pi}\Gamma(\frac{k}{2})} \left(1 + \frac{x^2}{k}\right)^{-\frac{k+1}{2}} \\ E[X] &= 0 \quad (k > 1) \\ \text{Var}[X] &= \frac{k}{k-2} \quad (k > 2) \end{aligned} \right.$$




图 1.3-5 $t(k)$ 分布密度函数图

2.3.2 回归方程显著性的 F 检验

对多元线性回归方程的显著性检验就是要看自变量 $x_1, \dots, x_p$ 从整体上对随机变量 Y 是否有显著的影响。

考虑第一类错误概率界限为 α 的检验问题 $H_0: \beta_1 = \dots = \beta_p = 0 \leftrightarrow H_1: \exists i \in \{1, \dots, p\}$ such that $\beta_i \neq 0$ 如果零假设 H_0 被推翻, 那么我们认为自变量 $x_1, \dots, x_p$ 从整体上对随机变量 Y 有显著的影响。

(1) 基本记号

① 总平方和 (Total Sum of Squares)

$$\begin{aligned} \text{SST} &= S_{yy} \\ &= \|y - \bar{y}1_n\|_2^2 \\ &= (y - \bar{y}1_n)^T (y - \bar{y}1_n) \\ &= y^T y - n\bar{y}^2 \\ &= y^T y - n\left(\frac{1}{n}1_n^T y\right)^2 \\ &= y^T \left(I_n - \frac{1}{n}1_n 1_n^T\right) y \end{aligned}$$

显然 SST 只与样本有关, 与模型无关。

当零假设 $H_0: \beta_1 = \dots = \beta_p = 0$ 成立时, 我们有 $y = X\beta + \varepsilon = \beta_0 1_n + \varepsilon$, 因而有:

$$\begin{aligned} \text{SST} &= y^T \left(I_n - \frac{1}{n}1_n 1_n^T\right) y \\ &\stackrel{H_0}{=} (\beta_0 1_n + \varepsilon)^T \left(I_n - \frac{1}{n}1_n 1_n^T\right) (\beta_0 1_n + \varepsilon) \\ &= \varepsilon^T \left(I_n - \frac{1}{n}1_n 1_n^T\right) \varepsilon \end{aligned}$$

注意到 $I_n - \frac{1}{n}1_n 1_n^T$ 对称、幂等且 $\text{tr}\left(I_n - \frac{1}{n}1_n 1_n^T\right) = n - 1$

因此它存在谱分解, 且有 $n - 1$ 个特征值是 1, 1 个特征值是 0

我们可设其谱分解为:

$$U^T \left(I_n - \frac{1}{n}1_n 1_n^T\right) U = \Lambda = \text{diag}\{\underbrace{1, \dots, 1}_{n-1}, 0\}$$

记 $\eta := \frac{1}{\sigma} U^T \varepsilon$, 根据 $\varepsilon \sim N(0_n, \sigma^2 I_n)$ 可知 $\eta = \frac{1}{\sigma} U^T \varepsilon \sim N\left(\frac{1}{\sigma} U^T 0_n, \frac{1}{\sigma^2} U^T \sigma^2 I_n U\right) = N(0_n, I_n)$

这表明 $\eta = [\eta_1, \dots, \eta_n]^T$ 的分量是独立同分布的标准正态随机变量。

于是我们有:

$$\begin{aligned} \frac{1}{\sigma^2} \text{SST} &= \frac{1}{\sigma^2} \|y - \bar{y}1_n\|_2^2 \\ &\stackrel{H_0}{=} \frac{1}{\sigma^2} \varepsilon^T \left(I_n - \frac{1}{n}1_n 1_n^T\right) \varepsilon \\ &= \frac{1}{\sigma^2} \varepsilon^T U \Lambda U^T \varepsilon \\ &= \eta^T \Lambda \eta \\ &= \sum_{i=1}^{n-1} \eta_i^2 \sim \chi_{(n-1)}^2 \quad (\text{note that } \Lambda = \text{diag}\{\underbrace{1, \dots, 1}_{n-1}, 0\}) \end{aligned}$$

此时我们定义**总均方和** (Total Mean Squares) $\text{MST} = \frac{\text{SST}}{\text{df}_T} = \frac{\text{SST}}{n-1} = \frac{1}{n-1} S_{yy}$, 则我们有:

$$\begin{aligned} \text{SST} &= S_{yy} \stackrel{H_0}{\sim} \sigma^2 \chi_{(n-1)}^2 \\ \text{MST} &= \frac{1}{n-1} S_{yy} \stackrel{H_0}{\sim} \sigma^2 \frac{\chi_{(n-1)}^2}{n-1} \end{aligned}$$

② 回归平方和 (Regression Sum of Squares)

$$\begin{aligned}
 \text{SSR} &= \|\hat{y} - \bar{y}1_n\|_2^2 \\
 &= \|Hy - \frac{1}{n}1_n^T y 1_n\|_2^2 \\
 &= \|(H - \frac{1}{n}1_n 1_n^T)y\|_2^2 \\
 &= y^T (H - \frac{1}{n}1_n 1_n^T)^T (H - \frac{1}{n}1_n 1_n^T) y \quad (\text{note that } H \text{ satisfies } \begin{cases} H^T = H \\ H^2 = H \\ H1_n = 1_n \end{cases}) \\
 &= y^T (H - \frac{1}{n}1_n 1_n^T) y
 \end{aligned}$$

当零假设 $H_0: \beta_1 = \dots = \beta_p = 0$ 成立时, 我们有 $y = X\beta + \varepsilon = \beta_0 1_n + \varepsilon$, 因而有:

$$\begin{aligned}
 \text{SSR} &= y^T (H - \frac{1}{n}1_n 1_n^T) y \\
 &\stackrel{H_0}{=} (\beta_0 1_n + \varepsilon)^T (H - \frac{1}{n}1_n 1_n^T) (\beta_0 1_n + \varepsilon) \quad (\text{note that } H1_n = 1_n \text{ so that } (H - \frac{1}{n}1_n 1_n^T)1_n = 0_n) \\
 &= \varepsilon^T (H - \frac{1}{n}1_n 1_n^T) \varepsilon
 \end{aligned}$$

注意到 $H - \frac{1}{n}1_n 1_n^T$ 对称、幂等且 $\text{tr}(H - \frac{1}{n}1_n 1_n^T) = (p+1) - 1 = p$

因此它存在谱分解, 且有 p 个特征值是 1, $n-p$ 个特征值是 0

我们可设其谱分解为:

$$U^T (I_n - \frac{1}{n}1_n 1_n^T) U = \Lambda = \text{diag}\{\underbrace{1, \dots, 1}_p, \underbrace{0, \dots, 0}_{n-p}\}$$

记 $\eta := \frac{1}{\sigma} U^T \varepsilon$, 根据 $\varepsilon \sim N(0_n, \sigma^2 I_n)$ 可知 $\eta = \frac{1}{\sigma} U^T \varepsilon \sim N(\frac{1}{\sigma} U^T 0_n, \frac{1}{\sigma^2} U^T \sigma^2 I_n U) = N(0_n, I_n)$

这表明 $\eta = [\eta_1, \dots, \eta_n]^T$ 的分量是独立同分布的标准正态随机变量.

于是我们有:

$$\begin{aligned}
 \frac{1}{\sigma^2} \text{SSR} &= \frac{1}{\sigma^2} \|\hat{y} - \bar{y}1_n\|_2^2 \\
 &\stackrel{H_0}{=} \frac{1}{\sigma^2} \varepsilon^T (H - \frac{1}{n}1_n 1_n^T) \varepsilon \\
 &= \frac{1}{\sigma^2} \varepsilon^T U \Lambda U^T \varepsilon \\
 &= \eta^T \Lambda \eta \\
 &= \sum_{i=1}^p \eta_i^2 \sim \chi_{(p)}^2 \quad (\text{note that } \Lambda = \text{diag}\{\underbrace{1, \dots, 1}_p, \underbrace{0, \dots, 0}_{n-p}\})
 \end{aligned}$$

此时我们定义**回归均方和** (Regression Mean Squares) $\text{MSR} = \frac{\text{SSR}}{\text{df}_R} = \frac{\text{SSR}}{p} = \frac{1}{p} \|\hat{y} - \bar{y}1_n\|_2^2$, 则我们有:

$$\begin{aligned}
 \text{SSR} &= \|\hat{y} - \bar{y}1_n\|_2^2 \stackrel{H_0}{\sim} \sigma^2 \chi_{(p)}^2 \\
 \text{MSR} &= \frac{1}{p} \|\hat{y} - \bar{y}1_n\|_2^2 \stackrel{H_0}{\sim} \sigma^2 \frac{\chi_{(p)}^2}{p}
 \end{aligned}$$

③ 误差平方和 (Sum of Squared Errors)

$$\begin{aligned}
 \text{SSE} &= \text{RSS}(\hat{\beta}) \\
 &= \|y - \hat{y}\|_2^2 \\
 &= \|y - Hy\|_2^2 \\
 &= (n-p-1)s^2 \sim \sigma^2 \chi_{(n-p-1)}^2
 \end{aligned}$$

值得注意的是 $SSE \sim \sigma^2 \chi_{(n-p-1)}^2$ 并不依赖于零假设 $H_0: \beta_1 = \dots = \beta_p = 0$ 成立.

可以证明 $SSE = SST - SSR$:

$$\begin{aligned} SSE &= \|y - \hat{y}\|_2^2 \\ &= \|y - Hy\|_2^2 \\ &= y^T (I_n - H)y \\ &= y^T [(I_n - \frac{1}{n} 1_n 1_n^T) - (H - \frac{1}{n} 1_n 1_n^T)]y \\ &= y^T (I_n - \frac{1}{n} 1_n 1_n^T)y - y^T (H - \frac{1}{n} 1_n 1_n^T)y \\ &= SST - SSR \end{aligned}$$

此时我们定义**均方误差** (Mean Square Error) $MSE = \frac{SSE}{df_E} = \frac{SSE}{n-p-1} = \frac{1}{n-p-1} \|y - \hat{y}\|_2^2$, 则我们有:

$$\begin{aligned} SSE &= \|y - \hat{y}\|_2^2 \sim \sigma^2 \chi_{(n-p-1)}^2 \\ MSE &= \frac{1}{n-p-1} \|y - \hat{y}\|_2^2 \sim \sigma^2 \frac{\chi_{(n-p-1)}^2}{n-p-1} \end{aligned}$$

总结如下:

$$\left\{ \begin{array}{l} H_0: \beta_1 = \dots = \beta_p = 0 \\ \hline SST = \|y - \bar{y}1_n\|_2^2 = S_{yy} \stackrel{H_0}{\sim} \sigma^2 \chi_{(n-1)}^2 \quad MST = \frac{SST}{df_T} = \frac{1}{n-1} S_{yy} \stackrel{H_0}{\sim} \sigma^2 \frac{\chi_{(n-1)}^2}{n-1} \\ SSR = \|\hat{y} - \bar{y}1_n\|_2^2 \stackrel{H_0}{\sim} \sigma^2 \chi_{(p)}^2 \quad MSR = \frac{SSR}{df_R} = \frac{1}{p} \|\hat{y} - \bar{y}1_n\|_2^2 \stackrel{H_0}{\sim} \sigma^2 \frac{\chi_{(p)}^2}{p} \\ SSE = \|y - \hat{y}\|_2^2 \sim \sigma^2 \chi_{(n-p-1)}^2 \quad MSE = \frac{SSE}{df_E} = \frac{1}{n-p-1} \|y - \hat{y}\|_2^2 \sim \sigma^2 \frac{\chi_{(n-p-1)}^2}{n-p-1} \\ \left\{ \begin{array}{l} SST = SSR + SSE \\ df_T = df_R + df_E \\ SSR \perp SSE \end{array} \right. \end{array} \right.$$

其中 $SSR \perp SSE$ 可由以下论断得到:

$$\begin{aligned} SSR &= \|\hat{y} - \bar{y}1_n\|_2^2 = \|(H - \frac{1}{n} 1_n 1_n^T)y\|_2^2 \\ SSE &= \|y - \hat{y}\|_2^2 = \|(I_n - H)y\|_2^2 \\ \hline Cov((H - \frac{1}{n} 1_n 1_n^T)y, (I_n - H)y) &= (H - \frac{1}{n} 1_n 1_n^T) \cdot Cov(y) \cdot (I_n - H) \\ &= (H - \frac{1}{n} 1_n 1_n^T) \cdot Cov(\varepsilon) \cdot (I_n - H) \\ &= (H - \frac{1}{n} 1_n 1_n^T) \cdot \sigma^2 I_n \cdot (I_n - H) \\ &= \sigma^2 (H - \frac{1}{n} 1_n 1_n^T - H^2 + \frac{1}{n} 1_n 1_n^T H) \\ &= \sigma^2 (H - \frac{1}{n} 1_n 1_n^T - H + \frac{1}{n} 1_n 1_n^T) \\ &= 0_{n \times n} \end{aligned}$$

由于 $(H - \frac{1}{n} 1_n 1_n^T)y$ 和 $(I_n - H)y$ 联合正态,

故根据 $Cov((H - \frac{1}{n} 1_n 1_n^T)y, (I_n - H)y) = 0_{n \times n}$ 就等价于 $(H - \frac{1}{n} 1_n 1_n^T)y \perp (I_n - H)y$

进而可知 $SSR \perp SSE$

(2) 检验法

考虑第一类型错误概率界限为 α 的检验问题 $H_0: \beta_1 = \dots = \beta_p = 0 \leftrightarrow H_1: \exists i \in \{1, \dots, n\}$ such that $\beta_i \neq 0$
我们使用如下的 F 统计量:

$$F = \frac{\text{MSR}}{\text{MSE}} = \frac{\text{SSR}/p}{\text{SSE}/(n-p-1)} \stackrel{H_0}{\sim} \frac{\sigma^2 \chi_{(p)}^2/p}{\sigma^2 \chi_{(n-p-1)}^2/(n-p-1)} = F_{p, n-p-1}$$

其中分子 MSR 和分母 MSE 是相互独立的 (无论零假设 H_0 是否成立).

记 $F_{p, n-p-1, \alpha}$ 为 $F_{p, n-p-1}$ 分布的 $1 - \alpha$ 分位数.

因此回归方程显著性的 F -检验法为:

- (F -检验法) 若 $F = \frac{\text{MSR}}{\text{MSE}} = \frac{\|\hat{y} - \bar{y} \mathbf{1}_n\|_2^2/p}{\|y - \hat{y}\|_2^2/(n-p-1)} > F_{p, n-p-1, \alpha}$, 则我们拒绝零假设 $H_0: \beta_1 = \dots = \beta_p = 0$

2.3.3 回归系数显著性的 t 检验

(1) 检验法

假设回归方程显著, 即自变量 $(x_1, \dots, x_p)$ 从整体上对随机变量 Y 有显著的解释作用.

我们总想从回归方程中剔除那些没有解释作用的变量, 重新建立更为简单的回归方程.

因此我们需要对每个自变量 x_i 进行显著性检验.

对于某个给定的 $i \in 1, 2, \dots, p$, 考虑第一类型错误概率界限为 α 的检验问题 $H_0: \beta_i = 0 \leftrightarrow H_1: \beta_i \neq 0$

如果 H_0 被推翻, 则说明 x_i 对 Y 有显著解释作用.

根据 $\beta \sim N(\beta, \sigma^2(X^T X)^{-1})$ 可知 $\hat{\beta}_i \sim N(\beta_i, \sigma^2(X^T X)^{-1}_{[i+1, i+1]})$ ($i = 0, \dots, p$)

我们使用如下的 t 统计量:

$$t_i = \frac{\hat{\beta}_i}{s \sqrt{(X^T X)^{-1}_{[i+1, i+1]}}} = \frac{\frac{\hat{\beta}_i}{\sigma \sqrt{(X^T X)^{-1}_{[i+1, i+1]}}}}{\frac{s}{\sigma}} \stackrel{H_0}{\sim} \frac{N(0, 1)}{\sqrt{\chi_{(n-p-1)}^2/(n-p-1)}} = t_{n-p-1}$$

(note that $\hat{\beta}_i \sim N(\beta_i, \sigma^2(X^T X)^{-1}_{[i+1, i+1]}) \stackrel{H_0}{=} N(0, \sigma^2(X^T X)^{-1}_{[i+1, i+1]})$)

其中分子和分母总是相互独立的 (无论零假设是否成立), 这是由 $s^2 \perp \hat{\beta}$ 保证的.

我们记 $t_{n-p-1, \frac{\alpha}{2}}$ 为 t_{n-p-1} 分布的 $1 - \frac{\alpha}{2}$ 分位数.

则 x_i 的回归系数显著性检验的 t -检验法为:

- (t -检验法) 若 $|t_i| = \left| \frac{\hat{\beta}_i}{s \sqrt{(X^T X)^{-1}_{[i+1, i+1]}}} \right| > t_{n-p-1, \frac{\alpha}{2}}$, 则我们拒绝零假设 $H_0: \beta_i = 0$

(2) 推广

考虑第一类型错误概率界限为 α 的检验问题 $H_0: \beta_i = b \leftrightarrow H_1: \beta_i \neq b$ (其中 $b \in \mathbb{R}$ 为给定常数)

我们使用如下的 t 统计量:

$$t_i = \frac{\hat{\beta}_i - b}{s \sqrt{(X^T X)^{-1}_{[i+1, i+1]}}} = \frac{\frac{\hat{\beta}_i - b}{\sigma \sqrt{(X^T X)^{-1}_{[i+1, i+1]}}}}{\frac{s}{\sigma}} \stackrel{H_0}{\sim} \frac{N(0, 1)}{\sqrt{\chi_{(n-p-1)}^2/(n-p-1)}} = t_{n-p-1}$$

(note that $\hat{\beta}_i \sim N(\beta_i, \sigma^2(X^T X)^{-1}_{[i+1, i+1]}) \stackrel{H_0}{=} N(b, \sigma^2(X^T X)^{-1}_{[i+1, i+1]})$)

其中分子和分母总是相互独立的 (无论零假设是否成立), 这是由 $s^2 \perp \hat{\beta}$ 保证的.

我们记 $t_{n-p-1, \frac{\alpha}{2}}$ 为 t_{n-p-1} 分布的 $1 - \frac{\alpha}{2}$ 分位数.

则上述假设检验问题的 t -检验法为:

- (t -检验法) 若 $|t_i| = \left| \frac{\hat{\beta}_i - b}{s \sqrt{(X^T X)^{-1}_{[i+1, i+1]}}} \right| > t_{n-p-1, \frac{\alpha}{2}}$, 则我们拒绝零假设 $H_0: \beta_i = b$

2.3.4 响应的估计

(1) 平均响应

考虑条件正态模型 $y \sim N(X\beta, \sigma^2 I_n)$

在得到了 β, σ^2 的无偏估计量 $\begin{cases} \hat{\beta} = (X^T X)^{-1} X^T y \\ s^2 = \frac{1}{n-p-1} \|y - \hat{y}\|_2^2 = \frac{1}{n-p-1} \|y - X\hat{\beta}\|_2^2 \end{cases}$ 之后,

试验者可能要设置 $x = x_0$ 来得到一个新的观测值 y_0 , 它是随机变量 $Y_0 \sim N(\beta^T x_0, \sigma^2)$ 的一个实现.

平均响应 $\mu = E[Y_0 | x_0] = \beta^T x_0$ 点估计的一个显然的选择就是 $\hat{\mu} = \hat{\beta}^T x_0$, 因为它无偏的.

$$\begin{aligned} E[\hat{\mu}] &= E[\hat{\beta}^T x_0] \\ &= E[\hat{\beta}]^T x_0 \\ &= \beta^T x_0 \\ \hline \text{Var}[\hat{\mu}] &= \text{Var}[\hat{\beta}^T x_0] \\ &= x_0^T \text{Var}[\hat{\beta}] x_0 \\ &= x_0^T \cdot \sigma^2 (X^T X)^{-1} \cdot x_0 \\ &= \sigma^2 x_0^T (X^T X)^{-1} x_0 \end{aligned}$$

由于 $\hat{\beta}$ 多元正态, 故 $\hat{\mu} = \hat{\beta}^T x_0$ 也服从正态分布:

$$\hat{\mu} = \hat{\beta}^T x_0 \sim N(\beta^T x_0, \sigma^2 x_0^T (X^T X)^{-1} x_0)$$

由于 s^2 与 $\hat{\beta}$ 独立, 故 s^2 也与 $\hat{\mu} = \hat{\beta}^T x_0$ 独立, 因此我们有:

$$\frac{\hat{\beta}^T x_0 - \beta^T x_0}{s \sqrt{x_0^T (X^T X)^{-1} x_0}} = \frac{\frac{\hat{\beta}^T x_0 - \beta^T x_0}{\sigma \sqrt{x_0^T (X^T X)^{-1} x_0}}}{\frac{s}{\sigma}} \sim \frac{N(0, 1)}{\sqrt{\chi_{(n-p-1)}^2 / (n-p-1)}} = t_{n-p-1}$$

根据这个枢轴量便可得到平均响应 $\mu = \beta^T x_0$ 的 $(1 - \alpha)$ 置信区间:

$$\mu = \beta^T x_0 \in [\hat{\beta}^T x_0 \pm s \sqrt{x_0^T (X^T X)^{-1} x_0} \cdot t_{n-p-1, \frac{\alpha}{2}}] \text{ where } \begin{cases} \hat{\beta} = (X^T X)^{-1} X^T y \\ s^2 = \frac{1}{n-p-1} \|y - \hat{y}\|_2^2 = \frac{1}{n-p-1} \|y - X\hat{\beta}\|_2^2 \end{cases}$$

其中 $t_{n-p-1, \frac{\alpha}{2}}$ 为 t_{n-p-1} 分布的 $1 - \frac{\alpha}{2}$ 分位数.

(2) 个体响应

现在我们考虑个体响应 $Y_0 \sim N(\beta^T x_0, \sigma^2)$ 的估计.

- (预测区间)

未观测随机变量 Y 的一个基于样本 X 的 $(1 - \alpha)$ 预测区间是一个随机区间 $[L(X), U(X)]$, 满足:

$$P_{\theta}\{L(X) \leq Y \leq U(X)\} \geq 1 - \alpha \quad (\forall \theta \in \Theta)$$

预测区间的定义与置信区间是相似的，区别在于预测区间是针对随机变量的，而不是针对参数的。
直观上，由于随机变量与参数(常数)相比具有变异性，故预测区间会比相同水平的置信区间更宽。

由于估计量 $\hat{\beta}$, s^2 是根据以前的数据计算出来的，故 Y_0 与 $\hat{\beta}$, s^2 独立。

$$\begin{aligned} & \begin{cases} Y_0 \sim N(\beta^T x_0, \sigma^2) \\ \hat{\beta}^T x_0 \sim N(\beta^T x_0, \sigma^2 x_0^T (X^T X)^{-1} x_0) \end{cases} \\ & \Rightarrow \\ & Y_0 - \hat{\beta}^T x_0 \sim N(\beta^T x_0 - \beta^T x_0, \sigma^2 + \sigma^2 x_0^T (X^T X)^{-1} x_0) \\ & = N(0, \sigma^2(1 + x_0^T (X^T X)^{-1} x_0)) \end{aligned}$$

利用 s^2 与 $Y_0 - \hat{\beta}^T x_0$ 的独立性，我们有：

$$\frac{Y_0 - \hat{\beta}^T x_0}{s \sqrt{1 + x_0^T (X^T X)^{-1} x_0}} = \frac{\frac{Y_0 - \hat{\beta}^T x_0}{\sigma \sqrt{1 + x_0^T (X^T X)^{-1} x_0}}}{\frac{s}{\sigma}} \sim \frac{N(0, 1)}{\sqrt{\frac{1}{n-p-1} \chi_{(n-p-1)}^2}} = t_{n-p-1}$$

于是我们得到个体响应 $Y_0 \sim N(\beta^T x_0, \sigma^2)$ 的 $(1 - \alpha)$ 预测区间：

$$Y_0 \in \left[\hat{\beta}^T x_0 \pm s \sqrt{1 + x_0^T (X^T X)^{-1} x_0} \cdot t_{n-p-1, \frac{\alpha}{2}} \right] \text{ where } \begin{cases} \hat{\beta} = (X^T X)^{-1} X^T y \\ s^2 = \frac{1}{n-p-1} \|y - \hat{y}\|_2^2 = \frac{1}{n-p-1} \|y - X\hat{\beta}\|_2^2 \end{cases}$$

其中 $t_{n-p-1, \frac{\alpha}{2}}$ 为 t_{n-p-1} 分布的 $1 - \frac{\alpha}{2}$ 分位数。

(3) 同时估计

在 2.3.4(1) 中我们已经看到，与 x_0 相联系的总体 $Y_0 \sim N(\beta^T x_0, \sigma^2)$ 的均值，
即平均响应 $\mu = E[Y|x_0] = \beta^T x_0$ 的 $(1 - \alpha)$ 置信区间为：

$$\mu = \beta^T x_0 \in \left[\hat{\beta}^T x_0 \pm s \sqrt{x_0^T (X^T X)^{-1} x_0} \cdot t_{n-p-1, \frac{\alpha}{2}} \right] \text{ where } \begin{cases} \hat{\beta} = (X^T X)^{-1} X^T y \\ s^2 = \frac{1}{n-p-1} \|y - \hat{y}\|_2^2 = \frac{1}{n-p-1} \|y - X\hat{\beta}\|_2^2 \end{cases}$$

现假定我们要在若干点处对于 Y 总体的均值进行推断。

具体来说，我们要求包含 $\mu_i = E[Y|x_0^{(i)}] = \beta^T x_0^{(i)}$ ($i = 1, \dots, m$) 的区间。

如果按上面的方法分别给出 μ_i ($i = 1, \dots, m$) 的 $(1 - \alpha)$ 置信区间，

那么合并得到的区间的置信水平将不是 $1 - \alpha$

一个简单且有用的处理方式是应用 Bonferroni 不等式。

当事件交的概率难以(甚至无法)计算，而我们只需知道其大致范围时，Bonferroni 不等式非常有用：

(Bonferroni 不等式, Statistical Inference 例 1.2.10)

设 A, B 是两个事件，则我们有 $P(A \cap B) \geq P(A) + P(B) - 1$

注意：若 A, B 发生概率不够大，则 Bonferroni 下界可能是一个毫无用处(尽管仍然正确)的负数。

由 Bonferroni 不等式可知，我们有：

$$\begin{aligned} & P \left\{ \beta^T x_0^{(i)} \in \left[\hat{\beta}^T x_0^{(i)} \pm s \sqrt{(x_0^{(i)})^T (X^T X)^{-1} x_0^{(i)}} \cdot t_{n-p-1, \frac{\alpha}{2m}} \right] \text{ for all } i = 1, \dots, m \right\} \\ & \geq \sum_{i=1}^m P \left\{ \beta^T x_0^{(i)} \in \left[\hat{\beta}^T x_0^{(i)} \pm s \sqrt{(x_0^{(i)})^T (X^T X)^{-1} x_0^{(i)}} \cdot t_{n-p-1, \frac{\alpha}{2m}} \right] \right\} - (m - 1) \\ & = m \cdot \left(1 - \frac{\alpha}{m} \right) - (m - 1) \\ & = 1 - \alpha \end{aligned}$$

也就是说, 我们至少以概率 $1 - \alpha$ 有事件 $\beta^T x_0^{(i)} \in [\hat{\beta}^T x_0^{(i)} \pm s \sqrt{(x_0^{(i)})^T (X^T X)^{-1} x_0^{(i)}} \cdot t_{n-p-1, \frac{\alpha}{2m}}]$ ($i = 1, \dots, m$) 同时成立.

(结合 2.3.4(2) 的内容, 我们可以通过类似的方法给出 $Y_0^{(i)} \sim N(\beta^T x_0^{(i)}, \sigma^2)$ ($i = 1, \dots, m$) 的同时预测区间)

我们还可进一步对所有 x 进行同时推断.

(Scheffe 置信区域)

在条件正态模型 $(Y|x) \sim N(\beta^T x, \sigma^2)$ 下, 我们至少以概率 $1 - \alpha$ 对所有 x 同时成立:

$$E[Y|x] = \beta^T x \in \left[\hat{\beta}^T x \pm s \sqrt{x^T (X^T X)^{-1} x} \cdot M_\alpha \right] \text{ where } M_\alpha = \sqrt{(p+1) F_{p+1, n-p-1, \alpha}}$$


• 注解:

由于上式至少以概率 $1 - \alpha$ 对所有 x 成立

故它给出的是整个总体回归超平面 $E[Y|x] = \beta^T x$ 的一个 $(1 - \alpha)$ 置信带 (称为 **Scheffe 带**).

就像一个置信区间覆盖一个参数一样, 这个置信区域覆盖了整个总体回归超平面.

下图给出了一个简单线性回归 Scheffe 带的例子, 同时给出了两个 Bonferroni 区间和一个 t 区间:



实际上 Bonferroni 区间有可能比 Scheffe 带更宽 (尽管图中没有给出这样的例子)

因此即使只对少数几个 x 感兴趣, 我们仍更倾向于选择 Scheffe 带而不是 Bonferroni 区间.

这是由于 Bonferroni 区间是通用的界 (而且实际覆盖率要比 $1 - \alpha$ 高), 而 Scheffe 带是问题的精确解.

此外, 理论上我们可以用类似方法得到针对所有 x 的**同时预测区间**, 但导出的统计量没有特别好的分布.

• 证明:

上述问题等价于寻找一个常数 M_α 使得:

$$P \left\{ \frac{(\hat{\beta}^T x - \beta^T x)^2}{s^2 \cdot x^T (X^T X)^{-1} x} \leq M_\alpha^2 \text{ for all } x \right\} = 1 - \alpha$$

即等价于使得:

$$P \left\{ \max_x \frac{(\hat{\beta}^T x - \beta^T x)^2}{s^2 \cdot x^T (X^T X)^{-1} x} \leq M_\alpha^2 \right\} = 1 - \alpha$$

Lemma: (广义 Rayleigh 商)

若 $b \in \mathbb{R}^n$ 为给定向量且 $A \in \mathbb{R}^{n \times n}$ 正定, 则 $\max_{x \neq 0, n \in \mathbb{R}^n} \frac{(b^T x)^2}{x^T A x} = b^T A^{-1} b$

证明:

$$\begin{aligned} \max_{x \neq 0, n \in \mathbb{R}^n} \frac{(b^T x)^2}{x^T A x} &= \max_{y \neq 0, n \in \mathbb{R}^n} \frac{(b^T A^{-\frac{1}{2}} y)^2}{y^T y} \quad (y = A^{\frac{1}{2}} x) \\ &= \max_{y \neq 0, n \in \mathbb{R}^n} \frac{y^T (A^{-\frac{1}{2}} b b^T A^{-\frac{1}{2}}) y}{y^T y} \quad (\text{Rayleigh theorem}) \\ &= \lambda_{\max}(A^{-\frac{1}{2}} b b^T A^{-\frac{1}{2}}) \quad (\text{note that } A \text{ is positive definite, hence symmetric}) \\ &= \lambda_{\max}\{(A^{-\frac{1}{2}} b)(A^{-\frac{1}{2}} b)^T\} \quad (\text{note that rank-one matrix } z z^T \text{'s only non-zero eigenvalue is } \|z\|_2^2) \\ &= \|A^{-\frac{1}{2}} b\|_2^2 \\ &= b^T A^{-1} b \end{aligned}$$

其中最大值可以在 $x = \alpha A^{-1} b$ ($\forall \alpha \neq 0 \in \mathbb{R}$) 取到.

注意到多元线性回归中的向量 x 的第一个分量总是 1, 因此它一定不会是零向量.

实际上其取值集合是 $x \in \{1\} \times \mathbb{R}^p$

但我们发现目标函数在 $x \in \{1\} \times \mathbb{R}^p$ 上优化和在 $x \neq 0_{p+1} \in \mathbb{R}^{p+1}$ 上优化是等价的.

$$\begin{aligned} \max_{x \neq 0_{p+1} \in \mathbb{R}^{p+1}} \frac{(\hat{\beta}^T x - \beta^T x)^2}{s^2 \cdot x^T (X^T X)^{-1} x} &= \frac{1}{s^2} \max_{x \neq 0_{p+1} \in \mathbb{R}^{p+1}} \frac{[(\hat{\beta} - \beta)^T x]^2}{x^T (X^T X)^{-1} x} \\ &= \frac{1}{s^2} \cdot (\hat{\beta} - \beta)^T [(X^T X)^{-1}]^{-1} (\hat{\beta} - \beta) \\ &= \frac{1}{s^2} (\hat{\beta} - \beta)^T (X^T X) (\hat{\beta} - \beta) \\ &= \frac{[\frac{1}{\sigma} (X^T X)^{\frac{1}{2}} (\hat{\beta} - \beta)]^T [\frac{1}{\sigma} (X^T X)^{\frac{1}{2}} (\hat{\beta} - \beta)]}{s^2 / \sigma^2} \\ &\quad (\text{note that } \begin{cases} \frac{1}{\sigma} (X^T X)^{\frac{1}{2}} (\hat{\beta} - \beta) \sim N(0_{p+1}, I_{p+1}) \\ (n-p-1)s^2 \sim \sigma^2 \chi_{(n-p-1)}^2 \end{cases} \text{ and they are independent}) \\ &\sim \frac{\chi_{(p+1)}^2}{\chi_{(n-p-1)}^2 / (n-p-1)} \\ &= (p+1) \frac{\chi_{(p+1)}^2 / (p+1)}{\chi_{(n-p-1)}^2 / (n-p-1)} \\ &= (p+1) F_{p+1, n-p-1} \end{aligned}$$

因此 $M_\alpha^2 = (p+1) F_{p+1, n-p-1, \alpha}$, 即 $M_\alpha = \sqrt{(p+1) F_{p+1, n-p-1, \alpha}}$
命题得证.

2.3.5 线性约束检验

对于多元线性回归模型中的解释变量,

我们可能会推测它们之间存在某种线性的先验关系 (即其回归系数具有某种线性依赖关系)

例如把 $(x_1 - x_2)$ 作为解释变量会比单独使用 x_1, x_2 的解释作用更好.

这个例子可翻译为零假设 $H_0: \beta_1 + \beta_2 = 0$

如果 H_0 成立, 则原模型 $Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$ 可约简为 $Y = \gamma_0 + \gamma_1 (x_1 - x_2) + \varepsilon$

其中 $\begin{cases} \gamma_0 = \beta_0 \\ \gamma_1 = \beta_1 = -\beta_2 \end{cases}$

也就是说, 我们把解释变量 x_1, x_2 替换为线性组合 $x_1 - x_2$, 会有更好的解释效果.

对于一般的线性约束检验，零假设为 $H_0: C\beta = h$

其中 $\begin{cases} C \in \mathbb{R}^{m \times (p+1)} & (m < p+1) \\ h \in \mathbb{R}^m \\ \beta = [\beta_0, \beta_1, \dots, \beta_p]^T \in \mathbb{R}^{p+1} \end{cases}$ (我们假设 C 是行满秩的, 即 $\text{rank}(C) = m$)

我们将使用 $F = \frac{(\text{SSE}_{\text{reduced}} - \text{SSE}_{\text{full}})/m}{\text{SSE}_{\text{full}}/(n-p-1)} \stackrel{H_0}{\sim} F_{m, n-p-1}$ 作为检验统计量

其中 $\text{SSE}_{\text{full}}, \text{SSE}_{\text{reduced}}$ 分别是**全模型** (full model) 和**简约模型** (reduces model) 的误差平方和我们随后会明确这些概念的定义。

(1) 基本记号

我们最初定义的多元线性回归模型 $y = X\beta + \varepsilon$ (其中 $\varepsilon \sim N(0_n, \sigma^2 I_n)$) 便称为**全模型** (full model)

其中 $\beta \in \mathbb{R}^{p+1}$ 的各个分量之间是独立的。

于是 β 的估计量就可通过求解无约束最小二乘问题 $\min_{\beta \in \mathbb{R}^{p+1}} \|y - X\beta\|_2^2$ 得到, 记为 $\hat{\beta}_{\text{full}} = (X^T X)^{-1} X^T y$

我们在 2.2 节已经对其有过深入的研究, 现复述结论如下:

- 全模型回归系数估计量 $\hat{\beta}_{\text{full}} = (X^T X)^{-1} X^T y \sim N(\beta, \sigma^2 (X^T X)^{-1})$
- 全模型误差平方和 $\text{SSE}_{\text{full}} = \|y - X\hat{\beta}_{\text{full}}\|_2^2 = \varepsilon^T (I_n - H) \varepsilon \sim \sigma^2 \chi_{(n-p-1)}^2$
其中投影矩阵 $H = X(X^T X)^{-1} X^T \in \mathbb{R}^{n \times n}$

现在我们假设 $\beta \in \mathbb{R}^{p+1}$ 的各个分量之间存在线性依赖关系 $C\beta = h$

其中 $C \in \mathbb{R}^{m \times (p+1)}$ 是行满秩矩阵, $h \in \mathbb{R}^m$ 为给定向量。

那么我们可以视 β 的前 $p+1-m$ 个分量是独立的, 而后 m 个分量线性依赖于前 $p+1-m$ 个分量。

这样我们可以将 β 分为两个部分: $\beta^{(1)} \in \mathbb{R}^{p+1-m}$ 和 $\beta^{(2)} \in \mathbb{R}^m$

并假设 $\beta^{(2)} = A\beta^{(1)} + b$ (其中 $A \in \mathbb{R}^{m \times (p+1-m)}$ 和 $b \in \mathbb{R}^m$ 是依赖于 C, h 的)

对应地我们也可以将 $X \in \mathbb{R}^{n \times (p+1)}$ 分块为 $X^{(1)} \in \mathbb{R}^{n \times (p+1-m)}$ 和 $X^{(2)} \in \mathbb{R}^{n \times m}$

于是我们有:

$$\begin{aligned} y &= X\beta + \varepsilon \\ &= [X^{(1)}, X^{(2)}] \begin{bmatrix} \beta^{(1)} \\ \beta^{(2)} \end{bmatrix} + \varepsilon \\ &= [X^{(1)}, X^{(2)}] \begin{bmatrix} \beta^{(1)} \\ A\beta^{(1)} + b \end{bmatrix} + \varepsilon \\ &= [X^{(1)}, X^{(2)}] \begin{bmatrix} 0_{p+1-m} \\ b \end{bmatrix} + [X^{(1)}, X^{(2)}] \begin{bmatrix} I_{p+1-m} \\ A \end{bmatrix} \beta^{(1)} + \varepsilon \\ &= X^{(2)}b + (X^{(1)} + X^{(2)}A)\beta^{(1)} + \varepsilon \end{aligned}$$

若我们记 $\begin{cases} \tilde{y} = y - X^{(2)}b \in \mathbb{R}^n \\ Z = X^{(1)} + X^{(2)}A \in \mathbb{R}^{n \times (p+1-m)} \\ \gamma = \beta^{(1)} \in \mathbb{R}^{p+1-m} \end{cases}$

则我们就得到了一个新的多元线性回归模型 $\tilde{y} = Z\gamma + \varepsilon$ (其中 $\varepsilon \sim N(0_n, \sigma^2 I_n)$), 称为**简约模型** (reduced model)

其中它的解释变量 $z_1, \dots, z_{p-m}$ 是全模型解释变量 $x_1, \dots, x_{p-m}, \dots, x_p$ 的线性组合,

相应地, 其设计矩阵 $Z \in \mathbb{R}^{n \times (p+1-m)}$ 的列向量也是全模型设计矩阵 $X \in \mathbb{R}^{n \times (p+1)}$ 的线性组合。

其回归系数 $\gamma \in \mathbb{R}^{p+1-m}$ 的各个分量相互独立。

实际应用时, 我们并不显式地将全模型 $y = X\beta + \varepsilon$ 化为简约模型 $\tilde{y} = Z\gamma + \varepsilon$

(这样计算繁琐且没有必要, 不过邵美悦老师在数值算法课程中引入了这一 "消元" 的做法)

而是接受 " $\beta \in \mathbb{R}^{p+1}$ 的各个分量不完全独立" 这个事实,

通过求解线性约束最小二乘问题 $\min_{C\beta=h} \|y - X\beta\|_2^2$ 来得到简约模型下的 β 的估计量 $\hat{\beta}_{\text{reduced}}$

并研究简约模型误差平方和 $\text{SSE}_{\text{reduced}} = \|y - X\hat{\beta}_{\text{reduced}}\|_2^2$ 的分布

(值得注意的是, 由于求解时增添了约束条件 $C\beta = h$, 故 $\text{SSE}_{\text{reduced}}$ 一定是大于 SSE_{full} 的)

特例: (用 e_i 表示 $\mathbb{R}^{p+1}$ 的第 i 个标准正交基向量)

- $H_0 : \beta_1 = 0$ 等价于 $H_0 : e_2^T \beta = 0$
- $H_0 : \beta_1 = \beta_2 = 0$ 等价于 $H_0 : \begin{bmatrix} e_2^T \\ e_3^T \end{bmatrix} \beta = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$

(2) 简约模型的求解

考虑求解线性约束最小二乘问题 $\min_{C\beta=h} \|y - X\beta\|_2^2$

注意到目标函数 $f(\beta) = \|y - X\beta\|_2^2$ 是关于 β 的凸函数, 而问题只有线性等式约束 $C\beta = h$ 因此这是一个标准形式的凸优化问题, 其最优解即为 KKT 点.

定义其 Lagrange 函数 $L(\beta, \lambda)$ 为:

$$\begin{aligned} L(\beta, \lambda) &= f(\beta) - \lambda^T (C\beta - h) \\ &= \|y - X\beta\|_2^2 - \lambda^T (C\beta - h) \end{aligned}$$

$$\text{dom}\{L\} = \mathbb{R}^{p+1} \times \mathbb{R}^m$$

Lagrange 函数 $L(\beta, \lambda)$ 关于 β 的梯度为:

$$\begin{aligned} \nabla_{\beta} L(\beta, \lambda) &= \nabla_{\beta} \{ \|y - X\beta\|_2^2 - \lambda^T (C\beta - h) \} \\ &= -X^T \cdot 2(y - X\beta) - (\lambda^T C)^T \\ &= -2X^T y + 2X^T X\beta - C^T \lambda \end{aligned}$$

KKT 条件为:

$$\begin{cases} \nabla_{\beta} L(\beta, \lambda) = -2X^T y + 2X^T X\beta - C^T \lambda = 0_{p+1} & \text{①} \\ C\beta = h & \text{②} \end{cases}$$

① 式左乘 $(X^T X)^{-1}$ 可得 $-2(X^T X)^{-1} X^T y + 2\beta - (X^T X)^{-1} C^T \lambda = 0_{p+1}$

于是有 $\beta = (X^T X)^{-1} X^T y + \frac{1}{2} (X^T X)^{-1} C^T \lambda$

代入 ② 式即得 $C\beta = C(X^T X)^{-1} X^T y + \frac{1}{2} C(X^T X)^{-1} C^T \lambda = h$

解得 $\lambda_{\text{KKT}} = 2[C(X^T X)^{-1} C^T]^{-1} [h - C(X^T X)^{-1} X^T y]$

因此我们有:

$$\begin{aligned} \hat{\beta}_{\text{reduced}} &= \beta_{\text{KKT}} \\ &= (X^T X)^{-1} X^T y + \frac{1}{2} (X^T X)^{-1} C^T \lambda_{\text{KKT}} \\ &= (X^T X)^{-1} X^T y + \frac{1}{2} (X^T X)^{-1} C^T \cdot 2[C(X^T X)^{-1} C^T]^{-1} [h - C(X^T X)^{-1} X^T y] \\ &= \hat{\beta}_{\text{full}} - (X^T X)^{-1} C^T [C(X^T X)^{-1} C^T]^{-1} (C\hat{\beta}_{\text{full}} - h) \end{aligned}$$

其中 $\hat{\beta}_{\text{full}} = (X^T X)^{-1} X^T y$.

下面我们计算简约模型误差平方和 $\text{SSE}_{\text{reduced}} = \|y - X\hat{\beta}_{\text{reduced}}\|_2^2$

$$\begin{aligned} \text{SSE}_{\text{reduced}} &= \|y - X\hat{\beta}_{\text{reduced}}\|_2^2 \\ &= \|y - X(\hat{\beta}_{\text{full}} - (X^T X)^{-1} C^T [C(X^T X)^{-1} C^T]^{-1} (C\hat{\beta}_{\text{full}} - h))\|_2^2 \\ &= \|y - X\hat{\beta}_{\text{full}} + X(X^T X)^{-1} C^T [C(X^T X)^{-1} C^T]^{-1} (C\hat{\beta}_{\text{full}} - h)\|_2^2 \\ &= \|y - X\hat{\beta}_{\text{full}} + A(C\hat{\beta}_{\text{full}} - h)\|_2^2 \quad (\text{denote } A := X(X^T X)^{-1} C^T [C(X^T X)^{-1} C^T]^{-1}) \\ &= \|y - X\hat{\beta}_{\text{full}}\|_2^2 - 2(y - X\hat{\beta}_{\text{full}})^T A(C\hat{\beta}_{\text{full}} - h) + \|A(C\hat{\beta}_{\text{full}} - h)\|_2^2 \end{aligned}$$

其中 $A := X(X^T X)^{-1} C^T [C(X^T X)^{-1} C^T]^{-1} \in \mathbb{R}^{n \times m}$.

考虑交叉项 $(y - X\hat{\beta}_{\text{full}})^T A(C\hat{\beta}_{\text{full}} - h)$:

$$\begin{aligned} & (y - X\hat{\beta}_{\text{full}})^T A(C\hat{\beta}_{\text{full}} - h) \\ &= (y - Hy)^T A(C\hat{\beta}_{\text{full}} - h) \quad (\text{recall that } X\hat{\beta}_{\text{full}} = Hy \text{ where } H = X(X^T X)^{-1} X^T y) \\ &= y^T (I_n - H) X (X^T X)^{-1} C^T [C(X^T X)^{-1} C^T]^{-1} (C\hat{\beta}_{\text{full}} - h) \quad (\text{note that } HX = X \text{ so that } (I_n - H)X = 0_{n \times (p+1)}) \\ &= y^T 0_{n \times (p+1)} (X^T X)^{-1} C^T [C(X^T X)^{-1} C^T]^{-1} (C\hat{\beta}_{\text{full}} - h) \\ &= 0 \end{aligned}$$

因此我们有:

$$\begin{aligned} \text{SSE}_{\text{reduced}} &= \|y - X\hat{\beta}_{\text{full}}\|_2^2 - 2(y - X\hat{\beta}_{\text{full}})^T A(C\hat{\beta}_{\text{full}} - h) + \|A(C\hat{\beta}_{\text{full}} - h)\|_2^2 \\ &= \text{SSE}_{\text{full}} - 2 \cdot 0 + \|A(C\hat{\beta}_{\text{full}} - h)\|_2^2 \\ &= \text{SSE}_{\text{full}} + \|A(C\hat{\beta}_{\text{full}} - h)\|_2^2 \end{aligned}$$

我们定义**额外误差平方和** (extra sum of squares, ESS) 为从全模型到简约模型增加的误差平方和:

$$\text{ESS} = \text{SSE}_{\text{reduced}} - \text{SSE}_{\text{full}} = \|A(C\hat{\beta}_{\text{full}} - h)\|_2^2$$

其中 $\begin{cases} A = X(X^T X)^{-1} C^T [C(X^T X)^{-1} C^T]^{-1} \\ \hat{\beta}_{\text{full}} = (X^T X)^{-1} X^T y \end{cases}$

(3) 检验法

考虑第一类错误概率界限为 α 的检验问题 $H_0 : C\beta = h \leftrightarrow H_1 : C\beta \neq h$

下面我们研究**额外误差平方和** $\text{ESS} = \text{SSE}_{\text{reduced}} - \text{SSE}_{\text{full}} = \|A(C\hat{\beta}_{\text{full}} - h)\|_2^2$ 在零假设 $H_0 : C\beta = h$ 下的分布.

$$\begin{aligned} \text{ESS} &= \text{SSE}_{\text{reduced}} - \text{SSE}_{\text{full}} \\ &= \|A(C\hat{\beta}_{\text{full}} - h)\|_2^2 \\ &= (C\hat{\beta}_{\text{full}} - h)^T A^T A (C\hat{\beta}_{\text{full}} - h) \quad (\text{recall that } A = X(X^T X)^{-1} C^T [C(X^T X)^{-1} C^T]^{-1}) \\ &= (C\hat{\beta}_{\text{full}} - h)^T \{X(X^T X)^{-1} C^T [C(X^T X)^{-1} C^T]^{-1}\}^T \{X(X^T X)^{-1} C^T [C(X^T X)^{-1} C^T]^{-1}\} (C\hat{\beta}_{\text{full}} - h) \\ &= (C\hat{\beta}_{\text{full}} - h)^T \{[C(X^T X)^{-1} C^T]^{-1} C(X^T X)^{-1} X^T\} \cdot \{X(X^T X)^{-1} C^T [C(X^T X)^{-1} C^T]^{-1}\} (C\hat{\beta}_{\text{full}} - h) \\ &= (C\hat{\beta}_{\text{full}} - h)^T [C(X^T X)^{-1} C^T]^{-1} (C\hat{\beta}_{\text{full}} - h) \\ &= \eta^T \eta \quad (\text{denote } \eta = [C(X^T X)^{-1} C^T]^{-\frac{1}{2}} (C\hat{\beta}_{\text{full}} - h)) \end{aligned}$$

注意到 $\hat{\beta}_{\text{full}} = (X^T X)^{-1} X^T y \sim N(\beta, \sigma^2 (X^T X)^{-1})$

于是我们有:

$$\begin{aligned} C\hat{\beta}_{\text{full}} - h &\sim N(C\beta - h, \sigma^2 C(X^T X)^{-1} C^T) \\ &\stackrel{H_0}{=} N(0_m, \sigma^2 C(X^T X)^{-1} C^T) \quad (\text{where } H_0 : C\beta = h) \end{aligned}$$

因此我们有:

$$\begin{aligned} \eta &= [C(X^T X)^{-1} C^T]^{-\frac{1}{2}} (C\hat{\beta}_{\text{full}} - h) \\ &\stackrel{H_0}{\sim} N([C(X^T X)^{-1} C^T]^{-\frac{1}{2}} \cdot 0_m, [C(X^T X)^{-1} C^T]^{-\frac{1}{2}} \sigma^2 C(X^T X)^{-1} C^T \{[C(X^T X)^{-1} C^T]^{-\frac{1}{2}}\}^T) \quad (\text{where } H_0 : C\beta = h) \\ &= N(0_m, \sigma^2 I_m) \end{aligned}$$

于是我们有 $\text{ESS} = \eta^T \eta \stackrel{H_0}{\sim} \sigma^2 \chi_{(m)}^2$

现在我们可以构造线性约束检验问题 $H_0 : C\beta = h \leftrightarrow H_1 : C\beta \neq h$ 的检验统计量了:

$$\begin{aligned}
F &:= \frac{(\text{SSE}_{\text{reduced}} - \text{SSE}_{\text{full}})/m}{\text{SSE}_{\text{full}}/n - p - 1} \\
&= \frac{\text{ESS}/m}{\text{SSE}_{\text{full}}/n - p - 1} \\
&\quad (\text{note that } \begin{cases} \text{ESS} \stackrel{H_0}{\sim} \sigma^2 \chi_{(m)}^2 \\ \text{SSE}_{\text{full}} \sim \sigma^2 \chi_{(n-p-1)}^2 \end{cases} \text{ where } H_0 : C\beta = h) \\
&\stackrel{H_0}{\sim} \frac{\sigma^2 \chi_{(m)}^2/m}{\sigma^2 \chi_{(n-p-1)}^2/(n-p-1)} \\
&= F_{m, n-p-1}
\end{aligned}$$

其中分子 $\frac{1}{m} \text{ESS} = \frac{1}{m} \|A(C\hat{\beta}_{\text{full}} - h)\|_2^2$ 与分母 $s_{\text{full}}^2 = \frac{1}{n-p-1} \|y - X\hat{\beta}_{\text{full}}\|_2^2$ 的独立性由 $\hat{\beta}_{\text{full}} \perp s_{\text{full}}^2$ 保证。
(其中 s_{full}^2 记为全模型中根据 σ^2 的极大似然估计量构造出的无偏估计量)

我们记 $F_{m, n-p-1, \alpha}$ 为 $F_{m, n-p-1}$ 分布的 $1 - \alpha$ 分位数。

则线性约束 $C\beta = h$ 的显著性检验的 F -检验法为:

- (F -检验法)

$$\text{若 } F = \frac{\text{ESS}/m}{\text{SSE}_{\text{full}}/n - p - 1} = \frac{\|A(C\hat{\beta}_{\text{full}} - h)\|_2^2/m}{\|y - X\hat{\beta}_{\text{full}}\|_2^2/(n-p-1)} > F_{m, n-p-1, \alpha}$$

则我们拒绝零假设 $H_0 : C\beta = h$, 即我们认为线性先验关系 $C\beta = h$ 不成立。

$$\text{其中 } \begin{cases} A = X(X^T X)^{-1} C^T [C(X^T X)^{-1} C^T]^{-1} \\ \hat{\beta}_{\text{full}} = (X^T X)^{-1} X^T y \end{cases}$$

2.4 模型选择

"Finding a good model involves trading off fit and complexity."

(选取一个好的模型涉及到拟合度和复杂度之间的权衡)

考虑正态假设下的多元线性回归模型 $y \sim N(X\beta, \sigma^2 I_n)$

下面我们简要说明一下为什么模型的解释变量不是越多越好。

- 一方面, 根据最小二乘估计量 $\hat{\beta} = (X^T X)^{-1} X^T y$ 的几何解释 (即 $\hat{y} = X\hat{\beta}$ 是 y 在 $\text{span}\{X\}$ 上的投影) 可知: 随着解释变量的数量 p 不断增大, 设计矩阵 $X \in \mathbb{R}^{n \times (p+1)}$ 的列向量组张成的空间 $\text{span}\{X\}$ 势必会不断增大, 这会导致 y 在 $\text{span}\{X\}$ 上的投影 $\hat{y} = X\hat{\beta} = Hy$ 越来越接近 y , 也就是说, 只要向模型中不断加入新的解释变量, 不管它们是否有或有多大的解释作用, 最终都倾向于使误差平方和 $\text{SSE} = \|y - \hat{y}\|_2^2$ 变小, 表现为模型针对样本的拟合程度变好。

可以预见, 当解释变量的数量 $p \geq n - 1$ (其中 n 为样本容量) 时,

回归参数 $\beta_0, \beta_1, \dots, \beta_p$ 的自由度 $p + 1$ 便大于等于样本容量 n

此时这些参数总可以找到合适的值 $\hat{\beta}_{\text{best}}$ 使得 $y = X\hat{\beta}_{\text{best}}$ (即拟合曲线 $y = \hat{\beta}_{\text{best}}^T x$ 经过所有 n 个样本点)

这相当于把随机噪音完全拟合进去了, 因此这样的模型对随机噪音的耐受能力非常弱。

一旦该样本进行重采样 (随机噪音发生变动), 模型的参数便会发生很大的波动。

- 另一方面, 根据 $\text{tr}(\text{Cov}(\hat{\beta})) = \sigma^2 \text{tr}\{(X^T X)^{-1}\}$ 可知: 最小二乘估计量 $\hat{\beta}$ 分量方差之和 $\text{tr}(\text{Cov}(\hat{\beta}))$ 与 $\text{tr}\{(X^T X)^{-1}\}$ 正相关。如果我们向模型中不断加入新的解释变量, 那么它们的依赖关系 (又称多重共线性) 势必会增强, 这可能会导致 X 列满秩的假设越来越 "弱", 使得 $X^T X$ 越来越接近奇异, 进而使 $(X^T X)^{-1}$ 的对角元 "膨胀" 结果必然是最小二乘估计量 $\hat{\beta}$ 的分量方差之和 $\text{tr}(\text{Cov}(\hat{\beta}))$ 越来越大, 表明波动性越来越强。一旦该样本进行重采样, 模型的参数便会发生很大的波动, 从而影响模型的稳定性和可靠性。

综上所述, 模型的解释变量不是越多越好。

我们需要把解释变量的数量 p (它表征模型复杂度) 降下来, 把真正有用的解释变量留下。

一般有两类模型选择的方法:

- 一种是**所有子集回归** (All Possible Regression), 找出最优的解释变量集;
- 另一种是**逐步回归** (Stepwise Regression), 通过迭代不断更新解释变量集, 以更小的代价得到足够好的解释变量集.

2.4.1 所有子集回归

考虑有 m 个解释变量的多元线性回归模型 (称其为全模型)

设因变量的 n 个观测值构成的向量为 $y \in \mathbb{R}^n$

我们定义总平方和 $SST = \|y - \bar{y}1_n\|_2^2 = \|y - \frac{1}{n}1_n1_n^T y\|_2^2$ (自由度为 $n - 1$)

它反映的是因变量观测值的离差, 与模型选择无关, 因此我们把它定义在这里.

全模型的解释变量子集一共有 2^m 个, 我们希望从其中选取一个最优的解释变量子集.

模型选择依据的准则有以下几种:

(1) 样本决定系数

给定某个 p 元解释变量子集, 设其设计矩阵为 $X_p \in \mathbb{R}^{n \times (p+1)}$

我们记其回归参数向量 β_p 的估计量 $\hat{\beta}_p = (X_p^T X_p)^{-1} X_p^T y$ (这里的下标只代表模型的解释变量个数, 不代表分量)

误差平方和 $SSE_p = \|y - \hat{y}_p\|_2^2 = \|y - X_p \hat{\beta}_p\|_2^2$ (自由度为 $n - p - 1$)

回归平方和 $SSR_p = \|\hat{y}_p - \bar{y}1_n\|_2^2 = \|X_p \hat{\beta}_p - \frac{1}{n}1_n1_n^T y\|_2^2 = SST - SSE_p$ (自由度为 p)

我们定义样本决定系数 $R^2 := \frac{SSR}{SST} = \frac{SST - SSE}{SST} = 1 - \frac{SSE}{SST} \in [0, 1]$

它代表响应变量的观测 y 的总平方和 $SST = \|y - \bar{y}1_n\|_2^2$ 中有多少可以被模型解释.

可以证明: $R^2 = \text{Corr}^2(y, \hat{y})$ (因此 R^2 越大, y 和 $\hat{y}$ 之间的线性相关性就越大)

$$\begin{aligned}
 R^2 &= \frac{SSR}{SST} \\
 &= \frac{\|\hat{y} - \bar{y}1_n\|_2^2}{\|y - \bar{y}1_n\|_2^2} \\
 &= \frac{\|\hat{y} - \bar{y}1_n\|_2^2 \|\hat{y} - \bar{y}1_n\|_2^2}{\|y - \bar{y}1_n\|_2^2 \|\hat{y} - \bar{y}1_n\|_2^2} \\
 &= \frac{[y^T (H - \frac{1}{n}1_n1_n^T) y]^2}{\|y - \bar{y}1_n\|_2^2 \|\hat{y} - \bar{y}1_n\|_2^2} \quad (\text{note that } (H - \frac{1}{n}1_n1_n^T) \frac{1}{n}1_n1_n^T = \frac{1}{n}1_n1_n^T - \frac{1}{n}1_n1_n^T = 0_{n \times n}) \\
 &= \frac{[y^T (H - \frac{1}{n}1_n1_n^T) (I_n - \frac{1}{n}1_n1_n^T) y]^2}{\|y - \bar{y}1_n\|_2^2 \|\hat{y} - \bar{y}1_n\|_2^2} \\
 &= \frac{[(\hat{y} - \bar{y}1_n)^T (y - \bar{y}1_n)]^2}{\|y - \bar{y}1_n\|_2^2 \|\hat{y} - \bar{y}1_n\|_2^2} \quad (\text{note that } \bar{\hat{y}} = \frac{1}{n}1_n^T \hat{y} = \frac{1}{n}1_n^T H y = \frac{1}{n}1_n^T y = \bar{y}) \\
 &= \frac{[(\hat{y} - \bar{\hat{y}}1_n)^T (y - \bar{y}1_n)]^2}{\|y - \bar{y}1_n\|_2^2 \|\hat{y} - \bar{\hat{y}}1_n\|_2^2} \\
 &= \frac{\text{Cov}^2(y, \hat{y})}{\text{Var}(y) \text{Var}(\hat{y})} \\
 &= \text{Corr}^2(y, \hat{y})
 \end{aligned}$$

值得注意的是, 它不能作为模型选择依据的准则

因为随着解释变量个数 p 增加, SSE_p 会非严格单调递减, 所以 $R_p^2 = 1 - \frac{SSE_p}{SST}$ 会非严格单调递增.

这表明它只考虑到了模型的拟合度, 而没有考虑模型的复杂度.

我们设法对样本决定系数 R_p^2 进行适当的修正,

使得只有加入真正可以提升模型解释能力的变量时, 经过修正的样本决定系数才会增加.

这就是所谓的自由度修正的样本决定系数:

$$\tilde{R}_p^2 := 1 - \frac{SSE_p / (n - p - 1)}{SST / (n - 1)} = 1 - \frac{MSE_p}{MST} \propto -MSE_p$$

它具有如下性质:

- $\tilde{R}_p^2 = 1 - \frac{\text{SSE}_p/(n-p-1)}{\text{SST}/(n-1)} \leq 1 - \frac{\text{SSE}_p}{\text{SST}} = R_p^2$
给定解释变量数量 p , 当样本数量 n 趋于无穷大时, $\tilde{R}_p^2$ 会收敛到 R_p^2
- $\tilde{R}_p^2$ 会对模型中解释变量数量 p 的增加进行惩罚,
因此如果新添加的解释变量没有显著提高模型的拟合度, 则 $\tilde{R}_p^2$ 可能会下降
 $\tilde{R}_p^2$ 的值可能为负, 特别是当对应的模型的拟合度极差时.
- $\tilde{R}_p^2$ 不是模型拟合优度的无偏估计量,
它只是相对于 R_p^2 引入了自由度的修正, 使其更适用于比较具有不同数量的解释变量的模型.

在所有回归子集中自由度修正的样本决定系数 $\tilde{R}_p^2$ 最大者对应的回归模型就是最优模型.

(2) AIC & BIC 准则

Akaike 信息量准则 (Akaike Information Criterion, AIC) 是根据最大似然估计原理提出的一种模型选择准则.
(因此只要模型能写出对数似然, 那么 AIC 准则以及后面的 BIC 准则就是定义良好的)

给定某个 p 元解释变量子集, 设其设计矩阵为 $X_p \in \mathbb{R}^{n \times (p+1)}$

我们记其回归参数向量 β_p 的估计量 $\hat{\beta}_p = (X_p^T X_p)^{-1} X_p^T y$ (这里的下标只代表模型的解释变量个数, 不代表分量)

误差平方和 $\text{SSE}_p = \|y - \hat{y}_p\|_2^2 = \|y - X_p \hat{\beta}_p\|_2^2$ (自由度为 $n - p - 1$)

在正态假设下, 我们有 $y \sim N(X_p \beta_p, \sigma^2 I_n)$ (其中 σ^2 反映的是随机噪音的强度, 与模型无关)

其概率密度函数为:

$$\begin{aligned} f(y) &= \frac{1}{(\sqrt{2\pi})^n |\sigma^2 I_n|^{\frac{1}{2}}} \exp\left\{-\frac{1}{2}(y - X_p \beta_p)^T (\sigma^2 I_n)^{-1} (y - X_p \beta_p)\right\} \\ &= \frac{1}{(\sqrt{2\pi}\sigma)^n} \exp\left\{-\frac{1}{2\sigma^2} \|y - X_p \beta_p\|_2^2\right\} \end{aligned}$$

似然函数 $L(\beta_p, \sigma^2 | X_p, y)$ 和对数似然函数 $\log L(\beta_p, \sigma^2 | X_p, y)$ 为:

$$\begin{aligned} L(\beta_p, \sigma^2 | X_p, y) &= f(y) = \frac{1}{(\sqrt{2\pi}\sigma)^n} \exp\left\{-\frac{1}{2\sigma^2} \|y - X_p \beta_p\|_2^2\right\} \\ \log L(\beta_p, \sigma^2 | X_p, y) &= -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \|y - X_p \beta_p\|_2^2 \end{aligned}$$

根据 2.2.3(1) 节的结论, 最大化对数似然函数 $\log L(\beta_p, \sigma^2 | X_p, y)$ 得到的似然解为:

$$\begin{aligned} &\begin{cases} \hat{\beta}_p = (X_p^T X_p)^{-1} X_p^T y \\ \hat{\sigma}_p^2 = \frac{1}{n} \|y - X_p \hat{\beta}_p\|_2^2 = \frac{1}{n} \text{SSE}_p \end{cases} \\ \max_{\beta, \sigma^2} \log L(\beta_p, \sigma^2 | X_p, y) &= \log L(\hat{\beta}_p, \hat{\sigma}_p^2 | X_p, y) \\ &= -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\hat{\sigma}_p^2) - \frac{1}{2\hat{\sigma}_p^2} \|y - X_p \hat{\beta}_p\|_2^2 \\ &= -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log\left(\frac{1}{n} \text{SSE}_p\right) - \frac{1}{2 \cdot \frac{1}{n} \text{SSE}_p} \text{SSE}_p \\ &= -\frac{n}{2} \log(\text{SSE}_p) - \frac{n}{2} \log(2\pi) + \frac{n}{2} \log(n) - \frac{n}{2} \end{aligned}$$

我们希望最大化: (王勤文老师采用的定义, 其中模型复杂度由解释变量个数来表征)

$$\begin{aligned} \text{AIC}_p &:= \text{maximum_log-likelihood} - \text{model_complexity} \\ &= -\frac{n}{2} \log(\text{SSE}_p) - p \end{aligned}$$

在所有回归子集中 Akaike 信息量 AIC_p 最大者对应的回归模型就是最优模型。
(不过我们通常使用 AIC 准则的另一等价形式，即最小化 $AIC_p := n \log(\text{SSE}_p) + 2p$)

AIC 准则经由 Bayes 理论改进得到了 **BIC 准则** (Bayesian Information Criterion)
它加大了对解释变量数量 p 的惩罚力度:

$$\begin{aligned} AIC_p &:= n \log(\text{SSE}_p) + 2p \\ BIC_p &:= n \log(\text{SSE}_p) + \log(n)p \end{aligned}$$

在所有回归子集中 Bayes 信息量 BIC_p 最小者对应的回归模型就是最优模型。
(与 AIC 准则相比，BIC 倾向于选择复杂度更低的模型)

(3) Mallows C_p 准则

Mallows C_p 准则是从最小化模型预测误差的角度提出的。

给定某个 p 元解释变量子集，设其设计矩阵为 $X_p \in \mathbb{R}^{n \times (p+1)}$

我们记其回归参数向量 β_p 的估计量 $\hat{\beta}_p = (X_p^T X_p)^{-1} X_p^T y$ (这里的下标只代表模型的解释变量个数，不代表分量)
误差平方和 $\text{SSE}_p = \|y - \hat{y}_p\|_2^2 = \|y - X_p \hat{\beta}_p\|_2^2$ (自由度为 $n - p - 1$)

在正态假设下，我们有 $y \sim N(X_p \beta_p, \sigma^2 I_n)$ (其中 σ^2 反映的是随机噪音的强度，与模型无关)

根据 σ^2 的最大似然估计量纠偏得到的无偏估计量 $s_p^2 = \frac{1}{n-p-1} \text{SSE}_p \sim \sigma^2 \chi_{(n-p-1)}^2$

而 β_p 的最大似然估计量即为最小二乘估计量 $\hat{\beta}_p = (X_p^T X_p)^{-1} X_p^T y \sim N(\beta_p, \sigma^2 (X_p^T X_p)^{-1})$

考虑模型预测值 $\hat{y}_p = X_p \hat{\beta}_p = H_p y$ 的均方误差:

(它由模型波动性 $\text{tr}(\text{Cov}(\hat{y}_p))$ 和模型偏差 $\|E[\hat{y}_p] - \mu\|^2 = \mu^T (I - H_p) \mu$ 构成)

$$\begin{aligned} \text{MSE}(\hat{y}_p) &:= E[\|\hat{y}_p - E[y]\|^2] \quad (\text{denote } \mu := E[y]) \\ &= E[\|\hat{y}_p - \mu\|^2] \\ &= E[\|\hat{y}_p - E[\hat{y}_p] + E[\hat{y}_p] - \mu\|^2] \\ &= E\{\|\hat{y}_p - E[\hat{y}_p]\|^2 + \|E[\hat{y}_p] - \mu\|^2 + 2(\hat{y}_p - E[\hat{y}_p])^T (E[\hat{y}_p] - \mu)\} \\ &= E[\|\hat{y}_p - E[\hat{y}_p]\|^2] + E[\|E[\hat{y}_p] - \mu\|^2] + 2E[(\hat{y}_p - E[\hat{y}_p])^T (E[\hat{y}_p] - \mu)] \\ &= E[\text{tr}((\hat{y}_p - E[\hat{y}_p])^T (\hat{y}_p - E[\hat{y}_p]))] + \|E[\hat{y}_p] - \mu\|^2 + 2(E[\hat{y}_p] - E[\hat{y}_p])^T (E[\hat{y}_p] - \mu) \\ &= E[\text{tr}((\hat{y}_p - E[\hat{y}_p])(\hat{y}_p - E[\hat{y}_p])^T)] + \|E[H_p y] - \mu\|^2 + 0 \\ &= \text{tr}(E[(\hat{y}_p - E[\hat{y}_p])(\hat{y}_p - E[\hat{y}_p])^T]) + \|H_p E[y] - \mu\|^2 \\ &= \text{tr}(\text{Cov}(\hat{y}_p)) + \|H_p \mu - \mu\|^2 \\ &= \text{tr}(\text{Cov}(\hat{y}_p)) + \mu^T (I - H_p) \mu \\ &\geq \text{tr}(\text{Cov}(\hat{y}_p)) \quad (\text{note that } \hat{y}_p = H_p y = X_p (X_p^T X_p)^{-1} X_p^T y) \\ &= \text{tr}(\text{Cov}(H_p y)) \\ &= \text{tr}(H_p \text{Cov}(y) H_p^T) \\ &= \text{tr}(H_p \cdot \sigma^2 I_n \cdot H_p) \\ &= \sigma^2 \text{tr}(H_p) \\ &= \sigma^2 (p + 1) \end{aligned}$$

考虑模型预测值 $\hat{y}_p = X_p \hat{\beta}_p = H_p y$ 的误差平方和:

$$\begin{aligned}
E[SSE_p] &= E[\|y - \hat{y}_p\|^2] \\
&= E[\|y - H_p y\|^2] \\
&= E[y^T (I - H_p)^T (I - H_p) y] \\
&= E[y^T (I - H_p) y] \\
&= E[\text{tr}(y^T (I - H_p) y)] \\
&= E[\text{tr}((I - H_p) y y^T)] \\
&= \text{tr}((I - H_p) E[yy^T]) \\
&= \text{tr}\{(I - H_p) E[(\mu + \varepsilon)(\mu + \varepsilon)^T]\} \\
&= \text{tr}\{(I - H_p) E[\mu\mu^T + 2\mu\varepsilon^T + \varepsilon\varepsilon^T]\} \\
&= \text{tr}\{(I - H_p) [\mu\mu^T + 2\mu \cdot 0_n^T + \text{Cov}(\varepsilon)]\} \\
&= \text{tr}\{(I - H_p) [\mu\mu^T + \sigma^2 I_n]\} \\
&= \mu^T (I - H_p) \mu + \sigma^2 \text{tr}(I - H_p) \\
&= \mu^T (I - H_p) \mu + \sigma^2 (n - p - 1)
\end{aligned}$$

因此我们有:

$$\begin{aligned}
\frac{E[SSE_p]}{\sigma^2} - n + 2(p + 1) &= \frac{\mu^T (I - H_p) \mu + \sigma^2 (n - p - 1)}{\sigma^2} - n + 2(p + 1) \\
&= \frac{\mu^T (I - H_p) \mu}{\sigma^2} + (p + 1) \\
&\geq p + 1
\end{aligned}$$

它由模型相对偏差 $\frac{1}{\sigma^2} \|E[\hat{y}_p] - \mu\|^2 = \frac{1}{\sigma^2} \mu^T (I - H_p) \mu$ 和模型复杂度 $p + 1$ 构成.

据此构造 C_p 统计量: (其中我们使用全模型的估计量 s_m^2 来作为 σ^2 的估计量 (此时不一定无偏))

$$\begin{aligned}
C_p &:= \frac{SSE_p}{s_m^2} - n + 2(p + 1) \\
&= \frac{SSE_p}{SSE_m / (n - m - 1)} - n + 2(p + 1) \\
&= (n - m - 1) \frac{SSE_p}{SSE_m} - n + 2(p + 1)
\end{aligned}$$

在所有回归子集中, 我们尽量选择 Mallows 指数 $C_p \approx p + 1$ 的子集.

若有多个子集满足 $C_p \approx p + 1$ (它们对应的 p 可能是不同的), 则我们尽量选取 C_p 值较小的子集.

2.4.1 逐步回归

考虑有 p 个解释变量的多元线性回归模型 (称其为全模型)

它一共有 2^p 个回归子集, 能构建 $2^p - 1$ 个回归方程.

因此当 p 较大时, 所有子集回归的代价就太高了.

我们可以选择向现实妥协一下, 放弃对最优回归模型的追求,

通过迭代不断更新解释变量集, 以更小的代价得到足够好的回归模型.

回忆起线性约束检验的内容:

对于一般的线性约束检验, 零假设为 $H_0: C\beta = h$

其中 $\begin{cases} C \in \mathbb{R}^{m \times (p+1)} & (m < p + 1) \\ h \in \mathbb{R}^m \\ \beta = [\beta_0, \beta_1, \dots, \beta_p]^T \in \mathbb{R}^{p+1} \end{cases}$ (我们假设 C 是行满秩的, 即 $\text{rank}(C) = m$)

我们将使用 $F = \frac{(SSE_{\text{reduced}} - SSE_{\text{full}})/m}{SSE_{\text{full}}/(n - p - 1)} \stackrel{H_0}{\sim} F_{m, n-p-1}$ 作为检验统计量

其中 SSE_{full} , SSE_{reduced} 分别是**全模型** (full model) 和**简约模型** (reduces model) 的误差平方和

假设当前的回归子集为 $\{x_1, \dots, x_k\}$

- ① 若我们要判断已有的解释变量 x_i 是否可以删掉, 则我们可对其回归系数进行显著性检验.

考虑检验问题 $H_0: \beta_i = 0 \leftrightarrow H_1: \beta_i \neq 0$ (这里线性约束的个数 $m = 1$)

$$F_i = \frac{(\text{SSE}_{\{x_1, \dots, x_k\} \setminus \{x_i\}} - \text{SSE}_{\{x_1, \dots, x_k\}})/1}{\text{SSE}_{\{x_1, \dots, x_k\}}/(n - k - 1)} \stackrel{H_0}{\sim} F_{1, n-k-1}$$

F_i 越大, 则我们越倾向于拒绝 H_0 , 意味着 x_i 的解释作用越显著, 越应该保留 x_i

- ② 若我们要判断是否可以引入新的解释变量 x_i , 则我们可对其回归系数进行显著性检验.

考虑检验问题 $H_0: \beta_i = 0 \leftrightarrow H_1: \beta_i \neq 0$ (这里线性约束的个数 $m = 1$)

$$F_i = \frac{(\text{SSE}_{\{x_1, \dots, x_k\}} - \text{SSE}_{\{x_1, \dots, x_k\} \cup \{x_i\}})/1}{\text{SSE}_{\{x_1, \dots, x_k\} \cup \{x_i\}}/(n - k - 2)} \stackrel{H_0}{\sim} F_{1, n-k-2}$$

F_i 越大, 则我们越倾向于拒绝 H_0 , 意味着 x_i 的解释作用越显著, 越应该引入 x_i

(1) 前进法

前进法的思想是解释变量由少到多

每轮迭代增加一个偏 F 检验最显著 (而且显著水平高于阈值) 的解释变量, 直至没有可引入的解释变量.

考虑有 p 个解释变量的多元线性回归模型 (称其为全模型)

其设计矩阵为 $X \in \mathbb{R}^{n \times (p+1)}$, 因变量观测向量为 $y \in \mathbb{R}^n$

计算某一回归子集 (通过传入下标指定) 的均方误差的函数为:

```
function: SSE_subset = Compute_SSE(y, X, indices)
    X_subset = X[ : , indices]    (note that the first column of X_subset is always 1_n)
    beta_hat_subset = (X_subset^T X_subset)^-1 X_subset^T y
    y_hat_subset = X_subset beta_hat_subset
    return ||y - y_hat_subset||_2^2
```

因子水平为 α 的前进法的算法如下:

```

function: best_vars = ForwardSelection( $y$ ,  $X$ ,  $\alpha$ )
     $n = X.\text{shape}[0]$ 
     $p = X.\text{shape}[1] - 1$ 
    selected_vars = [0]      (Initialize with the intercept term only)
    remaining_vars = [1, ...,  $p$ ]
    current_SSE = Compute_SSE( $y$ ,  $X$ , selected_vars)
    while remaining_vars is not empty:
        best_F_stat = 0
        best_var = None
        degree_of_freedom =  $n - 1 - \text{len}(\text{selected\_vars})$ 
        critical_value =  $F_{1, \text{degree\_of\_freedom}, \alpha}$ 
        for  $i$  in remaining_vars:
            temp_vars = selected_vars + [ $i$ ]
            new_SSE = Compute_SSE( $y$ ,  $X$ , temp_vars)      (Compute SSE with  $x_i$  included)
            
$$F\_stat = \frac{\text{current\_SSE} - \text{new\_SSE}}{\text{new\_SSE} / \text{degree\_of\_freedom}}$$
      (Compute F_statistics of  $x_i$ )
            if  $F\_stat > \text{best\_F\_stat}$ 
                best_F_stat =  $F\_stat$ 
                best_var =  $i$ 
            end
        end
        if best_F_stat > critical_value
            selected_vars.append(best_var)      (Add the best variable to the selected set)
            remaining_vars.remove(best_var)      (Remove the best variable from remaining set)
        else
            break      (Stop if no F value meet the critical value determined by the significance level  $\alpha$ )
        end
    end
    return selected_vars

```

(2) 后退法

后退法与前进法相反:

首先用全部解释变量进行回归,

随后每轮迭代删除一个偏 F 检验最不显著 (而且显著水平低于阈值) 的解释变量, 直至没有可删除的解释变量.

因子水平为 α 的后退法的算法如下:

```

function: best_vars = BackwardSelection( $y, X, \alpha$ )
     $n = X.\text{shape}[0]$ 
     $p = X.\text{shape}[1] - 1$ 
    selected_vars = [0, 1, ...,  $p$ ]    (Initialize with the intercept term and all variables)
    current_SSE = Compute_SSE( $y, X, \text{selected\_vars}$ )
    while len(selected_vars) > 1
        worst_F_stat =  $\infty$ 
        worst_var = None
        degree_of_freedom =  $n - \text{len}(\text{selected\_vars})$ 
        critical_value =  $F_{1, \text{degree\_of\_freedom}, \alpha}$ 
        for  $i$  in selected_vars[1:]    (Note that the first entry of selected_vars is always 0)
            temp_vars = selected_vars - [ $i$ ]
            new_SSE = Compute_SSE( $y, X, \text{temp\_vars}$ )    (Compute SSE without  $x_i$ )
            
$$F\_stat = \frac{\text{new\_SSE} - \text{current\_SSE}}{\text{current\_SSE} / \text{degree\_of\_freedom}}$$
    (Compute F_statistics of  $x_i$ )
            if  $F\_stat < \text{best\_F\_stat}$ 
                worst_F_stat =  $F\_stat$ 
                worst_var =  $i$ 
            end
        end
        if worst_F_stat < critical_value
            selected_vars.remove(worst_var)    (Remove the worst variable from the selected set)
        else
            break    (Stop if all F values are above the critical value determined by the significance level  $\alpha$ )
        end
    end
    return selected_vars

```

如果所有解释变量 $x_1, \dots, x_p$ 都是相互不相关的，则二者的结果是相同的。

但在绝大部分实际问题中解释变量都有一定的相关性。

如果有若干个解释变量联合起来解释作用显著，但单个来看解释作用不显著，则前进法无法引入这几个解释变量，而后退法却能保留这几个解释变量，这便是后退法的优点。但后退法相对于前进法的缺点也很明显：它从最大的回归子集开始迭代，这样计算量会很大。

(3) 逐步回归

尽管后退法和前进法用起来相当简便，但它们有一个共同的缺陷：

解释变量的删除或增加都只取决于某一步骤中的局部情况，

删除或增加一旦发生，后面是无法“挽救”的。

以前进法为例，引入的某个解释变量刚开始可能是显著的，

但随着我们不断引入新的解释变量，它有可能变得不再显著了，但前进法无法将它剔除。

这种只考虑引入而不考虑剔除的做法显然是不全面的。

我们自然想到构造一种方法，将前进法和后退法结合起来，这就产生了逐步回归法：

具体来说，每步迭代都先进行单步前进法，再进行单步后退法。

其中单步前进法负责引入新变量，而单步后退法用于剔除已有的解释变量（如果它由于新变量的引入而变得不再显著）

上述迭代一直进行，直到单步前进法无法引入新的解释变量为止。

值得注意的是，单步前进法的因子水平 α_{entry} 应当小于单步后退法的因子水平 α_{removal} （即引入要比剔除更加严格）否则可能会出现某个变量反复被引入和剔除的死循环。

① 单步前进法：

```

function: best_var = StepwiseForwardSelection(y, X, selected_vars, remaining_vars,  $\alpha$ )
    n = X.shape[0]
    current_SSE = Compute_SSE(y, X, selected_vars)
    degree_of_freedom = n - len(selected_vars) - 1
    critical_value =  $F_{1, \text{degree\_of\_freedom}, \alpha}$ 
    best_F_stat = 0
    best_var = None
    for i in remaining_vars:
        temp_vars = selected_vars + [i]
        new_SSE = Compute_SSE(y, X, temp_vars)
        F_stat =  $\frac{(\text{current\_SSE} - \text{new\_SSE})/1}{\text{new\_SSE}/\text{degree\_of\_freedom}}$ 
        if F_stat > best_F_stat:
            best_F_stat = F_stat
            best_var = i
    end
end
if best_F_stat > critical_value:
    return best_var
else:
    return None
end

```

② 单步后退法:

```

function: worst_var = StepwiseBackwardSelection(y, X, selected_vars,  $\alpha$ )
    n = X.shape[0]
    current_SSE = Compute_SSE(y, X, selected_vars)
    degree_of_freedom = n - len(selected_vars)
    critical_value =  $F_{1, \text{degree\_of\_freedom}, \alpha}$ 
    worst_F_stat =  $\infty$ 
    worst_var = None
    for i in selected_vars[1:] (Note that the first entry of selected_vars is always 0)
        temp_vars = selected_vars - [i]
        new_SSE = Compute_SSE(y, X, temp_vars)
        F_stat =  $\frac{(\text{new\_SSE} - \text{current\_SSE})/1}{\text{current\_SSE}/\text{degree\_of\_freedom}}$ 
        if F_stat < worst_F_stat:
            worst_F_stat = F_stat
            worst_var = i
    end
end
if worst_F_stat < critical_value:
    return worst_var
else:
    return None
end

```

③ 逐步回归:

```

function: best_vars = StepwiseRegression( $y, X, \alpha_{\text{entry}}, \alpha_{\text{removal}}$ )
    if  $\alpha_{\text{entry}} \geq \alpha_{\text{removal}}$  :
        raise ValueError("Entry significance level  $\alpha_{\text{entry}}$  must be less than removal significance level  $\alpha_{\text{removal}}$ ")
     $n = X.\text{shape}[0]$ 
     $p = X.\text{shape}[1] - 1$ 
    selected_vars = [0]      (Initialize with the intercept term only)
    remaining_vars = [1, ...,  $p$ ]
    while TRUE:
        best_var = StepwiseForwardSelection( $y, X, \text{selected\_vars}, \text{remaining\_vars}, \alpha_{\text{entry}}$ )
        if best_var  $\neq$  None:
            selected_vars.append(best_var)      (Add the best variable to the selected set)
            remaining_vars.remove(best_var)     (Remove the best variable from remaining set)
        else
            break
    end
    worst_var = StepwiseBackwardSelection( $y, X, \text{selected\_vars}, \alpha_{\text{removal}}$ )
    if worst_var  $\neq$  None:
        selected_vars.remove(worst_var)        (Remove the worst variable from the selected set)
        remaining_vars.append(worst_var)       (Add the worst variable back to the remaining set)
    end
end
return selected_vars

```

2.5 模型诊断

随机噪声 ε 的基本假设是 $\begin{cases} E(\varepsilon) = 0_n \\ \text{Cov}(\varepsilon) = \sigma^2 I_n \end{cases}$

- 第一个基本假设 $E[\varepsilon] = 0_n$ 被违反我们是不担心的
这是因为我们可以将 y 中心化, 让 $E[y]$ 把 $E[\varepsilon]$ 的非零值吃掉.
因此这不是模型诊断的重点.
- 第二个基本假设 $\text{Cov}(\varepsilon) = \sigma^2 I_n$ 被违反的情况就要严重多了, 主要分为两种:
 - ① 异方差性 (hetero-skedasticity): 存在某对 $i \neq j$ 使得 $\text{Var}(\varepsilon_i) \neq \text{Var}(\varepsilon_j)$
 - ② 自相关性 (auto-correlation): 存在某对 $i \neq j$ 使得 $\text{Cov}(\varepsilon_i, \varepsilon_j) \neq 0$

我们将残差向量 $e = y - \hat{y}$ 作为随机噪声 ε 的估计

根据 e 的表现来判断是否需要检验 ε 的第二个基本假设 $\text{Cov}(\varepsilon) = \sigma^2 I_n$

如果它成立, 则我们有:

$$\begin{aligned}
 \text{Cov}(\hat{y}, e) &= \text{Cov}(Hy, (I_n - H)y) \\
 &= H \cdot \text{Cov}(y) \cdot (I_n - H)^T \\
 &\quad (\text{if } \text{Cov}(\varepsilon) = \sigma^2 I_n \text{ then we have } \text{Cov}(y) = \sigma^2 I_n) \\
 &= H \cdot \sigma^2 I_n \cdot (I_n - H) \quad (\text{note that } H \text{ is symmetric and idempotent}) \\
 &= \sigma^2 (H - H^2) \\
 &= \sigma^2 (H - H) \\
 &= 0_{n \times n}
 \end{aligned}$$

$\text{Cov}(\hat{y}, e)$ 的矩估计量 $\widehat{\text{Cov}}(\hat{y}, e)$ 为:

$$\begin{aligned}
 \widehat{\text{Cov}}(\hat{y}, e) &= (\hat{y} - \bar{\hat{y}}\mathbf{1}_n)(e - \bar{e}\mathbf{1}_n)^T \quad (\text{note that } \bar{\hat{y}} = \bar{y} \text{ and } \bar{e} = 0) \\
 &= (\hat{y} - \bar{y}\mathbf{1}_n)e^T
 \end{aligned}$$

因此如果 $\widehat{\text{Cov}}(\hat{y}, e) = (\hat{y} - \bar{y}1_n)e^T$ 与 $0_{n \times n}$ 相差较远, 那么我们就对 ε 的第二个基本假设 $\text{Cov}(\varepsilon) = \sigma^2 I_n$ 进行检验.

其中 $\bar{\hat{y}} = \bar{y}$ 和 $\bar{e} = 0$ 是因为:

$$\begin{aligned} 1_n^T e &= 1_n^T (y - \hat{y}) \\ &= 1_n^T (y - Hy) \\ &= 1_n^T (I_n - H)y \quad (\text{note that } H1_n = 1_n \text{ so that } (I_n - H)1_n = 0_n) \\ &= 0_n^T y \\ &= 0 \end{aligned}$$

因此 $\bar{\hat{y}} - \bar{y} = \bar{e} = \frac{1}{n} 1_n^T e = 0$, 表明 $\bar{\hat{y}} = \bar{y}$ 和 $\bar{e} = 0$

或者考虑 e 和 $\hat{y}$ 的样本相关系数 $\hat{\rho}(e, \hat{y})$:

$$\hat{\rho}(e, \hat{y}) := \frac{\sum_{i=1}^n (e_i - \bar{e})(\hat{y}_i - \bar{y})}{\sqrt{\sum_{i=1}^n (e_i - \bar{e})^2 \sum_{i=1}^n (\hat{y}_i - \bar{y})^2}}$$

如果这个量离 0 较远, 则我们就对 ε 的第二个基本假设 $\text{Cov}(\varepsilon) = \sigma^2 I_n$ 进行检验.

2.5.1 异方差性

异方差性 (hetero-skedasticity): 存在某对 $i \neq j$ 使得 $\text{Var}(\varepsilon_i) \neq \text{Var}(\varepsilon_j)$

当存在异方差性时, 最小二乘估计存在以下问题:

- 参数向量 β 的最小二乘估计量 $\hat{\beta}_{\text{LSE}} = (X^T X)^{-1} X^T y$ 仍是无偏估计量, 但不再是最佳线性无偏估计量.
- 参数的显著性检验失效.
- 回归方程的应用效果极不理想.

(1) 检验

异方差性的检验方法有十余种, 但没有一个公认的最优方法.

本课程介绍残差图分析法和 Breusch-Pagan 检验.

残差图分析法是最简便直观的检验方法.

它以残差 $e_1, \dots, e_n$ 为纵坐标, 以其他适宜的变量为横坐标绘制散点图.

常见的横坐标有三种选择:

- ① 拟合值 $\hat{y}_1, \dots, \hat{y}_n$ (其中 $\hat{y}_i = x_i^T \hat{\beta}$)
- ② (如果是一元线性回归的话) 自变量取值 $x_1, \dots, x_n$
- ③ 观测时间或序号 $(1, \dots, n)$


如果回归模型适合样本数据, 那么残差 $e_1, \dots, e_n$ 应当反映 $\varepsilon_1, \dots, \varepsilon_n$ 所假定的性质.

此时若 $\varepsilon_1, \dots, \varepsilon_n$ 确实满足我们所假定的性质,

则我们应当只能从残差 $e_1, \dots, e_n$ 的图像上观察到符合假设的特征, 但没有额外的信息 (即明显的、未出现在假设中的规律)


例如下图就是一张 "好" 的残差图:

Good residual pattern




而下面的 "坏" 的残差图表现出了没有被加入模型中的规律 (即模型不充分):

Model form not adequate




Model form not adequate



有时我们对随机噪音分布的假设是错误的, 例如下面的残差图暗示随机噪音的方差是逐渐变大的:
(这幅图就展示了典型的异方差性)

Nonconstant variance



Breusch-Pagan 检验 (又称 BP 检验)

$$H_0 : \text{Var}(\varepsilon_i) = \text{Var}(\varepsilon_j) \ (\forall i, j = 1, \dots, n) \leftrightarrow H_1 : \exists i \neq j \in \{1, \dots, n\} \text{ such that } \text{Var}(\varepsilon_i) \neq \text{Var}(\varepsilon_j)$$

其基本思想是:

如果存在异方差性, 那么残差项的方差将随解释变量变化.

因此可以对残差的平方进行回归, 检验这些残差的方差是否显著依赖于解释变量.

设因子水平 (第一类型错误概率的上界) 为 α , 记因变量观测为 $y \in \mathbb{R}^n$, 设计矩阵为 $X \in \mathbb{R}^{n \times (p+1)}$

BP 检验分为以下三步:

- ① 原模型回归 (又称普通最小二乘回归, Ordinary Least Squares Regression)

对 $y, \tilde{X}$ 进行标准多元线性回归 (回归方程为 $y = \beta + \varepsilon$), 得到 β 的最小二乘估计量 $\hat{\beta} = (X^T X)^{-1} X^T y$

然后计算残差 $e = y - \hat{y} = y - X\hat{\beta}$, 并计算残差的逐项二次幂: $e^2 := e \circ e$

• ② 辅助回归 (Auxiliary Regression)

对 e^2 , X 进行标准多元线性回归 (回归方程为 $e^2 = X\gamma + u$, 其中假设 $u \sim N(0_n, \sigma_{\text{auxiliary}}^2 I_n)$)

最终得到以下统计量:

$$\begin{aligned}\hat{\gamma} &= (X^T X)^{-1} X^T e^2 \\ \hat{u} &= e^2 - X\hat{\gamma} = (I_n - H)e^2 \quad (\text{where } H = X(X^T X)^{-1} X^T, \text{tr}(H) = p + 1) \\ \text{SSE}_{\text{auxiliary}} &= \|\hat{u}\|_2^2 = \|(I_n - H)e^2\|_2^2 = (e^2)^T (I_n - H)e^2 \sim \sigma_{\text{auxiliary}}^2 \chi_{(n-p-1)}^2 \\ \text{SST}_{\text{auxiliary}} &= \|e^2 - \bar{e}^2 \mathbf{1}_n\|_2^2 = \|(I_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^T) e^2\|_2^2 = (e^2)^T (I_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^T) e^2 \\ \text{SSR}_{\text{auxiliary}} &= \|X\hat{\gamma} - \bar{e}^2 \mathbf{1}_n\|_2^2 = \|(H - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^T) e^2\|_2^2 = (e^2)^T (H - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^T) e^2\end{aligned}$$

• ③ 辅助回归的回归方程显著性检验

原检验问题可以转换为辅助回归的回归方程显著性检验:

$$\tilde{H}_0 : \gamma_1 = \dots = \gamma_p = 0 \leftrightarrow \tilde{H}_1 : \exists i \in \{1, \dots, p\} \text{ such that } \gamma_i \neq 0$$

注意到在零假设 $\tilde{H}_0 : \gamma_1 = \dots = \gamma_p = 0$ 下我们有:

$$\begin{aligned}\text{SST}_{\text{auxiliary}} &\stackrel{\tilde{H}_0}{\sim} \sigma_{\text{auxiliary}}^2 \chi_{(n-1)}^2 \\ \text{SSR}_{\text{auxiliary}} &\stackrel{\tilde{H}_0}{\sim} \sigma_{\text{auxiliary}}^2 \chi_{(p)}^2 \\ \text{SSE}_{\text{auxiliary}} &\sim \sigma_{\text{auxiliary}}^2 \chi_{(n-p-1)}^2 \\ \text{SSR}_{\text{auxiliary}} &\stackrel{\tilde{H}_0}{\perp} \text{SSE}_{\text{auxiliary}}\end{aligned}$$

因此检验统计量的分布为:

$$F = \frac{\text{MSR}_{\text{auxiliary}}}{\text{MSE}_{\text{auxiliary}}} = \frac{\text{SSR}_{\text{auxiliary}}/p}{\text{SSE}_{\text{auxiliary}}/(n-p-1)} \stackrel{\tilde{H}_0}{\sim} \frac{\sigma^2 \chi_{(p)}^2/p}{\sigma^2 \chi_{(n-p-1)}^2/(n-p-1)} = F_{p, n-p-1}$$

记 $F_{p, n-p-1, \alpha}$ 为 $F_{p, n-p-1}$ 分布的 $1 - \alpha$ 分位数.

(F-检验法)

若 $F = \frac{\text{MSR}_{\text{auxiliary}}}{\text{MSE}_{\text{auxiliary}}} = \frac{\text{SSR}_{\text{auxiliary}}/p}{\text{SSE}_{\text{auxiliary}}/(n-p-1)} > F_{p, n-p-1, \alpha}$, 则我们拒绝零假设 $\tilde{H}_0 : \gamma_1 = \dots = \gamma_p = 0$

这表明残差项的方差 e^2 显著依赖于解释变量, 即有异方差性.

BP 检验的推广是 White 检验, 二者的区别在于第二步辅助回归:

BP 检验在辅助回归中使用的解释变量就是原模型的解释变量 $x_1, \dots, x_p$

而 White 检验在辅助回归中不但使用 $x_1, x_2, \dots, x_p$, 还会使用它们的平方项或交叉项 (例如 $x_1^2, x_1 x_2$)

这样, White 检验的辅助回归中的解释变量个数 $p_{\text{white}} > p$,

于是检验统计量 $F_{\text{white}} = \frac{\text{MSR}_{\text{auxiliary}}}{\text{MSE}_{\text{auxiliary}}} = \frac{\text{SSR}_{\text{auxiliary}}/p_{\text{white}}}{\text{SSE}_{\text{auxiliary}}/(n-p_{\text{white}}-1)} \stackrel{\tilde{H}_0}{\sim} F_{p_{\text{white}}, n-p_{\text{white}}-1}$

(2) 处理方法

如果通过残差图或 BP 检验发现存在异方差性, 那么我们该如何处理呢?

(广义最小二乘, Generalized Least Squares)

我们将随机噪声的假设 $\begin{cases} E[\varepsilon] = 0_n \\ \text{Cov}[\varepsilon] = \sigma^2 I_n \end{cases}$ 放宽为 $\begin{cases} E[\varepsilon] = 0_n \\ \text{Cov}[\varepsilon] = W \end{cases}$

其中 $W \in \mathbb{R}^{n \times n}$ 为给定的对称正定矩阵 (代表我们对随机噪声的方差和协方差的假设)

设其谱分解为 $W = Q\Lambda Q^T = Q \text{diag}\{\lambda_1, \dots, \lambda_n\} Q^T$

我们定义 $W^{\frac{1}{2}} := Q\Lambda^{\frac{1}{2}}Q^T = Q \text{diag}\{\lambda_1^{\frac{1}{2}}, \dots, \lambda_n^{\frac{1}{2}}\} Q^T$, 并对回归模型做以下变换:

$$\begin{cases} \tilde{y} = W^{-\frac{1}{2}}y \\ \tilde{X} = W^{-\frac{1}{2}}X \\ \tilde{\varepsilon} = W^{-\frac{1}{2}}\varepsilon \end{cases} \quad (\text{note that } \begin{cases} \mathbf{E}[\tilde{\varepsilon}] = W^{-\frac{1}{2}}\mathbf{E}[\varepsilon] = 0_n \\ \text{Cov}[\tilde{\varepsilon}] = W^{-\frac{1}{2}}\text{Cov}[\varepsilon](W^{-\frac{1}{2}})^T = I_n \end{cases})$$

$$y = X\beta + \varepsilon \Rightarrow \tilde{y} = \tilde{X}\beta + \tilde{\varepsilon}$$

此时参数 β 的广义最小二乘估计量为:

$$\begin{aligned} \hat{\beta}_{\text{GLSE}} &= (\tilde{X}^T \tilde{X})^{-1} \tilde{X}^T \tilde{y} \\ &= [(W^{-\frac{1}{2}}X)^T (W^{-\frac{1}{2}}X)]^{-1} (W^{-\frac{1}{2}}X)^T (W^{-\frac{1}{2}}y) \\ &= (X^T W^{-1} X)^{-1} X^T W^{-1} y \end{aligned}$$

显然 $\hat{\beta}_{\text{GLSE}}$ 在假设 $\begin{cases} \mathbf{E}[\varepsilon] = 0_n \\ \text{Cov}[\varepsilon] = W \end{cases}$ 下是最佳线性无偏估计量, 其协方差矩阵及其迹为:

$$\begin{aligned} \text{Cov}[\hat{\beta}_{\text{GLSE}}] &= \text{Cov}[(\tilde{X}^T \tilde{X})^{-1} \tilde{X}^T \tilde{y}] \\ &= (\tilde{X}^T \tilde{X})^{-1} \tilde{X}^T \text{Cov}[\tilde{y}] (\tilde{X}^T \tilde{X})^{-1} \tilde{X}^T \\ &= (\tilde{X}^T \tilde{X})^{-1} \tilde{X}^T \cdot I_n \cdot \tilde{X} (\tilde{X}^T \tilde{X})^{-1} \\ &= (\tilde{X}^T \tilde{X})^{-1} \\ &= [(W^{-\frac{1}{2}}X)^T (W^{-\frac{1}{2}}X)]^{-1} \\ &= (X^T W X)^{-1} \end{aligned}$$

$$\text{tr}\{\text{Cov}[\hat{\beta}_{\text{GLSE}}]\} = \text{tr}\{(X^T W X)^{-1}\}$$

特殊地, 当 $\text{Cov}[\varepsilon] = \sigma^2 W = \text{diag}\{\frac{1}{w_1}, \dots, \frac{1}{w_n}\}$ 时, 我们称广义最小二乘为**加权最小二乘** (Weighted Least Squares) 通过引入合适的权重, 可以调整不同观测值的贡献, 使得加权后的误差项方差变得恒定, 从而使得模型满足经典的回归假设.

- 若我们对模型中的误差项方差结构有明确的先验知识, 即知道 $\text{Cov}[\varepsilon] = \text{diag}\{\sigma_1^2, \dots, \sigma_n^2\}$, 则我们可以设 $w_i = \frac{1}{\sigma_i^2}$ ($i = 1, \dots, n$)
- (似乎是错误的想法)
若模型中的误差项方差结构是未知的,
则我们可对残差平方 e^2 进行辅助回归 (使用解释变量 $x_1, \dots, x_p$, 也可加入其平方项或交叉项)
然后将辅助回归的预测值 $\text{diag}\{\hat{e}_1^2, \dots, \hat{e}_n^2\}$ 作为 $\text{Cov}[\varepsilon]$ 的估计, 取 $w_i = \frac{1}{\hat{e}_i^2}$ ($i = 1, \dots, n$)

可以证明最小二乘估计量 $\hat{\beta}_{\text{LSE}} = (X^T X)^{-1} X^T Y$ 仍是 β 的线性无偏估计量, 只是不再满足最小方差性.

实际上, 基于设计矩阵 $X^{n \times (p+1)}$ 的最小二乘估计量 $\hat{\beta}_{\text{LSE}}$ 是 β 的相合估计量.

即对于任意给定的 $\beta \in \mathbb{R}^{p+1}$, 当 $n \rightarrow \infty$ 时都有 $\hat{\beta}_{\text{LSE}} \xrightarrow{p} \beta$ 成立 (依概率收敛)

即对于任意 $\varepsilon > 0$ 都有 $\lim_{n \rightarrow \infty} P_\beta\{\|\hat{\beta}_{\text{LSE}} - \beta\| > \varepsilon\} = 0$ 成立.

其中 $P_\beta\{\cdot\}$ 的下标 β 代表在固定 β 的情况下的概率 (简单起见, 后文省略这个下标)

要证明上述命题, 只需要证明 $\hat{\beta}_{\text{LSE}} = [\hat{\beta}_0, \dots, \hat{\beta}_p]$ 的分量分别是 $\beta = [\beta_0, \dots, \beta_p]$ 的相合估计量即可.

即证明:

$$\lim_{n \rightarrow \infty} P\{|\hat{\beta}_i - \beta_i| > \varepsilon\} = 0 \quad (\forall i = 0, 1, \dots, p)$$

根据 Markov 不等式我们有:

$$\begin{aligned}
P\{|\hat{\beta}_i - \beta_i| > \varepsilon\} &\leq \frac{E[(\hat{\beta}_i - \beta_i) - E(\hat{\beta}_i - \beta_i)]^2}{\varepsilon^2} \quad (\text{note that } E[\hat{\beta}_i] = \beta_i) \\
&= \frac{E[(\hat{\beta}_i - \beta_i)^2]}{\varepsilon^2} \quad (\forall i = 0, 1, \dots, p) \\
&= \frac{\text{Var}(\hat{\beta}_i)}{\varepsilon^2}
\end{aligned}$$

因此我们只需证明 $\lim_{n \rightarrow \infty} \text{Var}(\hat{\beta}_i) = 0$ ($\forall i = 0, 1, \dots, p$)

即只需证明 $\lim_{n \rightarrow \infty} \text{tr}\{\text{Cov}(\hat{\beta}_{\text{LSE}})\} = 0$ 即可。

注意到:

$$\begin{aligned}
\text{Cov}[\hat{\beta}_{\text{LSE}}] &= \text{Cov}[(X^T X)^{-1} X^T y] \\
&= (X^T X)^{-1} X^T \text{Cov}[y] [(X^T X)^{-1} X^T]^T \\
&= (X^T X)^{-1} X^T \cdot W \cdot [(X^T X)^{-1} X^T]^T \\
&= (X^T X)^{-1} (X^T W X) (X^T X)^{-1}
\end{aligned}$$

于是我们有:

$$\begin{aligned}
\text{tr}\{\text{Cov}[\hat{\beta}_{\text{LSE}}]\} &= \text{tr}\{(X^T X)^{-1} (X^T W X) (X^T X)^{-1}\} \\
&= \|(X^T X)^{-1} X^T W^{\frac{1}{2}}\|_F^2
\end{aligned}$$

- 若 W 为对角阵 (记为 $W = \text{diag}\{w_1^2, \dots, w_n^2\}$, 其中 $w_1^2, \dots, w_n^2 > 0$) 则我们有:

$$\begin{aligned}
\text{tr}\{\text{Cov}[\hat{\beta}_{\text{LSE}}]\} &= \|(X^T X)^{-1} X^T W^{\frac{1}{2}}\|_F^2 \\
&\leq \max_{1 \leq i \leq n} w_i^2 \cdot \|(X^T X)^{-1} X^T\|_F^2 \\
&= \max_{1 \leq i \leq n} w_i^2 \cdot \text{tr}\{(X^T X)^{-1} (X^T X) (X^T X)^{-1}\} \\
&= \max_{1 \leq i \leq n} w_i^2 \cdot \text{tr}\{(X^T X)^{-1}\} \\
&\leq \max_{1 \leq i \leq n} w_i^2 \cdot (p+1) \max_{0 \leq i \leq p} [(X^T X)^{-1}]_{(i+1, i+1)}
\end{aligned}$$

引理:

将设计矩阵按列记为 $X := [x_0, x_1, \dots, x_p] \in \mathbb{R}^{n \times (p+1)}$ (其中 $x_0 = 1_n$)

记 $X_{(i)} \in \mathbb{R}^{n \times p}$ 为 X 删去第 i 列 x_i 后得到的矩阵。

记 $\text{span}\{X_{(i)}\}$ 的投影算子为 $H_{(i)} := X_{(i)} [X_{(i)}^T X_{(i)}]^{-1} X_{(i)}^T$

记 x_i 垂直于 $\text{span}\{X_{(i)}\}$ 的分量为 $r_i = (I_n - H_{(i)})x_i$, 则我们有:

$$[(X^T X)^{-1}]_{(i+1, j+1)} = \frac{r_i^T r_j}{\|r_i\|^2 \|r_j\|^2} \quad (\forall i, j = 0, 1, \dots, p)$$

特殊地, 对于对角元我们有:

$$[(X^T X)^{-1}]_{(i+1, i+1)} = \frac{r_i^T r_i}{\|r_i\|^2 \|r_i\|^2} = \frac{1}{\|r_i\|^2} = \frac{1}{\|(I_n - H_{(i)})x_i\|^2} = \frac{1}{x_i^T (I_n - H_{(i)}) x_i} \quad (\forall i = 0, 1, \dots, p)$$

随着 n 不断增大, $\text{span}\{X_{(i)}\}$ 的维数 p 相比于 n 越来越小,

因此 x_i 在 $\text{span}\{X_{(i)}\}$ 中的投影 $H_{(i)}x_i$ 相比于 x_i 越来越小, 使得 $(I_n - H_{(i)})x_i$ 越来越趋向于 x_i

换言之, $[(X^T X)^{-1}]_{(i+1, i+1)}$ 越来越趋近于 $\frac{1}{\|x_i\|^2}$

于是我们有: (存疑)

$$\lim_{n \rightarrow \infty} [(X^T X)^{-1}]_{(i+1, i+1)} = \lim_{n \rightarrow \infty} \frac{1}{\|x_i\|^2} = 0$$

根据引理可知 $\text{tr}\{\text{Cov}[\hat{\beta}_{\text{LSE}}]\} \rightarrow 0$ ($n \rightarrow \infty$)

因此当 W 为对角阵时, $\hat{\beta}_{\text{LSE}}$ 是 β 的相合估计量.

- 对于一般的对称正定阵 W , 我们设其谱分解为 $W = Q\Lambda Q^T$ (其中 $Q \in \mathbb{R}^{n \times n}$ 为实正交阵, Λ 为具有正实数对角元的对角阵)
我们做以下变换:

$$\begin{cases} \tilde{y} = Q^T y \\ \tilde{X} = Q^T X \\ \tilde{\varepsilon} = Q^T \varepsilon \end{cases} \quad (\text{note that } \begin{cases} E[\tilde{\varepsilon}] = Q^T E[\varepsilon] = 0_n \\ \text{Cov}[\tilde{\varepsilon}] = Q^T \text{Cov}[\varepsilon] Q = Q^T W Q = \Lambda \end{cases})$$

$$y = X\beta + \varepsilon \Rightarrow \tilde{y} = \tilde{X}\beta + \tilde{\varepsilon}$$

这样就归结为 W 为对角阵的情形.

根据之前的结论可知, 对于一般的对称正定阵 W , $\hat{\beta}_{\text{LSE}}$ 都是 β 的相合估计量.

2.5.2 自相关性

自相关性 (auto-correlation): 存在某对 $i \neq j$ 使得 $\text{Cov}(\varepsilon_i, \varepsilon_j) \neq 0$

当存在自相关性时, 最小二乘估计存在以下问题:

- 参数向量 β 的最小二乘估计量 $\hat{\beta}_{\text{LSE}} = (X^T X)^{-1} X^T y$ 仍是无偏估计量, 但不再是最佳线性无偏估计量. 它对样本的重采样异常敏感.
- 常用的 F 检验和 t 检验失效:
 F 值和 t 值评价偏高, 容易造成实际不显著的回归方程和回归系数判断为显著.
- 回归方程的应用效果极不理想, 波动性很大.

我们通常认为 $\{x_t\}$ 是从时刻 $t = 1, 2, \dots$ 的观测序列, 且 x_t 是与时刻 t 无关的.

简单起见, 我们假设随机变量序列 $\{\varepsilon_t\}$ 是**平稳的一阶自回归模型** (AR(1)):

- ① 随机变量序列 $\{\varepsilon_t\}$ 是**平稳的** (stationary)
即对于任意时刻 $t \in \mathbb{Z}_+$ 都有 $\begin{cases} E[\varepsilon_t] = \mu < \infty \\ \text{Var}[\varepsilon_t] = \sigma_0^2 < \infty \end{cases}$ 成立 (根据 AR(1) 假设可以证明 $\mu = 0$, 参见后文)
 $\text{Cov}(\varepsilon_t, \varepsilon_s) = \sigma_{t-s}^2$
(均值和方差存在且与时间无关, 自协方差存在且依赖于时间差)

给定正整数 k , 我们定义序列的**滞后 k 阶自相关系数** (lag- k autocorrelation coefficient) 及其估计量为:

$$\rho_{\text{lag-}k} := \frac{\text{Cov}(\varepsilon_t, \varepsilon_{t-k})}{\sqrt{\text{Var}(\varepsilon_t)} \sqrt{\text{Var}(\varepsilon_{t-k})}} = \frac{\sigma_k^2}{\sigma_0^2}$$

$$\hat{\rho}_{\text{lag-}k} := \frac{\sum_{t=k+1}^n e_t e_{t-k}}{\sqrt{\sum_{t=k+1}^n e_t^2} \sqrt{\sum_{t=k+1}^n e_{t-k}^2}}$$

- ② 随机变量序列 $\{\varepsilon_t\}$ 满足以下关系式:

$$\varepsilon_t = \rho \varepsilon_{t-1} + u_t \quad (t = 2, 3, \dots)$$

其中 ρ 为常数 (平稳性要求其满足 $|\rho| < 1$, 参见后文)

- 当 $\rho = 0$ 时, 序列 $\{\varepsilon_t\}$ 不存在自相关性
- 当 $\rho \in (0, 1)$ 时, 序列 $\{\varepsilon_t\}$ 具有正相关性
- 当 $\rho \in (-1, 0)$ 时, 序列 $\{\varepsilon_t\}$ 具有负相关性

而 $\{u_t\}$ 为取自 $N(0, \sigma_u^2)$ 的一列独立同分布的随机变量 (Gauss 白噪声序列, 即独立于下标)

可以证明 $\sigma_u^2 = (1 - \rho^2) \sigma_0^2$ (参见后文)

可以证明在上述模型假设下 $\rho = \text{Corr}(\varepsilon_t, \varepsilon_{t-1})$ ($\forall t \geq 2$):

$$\begin{aligned}
 \text{Corr}(\varepsilon_t, \varepsilon_{t-1}) &= \frac{\text{Cov}(\varepsilon_t, \varepsilon_{t-1})}{\sqrt{\text{Var}(\varepsilon_t)}\sqrt{\text{Var}(\varepsilon_{t-1})}} \quad (\text{note that } \text{Var}[\varepsilon_t] = \sigma_0^2 \text{ for all } t \in \mathbb{Z}_+) \\
 &= \frac{\text{Cov}(\varepsilon_t, \varepsilon_{t-1})}{\text{Var}(\varepsilon_{t-1})} \quad (\text{note that } \varepsilon_t = \rho\varepsilon_{t-1} + u_t) \\
 &= \frac{\text{Cov}(\rho\varepsilon_{t-1} + u_t, \varepsilon_{t-1})}{\text{Var}(\varepsilon_{t-1})} \quad (\text{note that } u_t \perp \varepsilon_{t-1}, \text{ since } \varepsilon_{t-1} \text{ is relevant to } u_1, \dots, u_{t-1}) \\
 &= \frac{\text{Cov}(\rho\varepsilon_{t-1}, \varepsilon_{t-1})}{\text{Var}(\varepsilon_{t-1})} \\
 &= \frac{\rho\text{Var}(\varepsilon_{t-1})}{\text{Var}(\varepsilon_{t-1})} \\
 &= \rho
 \end{aligned}$$

(1) 检验

残差图分析法是最简便直观的检验方法.

① 绘制 $e_i - e_{i-1}$ 散点图 (即数据点为 (e_i, e_{i-1}) ($i = 2, \dots, n$))

- 若大部分点落在 1, 3 象限, 则表明随机噪声存在正的序列相关性
- 若大部分点落在 2, 4 象限, 则表明随机噪声存在负的序列相关性




图 4-4

② 绘制 $e_i - i$ 散点图 (即数据点为 (e_i, i) ($i = 1, \dots, n$))

- 若 e_i 随着 i 的增大不频繁地改变符号, 则表明随机噪声存在正的序列相关性
- 若 e_i 随着 i 的增大频繁地改变符号 (蛛网现象), 则表明随机噪声存在负的序列相关性




图 4-5

自相关系数法:

随机噪音项 $\varepsilon_1, \dots, \varepsilon_n$ 的样本 lag-1 相关系数 $\hat{\rho}_1$ 为:

$$\hat{\rho}_{\text{lag-1}} = \frac{\sum_{i=2}^n e_i e_{i-1}}{\sqrt{\sum_{i=2}^n e_i^2} \sqrt{\sum_{i=2}^n e_{i-1}^2}}$$

- 若 $\hat{\rho}_{\text{lag-1}}$ 接近于 1, 则表明随机噪音存在正的序列相关性
- 若 $\hat{\rho}_{\text{lag-1}}$ 接近于 -1, 则表明随机噪音存在负的序列相关性

当样本量 n 足够大时, $\hat{\rho}_{\text{lag-1}}$ 的估计结果才可信.

(Durbin-Watson 检验)

DW 检验是一种适用于小样本的检验方法, 用于检验随机噪音序列 $\{\varepsilon_t\}$ 具有一阶自回归形式的自相关问题.

$$\varepsilon_t = \rho \varepsilon_{t-1} + u_t \quad (t = 2, 3, \dots)$$

考虑检验问题 $H_0: \rho = 0 \leftrightarrow H_1: \rho \neq 0$, 我们定义 DW 统计量为:

$$\text{DW} := \frac{\sum_{i=2}^n (e_i - e_{i-1})^2}{\sum_{i=2}^n e_i^2}$$

当样本量 n 足够大时, 我们可认为 $\sum_{i=2}^n e_i^2$ 和 $\sum_{i=2}^n e_{i-1}^2$ 近似相等, 此时我们有:

$$\begin{aligned} \text{DW} &= \frac{\sum_{i=2}^n (e_i - e_{i-1})^2}{\sum_{i=2}^n e_i^2} \\ &= \frac{\sum_{i=2}^n e_i^2 + \sum_{i=2}^n e_{i-1}^2 - 2 \sum_{i=2}^n e_i e_{i-1}}{\sum_{i=2}^n e_i^2} \\ &\approx 2 \left(1 - \frac{\sum_{i=2}^n e_i e_{i-1}}{\sqrt{\sum_{i=2}^n e_i^2} \sqrt{\sum_{i=2}^n e_{i-1}^2}} \right) \\ &= 2(1 - \hat{\rho}_{\text{lag-1}}) \end{aligned}$$

因此 DW 值理论上提供了如下判据:

- 若 $\text{DW} \in (0, 2)$ (对应 $\hat{\rho}_{\text{lag-1}} \in (0, 1)$), 则表明随机噪音存在正的序列相关性
- 若 $\text{DW} \in (2, 4)$ (对应 $\hat{\rho}_{\text{lag-1}} \in (-1, 0)$), 则表明随机噪音存在负的序列相关性

但在实际使用中, 我们需要根据样本量 n (一般要求 $n > 15$) 和解释变量数 $p + 1$ (这里包括截距项) 查 DW 分布表, 得到临界值 d_L 和 d_U , 这帮助我们判断模型的自相关性是否显著 (如下图所示)

我们发现 $DW = 2$ 附近有一个较大的无自相关区,

因此当 DW 值在 2 左右时, 无须查表便可认为模型不存在序列相关性.




图 4 - 6

(2) 处理方法

当一个回归模型存在序列相关性时, 首先要查明序列相关性产生的原因.

若是回归模型选用不当或缺少重要的自变量, 则应当选用合适的模型或增加自变量.

若上述方法都不能消除序列相关性, 则我们需要按以下方式处理:

简单起见, 我们假设随机变量序列 $\{\varepsilon_t\}$ 是**平稳的一阶自回归模型** (AR(1)):

- ① 随机变量序列 $\{\varepsilon_t\}$ 是**平稳的** (stationary)

$$\text{即对于任意时刻 } t \in \mathbb{Z}_+ \text{ 都有 } \begin{cases} E[\varepsilon_t] = \mu < \infty \\ \text{Var}[\varepsilon_t] = \sigma_0^2 < \infty \text{ 成立} \\ \text{Cov}(\varepsilon_t, \varepsilon_s) = \sigma_{t-s}^2 \end{cases}$$

(均值和方差存在且与时间无关, 自协方差存在且依赖于时间差)

- ② 随机变量序列 $\{\varepsilon_t\}$ 满足以下关系式:

$$\varepsilon_t = \rho \varepsilon_{t-1} + u_t \quad (t = 2, 3, \dots)$$

其中 ρ 为常数, 而 $\{u_t\}$ 为取自 $N(\mu_u, \sigma_u^2)$ 的一系列独立同分布的随机变量 (Gauss 白噪声序列)

(我们之前假设 $\mu_u = 0$, 这里为得到更深刻的结果, 将 $\{u_t\}$ 的均值设为更一般的 μ_u)

则我们有:

$$\begin{aligned} \varepsilon_t &= \rho \varepsilon_{t-1} + u_t \\ &= \rho(\rho \varepsilon_{t-2} + u_{t-1}) + u_t \\ &= \rho^2 \varepsilon_{t-2} + \rho u_{t-1} + u_t \\ &= \dots \\ &= \rho^{t-1} \varepsilon_1 + \rho^{t-2} u_2 + \dots + \rho u_{t-1} + u_t \end{aligned}$$

对于二阶中心矩有:

$$\begin{aligned}
\text{Var}(\varepsilon_t) &= \text{Var}(\rho^{t-1}\varepsilon_1 + \rho^{t-2}u_2 + \cdots + \rho u_{t-1} + u_t) \\
&= \rho^{2(t-1)}\text{Var}(\varepsilon_1) + \rho^{2(t-2)}\text{Var}(u_2) + \cdots + \rho^2\text{Var}(u_{t-1}) + \text{Var}(u_t) \\
&= \rho^{2(t-1)}\sigma_0^2 + \rho^{2(t-2)}\sigma_u^2 + \cdots + \rho^2\sigma_u^2 + \sigma_u^2
\end{aligned}$$

回忆起 $\text{Var}(\varepsilon_t) = \sigma_0^2$, 故我们有: $\rho^{2(t-1)}\sigma_0^2 + \rho^{2(t-2)}\sigma_u^2 + \cdots + \rho^2\sigma_u^2 + \sigma_u^2 = \sigma_0^2$
 从这里我们可以得到 $|\rho| < 1$ 成立 (因为若 $|\rho| \geq 1$ 成立, 则左式在 $t \rightarrow \infty$ 时趋于正无穷)

$$\begin{aligned}
\sigma_0^2 &= \frac{1}{1 - \rho^{2(t-1)}} \{\rho^{2(t-2)} + \cdots + \rho^2 + 1\} \sigma_u^2 \\
&= \frac{1}{1 - \rho^{2(t-1)}} \cdot \frac{1 - \rho^{2(t-1)}}{1 - \rho^2} \sigma_u^2 \\
&= \frac{\sigma_u^2}{1 - \rho^2}
\end{aligned}$$

对于一阶矩有:

$$\begin{aligned}
\text{E}(\varepsilon_t) &= \text{E}(\rho^{t-1}\varepsilon_1 + \rho^{t-2}u_2 + \cdots + \rho u_{t-1} + u_t) \\
&= \rho^{t-1}\text{E}(\varepsilon_1) + \rho^{t-2}\text{E}(u_2) + \cdots + \rho\text{E}(u_{t-1}) + \text{E}(u_t) \\
&= \rho^{t-1}\mu + \rho^{t-2}\mu_u + \cdots + \rho\mu_u + \mu_u \quad (\text{note that } |\rho| < 1) \\
&= \rho^{t-1}\mu + \frac{1 - \rho^{t-1}}{1 - \rho} \mu_u
\end{aligned}$$

回忆起 $\text{E}(\varepsilon_t) = \mu$, 于是我们有 $\rho^{t-1}\mu + \frac{1 - \rho^{t-1}}{1 - \rho} \mu_u = \mu$, 得到 $\mu = \frac{\mu_u}{1 - \rho}$

当 $\mu_u = 0$ 时, 我们有 $\mu = 0$ 成立.

因此当 $\mu_u = 0$ 时, 平稳的一阶自回归序列 $\{\varepsilon_t\}$ 仍然满足零均值和同方差的假设, 只是违反了不相关的假设.

(I) 假设 ρ 已知

(例如当 $\text{DW} \approx 0$ 或 4 时我们可取 $\rho = 1$ 或 -1)

对于任意 $i = 2, \dots, n$ 我们都有:

$$\begin{cases} y_i = x_i^T \beta + \varepsilon_i \\ y_{i-1} = x_{i-1}^T \beta + \varepsilon_{i-1} \Rightarrow (y_i - \rho y_{i-1}) = (x_i - \rho x_{i-1})^T \beta + u_i \\ \varepsilon_i = \rho \varepsilon_{i-1} + u_i \end{cases}$$

我们记 $\begin{cases} \tilde{y}_i = y_i - \rho y_{i-1} \\ \tilde{x}_i = x_i - \rho x_{i-1} \end{cases} (i = 2, \dots, n)$ 则我们有 $\tilde{y}_i = \tilde{x}_i^T \beta + u_i (i = 2, \dots, n)$

$$\text{denote } \tilde{y} = \begin{bmatrix} \tilde{y}_2 \\ \vdots \\ \tilde{y}_n \end{bmatrix} \in \mathbb{R}^{n-1}, \tilde{X} = \begin{bmatrix} \tilde{x}_2^T \\ \vdots \\ \tilde{x}_n^T \end{bmatrix} \in \mathbb{R}^{(n-1) \times (p+1)}, u = \begin{bmatrix} u_2 \\ \vdots \\ u_n \end{bmatrix} \in \mathbb{R}^{n-1}$$

note that the first column of $\tilde{X}$ is $(1 - \rho)1_{n-1}$ and $u \sim N(0_{n-1}, \sigma_u^2 I_{n-1})$

$$\text{we obtain } \tilde{y} = \tilde{X}\beta + u$$

这便将一阶自回归模型 (AR(1)) $y = X\beta + \varepsilon$ 转变为标准多元线性回归模型 $\tilde{y} = \tilde{X}\beta + u$

此时我们可取 $\hat{\beta}$ 为新模型下的最小二乘估计量 $\hat{\beta} = (\tilde{X}^T \tilde{X})^{-1} \tilde{X}^T \tilde{y}$ (即新模型的 BLUE)

而 $\hat{\sigma}_u$ 为新模型下的无偏估计量 $\hat{\sigma}_u = \frac{1}{(n-1)-p-1} \|\tilde{y} - \tilde{X}\hat{\beta}\|_2^2$

给定新样本 x_{n+1} (紧跟 x_n 的取值) 时, 模型的预测值为 $\hat{y}_{n+1} = \hat{\beta}^T x_{n+1} + \rho y_n$

(II) 假设 ρ 未知

此时我们的目标是找到 ρ 的一个足够好的估计 $\hat{\rho}$, 然后就可以当作 ρ 已知的情况处理.

寻找 $\hat{\rho}$ 的方法有迭代法和差分法.

① 迭代法:

- **第一步: 设置初值**

对原始样本 (y, X) 进行标准的多元线性回归 $y = X\beta + \varepsilon$

此时 $\hat{\beta} = (X^T X)^{-1} X^T y$ 仍是 β 的无偏估计量, 只不过不满足最小方差性.

计算残差向量 $e = y - \hat{y} = y - X\hat{\beta}$

$$e^{(1)} := e(1:n-1) = \begin{bmatrix} e_1 \\ \vdots \\ e_{n-1} \end{bmatrix} \in \mathbb{R}^{n-1}$$

$$e^{(2)} := e(2:n) = \begin{bmatrix} e_2 \\ \vdots \\ e_n \end{bmatrix} \in \mathbb{R}^{n-1}$$

考虑不带截距项的一元线性回归模型 $e^{(2)} = e^{(1)}\rho + u$

计算最小二乘估计量 $\hat{\rho} = [(e^{(1)})^T e^{(1)}]^{-1} (e^{(1)})^T e^{(2)}$ 作为初值.

- **第二步: 根据 $\hat{\rho}$ 对样本做变换, 并更新残差向量 e**

对原始样本 (y, X) 做如下变换:

$$\tilde{y} = \begin{bmatrix} \tilde{y}_2 \\ \vdots \\ \tilde{y}_n \end{bmatrix} = \begin{bmatrix} y_2 - \hat{\rho}y_1 \\ \vdots \\ y_n - \hat{\rho}y_{n-1} \end{bmatrix} \in \mathbb{R}^{n-1}$$

$$\tilde{X} = \begin{bmatrix} \tilde{x}_2^T \\ \vdots \\ \tilde{x}_n^T \end{bmatrix} = \begin{bmatrix} (x_2 - \hat{\rho}x_1)^T \\ \vdots \\ (x_n - \hat{\rho}x_{n-1})^T \end{bmatrix} \in \mathbb{R}^{(n-1) \times (p+1)}$$

$$u = \begin{bmatrix} u_2 \\ \vdots \\ u_n \end{bmatrix} = \begin{bmatrix} \varepsilon_2 - \hat{\rho}\varepsilon_1 \\ \vdots \\ \varepsilon_n - \hat{\rho}\varepsilon_{n-1} \end{bmatrix} \in \mathbb{R}^{n-1}$$

根据变换后的样本 $(\tilde{y}, \tilde{X})$ 计算最小二乘估计量 $\hat{\beta} = (\tilde{X}^T \tilde{X})^{-1} \tilde{X}^T \tilde{y}$

更新残差向量 $e = y - \hat{y} = y - X\hat{\beta}$

- **第三步: 更新 $\hat{\rho}$**

$$e^{(1)} := e(1:n-1) = \begin{bmatrix} e_1 \\ \vdots \\ e_{n-1} \end{bmatrix} \in \mathbb{R}^{n-1}$$

$$e^{(2)} := e(2:n) = \begin{bmatrix} e_2 \\ \vdots \\ e_n \end{bmatrix} \in \mathbb{R}^{n-1}$$

考虑不带截距项的一元线性回归模型 $e^{(2)} = e^{(1)}\rho + u$

计算最小二乘估计量 $\hat{\rho} = [(e^{(1)})^T e^{(1)}]^{-1} (e^{(1)})^T e^{(2)}$, 然后再转到第二步.

反复进行上述迭代, 直至相邻两次迭代的 $SSE = \|y - X\hat{\beta}\|_2^2$ 非常接近为止.

给定新样本 x_{n+1} (紧跟 x_n 的取值) 时, 模型的预测值为 $\hat{y}_{n+1} = \hat{\beta}^T x_{n+1} + \hat{\rho}y_n$

② 差分法

差分法就是对 ρ 可能的范围进行划分.

不妨假设根据残差图和 DW 检验发现随机噪声存在正的序列相关性

则可对区间 $(0, 1)$ 进行划分 $0 = \rho_0 < \rho_1 < \dots < \rho_{m-1} < \rho_m = 1$

我们分别使用 $\rho_0, \rho_1, \dots, \rho_m$ 对样本 (y, X) 进行变换, 得到 $\{(\tilde{y}_i, \tilde{X}_i)\}_{i=0}^m$

并计算 β 的最小二乘估计量 $\hat{\beta}^{(i)} = (\tilde{X}_i^T \tilde{X}_i)^{-1} \tilde{X}_i^T \tilde{y}_i$ ($i = 0, \dots, m$)

我们计算均方误差 $SSE_{(i)} = \|\tilde{y}_i - \tilde{X}_i \hat{\beta}^{(i)}\|^2$ ($i = 0, \dots, m$)

找出最小的均方误差对应的 $\hat{\beta}^{(i_{\min})}$ 和 $\rho_{i_{\min}}$

给定新样本 x_{n+1} (紧跟 x_n 的取值) 时, 模型的预测值为 $\hat{y}_{n+1} = (\hat{\beta}^{(i_{\min})})^T x_{n+1} + \rho_{i_{\min}} y_n$

③ 求解以下最优化问题:

(可能还需加上约束 $|\rho| < 1$)

$$\min_{\beta, \rho} \|\tilde{y}(\rho) - \tilde{X}(\rho)\beta\|_2^2$$

$$\text{where } \tilde{y}(\rho) = \begin{bmatrix} y_2 - \rho y_1 \\ \vdots \\ y_n - \rho y_{n-1} \end{bmatrix} \in \mathbb{R}^{n-1}, \tilde{X}(\rho) = \begin{bmatrix} (x_2 - \rho x_1)^T \\ \vdots \\ (x_n - \rho x_{n-1})^T \end{bmatrix} \in \mathbb{R}^{(n-1) \times (p+1)}$$

2.5.3 非线性

若响应变量 Y 与解释变量 $x_1, \dots, x_p$ 不是线性关系, 则我们可对响应变量的观测 y 进行 Box-Cox 变换:

Choose α such that $y_i + \alpha > 0$ for all $i = 1, \dots, n$

$$GM(y, \alpha) = \left(\prod_{i=1}^n (y_i + \alpha) \right)^{\frac{1}{n}}$$

$$\tau(y_i; \lambda, \alpha) := \begin{cases} GM(y, \alpha) \log(y_i + \alpha) & \text{if } \lambda = 0 \\ \frac{y_i^\lambda - 1}{\lambda (GM(y, \alpha))^{\lambda-1}} & \text{if } \lambda \neq 0 \end{cases}$$

简单起见, 我们假设 $y_i > 0$ ($i = 1, \dots, n$), 并把 Box-Cox 变换简写为:

$$\tau(y_i; \lambda) := \begin{cases} \log(y_i) & \text{if } \lambda = 0 \\ \frac{y_i^\lambda - 1}{\lambda} & \text{if } \lambda \neq 0 \end{cases}$$

我们希望找到 λ 使得 $y^{(\lambda)}$ 与设计矩阵 X 之间的关系是线性的.

设 $y^{(\lambda)} = X\beta + \varepsilon \sim N(X\beta, \sigma^2 I_n)$ (其中 $\varepsilon \sim N(0_n, \sigma^2 I_n)$)

则 $y^{(\lambda)}$ 的概率密度函数为:

$$f(y^{(\lambda)}) = \frac{1}{(\sqrt{2\pi})^n (\det(\sigma^2 I_n))^{\frac{1}{2}}} \exp\left\{-\frac{1}{2}(y^{(\lambda)} - X\beta)^T (\sigma^2 I_n)^{-1} (y^{(\lambda)} - X\beta)\right\}$$

$$= \frac{1}{(\sqrt{2\pi}\sigma)^n} \exp\left\{-\frac{1}{2\sigma^2} \|y^{(\lambda)} - X\beta\|^2\right\}$$

Lemma (联合概率密度在双射下的变换规则, S. Ross Section 2.5.4):

假设 X 是 k 维连续随机变量, 具有概率密度函数 $f_X(\cdot)$

给定变换 $g: \mathbb{R}^k \rightarrow \mathbb{R}^k$, 记 $Y = g(X)$

若 g 满足:

- g 存在逆变换 $h = g^{-1}$
- g 一阶连续可求偏导, 即在所有 x 上有连续的偏导数.

且对于任意 x 都有 Jacobi 行列式 $J(x) = \begin{vmatrix} \frac{\partial g_1}{\partial x_1} & \cdots & \frac{\partial g_1}{\partial x_k} \\ \vdots & & \vdots \\ \frac{\partial g_k}{\partial x_1} & \cdots & \frac{\partial g_k}{\partial x_k} \end{vmatrix} \neq 0$

在这两个条件下, 可以证明 $Y = (Y_1, Y_2, \dots, Y_k)$ **联合地连续**, 且联合密度函数为:

$$f_Y(y) = f_X(x) |J(x)|^{-1} = f_X(h(y)) |J(h(y))|^{-1}$$

- 特殊地, 假设 X 是 k 维连续随机变量, 具有概率密度函数 $f_X(\cdot)$

给定可逆矩阵 $A \in \mathbb{R}^{k \times k}$ 和向量 $b \in \mathbb{R}^k$, 记 $Y = AX + b$

则 $f_Y(y) = \frac{1}{|\det(A)|} f_X(A^{-1}(y - b))$

因此 y 的概率密度函数为:

$$f(y) = f(y^{(\lambda)})J(\lambda)$$

where Jacobian matrix $J(\lambda) := \det \left(\left[\frac{\partial}{\partial y_j} y_i^{(\lambda)} \right]_{i,j=1}^n \right) = \prod_{i=1}^n \frac{\partial}{\partial y_i} y_i^{(\lambda)} = \begin{cases} \prod_{i=1}^n \frac{1}{y_i} & \text{if } \lambda = 0 \\ \prod_{i=1}^n y_i^{\lambda-1} & \text{if } \lambda \neq 0 \end{cases}$

则对数似然函数为:

$$\begin{aligned} L(\beta, \sigma^2, \lambda) &= \log(f(y^{(\lambda)})J(\lambda)) \\ &= \log \left(\frac{1}{(\sqrt{2\pi}\sigma)^n} \exp\left\{-\frac{1}{2\sigma^2} \|y^{(\lambda)} - X\beta\|^2\right\} J(\lambda) \right) \\ &= -\frac{1}{2\sigma^2} \|y^{(\lambda)} - X\beta\|^2 - \frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) + \log(J(\lambda)) \end{aligned}$$

易知 β, σ^2 的极大似然估计量为:

$$\begin{cases} \hat{\beta}_{\text{MLE}} := (X^T X)^{-1} X^T y^{(\lambda)} \\ \hat{\sigma}_{\text{MLE}}^2 := \frac{1}{n} \|y^{(\lambda)} - X\hat{\beta}_{\text{MLE}}\|^2 = \frac{1}{n} (y^{(\lambda)})^T (I_n - H) y^{(\lambda)} \text{ where } H := X(X^T X)^{-1} X^T \end{cases}$$

将 $\hat{\beta}_{\text{MLE}}$ 和 $\hat{\sigma}_{\text{MLE}}^2$ 代入对数似然函数, 便得到:

$$\begin{aligned} &L(\hat{\beta}_{\text{MLE}}, \hat{\sigma}_{\text{MLE}}^2, \lambda) \\ &= -\frac{1}{2\hat{\sigma}_{\text{MLE}}^2} \|y^{(\lambda)} - X\hat{\beta}_{\text{MLE}}\|^2 - \frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\hat{\sigma}_{\text{MLE}}^2) + \log(J(\lambda)) \\ &= -\frac{1}{2 \cdot \frac{1}{n} \|y^{(\lambda)} - X\hat{\beta}_{\text{MLE}}\|^2} \|y^{(\lambda)} - X\hat{\beta}_{\text{MLE}}\|^2 - \frac{n}{2} \log(2\pi) - \frac{n}{2} \log \left(\frac{1}{n} (y^{(\lambda)})^T (I_n - H) y^{(\lambda)} \right) + \log(J(\lambda)) \\ &= -\frac{n}{2} - \frac{n}{2} \log(2\pi) - \frac{n}{2} \log \left(\left(\frac{y^{(\lambda)}}{(J(\lambda))^{\frac{1}{n}}} \right)^T (I_n - H) \left(\frac{y^{(\lambda)}}{(J(\lambda))^{\frac{1}{n}}} \right) \right) + \frac{n}{2} \log(n) \\ &= -\frac{n}{2} - \frac{n}{2} \log(2\pi) - \frac{n}{2} \log \left((z^{(\lambda)})^T (I_n - H) (z^{(\lambda)}) \right) + \frac{n}{2} \log(n) \quad (\text{Denote } z^{(\lambda)} := \frac{y^{(\lambda)}}{(J(\lambda))^{\frac{1}{n}}}) \end{aligned}$$

因此 λ 的极大似然估计量为:

$$\begin{aligned} \hat{\lambda}_{\text{MLE}} &= \arg \max_{\lambda \in \mathbb{R}} L(\hat{\beta}_{\text{MLE}}, \hat{\sigma}_{\text{MLE}}^2, \lambda) \\ &= \arg \max_{\lambda \in \mathbb{R}} \left\{ -\frac{n}{2} - \frac{n}{2} \log(2\pi) - \frac{n}{2} \log \left((z^{(\lambda)})^T (I_n - H) (z^{(\lambda)}) \right) + \frac{n}{2} \log(n) \right\} \\ &= \arg \min_{\lambda \in \mathbb{R}} \left\{ \log \left((z^{(\lambda)})^T (I_n - H) (z^{(\lambda)}) \right) \right\} \\ &= \arg \min_{\lambda \in \mathbb{R}} \left\{ (z^{(\lambda)})^T (I_n - H) (z^{(\lambda)}) \right\} \end{aligned}$$

其中投影矩阵 $H = X(X^T X)^{-1} X^T$, 而 $z^{(\lambda)} := \frac{y^{(\lambda)}}{(J(\lambda))^{\frac{1}{n}}}$

值得注意的是, λ 的极大似然估计量 $\hat{\lambda}_{\text{MLE}}$ 有时没有显式表示.

我们可以取一系列值 $a = \lambda_0 < \lambda_1 < \dots < \lambda_m = b$

分别计算 $z^{(\lambda_i)}$ 和均方误差 $(z^{(\lambda_i)})^T (I_n - H) (z^{(\lambda_i)})$

找出最小的均方误差对应的 $\lambda_{i_{\min}}$ 作为 $\hat{\lambda}_{\text{MLE}}$ 的近似.

The End