

FDU 回归分析 3. 岭回归

本文根据王勤文老师课堂笔记整理而成，并参考以下教材：

- 应用回归分析 (第 5 版, 何晓群, 刘文卿) 第 6, 7 章

欢迎批评指正!

3.1 多重共线性

在 FDU 回归分析 2. 多元线性回归中,

我们默认设计矩阵 $X \in \mathbb{R}^{n \times (p+1)}$ 满足列满秩假设 $\text{rank}(X) = p + 1 \leq n$

这保证了 $(X^T X) \in \mathbb{R}^{(p+1) \times (p+1)}$ 是非奇异阵.

于是 X 的 Moore-Penrose 逆 $X^\dagger = (X^T X)^{-1} X^T \in \mathbb{R}^{(p+1) \times n}$

但如果设计矩阵 $X \in \mathbb{R}^{n \times (p+1)}$ 的列越来越趋于线性相关 (即列满秩假设越来越趋于不成立),

那么 $X^T X$ 会越来越趋于奇异, 即其模最小特征值 $\lambda_{\min}(X^T X)$ 越来越趋于 0

此时我们称设计矩阵 X 的列向量之间存在**多重共线性** (multi-collinearity)

即解释变量之间存在显著的相关性.

3.1.1 影响

(Proof of the below proposition)

设 $X := [x_1, \dots, x_p] \in \mathbb{R}^{n \times p}$

记 $X_{(i)} \in \mathbb{R}^{n \times (p-1)}$ 为 X 删去第 i 列 x_i 后得到的矩阵.

记 $\text{span}\{X_{(i)}\}$ 的投影算子为 $H_{(i)} := X_{(i)} [X_{(i)}^T X_{(i)}]^{-1} X_{(i)}^T$

记 x_i 垂直于 $\text{span}\{X_{(i)}\}$ 的分量为 $r_i = (I_n - H_{(i)})x_i$, 则我们有:

$$\begin{aligned} [(X^T X)^{-1}]_{(i,j)} &= \frac{r_i^T r_j}{\|r_i\|^2 \|r_j\|^2} \quad (\forall i, j = 1, \dots, p) \\ &\Leftrightarrow \\ (X^T X)^{-1} &= \left[\frac{r_i^T r_j}{\|r_i\|^2 \|r_j\|^2} \right]_{i,j=1}^p \end{aligned}$$

特殊地, 对于对角元我们有:

$$\begin{aligned} [(X^T X)^{-1}]_{(i,i)} &= \frac{r_i^T r_i}{\|r_i\|^2 \|r_i\|^2} = \frac{1}{\|r_i\|^2} = \frac{1}{\|(I_n - H_{(i)})x_i\|^2} = \frac{1}{x_i^T (I_n - H_{(i)})x_i} \quad (\forall i = 1, \dots, p) \\ &\Leftrightarrow \\ \text{diag}((X^T X)^{-1}) &= \text{diag} \left\{ \frac{1}{\|r_1\|^2}, \dots, \frac{1}{\|r_p\|^2} \right\} \end{aligned}$$

- **推论:**

定义变换:

$$\begin{aligned} Z &:= (I_n - \frac{1}{n} 1_n 1_n^T) X = [x_1 - \bar{x}_1 1_n, \dots, x_p - \bar{x}_p 1_n] \\ D &:= \text{diag}(Z^T Z) = \text{diag} \{ \|x_1 - \bar{x}_1 1_n\|^2, \dots, \|x_p - \bar{x}_p 1_n\|^2 \} \\ \tilde{X} &:= X D^{-\frac{1}{2}} \end{aligned}$$

则我们有:

$$\begin{aligned}
(\tilde{X}^T \tilde{X})^{-1} &= \left\{ D^{-\frac{1}{2}} (X^T X) D^{-\frac{1}{2}} \right\}^{-1} \\
&= D^{\frac{1}{2}} (X^T X)^{-1} D^{\frac{1}{2}} \\
&= \text{diag} \{ \|x_1 - \bar{x}_1 \mathbf{1}_n\|, \dots, \|x_p - \bar{x}_p \mathbf{1}_n\| \} \left[\frac{r_i^T r_j}{\|r_i\|^2 \|r_j\|^2} \right]_{i,j=1}^p \text{diag} \{ \|x_1 - \bar{x}_1 \mathbf{1}_n\|, \dots, \|x_p - \bar{x}_p \mathbf{1}_n\| \} \\
&= \left[\|x_i - \bar{x}_i \mathbf{1}_n\| \frac{r_i^T r_j}{\|r_i\|^2 \|r_j\|^2} \|x_j - \bar{x}_j \mathbf{1}_n\| \right]_{i,j=1}^p
\end{aligned}$$

因此其对角元为:

$$[(\tilde{X}^T \tilde{X})^{-1}]_{(i,i)} = \frac{\|x_i - \bar{x}_i \mathbf{1}_n\|^2}{\|r_i\|^2} \quad (i = 1, \dots, p)$$

证明:

在 $x_1, \dots, x_p$ 线性无关的假设下, $r_1, \dots, r_p$ 也构成 $\text{span}\{x_1, \dots, x_p\}$ 的一组基.

我们设:

$$\begin{aligned}
A &= [a_{ij}]_{i,j=1}^p \text{ such that } X = [x_1, \dots, x_p] = [r_1, \dots, r_p]A = RA \\
B &= [b_{ij}]_{i,j=1}^p \text{ such that } R = [r_1, \dots, r_p] = [x_1, \dots, x_p]B = XB
\end{aligned}$$

根据基变换的性质可知 $B = A^{-1}$

- 一方面, 注意到 $r_i^T x_j = \begin{cases} 0 & \text{if } i \neq j \\ r_i^T r_i = \|r_i\|^2 & \text{if } i = j \end{cases}$

因此我们有:

$$\begin{aligned}
x_i^T x_j &= x_i^T \left(\sum_{k=1}^p a_{kj} r_k \right) \\
&= \sum_{k=1}^p a_{kj} x_i^T r_k \quad (\text{note that } r_i^T x_j = \begin{cases} 0 & \text{if } i \neq j \\ r_i^T r_i = \|r_i\|^2 & \text{if } i = j \end{cases} \quad (\forall i, j = 1, \dots, p)) \\
&= a_{ij} x_i^T r_i \\
&= a_{ij} r_i^T r_i \\
&= a_{ij} \|r_i\|^2
\end{aligned}$$

因此 $a_{ij} = \frac{x_i^T x_j}{\|r_i\|^2} \quad (\forall i, j = 1, \dots, p)$

于是我们有:

$$\begin{aligned}
A &= [a_{ij}]_{i,j=1}^p \\
&= \left[\frac{x_i^T x_j}{\|r_i\|^2} \right]_{i,j=1}^p \\
&= \text{diag} \left\{ \frac{1}{\|r_1\|^2}, \dots, \frac{1}{\|r_p\|^2} \right\} [x_i^T x_j]_{i,j=1}^p \\
&= \text{diag} \left\{ \frac{1}{\|r_1\|^2}, \dots, \frac{1}{\|r_p\|^2} \right\} (X^T X)
\end{aligned}$$

- 另一方面, 我们有:

$$\begin{aligned}
r_i^T r_j &= r_i^T \left(\sum_{k=1}^n b_{kj} x_k \right) \\
&= \sum_{k=1}^n b_{kj} r_i^T x_k \quad (\forall i, j = 1, \dots, p) \\
&= b_{ij} r_i^T x_i \\
&= b_{ij} r_i^T r_i \\
&= b_{ij} \|r_i\|^2
\end{aligned}$$

因此 $b_{ij} = \frac{r_i^T r_j}{\|r_i\|^2} \quad (\forall i, j = 1, \dots, p)$

于是我们有:

$$\begin{aligned}
B &= [b_{ij}]_{i,j=1}^p \\
&= \left[\frac{r_i^T r_j}{\|r_i\|^2} \right]_{i,j=1}^p \\
&= \text{diag} \left\{ \frac{1}{\|r_1\|^2}, \dots, \frac{1}{\|r_p\|^2} \right\} [r_i^T r_j]_{i,j=1}^p \\
&= \text{diag} \left\{ \frac{1}{\|r_1\|^2}, \dots, \frac{1}{\|r_p\|^2} \right\} (R^T R)
\end{aligned}$$

根据 $A = B^{-1}$ 可知:

$$BA = \text{diag} \left\{ \frac{1}{\|r_1\|^2}, \dots, \frac{1}{\|r_p\|^2} \right\} (R^T R) \text{diag} \left\{ \frac{1}{\|r_1\|^2}, \dots, \frac{1}{\|r_p\|^2} \right\} (X^T X) = I_n$$

因此我们有:

$$(X^T X)^{-1} = \text{diag} \left\{ \frac{1}{\|r_1\|^2}, \dots, \frac{1}{\|r_p\|^2} \right\} (R^T R) \text{diag} \left\{ \frac{1}{\|r_1\|^2}, \dots, \frac{1}{\|r_p\|^2} \right\} = \left[\frac{r_i^T r_j}{\|r_i\|^2 \|r_j\|^2} \right]_{i,j=1}^p$$

命题得证.

将设计矩阵按列记为 $X := [x_0, x_1, \dots, x_p] \in \mathbb{R}^{n \times (p+1)}$ (其中 $x_0 = 1_n$)

记 $X_{(i)} \in \mathbb{R}^{n \times p}$ 为 X 删去第 i 列 x_i 后得到的矩阵.

记 $\text{span}\{X_{(i)}\}$ 的投影算子为 $H_{(i)} := X_{(i)} [X_{(i)}^T X_{(i)}]^{-1} X_{(i)}^T$

记 x_i 垂直于 $\text{span}\{X_{(i)}\}$ 的分量为 $r_i = (I_n - H_{(i)})x_i$, 则我们有:

$$[(X^T X)^{-1}]_{(i+1, j+1)} = \frac{r_i^T r_j}{\|r_i\|^2 \|r_j\|^2} \quad (\forall i, j = 0, 1, \dots, p)$$

特殊地, 对于对角元我们有:

$$[(X^T X)^{-1}]_{(i+1, i+1)} = \frac{r_i^T r_i}{\|r_i\|^2 \|r_i\|^2} = \frac{1}{\|r_i\|^2} = \frac{1}{\|(I_n - H_{(i)})x_i\|^2} = \frac{1}{x_i^T (I_n - H_{(i)})x_i} \quad (\forall i = 0, 1, \dots, p)$$

• 推论:

定义变换:

$$Z := [1_n, x_1 - \bar{x}_1 1_n, \dots, x_p - \bar{x}_p 1_n]$$

$$D := \text{diag}(Z^T Z) = \text{diag}\{1, \|x_1 - \bar{x}_1 1_n\|^2, \dots, \|x_p - \bar{x}_p 1_n\|^2\}$$

$$\tilde{X} := XD^{-\frac{1}{2}}$$

则我们有:

$$\begin{aligned}
(\tilde{X}^T \tilde{X})_{(2:p+1, 2:p+1)}^{-1} &= \left\{ D^{-\frac{1}{2}} (X^T X) D^{-\frac{1}{2}} \right\}_{(2:p+1, 2:p+1)}^{-1} \\
&= \left\{ D^{\frac{1}{2}} (X^T X)^{-1} D^{\frac{1}{2}} \right\}_{(2:p+1, 2:p+1)} \\
&= \text{diag}\{\|x_1 - \bar{x}_1 1_n\|^2, \dots, \|x_p - \bar{x}_p 1_n\|^2\} \left[\frac{r_i^T r_j}{\|r_i\|^2 \|r_j\|^2} \right]_{i,j=1}^p \text{diag}\{\|x_1 - \bar{x}_1 1_n\|^2, \dots, \|x_p - \bar{x}_p 1_n\|^2\} \\
&= \left[\|x_i - \bar{x}_i 1_n\|^2 \frac{r_i^T r_j}{\|r_i\|^2 \|r_j\|^2} \|x_j - \bar{x}_j 1_n\|^2 \right]_{i,j=1}^p
\end{aligned}$$

因此其对角元为:

$$[(\tilde{X}^T \tilde{X})^{-1}]_{(i+1, i+1)} = \frac{\|x_i - \bar{x}_i 1_n\|^2}{\|r_i\|^2} = \frac{\|x_i - \bar{x}_i 1_n\|^2}{\|(I_n - H_{(i)})x_i\|^2} \quad (i = 1, \dots, p)$$

考虑多元线性回归模型 $y = X\beta + \varepsilon$ (where $\begin{cases} E[\varepsilon] = 0_n \\ \text{Cov}[\varepsilon] = \sigma^2 I_n \end{cases}$) 的最小二乘估计量 $\hat{\beta} = (X^T X)^{-1} X^T y$

其协方差为:

$$\begin{aligned}
\text{Cov}[\hat{\beta}] &= \text{Cov}[(X^T X)^{-1} X^T y] \\
&= \text{Cov}[(X^T X)^{-1} X^T (X\beta + \varepsilon)] \\
&= \text{Cov}[\beta + (X^T X)^{-1} X^T \varepsilon] \\
&= (X^T X)^{-1} X^T \text{Cov}[\varepsilon] X (X^T X)^{-1} \\
&= (X^T X)^{-1} X^T \cdot \sigma^2 I_n \cdot X (X^T X)^{-1} \\
&= \sigma^2 (X^T X)^{-1}
\end{aligned}$$

因此对于 $\hat{\beta} = [\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_p]^T$ 的每个分量都有:

$$\text{Var}(\hat{\beta}_i) = \sigma^2 [(X^T X)^{-1}]_{(i+1, i+1)} = \sigma^2 \frac{1}{\|(I_n - H_{(i)})x_i\|^2} \quad (i = 0, 1, \dots, p)$$

这说明当 x_i 与 $X_{(i)}$ 之间存在多重共线性关系 (即 $(I_n - H_{(i)})x_i \approx 0_n$, 也即 x_i 几乎包含在 $\text{span}\{X_{(i)}\}$ 中) 时, 参数 β_i 的估计量 $\hat{\beta}_i$ 的方差会非常大, 波动性会很强, 模型的泛化能力可能会很差.

直观判断:

- ① 在减少或增加解释变量时, 若估计量 $\hat{\beta}$ 的某些分量变化很大, 则存在多重共线性的可能.
- ② 在估计量 $\hat{\beta}$ 的协方差矩阵中, 若某些方差项或协方差项很大, 则存在多重共线性的可能.
- ③ 若 $\hat{\beta}$ 的某些分量的绝对值很大 (表明对应的解释变量很重要), 但相应的回归系数的显著性 t 检验没有通过 (表明对应的解释变量不重要, 产生矛盾), 则我们认为存在多重共线性的可能.

3.1.2 检验

我们使用**方差膨胀因子** VIF (Variance Inflation Factor) 来刻画多重共线性的严重程度.

将设计矩阵按列记为 $X := [x_0, x_1, \dots, x_p] \in \mathbb{R}^{n \times (p+1)}$ (其中 $x_0 = 1_n$)

记 $X_{(j)} \in \mathbb{R}^{n \times p}$ 为 X 删去第 j 列 x_j 后得到的矩阵.

记 $\text{span}\{X_{(j)}\}$ 的投影算子为 $H_{(j)} := X_{(j)}[X_{(j)}^T X_{(j)}]^{-1} X_{(j)}^T$

考虑使用多元线性回归模型表征 x_j 与 $X_{(j)}$ 之间的线性相关性, 定义:

(不需要计算截距项的方差膨胀因子, 因此 $j = 1, \dots, p$, (**存疑**) 实际上设计矩阵的第一列 1_n 也不用加, 不过那样比较麻烦)

$$\begin{aligned}
\text{SST}_j &:= \|x_j - \bar{x}_j 1_n\|^2 \\
&= \|x_j - \frac{1}{n} 1_n 1_n^T x_j\|^2 \\
&= x_j^T (I_n - \frac{1}{n} 1_n 1_n^T) x_j \\
&= \|x_j - \mathbb{E}[x_j]\|^2 \\
&= \text{tr}(\text{Cov}(x_j)) \\
\text{SSR}_j &:= \|\hat{x}_j - \bar{x}_j 1_n\|^2 \\
&= \|H_{(j)} x_j - \frac{1}{n} 1_n 1_n^T x_j\|^2 \\
&= x_j^T (H_{(j)} - \frac{1}{n} 1_n 1_n^T) x_j \\
&= \|\mathbb{E}[x_j | X_{(j)}] - \mathbb{E}[x_j]\|^2 \\
\text{SSE}_j &:= \|x_j - \hat{x}_j\|^2 \\
&= \|x_j - H_{(j)} x_j\|^2 \\
&= x_j^T (I_n - H_{(j)}) x_j \\
&= \|x_j - \mathbb{E}[x_j | X_{(j)}]\|^2 \\
&= \text{tr}(\text{Cov}(x_j | X_{(j)}))
\end{aligned}$$

定义决定系数 $R_j^2 := \frac{\text{SSR}_j}{\text{SST}_j}$, 则 $(x_j, X_{(j)})$ 的方差膨胀因子 VIF_j 定义如下:

$$\begin{aligned}
\text{VIF}_j &:= \frac{1}{1 - R_j^2} \\
&= \frac{1}{1 - \frac{\text{SSR}_j}{\text{SST}_j}} \quad (\text{note that } \text{SST}_j = \text{SSE}_j + \text{SSR}_j) \\
&= \frac{\text{SST}_j}{\text{SSE}_j} \in [1, +\infty) \quad (\text{note that } \text{SST}_j \geq \text{SSE}_j) \\
&= \frac{x_j^T (I_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^T) x_j}{x_j^T (I_n - H_{(j)}) x_j} \quad (\forall j = 1, \dots, p) \\
&= \frac{\text{tr}(\text{Cov}(x_j))}{\text{tr}(\text{Cov}(x_j | X_{(j)}))} \\
&= \text{Estimator of } \left\{ \frac{\text{Var}(X_j)}{\text{Var}(X_j | \{X_1, \dots, X_p\} \setminus \{X_j\})} \right\}
\end{aligned}$$

我们可以看出 VIF_j 是 $\frac{\text{Var}(X_j)}{\text{Var}(X_j | \{X_1, \dots, X_p\} \setminus \{X_j\})}$ 的矩估计量，这就是 "方差膨胀因子" 名称的由来。

它的数值反映了第 j 个解释变量的方差膨胀程度。

当 $\text{VIF}_j \geq 20$ ，则我们认为第 j 个解释变量与其余解释变量之间有严重的多重共线性。

当平均方差膨胀因子 $\frac{1}{p} \sum_{j=1}^p \text{VIF}_j$ 较大时，我们也认为设计矩阵 X 具有严重的多重共线性。

此外，我们发现：

$$\begin{aligned}
\text{Var}(\hat{\beta}_j) &= \sigma^2 [(X^T X)^{-1}]_{(j+1, j+1)} \\
&= \sigma^2 \frac{1}{\|(I_n - H_{(j)}) x_j\|^2} \\
&= \sigma^2 \frac{1}{x_j^T (I_n - H_{(j)}) x_j} \quad (\forall j = 1, \dots, p) \\
&= \sigma^2 \frac{1}{\text{SSE}_{(j)}} \quad (\text{note that } \text{VIF}_j = \frac{\text{SST}_j}{\text{SSE}_j}) \\
&= \sigma^2 \frac{\text{VIF}_j}{\text{SST}_j}
\end{aligned}$$

因此 VIF_j 可以刻画参数 β_j 的估计量 $\hat{\beta}_j$ 的波动性。

这也提供了计算方差膨胀因子的简便方法：

$$\begin{aligned}
\text{VIF}_j &= \frac{\text{SST}_j}{\text{SSE}_j} \quad (\text{note that } [(X^T X)^{-1}]_{(j+1, j+1)} = \frac{1}{x_j^T (I_n - H_{(j)}) x_j} = \frac{1}{\text{SSE}_j}) \\
&= \text{SST}_j [(X^T X)^{-1}]_{(j+1, j+1)} \quad (\forall j = 1, \dots, p)
\end{aligned}$$

更深刻地，我们可以做变换：

$$\begin{aligned}
Z &:= [1_n, x_1 - \bar{x}_1 \mathbf{1}_n, \dots, x_p - \bar{x}_p \mathbf{1}_n] \\
D &:= \text{diag}(Z^T Z) = \text{diag}\{1, \|x_1 - \bar{x}_1 \mathbf{1}_n\|^2, \dots, \|x_p - \bar{x}_p \mathbf{1}_n\|^2\} \\
\tilde{X} &:= X D^{-\frac{1}{2}}
\end{aligned}$$

则根据 3.1.1 节的结论我们有：

$$[(\tilde{X}^T \tilde{X})^{-1}]_{(j+1, j+1)} = \frac{\|x_j - \bar{x}_j \mathbf{1}_n\|^2}{\|r_j\|^2} = \frac{\|x_j - \bar{x}_j \mathbf{1}_n\|^2}{\|(I_n - H_{(j)}) x_j\|^2} = \frac{\text{SST}_j}{\text{SSE}_j} \quad (j = 1, \dots, p)$$

因此我们有：

$$\text{VIF}_j = \frac{\text{SST}_j}{\text{SSE}_j} = [(\tilde{X}^T \tilde{X})^{-1}]_{(j+1, j+1)} \quad (j = 1, \dots, p)$$

实际上 $X^T X$ 有多少个特征值近似为 0， X 的列之间就有多少个多重共线性关系。

具体来说，如果 (λ, η) 为 $X^T X$ 的一个特征对 (满足 $\lambda \approx 0$ 和 $\|\eta\|_2 = 1$)，我们就有：

$$\begin{aligned}
\|X\eta\|_2^2 &= \eta^T (X^T X) \eta \quad (\text{note that } (X^T X)\eta = \eta\lambda) \\
&= \eta^T \eta \lambda \quad (\text{note that } \|\eta\|_2 = 1) \\
&= \lambda \\
&\approx 0
\end{aligned}$$

于是有 $X\eta = \eta_0 1_n + \eta_1 x_1 + \cdots + \eta_p x_p \approx 0_n$ 成立.

注意到 $X^T X$ 是对称阵 (自然是正规矩阵), 因此可以酉对角化 (自然可以相似对角化)

于是 $X^T X$ 的任意特征值的几何重数都等于代数重数.

若 $X^T X$ 有 k 个特征值 (计代数重数) 近似为 0, 则这些特征值对应的特征空间的和是一个 k 维向量空间.

于是从某种意义上说, 我们有 k 个多重共线性关系.

我们还可以根据条件数 $\kappa_2(X) = \|X\|_2 \|X^{-1}\|_2 = \sqrt{\frac{\lambda_{\max}(X^T X)}{\lambda_{\min}(X^T X)}}$ 来刻画多重共线性的严重程度.

当 $0 < \kappa_2(X^T X) < 10$ 时, 可以认为不存在多重共线性.

当 $10 \leq \kappa_2(X^T X) < 100$ 时, 可以认为存在多重共线性.

当 $\kappa_2(X^T X) \geq 100$ 时, 可以认为存在严重的多重共线性.

3.1.3 处理方法

若原始模型存在多重共线性, 则我们可以剔除方差膨胀因子最大的解释变量, 重新建立线性回归模型.

上述过程可以重复进行, 直至不存在严重的多重共线性为止.

我们还可以结合之前学过的回归系数显著性检验、模型选择等知识, 以及问题的实际背景, 对解释变量进行筛选和剔除.

实际问题中, 当样本数量 n 过小时, 也容易产生多重共线性, 因此我们可以适当增加样本数量.

事实上, 增大样本数量可以减小最小二乘估计量 $\hat{\beta} = (X^T X)^{-1} X^T y$ 的方差:

$$\begin{aligned} \text{tr}(\text{Cov}(\hat{\beta})) &= \text{tr}(\sigma^2 (X^T X)^{-1}) \\ &= \sigma^2 \text{tr}((X^T X)^{-1}) \rightarrow 0 \quad (n \rightarrow \infty) \end{aligned}$$

尽管最小二乘估计量 $\hat{\beta} = (X^T X)^{-1} X^T y$ 作为 β 的无偏估计量有着良好的性质, 但我们也不必局限于此.

事实上, 有很多方法 (例如 Ridge 回归、偏最小二乘法等) 以牺牲无偏性为代价,

对最小二乘估计量进行改进, 以提高估计量的稳定性.

3.2 岭回归

3.2.1 岭估计量

考虑多元线性回归模型 $y = X\beta + \varepsilon$

其中 $y \in \mathbb{R}^n$, $X \in \mathbb{R}^{n \times (p+1)}$, $\varepsilon \sim N(0_n, \sigma^2 I_n)$

岭回归以牺牲无偏性为代价, 将最小二乘估计量 $\hat{\beta}_{\text{LSE}} := (X^T X)^{-1} X^T y$ 改进为 $\hat{\beta}_{\text{Ridge}}(\lambda) := (X^T X + \lambda I_{p+1})^{-1} X^T y$

其中 $\lambda > 0$ 称为岭回归的正则化系数, 用于提高估计量的稳定性.

它还有另一种等价的表示形式: (但计算复杂度更高, 如果 $n > p + 1$ 的话)

$$\begin{aligned} \hat{\beta}_{\text{Ridge}}(\lambda) &:= (X^T X + \lambda I_{p+1})^{-1} X^T y \\ &= (X^T X + \lambda I_{p+1})^{-1} X^T (X X^T + \lambda I_n)(X X^T + \lambda I_n)^{-1} y \\ &= (X^T X + \lambda I_{p+1})^{-1} (X^T X X^T + \lambda X^T)(X X^T + \lambda I_n)^{-1} y \\ &= (X^T X + \lambda I_{p+1})^{-1} (X^T X + \lambda I_{p+1}) X^T (X X^T + \lambda I_n)^{-1} y \\ &= X^T (X X^T + \lambda I_n)^{-1} y \end{aligned}$$

我们可以将最小二乘估计量 $\hat{\beta}_{\text{LSE}}$ 视为岭估计量 $\hat{\beta}_{\text{Ridge}}(\lambda)$ 的特殊情况:

$$\hat{\beta}_{\text{LSE}} = (X^T X)^{-1} X^T y = \hat{\beta}_{\text{Ridge}}(0)$$

岭估计量 $\hat{\beta}_{\text{Ridge}}(\lambda)$ 可以表示为最小二乘估计量 $\hat{\beta}_{\text{LSE}}$ 的线性组合:

$$\begin{aligned} \hat{\beta}_{\text{Ridge}}(\lambda) &= (X^T X + \lambda I)^{-1} X^T y \\ &= (X^T X + \lambda I)^{-1} (X^T X) (X^T X)^{-1} X^T y \\ &= (X^T X + \lambda I)^{-1} (X^T X) \hat{\beta}_{\text{LSE}} \end{aligned}$$

其中算子 $(X^T X + \lambda I)^{-1} (X^T X)$ 的作用是对 $\hat{\beta}_{\text{LSE}}$ 进行压缩.

(值得注意的是, 在实际应用中最优的 λ 的选取通常依赖于样本, 因此本质上 $\hat{\beta}_{\text{Ridge}}(\lambda)$ 并非 $\hat{\beta}_{\text{LSE}}$ 的线性组合)

设 $X^T X \in \mathbb{R}^{(p+1) \times (p+1)}$ 的谱分解为 $X^T X = UDU^T$

其中 $U \in \mathbb{R}^{n \times n}$ 为实正交阵, $D := \text{diag}\{d_1, \dots, d_{p+1}\}$ 为具有正实数对角元的对角阵.

于是我们有:

$$\begin{aligned}(X^T X + \lambda I)^{-1}(X^T X) &= (UDU^T + \lambda I)^{-1}(UDU^T) \\ &= U(D + \lambda I)^{-1}U^T UDU^T \\ &= U(D + \lambda I)^{-1}DU^T \\ &= U \cdot \text{diag}\left\{\frac{d_1}{d_1 + \lambda}, \dots, \frac{d_{p+1}}{d_{p+1} + \lambda}\right\} \cdot U^T\end{aligned}$$

这表明算子 $(X^T X + \lambda I)^{-1}(X^T X)$ 的特征值均属于 $(0, 1)$ 区间,

因此其作用是把 $\hat{\beta}_{\text{LSE}}$ 往 0_{p+1} 压缩, 压缩程度取决于 λ 的大小.

换言之, 当 $\|\hat{\beta}_{\text{LSE}}\| > 0$ 时, 对于任意 $\lambda > 0$ 我们都有 $\|\hat{\beta}_{\text{Ridge}}(\lambda)\| < \|\hat{\beta}_{\text{LSE}}\|$ 成立, 且 $\lim_{\lambda \rightarrow \infty} \|\hat{\beta}_{\text{Ridge}}(\lambda)\| = 0$

我们还可将岭估计量 $\hat{\beta}_{\text{Ridge}}(\lambda) := (X^T X + \lambda I)^{-1} X^T y$ 视为以下优化问题的最优解:

$$\min_{\beta \in \mathbb{R}^{p+1}} \{\|y - X\beta\|^2 + \lambda\|\beta\|^2\} \quad (\text{where } \lambda > 0 \text{ is a given constant})$$

这相当于在最小二乘问题的基础上加了一个 l_2 正则项 $\lambda\|\beta\|^2$, 对估计量的大小进行了限制.

注意到目标函数关于 β 的梯度为:

$$\begin{aligned}\nabla_{\beta}\{\|y - X\beta\|^2 + \lambda\|\beta\|^2\} &= -2X^T(y - X\beta) + 2\lambda\beta \\ &= 2(X^T X + \lambda I)\beta - 2X^T y\end{aligned}$$

令 $\nabla_{\beta}\{\|y - X\beta\|^2 + \lambda\|\beta\|^2\} = 2(X^T X + \lambda I)\beta - 2X^T y = 0_{p+1}$ 就得到 $\hat{\beta}_{\text{Ridge}}(\lambda) = (X^T X + \lambda I)^{-1} X^T y$

3.2.2 偏差-方差

对于最小二乘估计量 $\hat{\beta}_{\text{LSE}} := \hat{\beta}_{\text{Ridge}}(0) = (X^T X)^{-1} X^T y$ 我们有:

$$\begin{cases} \mathbb{E}[\hat{\beta}_{\text{LSE}}] = \beta \\ \text{Cov}(\hat{\beta}_{\text{LSE}}) = \sigma^2(X^T X)^{-1} \end{cases}$$

对于岭估计量 $\hat{\beta}_{\text{Ridge}}(\lambda) = (X^T X + \lambda I)^{-1} X^T y$ 我们有:

(记 $(X^T X) \in \mathbb{R}^{(p+1) \times (p+1)}$ 的谱分解为 $X^T X = UDU^T$)

$$\begin{aligned}\hat{\beta}_{\text{Ridge}}(\lambda) &= (X^T X + \lambda I)^{-1} X^T y \\ &= (X^T X + \lambda I)^{-1} (X^T X) (X^T X)^{-1} X^T y \\ &= (X^T X + \lambda I)^{-1} (X^T X) \hat{\beta}_{\text{LSE}}\end{aligned}$$

$$\begin{aligned}\mathbb{E}[\hat{\beta}_{\text{Ridge}}(\lambda)] &= \mathbb{E}[(X^T X + \lambda I)^{-1} (X^T X) \hat{\beta}_{\text{LSE}}] \\ &= (X^T X + \lambda I)^{-1} (X^T X) \mathbb{E}[\hat{\beta}_{\text{LSE}}] \\ &= (X^T X + \lambda I)^{-1} (X^T X) \beta \\ &\neq \beta\end{aligned}$$


$$\begin{aligned}\text{bias}^2(\hat{\beta}_{\text{Ridge}}(\lambda)) &= \|\mathbb{E}[\hat{\beta}_{\text{Ridge}}(\lambda)] - \beta\|^2 \\ &= \|(X^T X + \lambda I)^{-1} (X^T X) \beta - \beta\|^2 \\ &= \|(X^T X + \lambda I)^{-1} (X^T X) \beta - (X^T X + \lambda I)^{-1} (X^T X + \lambda I) \beta\|^2 \\ &= \|(X^T X + \lambda I)^{-1} \lambda I \beta\|^2 \\ &= \|\lambda (X^T X + \lambda I)^{-1} \beta\|^2 \\ &= \|\lambda (UDU^T + \lambda I)^{-1} \beta\|^2 \\ &= \|\lambda U(D + \lambda I)^{-1} U^T \beta\|^2 \quad (\text{note that } l_2 \text{ norm is unitary invariant}) \\ &= \|\lambda (D + \lambda I)^{-1} U^T \beta\|^2 \\ &= \left\| \text{diag}\left\{\frac{\lambda}{d_1 + \lambda}, \dots, \frac{\lambda}{d_{p+1} + \lambda}\right\} U^T \beta \right\|^2 \\ &< \|U^T \beta\|^2 \\ &= \|\beta\|^2\end{aligned}$$

这表明岭估计量 $\hat{\beta}_{\text{Ridge}}(\lambda)$ 不再是 β 的无偏估计量.

$$\begin{aligned}
\text{Cov}[\hat{\beta}_{\text{Ridge}}(\lambda)] &= \text{Cov}[(X^T X + \lambda I)^{-1}(X^T X)\hat{\beta}_{\text{LSE}}] \\
&= (X^T X + \lambda I)^{-1}(X^T X) \cdot \text{Cov}[\hat{\beta}_{\text{LSE}}] \cdot (X^T X)(X^T X + \lambda I)^{-1} \\
&= (X^T X + \lambda I)^{-1}(X^T X) \cdot \sigma^2(X^T X)^{-1} \cdot (X^T X)(X^T X + \lambda I)^{-1} \\
&= \sigma^2(X^T X + \lambda I)^{-1}(X^T X)(X^T X + \lambda I)^{-1} \\
\hline
\text{tr}(\text{Cov}[\hat{\beta}_{\text{Ridge}}(\lambda)]) &= \text{tr}(\sigma^2(X^T X + \lambda I)^{-1}(X^T X)(X^T X + \lambda I)^{-1}) \\
&= \sigma^2 \text{tr}((X^T X + \lambda I)^{-2}(X^T X)) \\
&= \sigma^2 \text{tr}((UDU^T + \lambda I)^{-2}(UDU^T)) \\
&= \sigma^2 \text{tr}(U(D + \lambda I)^{-2}U^T UDU^T) \\
&= \sigma^2 \text{tr}(U(D + \lambda I)^{-2}DU^T) \\
&= \sigma^2 \text{tr}((D + \lambda I)^{-2}DU^T U) \\
&= \sigma^2 \text{tr}((D + \lambda I)^{-2}D) \\
&= \sigma^2 \text{tr}((D + \lambda I)^{-2}D^2 \cdot D^{-1}) \\
&< \sigma^2 \text{tr}(D^{-1}) \\
&= \sigma^2 \text{tr}(D^{-1}U^T U) \\
&= \sigma^2 \text{tr}(UD^{-1}U^T) \\
&= \text{tr}(\sigma^2(X^T X)^{-1}) \\
&= \text{tr}(\text{Cov}[\hat{\beta}_{\text{LSE}}])
\end{aligned}$$

这表明岭估计量 $\hat{\beta}_{\text{Ridge}}(\lambda)$ 的稳定性要优于最小二乘估计量 $\hat{\beta}_{\text{LSE}}$

岭估计量 $\hat{\beta}_{\text{Ridge}}(\lambda)$ 的偏差平方 $\text{bias}^2(\hat{\beta}_{\text{Ridge}}(\lambda))$ 和方差 $\text{tr}(\text{Cov}[\hat{\beta}_{\text{Ridge}}(\lambda)])$ 关于 λ 的变换图像大致是这样的:



3.2.3 均方误差

考虑均方误差:

$$\begin{aligned}
\text{MSE}[\hat{\beta}_{\text{Ridge}}(\lambda)] &= \text{E}[\|\hat{\beta}_{\text{Ridge}}(\lambda) - \beta\|^2] \\
&= \text{E}[\|\hat{\beta}_{\text{Ridge}}(\lambda) - \text{E}[\hat{\beta}_{\text{Ridge}}(\lambda)] + \text{E}[\hat{\beta}_{\text{Ridge}}(\lambda)] - \beta\|^2] \\
&= \text{E}[\|\hat{\beta}_{\text{Ridge}}(\lambda) - \text{E}[\hat{\beta}_{\text{Ridge}}(\lambda)]\|^2] + \|\text{E}[\hat{\beta}_{\text{Ridge}}(\lambda)] - \beta\|^2 \\
&= \text{tr}(\text{Cov}[\hat{\beta}_{\text{Ridge}}(\lambda)]) + \text{bias}^2(\hat{\beta}_{\text{Ridge}}(\lambda)) \\
&= \text{tr}\{(X^T X + \lambda I)^{-1} X^T \text{Cov}(y) X (X^T X + \lambda I)^{-1}\} + \|(X^T X + \lambda I)^{-1} X^T X \beta - \beta\|^2 \\
&= \text{tr}\{(X^T X + \lambda I)^{-1} X^T \cdot \sigma^2 I_n \cdot X (X^T X + \lambda I)^{-1}\} + \|\lambda(X^T X + \lambda I)^{-1} \beta\|^2 \\
&= \sigma^2 \text{tr}((X^T X + \lambda I)^{-2}(X^T X)) + \lambda^2 \beta^T (X^T X + \lambda I)^{-2} \beta \\
\hline
\text{MSE}[\hat{\beta}_{\text{LSE}}] &= \text{E}[\|\hat{\beta}_{\text{LSE}} - \beta\|^2] \\
&= \text{E}[\|\hat{\beta}_{\text{LSE}} - \text{E}[\hat{\beta}_{\text{LSE}}] + \text{E}[\hat{\beta}_{\text{LSE}}] - \beta\|^2] \\
&= \text{E}[\|\hat{\beta}_{\text{LSE}} - \text{E}[\hat{\beta}_{\text{LSE}}]\|^2] + \|\text{E}[\hat{\beta}_{\text{LSE}}] - \beta\|^2 \\
&= \text{tr}(\text{Cov}[\hat{\beta}_{\text{LSE}}]) + \text{bias}^2(\hat{\beta}_{\text{LSE}}) \\
&= \text{tr}(\sigma^2(X^T X)^{-1}) + 0^2 \\
&= \sigma^2 \text{tr}((X^T X)^{-1})
\end{aligned}$$

设 $X^T X \in \mathbb{R}^{(p+1) \times (p+1)}$ 的谱分解为 $X^T X = UDU^T$
 其中 $U \in \mathbb{R}^{(p+1) \times (p+1)}$ 为正交阵, $D = \text{diag}\{d_1, \dots, d_{p+1}\}$ 为对角阵.
 于是我们有:

$$\begin{aligned} \text{MSE}[\hat{\beta}_{\text{Ridge}}(\lambda)] &= \sigma^2 \text{tr}((X^T X + \lambda I)^{-2}(X^T X)) + \lambda^2 \beta^T (X^T X + \lambda I)^{-2} \beta \\ &= \sigma^2 \text{tr}((UDU^T + \lambda I)^{-2}UDU) + \lambda^2 \beta^T (UDU^T + \lambda I)^{-2} \beta \\ &= \sigma^2 \text{tr}(U(D + \lambda I)^{-2}DU^T) + \lambda^2 \beta^T U(D + \lambda I)^{-2}U^T \beta \\ &= \sigma^2 \text{tr}((D + \lambda I)^{-2}D) + \lambda^2 \beta^T U(D + \lambda I)^{-2}U^T \beta \end{aligned}$$

我们断言存在某个 $\lambda > 0$ 使得 $\text{MSE}[\hat{\beta}_{\text{Ridge}}(\lambda)] < \text{MSE}[\hat{\beta}_{\text{LSE}}]$

注意到最小二乘估计量 $\hat{\beta}_{\text{LSE}} = (X^T X)^{-1} X^T y = \hat{\beta}_{\text{Ridge}}(0)$, 即 Ridge 估计量 $\lambda = 0$ 的情形.

因此要证明存在某个 $\lambda > 0$ 使得 $\text{MSE}[\hat{\beta}_{\text{Ridge}}(\lambda)] < \text{MSE}[\hat{\beta}_{\text{LSE}}]$,

我们只要证明 $\text{MSE}[\hat{\beta}_{\text{Ridge}}(\lambda)]$ 关于 λ 的导数在 $\lambda = 0$ 处为负值即可.

$$\begin{aligned} \frac{d}{d\lambda} \text{MSE}[\hat{\beta}_{\text{Ridge}}(\lambda)] &= \frac{d}{d\lambda} \{ \sigma^2 \text{tr}((D + \lambda I)^{-2}D) + \lambda^2 \beta^T U(D + \lambda I)^{-2}U^T \beta \} \\ &= -2\sigma^2 \text{tr}((D + \lambda I)^{-3}D) + 2\lambda \beta^T U(D + \lambda I)^{-2}U^T \beta + \lambda^2 \cdot (-2\beta^T U(D + \lambda I)^{-3}U^T \beta) \end{aligned}$$

$$\begin{aligned} \left. \frac{d}{d\lambda} \text{MSE}[\hat{\beta}_{\text{Ridge}}(\lambda)] \right|_{\lambda=0} &= -2\sigma^2 \text{tr}(D^{-3}D) + 0 + 0 \\ &= -2\sigma^2 \text{tr}(D^{-2}) \\ &< 0 \end{aligned}$$

尽管根据 Gauss-Markov 定理, 最小二乘估计量 $\hat{\beta}_{\text{LSE}}$ 是线性无偏估计量中方差最小的, 即均方差最小的 (因为此时偏差为 0)

但我们可以通过牺牲无偏性 (例如岭估计量 $\hat{\beta}_{\text{Ridge}}(\lambda)$) 来获得更低的均方差, 这可能会带来更好的预测性能.

下图清晰地展示了有偏估计量优于无偏估计量的情形:




图 7-7

特殊地, 当 $X^T X = I_{p+1}$ (存疑: 这个假设不可能成立?) 时, 我们有:

$$\begin{aligned} \text{MSE}[\hat{\beta}_{\text{Ridge}}(\lambda)] &= \sigma^2 \text{tr}((X^T X + \lambda I_{p+1})^{-2}(X^T X)) + \lambda^2 \beta^T (X^T X + \lambda I_{p+1})^{-2} \beta \\ &= \sigma^2 \text{tr}((I_{p+1} + \lambda I_{p+1})^{-2}I_{p+1}) + \lambda^2 \beta^T (I_{p+1} + \lambda I_{p+1})^{-2} \beta \\ &= \sigma^2(p+1) \frac{1}{(1+\lambda)^2} + \|\beta\|^2 \frac{\lambda^2}{(1+\lambda)^2} \end{aligned}$$

$$\begin{aligned} \text{MSE}[\hat{\beta}_{\text{LSE}}] &= \sigma^2 \text{tr}((X^T X)^{-1}) \\ &= \sigma^2 \text{tr}((I_{p+1})^{-1}) \\ &= \sigma^2(p+1) \end{aligned}$$

- 假设 $\|\beta\|^2 > \sigma^2(p+1)$ (这个假设是否成立?), 令 $\text{MSE}[\hat{\beta}_{\text{Ridge}}(\lambda)] = \text{MSE}[\hat{\beta}_{\text{LSE}}]$ 解得 $\lambda_{\max} = \frac{2\sigma^2(p+1)}{\|\beta\|^2 - \sigma^2(p+1)} > 0$
 因此 $\text{MSE}[\hat{\beta}_{\text{Ridge}}(\lambda)]$ 曲线在 $\lambda_{\max} = \frac{2\sigma^2(p+1)}{\|\beta\|^2 - \sigma^2(p+1)} > 0$ 处与 $\text{MSE}[\hat{\beta}_{\text{LSE}}] = \sigma^2(p+1)$ 相等.
- 计算 $\text{MSE}[\hat{\beta}_{\text{Ridge}}(\lambda)]$ 关于 λ 的导数:


$$\begin{aligned}
\frac{d}{d\lambda} \text{MSE}[\hat{\beta}_{\text{Ridge}}(\lambda)] &= \frac{d}{d\lambda} \left\{ \sigma^2(p+1) \frac{1}{(1+\lambda)^2} + \|\beta\|^2 \frac{\lambda^2}{(1+\lambda)^2} \right\} \\
&= \sigma^2(p+1) \frac{-2}{(1+\lambda)^3} + \|\beta\|^2 \left[\frac{2\lambda}{(1+\lambda)^2} + \lambda^2 \frac{-2}{(1+\lambda)^3} \right] \\
&= -2\sigma^2(p+1) \frac{1}{(1+\lambda)^3} + 2\|\beta\|^2 \frac{\lambda}{(1+\lambda)^3} \\
\frac{d^2}{(d\lambda)^2} \text{MSE}[\hat{\beta}_{\text{Ridge}}(\lambda)] &= \frac{d}{d\lambda} \left\{ -2\sigma^2(p+1) \frac{1}{(1+\lambda)^3} + 2\|\beta\|^2 \frac{\lambda}{(1+\lambda)^3} \right\} \\
&= -2\sigma^2(p+1) \frac{-3}{(1+\lambda)^4} + 2\|\beta\|^2 \left[\frac{1}{(1+\lambda)^3} + \lambda \frac{-3}{(1+\lambda)^4} \right] \\
&= 6\sigma^2(p+1) \frac{1}{(1+\lambda)^4} + 2\|\beta\|^2 \frac{1-2\lambda}{(1+\lambda)^4}
\end{aligned}$$

因此 $\text{MSE}[\hat{\beta}_{\text{Ridge}}(\lambda)]$ 大致是一个先凸后凹的曲线。

令 $\frac{d}{d\lambda} \text{MSE}[\hat{\beta}_{\text{Ridge}}(\lambda)] = -2\sigma^2(p+1) \frac{1}{(1+\lambda)^3} + 2\|\beta\|^2 \frac{\lambda}{(1+\lambda)^3} = 0$ 解得 $\lambda_{\min} = \frac{\sigma^2(p+1)}{\|\beta\|^2}$

注意到 $\lambda_{\max} = \frac{2\sigma^2(p+1)}{\|\beta\|^2 - \sigma^2(p+1)} > \frac{\sigma^2(p+1)}{\|\beta\|^2} = \lambda_{\min}$

据此我们可以大致绘制 $\text{MSE}[\hat{\beta}_{\text{Ridge}}(\lambda)]$ 关于 λ 的图像:



同时我们发现 $\lambda_{\max} = \frac{2\sigma^2(p+1)}{\|\beta\|^2 - \sigma^2(p+1)} = \frac{2}{\frac{\|\beta\|^2}{\sigma^2(p+1)} - 1}$ 和 $\lambda_{\min} = \frac{\sigma^2(p+1)}{\|\beta\|^2}$ 都与 $\frac{\|\beta\|^2}{\sigma^2(p+1)}$ 有关。

我们定义信噪比 (Signal-to-Noise Ratio) 为 $\text{SNR} := \frac{\|\beta\|^2}{\sigma^2(p+1)} = \frac{\|\beta\|^2/(p+1)}{\sigma^2}$

对于多元线性回归模型 $y = X\beta + \varepsilon$, 我们称 $X\beta$ 为信号 (signal), ε 为噪声 (noise)

在 $X^T X = I_{k+1}$ 的条件下, 信号强度 $\|X\beta\|^2/(p+1) = (\beta^T X^T X \beta)/(p+1) = \|\beta\|^2/(p+1)$

从这个角度来看, $\text{SNR} = \frac{\|\beta\|^2/(p+1)}{\sigma^2}$ 的分子代表信号强度, 而分母 σ^2 代表噪音强度。

信噪比 $\text{SNR} = \frac{\|\beta\|^2/(p+1)}{\sigma^2}$ 越小, 则 $\lambda_{\min}$ 和 $\lambda_{\max}$ 越大,

说明用岭回归比普通最小二回归更好的参数范围 $(0, \lambda_{\max})$ 更大, 最优参数 $\lambda_{\min}$ 也较大。

此时我们会更倾向于使用岭回归。

换言之, 在噪声较大的情况下, 普通最小二回归可能会对噪声过于敏感, 而岭回归通过引入正则化项能够缓解这一问题。

3.2.4 核岭回归

岭回归的拟合值为:

$$\begin{aligned}
\hat{y} &= X\hat{\beta}_{\text{Ridge}}(\lambda) \\
&= X(X^T X + \lambda I_{p+1})^{-1} X^T y \\
&= X(X^T X + \lambda I_{p+1})^{-1} X^T (X X^T + \lambda I_n)(X X^T + \lambda I_n)^{-1} y \\
&= X(X^T X + \lambda I_{p+1})^{-1} (X^T X X^T + \lambda X^T)(X X^T + \lambda I_n)^{-1} y \\
&= X(X^T X + \lambda I_{p+1})^{-1} (X^T X + \lambda I_{p+1}) X^T (X X^T + \lambda I_n)^{-1} y \\
&= X X^T (X X^T + \lambda I_n)^{-1} y
\end{aligned}$$

记 $X \in \mathbb{R}^{n \times (p+1)}$ 的行向量为 $x_1, \dots, x_n$, 则 $XX^T = [x_i^T x_j]_{i,j=1}^n = [\langle x_i, x_j \rangle]_{i,j=1}^n$

其中 $\langle \cdot, \cdot \rangle_2$ 代表 $\mathbb{R}^{p+1}$ 上的 Euclid 内积.

如果我们定义某个核函数 $k(\cdot, \cdot)$, 则可构造 $K := [k(x_i, x_j)]_{i,j=1}^n$ 来代替 XX^T

此时拟合值 $\hat{y} := K(K + \lambda I_n)^{-1}y$

这样我们就将岭回归推广为**核岭回归** (Kernel Ridge Regression, KRR)

- **线性核 (Linear Kernel):**

$$k(x_i, x_j) = x_i^T x_j \text{ (对应一般的岭回归)}$$

- **多项式核 (Polynomial Kernel):**

$$k(x_i, x_j) = (x_i^T x_j + c)^d \text{ (其中 } c \text{ 是常数, } d \text{ 是多项式的阶数)}$$

可推广为 Chebyshev 核: $k(x_i, x_j) = \sum_{d=0}^D a_d (x_i^T x_j)^d$ (其中 D 为最大阶数, 而 $\alpha_0, \dots, \alpha_D$ 为常数)

- **Gauss 径向基核 (Gaussian Radial Basis Function Kernel):**

$$k(x_i, x_j) = \exp\left\{-\frac{1}{2\sigma^2} \|x_i - x_j\|_2^2\right\} \text{ (其中 } \sigma \text{ 是一个超参数)}$$

- **Sigmoid 核 (Sigmoid Kernel):**

$$k(x_i, x_j) = \tanh(\alpha x_i^T x_j + c) \text{ (其中 } \alpha, c \text{ 是超参数)}$$

- **Laplace 核 (Laplacian Kernel):**

$$k(x_i, x_j) = \exp\left\{-\frac{1}{\sigma} \|x_i - x_j\|_1\right\} \text{ (其中 } \sigma \text{ 是一个超参数)}$$

给定新观测 x 的模型预测为:

$$y_{\text{predict}} := \begin{bmatrix} k(x_1, x) \\ \vdots \\ k(x_n, x) \end{bmatrix}^T (K + \lambda I_n)^{-1} y$$

3.3 正则化系数的确定


3.3.1 岭迹分析

岭估计量 $\hat{\beta}_{\text{Ridge}}(\lambda) = (X^T X + \lambda I)^{-1} X^T y$ 的分量 $\hat{\beta}_{\text{Ridge}}^{(i)}(\lambda)$ 关于 λ 的图像称为**岭迹图** (ridge trace)

它们可用来定性分析自变量的作用和相互关系, 以及多元线性回归是否适用.

(注意最小二乘估计量 $\hat{\beta}_{\text{LSE}} = \hat{\beta}_{\text{Ridge}}(0) = (X^T X)^{-1} X^T y$)

- ① 例一:



最小二乘估计量的分量 $\hat{\beta}_{\text{LSE}}^{(i)} = \hat{\beta}_{\text{Ridge}}^{(i)}(0)$ 显著大于 0

即从多元线性回归的观点来看, 解释变量 X_i 的解释作用相当显著.


但是 $\hat{\beta}_{\text{Ridge}}^{(i)}(\lambda)$ 的岭迹图表现出相当的不稳定性:

随着 λ 的增大显著下降, 且趋于 0 的速度相当快 (尽管我们知道它一定会趋于 0).

因此从岭回归的观点来看, 解释变量 X_i 的解释作用可能不显著.

这说明在本例中, 多元线性回归可能没有反映真实情况.

- ② 例二:



最小二乘估计量的分量 $\hat{\beta}_{LSE}^{(i)} = \hat{\beta}_{Ridge}^{(i)}(0)$ 近似于 0,

即从多元线性回归的观点来看, 解释变量 X_i 的解释作用不显著.


但是 $\hat{\beta}_{Ridge}^{(i)}(\lambda)$ 的岭迹图显示:

随着 λ 增大, $\hat{\beta}_{Ridge}^{(i)}(\lambda)$ 在相当长的区间内稳定为离 0 较远的负值 (虽然我们知道它最终会趋于 0).

因此从岭回归的观点来看, 解释变量 X_i 的解释作用显著.

这说明在本例中, 多元线性回归可能没有反映真实情况.

• ③ 例三:




我们发现 $\hat{\beta}_{Ridge}^{(1)}(\lambda)$ 和 $\hat{\beta}_{Ridge}^{(2)}(\lambda)$ 的岭迹曲线都很不稳定,

但它们的线性组合 $\hat{\beta}_{Ridge}^{(1)}(\lambda) + \hat{\beta}_{Ridge}^{(2)}(\lambda)$ 却相当稳定.

这说明解释变量 X_1, X_2 之间存在多重共线性.

从变量选择的角度来说, 二者只需保留一个就足够了.

• ④ 例四:



从全局来看, 岭迹分析可用于判断多元线性回归是否适用.


我们将所有回归系数的岭迹曲线绘制在一张图像上.

如果这些岭迹曲线的不稳定性很强, 即整个图像呈现比较 "乱" 的局面 (如左图所示),


则我们倾向于认为多元线性回归是不适用的.

此时我们应该剔除某些变量，或使用岭回归（可选择使得所有岭迹曲线趋于稳定的 λ 值）
 否则我们认为多元线性回归是适用的（如右图所示）

(应用回归分析 例 7.3)



(a) 10个自变量的岭迹图



(b) 剔除自变量 x_5, x_7 的岭迹图

与基于残差的方法相比，岭迹法确定正则化系数 λ 的方法存在一定主观性。
 我们可以将其作为一种**定性分析**，与后文所述的定量分析相辅相成。

3.3.2 交叉验证

(1) K-fold 交叉验证

记设计矩阵 $X \in \mathbb{R}^{n \times (p+1)}$ 的行向量为 $x_1, \dots, x_n \in \mathbb{R}^{p+1}$
 将 n 个观测 $\{(x_i, y_i)\}_{i=1}^n$ (近似) 等分为 K 份，记为 $S_1, \dots, S_K$
 给定正则化系数 $\lambda > 0$ ，遍历 $k = 1, \dots, K$:

- 以 S_k 为验证集，其余 $K - 1$ 份为训练集。
 对应的估计量和残差平方和为:

$$\hat{\beta}_{(k)}(\lambda) := \left(\sum_{j \neq S_k} x_j x_j^T + \lambda I_{p+1} \right)^{-1} \sum_{j \neq S_k} x_j y_j$$

$$\text{SSE}_{(k)}(\lambda) := \sum_{j \in S_k} (y_j - x_j^T \hat{\beta}_{(k)}(\lambda))^2$$

最终得到 $\text{SSE}_{(1)}(\lambda), \dots, \text{SSE}_{(K)}(\lambda)$
 定义平均残差平方和为:

$$\text{CV}(\lambda) := \frac{1}{K} \sum_{k=1}^K \text{SSE}_{(k)}(\lambda)$$

设待选的 λ 值属于一个离散的集合 $\{\lambda_1, \lambda_2, \dots, \lambda_m\}$
 我们可对所有的 λ 进行 K -折交叉验证，得到 $\text{CV}(\lambda_1), \dots, \text{CV}(\lambda_m)$
 并取最小值对应的 λ 值:

$$\lambda_* := \arg \min_{\lambda \in \{\lambda_1, \dots, \lambda_m\}} \text{CV}(\lambda)$$

我们以 λ_* 作为岭回归的正则化系数。

(2) Leave-one-out 交叉验证

记设计矩阵 $X \in \mathbb{R}^{n \times (p+1)}$ 的行向量为 $x_1, \dots, x_n \in \mathbb{R}^{p+1}$
 当 $K = n$ 时， K -折交叉验证就称为留一交叉验证 (Leave-one-out Cross Validation)
 给定正则化系数 $\lambda > 0$ ，遍历 $k = 1, \dots, n$:

- 以 (x_k, y_k) 为验证集，其余 $n - 1$ 个样本为训练集。
 对应的估计量和残差平方和为:

$$\hat{\beta}_{(k)}(\lambda) := \left(\sum_{j \neq k} x_j x_j^T + \lambda I_{p+1} \right)^{-1} \sum_{j \neq k} x_j y_j$$

$$\text{SSE}_{(k)}(\lambda) := (y_k - x_k^T \hat{\beta}_{(k)}(\lambda))^2$$

最终得到 $\text{SSE}_{(1)}(\lambda), \dots, \text{SSE}_{(n)}(\lambda)$

定义平均残差平方和为:

$$\text{CV}(\lambda) := \frac{1}{n} \sum_{k=1}^n \text{SSE}_{(k)}(\lambda)$$

设待选的 λ 值属于一个离散的集合 $\{\lambda_1, \lambda_2, \dots, \lambda_m\}$

我们可对所有的 λ 进行 K -折交叉验证, 得到 $\text{CV}(\lambda_1), \dots, \text{CV}(\lambda_m)$

并取最小值对应的 λ 值:

$$\lambda_* := \arg \min_{\lambda \in \{\lambda_1, \dots, \lambda_m\}} \text{CV}(\lambda)$$

我们以 λ_* 作为岭回归的正则化系数.

(3) 一般交叉验证

记设计矩阵 $X \in \mathbb{R}^{n \times (p+1)}$ 的行向量为 $x_1, \dots, x_n \in \mathbb{R}^{p+1}$

在留一交叉验证的背景下, 考虑 $\hat{\beta}_{(k)}(\lambda)$ 与 $\hat{\beta}(\lambda)$ 的差距:

$$\begin{aligned} \hat{\beta}(\lambda) &= (X^T X + \lambda I_{p+1})^{-1} X^T y \\ &= \left(\sum_{j=1}^n x_j x_j^T + \lambda I_{p+1} \right)^{-1} \sum_{j=1}^n x_j y_j \\ \hat{\beta}_{(k)}(\lambda) &= \left(\sum_{j \neq k} x_j x_j^T + \lambda I_{p+1} \right)^{-1} \sum_{j \neq k} x_j y_j \quad (k = 1, \dots, n) \end{aligned}$$

我们发现当 n 很大时, $\hat{\beta}_{(k)}(\lambda)$ 和 $\hat{\beta}(\lambda)$ 很接近, 因此将 $\hat{\beta}_{(k)}(\lambda)$ 替换为 $\hat{\beta}(\lambda)$ 似乎是合理的.

基于上述观察, 我们希望找到一种能够快速计算 $\hat{\beta}_{(k)}(\lambda)$ ($k = 1, \dots, n$) 的方法.

注意到对于任意可逆方阵 $A, B \in \mathbb{C}^{n \times n}$ 我们都有 $A^{-1} - B^{-1} = A^{-1}(B - A)B^{-1}$

于是我们有:

$$\begin{aligned} &\left(\sum_{j=1}^n x_j x_j^T + \lambda I_{p+1} \right)^{-1} - \left(\sum_{j \neq k} x_j x_j^T + \lambda I_{p+1} \right)^{-1} \\ &= \left(\sum_{j=1}^n x_j x_j^T + \lambda I_{p+1} \right)^{-1} \left\{ \left(\sum_{j \neq k} x_j x_j^T + \lambda I_{p+1} \right) - \left(\sum_{j=1}^n x_j x_j^T + \lambda I_{p+1} \right) \right\} \left(\sum_{j \neq k} x_j x_j^T + \lambda I_{p+1} \right)^{-1} \\ &= - \left(\sum_{j=1}^n x_j x_j^T + \lambda I_{p+1} \right)^{-1} (x_k x_k^T) \left(\sum_{j \neq k} x_j x_j^T + \lambda I_{p+1} \right)^{-1} \end{aligned}$$

左右同乘 x_k^T 可得:

$$x_k^T \left(\sum_{j=1}^n x_j x_j^T + \lambda I_{p+1} \right)^{-1} - x_k^T \left(\sum_{j \neq k} x_j x_j^T + \lambda I_{p+1} \right)^{-1} = -x_k^T \left(\sum_{j=1}^n x_j x_j^T + \lambda I_{p+1} \right)^{-1} (x_k x_k^T) \left(\sum_{j \neq k} x_j x_j^T + \lambda I_{p+1} \right)^{-1}$$

于是我们有:

$$\begin{aligned} &x_k^T \left(\sum_{j=1}^n x_j x_j^T + \lambda I_{p+1} \right)^{-1} \\ &= x_k^T \left(\sum_{j \neq k} x_j x_j^T + \lambda I_{p+1} \right)^{-1} - x_k^T \left(\sum_{j=1}^n x_j x_j^T + \lambda I_{p+1} \right)^{-1} (x_k x_k^T) \left(\sum_{j \neq k} x_j x_j^T + \lambda I_{p+1} \right)^{-1} \\ &= x_k^T \left(\sum_{j \neq k} x_j x_j^T + \lambda I_{p+1} \right)^{-1} \left\{ 1 - x_k^T \left(\sum_{j=1}^n x_j x_j^T + \lambda I_{p+1} \right)^{-1} x_k \right\} \end{aligned}$$

于是我们有:

$$x_k^T \left(\sum_{j \neq k}^n x_j x_j^T + \lambda I_{p+1} \right)^{-1} = \frac{x_k^T \left(\sum_{j=1}^n x_j x_j^T + \lambda I_{p+1} \right)^{-1}}{1 - x_k^T \left(\sum_{j=1}^n x_j x_j^T + \lambda I_{p+1} \right)^{-1} x_k}$$

进而有:

$$\begin{aligned} y_k - x_k^T \hat{\beta}_{(i)}(\lambda) &= y_k - x_k^T \left(\sum_{j \neq k}^n x_j x_j^T + \lambda I_{p+1} \right)^{-1} \sum_{j \neq k}^n x_j y_j \\ &= y_k - \frac{x_k^T \left(\sum_{j=1}^n x_j x_j^T + \lambda I_{p+1} \right)^{-1} \sum_{j \neq k}^n x_j y_j}{1 - x_k^T \left(\sum_{j=1}^n x_j x_j^T + \lambda I_{p+1} \right)^{-1} x_k} \\ &= \frac{y_k - x_k^T \left(\sum_{j=1}^n x_j x_j^T + \lambda I_{p+1} \right)^{-1} x_k y_k - x_k^T \left(\sum_{j=1}^n x_j x_j^T + \lambda I_{p+1} \right)^{-1} \sum_{j \neq k}^n x_j y_j}{1 - x_k^T \left(\sum_{j=1}^n x_j x_j^T + \lambda I_{p+1} \right)^{-1} x_k} \\ &= \frac{y_k - x_k^T \left(\sum_{j=1}^n x_j x_j^T + \lambda I_{p+1} \right)^{-1} \sum_{j=1}^n x_j y_j}{1 - x_k^T \left(\sum_{j=1}^n x_j x_j^T + \lambda I_{p+1} \right)^{-1} x_k} \\ &= \frac{y_k - x_k^T (X^T X + \lambda I_{p+1})^{-1} X^T y}{1 - x_k^T (X^T X + \lambda I_{p+1})^{-1} x_k} \\ &= \frac{y_k - x_k^T \hat{\beta}(\lambda)}{1 - [X(X^T X + \lambda I_{p+1})^{-1} X^T]_{[k,k]}} \\ &= \frac{y_k - x_k^T \hat{\beta}(\lambda)}{1 - [H(\lambda)]_{[k,k]}} \end{aligned}$$

其中投影矩阵 $H(\lambda) := X(X^T X + \lambda I_{p+1})^{-1} X^T \in \mathbb{R}^{n \times n}$

其第 k 个对角元为 $[H(\lambda)]_{[k,k]} := x_k^T (X^T X + \lambda I_{p+1})^{-1} x_k$

于是第 k 个样本作为验证集得到的残差平方和为:

$$\begin{aligned} \text{SSE}_{(k)}(\lambda) &:= [y_k - x_k^T \hat{\beta}_{(i)}(\lambda)]^2 \\ &= \left[\frac{y_k - x_k^T \hat{\beta}(\lambda)}{1 - [H(\lambda)]_{[k,k]}} \right]^2 \quad (k = 1, \dots, n) \end{aligned}$$

这样我们就得到了留一交叉验证的 $\text{CV}(\lambda)$ 的简便计算公式:

$$\begin{aligned} \text{CV}(\lambda) &:= \frac{1}{n} \sum_{k=1}^n \text{SSE}_{(k)}(\lambda) \\ &= \frac{1}{n} \sum_{k=1}^n \left[\frac{y_k - x_k^T \hat{\beta}(\lambda)}{1 - [H(\lambda)]_{[k,k]}} \right]^2 \end{aligned}$$

事实上, 我们还可将其进一步简化成以下近似公式:

$$\begin{aligned} \text{CV}(\lambda) &= \frac{1}{n} \sum_{k=1}^n \left[\frac{y_k - x_k^T \hat{\beta}(\lambda)}{1 - [H(\lambda)]_{[k,k]}} \right]^2 \\ &\approx \frac{1}{n} \sum_{k=1}^n \left[\frac{y_k - x_k^T \hat{\beta}(\lambda)}{1 - \frac{1}{n} \text{tr}(H(\lambda))} \right]^2 \\ &= \frac{1}{n(1 - \frac{1}{n} \text{tr}(H(\lambda)))^2} \sum_{k=1}^n (y_k - x_k^T \hat{\beta}(\lambda))^2 \\ &= \frac{n}{(n - \text{tr}(H(\lambda)))^2} \|y - X\hat{\beta}(\lambda)\|^2 \\ &= \frac{n}{(n - \text{tr}(H(\lambda)))^2} \text{SSE}(\lambda) \end{aligned}$$

其中 $\text{SSE}(\lambda) := \|y - X\hat{\beta}(\lambda)\|^2$ 是参数为 λ 的岭回归在整个训练集上的残差平方和。

考虑 $\text{tr}(H(\lambda))$ 的快速计算:

(假设 $X \in \mathbb{R}^{n \times (p+1)}$ 的奇异值分解为 $X = U\Sigma V^T$, 则 $X^T X$ 的特征分解为 $X^T X = V\Sigma^T \Sigma V^T$)

$$\begin{aligned}\text{tr}(H(\lambda)) &= \text{tr}(X(X^T X + \lambda I_{p+1})^{-1} X^T) \\ &= \text{tr}((X^T X + \lambda I_{p+1})^{-1} X^T X) \\ &= \text{tr}((V\Sigma^T \Sigma V^T + \lambda I_{p+1})^{-1} V\Sigma^T \Sigma V^T) \\ &= \text{tr}(V(\Sigma^T \Sigma + \lambda I_{p+1})^{-1} V^T V\Sigma^T \Sigma V^T) \\ &= \text{tr}(V(\Sigma^T \Sigma + \lambda I_{p+1})^{-1} \Sigma^T \Sigma V^T) \\ &= \text{tr}((\Sigma^T \Sigma + \lambda I_{p+1})^{-1} \Sigma^T \Sigma V^T V) \\ &= \text{tr}((\Sigma^T \Sigma + \lambda I_{p+1})^{-1} \Sigma^T \Sigma)\end{aligned}$$

考虑 $\text{SSE}(\lambda)$ 的快速计算:

$$\begin{aligned}\text{SSE}(\lambda) &= \|y - X\hat{\beta}(\lambda)\|_2^2 \\ &= \|y - X(X^T X + \lambda I_{p+1})^{-1} X^T y\|_2^2 \\ &= \|y - U\Sigma V^T(V\Sigma^T \Sigma V^T + \lambda I_{p+1})^{-1} V\Sigma^T U^T y\|_2^2 \\ &= \|y - U\Sigma(\Sigma^T \Sigma + \lambda I_{p+1})^{-1} \Sigma^T U^T y\|_2^2 \quad (\text{note that } \|\cdot\|_2 \text{ is unitary invariant}) \\ &= \|U^T y - \Sigma(\Sigma^T \Sigma + \lambda I_{p+1})^{-1} \Sigma^T U^T y\|_2^2 \quad (\text{denote } \tilde{y} = U^T y) \\ &= \|\tilde{y} - \Sigma(\Sigma^T \Sigma + \lambda I_{p+1})^{-1} \Sigma^T \tilde{y}\|_2^2\end{aligned}$$

于是我们得到 Leave-one-out $\text{CV}(\lambda)$ 的快速近似算法 (一般交叉验证):

设待选的 λ 值属于一个离散的集合 $\{\lambda_1, \lambda_2, \dots, \lambda_m\}$

- 计算 $X \in \mathbb{R}^{n \times (p+1)}$ 的奇异值分解 $X = U\Sigma V^T$
其中 $U \in \mathbb{R}^{n \times n}$ 和 $V \in \mathbb{R}^{(p+1) \times (p+1)}$ 为实正交阵, $\Sigma \in \mathbb{R}^{n \times (p+1)}$ 为对角元为非负实数的对角阵
- 计算 $\tilde{y} = U^T y \in \mathbb{R}^n$
- 对于 $\{\lambda_1, \lambda_2, \dots, \lambda_m\}$ 中的每个 λ , 执行以下步骤:
 - ① 计算 $\text{tr}(H(\lambda)) = \text{tr}((\Sigma^T \Sigma + \lambda I_{p+1})^{-1} \Sigma^T \Sigma)$
 - ② 计算 $\text{SSE}(\lambda) = \|\tilde{y} - \Sigma(\Sigma^T \Sigma + \lambda I_{p+1})^{-1} \Sigma^T \tilde{y}\|_2^2$
 - ③ 计算 $\text{CV}(\lambda) \approx \frac{n}{(n - \text{tr}(H(\lambda)))^2} \text{SSE}(\lambda)$
- 最终得到 $\text{CV}(\lambda_1), \dots, \text{CV}(\lambda_m)$
- 并取最小值对应的 λ 值:

$$\lambda_\star := \arg \min_{\lambda \in \{\lambda_1, \dots, \lambda_m\}} \text{CV}(\lambda)$$

我们以 $\lambda_\star$ 作为岭回归的正则化系数.

3.3.3 Akaike 信息准则

由于岭估计量并不基于极大似然估计, 故 AIC 准则并不是用于选取正则化系数 λ 的最佳方法. 我们通常将交叉验证法作为首选, 但了解 AIC 准则也相当有用.

考虑多元线性回归模型 $y = X\beta + \varepsilon$

其中 $y \in \mathbb{R}^n$, $X \in \mathbb{R}^{n \times (p+1)}$, $\varepsilon \sim N(0_n, \sigma^2 I_n)$

记岭回归估计量为 $\hat{\beta}(\lambda) := (X^T X + \lambda I_{p+1})^{-1} X^T y$

其中 $\lambda > 0$ 称为岭回归的正则化系数.

在正态假设下, 我们有 $y \sim N(X\beta, \sigma^2 I_n)$ (其中 σ^2 反映的是随机噪音的强度, 与模型无关) 其概率密度函数为:

$$\begin{aligned}f(y) &= \frac{1}{(\sqrt{2\pi})^n |\sigma^2 I_n|^{\frac{1}{2}}} \exp\left\{-\frac{1}{2}(y - X\beta)^T (\sigma^2 I_n)^{-1} (y - X\beta)\right\} \\ &= \frac{1}{(\sqrt{2\pi}\sigma)^n} \exp\left\{-\frac{1}{2\sigma^2} \|y - X\beta\|_2^2\right\}\end{aligned}$$

似然函数 $L(\beta, \sigma^2 | X, y)$ 和对数似然函数 $\log L(\beta, \sigma^2 | X, y)$ 为:

$$L(\beta, \sigma^2 | X, y) = f(y) = \frac{1}{(\sqrt{2\pi}\sigma)^n} \exp\left\{-\frac{1}{2\sigma^2} \|y - X\beta\|_2^2\right\}$$

$$\log L(\beta, \sigma^2 | X, y) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \|y - X\beta\|_2^2$$

在岭回归中，我们固定 $\beta = \hat{\beta}(\lambda) = (X^T X + \lambda I_{p+1})^{-1} X^T y$ ，得到：

$$\log L(\hat{\beta}(\lambda), \sigma^2 | X, y) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \|y - X\hat{\beta}(\lambda)\|_2^2$$

$$\nabla_{\sigma^2} \{\log L(\hat{\beta}(\lambda), \sigma^2 | X, y)\} = \nabla_{\sigma^2} \left\{ -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \|y - X\hat{\beta}(\lambda)\|_2^2 \right\}$$

$$= -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \|y - X\hat{\beta}(\lambda)\|^2$$

$$\text{令 } \nabla_{\sigma^2} \{\log L(\hat{\beta}(\lambda), \sigma^2 | X, y)\} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \|y - X\hat{\beta}(\lambda)\|^2 = 0$$

即得 σ^2 在固定 $\beta = \hat{\beta}(\lambda)$ 条件下的极大似然解为：

$$\hat{\sigma}^2 = \frac{1}{n} \|y - X\hat{\beta}(\lambda)\|^2$$

$$= \frac{1}{n} \text{SSE}(\lambda)$$

代入得到固定 $\beta = \hat{\beta}(\lambda)$ 条件下的极大似然为：

$$\log L(\hat{\beta}(\lambda), \hat{\sigma}^2 | X, y) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\hat{\sigma}^2) - \frac{1}{2\hat{\sigma}^2} \|y - X\hat{\beta}(\lambda)\|^2$$

$$= -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log\left(\frac{1}{n} \text{SSE}(\lambda)\right) - \frac{1}{2 \cdot \frac{1}{n} \text{SSE}(\lambda)} \text{SSE}(\lambda)$$

$$= -\frac{n}{2} \log(2\pi) + \frac{n}{2} \log(n) - \frac{n}{2} \log(\text{SSE}(\lambda)) - \frac{n}{2}$$

考虑到 $\text{AIC} := \text{maximum_log-likelihood} - \text{model_complexity}$

我们可将 $\log L(\hat{\beta}(\lambda), \hat{\sigma}^2 | X, y)$ 作为全局极大似然 $\max_{\beta, \sigma^2} \log L(\beta, \sigma^2 | X, y)$ 的近似值 (删除常数项)

同时将 $\text{tr}(H(\lambda))$ 作为模型复杂度的近似值。

最终得到：

$$\text{AIC}_p := \text{maximum_log-likelihood} - \text{model_complexity}$$

$$= -\frac{n}{2} \log(\text{SSE}(\lambda)) - \text{tr}(H(\lambda))$$

$$\text{where } \begin{cases} \hat{\beta}(\lambda) := (X^T X + \lambda I_{p+1})^{-1} X^T y \\ \text{SSE}(\lambda) := \|y - X\hat{\beta}(\lambda)\|^2 \\ H(\lambda) := X(X^T X + \lambda I_{p+1})^{-1} X^T \end{cases}$$

设待选的 λ 值属于一个离散的集合 $\{\lambda_1, \lambda_2, \dots, \lambda_m\}$

我们可对所有的 λ 计算 $\text{AIC}(\lambda)$ ，得到 $\text{AIC}(\lambda_1), \dots, \text{AIC}(\lambda_m)$

并取最大值对应的 λ 值：

$$\lambda_{\star} := \arg \max_{\lambda \in \{\lambda_1, \dots, \lambda_m\}} \text{AIC}(\lambda)$$

我们以 $\lambda_{\star}$ 作为岭回归的正则化系数。

The End