

FDU 回归分析 5. 方差分析

5.1 An Introduction

在多元线性回归模型 $y = X\beta + \varepsilon$ 中,
无论是响应变量 Y 还是解释变量 $X_1, X_2, \dots, X_k$, 它们都是连续变量.
但在实际问题的研究中, 我们会遇到离散变量, 也称为定性变量,
例如性别、职业、颜色等等, 此时多元线性回归模型就不适用了.

Logistic 回归所解决的二分类问题中, 响应变量 Y 为 0-1 型离散变量, 而解释变量均为连续变量.
这里我们考虑另一类问题:

响应变量 Y 为连续变量, 而解释变量 $X_1, \dots, X_k$ 为离散变量的问题,
例如研究 "调查问卷纸张的颜色" 对其 "回收率" 的影响.
再例如 "定价" 和 "包装" 对商品 "销售量" 的影响.

处理这类问题通常采用方差分析方法,
只考虑单个解释变量的方差分析称为**单因子方差分析** (Single-Factor ANOVA)
同时考虑多个解释变量的方差分析称为**多因子方差分析** (Multi-Factor ANOVA)
本课程里, 我们只研究到**双因子方差分析** (Two-Factor ANOVA)

所谓 "**因子**" (Factor), 即离散的解释变量

所谓 "**因子水平**" (Factor Level), 即这个因子可能的取值

在单因子方差分析中, 我们通常记模型中唯一的因子为 A , 记其 a 个因子水平为 $A_1, A_2, \dots, A_a$

设在这 a 个因子水平下分别有 $n_1, n_2, \dots, n_a$ 个观测, 记**观测总数** $n := \sum_{i=1}^a n_i$

我们将这些观测记为:

Factor Level:	A_1	$\dots$	A_i	$\dots$	A_n
	$y_{1,1}$		$y_{i,1}$		$y_{a,1}$
Observation:	$\vdots$	$\dots$	$\vdots$	$\dots$	$\vdots$
	y_{1,n_1}		y_{i,n_i}		y_{a,n_a}

其中 y_{ij} 代表因子水平 A_i 下的第 j 个观测.

我们记 $y_{ij} = \mu_i + \varepsilon_{ij}$

其中 μ_i 为因子水平 A_i 下观测的**理论均值**

扰动项 ε_{ij} 独立于下标 (i, j) , 服从某个零均值的分布 $\text{Distribution}(0, \sigma^2)$

我们通常做正态假设: $\{\varepsilon_{ij}\} \stackrel{iid}{\sim} N(0, \sigma^2)$

于是上述观测可表示成缺少截距项的线性回归模型:

$$\begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(a)} \end{bmatrix} = \begin{bmatrix} y_{1,1} \\ \vdots \\ y_{1,n_1} \\ y_{2,1} \\ \vdots \\ y_{2,n_2} \\ \vdots \\ y_{a,1} \\ \vdots \\ y_{a,n_a} \end{bmatrix} = \begin{bmatrix} \mu_1 1_{n_1} \\ \mu_2 1_{n_2} \\ \vdots \\ \mu_a 1_{n_a} \end{bmatrix} + \begin{bmatrix} \varepsilon_{1,1} \\ \vdots \\ \varepsilon_{1,n_1} \\ \varepsilon_{2,1} \\ \vdots \\ \varepsilon_{2,n_2} \\ \vdots \\ \varepsilon_{a,1} \\ \vdots \\ \varepsilon_{a,n_a} \end{bmatrix} = \begin{bmatrix} 1_{n_1} & & & \\ & 1_{n_2} & & \\ & & \ddots & \\ & & & 1_{n_a} \end{bmatrix}_{n \times a} \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_a \end{bmatrix}_{a \times 1} + \begin{bmatrix} \varepsilon^{(1)} \\ \varepsilon^{(2)} \\ \vdots \\ \varepsilon^{(a)} \end{bmatrix}_{n \times 1}$$

进一步, 我们记:

$$\begin{cases} y_{i\cdot} = \sum_{j=1}^{n_i} y_{ij} \\ \bar{y}_{i\cdot} = \frac{1}{n_i} y_{i\cdot} = \frac{1}{n_i} \sum_{j=1}^{n_i} y_{ij} \\ y_{\cdot\cdot} = \sum_{i=1}^a y_{i\cdot} = \sum_{i=1}^a \sum_{j=1}^{n_i} y_{ij} \\ \bar{y}_{\cdot\cdot} = \frac{1}{n} y_{\cdot\cdot} = \frac{1}{n} \sum_{i=1}^a \sum_{j=1}^{n_i} y_{ij} \end{cases}$$

其中 $y_{i\cdot}$ 称为因子水平 A_i 下的观测和, $\bar{y}_{i\cdot}$ 称为因子水平 A_i 下的样本均值
而 $y_{\cdot\cdot}$ 称为因子 A 的总观测和, $\bar{y}_{\cdot\cdot}$ 称为因子 A 的总样本均值

类似地记:

$$\begin{cases} \varepsilon_{i\cdot} = \sum_{j=1}^{n_i} \varepsilon_{ij} \\ \bar{\varepsilon}_{i\cdot} = \frac{1}{n_i} \varepsilon_{i\cdot} = \frac{1}{n_i} \sum_{j=1}^{n_i} \varepsilon_{ij} \\ \varepsilon_{\cdot\cdot} = \sum_{i=1}^a \sum_{j=1}^{n_i} \varepsilon_{ij} \\ \bar{\varepsilon}_{\cdot\cdot} = \frac{1}{n} \varepsilon_{\cdot\cdot} = \frac{1}{n} \sum_{i=1}^a \sum_{j=1}^{n_i} \varepsilon_{ij} \end{cases}$$

根据 $y_{ij} = \mu_i + \varepsilon_{ij}$ 可得:

$$\begin{cases} y_{i\cdot} = n_i \mu_i + \varepsilon_{i\cdot} \\ \bar{y}_{i\cdot} = \mu_i + \bar{\varepsilon}_{i\cdot} \\ y_{\cdot\cdot} = \sum_{i=1}^a n_i \mu_i + \varepsilon_{\cdot\cdot} \\ \bar{y}_{\cdot\cdot} = \sum_{i=1}^a \frac{n_i}{n} \mu_i + \bar{\varepsilon}_{\cdot\cdot} \end{cases}$$

5.2 单因子方差分析

5.2.1 点估计

注意到因子水平 A_i 下的观测 $y_{i,1}, y_{i,2}, \dots, y_{i,n_i}$ 相互独立, 且同分布于 $N(\mu_i, \sigma^2)$
考虑优化问题:

$$\min_{\mu \in \mathbb{R}} \|y^{(i)} - \mu 1_{n_i}\|^2 := \sum_{j=1}^{n_i} (y_{ij} - \mu)^2$$

令 $\nabla_{\mu} \|y^{(i)} - \mu 1_{n_i}\|^2 = -2 \cdot 1_{n_i}^T (y^{(i)} - \mu 1_{n_i}) = 0_{n_i}$ 可知 μ_i 的最小二乘估计量为:

$$\hat{\mu}_i = (1_{n_i}^T 1_{n_i})^{-1} 1_{n_i}^T y^{(i)} = \frac{1}{n_i} \sum_{j=1}^{n_i} y_{ij} = \bar{y}_{i\cdot}$$

根据多元线性回归的 **Gauss-Markov 定理** 可知 $\bar{y}_{i\cdot}$ 是 μ_i 的最佳线性无偏估计量 (BLUE)
它服从正态分布:

$$\bar{y}_{i\cdot} = \frac{1}{n_i} \sum_{j=1}^{n_i} y_{ij} \sim N(\mu_i, \frac{\sigma^2}{n_i})$$

(多元线性回归中的 Gauss-Markov 定理)

给定数据点 $(x^{(1)}, y_1), \dots, (x^{(n)}, y_n)$ 和多元线性回归模型 $Y = \beta^T x + \varepsilon$

(其中 $\beta \in \mathbb{R}^{p+1}$ 为参数向量, ε 为随机噪音)

记样本关系为 $y = X\beta + \varepsilon$

(其中 $X = [x^{(1)}, \dots, x^{(n)}]^T \in \mathbb{R}^{n \times (p+1)}$ 为设计矩阵, $\varepsilon \in \mathbb{R}^n$ 为随机误差构成的列向量)

若 $\begin{cases} E[\varepsilon] = 0_n \\ \text{Var}[\varepsilon] = \sigma^2 I_n \end{cases}$ (零均值和互不相关, 无需给出分布上的假设),

则最小二乘估计量 $\hat{\beta} = (X^T X)^{-1} X^T y$ 是参数向量 β 的最佳线性无偏估计量 (Best Linear Unbiased Estimator, BLUE)

$$E[\hat{\beta}] = \beta$$

$$\text{Cov}[\hat{\beta}] = \sigma^2 (X^T X)^{-1}$$

考虑单因子方差分析的多元线性回归形式:

$$\begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(a)} \end{bmatrix} = \begin{bmatrix} 1_{n_1} & & & \\ & 1_{n_2} & & \\ & & \ddots & \\ & & & 1_{n_a} \end{bmatrix}_{n \times a} \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_a \end{bmatrix} + \begin{bmatrix} \varepsilon^{(1)} \\ \varepsilon^{(2)} \\ \vdots \\ \varepsilon^{(a)} \end{bmatrix}$$

其中:

$$y^{(i)} = \begin{bmatrix} y_{i,1} \\ y_{i,2} \\ \vdots \\ y_{i,n_i} \end{bmatrix} \quad \varepsilon^{(i)} = \begin{bmatrix} \varepsilon_{i,1} \\ \varepsilon_{i,2} \\ \vdots \\ \varepsilon_{i,n_i} \end{bmatrix} \quad (i = 1, \dots, a)$$

$$n = n_1 + n_2 + \dots + n_a$$

$$\{\varepsilon_{i,j}\} \stackrel{i.i.d}{\sim} N(0, \sigma^2)$$

根据多元线性回归的结论可知 σ^2 的无偏估计量为:

$$\begin{aligned} s^2 &= \frac{1}{n-a} \left\| \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(a)} \end{bmatrix} - \begin{bmatrix} 1_{n_1} & & & \\ & 1_{n_2} & & \\ & & \ddots & \\ & & & 1_{n_a} \end{bmatrix}_{n \times a} \begin{bmatrix} \bar{y}_1 \\ \bar{y}_2 \\ \vdots \\ \bar{y}_a \end{bmatrix} \right\|^2 \\ &= \frac{1}{n-a} \left\| \begin{bmatrix} y^{(1)} - \bar{y}_1 \cdot 1_{n_1} \\ y^{(2)} - \bar{y}_2 \cdot 1_{n_2} \\ \vdots \\ y^{(a)} - \bar{y}_a \cdot 1_{n_a} \end{bmatrix} \right\|^2 \\ &= \frac{1}{n-a} \sum_{i=1}^a \|y^{(i)} - \bar{y}_i \cdot 1_{n_i}\|^2 \\ &= \frac{1}{n-a} \sum_{i=1}^a (n_i - 1) s_i^2 \end{aligned}$$

其中 $s_i^2 = \frac{1}{n_i-1} \|y^{(i)} - \bar{y}_i \cdot 1_{n_i}\|^2 = \frac{1}{n_i-1} \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_i)^2$ 为因子水平 A_i 下的样本方差.

根据多元线性回归的结论可知:

- ① $\bar{y}_i = \frac{1}{n_i} \sum_{j=1}^{n_i} y_{ij} \sim N(\mu_i, \frac{\sigma^2}{n_i})$
- ② $s_i^2 = \frac{1}{n_i-1} \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_i)^2 \sim \frac{1}{n_i-1} \sigma^2 \chi_{(n_i-1)}^2$ 且 $\bar{y}_i \perp s_i^2$
(事实上对于任意 $i, j = 1, \dots, a$ 都有 $\bar{y}_i \perp s_j^2$ 成立)
- ③ $s^2 = \frac{1}{n-a} \sum_{i=1}^a (n_i - 1) s_i^2 \sim \frac{1}{n-a} \sigma^2 \chi_{(n-a)}^2$ 且 $s^2 \perp \bar{y}_i$ ($\forall i = 1, \dots, a$)

5.2.2 置信区间估计

给定置信水平为 α

(1) 理论均值

因子水平 A_i 下的理论均值 μ_i 的 t 检验统计量为:

$$\begin{aligned}\frac{\sqrt{n_i}(\bar{y}_{i\cdot} - \mu_i)}{s} &= \frac{\frac{\sqrt{n_i}(\bar{y}_{i\cdot} - \mu_i)}{\sigma}}{\frac{s}{\sigma}} \quad (\text{note that } \begin{cases} \bar{y}_{i\cdot} \sim N(\mu_i, \frac{\sigma^2}{n_i}) \\ s^2 \sim \frac{1}{n-a}\sigma^2\chi_{(n-a)}^2 \end{cases}) \\ &\sim \frac{N(0, 1)}{\frac{1}{n-a}\chi_{(n-a)}^2} \quad (\text{note that } s^2 \perp \bar{y}_{i\cdot}) \\ &= t_{n-a}\end{aligned}$$

因此 μ_i 的 $(1 - \alpha) \cdot 100\%$ 置信区间为 $\bar{y}_{i\cdot} \pm \frac{s}{\sqrt{n_i}} t_{n-a}(\frac{\alpha}{2})$

其中 $t_{n-a}(\frac{\alpha}{2})$ 为 t_{n-a} 分布的 $1 - \frac{\alpha}{2}$ 分位数.

(2) 组间偏差

记因子水平 A_i 和 A_j 的理论偏差为 $d_{ij} := \mu_i - \mu_j$

显然其无偏估计量为 $\hat{d}_{ij} := \bar{y}_{i\cdot} - \bar{y}_{j\cdot}$.

注意到:

$$\begin{cases} \bar{y}_{i\cdot} \sim N(\mu_i, \frac{\sigma^2}{n_i}) \\ \bar{y}_{j\cdot} \sim N(\mu_j, \frac{\sigma^2}{n_j}) \\ \bar{y}_{i\cdot} \perp \bar{y}_{j\cdot} \end{cases} \Rightarrow \begin{bmatrix} \bar{y}_{i\cdot} \\ \bar{y}_{j\cdot} \end{bmatrix} \sim N\left(\begin{bmatrix} \mu_i \\ \mu_j \end{bmatrix}, \sigma^2 \begin{bmatrix} \frac{1}{n_i} & 0 \\ 0 & \frac{1}{n_j} \end{bmatrix}\right)$$

因此我们有:

$$\begin{aligned}\hat{d}_{ij} &= \bar{y}_{i\cdot} - \bar{y}_{j\cdot} \\ &= \begin{bmatrix} 1 \\ -1 \end{bmatrix}^T \begin{bmatrix} \bar{y}_{i\cdot} \\ \bar{y}_{j\cdot} \end{bmatrix} \\ &\sim N\left(\begin{bmatrix} 1 \\ -1 \end{bmatrix}^T \begin{bmatrix} \mu_i \\ \mu_j \end{bmatrix}, \sigma^2 \begin{bmatrix} 1 \\ -1 \end{bmatrix}^T \begin{bmatrix} \frac{1}{n_i} & 0 \\ 0 & \frac{1}{n_j} \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix}\right) \\ &= N\left(\mu_i - \mu_j, \sigma^2 \left(\frac{1}{n_i} + \frac{1}{n_j}\right)\right)\end{aligned}$$

标准化后得到:

$$\frac{\hat{d}_{ij} - d_{ij}}{\sigma \sqrt{\frac{1}{n_i} + \frac{1}{n_j}}} \sim N(0, 1)$$

因此理论偏差 $d_{ij} = \mu_i - \mu_j$ 的 t 检验统计量为:

$$\begin{aligned}\frac{\hat{d}_{ij} - d_{ij}}{s \sqrt{\frac{1}{n_i} + \frac{1}{n_j}}} &= \frac{\frac{\hat{d}_{ij} - d_{ij}}{\sigma \sqrt{\frac{1}{n_i} + \frac{1}{n_j}}}}{\frac{s}{\sigma}} \quad (\text{note that } \begin{cases} \frac{\hat{d}_{ij} - d_{ij}}{\sigma \sqrt{\frac{1}{n_i} + \frac{1}{n_j}}} \sim N(0, 1) \\ s^2 \sim \frac{1}{n-a}\sigma^2\chi_{(n-a)}^2 \end{cases}) \\ &\sim \frac{N(0, 1)}{\frac{1}{n-a}\chi_{(n-a)}^2} \quad (\text{note that } s^2 \perp \bar{y}_{i\cdot} \text{ for all } i = 1, \dots, a \text{ so that } s^2 \perp \hat{d}_{ij} := \bar{y}_{i\cdot} - \bar{y}_{j\cdot}) \\ &= t_{n-a}\end{aligned}$$

因此 $d_{ij} = \mu_i - \mu_j$ 的 $(1 - \alpha) \cdot 100\%$ 置信区间为 $\hat{d}_{ij} \pm s \sqrt{\frac{1}{n_i} + \frac{1}{n_j}} t_{n-a}(\frac{\alpha}{2})$

其中 $t_{n-a}(\frac{\alpha}{2})$ 为 t_{n-a} 分布的 $1 - \frac{\alpha}{2}$ 分位数.

(3) 对比度

给定系数 $c_1, \dots, c_a$ 满足 $\sum_{i=1}^a c_i = 0$

定义对比度 $L := \sum_{i=1}^a c_i \mu_i = c^T \mu$

其中 $\mu := [\mu_1, \dots, \mu_a]^T$

显然其无偏估计量为:

$$\begin{aligned}\hat{L} &:= \sum_{i=1}^a c_i \bar{y}_i. \\ &= \begin{bmatrix} c_1 \\ \vdots \\ c_a \end{bmatrix}^T \begin{bmatrix} \bar{y}_1 \\ \vdots \\ \bar{y}_a \end{bmatrix} \quad \left(\text{note that } \begin{bmatrix} \bar{y}_1 \\ \vdots \\ \bar{y}_a \end{bmatrix} \sim N \left(\begin{bmatrix} \mu_1 \\ \vdots \\ \mu_a \end{bmatrix}, \sigma^2 \begin{bmatrix} \frac{1}{n_1} & & \\ & \ddots & \\ & & \frac{1}{n_a} \end{bmatrix} \right) \right) \\ &= N \left(\begin{bmatrix} c_1 \\ \vdots \\ c_a \end{bmatrix}^T \begin{bmatrix} \mu_1 \\ \vdots \\ \mu_a \end{bmatrix}, \sigma^2 \begin{bmatrix} c_1 \\ \vdots \\ c_a \end{bmatrix}^T \begin{bmatrix} \frac{1}{n_1} & & \\ & \ddots & \\ & & \frac{1}{n_a} \end{bmatrix} \begin{bmatrix} c_1 \\ \vdots \\ c_a \end{bmatrix} \right) \\ &= N \left(\sum_{i=1}^a c_i \mu_i, \sigma^2 \sum_{i=1}^a \frac{1}{n_i} c_i^2 \right)\end{aligned}$$

标准化后得到:

$$\frac{\hat{L} - L}{\sigma \sqrt{\sum_{i=1}^a \frac{c_i^2}{n_i}}} \sim N(0, 1)$$

因此对比度 $L = \sum_{i=1}^a c_i \mu_i = c^T \mu$ 的 t 检验统计量为:

$$\begin{aligned}\frac{\hat{L} - L}{s \sqrt{\sum_{i=1}^a \frac{c_i^2}{n_i}}} &= \frac{\frac{\hat{L} - L}{\sigma \sqrt{\sum_{i=1}^a \frac{c_i^2}{n_i}}}}{\frac{s}{\sigma}} \quad \left(\text{note that } \begin{cases} \frac{\hat{L} - L}{\sigma \sqrt{\sum_{i=1}^a \frac{c_i^2}{n_i}}} \sim N(0, 1) \\ s^2 \sim \frac{1}{n-a} \sigma^2 \chi_{(n-a)}^2 \end{cases} \right) \\ &\sim \frac{N(0, 1)}{\frac{1}{n-a} \chi_{(n-a)}^2} \quad \left(\text{note that } s^2 \perp \bar{y}_i \text{ for all } i = 1, \dots, a \text{ so that } s^2 \perp \hat{L} := \sum_{i=1}^a c_i \bar{y}_i \right) \\ &= t_{n-a}\end{aligned}$$

因此 $L = \sum_{i=1}^a c_i \mu_i = c^T \mu$ 的 $(1 - \alpha) \cdot 100\%$ 置信区间为 $\hat{L} \pm s \sqrt{\sum_{i=1}^a \frac{c_i^2}{n_i}} t_{n-a}(\frac{\alpha}{2})$

其中 $t_{n-a}(\frac{\alpha}{2})$ 为 t_{n-a} 分布的 $1 - \frac{\alpha}{2}$ 分位数.

5.2.3 主效应检验

考虑单因子方差分析的多元线性回归形式:

$$y = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(a)} \end{bmatrix} = \begin{bmatrix} 1_{n_1} & & & \\ & 1_{n_2} & & \\ & & \ddots & \\ & & & 1_{n_a} \end{bmatrix}_{n \times a} \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_a \end{bmatrix} + \begin{bmatrix} \varepsilon^{(1)} \\ \varepsilon^{(2)} \\ \vdots \\ \varepsilon^{(a)} \end{bmatrix} = X\mu + \varepsilon$$

其中:

$$y^{(i)} = \begin{bmatrix} y_{i,1} \\ y_{i,2} \\ \vdots \\ y_{i,n_i} \end{bmatrix} \quad \varepsilon^{(i)} = \begin{bmatrix} \varepsilon_{i,1} \\ \varepsilon_{i,2} \\ \vdots \\ \varepsilon_{i,n_i} \end{bmatrix} \quad (i = 1, \dots, a)$$

$$n = n_1 + n_2 + \dots + n_a$$

$$\{\varepsilon_{i,j}\} \stackrel{\text{i.i.d.}}{\sim} N(0, \sigma^2)$$

设计矩阵 $X = 1_{n_1} \oplus \dots \oplus 1_{n_a} \in \mathbb{R}^{n \times a}$

我们定义投影矩阵为:

$$H := X(X^T X)^{-1} X^T$$

$$= \begin{bmatrix} 1_{n_1} & & & \\ & 1_{n_2} & & \\ & & \ddots & \\ & & & 1_{n_a} \end{bmatrix} \begin{bmatrix} n_1 & & & \\ & n_2 & & \\ & & \ddots & \\ & & & n_a \end{bmatrix}^{-1} \begin{bmatrix} 1_{n_1} & & & \\ & 1_{n_2} & & \\ & & \ddots & \\ & & & 1_{n_a} \end{bmatrix}^T$$

$$= \begin{bmatrix} \frac{1}{n_1} 1_{n_1} 1_{n_1}^T & & & \\ & \frac{1}{n_2} 1_{n_2} 1_{n_2}^T & & \\ & & \ddots & \\ & & & \frac{1}{n_a} 1_{n_a} 1_{n_a}^T \end{bmatrix}$$

我们想知道在不同因子水平 $A_1, A_2, \dots, A_a$ 的理论均值是否完全一致. 因此零假设和备择假设分别为:

$$H_0 : \mu_1 = \mu_2 = \dots = \mu_a$$

$$\Updownarrow$$

$$H_1 : \exists i, j \text{ such that } \mu_i \neq \mu_j$$

(1) 基本记号

根据多元线性回归的结论我们有:

$$\begin{aligned}
\text{SST} &= \|y - \bar{y}..1_n\|^2 \\
&= \sum_{i=1}^a \sum_{j=1}^{n_i} (y_{ij} - \bar{y}..)^2 \\
\hline
\text{SSE} &= \|y - \hat{y}\|^2 \\
&= \|y - Hy\|^2 \\
&= \left\| \begin{bmatrix} y^{(1)} \\ \vdots \\ y^{(a)} \end{bmatrix} - \begin{bmatrix} \frac{1}{n_1} 1_{n_1} 1_{n_1}^T & & \\ & \ddots & \\ & & \frac{1}{n_a} 1_{n_a} 1_{n_a}^T \end{bmatrix} \begin{bmatrix} y^{(1)} \\ \vdots \\ y^{(a)} \end{bmatrix} \right\|^2 \\
&= \left\| \begin{bmatrix} y^{(1)} - \frac{1}{n_1} 1_{n_1} 1_{n_1}^T y^{(1)} \\ \vdots \\ y^{(a)} - \frac{1}{n_a} 1_{n_a} 1_{n_a}^T y^{(a)} \end{bmatrix} \right\|^2 \\
&= \left\| \begin{bmatrix} y^{(1)} - \bar{y}_{1.} 1_{n_1} \\ \vdots \\ y^{(a)} - \bar{y}_{a.} 1_{n_a} \end{bmatrix} \right\|^2 \\
&= \sum_{i=1}^a \|y^{(i)} - \bar{y}_{i.} 1_{n_i}\|^2 \\
&= \sum_{i=1}^a \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_{i.})^2 \\
\hline
\text{SSR} &= \|\hat{y} - \bar{y}..1_n\|^2 \\
&= \|Hy - \bar{y}..1_n\|^2 \quad (\text{use conclusion above}) \\
&= \left\| \begin{bmatrix} \bar{y}_{1.} 1_{n_1} - \bar{y}.. 1_{n_1} \\ \vdots \\ \bar{y}_{a.} 1_{n_a} - \bar{y}.. 1_{n_a} \end{bmatrix} \right\|^2 \\
&= \sum_{i=1}^a \|(\bar{y}_{i.} - \bar{y}..) 1_{n_i}\|^2 \\
&= \sum_{i=1}^a n_i (\bar{y}_{i.} - \bar{y}..)^2
\end{aligned}$$

而且它们的分布满足:

$$\left\{ \begin{array}{l} H_0 : \mu_1 = \cdots = \mu_a \\ \text{SST} = \|y - \bar{y}..1_n\|^2 = \sum_{i=1}^a \sum_{j=1}^{n_i} (y_{ij} - \bar{y}..)^2 \stackrel{H_0}{\sim} \sigma^2 \chi_{(n-1)}^2 \\ \text{SSR} = \|\hat{y} - \bar{y}..1_n\|^2 = \sum_{i=1}^a n_i (\bar{y}_{i.} - \bar{y}..)^2 \stackrel{H_0}{\sim} \sigma^2 \chi_{(a-1)}^2 \\ \text{SSE} = \|y - \hat{y}\|^2 = \sum_{i=1}^a \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_{i.})^2 \sim \sigma^2 \chi_{(n-a)}^2 \\ \left\{ \begin{array}{l} \text{SST} = \text{SSR} + \text{SSE} \\ \text{df}_T = \text{df}_R + \text{df}_E \\ \text{SSR} \perp \text{SSE} \end{array} \right. \end{array} \right. \quad \begin{array}{l} \text{MST} = \frac{\text{SST}}{\text{df}_T} \stackrel{H_0}{\sim} \sigma^2 \frac{\chi_{(n-1)}^2}{n-1} \\ \text{MSR} = \frac{\text{SSR}}{\text{df}_R} \stackrel{H_0}{\sim} \sigma^2 \frac{\chi_{(a-1)}^2}{a-1} \\ \text{MSE} = \frac{\text{SSE}}{\text{df}_E} \sim \sigma^2 \frac{\chi_{(n-a)}^2}{n-a} \end{array}$$

(2) 主效应

注意到:

$$\begin{aligned}
SSR &= \|\hat{y} - \bar{y}_{..} \mathbf{1}_n\|^2 \\
&= \sum_{i=1}^a n_i (\bar{y}_{i.} - \bar{y}_{..})^2 \\
&= \sum_{i=1}^a n_i \left((\mu_i + \bar{\varepsilon}_{i.}) - \left(\frac{1}{n} \sum_{k=1}^a n_k \mu_k + \bar{\varepsilon}_{..} \right) \right)^2 \\
&= \sum_{i=1}^a n_i \left(\mu_i - \frac{1}{n} \sum_{k=1}^a n_k \mu_k + \bar{\varepsilon}_{i.} - \bar{\varepsilon}_{..} \right)^2 \\
&= \sum_{i=1}^a n_i (\text{ME}_{A_i} + \varepsilon_{i.} - \bar{\varepsilon}_{..})^2
\end{aligned}$$

其中 $\text{ME}_{A_i} = \mu_i - \frac{1}{n} \sum_{k=1}^a n_k \mu_k = \mu_i - \mu$. 称为因子水平 A_i 的**主效应** (main effect)
于是我们可以将零假设和备择假设等价表示为:

$$\begin{aligned}
H_0 : \text{ME}_{A_1} = \text{ME}_{A_2} = \cdots = \text{ME}_{A_a} = 0 \\
\Updownarrow \\
H_1 : \exists i \text{ such that } \text{ME}_{A_i} \neq 0
\end{aligned}$$

这就和多元线性回归的**回归方程显著性检验**之间建立了联系.

(3) 检验法

设第一类型错误概率界限为 α

多元线性回归的**回归方程显著性检验**指导我们使用如下的 F 统计量:

$$F := \frac{\text{MSR}}{\text{MSE}} \underset{H_0}{\sim} \frac{\sigma^2 \chi_{(a-1)}^2 / (a-1)}{\sigma^2 \chi_{(n-a)}^2 / (n-a)} = F_{a-1, n-a}$$

其中分子 MSR 和分母 MSE 是相互独立的 (无论零假设 H_0 是否成立)

记 $F_{a-1, n-a}(\alpha)$ 为 $F_{a-1, n-a}$ 分布的 $1 - \alpha$ 分位数.

主效应检验的 F -检验法为:

- 若 $F = \frac{\text{MSR}}{\text{MSE}} = \frac{\sum_{i=1}^a n_i (\bar{y}_{i.} - \bar{y}_{..})^2 / (a-1)}{\sum_{i=1}^a \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_{i.})^2 / (n-a)} > F_{a-1, n-a}(\alpha)$
则我们拒绝零假设 $H_0 : \text{ME}_{A_1} = \text{ME}_{A_2} = \cdots = \text{ME}_{A_a} = 0$
即拒绝零假设 $H_0 : \mu_1 = \mu_2 = \cdots = \mu_a$
说明当前所研究的因子 A 对响应变量 Y 有解释作用.

5.3 双因子方差分析

5.3.1 模型假设

在双因子方差分析中, 我们记模型中唯二的因子为 A, B

记 A 的 a 个因子水平为 $A_1, A_2, \dots, A_a$

记 B 的 b 个因子水平为 $B_1, B_2, \dots, B_b$

我们称 A, B 因子水平的组合 (A_i, B_j) 为一个 treatment

易知模型共计 ab 个 treatment:

A/B	B_1	$\cdots$	B_j	$\cdots$	B_b
A_1	μ_{11}				μ_{1b}
$\vdots$					
A_i			μ_{ij}		
$\vdots$					
A_a	μ_{a1}				μ_{ab}

其中 (i, j) 位置上的单元格对应的就是 treatment (A_i, B_j)

我们设每个 treatment 下都有 n 个观测

设 treatment (A_i, B_j) 下的 n 个观测为 $y_{ij1}, \dots, y_{ijn}$

其中 y_{ijk} 的下标 (i, j, k) 表明 y_{ijk} 是 treatment (A_i, B_j) 下的第 k 个观测

记 $y_{ijk} = \mu_{ij} + \varepsilon_{ijk}$

其中 μ_{ij} 为 treatment (A_i, B_j) 下观测的**理论均值**

随机项 $\{\varepsilon_{ijk}\} \stackrel{iid}{\sim} N(0, \sigma^2)$

我们记**行均值**、**列均值**和**总体均值**为:

$$\begin{cases} \mu_{i\cdot} = \frac{1}{b} \sum_{j=1}^b \mu_{ij} \\ \mu_{\cdot j} = \frac{1}{a} \sum_{i=1}^a \mu_{ij} \\ \mu_{\cdot\cdot} = \frac{1}{ab} \sum_{i=1}^a \sum_{j=1}^b \mu_{ij} \end{cases}$$

我们分别记 A_i 和 B_j 以及 (A_i, B_j) 的**主效应** (main effect) 为:

$$\begin{cases} \text{ME}_{A_i} = \mu_{i\cdot} - \mu_{\cdot\cdot} \\ \text{ME}_{B_j} = \mu_{\cdot j} - \mu_{\cdot\cdot} \\ \text{ME}_{(A_i, B_j)} = \mu_{ij} - \mu_{\cdot\cdot} \end{cases}$$

- 若 $\mu_{1\cdot} = \dots = \mu_{a\cdot} = \mu_{\cdot\cdot}$, 则主效应 $\text{ME}_{A_1} = \dots = \text{ME}_{A_a} = 0$
- 若 $\mu_{\cdot 1} = \dots = \mu_{\cdot b} = \mu_{\cdot\cdot}$, 则主效应 $\text{ME}_{B_1} = \dots = \text{ME}_{B_b} = 0$

我们称因子 A, B 是**可加的**, 如果它们满足:

$$\text{ME}_{(A_i, B_j)} = \text{ME}_{A_i} + \text{ME}_{B_j} \quad (\text{for all } \begin{cases} i = 1, 2, \dots, a \\ j = 1, 2, \dots, b \end{cases})$$

此时我们也称因子 A, B 之间不存在**交互效应** (interaction)

否则, 我们称因子 A, B 是**不可加的**, 代表因子 A, B 之间**存在交互效应**

双因子方差分析的模型通常建立在 "存在交互效应" 的基本假设下.

我们定义 $\text{IA}_{(A_i, B_j)}$ 用于衡量交互效应:

$$\begin{aligned} \text{IA}_{(A_i, B_j)} &:= \text{ME}_{(A_i, B_j)} - \text{ME}_{A_i} - \text{ME}_{B_j} \\ &= (\mu_{ij} - \mu_{\cdot\cdot}) - (\mu_{i\cdot} - \mu_{\cdot\cdot}) - (\mu_{\cdot j} - \mu_{\cdot\cdot}) \\ &= \mu_{ij} + \mu_{\cdot\cdot} - \mu_{i\cdot} - \mu_{\cdot j} \end{aligned}$$

值得注意的是:

$$\begin{aligned}
\sum_{i=1}^a \text{ME}_{A_i} &= \sum_{i=1}^a (\mu_{i\cdot} - \mu_{\cdot\cdot}) \\
&= a\mu_{\cdot\cdot} - a\mu_{\cdot\cdot} \\
&= 0
\end{aligned}

$$\begin{aligned}
\sum_{j=1}^b \text{ME}_{B_j} &= \sum_{j=1}^b (\mu_{\cdot j} - \mu_{\cdot\cdot}) \\
&= b\mu_{\cdot\cdot} - b\mu_{\cdot\cdot} \\
&= 0
\end{aligned}

$$\begin{aligned}
\sum_{i=1}^a \sum_{j=1}^b \text{ME}_{(A_i, B_j)} &= \sum_{i=1}^a \sum_{j=1}^b (\mu_{ij} - \mu_{\cdot\cdot}) \\
&= ab\mu_{\cdot\cdot} - ab\mu_{\cdot\cdot} \\
&= 0
\end{aligned}

$$\begin{aligned}
\sum_{i=1}^a \text{IA}_{(A_i, B_j)} &= \sum_{i=1}^a (\mu_{ij} + \mu_{\cdot\cdot} - \mu_{i\cdot} - \mu_{\cdot j}) \\
&= a\mu_{\cdot j} + a\mu_{\cdot\cdot} - a\mu_{\cdot\cdot} - a\mu_{\cdot j} \\
&= 0
\end{aligned}

$$\begin{aligned}
\sum_{j=1}^b \text{IA}_{(A_i, B_j)} &= \sum_{j=1}^b (\mu_{ij} + \mu_{\cdot\cdot} - \mu_{i\cdot} - \mu_{\cdot j}) \\
&= b\mu_{i\cdot} + b\mu_{\cdot\cdot} - b\mu_{\cdot\cdot} - b\mu_{i\cdot} \\
&= 0
\end{aligned}$$$$$$$$$$

5.3.2 点估计

(1) 记号

给定 abn 个样本观测 $\{y_{ijk}\}$ (其中 $i = 1, \dots, a, j = 1, \dots, b, k = 1, \dots, n$) 我们定义:

$$\begin{aligned}
\bar{y}_{ij\cdot} &:= \frac{1}{n} \sum_{k=1}^n y_{ijk} \\
\bar{y}_{i\cdot\cdot} &:= \frac{1}{bn} \sum_{j=1}^b \sum_{k=1}^n y_{ijk} = \frac{1}{b} \sum_{j=1}^b \bar{y}_{ij\cdot} \\
\bar{y}_{\cdot j\cdot} &:= \frac{1}{an} \sum_{i=1}^a \sum_{k=1}^n y_{ijk} = \frac{1}{a} \sum_{i=1}^a \bar{y}_{ij\cdot} \\
\bar{y}_{\cdot\cdot\cdot} &:= \frac{1}{abn} \sum_{i=1}^a \sum_{j=1}^b \sum_{k=1}^n y_{ijk} = \frac{1}{ab} \sum_{i=1}^a \sum_{j=1}^b \bar{y}_{ij\cdot}
\end{aligned}$$

设 $y_{ijk} = \mu_{ij} + \varepsilon_{ijk}$

其中 μ_{ij} 为 treatment (A_i, B_j) 的理论均值, 而 $\{\varepsilon_{ijk}\} \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$

类似地, 我们定义:

$$\begin{aligned}\bar{\varepsilon}_{ij\cdot} &:= \frac{1}{n} \sum_{k=1}^n \varepsilon_{ijk} \\ \bar{\varepsilon}_{i..} &:= \frac{1}{bn} \sum_{j=1}^b \sum_{k=1}^n \varepsilon_{ijk} = \frac{1}{b} \sum_{j=1}^b \bar{\varepsilon}_{ij\cdot} \\ \bar{\varepsilon}_{\cdot j\cdot} &:= \frac{1}{an} \sum_{i=1}^a \sum_{k=1}^n \varepsilon_{ijk} = \frac{1}{a} \sum_{i=1}^a \bar{\varepsilon}_{ij\cdot} \\ \bar{\varepsilon}_{...} &:= \frac{1}{abn} \sum_{i=1}^a \sum_{j=1}^b \sum_{k=1}^n \varepsilon_{ijk} = \frac{1}{ab} \sum_{i=1}^a \sum_{j=1}^b \bar{\varepsilon}_{ij\cdot}\end{aligned}$$

于是我们有:

$$\begin{aligned}\bar{y}_{ij\cdot} &= \frac{1}{n} \sum_{k=1}^n y_{ijk} = \frac{1}{n} \sum_{k=1}^n (\mu_{ij} + \varepsilon_{ijk}) = \mu_{ij} + \bar{\varepsilon}_{ij\cdot} \\ \bar{y}_{i..} &= \frac{1}{b} \sum_{j=1}^b \bar{y}_{ij\cdot} = \frac{1}{b} \sum_{j=1}^b (\mu_{ij} + \bar{\varepsilon}_{ij\cdot}) = \mu_{i\cdot} + \bar{\varepsilon}_{i..} \\ \bar{y}_{\cdot j\cdot} &= \frac{1}{a} \sum_{i=1}^a \bar{y}_{ij\cdot} = \frac{1}{a} \sum_{i=1}^a (\mu_{ij} + \bar{\varepsilon}_{ij\cdot}) = \mu_{\cdot j} + \bar{\varepsilon}_{\cdot j\cdot} \\ \bar{y}_{...} &= \frac{1}{ab} \sum_{i=1}^a \sum_{j=1}^b \bar{y}_{ij\cdot} = \frac{1}{ab} \sum_{i=1}^a \sum_{j=1}^b (\mu_{ij} + \bar{\varepsilon}_{ij\cdot}) = \mu_{..} + \bar{\varepsilon}_{...}\end{aligned}$$

(2) 均值

注意到 treatment (A_i, B_j) 下的观测 $y_{i,j,1}, y_{i,j,2}, \dots, y_{i,j,n}$ 相互独立, 且同分布于 $N(\mu_{ij}, \sigma^2)$
考虑优化问题:

$$\begin{aligned}\min_{\mu \in \mathbb{R}} \|y^{(i,j)} - \mu \mathbf{1}_n\|^2 &:= \sum_{k=1}^n (y_{ijk} - \mu)^2 \\ \text{where } y^{(i,j)} &= \begin{bmatrix} y_{i,j,1} \\ \vdots \\ y_{i,j,n} \end{bmatrix}\end{aligned}$$

令 $\nabla_{\mu} \|y^{(i,j)} - \mu \mathbf{1}_n\|^2 = -2 \cdot \mathbf{1}_n^T (y^{(i,j)} - \mu \mathbf{1}_n) = 0_n$ 可知 μ_{ij} 的最小二乘估计量为:

$$\hat{\mu}_{ij} := (\mathbf{1}_n^T \mathbf{1}_n)^{-1} \mathbf{1}_n^T y^{(i,j)} = \frac{1}{n} \sum_{k=1}^n y_{ijk} = \bar{y}_{ij\cdot}$$

根据多元线性回归的 **Gauss-Markov 定理**可知 $\bar{y}_{ij\cdot}$ 是 μ_{ij} 的最佳线性无偏估计量 (BLUE)
它服从正态分布:

$$\bar{y}_{ij\cdot} = \frac{1}{n} \sum_{k=1}^n y_{ijk} \sim N(\mu_{ij}, \frac{\sigma^2}{n})$$

基于上述结论我们有:

- $\hat{\mu}_{ij} := \bar{y}_{ij\cdot} \sim N(\mu_{ij}, \frac{\sigma^2}{n})$ 是 μ_{ij} 的 BLUE
- $\hat{\mu}_{i\cdot} := \bar{y}_{i..} \sim N(\mu_{i\cdot}, \frac{\sigma^2}{bn})$ 是 $\mu_{i\cdot}$ 的 BLUE
- $\hat{\mu}_{\cdot j} := \bar{y}_{\cdot j\cdot} \sim N(\mu_{\cdot j}, \frac{\sigma^2}{an})$ 是 $\mu_{\cdot j}$ 的 BLUE
- $\hat{\mu}_{..} := \bar{y}_{...} \sim N(\mu_{..}, \frac{\sigma^2}{abn})$ 是 $\mu_{..}$ 的 BLUE
- $\widehat{\text{ME}}_{A_i} := \bar{y}_{i..} - \bar{y}_{...}$ 是 $\text{ME}_{A_i} = \mu_{i\cdot} - \mu_{..}$ 的 BLUE

- $\widehat{\text{ME}}_{B_j} := \bar{y}_{\cdot j} - \bar{y}_{\dots}$ 是 $\text{ME}_{B_j} = \mu_{\cdot j} - \mu_{\dots}$ 的 BLUE
- $\widehat{\text{ME}}_{(A_i, B_j)} := \bar{y}_{ij\cdot} - \bar{y}_{\dots}$ 是 $\text{ME}_{(A_i, B_j)} = \mu_{ij} - \mu_{\dots}$ 的 BLUE
- $\widehat{\text{IA}}_{(A_i, B_j)} := \widehat{\text{ME}}_{(A_i, B_j)} - \widehat{\text{ME}}_{A_i} - \widehat{\text{ME}}_{B_j} = \bar{y}_{ij\cdot} + \bar{y}_{\dots} - \bar{y}_{i\cdot} - \bar{y}_{\cdot j}$ 是 $\text{IA}_{(A_i, B_j)} := \text{ME}_{(A_i, B_j)} - \text{ME}_{A_i} - \text{ME}_{B_j} = \mu_{ij} + \mu_{\dots} - \mu_{i\cdot} - \mu_{\cdot j}$ 的 BLUE
- 类似地, 我们有:

$$\begin{aligned}
\sum_{i=1}^a \widehat{\text{ME}}_{A_i} &= \sum_{i=1}^a (\bar{y}_{i\cdot} - \bar{y}_{\dots}) \\
&= a\bar{y}_{\dots} - a\bar{y}_{\dots} \\
&= 0 \\
\hline
\sum_{j=1}^b \widehat{\text{ME}}_{B_j} &= \sum_{j=1}^b (\bar{y}_{\cdot j} - \bar{y}_{\dots}) \\
&= b\bar{y}_{\dots} - b\bar{y}_{\dots} \\
&= 0 \\
\hline
\sum_{i=1}^a \sum_{j=1}^b \widehat{\text{ME}}_{(A_i, B_j)} &= \sum_{i=1}^a \sum_{j=1}^b (\bar{y}_{ij\cdot} - \bar{y}_{\dots}) \\
&= ab\bar{y}_{\dots} - ab\bar{y}_{\dots} \\
&= 0 \\
\hline
\sum_{i=1}^a \widehat{\text{IA}}_{(A_i, B_j)} &= \sum_{i=1}^a (\bar{y}_{ij\cdot} + \bar{y}_{\dots} - \bar{y}_{i\cdot} - \bar{y}_{\cdot j}) \\
&= a\bar{y}_{\cdot j} + a\bar{y}_{\dots} - a\bar{y}_{\dots} - a\bar{y}_{\cdot j} \\
&= 0 \\
\hline
\sum_{j=1}^b \widehat{\text{IA}}_{(A_i, B_j)} &= \sum_{j=1}^b (\bar{y}_{ij\cdot} + \bar{y}_{\dots} - \bar{y}_{i\cdot} - \bar{y}_{\cdot j}) \\
&= b\bar{y}_{i\cdot} + b\bar{y}_{\dots} - b\bar{y}_{\dots} - b\bar{y}_{i\cdot} \\
&= 0
\end{aligned}$$

(3) 方差

考虑双因子方差分析的多元线性回归形式:

$$\begin{bmatrix} y^{(\cdot 1)} \\ y^{(\cdot 2)} \\ \vdots \\ y^{(\cdot b)} \end{bmatrix} = \begin{bmatrix} I_a \otimes 1_n & & & \\ & I_a \otimes 1_n & & \\ & & \ddots & \\ & & & I_a \otimes 1_n \end{bmatrix}_{abn \times ab} \begin{bmatrix} \mu^{(\cdot 1)} \\ \mu^{(\cdot 2)} \\ \vdots \\ \mu^{(\cdot b)} \end{bmatrix} + \begin{bmatrix} \varepsilon^{(\cdot 1)} \\ \varepsilon^{(\cdot 2)} \\ \vdots \\ \varepsilon^{(\cdot b)} \end{bmatrix}$$

其中 $\otimes$ 代表 Kronecker 乘积, 而其他记号定义如下:

$$I_a \otimes 1_n = \begin{bmatrix} 1_n & & & \\ & 1_n & & \\ & & \ddots & \\ & & & 1_n \end{bmatrix}_{an \times a}$$

$$y^{(i,j)} = \begin{bmatrix} y_{i,j,1} \\ y_{i,j,2} \\ \vdots \\ y_{i,j,n} \end{bmatrix} \quad y^{(\cdot,j)} = \begin{bmatrix} y^{(1,j)} \\ y^{(2,j)} \\ \vdots \\ y^{(a,j)} \end{bmatrix}$$

$$\varepsilon^{(i,j)} = \begin{bmatrix} \varepsilon_{i,j,1} \\ \varepsilon_{i,j,2} \\ \vdots \\ \varepsilon_{i,j,n} \end{bmatrix} \quad \varepsilon^{(\cdot,j)} = \begin{bmatrix} \varepsilon^{(1,j)} \\ \varepsilon^{(2,j)} \\ \vdots \\ \varepsilon^{(a,j)} \end{bmatrix}$$

$$\{\varepsilon_{ijk}\} \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$$

$$\mu^{(\cdot,j)} = \begin{bmatrix} \mu_{1j} \\ \mu_{2j} \\ \vdots \\ \mu_{aj} \end{bmatrix} \quad \bar{y}^{(\cdot,j)} = \begin{bmatrix} \bar{y}_{1j\cdot} \\ \bar{y}_{2j\cdot} \\ \vdots \\ \bar{y}_{aj\cdot} \end{bmatrix}$$

根据多元线性回归的结论可知 σ^2 的无偏估计量为:

$$s^2 = \frac{1}{abn - ab} \left\| \begin{bmatrix} y^{(\cdot 1)} \\ y^{(\cdot 2)} \\ \vdots \\ y^{(\cdot b)} \end{bmatrix} - \begin{bmatrix} I_a \otimes 1_n & & \\ & I_a \otimes 1_n & \\ & & \ddots \\ & & & I_a \otimes 1_n \end{bmatrix}_{abn \times ab} \begin{bmatrix} \bar{y}^{(\cdot 1)} \\ \bar{y}^{(\cdot 2)} \\ \vdots \\ \bar{y}^{(\cdot b)} \end{bmatrix} \right\|^2$$

$$= \frac{1}{ab(n-1)} \left\| \begin{bmatrix} y^{(\cdot 1)} - \bar{y}^{(\cdot 1)} \odot 1_{an} \\ y^{(\cdot 2)} - \bar{y}^{(\cdot 2)} \odot 1_{an} \\ \vdots \\ y^{(\cdot b)} - \bar{y}^{(\cdot b)} \odot 1_{an} \end{bmatrix} \right\|^2 \quad (\text{where } \odot \text{ denote elementwise product})$$

$$= \frac{1}{ab(n-1)} \sum_{i=1}^a \sum_{j=1}^b \|y^{(i,j)} - \bar{y}_{ij\cdot} 1_n\|^2$$

$$= \frac{1}{ab(n-1)} \sum_{i=1}^a \sum_{j=1}^b (n-1) s_{ij}^2$$

其中 $s_{ij}^2 = \frac{1}{n-1} \|y^{(i,j)} - \bar{y}_{ij\cdot} 1_n\|^2 = \frac{1}{n-1} \sum_{k=1}^n (y_{ijk} - \bar{y}_{ij\cdot})^2$ 为 treatment (A_i, B_j) 下的样本方差.

(4) 分布

根据多元线性回归的结论可知:

- ① 关于样本均值:

$$\bar{y}_{ij\cdot} = \frac{1}{n} \sum_{k=1}^n y_{ijk} \sim N\left(\mu_{ij}, \frac{\sigma^2}{n}\right)$$

$$\bar{y}_{i\cdot\cdot} = \frac{1}{b} \sum_{j=1}^b \bar{y}_{ij\cdot} \sim N\left(\mu_i, \frac{\sigma^2}{bn}\right)$$

$$\bar{y}_{\cdot j\cdot} = \frac{1}{a} \sum_{i=1}^a \bar{y}_{ij\cdot} \sim N\left(\mu_{\cdot j}, \frac{\sigma^2}{an}\right)$$

$$\bar{y}_{\dots} = \frac{1}{ab} \sum_{i=1}^a \sum_{j=1}^b \bar{y}_{ij\cdot} \sim N\left(\mu_{\dots}, \frac{\sigma^2}{abn}\right)$$

- ② $s_i^2 = \frac{1}{n-1} \sum_{k=1}^n (y_{ijk} - \bar{y}_{ij\cdot})^2 \sim \frac{1}{n-1} \sigma^2 \chi_{(n-1)}^2$ 且 $\bar{y}_{ij\cdot} \perp s_{ij}^2$
(事实上对于任意 i_1, i_2 和 j_1, j_2 , 我们都有 $\bar{y}_{i_1 j_1\cdot} \perp s_{i_2 j_2}^2$ 成立)
- ③ $s^2 = \frac{1}{ab(n-1)} \sum_{i=1}^a \sum_{j=1}^b (n-1) s_{ij}^2 \sim \frac{1}{ab(n-1)} \sigma^2 \chi_{(ab(n-1))}^2$ 且 $s^2 \perp \bar{y}_{ij\cdot} (\forall i = 1, \dots, a, j = 1, \dots, b)$

5.3.3 交互效应存在性检验

首先我们想知道因子 A, B 之间是否存在交互效应.

因此零假设和备择假设分别为:

$$H_0 : \widehat{\text{IA}}_{(A_i, B_j)} = 0 \text{ for all } \begin{cases} i = 1, \dots, a \\ j = 1, \dots, b \end{cases}$$

$$\Updownarrow$$

$$H_1 : \exists i, j \text{ such that } \widehat{\text{IA}}_{(A_i, B_j)} \neq 0$$

(1) 基本记号

为了记号的简便, 我们记:

$$\begin{aligned} \sum_{i=1}^a \sum_{j=1}^b \sum_{k=1}^n &\equiv \sum_{i,j,k}^{a,b,n} \\ \sum_{i=1}^a \sum_{j=1}^b &\equiv \sum_{i,j}^{a,b} \end{aligned}$$

考虑总平方和 SST (Total Sum of Squares) 的分解:

$$\begin{aligned}
\text{SST} &= \sum_{i,j,k}^{a,b,n} (y_{ijk} - \bar{y}_{...})^2 \\
&= \sum_{i,j,k}^{a,b,n} (y_{i,j,k} - \bar{y}_{ij\cdot} + \bar{y}_{ij\cdot} - \bar{y}_{...})^2 \\
&= \sum_{i,j,k}^{a,b,n} (y_{ijk} - \bar{y}_{ij\cdot})^2 + \sum_{i,j,k}^{a,b,n} (\bar{y}_{ij\cdot} - \bar{y}_{...})^2 + 2 \sum_{i,j,k}^{a,b,n} (y_{ijk} - \bar{y}_{ij\cdot})(\bar{y}_{ij\cdot} - \bar{y}_{...}) \\
&= \sum_{i,j,k}^{a,b,n} (y_{ijk} - \bar{y}_{ij\cdot})^2 + n \sum_{i,j}^{a,b} (\bar{y}_{ij\cdot} - \bar{y}_{...})^2 + 2 \sum_{i,j}^{a,b} \left\{ (\bar{y}_{ij\cdot} - \bar{y}_{...}) \sum_{k=1}^n (y_{ijk} - \bar{y}_{ij\cdot}) \right\} \\
&= \sum_{i,j,k}^{a,b,n} (y_{ijk} - \bar{y}_{ij\cdot})^2 + n \sum_{i,j}^{a,b} (\bar{y}_{ij\cdot} - \bar{y}_{...})^2 + 2 \sum_{i,j}^{a,b} \{ (\bar{y}_{ij\cdot} - \bar{y}_{...})(n\bar{y}_{ij\cdot} - n\bar{y}_{ij\cdot}) \} \\
&= \sum_{i,j,k}^{a,b,n} (y_{ijk} - \bar{y}_{ij\cdot})^2 + n \sum_{i,j}^{a,b} (\bar{y}_{ij\cdot} - \bar{y}_{...})^2 \\
&= \text{SSE} + \text{SAB}
\end{aligned}$$

注意到 SST 有 abn 个变量 $\{y_{ijk}\}$ 和一个约束 $\sum_{i,j,k}^{a,b,n} (y_{ijk} - \bar{y}_{...}) = 0$
因此其自由度 $\text{df}_{\text{SST}} = abn - 1$

- 根据交叉项 = 0 可知 $\text{SSE} \perp \text{SAB}$
- **组内偏差平方和** (Within-Group Deviation Sum of Squares)

$$\begin{aligned}
\text{SSE} &= \sum_{i,j,k}^{a,b,n} (y_{ijk} - \bar{y}_{ij\cdot})^2 \quad (\text{note that } s_{ij}^2 := \frac{1}{n-1} \sum_{k=1}^n (y_{ijk} - \bar{y}_{ij\cdot})^2) \\
&= \sum_{i,j}^{a,b} (n-1) s_{ij}^2 \quad (\text{note that } s^2 := \frac{1}{ab(n-1)} \sum_{i,j}^{a,b} (n-1) s_{ij}^2 \sim \frac{\sigma^2}{ab(n-1)} \chi_{ab(n-1)}^2) \\
&= ab(n-1) s^2 \\
&\sim \sigma^2 \chi_{ab(n-1)}^2
\end{aligned}$$

显然 SSE 的自由度 $\text{df}_{\text{SSE}} = ab(n-1)$

- **组间偏差平方和** (Between-Group Deviation Sum of Squares)

$$\begin{aligned}
\text{SAB} &= \sum_{i,j,k}^{a,b,n} (\bar{y}_{ij\cdot} - \bar{y}_{\dots})^2 \\
&= n \sum_{i,j}^{a,b} (\bar{y}_{ij\cdot} - \bar{y}_{\dots})^2 \\
&= n \sum_{i,j}^{a,b} \widehat{\text{ME}}_{(A_i, B_j)}^2 \quad (\text{note that } \widehat{\text{IA}}_{(A_i, B_j)} := \widehat{\text{ME}}_{(A_i, B_j)} - \widehat{\text{ME}}_{A_i} - \widehat{\text{ME}}_{B_j}) \\
&= n \sum_{i,j}^{a,b} (\widehat{\text{IA}}_{(A_i, B_j)} + \widehat{\text{ME}}_{A_i} + \widehat{\text{ME}}_{B_j})^2 \\
&= n \sum_{i,j}^{a,b} \widehat{\text{IA}}_{(A_i, B_j)}^2 + n \sum_{i,j}^{a,b} \widehat{\text{ME}}_{A_i}^2 + n \sum_{i,j}^{a,b} \widehat{\text{ME}}_{B_j}^2 \\
&\quad + 2n \sum_{i,j}^{a,b} \widehat{\text{ME}}_{A_i} \widehat{\text{ME}}_{B_j} + 2n \sum_{i,j}^{a,b} \widehat{\text{IA}}_{(A_i, B_j)} \widehat{\text{ME}}_{A_i} + 2n \sum_{i,j}^{a,b} \widehat{\text{IA}}_{(A_i, B_j)} \widehat{\text{ME}}_{B_j} \\
&= n \sum_{i,j}^{a,b} \widehat{\text{IA}}_{(A_i, B_j)}^2 + bn \sum_{i=1}^a \widehat{\text{ME}}_{A_i}^2 + an \sum_{j=1}^b \widehat{\text{ME}}_{B_j}^2 \\
&\quad + 2n \sum_{i=1}^a \widehat{\text{ME}}_{A_i} \sum_{j=1}^b \widehat{\text{ME}}_{B_j} + 2n \sum_{i=1}^a \left\{ \widehat{\text{ME}}_{A_i} \sum_{j=1}^b \widehat{\text{IA}}_{(A_i, B_j)} \right\} + 2n \sum_{j=1}^b \left\{ \widehat{\text{ME}}_{B_j} \sum_{i=1}^a \widehat{\text{IA}}_{(A_i, B_j)} \right\} \\
&= n \sum_{i,j}^{a,b} \widehat{\text{IA}}_{(A_i, B_j)}^2 + bn \sum_{i=1}^a \widehat{\text{ME}}_{A_i}^2 + an \sum_{j=1}^b \widehat{\text{ME}}_{B_j}^2 \\
&\quad + 2n \cdot 0 \cdot 0 + 2n \sum_{i=1}^a \left\{ \widehat{\text{ME}}_{A_i} \cdot 0 \right\} + 2n \sum_{j=1}^b \left\{ \widehat{\text{ME}}_{B_j} \cdot 0 \right\} \\
&= n \sum_{i,j}^{a,b} \widehat{\text{IA}}_{(A_i, B_j)}^2 + bn \sum_{i=1}^a \widehat{\text{ME}}_{A_i}^2 + an \sum_{j=1}^b \widehat{\text{ME}}_{B_j}^2 \\
&= \text{SSAB} + \text{SSA} + \text{SSB}
\end{aligned}$$

注意到 SAB 有 ab 个变量 $\{\bar{y}_{ij\cdot}\}$ 和一个约束 $\sum_{i,j}^{a,b} (\bar{y}_{ij\cdot} - \bar{y}_{\dots}) = 0$

因此其自由度 $\text{df}_{\text{SAB}} = ab - 1$

- 根据交叉项 = 0 可知 SSAB, SSA, SSB 相互独立。
- **交互效应平方和** (Interaction Sum of Squares)

$$\begin{aligned}
\text{SSAB} &= n \sum_{i,j}^{a,b} \widehat{\text{IA}}_{(A_i, B_j)}^2 \\
&= n \sum_{i,j}^{a,b} (\bar{y}_{ij\cdot} + \bar{y}_{\dots} - \bar{y}_{i\cdot\cdot} - \bar{y}_{\cdot j\cdot})^2
\end{aligned}$$

注意到 SSAB 有 ab 个变量 $\{\bar{y}_{ij\cdot}\}$ 和 $a + b - 1$ 个约束 (注意不是 $a + b$ 个, 因为有一个约束是冗余的):

$$\begin{aligned}
\sum_{i=1}^a \widehat{\text{IA}}_{(A_i, B_j)} &= 0 \quad (j = 1, \dots, b) \\
\sum_{j=1}^b \widehat{\text{IA}}_{(A_i, B_j)} &= 0 \quad (i = 1, \dots, a - 1)
\end{aligned}$$

因此其自由度 $\text{df}_{\text{SSAB}} = ab - (a + b - 1) = (a - 1)(b - 1)$

- 因子 A 的因子水平 $A_1, \dots, A_a$ 之间的**偏差平方和**:

$$\begin{aligned} \text{SSA} &= bn \sum_{i=1}^a \widehat{\text{ME}}_{A_i}^2 \\ &= bn \sum_{i=1}^a (\bar{y}_{i..} - \bar{y}_{...})^2 \end{aligned}$$

注意到 SSA 有 a 个变量 $\{\bar{y}_{i..}\}$ 和一个约束 $\sum_{i=1}^a (\bar{y}_{i..} - \bar{y}_{...}) = 0$
因此其自由度 $\text{df}_{\text{SSA}} = a - 1$

- 因子 B 的因子水平 $B_1, \dots, B_b$ 之间的**偏差平方和**

$$\begin{aligned} \text{SSB} &= an \sum_{j=1}^b \widehat{\text{ME}}_{B_j}^2 \\ &= an \sum_{j=1}^b (\bar{y}_{.j.} - \bar{y}_{...})^2 \end{aligned}$$

注意到 SSB 有 b 个变量 $\{\bar{y}_{.j.}\}$ 和一个约束 $\sum_{j=1}^b (\bar{y}_{.j.} - \bar{y}_{...}) = 0$
因此其自由度 $\text{df}_{\text{SSB}} = b - 1$

在存在交互效应的假设下，双因子方差分析的 ANOVA TABLE 如下:

ANOVA TABLE (with interaction)

Sum of Squares		Degree of Freedom	Mean Squares
SST	$\sum_{i,j,k}^{a,b,n} (y_{ijk} - \bar{y}_{...})^2$	$abn - 1$	$\text{MST} = \frac{\text{SST}}{abn-1}$
SSE	$\sum_{i,j,k}^{a,b,n} (y_{ijk} - \bar{y}_{ij.})^2$	$ab(n - 1)$	$\text{MSE} = \frac{\text{SSE}}{ab(n-1)}$
SAB	$n \sum_{i,j}^{a,b} \widehat{\text{ME}}_{(A_i, B_j)}^2$	$ab - 1$	$\text{MAB} = \frac{\text{SAB}}{ab-1}$
SSAB	$n \sum_{i,j}^{a,b} \widehat{\text{IA}}_{(A_i, B_j)}^2$	$(a - 1)(b - 1)$	$\text{MSAB} = \frac{\text{SSAB}}{(a-1)(b-1)}$
SSA	$bn \sum_{i=1}^a \widehat{\text{ME}}_{A_i}^2$	$a - 1$	$\text{MSA} = \frac{\text{SSA}}{a-1}$
SSB	$an \sum_{j=1}^b \widehat{\text{ME}}_{B_j}^2$	$b - 1$	$\text{MSB} = \frac{\text{SSB}}{b-1}$

$$\widehat{\text{ME}}_{A_i} = \bar{y}_{i..} - \bar{y}_{...}$$

$$\widehat{\text{ME}}_{B_j} = \bar{y}_{.j.} - \bar{y}_{...}$$

$$\widehat{\text{ME}}_{(A_i, B_j)} = \bar{y}_{ij.} - \bar{y}_{...}$$

$$\widehat{\text{IA}}_{(A_i, B_j)} = \widehat{\text{ME}}_{(A_i, B_j)} - \widehat{\text{ME}}_{A_i} - \widehat{\text{ME}}_{B_j} = \bar{y}_{ij.} + \bar{y}_{...} - \bar{y}_{i..} - \bar{y}_{.j.}$$

(2) 零假设分布

考虑零假设 H_0 :

$$H_0 : \widehat{\text{IA}}_{(A_i, B_j)} = 0 \text{ for all } \begin{cases} i = 1, \dots, a \\ j = 1, \dots, b \end{cases}$$

在零假设 H_0 成立的前提条件下，我们有:

$$\begin{aligned}
\widehat{\mathbf{IA}}_{(A_i, B_j)} &= \widehat{\mathbf{ME}}_{(A_i, B_j)} - \widehat{\mathbf{ME}}_{A_i} - \widehat{\mathbf{ME}}_{B_j} \\
&= \bar{y}_{ij\cdot} + \bar{y}_{\dots} - \bar{y}_{i\cdot\cdot} - \bar{y}_{\cdot j\cdot} \\
&= (\mu_{ij} + \bar{\varepsilon}_{ij\cdot}) + (\mu_{\dots} + \bar{\varepsilon}_{\dots}) - (\mu_{i\cdot} + \bar{\varepsilon}_{i\cdot\cdot}) - (\mu_{\cdot j} + \bar{\varepsilon}_{\cdot j\cdot}) \\
&= (\mu_{ij} + \mu_{\dots} - \mu_{i\cdot} - \mu_{\cdot j}) + \bar{\varepsilon}_{ij\cdot} + \bar{\varepsilon}_{\dots} - \bar{\varepsilon}_{i\cdot\cdot} - \bar{\varepsilon}_{\cdot j\cdot} \\
&= \mathbf{IA}_{(A_i, B_j)} + \bar{\varepsilon}_{ij\cdot} + \bar{\varepsilon}_{\dots} - \bar{\varepsilon}_{i\cdot\cdot} - \bar{\varepsilon}_{\cdot j\cdot} \\
&\stackrel{H_0}{=} \bar{\varepsilon}_{ij\cdot} + \bar{\varepsilon}_{\dots} - \bar{\varepsilon}_{i\cdot\cdot} - \bar{\varepsilon}_{\cdot j\cdot}
\end{aligned}$$

定义 $\mathbf{E} := [\bar{\varepsilon}_{ij\cdot}] \in \mathbb{R}^{a \times b}$

用 $\mathbf{E}_{(i,:)}$ 代表 $\mathbf{E}$ 的第 i 行, 用 $\mathbf{E}_{(:,j)}$ 代表 $\mathbf{E}$ 的第 j 列.

注意到:

$$\begin{aligned}
\bar{\varepsilon}_{i\cdot\cdot} &= \frac{1}{b} \sum_{j=1}^b \bar{\varepsilon}_{ij\cdot} = \mathbf{E}_{(i,:)} \cdot \frac{1}{b} \mathbf{1}_b \\
\bar{\varepsilon}_{\cdot j\cdot} &= \frac{1}{a} \sum_{i=1}^a \bar{\varepsilon}_{ij\cdot} = \frac{1}{a} \mathbf{1}_a^T \cdot \mathbf{E}_{(:,j)} \\
\bar{\varepsilon}_{\dots} &= \frac{1}{ab} \sum_{i=1}^a \sum_{j=1}^b \bar{\varepsilon}_{ij\cdot} = \frac{1}{a} \mathbf{1}_a^T \cdot \mathbf{E} \cdot \frac{1}{b} \mathbf{1}_b
\end{aligned}$$

因此我们有:

$$\begin{aligned}
\begin{bmatrix} \bar{\varepsilon}_{1\cdot\cdot} & \cdots & \bar{\varepsilon}_{1\cdot\cdot} \\ \vdots & & \vdots \\ \bar{\varepsilon}_{a\cdot\cdot} & \cdots & \bar{\varepsilon}_{a\cdot\cdot} \end{bmatrix} &= \begin{bmatrix} \bar{\varepsilon}_{1\cdot\cdot} \mathbf{1}_b^T \\ \vdots \\ \bar{\varepsilon}_{a\cdot\cdot} \mathbf{1}_b^T \end{bmatrix} = \mathbf{E} \cdot \frac{1}{b} \mathbf{1}_b \mathbf{1}_b^T \\
\begin{bmatrix} \bar{\varepsilon}_{\cdot 1\cdot} & \cdots & \bar{\varepsilon}_{\cdot b\cdot} \\ \vdots & & \vdots \\ \bar{\varepsilon}_{\cdot 1\cdot} & \cdots & \bar{\varepsilon}_{\cdot b\cdot} \end{bmatrix} &= [\bar{\varepsilon}_{\cdot 1\cdot} \mathbf{1}_a \quad \cdots \quad \bar{\varepsilon}_{\cdot b\cdot} \mathbf{1}_a] = \frac{1}{a} \mathbf{1}_a \mathbf{1}_a^T \cdot \mathbf{E} \\
\begin{bmatrix} \bar{\varepsilon}_{\dots} & \cdots & \bar{\varepsilon}_{\dots} \\ \vdots & & \vdots \\ \bar{\varepsilon}_{\dots} & \cdots & \bar{\varepsilon}_{\dots} \end{bmatrix} &= \mathbf{1}_a \bar{\varepsilon}_{\dots} \mathbf{1}_b^T = \frac{1}{a} \mathbf{1}_a \mathbf{1}_a^T \cdot \mathbf{E} \cdot \frac{1}{b} \mathbf{1}_b \mathbf{1}_b^T
\end{aligned}$$

于是我们有:

$$\begin{aligned}
&(\mathbf{I}_a - \frac{1}{a} \mathbf{1}_a \mathbf{1}_a^T) \mathbf{E} (\mathbf{I}_b - \frac{1}{b} \mathbf{1}_b \mathbf{1}_b^T) \\
&= \mathbf{E} + \frac{1}{a} \mathbf{1}_a \mathbf{1}_a^T \cdot \mathbf{E} \cdot \frac{1}{b} \mathbf{1}_b \mathbf{1}_b^T - \mathbf{E} \cdot \frac{1}{b} \mathbf{1}_b \mathbf{1}_b^T - \frac{1}{a} \mathbf{1}_a \mathbf{1}_a^T \cdot \mathbf{E} \\
&= [\bar{\varepsilon}_{ij\cdot}] + [\bar{\varepsilon}_{\dots}] - [\bar{\varepsilon}_{i\cdot\cdot}] - [\bar{\varepsilon}_{\cdot j\cdot}] \\
&= [\bar{\varepsilon}_{ij\cdot} + \bar{\varepsilon}_{\dots} - \bar{\varepsilon}_{i\cdot\cdot} - \bar{\varepsilon}_{\cdot j\cdot}] \\
&\stackrel{H_0}{=} [\widehat{\mathbf{IA}}_{(A_i, B_j)}]
\end{aligned}$$

记 $\begin{cases} P_a = \mathbf{I}_a - \frac{1}{a} \mathbf{1}_a \mathbf{1}_a^T \\ P_b = \mathbf{I}_b - \frac{1}{b} \mathbf{1}_b \mathbf{1}_b^T \end{cases}$

显然它们是投影算子 (即自伴且幂等), 记其谱分解为:

$$\begin{cases} P_a = Q_a \Lambda_a Q_a^T \\ P_b = Q_b \Lambda_b Q_b^T \end{cases} \text{ where } \begin{cases} \Lambda_a = \text{diag}\{\underbrace{1, \dots, 1}_{a-1 \text{ times}}, 0\} \\ \Lambda_b = \text{diag}\{\underbrace{1, \dots, 1}_{b-1 \text{ times}}, 0\} \end{cases}$$

则我们有:

$$\begin{aligned}
\text{SSAB} &= n \sum_{i,j}^{a,b} \widehat{\mathbf{I}\mathbf{A}}_{(A_i, B_j)}^2 \quad (\text{note that } \widehat{\mathbf{I}\mathbf{A}}_{(A_i, B_j)} \stackrel{H_0}{=} \bar{\varepsilon}_{ij\cdot} + \bar{\varepsilon}_{\dots} - \bar{\varepsilon}_{i\cdot\cdot} - \bar{\varepsilon}_{\cdot j\cdot}) \\
&\stackrel{H_0}{=} n \sum_{i,j}^{a,b} (\bar{\varepsilon}_{ij\cdot} + \bar{\varepsilon}_{\dots} - \bar{\varepsilon}_{i\cdot\cdot} - \bar{\varepsilon}_{\cdot j\cdot})^2 \quad (\text{note that } \bar{\varepsilon}_{ij\cdot} + \bar{\varepsilon}_{\dots} - \bar{\varepsilon}_{i\cdot\cdot} - \bar{\varepsilon}_{\cdot j\cdot} = [P_a \mathbf{E} P_b]_{(i,j)}) \\
&= n \sum_{i,j}^{a,b} ([P_a \mathbf{E} P_b]_{(i,j)})^2 \\
&= n \|\mathbf{P}_a \mathbf{E} P_b\|_{\text{F}}^2 \quad (\text{Frobenius norm}) \\
&= n \cdot \text{tr}((P_a \mathbf{E} P_b)^{\text{T}} P_a \mathbf{E} P_b) \\
&= n \cdot \text{tr}(P_b^{\text{T}} \mathbf{E}^{\text{T}} P_a^{\text{T}} P_a \mathbf{E} P_b) \\
&= n \cdot \text{tr}(\mathbf{E}^{\text{T}} P_a^{\text{T}} P_a \mathbf{E} P_b P_b^{\text{T}}) \quad (\text{note that } \begin{cases} P_a^{\text{T}} P_a = P_a^2 = P_a \\ P_b^{\text{T}} P_b = P_b^2 = P_b \end{cases}) \\
&= n \cdot \text{tr}(\mathbf{E}^{\text{T}} P_a \mathbf{E} P_b) \quad (\text{note that } \begin{cases} P_a = Q_a \Lambda_a Q_a^{\text{T}} \\ P_b = Q_b \Lambda_b Q_b^{\text{T}} \end{cases}) \\
&= n \cdot \text{tr}(\mathbf{E}^{\text{T}} Q_a \Lambda_a Q_a^{\text{T}} \mathbf{E} Q_b \Lambda_b Q_b^{\text{T}}) \\
&= n \cdot \text{tr}(Q_b^{\text{T}} \mathbf{E}^{\text{T}} Q_a \Lambda_a Q_a^{\text{T}} \mathbf{E} Q_b \Lambda_b) \quad (\text{denote } \tilde{\mathbf{E}} := Q_a^{\text{T}} \mathbf{E} Q_b) \\
&= n \cdot \text{tr}(\tilde{\mathbf{E}}^{\text{T}} \Lambda_a \tilde{\mathbf{E}} \Lambda_b) \\
&= n \cdot \text{tr}((\Lambda_a \tilde{\mathbf{E}})^{\text{T}} (\tilde{\mathbf{E}} \Lambda_b)) \quad (\text{note that } \Lambda_a = \underbrace{\text{diag}\{1, \dots, 1, 0\}}_{a-1 \text{ times}} \text{ and } \Lambda_b = \underbrace{\text{diag}\{1, \dots, 1, 0\}}_{b-1 \text{ times}}) \\
&= n \sum_{i=1}^{a-1} \sum_{j=1}^{b-1} \tilde{\mathbf{E}}_{(i,j)}^2
\end{aligned}$$

注意到 $\mathbf{E} := [\bar{\varepsilon}_{ij\cdot}] \in \mathbb{R}^{a \times b}$ 的元素独立同分布:

$$\{\bar{\varepsilon}_{ij\cdot}\} \stackrel{\text{iid}}{\sim} N\left(0, \frac{\sigma^2}{n}\right)$$

我们可以将整个 $\mathbf{E} \in \mathbb{R}^{a \times b}$ 的分布表示为:

$$\text{vec}(\mathbf{E}) \sim N\left(0_{ab}, \frac{\sigma^2}{n} I_b \otimes I_a\right)$$

其中 $\text{vec}(\cdot)$ 是向量化操作符 (即将一个矩阵按列拉伸为向量), 而 $\otimes$ 代表 Kronecker 乘积. 于是我们有:

$$\begin{aligned}
\text{vec}(\tilde{\mathbf{E}}) &= \text{vec}(Q_a^{\text{T}} \mathbf{E} Q_b) \quad (\text{note that } \text{vec}(AXB) = (B^{\text{T}} \otimes A) \text{vec}(X)) \\
&= (Q_b^{\text{T}} \otimes Q_a^{\text{T}}) \text{vec}(\mathbf{E}) \\
&\sim N\left((Q_b^{\text{T}} \otimes Q_a^{\text{T}}) 0_{ab}, (Q_b^{\text{T}} \otimes Q_a^{\text{T}}) \cdot \frac{\sigma^2}{n} I_b \otimes I_a \cdot (Q_b^{\text{T}} \otimes Q_a^{\text{T}})^{\text{T}}\right) \\
&= N\left(0_{ab}, (Q_b^{\text{T}} \otimes Q_a^{\text{T}}) \cdot \frac{\sigma^2}{n} I_b \otimes I_a \cdot (Q_b \otimes Q_a)\right) \\
&= N\left(0_{ab}, \frac{\sigma^2}{n} [(Q_b^{\text{T}} \cdot I_b \cdot Q_b) \otimes (Q_a^{\text{T}} \cdot I_a \cdot Q_a)]\right) \\
&= N\left(0_{ab}, \frac{\sigma^2}{n} I_b \otimes I_a\right)
\end{aligned}$$

因此 $\tilde{\mathbf{E}} = Q_a^{\text{T}} \mathbf{E} Q_b \in \mathbb{R}^{a \times b}$ 的元素独立同分布:

$$\{\tilde{\mathbf{E}}_{ij\cdot}\} \stackrel{\text{iid}}{\sim} N\left(0, \frac{\sigma^2}{n}\right)$$

于是 SSAB 的零假设分布为:

$$SSAB \stackrel{H_0}{=} n \sum_{i=1}^{a-1} \sum_{j=1}^{b-1} \tilde{E}_{(i,j)}^2 \sim n \cdot \frac{\sigma^2}{n} \chi_{(a-1)(b-1)}^2 = \sigma^2 \chi_{(a-1)(b-1)}^2$$

$$MSAB := \frac{SSAB}{(a-1)(b-1)} \stackrel{H_0}{\sim} \frac{\sigma^2 \chi_{(a-1)(b-1)}^2}{(a-1)(b-1)}$$

(3) 检验法

零假设和备择假设分别为:

$$\begin{aligned} H_0 : \widehat{\text{IA}}_{(A_i, B_j)} &= 0 \text{ for all } \begin{cases} i = 1, \dots, a \\ j = 1, \dots, b \end{cases} \\ \Updownarrow \\ H_1 : \exists i, j \text{ such that } \widehat{\text{IA}}_{(A_i, B_j)} &= 0 \end{aligned}$$

设第一类型错误概率界限为 α

我们构造如下的 F 检验统计量:

$$F := \frac{MSAB}{MSE} \stackrel{H_0}{\sim} \frac{\sigma^2 \chi_{(a-1)(b-1)}^2 / (a-1)(b-1)}{\sigma^2 \chi_{ab(n-1)}^2 / ab(n-1)} = F_{(a-1)(b-1), ab(n-1)}$$

其中分子 MSAB 和分母 MSE 是相互独立的 (无论零假设 H_0 是否成立)

记 $F_{(a-1)(b-1), ab(n-1)}(\alpha)$ 为 $F_{(a-1)(b-1), ab(n-1)}$ 分布的 $1 - \alpha$ 分位数.

交互效应存在性检验的 F -检验法为:

- 若 $F = \frac{MSAB}{MSE} = \frac{n \sum_{i,j}^{a,b} (\bar{y}_{ij\cdot} - \bar{y}_{\cdot\cdot})^2 / (a-1)(b-1)}{\sum_{i,j,k}^{a,b,n} (y_{ijk} - \bar{y}_{ij\cdot})^2 / ab(n-1)} > F_{(a-1)(b-1), ab(n-1)}(\alpha)$

则我们拒绝零假设 $H_0 : \widehat{\text{IA}}_{(A_i, B_j)} = 0$ for all i, j

说明当前所研究的因子 A, B 之间存在交互效应.

5.3.4 无交互效应时的主效应检验

假设交互效应存在性检验的零假设没有被拒绝 (注意: 没有被拒绝 $\neq$ 成立)

考虑交互效应不存在时双因子方差分析的因子 A 的主效应检验.

零假设和备择假设分别为:

$$\begin{aligned} H_0 : \mu_{1\cdot} &= \dots = \mu_{a\cdot} (= \mu_{\cdot\cdot}) \\ \Updownarrow \\ H_1 : \exists i_1, i_2 \text{ such that } \mu_{i_1\cdot} &\neq \mu_{i_2\cdot} \end{aligned}$$

回忆起因子 A 的因子水平 A_i 的主效应的定义为 $\text{ME}_{A_i} := \mu_{i\cdot} - \mu_{\cdot\cdot}$

于是零假设和备择假设可以等价表示为:

$$\begin{aligned} H_0 : \text{ME}_{A_1} &= \dots = \text{ME}_{A_a} = 0 \\ \Updownarrow \\ H_1 : \exists i = 1, \dots, a \text{ such that } \text{ME}_{A_i} &\neq 0 \end{aligned}$$

(1) 基本记号

根据 5.3.3(2) 的结论可知, 在不存在交互效应的假设下,

交互效应平方和 $SSAB = n \sum_{i,j}^{a,b} \widehat{\text{IA}}_{(A_i, B_j)}^2 \sim \sigma^2 \chi_{(a-1)(b-1)}^2$

此时它已经没有单独存在的必要了, 我们将它并入 SSE:

$$\text{SSE}_{\text{reduced}} := \text{SSE} + \text{SSAB}$$

$$\begin{aligned} &= \sum_{i,j,k}^{a,b,n} (y_{ijk} - \bar{y}_{ij\cdot})^2 + n \sum_{i,j}^{a,b} \widehat{\text{IA}}_{(A_i, B_j)}^2 \\ &= \sum_{i,j,k}^{a,b,n} (y_{ijk} - \bar{y}_{ij\cdot})^2 + n \sum_{i,j}^{a,b} (\bar{y}_{ij\cdot} + \bar{y}_{\dots} - \bar{y}_{i\cdot\cdot} - \bar{y}_{\cdot j\cdot})^2 \quad (\text{note that } \text{SSE} \perp \text{SSAB}) \\ &= \sum_{i,j,k}^{a,b,n} (y_{ijk} - \bar{y}_{ij\cdot} + \bar{y}_{ij\cdot} + \bar{y}_{\dots} - \bar{y}_{i\cdot\cdot} - \bar{y}_{\cdot j\cdot})^2 \\ &= \sum_{i,j,k}^{a,b,n} (y_{ijk} + \bar{y}_{\dots} - \bar{y}_{i\cdot\cdot} - \bar{y}_{\cdot j\cdot})^2 \quad (\text{note that } \begin{cases} \text{SSE} \sim \sigma^2 \chi_{ab(n-1)}^2 \\ \text{SSAB} \sim \sigma^2_{(a-1)(b-1)} \end{cases}) \\ &\sim \sigma^2 \chi_{(abn-a-b+1)}^2 \end{aligned}$$

在不存在交互效应的假设下，双因子方差分析的 ANOVA TABLE 如下:

ANOVA TABLE (without interaction)

Sum of Squares		Degree of Freedom	Mean Squares
SST	$\sum_{i,j,k}^{a,b,n} (y_{ijk} - \bar{y}_{\dots})^2$	$abn - 1$	$\text{MST} = \frac{\text{SST}}{abn-1}$
$\text{SSE}_{\text{reduced}}$	$\sum_{i,j,k}^{a,b,n} (y_{ijk} + \bar{y}_{\dots} - \bar{y}_{i\cdot\cdot} - \bar{y}_{\cdot j\cdot})^2$	$abn - a - b + 1$	$\text{MSE}_{\text{reduced}} = \frac{\text{SSE}_{\text{reduced}}}{abn-a-b+1}$
SSA	$bn \sum_{i=1}^a \widehat{\text{ME}}_{A_i}^2$	$a - 1$	$\text{MSA} = \frac{\text{SSA}}{a-1}$
SSB	$an \sum_{j=1}^b \widehat{\text{ME}}_{B_j}^2$	$b - 1$	$\text{MSB} = \frac{\text{SSB}}{b-1}$

$$\widehat{\text{ME}}_{A_i} = \bar{y}_{i\cdot\cdot} - \bar{y}_{\dots}$$

$$\widehat{\text{ME}}_{B_j} = \bar{y}_{\cdot j\cdot} - \bar{y}_{\dots}$$

(2) 零假设分布

考虑零假设 H_0 :

$$H_0 : \text{ME}_{A_1} = \dots = \text{ME}_{A_a} = 0$$

在零假设 H_0 成立的前提条件下，我们有:

$$\begin{aligned} \widehat{\text{ME}}_{A_i} &= \bar{y}_{i\cdot\cdot} - \bar{y}_{\dots} \\ &= \mu_{i\cdot} + \bar{\varepsilon}_{i\cdot\cdot} - \mu_{\dots} - \bar{\varepsilon}_{\dots} \\ &= \text{ME}_{A_i} + \bar{\varepsilon}_{i\cdot\cdot} - \bar{\varepsilon}_{\dots} \\ &\stackrel{H_0}{=} \bar{\varepsilon}_{i\cdot\cdot} - \bar{\varepsilon}_{\dots} \end{aligned}$$

定义 $\mathbf{E} := [\bar{\varepsilon}_{ij\cdot}] \in \mathbb{R}^{a \times b}$ ，用 $\mathbf{E}_{(i,:)}$ 代表 $\mathbf{E}$ 的第 i 行

注意到:

$$\begin{aligned} \bar{\varepsilon}_{i\cdot\cdot} &= \frac{1}{b} \sum_{j=1}^b \bar{\varepsilon}_{ij\cdot} = \mathbf{E}_{(i,:)} \cdot \frac{1}{b} \mathbf{1}_b \\ \bar{\varepsilon}_{\dots} &= \frac{1}{ab} \sum_{i=1}^a \sum_{j=1}^b \bar{\varepsilon}_{ij\cdot} = \frac{1}{a} \mathbf{1}_a^T \cdot \mathbf{E} \cdot \frac{1}{b} \mathbf{1}_b \end{aligned}$$

因此我们有:

$$\begin{aligned} \begin{bmatrix} \bar{\varepsilon}_{1..} \\ \vdots \\ \bar{\varepsilon}_{a..} \end{bmatrix} &= \begin{bmatrix} \mathbf{E}_{(1,:)} \cdot \frac{1}{b} \mathbf{1}_b \\ \vdots \\ \mathbf{E}_{(a,:)} \cdot \frac{1}{b} \mathbf{1}_b \end{bmatrix} = \mathbf{E} \cdot \frac{1}{b} \mathbf{1}_b \mathbf{1}_b^T \\ \begin{bmatrix} \bar{\varepsilon}_{...} \\ \vdots \\ \bar{\varepsilon}_{...} \end{bmatrix} &= \mathbf{1}_a \bar{\varepsilon}_{...} = \frac{1}{a} \mathbf{1}_a \mathbf{1}_a^T \cdot \mathbf{E} \cdot \frac{1}{b} \mathbf{1}_b \end{aligned}$$

于是我们有:

$$\begin{aligned} & \left(\mathbf{I}_a - \frac{1}{a} \mathbf{1}_a \mathbf{1}_a^T \right) \cdot \mathbf{E} \cdot \frac{1}{b} \mathbf{1}_b \\ &= \mathbf{E} \cdot \frac{1}{b} \mathbf{1}_b - \frac{1}{a} \mathbf{1}_a \mathbf{1}_a^T \cdot \mathbf{E} \cdot \frac{1}{b} \mathbf{1}_b \\ &= \begin{bmatrix} \bar{\varepsilon}_{1..} \\ \vdots \\ \bar{\varepsilon}_{a..} \end{bmatrix} - \begin{bmatrix} \bar{\varepsilon}_{...} \\ \vdots \\ \bar{\varepsilon}_{...} \end{bmatrix} \\ &= \begin{bmatrix} \bar{\varepsilon}_{1..} - \bar{\varepsilon}_{...} \\ \vdots \\ \bar{\varepsilon}_{a..} - \bar{\varepsilon}_{...} \end{bmatrix} \\ &\stackrel{H_0}{=} \begin{bmatrix} \widehat{\text{ME}}_{A_1} \\ \vdots \\ \widehat{\text{ME}}_{A_a} \end{bmatrix} \end{aligned}$$

记 $P_a = \mathbf{I}_a - \frac{1}{a} \mathbf{1}_a \mathbf{1}_a^T$

显然它是投影算子 (即自伴且幂等), 记其谱分解为:

$$P_a = Q_a \Lambda_a Q_a^T \text{ where } \Lambda_a = \text{diag}\{\underbrace{1, \dots, 1}_{a-1 \text{ times}}, 0\}$$

则我们有:

$$\begin{aligned} \text{SSA} &= bn \sum_{i=1}^a \widehat{\text{ME}}_{A_i}^2 \quad (\text{note that } \widehat{\text{ME}}_{A_i} \stackrel{H_0}{=} \bar{\varepsilon}_{i..} - \bar{\varepsilon}_{...}) \\ &\stackrel{H_0}{=} bn \sum_{i=1}^a (\bar{\varepsilon}_{i..} - \bar{\varepsilon}_{...})^2 \quad (\text{note that } \bar{\varepsilon}_{i..} - \bar{\varepsilon}_{...} = \left[P_a \mathbf{E} \cdot \frac{1}{b} \mathbf{1}_b \right]_{(i)}) \\ &= bn \sum_{i=1}^a \left(\left[P_a \mathbf{E} \cdot \frac{1}{b} \mathbf{1}_b \right]_{(i)} \right)^2 \\ &= bn \left\| P_a \mathbf{E} \cdot \frac{1}{b} \mathbf{1}_b \right\|_2^2 \\ &= bn \cdot \frac{1}{b} \mathbf{1}_b^T \mathbf{E}^T P_a^T P_a \mathbf{E} \cdot \frac{1}{b} \mathbf{1}_b \quad (\text{note that } P_a^T P_a = P_a^2 = P_a) \\ &= \frac{n}{b} \mathbf{1}_b^T \mathbf{E}^T P_a \mathbf{E} \mathbf{1}_b \quad (\text{note that } P_a = Q_a \Lambda_a Q_a^T) \\ &= \frac{n}{b} \mathbf{1}_b^T \mathbf{E}^T Q_a \Lambda_a Q_a^T \mathbf{E} \mathbf{1}_b \quad (\text{denote } \tilde{e} := Q_a^T \mathbf{E} \mathbf{1}_b \in \mathbb{R}^a) \\ &= \frac{n}{b} \tilde{e}^T \Lambda_a \tilde{e} \quad (\text{note that } \Lambda_a = \text{diag}\{\underbrace{1, \dots, 1}_{a-1 \text{ times}}, 0\}) \\ &= \frac{n}{b} \sum_{i=1}^a \tilde{e}_i^2 \end{aligned}$$

注意到 $\mathbf{E} := [\bar{\varepsilon}_{ij.}] \in \mathbb{R}^{a \times b}$ 的元素独立同分布:

$$\{\bar{\varepsilon}_{ij.}\} \stackrel{\text{iid}}{\sim} N\left(0, \frac{\sigma^2}{n}\right)$$

我们可以将整个 $\mathbf{E} \in \mathbb{R}^{a \times b}$ 的分布表示为:

$$\text{vec}(\mathbf{E}) \sim N\left(0_{ab}, \frac{\sigma^2}{n} I_b \otimes I_a\right)$$

其中 $\text{vec}(\cdot)$ 是向量化操作符 (即将一个矩阵按列拉伸为向量), 而 $\otimes$ 代表 Kronecker 乘积. 于是我们有:

$$\begin{aligned} \tilde{e} &= Q_a^T \mathbf{E} \mathbf{1}_b \quad (\text{note that } \text{vec}(AXB) = (B^T \otimes A) \text{vec}(X)) \\ &= (\mathbf{1}_b^T \otimes Q_a^T) \text{vec}(\mathbf{E}) \\ &\sim N\left((\mathbf{1}_b^T \otimes Q_a^T) 0_{ab}, (\mathbf{1}_b^T \otimes Q_a^T) \cdot \frac{\sigma^2}{n} I_b \otimes I_a \cdot (\mathbf{1}_b^T \otimes Q_a^T)^T\right) \\ &= N\left(0_{ab}, (\mathbf{1}_b^T \otimes Q_a^T) \cdot \frac{\sigma^2}{n} I_b \otimes I_a \cdot (\mathbf{1}_b \otimes Q_a)\right) \\ &= N\left(0_{ab}, \frac{\sigma^2}{n} [(\mathbf{1}_b^T \cdot I_b \cdot \mathbf{1}_b) \otimes (Q_a^T \cdot I_a \cdot Q_a)]\right) \\ &= N\left(0_{ab}, \frac{\sigma^2 b}{n} I_a\right) \end{aligned}$$

因此 $\tilde{e} = Q_a^T \mathbf{E} \mathbf{1}_b \in \mathbb{R}^a$ 的元素独立同分布:

$$\{\tilde{e}_i\} \stackrel{\text{iid}}{\sim} N\left(0, \frac{\sigma^2 b}{n}\right)$$

于是 SSA 的零假设分布为:

$$\begin{aligned} \text{SSA} &\stackrel{H_0}{=} \frac{n}{b} \sum_{i=1}^a \tilde{e}_i^2 \sim \frac{n}{b} \cdot \frac{\sigma^2 b}{n} \chi_{(a-1)}^2 = \sigma^2 \chi_{(a-1)}^2 \\ \text{MSA} &:= \frac{\text{SSA}}{a-1} \stackrel{H_0}{\sim} \frac{\sigma^2 \chi_{(a-1)}^2}{a-1} \end{aligned}$$

(3) 检验法

零假设和备择假设分别为:

$$\begin{aligned} H_0 &: \text{ME}_{A_1} = \dots = \text{ME}_{A_a} = 0 \\ &\quad \updownarrow \\ H_1 &: \exists i = 1, \dots, a \text{ such that } \text{ME}_{A_i} \neq 0 \end{aligned}$$

设第一类型错误概率界限为 α

我们构造如下的 F 检验统计量:

$$F := \frac{\text{MSA}}{\text{MSE}_{\text{reduced}}} \stackrel{H_0}{\sim} \frac{\sigma^2 \chi_{(a-1)}^2 / (a-1)}{\sigma^2 \chi_{abn-a-b+1}^2 / (abn-a-b+1)} = F_{a-1, abn-a-b+1}$$

其中分子 MSA 和分母 $\text{MSE}_{\text{reduced}}$ 是相互独立的 (无论零假设 H_0 是否成立)

记 $F_{a-1, abn-a-b+1}(\alpha)$ 为 $F_{a-1, abn-a-b+1}$ 分布的 $1 - \alpha$ 分位数.

在无交互效应的假设下关于因子 A 的主效应检验的 F -检验法为:

- 若 $F = \frac{\text{MSA}}{\text{MSE}_{\text{reduced}}} = \frac{bn \sum_{i=1}^a (\bar{y}_{i..} - \bar{y}_{...})^2 / (a-1)}{\sum_{i,j,k}^{a,b,n} (y_{ijk} + \bar{y}_{...} - \bar{y}_{i..} - \bar{y}_{.j.})^2 / (abn-a-b+1)} > F_{a-1, abn-a-b+1}(\alpha)$

则我们拒绝零假设 $H_0: \text{ME}_{A_1} = \dots = \text{ME}_{A_a} = 0$

即拒绝零假设 $H_0: \mu_{1.} = \dots = \mu_{a.}$

说明在无交互效应的假设下因子 A 对响应变量 Y 有解释作用.

5.3.5 置信区间估计

给定置信水平为 α

回忆起 $\hat{\mu}_{ij} := \bar{y}_{ij\cdot} = \frac{1}{n} \sum_{k=1}^n y_{ijk} \sim N(\mu_{ij}, \frac{\sigma^2}{n})$ 是 μ_{ij} 的最佳线性无偏估计量 (BLUE)
因此我们有:

$$\frac{\sqrt{n}(\hat{\mu}_{ij} - \mu_{ij})}{\sigma} = \frac{\sqrt{n}(\bar{y}_{ij\cdot} - \mu_{ij})}{\sigma} \sim N(0, 1)$$

关于 σ^2 的无偏估计量, 在不同假设下可以有不同选择.

(类似地, 我们可以对 $\mu_{i\cdot}$ 和 $\mu_{\cdot j}$ 及其线性组合进行置信区间估计)

(1) 有交互效应

在有交互效应的假设下, 我们使用 $s^2 = \text{MSE}$ 作为 σ^2 的无偏估计量.

根据 5.3.2(3) 可知:

$$s^2 = \text{MSE} = \frac{1}{ab(n-1)} \text{SSE} = \frac{1}{ab(n-1)} \sum_{i,j,k}^{a,b,n} (y_{ijk} - \bar{y}_{ij\cdot})^2 \sim \frac{\sigma^2 \chi_{(ab(n-1))}^2}{ab(n-1)}$$

$$s^2 \perp \mu_{ij} \text{ for all } \begin{cases} i = 1, \dots, a \\ j = 1, \dots, b \end{cases}$$

于是我们可以考虑以下枢轴量:

$$\frac{\sqrt{n}(\hat{\mu}_{ij} - \mu_{ij})}{\sqrt{\text{MSE}}} = \frac{\frac{\sqrt{n}(\hat{\mu}_{ij} - \mu_{ij})}{\sigma}}{\frac{\sqrt{\text{MSE}}}{\sigma}} \sim \frac{N(0, 1)}{\sqrt{\chi_{(ab(n-1))}^2 / (ab(n-1))}} = t_{ab(n-1)}$$

因此 μ_{ij} 的 $(1 - \alpha) \cdot 100\%$ 置信区间为 $\bar{y}_{ij\cdot} \pm \frac{\sqrt{\text{MSE}}}{\sqrt{n}} t_{ab(n-1)}(\frac{\alpha}{2})$

其中 $t_{ab(n-1)}(\frac{\alpha}{2})$ 为 $t_{ab(n-1)}$ 分布的 $1 - \frac{\alpha}{2}$ 分位数.

(2) 无交互效应

在无交互效应的假设下, 我们使用 $\text{MSE}_{\text{reduced}}$ 作为 σ^2 的无偏估计量.

根据 5.3.4(1) 可知 $\text{MSE}_{\text{reduced}}$ 在无交互效应的假设下的分布为:

$$\begin{aligned} \text{MSE}_{\text{reduced}} &= \frac{1}{abn - a - b + 1} \text{SSE}_{\text{reduced}} \\ &= \frac{1}{abn - a - b + 1} \sum_{i,j,k}^{a,b,n} (y_{ijk} + \bar{y}_{\dots} - \bar{y}_{i\cdot\cdot} - \bar{y}_{\cdot j\cdot})^2 \\ &\sim \frac{\sigma^2 \chi_{(abn - a - b + 1)}^2}{abn - a - b + 1} \end{aligned}$$

(待补充: $\text{MSE}_{\text{reduced}} \perp \bar{y}_{ij\cdot}$ 的证明)

于是我们可以考虑以下枢轴量:

$$\frac{\sqrt{n}(\hat{\mu}_{ij} - \mu_{ij})}{\sqrt{\text{MSE}_{\text{reduced}}}} = \frac{\frac{\sqrt{n}(\hat{\mu}_{ij} - \mu_{ij})}{\sigma}}{\frac{\sqrt{\text{MSE}_{\text{reduced}}}}{\sigma}} \sim \frac{N(0, 1)}{\sqrt{\chi_{(abn - a - b + 1)}^2 / (abn - a - b + 1)}} = t_{abn - a - b + 1}$$

因此 μ_{ij} 的 $(1 - \alpha) \cdot 100\%$ 置信区间为 $\bar{y}_{ij\cdot} \pm \frac{\sqrt{\text{MSE}_{\text{reduced}}}}{\sqrt{n}} t_{abn - a - b + 1}(\frac{\alpha}{2})$

其中 $t_{abn - a - b + 1}(\frac{\alpha}{2})$ 为 $t_{abn - a - b + 1}$ 分布的 $1 - \frac{\alpha}{2}$ 分位数.

The End

