

复旦大学大数据学院

2022-2023 学年第一学期期末考试试卷

A 卷[✓] B 卷[] C 卷[]

课程名称:统计（机器）学习概论课程代码:DATA130003.01

开课院系:大数据学院考试形式:开卷[] 闭卷[✓]

姓名:学号:专业:

声明: 我已知悉学校对于考试纪律的严肃规定, 将秉持诚实守信宗旨, 严守考试纪律, 不作弊, 不剽窃; 若有违反学校考试纪律的行为, 自愿接受学校严肃处理。

学生 (签名):

年 月 日

注意事项:

- 1、试卷共 30 道选择题, 3 道解答题, 考试时间为 2 小时, 请合理安排时间
- 2、试卷共 12 页, 请注意不要漏题; 同时选择题部分请将答案写入表格中
- 3、考试全程禁止使用计算器

题 号	一	二、1	二、2	二、3	总分
得 分					

一、选择题 (共 30 小题, 每小题 2 分, 共 60 分)

答题须知: 本题答案必须写在如下表格中, 否则不给分.

小题	1	2	3	4	5	6
答案						
小题	7	8	9	10	11	12
答案						
小题	13	14	15	16	17	18
答案						
小题	19	20	21	22	23	24
答案						
小题	25	26	27	28	29	30
答案						

1. 下列关于逻辑回归模型说法错误的是:.....()
(A) 一个事件的几率 (odds) 是指该事件发生的概率与该事件不发生的概率的比值;
(B) 二分类逻辑回归模型中, 事件发生的条件分布为 $P(Y = 1 | x) = \frac{\exp(w \cdot x + b + \epsilon)}{1 + \exp(w \cdot x + b + \epsilon)}$, ϵ 为随机误差项;
(C) 逻辑回归模型学习时, 可以使用极大似然估计法来估计模型参数;
(D) 二分类逻辑回归模型可以推广至多分类逻辑回归模型;
2. 假设我们有两个类 (A 和 B) 以及一个新的文档 d 要分类. 现有以下训练数据:

文档	类别	$\cos(\vec{v}(d_i), \vec{v}(d))$
d_1	A	1
d_2	B	0.95
d_3	B	0.94
d_4	A	0.45
d_5	A	0.4
d_6	B	0.39

假设使用余弦 (cosine) 作为距离度量, 即余弦值越高, 两个向量越接近. 使用于余弦距离, 通过 k 近邻方法, 以下说法正确的是:.....()


(A) 若 $k = 3$, 使用多数表决的决策规则, 则新样本 d 被分为 A 类;

(B) 若 $k = 5$, 使用多数表决的决策规则, 则新样本 d 被分为 B 类;

(C) 若 $k = 5$, 使用多数表决的决策规则, 则新样本 d 被分为 A 类;

(D) 若 $k = 4$, 使用多数表决的决策规则, 则新样本 d 被分为 B 类;

3. 在一种折叠塑料薄膜的机器上, 机器温度可以在 130-185℃ 的范围内变化. 为了研究温度对折叠厚度的影响, 现测量了 12 个相关的温度值和折叠厚度, 如下图所示:



假设该模型为 $y = \beta_0 + \beta_1 x + \epsilon, \epsilon \sim N(0, \sigma^2)$, 关于这个线性回归模型, 下列给出的参数估计最有可能的是:.....()

- (A) $\hat{\beta}_0 = 0, \hat{\beta}_1 = -0.9, \hat{\sigma} = 36$ (B) $\hat{\beta}_0 = 252, \hat{\beta}_1 = -0.9, \hat{\sigma} = 3.6$
(C) $\hat{\beta}_0 = -252, \hat{\beta}_1 = -0.9, \hat{\sigma} = 36$ (D) $\hat{\beta}_0 = 252, \hat{\beta}_1 = -0.9, \hat{\sigma} = 36$

4. 关于朴素贝叶斯分类方法，下列说法不正确的是：.....()

- (A) 朴素贝叶斯方法通过训练数据集学习联合概率分布 $P(X, Y)$
(B) 该方法对条件概率分布做了条件独立性的假设；
(C) 该方法将实例分到后验概率最大的类别中；
(D) 对于一个要做预测的实例，它一定只能被分到某一类；

5. 下列关于支持向量机分类方法说法不正确的是：.....()

- (A) 当训练数据集线性可分时，存在无穷多个分离超平面可将两类数据正确分开；
(B) 线性可分支持向量机利用间隔最大化求最优分离超平面；
(C) 线性支持向量机模型只能求解线性可分问题；
(D) 对于输入空间中的非线性分类问题，可以通过非线性变换将它转化为某个高维特征空间中的线性分类问题，在高维特征空间中学习线性支持向量机；

6. 关于 AdaBoost 方法中，弱分类器的权重说法不正确的是：.....()

- (A) 每轮迭代中，各个弱分类器的权重 α_m 与当前轮的分类误差率有关；
(B) 弱分类器的分类误差越大，权重越大，因此这个分类器对最终的强分类器影响越大；
(C) 对于样本点而言，正确分类的点权重降低，错误分类的点权重增大，因此在下一轮中错误的分类点会得到更多的关注；
(D) 若 w_{mi} 表示第 m 轮中第 i 个样本点的权值，那么 $\sum_{i=1}^N w_{mi} = 1$ ；

7. 下列关于主成分分析说法不正确的是：.....()

- (A) 样本主成分是中心化的数据矩阵的特征向量；
(B) 样本主成分是中心化的数据矩阵的右奇异向量；
(C) 样本主成分是样本协方差矩阵的特征向量；
(D) 样本主成分是样本协方差矩阵的右奇异向量；


8. 若想通过某种描述性统计图形描述一个定量变量（连续变量）和一个定性变量（分类变量）之间的关系，以下图形中最合适的是：.....()

- (A) 散点图 (B) 箱线图 (C) 直方图 (D) 折线图

9. 以下关于监督学习方法说法错误的是：.....()

- (A) 支持向量机模型求解可以通过解一个凸二次规划的对偶问题；
(B) 决策树方法包括特征选择、树生成、剪枝等启发式学习过程；
(C) k-means 算法是一种迭代算法，可以保证收敛到全局最优；
(D) Adaboost 方法利用学习的模型是加法模型、损失函数是指数损失函数；

10. 假设训练一个逻辑回归分类器 $h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$ ，其中 $g(z)$ 为 Sigmoid 函数 ($g(z) = [1 + \exp(-z)]^{-1}$)，假设 $\theta_0 = 6, \theta_1 = -1, \theta_2 = 0$ ，下列哪个图表示分类器找到的决策边界？.....()




11. 以下说法错误的是：.....()

- (A) Bagging 算法使个体学习器尽可能独立
(B) 随机森林中，只能训练数据来评估变量的重要性
(C) Bagging 一般采用 bootstrap sampling
(D) Bagging 的输出，对分类问题可采用投票法，回归问题可采用求平均法

12. 在各互联网大厂中，风控部门扮演着非常重要的角色，在针对超高危行为的识别中，通常要求不漏掉高危风险且允许有一定误伤（即将正常行为识别为超高危行为），我们可以将该识别任务看作一个二分类问题（超高危行为标签为 1，正常行为标签为 0），下面四个选项是四种不同的二分类模型在某份测试集上的查全率（Recall）和查准率（Precision），则最适合该问题的模型为：.....()

- (A) 查全率为 0.8；查准率为 0.9 (B) 查全率为 0.7；查准率为 0.95
(C) 查全率为 0.95；查准率为 0.7 (D) 查全率为 0.9；查准率为 0.9

13. 下图为三个不同的模型（蓝色）在相同的训练数据上的拟合曲线。则下列说法正确的有：.....()




- (1) 与第 2 个和第 3 个模型相比，第 1 个模型中的训练误差更高
(2) 最佳模型是第 3 个模型，因为它具有最小的训练误差

- (3) 第 2 个模型比第 1 个和第 3 个模型更适用于数据
- (4) 与第 1 个和第 2 个模型相比，第 3 个模型是一个过拟合模型
- (5) 第 1 个模型的模型复杂度最高
- (A) (3)(4)(5) (B) (1)(3)(4) (C) (1)(3)(4)(5) (D) (1)(4)(5)
14. 如果回归模型具有多重共线性效应，在不损失太多信息的情况下可以用下面的哪几种方法修正模型?.....()
- (1) 去除所有共线变量
- (2) 去除一个变量而不是都去掉
- (3) 计算 VIF（方差膨胀因子）来检验多重共线性效应，然后根据情况处理
- (4) 采用 AIC 或者 BIC 对变量进行筛选
- (A) (2) (B) (2)(3) (C) (2)(3)(4) (D) (1)(2)(3)(4)
15. 关于随机森林和梯度提升树，说法正确的有:.....()
- (1) 在随机森林中，中间树互相不独立，而在梯度回归树中，中间树相互独立
- (2) 随机森林使用随机特征子集来构建中间树
- (3) 在梯度提升树的情况下我们可以生成并行树，因为树互相独立
- (4) 梯度提升树在任何数据集上都比随机森林要好
- (A) (2) (B) (2)(3) (C) (2)(4) (D) (1)(2)
16. 针对朴素贝叶斯模型，有如下数据集，现有测试样本 (A=0, B=1, C=0)，若已知 $P(A=0, B=1, C=0)=d$ ，则以下描述正确的是:.....()

A	B	C	类
0	0	0	+
0	0	1	-
0	1	1	-
0	1	1	-
0	0	1	+
1	0	1	+
1	0	1	-
1	0	1	-
1	1	1	+
1	0	1	+

- (1) 测试样本属于 + 类的概率是 $0.008/d$
- (2) 测试样本属于 - 类的概率为 $0.008/d$
- (3) 该测试样本属于 + 类的概率大于 - 的概率，因此该测试样本的类标号为 +
- (4) 该测试样本属于 - 类的概率大于 + 的概率，因此该测试样本的类标号为 -
- (A) (1)(3) (B) (1)(4) (C) (2)(4) (D) (2)(3)
17. 以下关于主成分分析哪些是正确的:.....()
- (1) 在 PCA 前一般将数据标准化
- (2) 我们应该选择最高方差的主成分

- (3) 我们应该选择最低方差的主成分
- (4) 我们可以用 PCA 来可视化高维数据
- (A) (2) (B) (1)(2) (C) (1)(3) (D) (1)(2)(4)
18. 对于二分类问题，假设负样本量: 正样本量 =20:1，下列哪些方法可以处理这种不平衡的情况:
- (1) 直接训练模型，预测的时候调节阈值
- (2) 采用 SMOTE 算法对正样本插值，产生更多正样本
- (3) 随机降采样负样本
- (4) 训练过程中，增加负样本的权重.....()
- (A) (2) (B) (1)(2) (C) (1)(2)(3) (D) (1)(2)(3)(4)
19. 在对数据进行线性回归建模前，通常观察数据的正态性，则下面的 QQ 图中，满足正态性假设的是:.....()



- (A) (A) (B) (B) (C) (C) (D) (D)
20. 下列说法中表述恰当的个数为:.....()
- (1) R^2 可以刻画回归模型的拟合效果， R^2 越接近于 1，说明模型的拟合效果越好;
- (2) 在线性回归模型中， R^2 表示自变量对因变量的贡献率， R^2 越接近于 1，表示自变量和因变量的线性相关关系越强;
- (3) 若残差图中个别点的残差比较大，则应确认在采集样本点的过程中是否有人为的错误或模型是否恰当
- (A) 0 (B) 1 (C) 2 (D) 3

线

订

线

21. 关于 k 折交叉验证, 下列说法正确的是?.....()
- (A) k 值并不是越大越好, k 值过大, 会降低运算速度
- (B) 将含有 N 个样本的数据集, 分成 k 份, 每份含有 N/k 个样本。选择其中一份作为验证集, 另外 $k-1$ 份作为训练集, 验证集就有 k 种情况
- (C) 实际中多次重复 k 折交叉验证, 取平均后得到最终的评估结果
- (D)** 以上说法都正确
22. 关于回归问题和分类问题, 以下说法错误的是:.....()
- (A) 回归和分类都是有监督问题;
- (B) 回归问题的因变量是连续型变量;
- (C)** 分类问题的自变量必须是离散型变量;
- (D) 评估回归问题和分类问题的指标不相同。
23. 以下问题属于无监督问题的是:.....()
- (A) 根据房屋所在位置、面积大小预测房屋价格;
- (B) 根据历史贷款违约数据, 预测某用户未来违约的概率;
- (C) 训练 alpha go 与人类对弈围棋;
- (D)** 根据欧洲各种语言的语料库, 寻找各种语言之间的相似性。
24. 假设我们要解决一个二类分类问题, 我们已经建立好了模型, 输出是 0 或 1, 初始时设阈值为 0.5, 超过 0.5 概率估计, 就判别为 1, 否则就判别为 0; 如果我们现在用另一个大于 0.5 的阈值, 那么现在关于模型说法, 正确的是:.....()
- (A)** 模型分类的召回率会降低或不变; (B) 模型分类的召回率会升高;
- (C) 模型分类准确率会不变; (D) 模型分类准确率会降低。
25. 以下关于相似度和距离的说法中, 错误的是:.....()
- (A) 欧式距离是闵可夫斯基距离的一种;
- (B) 马氏距离考虑各个特征之间的相关性并与各个分量的尺度无关;
- (C) 用距离度量相似度时, 距离越小样本越相似;
- (D)** 样本之间的相似度还可以用夹角余弦来表示, 夹角余弦越接近 0, 表示两样本越相似。
26. 以下关于决策树模型说法错误的是:.....()
- (A) 造决策树时需同时考虑其拟合效果和泛化能力
- (B) 随机变量的熵只与其分布有关
- (C)** 熵越大, 随机变量的不确定性越小
- (D) 可以根据信息增益准则选择最优特征
27. 关于 CART 算法, 以下说法错误的是:.....()
- (A) CART 由决策树生成和剪枝两步组成
- (B) CART 回归树通过使平方误差最小化得到最优切分变量和切分点
- (C)** CART 分类树和 ID3 算法一样, 都采用基尼指数选择最优特征
- (D) CART 剪枝从底端开始, 剪去一些子树, 从而对未知数据有更好的预测性

线

订

线

28. 以下说法错误的是.....()
- (A) 可以通过因子负荷量的高低对主成分进行解读
- (B)** 通常选取 k 个主成分使得方差贡献率比较低
- (C) 可以通过崖底碎石图来选取最佳的主成分数目
- (D) 可以通过累计方差贡献率, 选择最佳主成分数目, 使得前 k 个主成分的累计方差解释比例达到一定数值
29. 下列关于分类器的说法中不正确的是.....()
- (A) SVM 的目标是找到使得训练数据尽可能分开且分类间隔最大的超平面, 属于结构风险最小化
- (B) 朴素贝叶斯是一种特殊的贝叶斯分类器, 其一个假定是每个变量相互条件独立
- (C)** AdaBoost 是一种优秀的集成方法, 它每一轮迭代时减少错误分类样本点权重, 其优点包括速度快、对异常值不敏感、支持自定义损失函数
- (D) 随机森林中列采样的过程保证了随机性, 所以就算不剪枝, 也不容易出现过拟合。
30. 关于线性回归中的离群点, 以下说法正确的是:.....()
- (A)** 可以绘制 Q-Q plot 来检验离群点;
- (B) 可以计算 Cook 距离来找到离群点;
- (C) 离群点不影响线性回归的无偏性和有效性;
- (D) 在建立线性回归模型时, 离群点可以不用剔除;

二、解答题（共 3 小题，第 1 题 15 分，第 2 题 10 分，第 3 题 15 分，共 40 分）

1. 回答下列问题：

(1) 如下图所示，"wages" 是一个包含 1379 个调查对象关于收入 [单位：美元]（earn）、身高（height）、性别（sex）、种族（race）教育得分（ed）、年龄（age）的数据集：

```
> summary(wages)
   earn      height      sex      race      ed      age
Min.   :  -98.6   Min.   :57.34 female:859   black   : 126   Min.   :  3.00   Min.   :22.00
1st Qu.: 10538.8 1st Qu.:63.72   male  :520   hispanic:  77   1st Qu.:12.00   1st Qu.:33.00
Median : 26877.9 Median :66.05              other   :  29   Median :13.00   Median :42.00
Mean   : 32446.3 Mean   :66.59              white  :1147   Mean   :13.35   Mean   :45.33
3rd Qu.: 44506.2 3rd Qu.:69.31              3rd Qu.:15.00   3rd Qu.:55.00
Max.   :317949.1 Max.   :77.21              Max.   :18.00   Max.   :95.00
```

针对该数据集，我们将收入（earn）作为因变量，其余变量作为自变量，建立线性回归模型，得到如下结果：

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept) -89820.65   18471.73  -4.863 1.29e-06 ***
height       632.74     275.72    2.295  0.0219 *
sexmale      17552.54   2139.65    8.203 5.32e-16 ***
racehispanic -2086.07   3947.50   -0.528  0.5973
raceother    -377.75   5625.71   -0.067  0.9465
racewhite    2506.72   2555.94    0.981  0.3269
ed           4382.09    305.17   14.359 < 2e-16 ***
age          287.47     47.32    6.075 1.60e-09 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 27180 on 1371 degrees of freedom
Multiple R-squared:  0.2477,    Adjusted R-squared:  0.2439
F-statistic: 64.49 on 7 and 1371 DF,  p-value: < 2.2e-16
```

请尝试针对显著性水平小于 0.001 的变量的回归系数进行解读（不用解读 intercept）【6 分】

(2) 考虑对数线性回归 $\log(Y) = \mathbf{X}\boldsymbol{\beta} + \epsilon$ ，其中 $\mathbf{Y} = (y_1, \dots, y_N)^\top \in \mathbb{R}^{N \times 1}$ ， $\mathbf{X} = (\mathbf{x}_1, \dots, \mathbf{x}_N)^\top \in \mathbb{R}^{N \times p}$ （ $\forall i, \mathbf{x}_i \in \mathbb{R}^p$ ）； $\epsilon = (\epsilon_1, \dots, \epsilon_N)^\top \in \mathbb{R}^{N \times 1}$ 服从正态分布 $\mathbf{N}(0, \sigma^2 \mathbf{I}_N)$ ， $\mathbf{I}_N \in \mathbb{R}^{N \times N}$ 为单位矩阵；参数 $\boldsymbol{\beta} \in \mathbb{R}^{p \times 1}$ 。试推导因变量 $\mathbf{Y}$ 的期望 $\mathbb{E}(\mathbf{Y})$ 。【4 分】

(3) 给定特征空间上的训练数据集 $T = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)\}$ ，其中 $\mathbf{x}_i \in \mathbb{R}^{p \times 1}$ 是第 i 个样本的特征向量， $y_i \in \{+1, -1\}$ 为类别标记（注意：这里的类别标记为 $\{+1, -1\}$ 而非 $\{+1, 0\}$ ）。若使用逻辑回归模型进行估计（采用极大似然函数法），请推导模型的对数似然函数并根据该对数似然函数写出牛顿法求解的详细步骤【5 分】

2. 2022 年卡塔尔世界杯吸引了全球的目光。足球作为世界上的第一大球类运动，有着非常科学的发展模式。如今，针对职业球员的训练，教练员往往需要参考

数据分析师的建议来指定每天的训练内容。例如：足球的室外训练容易受到天气、温度、风力等各方面的影响，在较恶劣的天气中，球员在室外训练中受伤的风险会增大，因此教练员通常会评估当天的天气情况，结合数据分析师给出的历史数据做出训练部署。如表 1 所示，为某支球队“是否进行室外有球训练”的历史数据：

日期	天气 (A_1)	温度 (A_2)	湿度 (A_3)	风力 (A_4)	室外有球训练
2022 年 10 月 1 日	晴天	热	高	弱	否
2022 年 10 月 2 日	晴天	热	高	强	否
2022 年 10 月 3 日	阴天	热	高	弱	是
2022 年 10 月 4 日	雨天	适中	高	强	否
2022 年 10 月 5 日	雨天	冷	正常	弱	是
2022 年 10 月 6 日	雨天	冷	正常	强	否
2022 年 10 月 7 日	阴天	冷	正常	强	是
2022 年 10 月 8 日	晴天	适中	正常	弱	否
2022 年 10 月 9 日	晴天	冷	正常	弱	是
2022 年 10 月 10 日	雨天	适中	正常	弱	是
2022 年 10 月 11 日	晴天	适中	正常	强	否
2022 年 10 月 12 日	阴天	适中	高	强	是
2022 年 10 月 13 日	阴天	热	正常	弱	是
2022 年 10 月 14 日	雨天	适中	高	强	否
2022 年 10 月 15 日	阴天	冷	高	强	否
2022 年 10 月 16 日	阴天	冷	正常	弱	是
2022 年 10 月 17 日	晴天	热	正常	强	是
2022 年 10 月 18 日	雨天	冷	高	弱	否
2022 年 10 月 19 日	雨天	冷	高	强	否
2022 年 10 月 20 日	晴天	冷	高	弱	否

表 1: 某只球队“是否进行室外有球训练”的历史数据

(1) 请分别计算四个特征：天气、温度、湿度、风力对应的信息增益比（使用以 2 为底的对数进行计算并保留 2 位小数）。并说明，根据计算结果，应该首先对哪个特征进行划分？（ $\log_2^3 = 1.6$, $\log_2^5 = 2.3$, $\log_2^7 = 2.8$, $\log_2^1 1 = 3.4$, $\log_2^1 3 = 3.7$, $\log_2^1 7 = 4.1$, $\log_2^1 9 = 4.2$ ）【7 分】

(2) 假如你为球队的数据分析师，若今天为晴天，且温度适中，湿度较高，风力较弱，请根据朴素贝叶斯模型预测今天是否适合进行户外有球训练【3 分】

3. (1) 通过支持向量机求得的分离超平面如图 1 所示，请问哪些可能是支持向量？请简述原因。【4 分】




图 1: 注：分离超平面由实线表示，间隔边界由虚线表示，两条平行的虚线之间的距离称为间隔，o 和 x 分别表示两个类别的样本。

(2) 已知一个如图 2 所示的训练数据集，其正例点是 $x_1 = (3, 2)^T$, $x_2 = (4, 3)^T$ ，负例点是 $x_3 = (1, 1)^T$ ，试求最大间隔超平面。【8 分】




图 2: o 和 x 分别表示两个类别的样本

(3) 考虑如下的因子模型 $\mathbf{X}^T = \mathbf{A}\mathbf{F}^T + \mathbf{E}^T$ ，其中 $\mathbf{X} \in R^{N \times p}$ 为收集到的样本矩阵， $\mathbf{F} = (F^{(1)}, \dots, F^{(n)})^T \in R^{N \times q}$ 为公共因子矩阵， $\mathbf{E}$ 为特殊因子矩阵， $\mathbf{A}$ 为载荷矩阵。假设 $\mathbf{A}$ 已求得，通过构造 Frobenius norm 的损失函数，求因子 $\mathbf{F}$ 的估计值表达式。（注：矩阵 $\mathbf{M} \in R^{n \times n}$ 的 Frobenius norm 表达式为 $\|\mathbf{M}\|_F = \sqrt{\sum_i \sum_j |m_{ij}|^2}$ ）【3 分】