

Lecture 1: 生成随机变量的基本方法

Layleace

2025 年 7 月 8 日

在统计计算和模拟中，生成随机变量是一个核心任务。给定一个随机变量的定义（例如通过其概率密度函数 (PDF)、累积分布函数 (CDF) 或其他特征参数），有效地生成服从该随机变量的独立同分布样本。这些样本可以用于仿真、蒙特卡洛模拟、统计推断等多种应用场景。

接下来将介绍几种生成随机变量的基本方法。

1 逆变换法 (Inverse Transform Method)

1.1 目标

从已知的 CDF $F(x)$ 中生成随机变量 X 。

1.2 原理

设 X 是一个连续随机变量，其累积分布函数 (CDF) 为 $F_X(x)$ ，则 $U = F_X(X)$ 服从均匀分布 $U(0, 1)$ 。具体推导如下：

$$F_X^{-1}(u) = \inf\{x : F_X(x) = u\}$$

考虑 $U \sim U(0, 1)$ ：

$$P(U \leq t) = P(F_X(X) \leq t) = P(F_X^{-1}(F_X(X)) \leq F_X^{-1}(t))$$

由于 F_X 是单调递增的，有：

$$= P(X \leq F_X^{-1}(t)) = F_X(F_X^{-1}(t)) = t$$

因此， $U \sim U(0, 1)$ 。

考察 $F_X^{-1}(U)$:

$$P(F_X^{-1}(U) \leq x) = P(U \leq F_X(x)) = F_X(x)$$

所以, $F_X^{-1}(U)$ 的分布与 X 的分布相同。

1.3 步骤

1. 求得 $F_X^{-1}(\cdot)$ 函数。
2. 随机生成 $U \sim U(0, 1)$ 。
3. 解 $X = F_X^{-1}(U)$, 得到 X 服从 CDF 为 F_X 的分布。

1.4 Tips

容易发现当 X 是离散变量时, $F(x)$ 是非连续的, 不存在 $F_X^{-1}(\cdot)$ 。但在逆法中, 连续性并不是必要的 (具体的证明并不考核, 如果有兴趣可以看书)。对于离散变量, 令 $F_X^{-1}(u) = \min\{x : F(x) \geq u\}$ 。

最好情况肯定是可以直接找到 $F_X^{-1}(\cdot)$ 的显式表达式, 但这在很多情况下是不现实的。在实践中, 通常通过递归/计算 CDF 等方式存储 CDF 向量, 再将生成的 U 与已存储的 CDF 向量比较得到对应的 x , 避免了函数求逆的一步。

例: 我们有一个离散随机变量 X , 其 CDF 为: $P(X \leq 0) = 0.1$, $P(X \leq 1) = 0.4$, $P(X \leq 2) = 0.8$, $P(X \leq 3) = 1$ 。

则生成一个样本的具体步骤为

1. 预先计算并存储 CDF 向量。
2. 生成一个 $U \sim U(0, 1)$ 。
3. 从前往后比较 u 与 CDF 中的值, 找到第一个大于等于 u 的位置。
4. 输出结果 x 。

假设生成的 $u = 0.67$, $0.4 < 0.67 < 0.8$, 故生成 $X = 2$ 。

2 接受-拒绝法 (Acceptance-Rejection Method)

2.1 目标

借用一个可以直接生成的, PDF $g(x)$ 与目标 PDF $f(x)$ 相似的 (非必要条件) 随机变量 Y , 从已知的 PDF $f(x)$ 中生成随机变量 X 。

2.2 步骤

1. 找到一个容易生成的随机变量 Y ，其 PDF 为 $g(x)$ ，且在 X 的支撑集上始终满足 $\frac{f(x)}{g(x)} \leq c$ 。
2. 随机生成一个 $y \sim g(x)$ 。
3. 随机生成一个 $u \sim U(0, 1)$ 。
4. 计算并判断：如果 $u < \frac{f(y)}{cg(y)}$ ，接受（即令 X 为 y ）。

2.3 原理

当给定生成的 Y 为 $\hat{y}$ 时，接受的概率为：

$$P(\text{Accept} \mid Y = \hat{y}) = P\left(u < \frac{f(\hat{y})}{cg(\hat{y})}\right) = \frac{f(\hat{y})}{cg(\hat{y})}$$

因此，总体的接受率为：

$$P(\text{Accept}) = \sum_{\hat{y}} P(\text{Accept} \mid Y = \hat{y})P(Y = \hat{y}) = \sum_{\hat{y}} \frac{f(\hat{y})}{cg(\hat{y})}g(\hat{y}) = \frac{1}{c} \sum_{\hat{y}} f(\hat{y}) = \frac{1}{c}$$

Tip: 这表明，接受率仅依赖于常数 c ，而与具体的分布形状无关。这意味着如果我们希望提高采样效率，就需要尽可能选择一个贴近 $f(x)$ 的提议分布 $g(x)$ ，从而使 c 尽量小。

最后验证一下最终输出的样本服从的分布 $f(x)$ ：


$$\begin{aligned} P(X = x) &= P(Y = x \mid \text{Accept}) \\ &= \frac{P(Y = x, \text{Accept})}{P(\text{Accept})} \\ &= \frac{P(\text{Accept} \mid Y = x)P(Y = x)}{P(\text{Accept})} \\ &= \frac{\frac{f(x)}{cg(x)}g(x)}{\frac{1}{c}} \\ &= f(x) \end{aligned}$$

2.4 Tips

对于 $g(x)$ ，我们希望尽可能地求到 c 的下界。由公式可以看出，尽管 c 的选择不影响最终生成的 X ，但会影响接受率。接受率越高，生成效率越高（要生成 n 个随机数，需要生成 cn 个 Y ）。

由于任何 PDF 在定义域上的积分都为 1，限制了 $c > 1$ 。为了使效率尽量高，我们希望 c 尽可能地接近 1（即两分布尽可能地相似）。

A-R 方法的一种理解：它本质上是一种蒙特卡洛方法（后续会学到具体的蒙特卡洛方法），如图所示，我们在蓝色线下采样，只接受绿色线下的 X 。



3 变换方法 (Transformation Methods)

3.1 非通用法

以下是一些常见的变换方法，用于从已知分布生成特定分布的随机变量。

1. $Z \sim N(0, 1) \Rightarrow V = Z^2 \sim \chi^2(1)$
2. $U \sim \chi^2(m) \perp V \sim \chi^2(n) \Rightarrow F = \frac{\frac{U}{m}}{\frac{V}{n}} \sim F_{m,n}$
3. $Z \sim N(0, 1) \perp V \sim \chi^2(n) \Rightarrow T = \frac{Z}{\sqrt{\frac{V}{n}}} \sim t_n$
4. $U \sim Unif(0, 1) \perp V \sim Unif(0, 1) \Rightarrow Z_1 = \sqrt{-2 \log U} \cos(2\pi V), Z_2 = \sqrt{-2 \log U} \sin(2\pi V) \sim N(0, 1)$
5. $U \sim T(r, \lambda) \perp V \sim T(s, \lambda) \Rightarrow X = \frac{U}{U+V} \sim Beta(r, s)$
6. $U \sim Unif(0, 1) \perp V \sim Unif(0, 1) \Rightarrow X = \left\lceil 1 + \frac{\log(V)}{\log((1-(1-\theta)^U)} \right\rceil \sim \text{Logarithmic}(\theta)$

4 Sums and Mixtures

4.1 Sums (Convolutions)

在同种分布下： $X_i \stackrel{iid}{\sim} X \Rightarrow S = X_1 + \dots + X_n$ 的分布函数是 X 分布函数的 n 折卷积。
特别地，有：

1. $\chi_r^2 = \sum_{i=1}^r X_i^2$ ，其中 $X_i \stackrel{iid}{\sim} N(0, 1)$

2. $NegBin(r, p) = \sum_{i=1}^r X_i$, 其中 $X_i \stackrel{iid}{\sim} Geom(p)$
3. $Gamma(r, \lambda) = \sum_{i=1}^r X_i$, 其中 $X_i \stackrel{iid}{\sim} Exp(\lambda)$

例：生成 χ_r^2 的方法

1. 随机生成 $n \times r$ 的 $N(0, 1)$ 矩阵。
2. 将每个 $N(0, 1)$ 平方。
3. 每一行求和，即为 n 个 X_r^2 分布。

4.2 Mixtures

混合分布定义为分布 X 以 θ_i 的概率来自分布 X_i ，具体公式：

$$F_X(x) = \sum \theta_i F_{X_i}(x), \quad \text{s.t.} \quad \sum \theta_i = 1$$

生成 X 的具体步骤：

1. 定义区间 $I_j = [\sum_{i=1}^{j-1} \theta_i, \sum_{i=1}^j \theta_i)$, $I_1 = [0, \theta_1)$ 。
2. 生成 $U \sim Unif(0, 1)$ 。
3. 如果 $U \in I_k$ ，则交付 X_k 。

例：生成 $F_X(x) = \frac{1}{5}\theta_i F_{X_i}(x)$ ，其中 $\theta_i = \frac{1}{5}$, $X_i \sim T(3, \lambda_i)$ 。

- $n \leftarrow 5000$; $k \leftarrow \text{sample}(1 : 5, \text{size} = n, \text{prob} = (1 : 5)/15, \text{replace} = \text{True})$ 。
- $\text{rate} \leftarrow 1/k$; $X \leftarrow \text{rgamma}(n, \text{shape} = 3, \text{rate} = \text{rate})$ 。

其它例子

$$F_X(x) = \sum \theta_i F_{X_i}(x), \quad \theta = [0.1, 0.2, 0.2, 0.3, 0.2]$$

$$\lambda_i = (1, 1.5, 2, 2.5, 3), \quad X_i \sim T(3, \lambda_i)$$

- $n \leftarrow 5000$; $p \leftarrow c(0.1, 0.2, 0.2, 0.3, 0.2)$; $\text{lambda} \leftarrow c(1, 1.5, 2, 2.5, 3)$ 。
- $k \leftarrow \text{sample}(1 : 5, \text{size} = n, \text{replace} = \text{True}, \text{prob} = p)$ 。
- $\text{rate} \leftarrow \text{lambda}[k]$ 。
- $X \leftarrow \text{rgamma}(n, \text{shape} = 3, \text{rate} = \text{rate})$ 。

5 特殊的例子：多维正态分布 Multivariate Distributions

5.1 多维正态分布的性质

1. PDF:

$$f(x) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(x - \mu)^T \Sigma^{-1}(x - \mu)\right), \quad x \in \mathbb{R}^d, X \sim N(\mu, \Sigma).$$

$$2. Z = \begin{pmatrix} X \\ Y \end{pmatrix} \sim N \left(\begin{pmatrix} \mu_X \\ \mu_Y \end{pmatrix}, \begin{pmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{pmatrix} \right).$$

条件分布: $X|Y = y \sim N(\mu_X + \Sigma_{XY}\Sigma_{YY}^{-1}(y - \mu_Y), \Sigma_{XX} - \Sigma_{XY}\Sigma_{YY}^{-1}\Sigma_{YX})$

3. 线性变换: $X \sim N(\mu, \Sigma) \Rightarrow AX + b \sim N(A\mu + b, A\Sigma A^T)$ 。

5.2 生成多维正态分布 $X \in \mathbb{R}^d \sim N(\mu, \Sigma)$:

步骤:

1. 生成 $Z \sim N(0, I_d)$ 。
2. 分解 $\Sigma = CC^T$:
 - 谱分解: $\Sigma = P\Lambda P^T$, 其中 $C = P\Lambda^{1/2}P^T$ 。
 - Cholesky 分解: $\Sigma = LL^T$, 其中 $C = L$ 。
3. 对 Z 做线性变换: $X = \mu + CZ$

5.3 多维正态分布的混合分布 $pN_d(\mu_1, \Sigma_1) + (1 - p)N_d(\mu_2, \Sigma_2)$

步骤:

1. 随机生成 $U \sim Unif(0, 1)$ 。
2. 如果 $U \leq p$, 生成 $X \sim N_d(\mu_1, \Sigma_1)$, 否则生成 $X \sim N_d(\mu_2, \Sigma_2)$ 。

5.4 Wishart Distribution

定义: $X \in \mathbb{R}^{n \times d}$, 每一行都服从 $N_d(\mu, \Sigma) \Rightarrow M = XX^T \sim W_d(\Sigma, n)$

简单方法: 每次都从 Z 生成 X , 再从 X 生成 M 。

Bartlett 分解法:

1. 生成下三角矩阵 T , 其中 $T_{ij} \stackrel{iid}{\sim} N(0, 1)$, $T_{ii} \sim \sqrt{n - i + 1}$ 。
2. 计算 $A = TT^T$ 。
3. 通过 Cholesky 分解得到 $\Sigma = LL^T$ 中的 L 。
4. 计算 LAL^T 即得。