

Lecture 2: 蒙特卡洛方法与方差缩减

Layleace

2025 年 12 月 16 日

蒙特卡洛方法是一种基于随机抽样的数值计算技术，广泛应用于积分估计、概率模拟等领域。本章将介绍简单蒙特卡洛估计器以及一些改进方法。

1 蒙特卡洛方法

目标：估计积分 $\int g(x) dx$

原理： $E(g(x)) = \int g(x)f_X(x) dx$

1.1 简单蒙特卡洛估计器

在均匀分布上进行采样。

- $[0, 1]$ 区间上： $\int_0^1 g(x) dx$: $\hat{\theta} = \frac{1}{m} \sum_{i=1}^m g(X_i)$, $X_i \sim \text{Uniform}(0, 1)$
- $[a, b]$ 区间上： $\int_a^b g(x) dx$: $\hat{\theta} = \frac{b-a}{m} \sum_{i=1}^m g(X_i)$, $X_i \sim \text{Uniform}(a, b)$
- 无界区间：
 1. 利用对称性.

2. 利用特殊分布 PDF 和示性函数 (“Hit-or-Miss” Approach)

示例：计算 $\int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt$

1. 利用对称性（将原函数看作 $g(x)$ ，在均匀分布上采样）：

$$\int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt = \frac{1}{2} + (-1)^{I(X < 0)} \cdot \int_0^{|x|} \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt$$

2. 利用特殊分布 PDF 和示性函数 (“Hit-or-Miss” 方法，将原函数看作 $f_X(x)$ ，在 $N(0, 1)$ 上采样）：

注意到 $g(x)$ 是标准正态分布 $N(0, 1)$ 的 PDF：

$$\int_{-\infty}^{\infty} I(t \leq x) g(t) dt = E(I(Z \leq x)), \quad Z \sim N(0, 1)$$

2 方差缩减 Variance Reduction

方差缩减是提高蒙特卡洛方法效率的关键技术。通过降低估计量的方差，可以在相同的样本量下获得更精确的结果。

如果 $\hat{\theta}_1$ 和 $\hat{\theta}_2$ 是两个估计量，则 $\text{Var}(\hat{\theta})$ 越小，效率越高。

定义方差缩减量：

$$\text{Reduction in Variance} = \frac{\text{Var}(\hat{\theta}_1) - \text{Var}(\hat{\theta}_2)}{\text{Var}(\hat{\theta}_1)}$$

下面介绍几种方差缩减的具体方法。

2.1 Antithetic Variate

原理：若 $f(x)$ 和 $g(x)$ 同时递增或递减，则 $E(f(x)g(x)) \geq E(f(x))E(g(x))$ 。（证明如下）

$Y = g(F_X^{-1}(U_1), \dots, F_X^{-1}(U_n))$ 与 $Y' = g(F_X^{-1}(1 - U_1), \dots, F_X^{-1}(1 - U_n))$ 有 Y 与 $-Y'$ 同递增递减。

故 $E(Y(-Y')) \geq E(Y)E(-Y') \rightarrow E(YY') - E(Y)E(Y') = \text{Cov}(Y, Y') \leq 0$ 。

即 Y 与 Y' 呈负相关，可利用这一性质减小方差。**证明**（归纳假设）：

i. 一维情况：

$\because f(x)$ 和 $g(x)$ 同时递增或递减;

$\therefore (f(x) - f(y))(g(x) - g(y)) \geq 0$

$\therefore f(x)g(x) - f(y)g(x) - f(x)g(y) + f(y)g(y) \geq 0$

$\therefore$ 两边取期望：

$$E(f(x)g(x)) + E(f(y)g(y)) - E(f(x))E(g(y)) - E(f(y))E(g(x)) \geq 0$$

$\because X \perp\!\!\!\perp Y$

$$\therefore E(f(x))E(g(x)) + E(f(y))E(g(y)) - E(f(x))E(g(y)) - E(f(y))E(g(x)) \geq 0$$

$$\therefore 2E(f(x)g(x)) - 2E(f(x))E(g(x)) \geq 0$$

$$\therefore E(f(x)g(x)) \geq E(f(x))E(g(x))$$

ii. n 维情况:

$$\begin{aligned} E(f(X)g(X) | X_n = x_n) &= E(f(X_1, \dots, X_{n-1}, x_n)g(X_1, \dots, X_{n-1}, x_n)) \\ &\geq E(f(X) | X_n = x_n)E(g(X) | X_n = x_n) \end{aligned}$$

$$\begin{aligned} \text{由全期望公式: } E(f(X)g(X)) &= E(E(f(X)g(X)|X_n = x_n)) \\ &\geq E(E(f(X)|X_n = x_n)E(g(X)|X_n = x_n)) \\ &\geq E(f(X))E(g(X)) \end{aligned}$$

2.1.1 步骤

1. 生成 $U_1, U_2, \dots, U_n$, 得到 $\hat{\theta}_1 = g(U_1, \dots, U_n)$ 。
2. 计算 $\hat{\theta}_2 = g(1 - U_1, \dots, 1 - U_n)$ 。
3. 计算平均值 $\hat{\theta}$, $\hat{\theta}$ 为一个估计值:

$$\hat{\theta} = \frac{1}{2}(\hat{\theta}_1 + \hat{\theta}_2)$$

2.1.2 方差比较

新的估计值方差:

$$\begin{aligned} \text{Var}(\bar{\hat{\theta}}) &= \text{Var}\left(\frac{2}{m} \sum_{i=1}^{\frac{m}{2}} \hat{\theta}\right) \\ &= \frac{2}{m} \text{Var}(\hat{\theta}) \\ &= \frac{2}{m} \text{Var}\left(\frac{1}{2}(\hat{\theta}_1 + \hat{\theta}_2)\right) \\ &= \frac{2}{m} \left(\frac{1}{4} \text{Var}(\hat{\theta}_1) + \frac{1}{4} \text{Var}(\hat{\theta}_2) + \frac{1}{2} \text{Cov}(\hat{\theta}_1, \hat{\theta}_2) \right) \\ &= \frac{1}{m} \left(\text{Var}(\hat{\theta}_1) + \text{Cov}(\hat{\theta}_1, \hat{\theta}_2) \right) \\ &\leq \frac{1}{m} \text{Var}(\hat{\theta}_1) \end{aligned}$$

简单蒙特卡洛方法方差:

$$\begin{aligned} \text{Var}(\bar{\hat{\theta}}) &= \text{Var}\left(\frac{1}{m} \sum_{i=1}^m \hat{\theta}\right) \\ &= \frac{1}{m} \text{Var}(\hat{\theta}) \\ &= \frac{1}{m} \text{Var}(\hat{\theta}_1) \end{aligned}$$

Tips: 方差的比较标准是生成次数 m 相同而不是估计值数量相同, Antithetic Method 只有 $\frac{m}{2}$ 个估计值。

2.2 Control Variate

原理：令新的估计值为 $\hat{\theta}_c = g(X) + c(f(X) - \mu)$ ，其中 $f(X)$ 为已知均值为 μ 的辅助函数。

$$\text{Var}(\hat{\theta}_c) = \text{Var}(g(X)) + c^2 \text{Var}(f(X)) + 2c \text{Cov}(g(X), f(X))$$

令上式最小化的 c^* 为（上式对 c 求导即可得）：

$$c^* = \text{argmin } \text{Var}(\hat{\theta}_c) = -\frac{\text{Cov}(g(X), f(X))}{\text{Var}(f(X))}$$

此时：

$$\text{Var}(\hat{\theta}_c) = \text{Var}(g(X)) - \frac{\text{Cov}^2(g(X), f(X))}{\text{Var}(f(X))}$$

注意到， $|\text{Cov}(g(X), f(X))|$ 越大，方差缩减量越多。

2.2.1 步骤

- ① 选择一个辅助函数 $f(X)$ （与目标函数 $g(X)$ 相关性越高越好），已知 $f(X)$ 在 g 的支撑集上均值为 μ 。计算最优系数：

$$c^* = -\frac{\text{Cov}(g(X), f(X))}{\text{Var}f(X)}$$

（注：也可以用程序估计）。

- ② 构造新的估计量：

$$\hat{\theta} = g(X) + c^*(f(X) - \mu)$$

- ③ 计算样本均值作为最终估计：

$$\bar{\hat{\theta}} = \frac{1}{m} \sum_{i=1}^m (g(X_i) + c^*(f(X_i) - \mu))$$

2.2.2 方差分析

新估计量的方差为：

$$\begin{aligned} \text{Var}(\bar{\hat{\theta}}) &= \frac{1}{m} \text{Var}(\hat{\theta}) \\ &= \frac{1}{m} \text{Var}(g(X) + c^*(f(X) - \mu)) \\ &= \frac{1}{m} \left(\text{Var}g(X) - \frac{\text{Cov}^2(g(X), f(X))}{\text{Var}f(X)} \right) \end{aligned}$$

2.2.3 对偶变量法 (Antithetic Method) 是控制变量法的特例

定义组合估计量:

$$\hat{\theta}_c = c\hat{\theta}_1 + (1-c)\hat{\theta}_2$$

其方差为:

$$\text{Var}\hat{\theta}_c = c^2\text{Var}\hat{\theta}_1 + (1-c)^2\text{Var}\hat{\theta}_2 + 2c(1-c)\text{Cov}(\hat{\theta}_1, \hat{\theta}_2)$$

在对偶变量情况下, 有 $\text{Var}\hat{\theta}_1 = \text{Var}\hat{\theta}_2$ 且 $\text{Cov}(\hat{\theta}_1, \hat{\theta}_2) = -\text{Var}(\hat{\theta}_1)$ 。因此,

$$\text{Var}\hat{\theta}_c = (c^2 + (1-c)^2 - 2c(1-c))\text{Var}\hat{\theta}_1 = (4c^2 - 4c + 1)\text{Var}\hat{\theta}_1$$

此时, 当 $c^* = \frac{1}{2}$ 时, 得到最优组合:

$$\hat{\theta}_c = \frac{1}{2}\hat{\theta}_1 + \frac{1}{2}\hat{\theta}_2$$

2.2.4 控制变量法 vs 线性回归 (Regression)

考虑线性模型:

$$g(X) = \beta_0 + \beta_1 f(X) + \varepsilon$$

其中 β_1 是斜率的最小二乘估计。

① 最小二乘估计:

$$\hat{\beta}_1 = \frac{\text{Cov}(g(X), f(X))}{\text{Var}(f(X))} = -c^*$$

(注意负号! 由此, c^* 可以用拟合模型的斜率相反数估计。)

② 截距项估计:

$$\hat{\beta}_0 = g(X) - \hat{\beta}_1 f(X) = g(X) - (-c^*)f(X)$$

因此, 预测响应为:

$$\hat{\beta}_0 + \hat{\beta}_1 \mu = g(X) + c^* f(X) - c^* \mu = g(X) + c^* (f(X) - \mu) = \hat{\theta}_c^*$$

($\hat{\theta}_c$ 是在点 μ 处的预测相应。)

③ 残差均方估计 (MSE):

$$\hat{\sigma}_\varepsilon^2 = \text{Var}(X - \hat{X}) = \text{Var}(X - (\hat{\beta}_0 + \hat{\beta}_1 Y)) = \text{Var}(X - \hat{\theta}_c^*)$$

估计值方差:

$$\text{Var}(\bar{\theta}) = \frac{1}{m} \text{Var}(g(X) + c^*(f(X) - \mu)) = \frac{1}{m} \text{Var}(g(X) + c^* f(X)) = \frac{1}{m} \hat{\sigma}_\varepsilon^2$$

(注: 可以用 R 语言中的 `summary` 方法求出 $\hat{\sigma}_\varepsilon^2$ 来计算方差。)

④ 方差减少比例:

$$\frac{\text{Cov}^2(g(X), f(X))}{\text{Var}f(X)\text{Var}g(X)} = \text{Corr}^2(f(X), g(X)) = R^2$$

2.3 重要性抽样 (Importance Sampling)

当利用 $\frac{b-a}{m} \sum_{i=1}^m g(X_i)$ 估计 $\int_a^b g(x)dx$ 时, 如果 $g(x)$ 不是非常均匀, 那么在整个区间上均匀抽样可能会效率低下。可以考虑更有效的抽样函数。

2.3.1 原理

- 简单蒙特卡洛 (Simple MC):

$$\int_a^b g(x)dx = (b-a) \int_a^b g(x) \frac{1}{b-a} dx = (b-a) \overline{g(x)}, \quad X \sim \text{Unif}(a, b)$$

- 重要性抽样 (Importance Sampling):

$$\int g(x)dx = \int \frac{g(x)}{f(x)} f(x)dx = \overline{\frac{g(x)}{f(x)}}, \quad X \text{ 由 pdf } f(x) \text{ 生成}$$

2.3.2 重要性函数的选择

目标是方差缩减, 故我们希望估计量 $\hat{\theta} = \frac{1}{m} \sum_{i=1}^m \frac{g(X_i)}{\phi(X_i)}$ 的方差最小。方差为:

$$\text{Var}\hat{\theta} = \frac{1}{m} \text{Var} \left(\frac{g(X)}{\phi(X)} \right)$$

由此, 我们期望 $\frac{g(X)}{\phi(X)}$ 接近一个常数, 以使得方差最小。

$$\text{Var}\hat{\theta} = \frac{1}{m} \text{Var} \left(\frac{g(X)}{\phi(X)} \right) = \frac{1}{m} \left(\mathbb{E} \left[\left(\frac{g(X)}{\phi(X)} \right)^2 \right] - \theta^2 \right) = \frac{1}{m} \left(\int_A \frac{g^2(x)}{\phi(x)} dx - \theta^2 \right)$$

上式在 $\phi(x) = \frac{|g(x)|}{\int_A |g(x)| dx}$ 时取得最小值 $\frac{1}{m} \left(\left(\int_A |g(x)| dx \right)^2 - \theta^2 \right)$ 。

2.3.3 证明:

利用 Cauchy-Schwarz 不等式:

$$||u|| \cdot ||v|| \geq |\langle u, v \rangle|$$

令 $u = \sqrt{\frac{g^2(x)}{\phi(x)}}$, $v = \sqrt{\phi(x)}$, 则:

$$\int \frac{g^2(x)}{\phi(x)} dx \cdot \int \phi(x) dx \geq \left(\int |g(x)| dx \right)^2$$

等号成立当且仅当 $\frac{g^2(x)}{\phi^2(x)} = k$ 对所有 x 成立, 即 $\phi(x) = c|g(x)|$ 。为使 $\phi(x)$ 在 A 上积分为 1, 取:

$$\phi(x) = \frac{|g(x)|}{\int_A |g(x)| dx}$$

注: 以上是一个理想的情况, 但估计 $\int_A |g(x)| dx$ 很难 (且目标本身就是估计 $\int_A g(x) dx$), 所以我们一般选择在形状上接近 $|g(x)|$ 的密度函数。

2.4 分层抽样 (Stratified Sampling)

2.4.1 标准分层抽样 (Standard Stratified Sampling)

步骤:

① 将 $(0, 1)$ 区间平均划分为 k 个子区间。

② 计算每个子区间上的估计值:

$$\hat{\theta}_j = \frac{1}{m} \sum_{i=1}^m g(X_{ij}), \quad X_{ij} \in A_j$$

③ 计算总体估计:

$$\hat{\theta}^S = \frac{1}{k} \sum_{j=1}^k \hat{\theta}_j$$

对于在 (a, b) 区间上的目标函数 $\int_a^b g(x) dx$:

$$\begin{aligned} \mathbb{E} \left(\sum_{j=1}^k \hat{\theta}_j \right) &= \sum_{j=1}^k \mathbb{E}(\hat{\theta}_j) = \sum_{j=1}^k \mathbb{E}g(X_j) = \sum_{j=1}^k \int_{A_k} g(x) f(x) dx \\ &= \sum_{j=1}^k \int_{A_k} g(x) \frac{k}{b-a} dx = \int_a^b g(x) dx \cdot \frac{k}{b-a} \\ &= \frac{k}{b-a} \theta \end{aligned}$$

因此, 总体估计为:

$$\hat{\theta}^S = \frac{b-a}{k} \sum_{j=1}^k \hat{\theta}_j$$

2.4.2 原理 (为什么能减小方差)

仅针对标准分层抽样:

$$\begin{aligned}\text{Var}\hat{\theta}^S &= \frac{1}{k^2} \text{Var} \left(\sum_{j=1}^k \hat{\theta}_j \right) = \frac{1}{k^2} \sum_{j=1}^k \text{Var}\hat{\theta}_j = \frac{1}{k^2} \sum_{j=1}^k \frac{1}{m} \text{Var}g(X_j) \\ &= \frac{1}{mk} \sum_{j=1}^k \text{Var}g(X_j)\end{aligned}$$

而简单蒙特卡洛的方差为:

$$\begin{aligned}\text{Var}\hat{\theta}^M &= \frac{1}{m} \text{Var}(g(X)) = \frac{1}{m} (\text{Var}(\mathbb{E}(g(X)|J=j)) + \mathbb{E}(\text{Var}(g(X)|J=j))) \\ &= \frac{1}{m} \text{Var}\hat{\theta}_J + \frac{1}{m} \mathbb{E}(\text{Var}(g_j)) \\ &= \frac{1}{m} \text{Var}\hat{\theta}_J + \frac{1}{m} \cdot \frac{1}{k} \sum_{j=1}^k \text{Var}g(X_j) \\ &= \frac{1}{m} \text{Var}\hat{\theta}_J + \text{Var}\hat{\theta}^S \geq \text{Var}\hat{\theta}^S\end{aligned}$$

等号成立当且仅当每一层的估计值相等。每层估计差异越大, 减小的方差越多。

2.5 分层重要性抽样 (Stratified Importance Sampling)

利用重要性抽样思想对分层抽样作改进。

2.5.1 原理

在分层抽样中, 我们从均匀分布中采样 U 加以处理得到估计值。在 SI 中, 我们利用辅助的重要性函数 $f(x)$ (pdf) 采样 X 得到估计值。

f 满足在被积区间 A 上 $\int_A f(x)dx = 1$, 其对应的 cdf 为 $F(x)$ 。

令 $a_0 = -\infty$, $a_j = F^{-1}(j/k)$, $a_k = +\infty$. $I_j = (a_{j-1}, a_j]$ 。

第 j 层的条件密度为:

$$f_j(x) = f_{X|I_j}(x|I_j) = \frac{P(X=x, X \in I_j)}{P(X \in I_j)} = \frac{f(x) \cdot I(a_{j-1} \leq x < a_j)}{1/k} = kf(x)I(a_{j-1} \leq x < a_j)$$

在每个区间中计算 $\hat{\theta}_j$:

$$\begin{aligned}\theta_j &= \int_{I_j} \frac{g(x)}{f_j(x)} \cdot f_j(x)dx \\ \hat{\theta}_j &= \frac{1}{m} \sum_{i=1}^m \frac{g(X_i)}{kf(X_i)}, \quad X \text{ 具有 pdf } kf(x)I(a_{j-1} \leq x < a_j)\end{aligned}$$

总体期望：

$$\mathbb{E} \left(\sum_{j=1}^k \hat{\theta}_j \right) = \sum_{j=1}^k \mathbb{E} \hat{\theta}_j = \sum_{j=1}^k \int_{I_j} \frac{g(x)}{kf(x)} \cdot kf(x) dx = \sum_{j=1}^k \int_{I_j} g(x) dx = \int g(x) dx = \theta$$

2.5.2 方差分析

SI 永远能减小方差（相比于 IS）：

证明：

为比较重要性抽样（IS）与分层重要性抽样（SI）的方差，设总样本量为 $M = mk$ 。

令 $X \sim f$ ，定义 $Y = g(X)/f(X)$ ，则 $\sigma^2 = \text{Var}(Y) = \text{Var}(g(X)/f(X))$ 。

对 SI，将实数轴按 f 的分位数划分为 k 个区间 $I_j = [a_{j-1}, a_j]$ ，其中 $a_j = F^{-1}(j/k)$ ，第 j 层的条件密度为 $f_j(x) = kf(x)\mathbf{1}_{x \in I_j}$ ，并记 $\sigma_j^2 = \text{Var}_{f_j}(g_j(X)/f_j(X))$ 。

SI 估计量为 $\hat{\theta}_{SI} = \sum_{j=1}^k \hat{\theta}_j$ ，其中 $\hat{\theta}_j = \frac{1}{m} \sum_{i=1}^m \frac{g(X_{ji})}{kf(X_{ji})}$ ，故其方差为 $\text{Var}(\hat{\theta}_{SI}) = \frac{1}{m} \sum_{j=1}^k \sigma_j^2 = \frac{k}{M} \sum_{j=1}^k \sigma_j^2$ ；

而 IS 估计量方差为 $\text{Var}(\hat{\theta}_I) = \sigma^2/M$ 。

因此 SI 优于 IS 当且仅当 $\sigma^2 - k \sum_{j=1}^k \sigma_j^2 \geq 0$ 。

为证此式，构造两阶段随机变量：

先从 $\{1, \dots, k\}$ 中均匀抽取 J ；再在给定 $J = j$ 下从 f_j 中抽取 X^* ，并令 $Y^* = g_J(X^*)/f_J(X^*) = g(X^*)/(kf(X^*))$ 。

注意到 $Y = g(X)/f(X) \stackrel{d}{=} kY^*$ （因 $X \sim f$ 等价于先抽层再抽样），故 $\sigma^2 = \text{Var}(Y) = k^2 \text{Var}(Y^*)$ 。由条件方差公式，

$$\text{Var}(Y^*) = \mathbb{E}[\text{Var}(Y^* | J)] + \text{Var}(\mathbb{E}[Y^* | J]) = \frac{1}{k} \sum_{j=1}^k \sigma_j^2 + \text{Var}(\theta_J),$$

其中 $\mathbb{E}[Y^* | J = j] = \theta_j$ 。因此，

$$\sigma^2 = k^2 \left(\frac{1}{k} \sum_{j=1}^k \sigma_j^2 + \text{Var}(\theta_J) \right) = k \sum_{j=1}^k \sigma_j^2 + k^2 \text{Var}(\theta_J),$$

从而

$$\sigma^2 - k \sum_{j=1}^k \sigma_j^2 = k^2 \text{Var}(\theta_J) \geq 0,$$

等号成立当且仅当 $\theta_1 = \theta_2 = \dots = \theta_k$ 。故分层重要性抽样永远不会增大方差，且只要各层积分值不全相等，方差就严格减小。