

Lecture4: Bootstrap and Jackknife

Layleace

2025 年 12 月 17 日

本章介绍两种重要的重抽样（resampling）技术：Bootstrap 和 Jackknife。它们的核心思想是“用数据估计数据”，即利用已观测到的有限样本，通过重复抽样的方式，模拟出一个“经验分布”或“伪总体”，从而对统计量（如标准误、偏差、置信区间等）进行估计。

Bootstrap 通过“有放回地”抽取样本（即重抽样）来近似统计量的抽样分布；而 Jackknife 则是一种“留一法”（leave-one-out）技术，通过系统地剔除一个观测值来评估统计量的稳定性。

1 Bootstrap

1.1 基本思想

Plug-in principle: 参数是总体的函数，统计量/估计是数据的函数。

令 F 代表总体， $\hat{F}$ 代表由已观测样本得到的离散分布， F^* 代表从 $\hat{F}$ 中抽样得到的离散分布。

则具有以下两个近似：

$$\begin{aligned}\hat{F} &\rightarrow F \\ F^* &\rightarrow \hat{F}\end{aligned}$$

注意： F^* 不一定是 F 的良好估计。Bootstrap 一章中最重要的就是，每次只向前走一步，用重抽样得到的结果拟合估计量，用估计量拟合真实值。

1.2 步骤

重复 R 次：

- 1 从观测值中有放回地抽取 n （与观测总数相同）个样本。
- 2 用待估参数 $\theta = g(X)$ 的函数计算出 $\hat{\theta}^{(i)} = g(X^{*(i)})$ 。（这里的 $X^{*(i)}$ 是一组样本）

由得到的 $\hat{\theta}^{(1)}, \dots, \hat{\theta}^{(R)}$ 可以作出估计。

1.3 估计结果

	估计目标	估计 H_0
1)	$F_{\hat{\theta}(\cdot)}$	$\hat{\theta}^{(i)}$ 的经验分布函数
2)	$\widehat{s.e.}(\hat{\theta})$	$\sqrt{\frac{1}{B-1} \sum_{b=1}^B (\hat{\theta}^{(b)} - \bar{\hat{\theta}})^2}$
3)	$\widehat{bias}(\hat{\theta})$	$\frac{1}{B} \sum_{b=1}^B \hat{\theta}^{(b)} - \hat{\theta}$

注： $\hat{\theta}$ 是用所有观测值作出的估计，根本上是在用 $\hat{\theta}^{(1)}, \dots, \hat{\theta}^{(R)}$ 对 $\hat{\theta}$ 的分布作出估计，与 θ 无关。

2 θ 的置信区间

2.1 根本问题

记：

$\hat{\theta}$ ：原始样本的估计值（点估计）

θ ：未知的真实参数（我们想对它做推断）

$\hat{\theta}_b^*$ ：第 b 次 Bootstrap 重抽样的估计值（共 B 次）

2.2 Standard Normal Bootstrap CI

原理： $Z = \frac{\hat{\theta} - \mathbb{E}\hat{\theta}}{se(\hat{\theta})}$ 近似服从正态分布。（正态性假设）

故，如果 $\hat{\theta}$ 是 θ 的无偏估计，则 θ 的置信区间为：

$$\left[\hat{\theta} - z_{\alpha/2} se(\hat{\theta}), \hat{\theta} + z_{\alpha/2} se(\hat{\theta}) \right]$$

2.3 Bootstrap t interval

Remark：相比于其它方法，Bootstrap t interval 多走了一层，做了第二次重抽样来对每一个 $\hat{\theta}^{(b)}$ 也进行估计！

Standard Normal Bootstrap CI 具有以下两个问题：

问题 1：由于我们没有精确的 $se(\hat{\theta})$ ，只能使用其估计，故用正态分布显然是有问题的。
解决方法：用 t 分布。

问题 2：由于 $se(\hat{\theta})$ 的分布未知，无法直接用 Student-t 分布（自由度未知）。解决方法：计算一个近似的 t 型统计量。

步骤:

- 1) 计算 $\hat{\theta}$ (利用观测样本)。
- 2) 重复 R 次:
 - (a) 从观测值中放回地抽取 n 个 $X^{(b)} = (X_1^{(b)}, \dots, X_n^{(b)})$ 。
 - (b) 利用这一组重抽样样本计算 $\hat{\theta}^{(b)}$ 。
 - (c) 从 $X^{(b)}$ 中再做重抽样, 估计 $\widehat{se}(\hat{\theta}^{(b)})$ 。(这里是重点, 重抽样套重抽样)
 - (d) 计算 $t^{(b)} = \frac{\hat{\theta}^{(b)} - \hat{\theta}}{\widehat{se}(\hat{\theta}^{(b)})}$ 。
- 3) 从 $t^{(b)}$ 分布中找到 $t_{\alpha/2}^*$ 和 $t_{1-\alpha/2}^*$ 。
- 4) 计算 $\widehat{se}(\hat{\theta})$ (外层重抽样的估计)。
- 5) 置信区间为:

$$\left[\hat{\theta} - t_{1-\alpha/2}^* \widehat{se}(\hat{\theta}), \hat{\theta} - t_{\alpha/2}^* \widehat{se}(\hat{\theta}) \right]$$

最大问题: 时间复杂度高。

2.4 Basic Bootstrap CI (pivotal)

这种估计不依赖于具体分布。

基本 Bootstrap CI 的关键假设是: 误差分布 $\hat{\theta} - \theta$ 在真实世界中 $\approx$ Bootstrap 误差分布 $\hat{\theta}^* - \hat{\theta}$ 。

$\hat{\theta}$ 是一个确定的数, 故可用 $\hat{\theta}_{1-\alpha/2}^* - \hat{\theta}$ 近似于 $\hat{\theta} - \theta$ 的 $1 - \alpha/2$ 分位数。

从而:

$$\begin{aligned} \hat{\theta}_{\alpha/2}^* - \hat{\theta} &\leq \hat{\theta} - \theta \leq \hat{\theta}_{1-\alpha/2}^* - \hat{\theta} \\ 2\hat{\theta} - \hat{\theta}_{1-\alpha/2}^* &\leq \theta \leq 2\hat{\theta} - \hat{\theta}_{\alpha/2}^* \end{aligned}$$

因此, 置信区间为:

$$\left[2\hat{\theta} - \hat{\theta}_{1-\alpha/2}^*, 2\hat{\theta} - \hat{\theta}_{\alpha/2}^* \right]$$

2.5 分位数 Bootstrap 置信区间 (Percentile Bootstrap CI)

原理: 利用 Bootstrap 得到的经验分布来代替参数的分布。

即对用 Bootstrap 求出的所有 $\hat{\theta}^*$ 进行一个排序 (从小到大), 按所需比例取其中的值。

例: $\alpha = 0.05$, 1000 个 $\hat{\theta}^*$: $[\hat{\theta}^{*(26)}, \hat{\theta}^{*(975)}]$

3 Jackknife

3.1 基本思想

“leave-one-out”。

步骤基本同 Bootstrap。区别在于 Jackknife 重采样的样本为 $X_{(i)} = (X_1, \dots, X_{i-1}, X_{i+1}, \dots, X_n)$ 。

3.2 估计量的计算

偏差 (Bias) 对于参数为方差: $\hat{\theta} = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$

理论上:

$$\begin{aligned} bias(\hat{\theta}) &= \mathbb{E}(\hat{\theta} - \theta) \\ &= \frac{n-1}{n} \sigma_X^2 - \sigma_X^2 \\ &= -\frac{\sigma_X^2}{n} \end{aligned}$$

另一方面,

$$\begin{aligned} \mathbb{E}(\hat{\theta}^* - \hat{\theta}) &= \mathbb{E}(\hat{\theta}^* - \theta) - \mathbb{E}(\hat{\theta} - \theta) \\ &= bias(\hat{\theta}_{(i)}) - bias(\hat{\theta}) \\ &= -\frac{\sigma_X^2}{n-1} - \left(-\frac{\sigma_X^2}{n}\right) \\ &= -\frac{\sigma_X^2}{(n-1)n} \end{aligned}$$

注意这个系数由于样本数量不同造成的。

因此,

$$\hat{bias}(\hat{\theta}) = (n-1)(\hat{\theta}_{(i)} - \hat{\theta})$$

其中, $\hat{\theta}_{(i)} = \frac{1}{n} \sum_{i=1}^n \hat{\theta}_{(i)}$ 。

标准误 (se) 对于参数为均值: $\hat{se}(\hat{\theta}) = \sqrt{\frac{n-1}{n} \sum_{i=1}^n (\hat{\theta}_{(i)} - \hat{\theta}_{(i)})^2}$

注: 背一下吧... 这玩意儿挺莫名其妙的。

3.3 问题

统计量对变化太敏感时容易失败。