

Lecture5: 马尔可夫链蒙特卡洛方法 (MCMC)

Layleace

2025 年 12 月 17 日

马尔可夫链蒙特卡洛 (Markov Chain Monte Carlo, MCMC) 方法的核心目标是解决一个在贝叶斯统计中普遍存在的难题: 如何从一个难以直接采样的目标分布 $f(X)$ 中生成样本。

MCMC 通过构造一个马尔可夫链, 使其平稳分布恰好等于我们想要采样的目标分布, 然后让这个链运行足够长的时间, 使其“收敛”到平稳分布。之后, 从链中抽取的样本就可以近似地视为来自目标分布的独立样本。

1 前情提要 1: 贝叶斯统计

在贝叶斯统计中, 我们有:

- 先验概率 $\pi(\theta)$: 依据主观猜测。
- 似然函数 $f(x|\theta)$ (即 $L(\theta|x)$): 通过真实的采样数据得到样本。似然函数依赖一个分布, 即我们事先知道 X 满足大致这样的分布, 只是不知道参数。
- 后验函数 $\pi(\theta|x)$:

$$\begin{aligned}\pi(\theta|x) &\propto \pi(\theta)f(x|\theta) \\ \Rightarrow \pi(\theta|x) &= \frac{\pi(\theta)f(x|\theta)}{\int \pi(\theta)f(x|\theta)d\theta}\end{aligned}$$

$\int \pi(\theta)f(x|\theta)d\theta$ 通常不显式, 导致 $\pi(\theta|x)$ 很难计算。为了从 $\pi(\theta|x)$ 这一后验分布中采样, 我们采用 MCMC。

2 前情提要 2: 马尔可夫链

2.1 性质

马尔可夫性:

$$P(X_{t+1}|X_0 = x_0, \dots, X_t = x_t) = P(X_{t+1}|X_t = x_t)$$

2.2 Ergodic theorem

当一个马尔可夫链不可约 (irreducible)、非周期 (aperiodic)、正常返 (positive recurrent), 则存在且仅有一个极限分布 π , 该马尔可夫链会收敛到这一极限分布。

2.3 极限分布

若一个分布 π 满足

$$\pi P = \pi$$

则称其为极限分布, 其中 P 为转移概率矩阵。

定理: 如果 π, P 满足 $P(X_t = r, X_{t+1} = s) = P(X_t = s, X_{t+1} = r) \quad \forall(r, s)$, 则 π 为极限分布。(你可能会觉得很奇怪, 上面这个式子里为什么没有 π , 事实上 $P(X_t = r, X_{t+1} = s) = P(X_{t+1} = s|X_t = r)P(X_t = r)$, 后一项即 $\pi(r)$ 。)

证明:

$$\begin{aligned} P(X_t = r) &= \sum_s P(X_t = r, X_{t+1} = s) \\ &= \sum_s P(X_t = s, X_{t+1} = r) \\ &= P(X_{t+1} = r) \end{aligned}$$

3 Metropolis-Hastings (MH) 算法

目标: 通过一个提议分布 $Y \sim g(\cdot|X_t)$, 输出服从 $f(\cdot)$ 的分布 (期待 f 作为极限分布 π)。

3.1 原理

期待 $P(X_t = r, X_{t+1} = s) = P(X_t = s, X_{t+1} = r) \quad \forall(r, s)$ 。

即:

$$\pi(r)P(r \rightarrow s) = \pi(s)P(s \rightarrow r)$$

显然 $\pi(\cdot)$ 直接乘上 $g(\cdot|X_t)$ 是无法满足上式的，故添加一个系数 α 。

令 $\alpha(r, s) = \min \left\{ 1, \frac{\pi(s)g(s|r)}{\pi(r)g(r|s)} \right\}$ ，则我们有：

$$\pi(r) \underbrace{g(X_{t+1} = s | X_t = r) \cdot \alpha(r, s)}_{\text{令其为 } P_{r \rightarrow s}} = \pi(s) \underbrace{g(X_{t+1} = r | X_t = s) \cdot \alpha(s, r)}_{\text{令其为 } P_{s \rightarrow r}}$$

此时 $\pi(\cdot)$ 为极限分布。

3.2 步骤

1) 选定一个提议分布 g ，从任意一点 X_0 出发。

2) 重复 m 次：

(a) 从 $g(\cdot|X_t)$ 中生成 Y 。

(b) 从 $\text{Unif}(0, 1)$ 中生成 U ，与 $r(X_t, Y) = \frac{\pi(Y)g(X_t|Y)}{\pi(X_t)g(Y|X_t)}$ 比较。

- 若 $U > r(X_t, Y)$ ，拒绝， $X_{t+1} = X_t$ 。
- 若 $U \leq r(X_t, Y)$ ，接受， $X_{t+1} = Y$ 。

3) 去掉前 k 个样本（这一步称为 Burn-in，因为我们要的是极限分布，故删去未收敛到极限的部分）。

注：个人认为这里写接受/拒绝不是一个好选择，因为被拒绝的样本也不是不要，或许可以称为“接受转移” / “拒绝转移”。可以理解为：当从 $X_t \rightarrow Y$ 时，若 $r(X_t, Y) < 1$ ，转移的概率为 $r(X_t, Y)$ ，则剩余的概率须被分配给留在原地。

3.3 MH 采样器

所有 $g(\cdot|X_t)$ ，无任何条件。

MH 采样器的特例：Metropolis 采样器 $g(\cdot|X_t)$ 对称，即 $g(r|s) = g(s|r)$ ，此时有：

$$r(X_t, Y) = \frac{\pi(Y)}{\pi(X_t)}$$

Metropolis 采样器的特例：Random Walk 采样器 $g(Y|X_t) = g(|Y - X_t|)$ ，各向同性。此时仍有：

$$r(X_t, Y) = \frac{\pi(Y)}{\pi(X_t)}$$

例如： $Y = X_t + Z$ ， $Z \sim N(0, \sigma^2) \Rightarrow Y|X_t \sim N(X_t, \sigma^2)$ 。其中 σ^2 可调节：

- σ^2 过大：移动范围更广，但很难控制接受率。
- σ^2 过小：移动范围小，困在原地，接受率高。

Independent sampler $g(Y|X_t) = g_2(Y)$ ，易于实现。

$$r(X_t, Y) = \frac{\pi(Y)g_2(Y)}{\pi(X_t)g_2(Y)}$$

当 g_2 与 π 很接近时， $r(X_t, Y) \approx 1$ 。

当建议密度分布与目标密度分布非常接近时能较好地工作，其他时候表现不佳。

3.4 监控收敛性：Gelman-Rubin Method

通过比较多个生成的链在某个或多个标量汇总统计量的方差方面的行为，监测 M-H 链的收敛性。

4 Gibbs Sampler

一种 MH 算法的特例，应用于目标是多元分布的情况。

4.1 步骤

- 1) 初始化 $X^{(0)} = (X_1^{(0)}, X_2^{(0)}, \dots, X_k^{(0)})$ 。
- 2) 重复（这里采用条件分布作为提议分布）：
 - (1) 生成 $X_1^{(t)} \sim f_{X_1}(X_1 | X_2^{(t-1)}, \dots, X_k^{(t-1)})$
 - (2) 生成 $X_2^{(t)} \sim f_{X_2}(X_2 | X_1^{(t)}, X_3^{(t-1)}, \dots, X_k^{(t-1)})$
 - $\vdots$
 - (i) 生成 $X_i^{(t)} \sim f_{X_i}(X_i | X_1^{(t)}, \dots, X_{i-1}^{(t)}, X_{i+1}^{(t-1)}, \dots, X_k^{(t-1)})$
 - $\vdots$
 - (k) 生成 $X_k^{(t)} \sim f_{X_k}(X_k | X_1^{(t)}, \dots, X_{k-1}^{(t)})$
- 3) Burn-in 前期样本。

4.2 Gibbs Sampler 的接受率始终为 1!

证明: 在 Gibbs Sampler 中, 提议分布为 $f(X_k|X_{(-k)})$, 目标分布为 $f(X_1, X_2, \dots, X_k)$ 。
下面我们假设为二元 (不失一般性):

$$\begin{aligned} r((X_1^{(t-1)}, X_2^{(t-1)}), (X_1^{(t)}, X_2^{(t-1)})) &= \frac{f(X_1^{(t)}, X_2^{(t-1)})f(X_1^{(t-1)}|X_2^{(t-1)})}{f(X_1^{(t-1)}, X_2^{(t-1)})f(X_1^{(t)}|X_2^{(t-1)})} \cdot \frac{f(X_1^{(t-1)}|X_2^{(t-1)})}{f(X_1^{(t)}|X_2^{(t-1)})} \\ &= \frac{f(X_1^{(t)}, X_2^{(t-1)})}{f(X_1^{(t)}|X_2^{(t-1)})} \cdot \frac{f(X_1^{(t-1)}|X_2^{(t-1)})}{f(X_1^{(t-1)}, X_2^{(t-1)})} \\ &= f(X_2^{(t-1)}) \cdot \frac{1}{f(X_2^{(t-1)})} \\ &= 1. \end{aligned}$$