

Lecture X: EM 算法

Layleace

2025 年 12 月 18 日

期望最大化 (Expectation-Maximization, EM) 算法的核心思想是“用已观测到的数据来估计缺失或潜在的数据”，从而简化对复杂似然函数的优化问题。当直接对观测数据的似然函数 $L(\theta; Y)$ 进行最大化非常困难时 (例如存在缺失数据或潜变量)，EM 算法通过引入一个“完整数据”的概念，将问题转化为对更易处理的“完整数据似然函数” $L(\theta; Y, W)$ 的迭代优化。

算法包含两个步骤：E 步 (Expectation step)，计算在当前参数估计下，缺失数据的条件期望；M 步 (Maximization step)，基于这个期望，最大化完整数据的对数似然函数。EM 算法保证每次迭代后，观测数据的似然值不会下降，最终收敛到局部最大值。它广泛应用于高斯混合模型、隐马尔可夫模型、生存分析等场景。

1 为什么需要 EM 算法？

1.1 定义：

- θ : 参数。
- Y : 已观测到的数据。
- W : 缺失/未观测到的数据 (潜变量)。

1.2 思路

当我们需要对似然函数作最大化时，可能很难直接最大化 $f(Y|\theta) = L(\theta; Y)$ (即观测似然函数)，但更容易最大化 $f(Y, W|\theta) = L(\theta; Y, W)$ (即完整似然函数)。

EM 算法本质上还是希望 $L(\theta; Y)$ 能取到最大 (即只用已观测到的数据)，只是借利用理想的用缺失/未观测数据来作简化计算。

1.3 例子：高斯混合模型

考虑一个高斯混合模型：

$$f(y|\theta) = \sum_{r=1}^P \pi_r \cdot f_r(y|\mu_r, \sigma_r^2)$$

(注意 π_r, μ_r, σ_r^2 都是参数)

此时观测似然函数为：

$$L(\theta; Y) = \prod_{j=1}^n f(y_j|\theta) = \prod_{j=1}^n \sum_{r=1}^P \pi_r f_r(y_j|\theta)$$

难以直接优化（我们习惯用 $\log$ 来处理似然函数，不希望其中有 σ 的形式）。

回顾生成高斯混合模型的过程：

- 1) 掷一个 P 面骰子，概率为 $\{\pi_r\}_{r=1}^P$ 。
- 2) 如果输出是 r ，则从 $f_r(\cdot|\mu_r, \sigma_r^2)$ 中采样。

参考以上过程：选择骰子的结果作为 W ，则 $P(W = r) = \pi_r$ 。

故：

$$\begin{aligned} f(y, w = r|\theta) &= f(y|w = r, \theta) f(w = r|\theta) \\ &= f(y|w = r, \theta) \cdot \pi_r \\ &= \pi_r f_r(y|\theta) \end{aligned}$$

因此，

$$f(y, w|\theta) = \prod_{r=1}^P \{\pi_r f_r(y|\theta)\}^{I\{w=r\}}$$

则完整似然函数为：

$$L(\theta; Y, W) = \prod_{j=1}^n f(y_j, w_j|\theta) = \prod_{j=1}^n \prod_{r=1}^P \{\pi_r f_r(y_j|\theta)\}^{I\{w_j=r\}}$$

更易于做优化。

2 EM 算法

2.1 流程

- **E-step:** 计算给定观测数据 Y 和当前参数估计 θ_{old} 时， $L(\theta; Y, W)$ 的期望值。

$$Q(\theta, \theta_{old}) \equiv \mathbb{E}_W[L(\theta; Y, W)|Y, \theta_{old}] = \int L(\theta; Y, W = r) P(W = r|Y, \theta_{old}), dr$$

跟平常不同的是我们在这里取了期望，用 Q 代替了 L 。

- **M-step:** 计算 $\theta_{new} = \arg \max_{\theta} Q(\theta, \theta_{old})$

迭代判断收敛的依据: $|L(\theta^{(t+1)}) - L(\theta^{(t)})|$ 或 $\frac{\|\theta^{(t+1)} - \theta^{(t)}\|}{\|\theta^{(t)}\|}$

2.2 继续前述高斯混合模型的例子

E-step: 给定 $Y = (y_1, \dots, y_n)$ ，一个 y_i 对应一个 w_i 。

定义：

$$Q(\theta, \theta^*) = \mathbb{E} [\log f(Y, W|\theta) | Y = y, \theta^*]$$

其中，条件分布 $W|(Y, \theta^*)$ 为：

$$P(W = r | Y = y, \theta^*) \propto f(W = r, Y = y | \theta^*)$$

我们知道

$$f(W = r, Y = y | \theta^*) = f(Y = y | W = r, \theta^*) P(W = r | \theta^*) = \pi_r^* f_r(y | \theta^*)$$

故：

$$P(W = r | Y = y, \theta^*) = \frac{\pi_r^* f_r(y | \theta^*)}{\sum_s \pi_s^* f_s(y | \theta^*)}$$

因此，

$$\begin{aligned} Q(\theta, \theta^*) &= \sum_{j=1}^n \mathbb{E} [\log f(y_j, w_j | \theta) | y_j, \theta^*] \\ &= \sum_{j=1}^n \sum_{r=1}^P \{\log \pi_r + \log f_r(y_j | \theta)\} P(w_j = r | y_j, \theta^*) \\ &= \underbrace{\sum_{r=1}^P \left\{ \sum_{j=1}^n P(w_j = r | y_j, \theta^*) \right\} \log \pi_r}_{\text{只跟 } \pi_r \text{ 有关}} + \underbrace{\sum_{r=1}^P \left\{ \sum_{j=1}^n P(w_j = r | y_j, \theta^*) \right\} \log f_r(y_j | \theta)}_{\text{只跟 } \mu_r, \sigma_r^2 \text{ 有关}} \end{aligned}$$

M-step:

$$\theta^{(t+1)} = \arg \max_{\theta} Q(\theta, \theta^{(t)})$$

(以下将 $P(w_j = r | y_j, \theta^*)$ 写作 $w_r(y_j, \theta^{(t)})$ 。)

对于参数 π_r, μ_r, σ_r^2 ：

- π_r :

$$\max_{\pi_r} \sum_{j=1}^n \sum_{r=1}^P w_r(y_j, \theta^{(t)}) \log \pi_r \quad \text{s.t.} \quad \sum_{r=1}^P \pi_r = 1$$

$$\Rightarrow \pi_r^{(t+1)} = \frac{1}{n} \sum_{j=1}^n w_r(y_j, \theta^{(t)})$$

(权重的平均)

- μ_r :

$$\mu_r^{(t+1)} = \frac{\sum_{j=1}^n w_r(y_j, \theta^{(t)}) y_j}{\sum_{j=1}^n w_r(y_j, \theta^{(t)})}$$

(y_j 的加权平均)

- σ_r^2 :

$$\sigma_r^{2(t+1)} = \frac{\sum_{j=1}^n w_r(y_j, \theta^{(t)}) (y_j - \mu_r^{(t+1)})^2}{\sum_{j=1}^n w_r(y_j, \theta^{(t)})}$$

(“方差” 的加权平均)

3 为什么 EM 算法是有效的?

考虑 $l(\theta; Y) = \log P(Y|\theta) = \log \int P(Y, W = r|\theta) dr$

要点:

- 1) 补全我们想要的式子。
- 2) 引入期望使引入合理。
- 3) 借 $\log$ 将除变减, 分离与 θ 无关的部分。

$$\begin{aligned} l(\theta; Y) &= \log \int \frac{P(Y, W = r|\theta)}{P(W = r|Y, \theta_{old})} P(W = r|Y, \theta_{old}) dr \\ &= \log \mathbb{E}_W \left[\frac{P(Y, W|\theta)}{P(W|Y, \theta_{old})} \mid Y, \theta_{old} \right] \\ &\geq \mathbb{E}_W \left[\log \left(\frac{P(Y, W|\theta)}{P(W|Y, \theta_{old})} \right) \mid Y, \theta_{old} \right] \quad (\text{由 Jensen 不等式}) \\ &= \mathbb{E}_W [\log P(Y, W|\theta) \mid Y, \theta_{old}] - \mathbb{E}_W [\log P(W|Y, \theta_{old}) \mid Y, \theta_{old}] \\ &= Q(\theta, \theta_{old}) - \underbrace{\mathbb{E} [\log P(W|Y, \theta_{old}) \mid Y, \theta_{old}]}_{\text{常数 (与}\theta\text{无关)}} \end{aligned}$$

同时

$$l(\theta_{old}; Y) = Q(\theta_{old}; \theta_{old}) - \mathbb{E}[\log P(W|Y, \theta_{old}) | Y, \theta_{old}]$$

故若 θ 使 $Q(\theta, \theta_{old}) > Q(\theta_{old}, \theta_{old})$, 则 $l(\theta; Y) > l(\theta_{old}; Y)$ 。

我们通过找最大化 $Q(\theta, \theta_{old})$ 的 θ 来满足这个条件。

可以看出上述证明说明了 EM 算法本质上还是在最大化 $l(\theta; Y)$, 只是通过引入一个潜变量来更好地计算。

4 案例：右删失数据 (Right censored data)

右删失：指删失水平 α 以下的数据可以正常观测， α 以上的数据观测值都为 α 。

从 $N(\theta, 1)$ 分布中采样 n 个独立同分布的样本，前 m 个被完全观测到，剩余 $n - m$ 个右删失了，水平为 a 。观察得到的数据为 $X = (x_1, \dots, x_m, a, \dots, a)$ 。

分析：

$$P(X \geq a) = P\left(\frac{X - \theta}{1} \geq a - \theta\right) = 1 - \Phi(a - \theta)$$

则观测似然函数为：

$$L(\theta; X) = \left(\frac{1}{\sqrt{2\pi}}\right)^m \exp\left\{-\frac{1}{2} \sum_{i=1}^m (x_i - \theta)^2\right\} (1 - \Phi(a - \theta))^{n-m}$$

难以直接做最大化。

EM 算法：

- 1) 采用潜变量 $Z = (z_{m+1}, \dots, z_n)$ 作为丢失的后 $n - m$ 个数据。

此时

$$L(\theta; X, Z) = \left(\frac{1}{\sqrt{2\pi}}\right)^n \exp\left\{-\frac{1}{2} \left[\sum_{i=1}^m (x_i - \theta)^2 + \sum_{j=m+1}^n (z_j - \theta)^2\right]\right\}$$

$$l(\theta; X, Z) = -\frac{n}{2} \log 2\pi - \frac{1}{2} \sum_{i=1}^m (x_i - \theta)^2 - \frac{1}{2} \sum_{j=m+1}^n (z_j - \theta)^2$$

- 2) 考察 $P(Z|X, \theta^*)$ (Z 与 X 前 m 个 i.i.d.)

$$f(z_j|x, \theta^*) = \frac{1}{1 - \Phi(a - \theta^*)} \cdot \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(z_j - \theta^*)^2}{2}\right), \quad z_j > a$$

- 3) $Q(\theta, \theta^*) = -\frac{n}{2} \log 2\pi - \frac{1}{2} \sum_{i=1}^m (x_i - \theta)^2 - \frac{1}{2} \sum_{j=m+1}^n \mathbb{E}[(z_j - \theta)^2 | x, \theta^*]$

4) $\max_{\theta} Q(\theta, \theta^*) \Rightarrow$ 求导:

$$\sum_{i=1}^m (x_i - \theta) + (n - m) \mathbb{E}(z_j | x, \theta^*) - (n - m)\theta = 0$$
$$\Rightarrow \theta = \frac{m}{n} \bar{X} + \frac{n - m}{n} \mathbb{E}(z_j | x, \theta^*)$$

5 迭代优化算法

5.1 Minorize-maximization / Majorize-minimization

Minorize-maximization: 每次迭代找到原非凸目标函数的一个上界函数, 求其最小值。

总目标: $\max_{\theta} f(\theta)$

用 $g(\theta | \theta^{(t)})$ 满足:

$$\begin{cases} 1) & g(\theta | \theta^{(t)}) \leq f(\theta), \quad \forall \theta, \\ 2) & g(\theta^{(t)} | \theta^{(t)}) = f(\theta^{(t)}). \end{cases}$$

替代 $f(\theta)$ 。

$$\text{令 } \theta^{(t+1)} = \arg \max_{\theta} g(\theta | \theta^{(t)}) \Rightarrow f(\theta^{(t+1)}) \geq g(\theta^{(t+1)} | \theta^{(t)}) \geq g(\theta^{(t)} | \theta^{(t)}) = f(\theta^{(t)})$$

6 EM 算法的性质

优势:

- 1) $l(\theta)$ 数值稳定, 不会减少。
- 2) 可以保证收敛到局部最大值。
- 3) M-step 存在解析解 $\iff$ E-step 可以简单地计算。
- 4) 与 Newton-Raphson 比较: 无需求导。

缺陷:

- 1) 缺少 $\text{cov}(\hat{\theta})$ 的信息。
- 2) 缓慢收敛。收敛速度取决于有多少信息是潜在的。
- 3) 有时 E-step 很难作估计, 需要 MC 近似, 此时 M-step 没有解析解。