

FDU 随机过程导论 1. 概率论回顾

本文根据王老师课堂笔记整理而成，并参考了以下教材：

- Introduction to Probability Models: Applied Stochastic Processes (S. Ross)
- 应用随机过程概率论模型导论 (S. Ross) 龚光鲁译 第 1, 2, 3 章
- 随机过程 (方兆本 & 缪柏其) 第 1 章
- 随机过程 (苏中根) 第 1 章

欢迎批评指正!

1.1 概率论基本概念

1.1.1 样本空间 (Sample Space) & 事件 (Event)

一个试验的所有可能结果的集合称为该试验的**样本空间** (sample space)，记为 Ω

样本空间 Ω 的任意子集 E 称为一个**事件** (event)，即部分可能结果的集合。

事件 E_1, E_2 的**并** (union) 记为 $E_1 \cup E_2$

事件 E_1, E_2 的**交** (intersection) 记为 $E_1 E_2$ (也记为 $E_1 \cap E_2$)

有 $\begin{cases} (E_1 \cup E_2) E_3 = (E_1 E_3) \cup (E_2 E_3) \\ (E_1 E_2) \cup E_3 = (E_1 \cup E_3)(E_2 \cup E_3) \end{cases}$ 成立。

不可能事件 (null event) 记为 $\emptyset$

若 $E_1 E_2 = \emptyset$ ，则我们称事件 E_1, E_2 **互不相容** (mutually exclusive)

事件 E 的**对立事件** (complement) 记为 E^c ，满足 $E \cup E^c = \Omega$

有 $\begin{cases} (E_1 \cup E_2)^c = E_1^c \cap E_2^c \\ (E_1 \cap E_2)^c = E_1^c \cup E_2^c \end{cases}$ 成立。

事件全体构成的集合称为**事件空间** (event space)，记为 $\mathcal{E} = \{E : E \subseteq \Omega\}$

它是样本空间 Ω 的一个 σ -代数，满足以下性质：

- $\emptyset, \Omega \in \mathcal{E}$
- 对于任意 $E \in \mathcal{E}$ ，都有 $E^c \in \mathcal{E}$ 成立
- 对于 $\mathcal{E}$ 中的任意序列 $E_1, E_2, \dots$ 都有 $\bigcup_{i=1}^{\infty} E_i \in \mathcal{E}$

σ -代数的上述性质确保了事件的交、并、补、差仍然留在事件空间 $\mathcal{E}$ 内。

1.1.2 定义在事件上的概率 (Probability)

考虑一个样本空间为 Ω 的**试验** (trial)

对于任意事件 $E \subseteq \Omega$ ，记其**概率**为 $P(E)$ ，它是 $\mathcal{E} \rightarrow [0, 1]$ 的函数，满足：

- **(规范性)** $\begin{cases} P(\emptyset) = 0 \\ P(\Omega) = 1 \\ 0 \leq P(E) \leq 1 \end{cases}$
- **(可列可加性)** 对于任意互不相容的事件序列 $\{E_i\}$ (即 $\forall i \neq j, E_i E_j = \emptyset$) 都有 $P(\bigcup_{i=1}^{\infty} E_i) = \sum_{i=1}^{\infty} P(E_i)$ 成立

我们还可以推出以下结果：

- 对于任意 $E \subseteq \Omega$ 都有 $\begin{cases} E \cup E^c = \Omega \\ P(\Omega) = 1 \end{cases}$ 成立，因此有 $P(E^c) = 1 - P(E)$ 成立
- **容斥原理 (Inclusion-Exclusion Principle):**
对于任意 n 个事件 $E_1, E_2, \dots, E_n \subseteq \Omega$ ，
都有 $P(\bigcup_{i=1}^n E_i) = \sum_{k=1}^n (-1)^{k+1} \sum_{1 \leq j_1 < j_2 < \dots < j_k \leq n} P(E_{j_1} E_{j_2} \dots E_{j_k})$ 成立。
特殊地，考虑 $n = 2$ 的情况：
对于任意 $E_1, E_2 \subseteq \Omega$ 都有 $P(E_1 \cup E_2) = P(E_1) + P(E_2) - P(E_1 E_2)$ 成立。
当且仅当 E_1, E_2 互不相容时 (i.e. $E_1 E_2 = \emptyset$)，
有 $P(E_1 \cup E_2) = P(E_1) + P(E_2)$ 成立。

- **次可加性 (Subadditivity):**

对于任意事件序列 $\{E_i\} \subseteq \Omega$ 都有 $P(\bigcup_{i=1}^{\infty} E_i) \leq \sum_{i=1}^{\infty} P(E_i)$

- **连续性 (Continuity):**

连续性保证了概率函数作为一个测度函数的合理性.

此外, 连续性在证明各种极限定理时是不可或缺的, 例如大数定律和中心极限定理.

- **上连续性:**

若有一个**单调递减**的事件序列 $\{E_n\} \subseteq \Omega$, 即 $E_{n+1} \subseteq E_n (\forall n \in \mathbb{N}_+)$,

并且其**交集**为 E (即 $\bigcap_{n=1}^{\infty} E_n = E$, 于是有 $\lim_{n \rightarrow \infty} E_n = E$),

则这个序列的概率趋于 E 的概率, 即有 $\lim_{n \rightarrow \infty} P(E_n) = P(\lim_{n \rightarrow \infty} E_n) = P(E)$

- **下连续性:**

若有一个**单调递增**的事件序列 $\{E_n\} \subseteq \Omega$, 即 $E_{n+1} \supseteq E_n (\forall n \in \mathbb{N}_+)$,

并且其**并集**为 E (即 $\bigcup_{n=1}^{\infty} E_n = E$, 于是有 $\lim_{n \rightarrow \infty} E_n = E$),

则这个序列的概率趋于 E 的概率, 即有 $\lim_{n \rightarrow \infty} P(E_n) = P(\lim_{n \rightarrow \infty} E_n) = P(E)$

这样我们就构造了一个**概率空间** $(\Omega, \mathcal{E}, P)$:

它由**样本空间** Ω 、**事件空间** $\mathcal{E} = \{E : E \subseteq \Omega\}$ 、**概率函数** $P : \mathcal{E} \rightarrow [0, 1]$ 构成.

1.1.3 条件概率 (Conditional Probability) & 事件的独立性

(I) 链式法则 (Chain Rule):

当且仅当 $P(E_2) > 0$ 时, 我们可以定义已知 E_2 发生的条件下 E_1 发生的**条件概率**,

记为 $P(E_1|E_2) = \frac{P(E_1 E_2)}{P(E_2)}$

由定义我们可以导出**链式法则**:

$$\begin{aligned} P(E_1 E_2) &= P(E_1)P(E_2|E_1) \\ &= P(E_2)P(E_1|E_2) \end{aligned}$$

其中 $P(E_1), P(E_2)$ 均大于 0.

链式法则的推广形式:

给定 n 个事件 $E_1, \dots, E_n \subseteq \Omega$, 若 $P(E_1), \dots, P(E_n)$ 均大于 0,

则有 $P(E_1 E_2 \cdots E_n) = P(E_1)P(E_2|E_1) \cdots P(E_n|E_1 E_2 \cdots E_{n-1})$

一个简单的例子:

假定盒中有 7 个黑球和 5 个白球, 不放回地摸取两个球, 这两个球都是黑球的概率是多少?

我们可以用 E_1, E_2 分别代表第 1, 2 次摸到的球是黑球的事件, 易知

$$\begin{cases} P(E_1) = \frac{7}{7+5} = \frac{7}{12} \\ P(E_2|E_1) = \frac{6}{6+5} = \frac{6}{11} \end{cases}$$

因此两次都摸到黑球的概率为

$$P(E_1 E_2) = P(E_1)P(E_2|E_1) = \frac{7}{12} \cdot \frac{6}{11} = \frac{7}{22}$$

(II) 全概率公式: (Law of Total Probability)

给定事件 $E_1, E_2 \subseteq \Omega$, 我们可以将 E_1 表示为:

$$\begin{aligned} E_1 &= E_1 \Omega \\ &= E_1 (E_2 \cup E_2^c) \\ &= (E_1 E_2) \cup (E_1 E_2^c) \end{aligned}$$

而事件 $E_1 E_2$ 和 $E_1 E_2^c$ 是不相容的, 因此有:

$$\begin{aligned} P(E_1) &= P(E_1 E_2) + P(E_1 E_2^c) \\ &= P(E_1|E_2)P(E_2) + P(E_1|E_2^c)P(E_2^c) \end{aligned}$$

全概率公式的推广形式:

若 $E_1, E_2, \dots, E_n \subseteq \Omega$ 是一个**完备事件组** (即这些事件互斥, 且并集为整个样本空间 i.e. $\begin{cases} E_i E_j = \emptyset, i \neq j, \\ \bigcup_{i=1}^n E_i = \Omega \end{cases}$),

则任意事件 $A \subseteq \Omega$ 的概率可以表示为 $P(A) = \sum_{i=1}^n P(A|E_i) \cdot P(E_i)$

(III) Bayes 公式:

结合链式法则和全概率公式可知:

若 $E_1, E_2, \dots, E_n \subseteq \Omega$ 是一个完备事件组,

则对于任意事件 $A \subseteq \Omega$ 都有:

$$\begin{aligned} P(E_i|A) &= \frac{P(AE_i)}{P(A)} \\ &= \frac{P(A|E_i)P(E_i)}{\sum_{j=1}^n P(A|E_j)P(E_j)} \quad (\forall i = 1, \dots, n) \end{aligned}$$

(IV) 事件的独立性:

若 $P(E_1 E_2) = P(E_1)P(E_2)$ (即有 $\begin{cases} P(E_1|E_2) = P(E_1) \\ P(E_2|E_1) = P(E_2) \end{cases}$),

则我们称事件 E_1, E_2 **相互独立** (independent)

也就是说, 事件 E_1 的发生独立于 E_2 是否发生, 反之亦然.

两两独立 (Pairwise Independent) $\nRightarrow$ **相互独立** (Mutually Independent) (又称联合独立, Jointly Independent)

即对于 n 个事件 $E_1, E_2, \dots, E_n \subseteq \Omega$,

$$P(E_i E_j) = P(E_i)P(E_j) \quad (\forall i \neq j) \nRightarrow \begin{cases} P(E_i E_j) = P(E_i)P(E_j) & (\forall i < j) \\ P(E_i E_j E_k) = P(E_i)P(E_j)P(E_k) & (\forall i < j < k) \\ \dots \\ P(E_{i_1} E_{i_2} \dots E_{i_{n-1}}) = P(E_{i_1})P(E_{i_2}) \dots P(E_{i_{n-1}}) & (\forall i_1 < i_2 < \dots < i_{n-1}) \\ P(\bigcap_{i=1}^n E_i) = \prod_{i=1}^n P(E_i) \end{cases}$$

这样的例子很好构造:

考虑事件 $\begin{cases} E_1 = \{1, 2\} \\ E_2 = \{1, 3\} \\ E_3 = \{1, 4\} \end{cases}$ 则有 $\begin{cases} P(E_1 E_2) = \frac{1}{4} = P(E_1)P(E_2) \\ P(E_1 E_3) = \frac{1}{4} = P(E_1)P(E_3) \\ P(E_2 E_3) = \frac{1}{4} = P(E_2)P(E_3) \end{cases}$

然而 $\frac{1}{4} = P(E_1 E_2 E_3) \neq P(E_1)P(E_2)P(E_3) = \frac{1}{8}$, 说明联合不独立.

1.2 随机变量

在进行统计试验时, 相较于试验结果本身, 我们其实对试验结果的某些函数更感兴趣.

例如, 在掷骰子时, 我们可能更关心两颗骰子的点数和, 而不关心其实际结果.

我们所关注的这些量, 或者更确切地, 这些定义在样本空间上的实值函数, 称为**随机变量** (random variable, r.v.).

由于随机变量的值由试验结果确定, 因此我们可以给随机变量的可能取值指定**概率**.

若随机变量可能取值的个数是**可数的** (countable), 则我们称之为**离散随机变量** (discrete r.v.)

若随机变量的取值范围由**若干个连续区间**构成, 则我们称之为**连续随机变量** (continuous r.v.)

理论上还存在混合随机变量, 我们不作讨论.

随机变量 X 的**累计分布函数** (CDF, Cumulative Distribution Function) 记为 $F(\cdot)$,

定义为 $\begin{cases} F(x) = P(X \leq x) \\ \text{dom}(F) = \mathbb{R} \end{cases}$

具有以下性质:

- ① 在 $\mathbb{R}$ 上非严格单调递增;
- ② $\begin{cases} \sup_{x \in \mathbb{R}} F(x) = 1 \\ \inf_{x \in \mathbb{R}} F(x) = 0 \end{cases}$ (上确界、下确界分别为 0, 1)

1.2.1 离散随机变量 (Discrete r.v.)

离散随机变量 X 的**概率质量函数** (PMF, Probability Mass Function) 记为 $\text{pmf}(\cdot)$,

定义为 $\begin{cases} \text{pmf}(x) = P(X = x) \\ \text{dom}(\text{pmf}) = \mathbb{R} \end{cases}$

若记 X 的可数个取值为 $x_1, x_2, \dots$,

则 $\text{pmf}(x) \begin{cases} > 0, & \text{if } x = x_i \text{ for some } i \\ = 0, & \text{otherwise} \end{cases}$, 且有 $\sum_{i=1}^{\infty} \text{pmf}(x_i) = 1$ 成立.

而累积分布函数也可以表示为 $F(x) = \sum_{\text{for all } x_i \leq x} \text{pmf}(x_i)$

容易想象到累计分布函数 $F(\cdot)$ 的图像是呈**阶梯状**的.

离散随机变量通常依据概率质量函数分类:

- (I) Bernoulli 随机变量 (二项随机变量的特例)

$X = \begin{cases} 1, & \text{if succeeded} \\ 0, & \text{if failed} \end{cases} \sim B(1, p)$ 代表单次试验的成功次数, 成功概率为 p

其概率质量函数的唯二有效取值为 $\begin{cases} \text{pmf}(1) = p \\ \text{pmf}(0) = 1 - p \end{cases}$

- (II) 二项随机变量 (Binomial r.v.)

若 X 代表 n 次独立试验的成功次数, 每次试验的成功概率均为 p

则称 X 为具有参数 (n, p) 的二项随机变量, 记为 $X \sim B(n, p)$

其概率质量函数的 $n+1$ 个取值为 $\text{pmf}(i) = \binom{n}{i} p^i (1-p)^{n-i} \quad (i = 0, 1, \dots, n)$

其中组合数 $\binom{n}{i} = \frac{n!}{(n-i)!i!}$

根据二项式定理 (Binomial Theorem) $(a+b)^n = \sum_{i=0}^n \binom{n}{i} a^i b^{n-i}$ 可知

$$\begin{aligned} \sum_{i=0}^n \text{pmf}(i) &= \sum_{i=0}^n \binom{n}{i} p^i (1-p)^{n-i} \\ &= [p + (1-p)]^n \\ &= 1 \end{aligned}$$

这与概率质量函数的性质相符.

- (III) 几何随机变量 (Geometric r.v.)

若 X 代表一系列独立试验首次成功所需的试验次数, 每次试验的成功概率均为 p ,

则称 X 为具有参数 p 的几何随机变量, 记为 $X \sim \text{Geo}(p)$

其概率质量函数的取值为 $\text{pmf}(i) = (1-p)^{i-1} p \quad (i = 1, 2, \dots)$

(前 $i-1$ 次失败, 第 i 次成功)

注意到:

$$\begin{aligned} \sum_{i=1}^{\infty} \text{pmf}(i) &= \sum_{i=1}^{\infty} (1-p)^{i-1} p \\ &= p \sum_{i=1}^{\infty} (1-p)^{i-1} \\ &= p \cdot \frac{1}{1 - (1-p)} \\ &= 1 \end{aligned}$$

这与概率质量函数的性质相符.

- (IV) Poisson 随机变量

对于取值于自然数集 $\mathbb{N}$ 的离散随机变量 X ,

若对于某个 $\lambda > 0$ 有 $\text{pmf}(i) = P(X=i) = e^{-\lambda} \frac{\lambda^i}{i!} \quad (i = 0, 1, \dots)$ 成立,

则称 X 为具有参数 λ 的 Poisson 随机变量, 记为 $X \sim \text{Poisson}(\lambda)$

注意到:

$$\begin{aligned} \sum_{i=1}^{\infty} \text{pmf}(i) &= \sum_{i=1}^{\infty} e^{-\lambda} \frac{\lambda^i}{i!} \\ &= e^{-\lambda} \sum_{i=1}^{\infty} \frac{\lambda^i}{i!} \\ &= e^{-\lambda} e^{\lambda} \\ &= 1 \end{aligned}$$

这与概率质量函数的性质相符.

Poisson 随机变量可用于近似 n 很大而 p 很小的二项随机变量.

设 $X \sim B(n, p)$, 定义参数 $\lambda := np$, 则有:

$$\begin{aligned} \text{pmf}(i) &= P(X=i) \\ &= \binom{n}{i} p^i (1-p)^{n-i} \\ &= \frac{n!}{i!(n-i)!} \left(\frac{\lambda}{n}\right)^i \left(1 - \frac{\lambda}{n}\right)^{n-i} \\ &= \frac{n(n-1)\cdots(n-i+1)}{n^i} \cdot \frac{\lambda^i}{i!} \left(1 - \frac{\lambda}{n}\right)^n \left(1 - \frac{\lambda}{n}\right)^{-i} \end{aligned}$$

假设 n 很大而 $p = \lambda/n$ 很小, 则有:

$$\begin{cases} \frac{n(n-1)\cdots(n-i+1)}{n^i} \approx 1 \\ (1 - \frac{\lambda}{n})^n \approx e^{-\lambda} \\ (1 - \frac{\lambda}{n})^i \approx 1 \end{cases}$$

于是有 $\text{pmf}(i) \approx e^{-\lambda} \frac{\lambda^i}{i!}$

说明在 n 很大而 p 很小时, 二项分布 $B(n, p) \approx \text{Poisson}(np)$, 这是一个非常重要的结论.

一个简单的例子:

假定 1 克放射性物质平均每秒裂变产生 3.2 个 α 粒子,

则任意一秒中这 1 克放射性物质产生 α 粒子的个数不超过 2 个的近似概率是多少?

应用刚才的结论, 我们可以认为这 1 克放射性物质每秒产生 α 粒子的数量 $X \sim \text{Poisson}(3.2)$

因此我们有:

$$\begin{aligned} P(X \leq 2) &= P(X = 0) + P(X = 1) + P(X = 2) \\ &= e^{-3.2} \left(1 + 3.2 + \frac{(3.2)^2}{2} \right) \\ &\approx 0.380 \end{aligned}$$

说明任意一秒释放的 α 粒子的个数不超过 2 个的近似概率是 38.0%.

1.2.2 连续随机变量 (Continuous r.v.)

连续随机变量 X 的**概率密度函数** (PDF, Probability Density Function) 记为 $f(\cdot)$,

定义为 $\begin{cases} f(x) = \frac{d}{dx} F(x) \\ \text{dom}(f) = \mathbb{R} \end{cases}$,

它满足:

- ① **非负性** (Non-negativity): $\forall x \in \mathbb{R}, f(x) \geq 0$
- ② **归一性** (Normalized): $\int_{-\infty}^{+\infty} f(x)dx = \lim_{x \rightarrow +\infty} F(x) = 1$

关于连续随机变量 X 的所有概率陈述都能被 $f(\cdot)$ 回答,

具体来说, 对于任意区间 $I \subseteq \mathbb{R}$, 都有 $P(X \in I) = \int_{x \in I} f(x)dx$

特别地, 对于足够小的 $\varepsilon > 0$ 和任意 $x_0 \in \mathbb{R}$,

都有 $P(X \in [x_0 - \frac{\varepsilon}{2}, x_0 + \frac{\varepsilon}{2}]) = \int_{x_0 - \frac{\varepsilon}{2}}^{x_0 + \frac{\varepsilon}{2}} f(x)dx \approx \varepsilon f(x_0)$

从中我们可以看出 $f(x_0)$ 是随机变量 X 在 x_0 附近可能性大小的某种 "密度".

连续随机变量通常依据概率密度函数分类:

- (I) **均匀随机变量 (Uniform r.v.)**

若 X 的概率密度函数给定为 $f(x) = \begin{cases} \frac{1}{b-a}, & \text{if } a < x < b \\ 0, & \text{otherwise} \end{cases}$

则称 X 的区间 (a, b) 上的均匀随机变量, 记为 $X \sim \text{Uniform}(a, b)$

其累计分布函数为 $F(x) = \begin{cases} 0, & x \leq a \\ \frac{x-a}{b-a}, & a < x < b \\ 1, & x \geq b \end{cases}$

- (II) **Gamma 随机变量**

定义 **Gamma 函数** 为 $\begin{cases} \Gamma(\alpha) = \int_0^{+\infty} e^{-t} t^{\alpha-1} dt \\ \text{dom}(\Gamma) = \{\alpha \in \mathbb{C} : \text{Re}(\alpha) > 0\} \end{cases}$

(特殊地, 对于任意整数 n 有 $\Gamma(n) = (n-1)!$ 成立, 实际上 Γ 函数是阶乘函数在实数域和复数域上的推广)

若对于某对 $\alpha, \lambda > 0$ 有 $\begin{cases} \frac{\lambda e^{-\lambda x} (\lambda x)^{\alpha-1}}{\Gamma(\alpha)}, & x \geq 0 \\ 0, & \text{otherwise} \end{cases}$ 成立

则称 X 为具有参数 (α, λ) 的 Gamma 随机变量, 记为 $X \sim \text{Gamma}(\alpha, \lambda)$

它没有解析形式的累计分布函数.

- (III) **指数随机变量 (Exponential r.v.) (Gamma 随机变量的特例)**

若对于某个 $\lambda > 0$ 有 $f(x) = \begin{cases} \lambda e^{-\lambda x}, & x \geq 0 \\ 0, & \text{otherwise} \end{cases}$ 成立

则称 X 为具有参数 λ 的指数随机变量, 记为 $X \sim \exp(\lambda) = \text{Gamma}(1, \lambda)$

其累计分布函数为 $F(x) = \int_{-\infty}^x f(t)dt = \begin{cases} 1 - e^{-\lambda x}, & x \geq 0 \\ 0, & \text{otherwise} \end{cases}$

- (IV) 正态随机变量 (Normal r.v.)

若对于某组 $\begin{cases} \mu \in \mathbb{R} \\ \sigma^2 > 0 \end{cases}$ 有 $f(x) = \frac{1}{\sqrt{2\pi\sigma}} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\}$ ($\forall x \in \mathbb{R}$) 成立,

则称 X 为具有参数 (μ, σ^2) 的正态随机变量, 记为 $X \sim N(\mu, \sigma^2)$

它没有解析形式的累计分布函数.

一个非常重要的性质是:

X 的线性变换 $\alpha X + \beta$ 也是正态随机变量, 满足 $(\alpha X + \beta) \sim N(\alpha\mu + \beta, \alpha^2\sigma^2)$

后面我们还会介绍这一结论的推广: **多元正态随机变量的线性变换也是多元正态的.**

- (V) 卡方随机变量 (Chi-Squared r.v.) (Gamma 随机变量的特例)

若对于某一 $k \in \mathbb{N}_+$ 有 $f(x) = \begin{cases} \frac{e^{-x/2} x^{k/2-1}}{2^{k/2} \Gamma(k/2)}, & x \geq 0 \\ 0, & \text{otherwise} \end{cases}$ 成立,

则称 X 为具有自由度 k 的卡方随机变量, 记为 $X \sim \chi^2(k) = \text{Gamma}(\frac{k}{2}, \frac{1}{2})$

它没有解析形式的累计分布函数.

一个非常重要的性质是:

自由度为 k 的卡方随机变量是 k 个相互独立的标准正态随机变量的平方和.

1.2.3 期望 (Expectation)

(I) 离散情形

若 X 是具有概率质量函数 $\text{pmf}(\cdot)$ 的离散随机变量,

则 X 的期望为 $E(X) = \sum_{x: \text{pmf}(x) > 0} x \cdot \text{pmf}(x)$

让我们来计算典型的离散随机变量的期望:

- ① Bernoulli 随机变量 (二项随机变量的特例)

$X \sim B(1, p)$ 有 $\begin{cases} \text{pmf}(1) = p \\ \text{pmf}(0) = 1 - p \end{cases}$

于是 $E(X) = 0(1 - p) + 1(p) = p$

- ② 二项随机变量 (Binomial r.v.)

$X \sim B(n, p)$ 有 $\text{pmf}(i) = \binom{n}{i} p^i (1 - p)^{n-i}$ ($i = 0, 1, \dots, n$)

于是:

$$\begin{aligned} E(X) &= \sum_{i=0}^n i \cdot \text{pmf}(i) \\ &= \sum_{i=1}^n i \cdot \binom{n}{i} p^i (1 - p)^{n-i} \\ &= \sum_{i=1}^n i \cdot \frac{n!}{i!(n-i)!} p^i (1 - p)^{n-i} \\ &= \sum_{i=1}^n \frac{n!}{(i-1)!(n-i)!} p^i (1 - p)^{n-i} \\ &= np \cdot \sum_{i=1}^n \frac{(n-1)!}{(i-1)!(n-i)!} p^{i-1} (1 - p)^{n-i} \\ &= np \cdot \sum_{k=0}^{n-1} \frac{(n-1)!}{k!(n-1-k)!} p^k (1 - p)^{n-1-k} \\ &= np \cdot \sum_{k=0}^{n-1} \binom{n-1}{k} p^k (1 - p)^{n-1-k} \\ &= np \cdot [p + (1 - p)]^{n-1} \\ &= np \end{aligned}$$

- ③ 几何随机变量 (Geometric r.v.)

$X \sim \text{Geo}(p)$ 有 $\text{pmf}(i) = (1 - p)^{i-1} p$ ($i = 1, 2, \dots$)

于是:

$$\begin{aligned}
E(X) &= \sum_{i=1}^{\infty} i \cdot \text{pmf}(i) \\
&= \sum_{i=1}^{\infty} i \cdot (1-p)^{i-1} p \\
&= p \sum_{i=1}^{\infty} i \cdot q^{i-1} \quad (q := 1-p) \\
&= p \sum_{i=1}^{\infty} \frac{d}{dq}(q^i) \\
&= p \frac{d}{dq} \left(\sum_{i=1}^{\infty} q^i \right) \\
&= p \frac{d}{dq} \left(\frac{q}{1-q} \right) \\
&= \frac{p}{(1-q)^2} \\
&= \frac{1}{p}
\end{aligned}$$

• ④ Poisson 随机变量

$X \sim \text{Poisson}(\lambda)$ 有 $\text{pmf}(i) = e^{-\lambda} \frac{\lambda^i}{i!}$ ($i = 0, 1, \dots$)

于是:

$$\begin{aligned}
E(X) &= \sum_{i=1}^{\infty} i \cdot \text{pmf}(i) \\
&= \sum_{i=1}^{\infty} i \cdot e^{-\lambda} \frac{\lambda^i}{i!} \\
&= \sum_{i=1}^{\infty} e^{-\lambda} \frac{\lambda^i}{(i-1)!} \\
&= \lambda e^{-\lambda} \sum_{i=1}^{\infty} \frac{\lambda^{i-1}}{(i-1)!} \\
&= \lambda e^{-\lambda} \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} \\
&= \lambda e^{-\lambda} e^{\lambda} \\
&= \lambda
\end{aligned}$$

(II) 连续情形

若 X 是具有概率密度函数 $f(x)$ 的连续随机变量,

则 X 的期望为 $E(X) = \int_{-\infty}^{\infty} x f(x) dx$

让我们来计算典型的连续随机变量的期望:

• ① 均匀随机变量 (Uniform r.v.)

$X \sim \text{Uniform}(a, b)$ 有 $f(x) = \begin{cases} \frac{1}{b-a}, & \text{if } a < x < b \\ 0, & \text{otherwise} \end{cases}$

于是:

$$\begin{aligned}
E(X) &= \int_{-\infty}^{\infty} x f(x) dx \\
&= \int_a^b x \cdot \frac{1}{b-a} dx \\
&= \frac{1}{b-a} \cdot \frac{b^2 - a^2}{2} \\
&= \frac{a+b}{2}
\end{aligned}$$

• ② 指数随机变量 (Exponential r.v.) (Gamma 随机变量的特例)

$X \sim \exp(\lambda) = \text{Gamma}(1, \lambda)$ 有 $f(x) = \begin{cases} \lambda e^{-\lambda x}, & x \geq 0 \\ 0, & \text{otherwise} \end{cases}$

于是:

$$\begin{aligned}
E(X) &= \int_{-\infty}^{\infty} x f(x) dx \\
&= \int_0^{\infty} x \cdot \lambda e^{-\lambda x} dx \\
&= -x e^{-\lambda x} \Big|_0^{\infty} - \int_0^{\infty} (-e^{-\lambda x}) dx \\
&= 0 - \frac{e^{-\lambda x}}{\lambda} \Big|_0^{\infty} \\
&= \frac{1}{\lambda}
\end{aligned}$$

(一般形式 Gamma 随机变量的期望公式参见 ④)

• ③ 正态随机变量 (Normal r.v.)

$X \sim N(\mu, \sigma^2)$ 有 $f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\{-\frac{(x-\mu)^2}{2\sigma^2}\}$ ($\forall x \in \mathbb{R}$)

于是:

$$\begin{aligned}
E(X) &= \int_{-\infty}^{\infty} x f(x) dx \\
&= \int_{-\infty}^{\infty} x \cdot \frac{1}{\sqrt{2\pi}\sigma} \exp\{-\frac{(x-\mu)^2}{2\sigma^2}\} dx \\
&= \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^{\infty} (x-\mu) \exp\{-\frac{(x-\mu)^2}{2\sigma^2}\} dx + \mu \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}\sigma} \exp\{-\frac{(x-\mu)^2}{2\sigma^2}\} dx \\
&= \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^{\infty} y \exp\{-\frac{y^2}{2\sigma^2}\} dy + \mu \int_{-\infty}^{\infty} f(x) dx \quad (y := x - \mu) \\
&= 0 + \mu \cdot 1 \\
&= \mu
\end{aligned}$$

• ④ Gamma 随机变量

$X \sim \text{Gamma}(\alpha, \lambda)$ 有 $f(x) = \begin{cases} \frac{\lambda e^{-\lambda x} (\lambda x)^{\alpha-1}}{\Gamma(\alpha)}, & x \geq 0 \\ 0, & \text{otherwise} \end{cases}$

于是:

$$\begin{aligned}
E(X) &= \int_{-\infty}^{\infty} x f(x) dx \\
&= \int_0^{\infty} x \cdot \frac{\lambda e^{-\lambda x} (\lambda x)^{\alpha-1}}{\Gamma(\alpha)} dx \\
&= \frac{\Gamma(\alpha+1)}{\lambda \Gamma(\alpha)} \int_0^{\infty} \frac{\lambda e^{-\lambda x} (\lambda x)^{\alpha}}{\Gamma(\alpha+1)} dx \\
&= \frac{\Gamma(\alpha+1)}{\lambda \Gamma(\alpha)} \int_0^{\infty} P\{\text{Gamma}(\alpha+1, \lambda) = x\} dx \\
&= \frac{\alpha \Gamma(\alpha)}{\lambda \Gamma(\alpha)} \cdot 1 \\
&= \frac{\alpha}{\lambda}
\end{aligned}$$

• ⑤ 卡方随机变量 (Chi-Squared r.v.) (Gamma 随机变量的特例)

$X \sim \chi^2(k) = \text{Gamma}(\frac{k}{2}, \frac{1}{2})$ 有 $f(x) = \begin{cases} \frac{e^{-x/2} x^{k/2-1}}{2^{k/2} \Gamma(k/2)}, & x \geq 0 \\ 0, & \text{otherwise} \end{cases}$

根据 ④ 的结论可知 $E(X) = \frac{k/2}{1/2} = k$

(III) 推广形式

我们不禁要问: 随机变量 X 的函数 $g(X)$ 的期望如何计算呢?

注意到 $g(X)$ 本身也是一个随机变量, 它必然服从一个概率分布,

如果我们能根据 X 的分布导出 $g(X)$ 的分布, 我们就能根据定义计算 $E[g(X)]$

这种方法我们就不赘述了, 因为我们有一个更容易的方法, 无需确定 $g(X)$ 的分布就能计算期望.

• ③ 离散情况:

若 X 是具有概率质量函数 $\text{pmf}(x)$ 的离散随机变量,

则对于任意实值函数 g 都有 $E[g(X)] = \sum_{x:p(x)>0} g(x)\text{pmf}(x)$ 成立.

- ② 连续情况:

若 X 是具有概率密度函数 $f(x)$ 的连续随机变量,
则对于任意实值函数 g 都有 $\mathbb{E}[g(X)] = \int_{-\infty}^{\infty} g(x)f(x)dx$ 成立.

推论: $\mathbb{E}(\alpha X + \beta) = \alpha \mathbb{E}(X) + \beta$

1.2.4 方差 (Variance)

随机变量 X 的方差定义为:

$$\begin{aligned}\text{Var}(X) &:= \mathbb{E}[(X - \mathbb{E}(X))^2] \\ &= \mathbb{E}[X^2 - 2\mathbb{E}(X)X + (\mathbb{E}(X))^2] \\ &= \mathbb{E}(X^2) - 2(\mathbb{E}(X))^2 + (\mathbb{E}(X))^2 \\ &= \mathbb{E}(X^2) - (\mathbb{E}(X))^2\end{aligned}$$

(I) 离散情形

- ① Bernoulli 随机变量 (二项随机变量的特例)

$X \sim B(1, p)$ 有 $\begin{cases} \text{pmf}(1) = p \\ \text{pmf}(0) = 1 - p \end{cases}$ 且 $\mathbb{E}(X) = p$

而 $\mathbb{E}(X^2) = 0^2(1 - p) + 1^2(p) = p$

因此:

$$\begin{aligned}\text{Var}(X) &= \mathbb{E}(X^2) - (\mathbb{E}(X))^2 \\ &= p - p^2 \\ &= p(1 - p)\end{aligned}$$

- ② 二项随机变量 (Binomial r.v.)

$X \sim B(n, p)$ 有 $\text{pmf}(i) = \binom{n}{i} p^i (1 - p)^{n-i}$ ($i = 0, 1, \dots, n$) 且 $\mathbb{E}(X) = np$

注意到:

$$\begin{aligned}\mathbb{E}(X^2) &= \sum_{i=0}^n i^2 \cdot \text{pmf}(i) \\ &= \sum_{i=1}^n i^2 \cdot \binom{n}{i} p^i (1 - p)^{n-i} \\ &= \sum_{i=2}^n i(i-1) \cdot \frac{n!}{i!(n-i)!} p^i (1 - p)^{n-i} + \sum_{i=1}^n i \cdot \frac{n!}{i!(n-i)!} p^i (1 - p)^{n-i} \\ &= \sum_{i=2}^n \frac{n!}{(i-2)!(n-i)!} p^i (1 - p)^{n-i} + \mathbb{E}(X) \\ &= n(n-1)p^2 \cdot \sum_{i=2}^n \frac{(n-2)!}{(i-2)!(n-i)!} p^{i-2} (1 - p)^{n-i} + np \\ &= n(n-1)p^2 \cdot \sum_{k=2}^n \frac{(n-2)!}{k!(n-2-k)!} p^k (1 - p)^{n-2-k} + np \\ &= n(n-1)p^2 \cdot (p + (1 - p))^{n-2} + np \\ &= n(n-1)p^2 + np\end{aligned}$$

因此:

$$\begin{aligned}\text{Var}(X) &= \mathbb{E}(X^2) - (\mathbb{E}(X))^2 \\ &= n(n-1)p^2 + np - (np)^2 \\ &= np(1 - p)\end{aligned}$$

- ③ 几何随机变量 (Geometric r.v.)

$X \sim \text{Geo}(p)$ 有 $\text{pmf}(i) = (1 - p)^{i-1} p$ ($i = 1, 2, \dots$) 而 $\mathbb{E}(X) = \frac{1}{p}$

注意到:

$$\begin{aligned}
E(X^2) &= \sum_{i=1}^{\infty} i^2 \cdot \text{pmf}(i) \\
&= \sum_{i=1}^{\infty} i^2 \cdot (1-p)^{i-1} p \\
&= p \sum_{i=1}^{\infty} [(i+1)i - i] \cdot q^{i-1} \quad (q := 1-p) \\
&= p \sum_{i=1}^{\infty} \frac{d^2}{dq^2} (q^{i+1}) - p \sum_{i=1}^{\infty} i q^{i-1} \\
&= p \frac{d^2}{dq^2} \left(\sum_{i=1}^{\infty} q^{i+1} \right) - \sum_{i=1}^{\infty} i (1-p)^{i-1} p \\
&= p \frac{d^2}{dq^2} \left(\frac{q}{1-q} \right) - E(X) \\
&= \frac{2p}{(1-q)^3} - \frac{1}{p} \\
&= \frac{2}{p^2} - \frac{1}{p}
\end{aligned}$$

因此:

$$\begin{aligned}
\text{Var}(X) &= E(X^2) - (E(X))^2 \\
&= \frac{2}{p^2} - \frac{1}{p} - \left(\frac{1}{p} \right)^2 \\
&= \frac{1}{p^2} - \frac{1}{p} \\
&= \frac{1-p}{p^2}
\end{aligned}$$

• ④ Poisson 随机变量

$X \sim \text{Poisson}(\lambda)$ 有 $\text{pmf}(i) = e^{-\lambda} \frac{\lambda^i}{i!}$ ($i = 0, 1, \dots$) 且 $E(X) = \lambda$

注意到:

$$\begin{aligned}
E(X^2) &= \sum_{i=1}^{\infty} i^2 \cdot \text{pmf}(i) \\
&= \sum_{i=1}^{\infty} i^2 \cdot e^{-\lambda} \frac{\lambda^i}{i!} \\
&= \sum_{i=2}^{\infty} i(i-1) \cdot e^{-\lambda} \frac{\lambda^i}{i!} + \sum_{i=1}^{\infty} i \cdot e^{-\lambda} \frac{\lambda^i}{i!} \\
&= \lambda^2 e^{-\lambda} \sum_{i=2}^{\infty} \frac{\lambda^{i-2}}{(i-2)!} + E(X) \\
&= \lambda^2 e^{-\lambda} \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} + \lambda \\
&= \lambda^2 e^{-\lambda} e^{\lambda} + \lambda \\
&= \lambda^2 + \lambda
\end{aligned}$$

因此:

$$\begin{aligned}
\text{Var}(X) &= E(X^2) - (E(X))^2 \\
&= \lambda^2 + \lambda - \lambda^2 \\
&= \lambda
\end{aligned}$$

(II) 连续情形

• ① 均匀随机变量 (Uniform r.v.)

$X \sim \text{Uniform}(a, b)$ 有 $f(x) = \begin{cases} \frac{1}{b-a}, & \text{if } a < x < b \\ 0, & \text{otherwise} \end{cases}$ 且 $E(X) = \frac{a+b}{2}$

注意到:

$$\begin{aligned}
E(X^2) &= \int_{-\infty}^{\infty} x^2 f(x) dx \\
&= \int_a^b x^2 \cdot \frac{1}{b-a} dx \\
&= \frac{1}{b-a} \cdot \frac{b^3 - a^3}{3} \\
&= \frac{a^2 + ab + b^2}{3}
\end{aligned}$$

因此:

$$\begin{aligned}
\text{Var}(X) &= E(X^2) - (E(X))^2 \\
&= \frac{a^2 + ab + b^2}{3} - \left(\frac{a+b}{2}\right)^2 \\
&= \frac{(a-b)^2}{12}
\end{aligned}$$

- ② 指数随机变量 (Exponential r.v.) (Gamma 随机变量的特例)

$$X \sim \exp(\lambda) = \text{Gamma}(1, \lambda) \text{ 有 } f(x) = \begin{cases} \lambda e^{-\lambda x}, & x \geq 0 \\ 0, & \text{otherwise} \end{cases} \text{ 且 } E(X) = \frac{1}{\lambda}$$

注意到:

$$\begin{aligned}
E(X^2) &= \int_{-\infty}^{\infty} x^2 f(x) dx \\
&= \int_0^{\infty} x^2 \cdot \lambda e^{-\lambda x} dx \\
&= -x^2 e^{-\lambda x} \Big|_0^{\infty} - \int_0^{\infty} (-2x e^{-\lambda x}) dx \\
&= 0 + \frac{2}{\lambda} \cdot \int_0^{\infty} x \cdot \lambda e^{-\lambda x} dx \\
&= \frac{2}{\lambda} \cdot E(X) \\
&= \frac{2}{\lambda} \cdot \frac{1}{\lambda} \\
&= \frac{2}{\lambda^2}
\end{aligned}$$

因此:

$$\begin{aligned}
\text{Var}(X) &= E(X^2) - (E(X))^2 \\
&= \frac{2}{\lambda^2} - \left(\frac{1}{\lambda}\right)^2 \\
&= \frac{1}{\lambda^2}
\end{aligned}$$

(一般形式 Gamma 随机变量的方差公式参见 ④)

- ③ 正态随机变量 (Normal r.v.)

$$X \sim N(\mu, \sigma^2) \text{ 有 } f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\} \quad (\forall x \in \mathbb{R}) \text{ 且 } E(X) = \mu$$

注意到:

$$\begin{aligned}
\text{Var}(X) &= E[(X - E(X))^2] \\
&= E[(X - \mu)^2] \\
&= \int_{-\infty}^{\infty} (x - \mu)^2 \cdot \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{(x - \mu)^2}{2\sigma^2}\right\} dx \\
&= \frac{\sigma^2}{\sqrt{2\pi}} \int_{-\infty}^{\infty} y^2 \exp\left\{-\frac{y^2}{2}\right\} dy \quad (y := \frac{x - \mu}{\sigma}) \\
&= \frac{\sigma^2}{\sqrt{2\pi}} \left\{ -y \exp\left\{-\frac{y^2}{2}\right\} \Big|_{-\infty}^{\infty} - \int_{-\infty}^{\infty} (-\exp\left\{-\frac{y^2}{2}\right\}) dy \right\} \\
&= \frac{\sigma^2}{\sqrt{2\pi}} \left\{ 0 + \sqrt{2\pi} \cdot \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} \exp\left\{-\frac{y^2}{2}\right\} dy \right\} \\
&= \frac{\sigma^2}{\sqrt{2\pi}} \cdot \sqrt{2\pi} \\
&= \sigma^2
\end{aligned}$$

于是我们反过来可以知道:

$$\begin{aligned}\mathbb{E}(X^2) &= \text{Var}(X) + (\mathbb{E}(X))^2 \\ &= \sigma^2 + \mu^2\end{aligned}$$

• ④ Gamma 随机变量

$$X \sim \text{Gamma}(\alpha, \lambda) \text{ 有 } f(x) = \begin{cases} \frac{\lambda e^{-\lambda x} (\lambda x)^{\alpha-1}}{\Gamma(\alpha)}, & x \geq 0 \\ 0, & \text{otherwise} \end{cases} \quad \text{且 } \mathbb{E}(X) = \frac{\alpha}{\lambda}$$

注意到:

$$\begin{aligned}\mathbb{E}(X^2) &= \int_{-\infty}^{\infty} x^2 f(x) dx \\ &= \int_0^{\infty} x^2 \cdot \frac{\lambda e^{-\lambda x} (\lambda x)^{\alpha-1}}{\Gamma(\alpha)} dx \\ &= \frac{\Gamma(\alpha+2)}{\lambda^2 \Gamma(\alpha)} \int_0^{\infty} \frac{\lambda e^{-\lambda x} (\lambda x)^{\alpha+1}}{\Gamma(\alpha+2)} dx \\ &= \frac{\Gamma(\alpha+2)}{\lambda^2 \Gamma(\alpha)} \int_0^{\infty} \text{P}\{\text{Gamma}(\alpha+2, \lambda) = x\} dx \\ &= \frac{\Gamma(\alpha+2)}{\lambda^2 \Gamma(\alpha)} \cdot 1 \\ &= \frac{(\alpha+1)\alpha \Gamma(\alpha)}{\lambda^2 \Gamma(\alpha)} \\ &= \frac{(\alpha+1)\alpha}{\lambda^2}\end{aligned}$$

因此:

$$\begin{aligned}\text{Var}(X) &= \mathbb{E}(X^2) - (\mathbb{E}(X))^2 \\ &= \frac{(\alpha+1)\alpha}{\lambda^2} - \left(\frac{\alpha}{\lambda}\right)^2 \\ &= \frac{\alpha}{\lambda^2}\end{aligned}$$

• ⑤ 卡方随机变量 (Chi-Squared r.v.) (Gamma 随机变量的特例)

$$X \sim \chi^2(k) = \text{Gamma}\left(\frac{k}{2}, \frac{1}{2}\right) \text{ 有 } f(x) = \begin{cases} \frac{e^{-x/2} x^{k/2-1}}{2^{k/2} \Gamma(k/2)}, & x \geq 0 \\ 0, & \text{otherwise} \end{cases}$$

$$\text{根据 ④ 的结论可知} \begin{cases} \mathbb{E}(X) = \frac{k/2}{1/2} = k \\ \mathbb{E}(X^2) = \frac{(k/2+1)(k/2)}{(1/2)^2} = k(k+2) \\ \text{Var}(X) = \frac{k/2}{(1/2)^2} = 2k \end{cases}$$

1.3 随机变量的联合分布

1.3.1 联合分布函数

对于任意两个随机变量 X, Y ,

我们定义其**联合累积分布函数** (Joint Cumulative Distribution Function) 为 $\begin{cases} F(x, y) = \text{P}\left(\begin{cases} X \leq x \\ Y \leq y \end{cases}\right) \\ \text{dom}(F) = \mathbb{R} \times \mathbb{R} \end{cases}$

X, Y 的**边缘分布** (Marginal Distribution) 可由 X, Y 的**联合分布** (Joint Distribution) 得到:

$$\begin{cases} F_X(x) = \text{P}(X \leq x) = \text{P}\left(\begin{cases} X \leq x \\ Y \leq \infty \end{cases}\right) = F(x, \infty) \\ F_Y(y) = \text{P}(Y \leq y) = \text{P}\left(\begin{cases} X \leq \infty \\ Y \leq y \end{cases}\right) = F(\infty, y) \end{cases}$$

• ① 在 X, Y 都是离散随机变量的情况下,

我们定义 X, Y 的**联合概率质量函数**为 $\begin{cases} p(x, y) = \text{P}\left(\begin{cases} X = x \\ Y = y \end{cases}\right) \\ \text{dom}(p) = \mathbb{R} \times \mathbb{R} \end{cases}$

X, Y 的**概率质量函数**可由 X, Y 的**联合概率质量函数**得到 $\begin{cases} p_X(x) = \sum_{y: p(x, y) > 0} p(x, y) \\ p_Y(y) = \sum_{x: p(x, y) > 0} p(x, y) \end{cases}$

- ② 若 X, Y **联合地连续** (jointly continuous),
即存在一个定义在 $\mathbb{R} \times \mathbb{R}$ 上的函数使得:
对于任意 $A, B \subseteq \mathbb{R}$ 都有 $P(X \in A, Y \in B) = \int_B \int_A f(x, y) dx dy$ 成立,
则称 $f(x, y)$ 为 X, Y 的**联合概率密度函数**.

X, Y 的**概率质量函数**可由 X, Y 的**联合概率质量函数**得到
$$\begin{cases} f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy \\ f_Y(y) = \int_{-\infty}^{\infty} f(x, y) dx \end{cases}$$

同单变量情形类似地, 有 $F(a, b) = P(X \leq a, Y \leq b) = \int_{-\infty}^b \int_{-\infty}^a f(x, y) dx dy$ 成立,
因此 $f(x, y) = \frac{d^2}{dx dy} F(x, y)$

- ③ **随机变量多元函数的期望:**

作为本文 1.2.3 (III) 中命题的引申叙述:

若 X, Y 都是随机变量, 则对于任意双变量函数 g 都有:

$$\mathbb{E}[g(x, y)] = \begin{cases} \sum_y \sum_x g(x, y) p(x, y) \\ \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x, y) f(x, y) dx dy \end{cases}$$

推论: 若 $X_1, \dots, X_n$ 是 n 个随机变量,

则对于任意 n 个常数 $c_1, \dots, c_n$ 都有 $\mathbb{E}(\sum_{i=1}^n c_i X_i) = \sum_{i=1}^n c_i \mathbb{E}(X_i)$ 成立.

1.3.2 相互独立的随机变量

若对于任意 $a, b \in \mathbb{R}$ 都有 $P(X \leq a, Y \leq b) = P(X \leq a) \cdot P(Y \leq b)$,

则我们称随机变量 X, Y 是相互独立的,

也就是说, 对于任意 $a, b \in \mathbb{R}$, 事件 $\begin{cases} E_a = \{X \leq a\} \\ E_b = \{Y \leq b\} \end{cases}$ 相互独立;

也就是说, 对于任意 $a, b \in \mathbb{R}$, 都有 $F(a, b) = F_X(a) \cdot F_Y(b)$ 成立;

- ① 当 X, Y 均为离散随机变量时, 独立性简化为 $p(x, y) \equiv p_X(x)p_Y(y)$, 论据如下:

$$\begin{aligned} P(X \leq a, Y \leq b) &= \sum_{y \leq b} \sum_{x \leq a} p(x, y) \\ &= \sum_{y \leq b} \sum_{x \leq a} p_X(x) p_Y(y) \quad (*) \\ &= \sum_{y \leq b} p_Y(y) \cdot \sum_{x \leq a} p_X(x) \\ &= P(Y \leq b) \cdot P(X \leq a) \end{aligned}$$

- ② 当 X, Y 联合地连续时, 独立性简化为 $f(x, y) \equiv f_X(x)f_Y(y)$, 论据如下:

$$\begin{aligned} P(X \leq a, Y \leq b) &= \int_{-\infty}^b \int_{-\infty}^a f(x, y) dx dy \\ &= \int_{-\infty}^b \int_{-\infty}^a f_X(x) f_Y(y) dx dy \quad (*) \\ &= \int_{-\infty}^b f_Y(y) dy \cdot \int_{-\infty}^a f_X(x) dx \\ &= P(Y \leq b) \cdot P(X \leq a) \end{aligned}$$

- ③ **独立随机变量多元函数的期望:**

若随机变量 X, Y 相互独立, 则对于任意函数 g, h 都有 $\mathbb{E}[g(X)h(Y)] = \mathbb{E}[g(X)] \cdot \mathbb{E}[h(Y)]$

(证明过程与 ①② 类似, 就是多元求和、多元积分的拆分)

特殊地, 取 g, h 为恒等映射, 则我们有 $\mathbb{E}[XY] = \mathbb{E}(X) \cdot \mathbb{E}(Y)$

1.3.3 协方差 (Covariance)

随机变量 X, Y 的协方差记为 $\text{Cov}(X, Y)$, 定义为:

$$\begin{aligned} \text{Cov}(X, Y) &= \mathbb{E}[(X - \mathbb{E}(X))(Y - \mathbb{E}(Y))] \\ &= \mathbb{E}[XY - Y\mathbb{E}(X) - X\mathbb{E}(Y) + \mathbb{E}(X)\mathbb{E}(Y)] \\ &= \mathbb{E}(XY) - \mathbb{E}(Y)\mathbb{E}(X) - \mathbb{E}(X)\mathbb{E}(Y) + \mathbb{E}(X)\mathbb{E}(Y) \\ &= \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y) \end{aligned}$$

易知, 当 X, Y 相互独立时, 协方差 $\text{Cov}(X, Y) = 0$

一般地, 可以证明 $\text{Cov}(X, Y) > 0$ 是表明 X 在增加时, Y 倾向于增加;

而 $\text{Cov}(X, Y) < 0$ 是表明 X 在增加时, Y 倾向于减少; (反之亦然)

(应用随机过程概率论模型导论, 例 2.33)

设 X, Y 的联合概率密度函数为 $f(x, y) = \frac{1}{y} e^{-(y+\frac{x}{y})}$ ($0 < x, y < \infty$)

我们使用 $\text{Cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)$ 来计算 $\text{Cov}(X, Y)$.

- ① 注意到:

$$\begin{aligned} f_Y(y) &= \int_{-\infty}^{\infty} f(x, y) dx \\ &= e^{-y} \int_0^{\infty} \frac{1}{y} e^{-\frac{x}{y}} dx \\ &= e^{-y} \cdot -e^{-\frac{x}{y}} \Big|_{x=0}^{x=\infty} \\ &= e^{-y} \end{aligned}$$

表明 $Y \sim \exp(1)$, 从而 $\mathbb{E}(Y) = 1/1 = 1$

- ② 注意到:

$$\begin{aligned} \mathbb{E}(X) &= \int_{-\infty}^{\infty} x \left(\int_{-\infty}^{\infty} f(x, y) dy \right) dx \\ &= \int_{-\infty}^{\infty} x \int_{-\infty}^{\infty} \frac{1}{y} e^{-(y+\frac{x}{y})} dy dx \\ &= \int_0^{\infty} e^{-y} \left(\int_0^{\infty} \frac{x}{y} e^{-\frac{x}{y}} dx \right) dy \\ &= \int_0^{\infty} e^{-y} \cdot \mathbb{E} \left[\exp \left(\frac{1}{y} \right) \right] dy \quad (*) \\ &= \int_0^{\infty} e^{-y} \cdot \frac{1}{1/y} dy \\ &= \int_0^{\infty} ye^{-y} dy \\ &= -(y+1)e^{-y} \Big|_0^{\infty} \\ &= 1 \end{aligned}$$

- ③ 注意到:

$$\begin{aligned} \mathbb{E}(XY) &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} xyf(x, y) dx dy \\ &= \int_0^{\infty} \int_0^{\infty} xy \cdot \frac{1}{y} e^{-(y+\frac{x}{y})} dx dy \\ &= \int_0^{\infty} ye^{-y} \left(\int_0^{\infty} \frac{x}{y} e^{-\frac{x}{y}} dx \right) dy \\ &= \int_0^{\infty} ye^{-y} \cdot \mathbb{E} \left[\exp \left(\frac{1}{y} \right) \right] dy \\ &= \int_0^{\infty} ye^{-y} \cdot \frac{1}{1/y} dy \\ &= \int_0^{\infty} y^2 e^{-y} dy \\ &= \{y^2 \cdot (-e^{-y})\} \Big|_0^{\infty} - \int_0^{\infty} 2y \cdot (-e^{-y}) dy \\ &= 0 - 2(y+1)e^{-y} \Big|_0^{\infty} \\ &= 2 \end{aligned}$$

- ④ 综上所述:

$$\begin{aligned} \text{Cov}(X, Y) &= \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y) \\ &= 2 - 1 \cdot 1 \\ &= 1 \end{aligned}$$

协方差的重要性质:

对于任意随机变量 X, Y, Z 和常数 c

- $\text{Cov}(X, X) = \text{Var}(X)$
- $\text{Cov}(X, Y) = \text{Cov}(Y, X)$
- $\text{Cov}(cX, Y) = c \cdot \text{Cov}(X, Y)$

- $\text{Cov}(X, Y + Z) = \text{Cov}(X, Y) + \text{Cov}(X, Z)$

第四点的证明:

$$\begin{aligned}\text{Cov}(X, Y + Z) &= \mathbb{E}[X(Y + Z)] - \mathbb{E}(X) \cdot \mathbb{E}(Y + Z) \\ &= \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y) + \mathbb{E}(XZ) - \mathbb{E}(X)\mathbb{E}(Z) \\ &= \text{Cov}(X, Y) + \text{Cov}(X, Z)\end{aligned}$$

容易将第四点推广:

$$\text{Cov}\left(\sum_{i=1}^n X_i, \sum_{j=1}^m Y_j\right) = \sum_{i=1}^n \sum_{j=1}^m \text{Cov}(X_i, Y_j)$$

进而得到一个有用的公式:

$$\begin{aligned}\text{Var}\left(\sum_{i=1}^n X_i\right) &= \text{Cov}\left(\sum_{i=1}^n X_i, \sum_{j=1}^n X_j\right) \\ &= \sum_{i=1}^n \sum_{j=1}^n \text{Cov}(X_i, X_j) \\ &= \sum_{i=1}^n \text{Cov}(X_i, X_i) + \sum_{i=1}^n \sum_{j \neq i} \text{Cov}(X_i, X_j) \\ &= \sum_{i=1}^n \text{Var}(X_i) + 2 \sum_{i=1}^n \sum_{j < i} \text{Cov}(X_i, X_j)\end{aligned}$$

若 $X_1, \dots, X_n$ 相互独立, 则公式化简为:

$$\text{Var}\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n \text{Var}(X_i)$$

若 $X_1, \dots, X_n$ 独立同分布, 则称随机变量 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 为**样本均值** (sample mean)

下面的命题说明了样本均值的一些性质:

若 $X_1, \dots, X_n$ 独立同分布, 且具有期望 μ 和方差 σ^2 , 则有:

- ① $\mathbb{E}(\bar{X}) = \mu$
- ② $\text{Var}(\bar{X}) = \frac{\sigma^2}{n}$
- ③ $\text{Cov}(\bar{X}, X_i - \bar{X}) = 0 \quad (\forall i = 1, 2, \dots, n)$

证明:

- ① 证明 $\mathbb{E}(\bar{X}) = \mu$:

$$\begin{aligned}\mathbb{E}[\bar{X}] &= \frac{1}{n} \sum_{i=1}^n \mathbb{E}[X_i] \\ &= \frac{1}{n} \cdot n\mu \\ &= \mu\end{aligned}$$

- ② 证明 $\text{Var}(\bar{X}) = \frac{\sigma^2}{n}$:

$$\begin{aligned}\text{Var}(\bar{X}) &= \frac{1}{n^2} \cdot \text{Var}\left(\sum_{i=1}^n X_i\right) \\ &= \frac{1}{n^2} \cdot \sum_{i=1}^n \text{Var}(X_i) \\ &= \frac{1}{n^2} \cdot n\sigma^2 \\ &= \frac{\sigma^2}{n}\end{aligned}$$

- ③ 证明 $\text{Cov}(\bar{X}, X_i - \bar{X}) = 0 \quad (\forall i = 1, 2, \dots, n)$:

对于任意 $i = 1, 2, \dots, n$, 我们都有:

$$\begin{aligned}
\text{Cov}(\bar{X}, X_i - \bar{X}) &= \text{Cov}(\bar{X}, X_i) - \text{Cov}(\bar{X}, \bar{X}) \\
&= \frac{1}{n} \text{Cov}\left(X_i + \sum_{j \neq i} X_j, X_i\right) - \text{Var}(\bar{X}) \\
&= \frac{1}{n} \text{Cov}(X_i, X_i) + \frac{1}{n} \text{Cov}\left(\sum_{j \neq i} X_j, X_i\right) - \frac{\sigma^2}{n} \\
&= \frac{\sigma^2}{n} + 0 - \frac{\sigma^2}{n} \\
&= 0
\end{aligned}$$

这说明样本均值与任一样本偏差之间的协方差为零，即二者之间不存在线性依赖。这也暗示着样本均值是理论均值的**无偏估计量** (unbiased estimator)。

1.3.4 随机变量之和的方差

在 1.3.3 节中我们得到了一个有用的公式：

$$\begin{aligned}
\text{Var}\left(\sum_{i=1}^n X_i\right) &= \text{Cov}\left(\sum_{i=1}^n X_i, \sum_{j=1}^n X_j\right) \\
&= \sum_{i=1}^n \sum_{j=1}^n \text{Cov}(X_i, X_j) \\
&= \sum_{i=1}^n \text{Cov}(X_i, X_i) + \sum_{i=1}^n \sum_{j \neq i} \text{Cov}(X_i, X_j) \\
&= \sum_{i=1}^n \text{Var}(X_i) + 2 \sum_{i=1}^n \sum_{j < i} \text{Cov}(X_i, X_j)
\end{aligned}$$

若 $X_1, \dots, X_n$ 相互独立，则公式化简为：

$$\text{Var}\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n \text{Var}(X_i)$$

上述公式在计算随机变量之和的方差时常常很有用。

- **(1) 二项随机变量的方差**

二项随机变量 $X \sim B(n, p)$ 可以看作 n 个相互独立的 Bernoulli 随机变量 $X_1, X_2, \dots, X_n \sim B(1, p)$ 之和。而我们知道 Bernoulli 随机变量的方差 $\text{Var}(B(1, p)) = p(1 - p)$ 因此有：

$$\begin{aligned}
\text{Var}(X) &= \text{Var}\left(\sum_{i=1}^n X_i\right) \\
&= \sum_{i=1}^n \text{Var}(X_i) \\
&= np(1 - p)
\end{aligned}$$

- **(2) 从有限的总体中不放回地抽样：超几何分布 (Hyper-geometric Distribution)**

超几何随机变量 $X = \sum_{i=1}^n X_i$ 可以设想为从含有 Np 个白球和 $N(1 - p)$ 个黑球的总体中，随机地抽取 n 个球所得到的白球数。

其中 $X_i = \begin{cases} 1, & \text{如果第 } i \text{ 个球是白球} \\ 0, & \text{otherwise} \end{cases} \sim B(1, p)$

我们下面计算它的均值和方差：

- 由于抽取的第 i 个球等可能地为总体中 N 个球的任意一个，因此有 $\mathbb{E}[\sum_{i=1}^n X_i] = \sum_{i=1}^n \mathbb{E}[X_i] = np$
- $\text{Var}(\sum_{i=1}^n X_i) = \sum_{i=1}^n \text{Var}(X_i) + 2 \sum_{i=1}^n \sum_{j < i} \text{Cov}(X_i, X_j)$
其中 $\text{Var}(X_i) = p(1 - p)$
而对于 $j \neq i$ ，有：

$$\begin{aligned}
\text{Cov}(X_i, X_j) &= \mathbb{E}(X_i X_j) - \mathbb{E}(X_i) \mathbb{E}(X_j) \\
&= P\{X_i = 1, X_j = 1\} - p^2 \\
&= P\{X_i = 1\} P\{X_j = 1 | X_i = 1\} - p^2 \\
&= \frac{Np}{N} \frac{Np-1}{N-1} - p^2 \\
&= \frac{p(Np-1)}{N-1} - p^2
\end{aligned}$$

因此有:

$$\begin{aligned}
\text{Var}\left(\sum_{i=1}^n X_i\right) &= \sum_{i=1}^n \text{Var}(X_i) + 2 \sum_{i=1}^n \sum_{j < i} \text{Cov}(X_i, X_j) \\
&= np(1-p) + 2 \binom{n}{2} \left[\frac{p(Np-1)}{N-1} - p^2 \right] \\
&= np(1-p) - \frac{n(n-1)p(1-p)}{N-1} \\
&= np(1-p) \cdot \frac{N-n}{N-1}
\end{aligned}$$

因此 p 的估计量 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 的期望和方差为:

$$\begin{cases} \mathbb{E}(\bar{X}) = \mathbb{E}\left[\frac{1}{n} \sum_{i=1}^n X_i\right] = p \\ \text{Var}(\bar{X}) = \text{Var}\left[\frac{1}{n} \sum_{i=1}^n X_i\right] = \frac{p(1-p)}{n} \cdot \frac{N-n}{N-1} \end{cases}$$

当 N 增大时, 估计量的方差 $\text{Var}(\bar{X})$ 也增大, 极限值为 $p(1-p)/n$.

这并不令人惊讶, 因为当 N 足够大时, 每一个 $X_i \sim B(1, p)$ 都将近似地是**独立随机变量**,

从而 $\sum_{i=1}^n X_i \sim B(n, p)$ 近似为**二项分布**.

容易知道超几何随机变量的概率质量函数为:

$$P\left\{\sum_{i=1}^n X_i = k\right\} = \frac{\binom{Np}{k} \binom{N-Np}{n-k}}{\binom{N}{n}}$$

当随机变量 X, Y 相互独立时, 我们能从 X 和 Y 的分布计算出 $Z = X + Y$ 的分布, 这一点非常重要.

- (I) 首先假定 X 和 Y 都是**连续的**, 则有:

$$\begin{aligned}
F_{X+Y}(a) &= P\{X + Y \leq a\} \\
&= \int_{-\infty}^a F_{X+Y}(z) dz \quad (z := x + y) \\
&= \iint_{x+y \leq a} f_X(x) f_Y(y) dx dy \quad (X \perp Y) \\
&= \int_{-\infty}^{\infty} \int_{-\infty}^{a-y} f_X(x) f_Y(y) dx dy \\
&= \int_{-\infty}^{\infty} \left(\int_{-\infty}^{a-y} f_X(x) dx \right) f_Y(y) dy \\
&= \int_{-\infty}^{\infty} F_X(a-y) f_Y(y) dy
\end{aligned}$$

总之我们有:

$$\begin{aligned}
F_{X+Y}(a) &= \int_{-\infty}^{\infty} F_X(a-y) f_Y(y) dy \\
&= \int_{-\infty}^{\infty} f_X(x) F_Y(a-x) dx
\end{aligned}$$

对此式求微分可知:

$$\begin{aligned}
f_{X+Y}(a) &= \frac{d}{da} \int_{-\infty}^{\infty} F_X(a-y) f_Y(y) dy \\
&= \int_{-\infty}^{\infty} \frac{d}{da} (F_X(a-y)) f_Y(y) dy \\
&= \int_{-\infty}^{\infty} f_X(a-y) f_Y(y) dy
\end{aligned}$$

我们称 f_{X+Y} 为 f_X 和 f_Y 的**卷积** (convolution).

一个简单的例子:

设 $\begin{cases} X, Y \sim \text{Uniform}(0, 1) \\ X \perp Y \end{cases}$, 考虑 $X + Y$ 的概率密度函数:

$$\begin{aligned} f_{X+Y}(a) &= \int_{-\infty}^{\infty} f_X(a-y)f_Y(y)dy \\ &= \int_0^1 f_X(a-y) \cdot 1dy \\ &= \int_0^1 f_X(a-y)dy \end{aligned}$$

当 $0 \leq a \leq 1$ 时, $f_{X+Y}(a) = \int_0^1 1 \cdot dy = a$

当 $1 < a < 2$ 时, $f_{X+Y}(a) = \int_{a-1}^1 1 \cdot dy = 2 - a$

因此 $f_{X+Y}(a) = \begin{cases} a, & 0 \leq a \leq 1 \\ 2-a, & 1 < a < 2 \\ 0, & \text{otherwise} \end{cases}$

- (II) 我们继续推导在离散情形下 $X + Y$ 分布的一般表达式, 而是考察一个例子:

设 $\begin{cases} X \sim \text{Poisson}(\lambda_1) \\ Y \sim \text{Poisson}(\lambda_2) \\ X \perp Y \end{cases}$, 考虑 $X + Y$ 的分布:

因为事件 $\{X + Y = n\}$ 可以写成一系列不相交事件 $\{X = k, Y = n - k\}$ ($0 \leq k \leq n$) 的并, 故有:

$$\begin{aligned} P(X + Y = n) &= \sum_{k=0}^n P\{X = k, Y = n - k\} \\ &= \sum_{k=0}^n P\{X = k\} \cdot P\{Y = n - k\} \\ &= \sum_{k=0}^n e^{-\lambda_1} \frac{\lambda_1^k}{k!} \cdot e^{-\lambda_2} \frac{\lambda_2^{n-k}}{(n-k)!} \\ &= e^{-(\lambda_1 + \lambda_2)} \sum_{k=0}^n \frac{\lambda_1^k \lambda_2^{n-k}}{k!(n-k)!} \\ &= \frac{e^{-(\lambda_1 + \lambda_2)}}{n!} \sum_{k=0}^n \binom{n}{k} \lambda_1^k \lambda_2^{n-k} \\ &= \frac{e^{-(\lambda_1 + \lambda_2)}}{n!} (\lambda_1 + \lambda_2)^n \end{aligned}$$

也就是说, $X + Y$ 有均值为 $\lambda_1 + \lambda_2$ 的 Poisson 分布.

这称为 **Poisson 分布的再生性** (reproductive property).

- (III) 考虑 n 个相互独立的随机变量 $X_1, \dots, X_n$,

对于所有的值 $a_1, \dots, a_n$ 都有:

$$P\{X_1 \leq a_1, \dots, X_n \leq a_n\} = P\{X_1 \leq a_1\} \cdots P\{X_n \leq a_n\}$$

一个重要的例子:

假设 $X_1, \dots, X_n$ 是独立同分布的连续随机变量,

若记 $X_{(i)}$ 为这些随机变量中第 i 小的值, 则称 $X_{(1)}, \dots, X_{(n)}$ 为**次序统计量** (order statistics).

我们注意到 $X_{(i)} \leq x$ 当且仅当 $X_1, \dots, X_n$ 至少有 i 个 $\leq x$

因此 $P\{X_{(i)} \leq x\} = \sum_{k=i}^n \binom{n}{k} (F(x))^k (1 - F(x))^{n-k}$

微分可得 $X_{(i)}$ 的密度函数如下:

$$\begin{aligned}
f_{X_{(i)}}(x) &= f(x) \sum_{k=i}^n \binom{n}{k} k (F(x))^{k-1} (1-F(x))^{n-k} - f(x) \sum_{k=i}^n \binom{n}{k} (n-k) (F(x))^k (1-F(x))^{n-k-1} \\
&= f(x) \sum_{k=i}^n \frac{n!}{(n-k)!(k-1)!} (F(x))^{k-1} (1-F(x))^{n-k} - f(x) \sum_{k=i}^{n-1} \frac{n!}{(n-k-1)!k!} (F(x))^k (1-F(x))^{n-k-1} \\
&= f(x) \sum_{k=i}^n \frac{n!}{(n-k)!(k-1)!} (F(x))^{k-1} (1-F(x))^{n-k} - f(x) \sum_{j=i+1}^n \frac{n!}{(n-j)!(j-1)!} (F(x))^{j-1} (1-F(x))^{n-j} \\
&= \frac{n!}{(n-i)!(i-1)!} f(x) (F(x))^{i-1} (1-F(x))^{n-i} \\
&= n f(x) \cdot \binom{n-1}{i-1} (F(x))^{i-1} (1-F(x))^{n-i} \\
&= \binom{n}{1} f(x) \cdot \binom{n-1}{i-1} (F(x))^{i-1} (1-F(x))^{n-i}
\end{aligned}$$

上述结果非常直观:

为了使 $X_{(i)} = x$, $X_1, \dots, X_n$ 必然有 $i-1$ 个 $\leq x$, 有 $n-i$ 个 $\geq x$, 且有一个 $= x$,

我们将 $X_1, \dots, X_n$ 划分为以上三组, 其组合数为 $\binom{n}{1} \cdot \binom{n-1}{i-1}$

再乘上对应的值 $f(x)(F(x))^{i-1}(1-F(x))^{n-i}$, 就得到 $X_{(i)}$ 的概率密度函数.

1.3.5 随机变量的函数的联合概率分布

设 X_1, X_2 是**联合地连续**的随机变量, 具有联合概率密度函数 $f_{X_1, X_2}(x_1, x_2)$

记 $Y_1 = g_1(X_1, X_2)$, $Y_2 = g_2(X_1, X_2)$, 我们想得到 Y_1, Y_2 的联合分布.

假定函数 g_1, g_2 满足以下条件:

- 由方程组 $\begin{cases} y_1 = g_1(x_1, x_2) \\ y_2 = g_2(x_1, x_2) \end{cases}$ 可以唯一地解出 x_1, x_2 , 记为 $\begin{cases} x_1 = h_1(y_1, y_2) \\ x_2 = h_2(y_1, y_2) \end{cases}$
- 函数 g_1, g_2 在所有的点 (x_1, x_2) 上有连续的偏导数, 且对于任意 (x_1, x_2) 都有:

$$J(x_1, x_2) = \begin{vmatrix} \frac{\partial y_1}{\partial x_1} & \frac{\partial y_1}{\partial x_2} \\ \frac{\partial y_2}{\partial x_1} & \frac{\partial y_2}{\partial x_2} \end{vmatrix} = \frac{\partial y_1}{\partial x_1} \frac{\partial y_2}{\partial x_2} - \frac{\partial y_1}{\partial x_2} \frac{\partial y_2}{\partial x_1} \neq 0$$

在这两个条件下, 可以证明 Y_1, Y_2 **联合地连续**, 且联合密度函数为:

$$f_{Y_1, Y_2}(y_1, y_2) = f_{X_1, X_2}(x_1, x_2) |J(x_1, x_2)|^{-1}$$

其中 $\begin{cases} x_1 = h_1(y_1, y_2) \\ x_2 = h_2(y_1, y_2) \end{cases}$

它实际上是通过下式对 y_1, y_2 求微分得到的:

$$P\{Y_1 \leq y_1, Y_2 \leq y_2\} = \iint_{(x_1, x_2): \begin{cases} g_1(x_1, x_2) \leq y_1 \\ g_2(x_1, x_2) \leq y_2 \end{cases}} f_{X_1, X_2}(x_1, x_2) dx_1 dx_2$$

一个具体的例子: (待补充)

推广:

假设 X 是 k 维连续随机变量, 具有概率密度函数 $f_X(\cdot)$

给定变换 $g: \mathbb{R}^k \rightarrow \mathbb{R}^k$, 记 $Y = g(X)$

若 g 满足:

- g 存在逆变换 $h = g^{-1}$
- g 一阶连续可求偏导, 即在所有 x 上有连续的偏导数, 且对于任意 x 都有:

$$J(x) = \begin{vmatrix} \frac{\partial y_1}{\partial x_1} & \cdots & \frac{\partial y_1}{\partial x_k} \\ \vdots & & \vdots \\ \frac{\partial y_k}{\partial x_1} & \cdots & \frac{\partial y_k}{\partial x_k} \end{vmatrix} \neq 0$$

在这两个条件下, 可以证明 Y **联合地连续**, 且联合密度函数为:

$$f_Y(y) = f_X(x) |J(x)|^{-1} = f_X(h(y)) |J(h(y))|^{-1}$$

• **推论:**

假设 X 是 k 维连续随机变量, 具有概率密度函数 $f_X(\cdot)$

给定可逆矩阵 $A \in \mathbb{R}^{k \times k}$ 和向量 $b \in \mathbb{R}^k$, 记 $Y = AX + b$

则 $f_Y(y) = \frac{1}{|\det(A)|} f_X(A^{-1}(y - b))$

1.4 矩母函数 (Moment Generating Function)

随机变量 X 的**矩母函数** $M_X(t)$ 对任意 $t \in \mathbb{R}$ 定义为:

$$M_X(t) = \mathbb{E}[e^{tX}] = \begin{cases} \sum_{x: \text{pmf}(x) > 0} e^{tx} \text{pmf}(x), & \text{Discrete case} \\ \int_{-\infty}^{\infty} e^{tx} f(x) dx, & \text{Continuous case} \end{cases}$$

我们称 $\phi(t)$ 为**矩母函数**, 是因为 X 所有的**矩** (moment) 都能由 $\phi(t)$ 求微分得到.

一般地, 对于任意 $k \geq 1$, 都有 $M_X^{(k)}(t) = \mathbb{E}[X^k e^{tX}]$

因此有 $\mathbb{E}[X^k] = M_X^{(k)}(0)$ 成立.

矩母函数唯一地确定了分布: 即随机变量的矩母函数和分布函数之间存在唯一对应.

对于非负随机变量 X , 我们也可以定义它的 **Laplace 变换**:

$$\mathcal{L}_X(t) = \mathbb{E}[e^{-tX}] = M_X(-t) \quad (t \geq 0)$$

当随机变量非负时, 与矩母函数相比, Laplace 变换的优点是:

如果 $X \geq 0$ 且 $t \geq 0$, 则 $0 \leq e^{-tX} \leq 1$, 即 Laplace 变换永远在 $0, 1$ 之间.

Laplace 变换同样能唯一确定分布.

1.4.1 常见分布的矩母函数:

(I) 离散情况:

• ① Bernoulli 随机变量 (二项随机变量的特例)

$$X \sim B(1, p) \text{ 有 } \begin{cases} \text{pmf}(1) = p \\ \text{pmf}(0) = 1 - p \end{cases} \text{ 且 } \begin{cases} \mathbb{E}(X) = p \\ \mathbb{E}(X^2) = p \\ \text{Var}(X) = p(1 - p) \end{cases}$$

$$\begin{aligned} M_X(t) &= \mathbb{E}[e^{tX}] \\ &= e^{t \cdot 0}(1 - p) + e^{t \cdot 1}p \\ &= pe^t + 1 - p \end{aligned}$$

因此 $\mathbb{E}[X^k] = M_X^{(k)}(0) = p \quad (\forall k = 1, 2, \dots)$

• ② 二项随机变量 (Binomial r.v.)

$$X \sim B(n, p) \text{ 有 } \text{pmf}(i) = \binom{n}{i} p^i (1 - p)^{n-i} \quad (i = 0, 1, \dots, n) \text{ 且 } \begin{cases} \mathbb{E}(X) = np \\ \mathbb{E}(X^2) = n(n-1)p^2 + np \\ \text{Var}(X) = np(1 - p) \end{cases}$$

$$\begin{aligned} M_X(t) &= \mathbb{E}[e^{tX}] \\ &= \sum_{i=0}^n e^{ti} \binom{n}{i} p^i (1 - p)^{n-i} \\ &= \sum_{i=0}^n \binom{n}{i} (pe^t)^i (1 - p)^{n-i} \\ &= (pe^t + 1 - p)^n \end{aligned}$$

• ③ 几何随机变量 (Geometric r.v.)

$$X \sim \text{Geo}(p) \text{ 有 } \text{pmf}(i) = (1 - p)^{i-1} p \quad (i = 1, 2, \dots) \text{ 而 } \begin{cases} \mathbb{E}(X) = \frac{1}{p} \\ \mathbb{E}(X^2) = \frac{2}{p^2} - \frac{1}{p} \\ \text{Var}(X) = \frac{1-p}{p^2} \end{cases}$$

$$\begin{aligned}
M_X(t) &= \mathbb{E}[e^{tX}] \\
&= \sum_{i=0}^{\infty} e^{t \cdot i} (1-p)^{i-1} p \\
&= p \cdot \sum_{i=0}^{\infty} [(1-p)e^t]^i \\
&= \frac{p}{1 - (1-p)e^t}
\end{aligned}$$

• ④ Poisson 随机变量

$$X \sim \text{Poisson}(\lambda) \text{ 有 } \text{pmf}(i) = e^{-\lambda} \frac{\lambda^i}{i!} \quad (i = 0, 1, \dots) \text{ 且 } \begin{cases} \mathbb{E}(X) = \lambda \\ \mathbb{E}(X^2) = \lambda^2 + \lambda \\ \text{Var}(X) = \lambda \end{cases}$$

$$\begin{aligned}
M_X(t) &= \mathbb{E}[e^{tX}] \\
&= \sum_{i=0}^{\infty} e^{t \cdot i} e^{-\lambda} \frac{\lambda^i}{i!} \\
&= e^{-\lambda} \sum_{i=0}^{\infty} \frac{(\lambda e^t)^i}{i!} \\
&= e^{-\lambda} e^{\lambda e^t} \\
&= e^{\lambda(e^t - 1)}
\end{aligned}$$

(II) 连续情况:

• ① 均匀随机变量 (Uniform r.v.)

$$X \sim \text{Uniform}(a, b) \text{ 有 } f(x) = \begin{cases} \frac{1}{b-a}, & \text{if } a < x < b \\ 0, & \text{otherwise} \end{cases} \text{ 且 } \begin{cases} \mathbb{E}(X) = \frac{a+b}{2} \\ \mathbb{E}(X^2) = \frac{a^2+ab+b^2}{3} \\ \text{Var}(X) = \frac{(a-b)^2}{12} \end{cases}$$

$$\begin{aligned}
M_X(t) &= \mathbb{E}[e^{tX}] \\
&= \int_a^b e^{tx} \frac{1}{b-a} dx \\
&= \frac{e^{bt} - e^{at}}{(b-a)t}
\end{aligned}$$

• ② 指数随机变量 (Exponential r.v.) (Gamma 随机变量的特例)

$$X \sim \exp(\lambda) = \text{Gamma}(1, \lambda) \text{ 有 } f(x) = \begin{cases} \lambda e^{-\lambda x}, & x \geq 0 \\ 0, & \text{otherwise} \end{cases} \text{ 且 } \begin{cases} \mathbb{E}(X) = \frac{1}{\lambda} \\ \mathbb{E}(X^2) = \frac{2}{\lambda^2} \\ \text{Var}(X) = \frac{1}{\lambda^2} \end{cases}$$

$$\begin{aligned}
M_X(t) &= \mathbb{E}[e^{tX}] \\
&= \int_0^{\infty} e^{tx} \cdot \lambda e^{-\lambda x} dx \\
&= \lambda \int_0^{\infty} e^{-(\lambda-t)x} dx \\
&= \frac{\lambda}{\lambda - t}
\end{aligned}$$

对于指数分布, $M_X(t)$ 只对小于 λ 的 t 值定义.

(一般形式 Gamma 随机变量的矩母函数参见 ④)

• ③ 正态随机变量 (Normal r.v.)

$$X \sim N(\mu, \sigma^2) \text{ 有 } f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\} \quad (\forall x \in \mathbb{R}) \text{ 且 } \begin{cases} \mathbb{E}(X) = \mu \\ \mathbb{E}(X^2) = \sigma^2 + \mu^2 \\ \text{Var}(X) = \sigma^2 \end{cases}$$

考虑标准正态随机向量 $Z \sim N(0, 1)$, 其矩母函数为:

$$\begin{aligned}
M_X(t) &= \mathbb{E}[e^{tX}] \\
&= \int_{-\infty}^{\infty} e^{tx} \cdot \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx \\
&= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-(x^2-2tx)/2} dx \\
&= e^{t^2/2} \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-(x-t)^2/2} d(x-t) \\
&= e^{t^2/2} \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-u^2/2} du \quad (u := x-t) \\
&= e^{t^2/2} \cdot 1 \\
&= e^{t^2/2}
\end{aligned}$$

则 $X = \sigma Z + \mu \sim N(\mu, \sigma^2)$ 的矩母函数为:

$$\begin{aligned}
M_X(t) &= \mathbb{E}[e^{tX}] \\
&= \mathbb{E}[e^{t(\sigma Z + \mu)}] \\
&= e^{t\mu} \mathbb{E}[e^{t\sigma Z}] \\
&= \exp\left\{\frac{\sigma^2 t^2}{2} + \mu t\right\}
\end{aligned}$$

(一元正态的矩母函数需要记忆)

• ④ Gamma 随机变量

$$X \sim \text{Gamma}(\alpha, \lambda) \text{ 有 } f(x) = \begin{cases} \frac{\lambda e^{-\lambda x} (\lambda x)^{\alpha-1}}{\Gamma(\alpha)}, & x \geq 0 \\ 0, & \text{otherwise} \end{cases} \quad \text{且} \quad \begin{cases} \mathbb{E}(X) = \frac{\alpha}{\lambda} \\ \mathbb{E}(X^2) = \frac{(\alpha+1)\alpha}{\lambda^2} \\ \text{Var}(X) = \frac{\alpha}{\lambda^2} \end{cases}$$

$$\text{其中 } \Gamma(\alpha) = \int_0^{\infty} e^{-t} t^{\alpha-1} dt$$

$$\begin{aligned}
M_X(t) &= \mathbb{E}[e^{tX}] \\
&= \int_0^{\infty} e^{tx} \cdot \frac{\lambda e^{-\lambda x} (\lambda x)^{\alpha-1}}{\Gamma(\alpha)} dx \\
&= \lambda^{\alpha} \int_0^{\infty} \frac{e^{-(\lambda-t)x} x^{\alpha-1}}{\Gamma(\alpha)} dx \\
&= \frac{\lambda^{\alpha}}{(\lambda-t)^{\alpha}} \int_0^{\infty} \frac{e^{-(\lambda-t)x} ((\lambda-t)x)^{\alpha-1}}{\Gamma(\alpha)} d((\lambda-t)x) \\
&= \frac{\lambda^{\alpha}}{(\lambda-t)^{\alpha}} \int_0^{\infty} \frac{e^{-u} u^{\alpha-1}}{\Gamma(\alpha)} du \quad (u := (\lambda-t)x) \\
&= \frac{\lambda^{\alpha}}{(\lambda-t)^{\alpha}} \cdot 1 \\
&= \left(\frac{\lambda}{\lambda-t}\right)^{\alpha}
\end{aligned}$$

(对于 Gamma 分布, $M_X(t)$ 只对小于 λ 的 t 值定义)

• ⑤ 卡方随机变量 (Chi-Squared r.v.) (Gamma 随机变量的特例)

$$X \sim \chi^2(k) = \text{Gamma}\left(\frac{k}{2}, \frac{1}{2}\right) \text{ 有 } f(x) = \begin{cases} \frac{e^{-x/2} x^{k/2-1}}{2^{k/2} \Gamma(k/2)}, & x \geq 0 \\ 0, & \text{otherwise} \end{cases}$$

$$\text{根据 ④ 的结论可知} \quad \begin{cases} \mathbb{E}(X) = \frac{k/2}{1/2} = k \\ \mathbb{E}(X^2) = \frac{(k/2+1)(k/2)}{(1/2)^2} = k(k+2) \\ \text{Var}(X) = \frac{k/2}{(1/2)^2} = 2k \end{cases}$$

$$\text{且 } M_X(t) = \left(\frac{1/2}{1/2-t}\right)^{k/2} = \left(\frac{1}{1-2t}\right)^{k/2} = (1-2t)^{-k/2}$$

1.4.2 独立随机变量之和的矩母函数

矩母函数的一个重要性质是:

独立随机变量之和的矩母函数正是单个矩母函数的乘积。

具体来说, 假设 X, Y 独立, 分别具有矩母函数 $M_X(t)$ 和 $M_Y(t)$

则 $X + Y$ 的矩母函数为:

$$\begin{aligned}
M_{X+Y}(t) &= \mathbb{E}[e^{t(X+Y)}] \\
&= \mathbb{E}[e^{tX}e^{tY}] \quad (\text{note that } X \perp Y) \\
&= \mathbb{E}[e^{tX}] \cdot \mathbb{E}[e^{tY}] \\
&= M_X(t) \cdot M_Y(t)
\end{aligned}$$

• ① 独立二项随机变量的和:

给定 $\begin{cases} X \sim B(n, p) \\ Y \sim B(m, p) \\ X \perp Y \end{cases}$ 有 $\begin{cases} M_X(t) = (pe^t + 1 - p)^n \\ M_Y(t) = (pe^t + 1 - p)^m \end{cases}$

于是 $M_{X+Y}(t) = M_X(t) \cdot M_Y(t) = (pe^t + 1 - p)^{m+n}$

从而 $X + Y \sim B(m + n, p)$

• ② 独立 Poisson 随机变量的和:

给定 $\begin{cases} X \sim \text{Poisson}(\lambda_1) \\ Y \sim \text{Poisson}(\lambda_2) \\ X \perp Y \end{cases}$ 有 $\begin{cases} M_X(t) = e^{\lambda_1(e^t - 1)} \\ M_Y(t) = e^{\lambda_2(e^t - 1)} \end{cases}$

于是 $M_{X+Y}(t) = M_X(t) \cdot M_Y(t) = e^{(\lambda_1 + \lambda_2)(e^t - 1)}$

从而 $X + Y \sim \text{Poisson}(\lambda_1 + \lambda_2)$

• ③ Poisson 范例 (paradigm):

在 1.2.1 节中, 我们说明过 Poisson 随机变量可用于近似 n 很大而 p 很小的二项随机变量. 即在 n 很大而 p 很小时, 二项分布 $B(n, p) \approx \text{Poisson}(np)$

我们可以继续加强这个结论:

- 首先, 每次独立试验不必拥有相同的成功概率, 只要所有的成功概率都很小即可.

考虑 n 次独立试验 $X_i \sim B(1, p_i)$, 其中 p_i 都很小 ($i = 1, \dots, n$)

X_i 的矩母函数为:

$$\begin{aligned}
M_{X_i}(t) &= p_i e^t + 1 - p_i \\
&= 1 + p_i(e^t - 1) \\
&\approx \exp\{p_i(e^t - 1)\}
\end{aligned}$$

(这说明 $X_i \sim B(1, p_i)$ 近似于 $\text{Poisson}(p_i)$)

记成功的总次数为 $X = \sum_{i=1}^n X_i$

X 的矩母函数为:

$$\begin{aligned}
M_X(t) &= \prod_{i=1}^n M_{X_i}(t) \\
&\approx \exp\left\{\sum_{i=1}^n p_i \cdot (e^t - 1)\right\}
\end{aligned}$$

(这说明 X 近似于 $\text{Poisson}(\sum_{i=1}^n p_i)$)

- 其次, 对于成功次数近似服从 Poisson 分布的试验,

不仅每次试验不必有相同的成功概率, 甚至不需要是独立的, 只要它们的依赖性是很弱的即可.

一个具体的例子:

假设有 n 个人把帽子放在一起, 再各自随机选取一个帽子.

将随机选取看出 n 次试验, 记第 i 次试验成功的事件为 X_i , 代表第 i 人恰好选取了自己的帽子.

由此推出 $\begin{cases} P(X_i) = \frac{1}{n} \\ P(X_i | X_j) = \frac{1}{n-1} \quad (\forall j \neq i) \end{cases}$

虽然这些试验不是相互独立的, 但当 n 很大时, 它们显示弱的依赖性和小的成功概率.

所有当 n 很大时, 匹配总数 $X = \sum_{i=1}^n X_i$ 近似服从 $\text{Poisson}(1)$ 分布.

- 总而言之:

当每次试验成功概率都很小的时候, 在 n 次独立 (或弱相依) 的试验中, 其成功次数近似是一个 Poisson 随机变量.

这个陈述称为 Poisson 范例.

• ④ 独立 Gamma 随机变量的和:

给定 $\begin{cases} X \sim \text{Gamma}(\alpha_1, \lambda) \\ Y \sim \text{Gamma}(\alpha_2, \lambda) \\ X \perp Y \end{cases}$ 有 $\begin{cases} M_X(t) = (\frac{\lambda}{\lambda - t})^{\alpha_1} \\ M_Y(t) = (\frac{\lambda}{\lambda - t})^{\alpha_2} \end{cases}$

于是 $M_{X+Y}(t) = M_X(t) \cdot M_Y(t) = (\frac{\lambda}{\lambda - t})^{\alpha_1 + \alpha_2}$

从而 $X + Y \sim \text{Gamma}(\alpha_1 + \alpha_2, \lambda)$

根据上述结论我们也可以知道:

对于独立卡方随机变量 $\begin{cases} X \sim \chi^2(k_1) = \text{Gamma}(\frac{k_1}{2}, \frac{1}{2}) \\ Y \sim \chi^2(k_2) = \text{Gamma}(\frac{k_2}{2}, \frac{1}{2}) \\ X \perp Y \end{cases}$

有 $X + Y \sim \chi^2(k_1 + k_2) = \text{Gamma}(\frac{k_1+k_2}{2}, \frac{1}{2})$

- ⑤ 独立正态随机变量的和:

给定 $\begin{cases} X \sim N(\mu_1, \sigma_1^2) \\ Y \sim N(\mu_2, \sigma_2^2) \\ X \perp Y \end{cases}$ 有 $\begin{cases} M_X(t) = \exp\{\frac{\sigma_1^2 t^2}{2} + \mu_1 t\} \\ M_Y(t) = \exp\{\frac{\sigma_2^2 t^2}{2} + \mu_2 t\} \end{cases}$

于是 $M_{X+Y}(t) = M_X(t) \cdot M_Y(t) = (\frac{\lambda}{\lambda-t})^{\alpha_1+\alpha_2}$

从而 $X + Y \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$

1.4.3 联合矩母函数

我们可以定义两个或更多的随机变量的联合矩母函数.

对于任意 n 个随机变量 $X_1, \dots, X_n$ 和所有的实值 $t_1, \dots, t_n \in \mathbb{R}$

联合矩母函数为 $M(t_1, \dots, t_n) = \mathbb{E}[e^{t_1 X_1 + \dots + t_n X_n}]$

可以证明 $M(t_1, \dots, t_n)$ 唯一地确定 $X_1, \dots, X_n$ 的联合分布.

- ① 多元正态分布:

令 $Z_1, \dots, Z_n$ 是 n 个相互独立的标准正态随机向量.

若对于某些常数 a_{ij} ($1 \leq i \leq m, 1 \leq j \leq n$) 和 μ_i ($1 \leq i \leq m$)

有 $\begin{bmatrix} X_1 \\ \vdots \\ X_m \end{bmatrix} = \begin{bmatrix} a_{11} & \dots & a_{1n} \\ \vdots & & \vdots \\ a_{m1} & \dots & a_{mn} \end{bmatrix} \begin{bmatrix} Z_1 \\ \vdots \\ Z_n \end{bmatrix} + \begin{bmatrix} \mu_1 \\ \vdots \\ \mu_m \end{bmatrix}$ 成立 (简记为 $X = AZ + \mu$),

则称 $X_1, \dots, X_m$ 具有(联合)多元正态分布.

由于独立正态随机变量的和本身就是一个正态随机变量,

因此 $X_1, \dots, X_m$ 各自也都是正态随机变量.

易知 $X = [X_1, \dots, X_m]^T \sim N(\mu, AA^T)$

对比一元正态分布的概率密度函数形式, 我们可以写出多元正态分布的概率密度函数:

$$f(X) = \frac{1}{(2\pi)^{m/2} \det(AA^T)} \exp \left\{ -\frac{1}{2} (X - \mu)^T (AA^T)^{-1} (X - \mu) \right\}$$

下面我们确定 $X_1, \dots, X_m$ 的联合矩母函数:

记 $t = \begin{bmatrix} t_1 \\ \vdots \\ t_m \end{bmatrix}$, 则 $Y := \sum_{i=1}^m t_i X_i = t^T X \sim N(t^T \mu, t^T \text{Cov}(X) t) = N(t^T \mu, t^T A A^T t)$

因此有:

$$\begin{aligned} M(t) &= \mathbb{E}[e^{t^T X}] \\ &= \mathbb{E}[e^Y] \\ &= M_Y(1) \\ &= \exp \left\{ \frac{\text{Var}(Y) \cdot 1^2}{2} + \mathbb{E}(Y) \cdot 1 \right\} \\ &= \exp \left\{ \frac{1}{2} t^T A A^T t + t^T \mu \right\} \\ &= \exp \left\{ \frac{1}{2} t^T \text{Cov}(Y) t + t^T \mathbb{E}(Y) \right\} \end{aligned}$$

这就证明了 $X = [X_1, \dots, X_m]^T$ 的联合分布由 $\mathbb{E}(X) = \mu$ 和 $\text{Cov}(X) = A A^T$ 完全确定.

- ② 多元正态随机变量做线性映射后仍是多元正态的

具体来说, 若 $X \sim N(\mu, \Sigma)$, 则 $Ax + b \sim N(A\mu + b, A\Sigma A^T)$

证明:

$$\begin{aligned}
M_{AX+b}(t) &= \mathbb{E}[e^{t^T(AX+b)}] \\
&= e^{b^T t} \cdot \mathbb{E}[e^{(A^T t)^T X}] \\
&= e^{b^T t} \cdot M_X(A^T t) \\
&= e^{b^T t} \cdot \exp\left\{\frac{1}{2}(A^T t)^T \Sigma (A^T t) + (A^T t)^T \mu\right\} \quad (X \sim N(\mu, \Sigma)) \\
&= \exp\left\{\frac{1}{2}t^T (A \Sigma A^T) t + t^T (A \mu + b)\right\} \\
&= M_{N(A \mu + b, A \Sigma A^T)}(t)
\end{aligned}$$

得证 $Ax + b \sim N(A\mu + b, A \Sigma A^T)$

推论:

- 多元正态随机向量的任意分量都是正态随机向量.
- n 维随机变量 $X \sim N(\mu, \Sigma)$ 当且仅当对于任意 $\alpha \in \mathbb{R}^n$ 都有 $\alpha^T X \sim N(\alpha^T \mu, \alpha^T \Sigma \alpha)$ 成立.

证明:

必要性显然成立, 下面验证充分性:

$$\begin{aligned}
M_{\alpha^T X}(t) &= \mathbb{E}[e^{t \alpha^T X}] \\
&= \exp\left\{\frac{1}{2} \alpha^T \Sigma \alpha \cdot t^2 + \alpha^T \mu \cdot t\right\} \\
&= \exp\left\{\frac{1}{2} (t \alpha)^T \Sigma (t \alpha) + (t \alpha)^T \mu\right\} \\
&= M_{N(\mu, \Sigma)}(t \alpha)
\end{aligned}$$

根据 $\alpha \in \mathbb{R}^n$ 的任意性, 我们知道 $t \alpha$ 可以取到 $\mathbb{R}^n$ 中的任意一点, 说明有 $X \sim N(\mu, \Sigma)$ 成立.

若 n 维随机变量 $X \sim N\left(\begin{bmatrix} \mu_1 \\ \vdots \\ \mu_n \end{bmatrix}, \begin{bmatrix} \sigma_1^2 & & \\ & \ddots & \\ & & \sigma_n^2 \end{bmatrix}\right)$

则有 $\begin{cases} X_i \sim N(\mu_i, \sigma_i^2) \quad (i = 1, \dots, n) \\ X_1, \dots, X_n \text{ are uncorrelated/independent} \end{cases}$ 成立.

这个结论可由上一个推论直接得到, 也可通过矩母函数证明.

它也说明联合多元正态的随机向量之间, **不相关和独立**是等价的.

注意, 必须在联合多元正态的前提条件下, 考虑以下示例:

给定 $\begin{cases} X \sim N(0, 1) \\ \varepsilon = \begin{cases} 1, & \frac{1}{2} \\ -1, & \frac{1}{2} \end{cases}, \text{ 记 } Y = \varepsilon X, \text{ 显然有 } \begin{cases} Y \sim N(0, 1) \\ Y \not\sim X \end{cases} \text{ 成立} \\ \varepsilon \perp X \end{cases}$

然而我们可以证明 X, Y 不相关:

$$\begin{aligned}
\text{Cov}(X, Y) &= \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y) \\
&= \mathbb{E}(X^2 \varepsilon) - 0 \cdot 0 \\
&= \mathbb{E}(X^2) \cdot \mathbb{E}(\varepsilon) \\
&= (0^2 + 1) \cdot 0 \\
&= 0
\end{aligned}$$

③ 正态总体的样本均值与样本方差的联合分布:

回顾 1.3.3 的内容:

若 $X_1, \dots, X_n$ 独立同分布, 则称随机变量 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 为**样本均值** (sample mean)

下面的命题说明了样本均值的一些性质:

若 $X_1, \dots, X_n$ 独立同分布, 且具有期望 μ 和方差 σ^2 , 则有:

- ① $\mathbb{E}(\bar{X}) = \mu$
- ② $\text{Var}(\bar{X}) = \frac{\sigma^2}{n}$
- ③ $\text{Cov}(\bar{X}, X_i - \bar{X}) = 0 \quad (\forall i = 1, 2, \dots, n)$

这说明样本均值 $\bar{X}$ 是理论均值 μ 的**无偏估计量** (unbiased estimator).

也说明样本均值 $\bar{X}$ 与任一样本偏差 $X_i - \bar{X}$ 之间的协方差为零, 即二者之间不存在线性依赖.

我们进而定义**样本方差** (sample variance):

若 $X_1, \dots, X_n$ 独立同分布, 则称随机变量 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 为**样本方差** (sample variance)

下面的命题说明了样本方差的一些性质:

若 $X_1, \dots, X_n$ 独立同分布, 且具有期望 μ 和方差 σ^2 , 则有:

◦ ① $\mathbb{E}(S^2) = \sigma^2$

◦ ② 当 $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2)$ 时, 我们有
$$\begin{cases} \bar{X} \perp S^2 \\ \bar{X} \sim N(\mu, \frac{\sigma^2}{n}) \\ S^2 \sim \sigma^2 \frac{\chi^2(n-1)}{n-1} \end{cases}$$

证明:

◦ ① 证明 $\mathbb{E}(S^2) = \sigma^2$:

$$\begin{aligned} \sum_{i=1}^n (X_i - \bar{X})^2 &= \sum_{i=1}^n (X_i - \mu + \mu - \bar{X})^2 \\ &= \sum_{i=1}^n (X_i - \mu)^2 + n(\mu - \bar{X})^2 + 2(\mu - \bar{X}) \sum_{i=1}^n (X_i - \mu) \\ &= \sum_{i=1}^n (X_i - \mu)^2 + n(\mu - \bar{X})^2 + 2(\mu - \bar{X})(n\bar{X} - n\mu) \\ &= \sum_{i=1}^n (X_i - \mu)^2 + n(\mu - \bar{X})^2 - 2n(\mu - \bar{X})^2 \\ &= \sum_{i=1}^n (X_i - \mu)^2 - n(\mu - \bar{X})^2 \end{aligned}$$

(这是一个相当重要的恒等式: $(n-1)S^2 = \sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n (X_i - \mu)^2 - n(\mu - \bar{X})^2$)
因此有:

$$\begin{aligned} \mathbb{E}[(n-1)S^2] &= \mathbb{E} \left[\sum_{i=1}^n (X_i - \mu)^2 - n(\mu - \bar{X})^2 \right] \\ &= \sum_{i=1}^n \mathbb{E}[(X_i - \mu)^2] - n\mathbb{E}[(\bar{X} - \mu)^2] \\ &= n\sigma^2 - n\text{Var}(\bar{X}) \quad (\text{note that } \text{Var}(\bar{X}) = \frac{\sigma^2}{n}) \\ &= n\sigma^2 - n \cdot \frac{\sigma^2}{n} \\ &= (n-1)\sigma^2 \end{aligned}$$

于是有 $\mathbb{E}(S^2) = \sigma^2$

◦ ② 证明当 $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2)$ 时, 有
$$\begin{cases} \bar{X} \perp S^2 \\ \bar{X} \sim N(\mu, \frac{\sigma^2}{n}) \\ S^2 \sim \sigma^2 \frac{\chi^2(n-1)}{n-1} \end{cases} \text{ 成立}$$

■ 证明 $\bar{X} \perp S^2$:

在正态假设下, 独立性等价于线性无关性.

根据前文结论 $\text{Cov}(\bar{X}, X_i - \bar{X}) = 0 \quad (\forall i = 1, 2, \dots, n)$

可知 $\bar{X}$ 与偏差序列 $X_i - \bar{X} \quad (i = 1, \dots, n)$ 是线性无关的, 因而是独立的.

由此推出 $\bar{X}$ 独立于样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$

(对于一般情况, $\bar{X}$ 与 S^2 一定线性无关, 但不一定相互独立)

■ 证明 $\bar{X} \sim N(\mu, \frac{\sigma^2}{n})$:

由于 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 是正态随机向量 $X_1, \dots, X_n$ 的线性组合, 故也是正态随机向量.

根据前文结论 $\begin{cases} \mathbb{E}(\bar{X}) = \mu \\ \text{Var}(\bar{X}) = \frac{\sigma^2}{n} \end{cases}$ 可知 $\bar{X} \sim N(\mu, \frac{\sigma^2}{n})$

■ 证明 $S^2 \sim \sigma^2 \frac{\chi^2(n-1)}{n-1}$:

利用恒等式 $(n-1)S^2 = \sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n (X_i - \mu)^2 - n(\mu - \bar{X})^2$

可知 $\frac{(n-1)S^2}{\sigma^2} + \left(\frac{\bar{X}-\mu}{\sigma/\sqrt{n}}\right)^2 = \sum_{i=1}^n \frac{(X_i-\mu)^2}{\sigma^2}$

由于 $\begin{cases} \left(\frac{\bar{X}-\mu}{\sigma/\sqrt{n}}\right)^2 \sim N(0, 1) = \chi^2(1) \\ \sum_{i=1}^n \frac{(X_i-\mu)^2}{\sigma^2} \sim \chi^2(n) \end{cases}$

因此 $\begin{cases} \left(\frac{\bar{X}-\mu}{\sigma/\sqrt{n}}\right)^2 \perp \sum_{i=1}^n \frac{(X_i-\mu)^2}{\sigma^2} \\ \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1) \end{cases}$

即 $S^2 \sim \sigma^2 \frac{\chi^2(n-1)}{n-1}$

1.5 发生事件数的分布

考虑任意 n 个事件 $E_1, \dots, E_n$, 记这些事件中发生的个数为 X

对于任意 $1 \leq k \leq n$, 记所有 $\binom{n}{k}$ 组 k 个不同事件的交的概率之和为 $S_k = \sum_{i_1 < \dots < i_k} P(E_{i_1} \cdots E_{i_k})$

我们希望证明
$$\begin{cases} \text{pmf}(k) = P(X = k) = \sum_{j=k}^n (-1)^{j-k} \binom{j}{k} S_j \\ P(X \geq k) = \sum_{j=k}^n (-1)^{j-k} \binom{j-1}{k-1} S_j \end{cases}$$

(I) 证明 $P(X = k) = \sum_{j=k}^n (-1)^{k+j} \binom{j}{k} S_j$

我们固定 n 个事件中的 k 个, 记为 $E_{i_1}, \dots, E_{i_k}$

记这 k 个事件都发生的事件为 $A = \bigcap_{j \in \{i_1, \dots, i_k\}} E_j$

记其余 $n - k$ 个事件都不发生的事件为 $B = \bigcap_{j \in \{i_1, \dots, i_k\}} E_j^c$

于是我们可以用 AB 代表恰好只有 $E_{i_1}, \dots, E_{i_k}$ 发生的事件.

$$\begin{aligned} P(AB) &= P(A) - P(AB^c) \\ &= P(A) - P\left[A \left(\bigcup_{j \notin \{i_1, \dots, i_k\}} E_j \right)\right] \\ &= P(A) - P\left(\bigcup_{j \notin \{i_1, \dots, i_k\}} AE_j \right) \\ &= P(A) - \sum_{s=1}^{n-k} [(-1)^{s+1} \sum_{j_1 < \dots < j_s \notin \{i_1, \dots, i_k\}} P(AE_{j_1} \cdots E_{j_s})] \quad (\text{容斥原理}) \end{aligned}$$

在所有 k 个不同下标的集合上对上式求和可得:

$$\begin{aligned} P(X = k) &= \sum_{i_1 < \dots < i_k} P(E_{i_1} \cdots E_{i_k}) - \sum_{i_1 < \dots < i_k} \sum_{s=1}^{n-k} [(-1)^{s+1} \sum_{j_1 < \dots < j_s \notin \{i_1, \dots, i_k\}} P(E_{i_1} \cdots E_{i_k} \cdot E_{j_1} \cdots E_{j_s})] \\ &= S_k - \sum_{s=1}^{n-k} (-1)^{s+1} \left[\sum_{i_1 < \dots < i_k} \sum_{j_1 < \dots < j_s \notin \{i_1, \dots, i_k\}} P(E_{i_1} \cdots E_{i_k} \cdot E_{j_1} \cdots E_{j_s}) \right] \\ &= S_k - \sum_{s=1}^{n-k} (-1)^{s+1} \left[\binom{k+s}{k} \sum_{m_1 < \dots < m_{k+s}} P(E_{m_1} \cdots E_{m_{k+s}}) \right] \\ &= S_k - \sum_{s=1}^{n-k} (-1)^{s+1} \left[\binom{k+s}{k} S_{k+s} \right] \\ &= \sum_{s=0}^{n-k} (-1)^s \binom{k+s}{k} S_{k+s} \\ &= \sum_{j=k}^n (-1)^{j-k} \binom{j}{k} S_j \end{aligned}$$

(II) 数学归纳法证明 $P(X \geq k) = \sum_{j=k}^n (-1)^{j-k} \binom{j-1}{k-1} S_j$

- 当 $k = n$ 时, 根据 (I) 中的结论有 $P(X \geq n) = P(X = n) = S_n$
此时命题成立.
- 假设命题对 $k + 1$ 成立, 即 $P(X \geq k + 1) = \sum_{j=k+1}^n (-1)^{j-(k+1)} \binom{j-1}{(k+1)-1} S_j$
则有:

$$\begin{aligned} P(X \geq k) &= P(X = k) + P(X \geq k + 1) \\ &= \sum_{j=k}^n (-1)^{j-k} \binom{j}{k} S_j + \sum_{j=k+1}^n (-1)^{j-(k+1)} \binom{j-1}{(k+1)-1} S_j \\ &= S_k + \sum_{j=k+1}^n (-1)^{j-k} \left[\binom{j}{k} - \binom{j-1}{k} \right] S_j \\ &= S_k + \sum_{j=k+1}^n (-1)^{j-k} \binom{j-1}{k-1} S_j \\ &= \sum_{j=k}^n (-1)^{j-k} \binom{j-1}{k-1} S_j \end{aligned}$$

这样就完成了证明.

1.6 极限定理

1.6.1 Markov 不等式 & Chebyshev 不等式

统计学家只懂两种不等式，一是 Markov 不等式，二是 Chebyshev 不等式。

(Markov 不等式)

若 X 为非负随机向量，且 $-\infty < \mathbb{E}(X) < \infty$ ，
则对于任意 $a > 0$ 都有 $P\{X \geq a\} \leq \frac{\mathbb{E}[X]}{a}$ 成立。

证明：

- 我们首先假设 X 为连续型随机变量，概率密度函数为 f ：

$$\begin{aligned}\mathbb{E}[X] &= \int_0^{\infty} x f(x) dx \\ &= \int_0^a x f(x) dx + \int_a^{\infty} x f(x) dx \\ &\geq \int_a^{\infty} x f(x) dx \\ &\geq \int_a^{\infty} a f(x) dx \\ &= a \int_a^{\infty} f(x) dx \\ &= a \cdot P\{X \geq a\}\end{aligned}$$

于是有 $P\{X \geq a\} \leq \frac{\mathbb{E}[X]}{a}$ 成立。

- 离散情况的证明十分类似，假设概率质量函数为 pmf：

$$\begin{aligned}\mathbb{E}[X] &= \sum_{x:\text{pmf}(x)>0} x \cdot \text{pmf}(x) \\ &= \sum_{\substack{x:\text{pmf}(x)>0 \\ 0 \leq x < a}} x \cdot \text{pmf}(x) + \sum_{\substack{x:\text{pmf}(x)>0 \\ x \geq a}} x \cdot \text{pmf}(x) \\ &\geq \sum_{\substack{x:\text{pmf}(x)>0 \\ x \geq a}} x \cdot \text{pmf}(x) \\ &\geq \sum_{\substack{x:\text{pmf}(x)>0 \\ x \geq a}} a \cdot \text{pmf}(x) \\ &= a \sum_{\substack{x:\text{pmf}(x)>0 \\ x \geq a}} \text{pmf}(x) \\ &= a \cdot P\{X \geq a\}\end{aligned}$$

作为 Markov 不等式的直接推论，我们有：

- 命题 (Chernoff 不等式)**

若 X 为非负随机向量，且矩母函数 $M_X(t)$ 存在，
则对于任意 $a > 0$ 都有 $P(X \geq a) \leq \inf_{t>0} M_X(t)e^{-at}$ 成立。

证明：

任意给定 $a > 0$

对于任意 $t > 0$ ， e^{tX} 都是非负随机变量，因此对其应用 Markov 不等式可得：

$$\begin{aligned}P(X \geq a) &= P(e^{tX} \geq e^{ta}) \\ &\leq \frac{\mathbb{E}[e^{tX}]}{e^{ta}} \quad (\text{Markov Inequality}) \\ &= M_X(t)e^{-at}\end{aligned}$$

因此我们有：

$$P(X \geq a) \leq \inf_{t>0} M_X(t)e^{-at}$$

- (Chebyshev 不等式)**

若 X 是具有均值 μ 和 $k \geq 2$ 阶中心距 $\mathbb{E}[|X - \mu|^k] < \infty$ 的随机变量，
则对于任意 $a > 0$ 都有 $P\{|X - \mu| \geq a\} \leq \frac{\mathbb{E}[|X - \mu|^k]}{a^k}$ 成立。

证明:

由于 $|X - \mu|^k$ 是非负随机变量, 因此对其应用 Markov 不等式可得:

$$\begin{aligned} P\{|X - \mu| \geq a\} &= P\{|X - \mu|^k \geq a^k\} \\ &\leq \frac{\mathbb{E}[|X - \mu|^k]}{a^k} \quad (\text{Markov Inequality}) \end{aligned}$$

Markov 不等式和 Chebyshev 不等式的重要性在于:

在只有概率分布的均值 (或者均值、方差) 已知时, 它们能为我们提供待求概率的上界, 尽管这些上界可能不是非常紧, 但在许多情况下, 这些简单的工具足以提供有用的信息或证明. 当然, 如果真实分布已知, 那么我们直接精确计算待求概率就好了.

一个具体的例子:

设某工厂每日生产的产品数 (记为 X) 的均值是 500

- ① 估计某一天生产的产品数至少有 1000 的概率.

解: 由于 X 是非负随机变量, 故可应用 Markov 不等式,

有 $P\{X \geq 1000\} \leq \frac{\mathbb{E}[X]}{1000} = \frac{500}{1000} = \frac{1}{2}$ 成立.

- ② 若今天生产的产品数的方差已知等于 100, 那么如何估计今天生产的产品数在 400 到 600 之间的概率?

解: 应用 Chebyshev 不等式, 可得:

$$\begin{aligned} P\{|X - 500| \geq 100\} &\leq \frac{\text{Var}(X)}{100^2} \\ &= \frac{100}{100^2} \\ &= \frac{1}{100} \end{aligned}$$

因此:

$$\begin{aligned} P\{400 < X < 600\} &= 1 - P\{|X - 500| \geq 100\} \\ &\geq 1 - \frac{1}{100} \\ &= \frac{99}{100} \end{aligned}$$

1.6.2 随机变量序列的收敛性

(1) 依分布收敛 (Convergence in Distribution)

(依分布收敛 & 弱收敛)

设随机变量序列 $\{X_n\}$ 的分布函数序列为 $\{F_n\}$, 随机变量 X 的分布函数为 F

若对于 F 的任意连续点 x (即我们不考虑间断点), 都有 $\lim_{n \rightarrow \infty} F_n(x) = F(x)$ 成立

则称分布函数序列 $\{F_n\}$ **弱收敛**于 F , 记为 $F_n \xrightarrow{w} F$

也称随机变量序列 $\{X_n\}$ **依分布收敛**于 X , 记为 $X_n \xrightarrow{d} X$

(它之所以称为弱收敛, 是因为它比逐点收敛要弱一些)

(2) 依概率收敛 (Convergence in Probability)

(依概率收敛)

设 $\{X_n\}$ 为一个随机变量序列, X 为一个随机变量

若对于任意 $\varepsilon > 0$ 都有 $\lim_{n \rightarrow \infty} P(|X_n - X| > \varepsilon) = 0$

则称序列 $\{X_n\}$ 依概率收敛于 X , 记作 $X_n \xrightarrow{p} X$

特别地, 当 X 退化为常数 c 处的单点分布 (即 $P(X = c) = 1$) 时,

则称序列 $\{X_n\}$ 收敛于常数 c , 记作 $X_n \xrightarrow{p} c$

- **依概率收敛**是一种比**依分布收敛**更强的收敛性, 即 $X_n \xrightarrow{p} X \Rightarrow X_n \xrightarrow{d} X$

证明:

设随机变量序列 $\{X_n\}$ 的分布函数序列为 $\{F_n\}$, 随机变量 X 的分布函数为 F

假设 $X_n \xrightarrow{p} X$, 我们要证明 $X_n \xrightarrow{d} X$, 即要证 $F_n \xrightarrow{w} F$

只需证明:

对于任意 $x \in \mathbb{R}$ 都有 $F(x-0) \leq \liminf_{n \rightarrow \infty} F_n(x) \leq \overline{\lim}_{n \rightarrow \infty} F_n(x) \leq F(x+0)$ (*) 成立.

因为若上式成立,

则当 x 为 F 的连续点时, 有 $F(x-0) = F(x+0)$, 进而有 $\lim_{n \rightarrow \infty} F_n(x) = F(x)$ 成立,

即可得 $F_n \xrightarrow{w} F$

为证明 (*) 式成立, 不妨取 $x' < x$, 则有:

$$\begin{aligned} \{X \leq x'\} &= \{X \leq x', X_n \leq x\} \cup \{X \leq x', X_n > x\} \\ &\subset \{X_n \leq x\} \cup \{|X_n - X| > x - x'\} \end{aligned}$$

从而有 $F(x') \leq F_n(x) + P(|X_n - X| > x - x')$

由 $X_n \xrightarrow{p} X$ 可知 $\lim_{n \rightarrow \infty} P(|X_n - X| > x - x') = 0$

故有 $F(x') \leq \liminf_{n \rightarrow \infty} F_n(x)$

再令 $x' \rightarrow x$, 即有 $F(x-0) \leq \liminf_{n \rightarrow \infty} F_n(x)$

同理可证 $\overline{\lim}_{n \rightarrow \infty} F_n(x) \leq F(x+0)$

因此对于任意 $x \in \mathbb{R}$ 都有 $F(x-0) \leq \liminf_{n \rightarrow \infty} F_n(x) \leq \overline{\lim}_{n \rightarrow \infty} F_n(x) \leq F(x+0)$ (*) 成立.

进而得证 $F_n \xrightarrow{w} F$, 即 $X_n \xrightarrow{d} X$

- **上述命题的逆命题不成立**, 即 $X_n \xrightarrow{d} X \not\Rightarrow X_n \xrightarrow{p} X$

这说明一般情况下, 依概率收敛、依分布收敛是不等价的.

一个具体的例子:

设随机变量 $X \sim N(0, 1)$

显然随机变量序列 $\{X_n = -X\}$ 的每一项都与 X 同分布, 于是有 $X_n \xrightarrow{d} X$

但对于任意给定的 $\varepsilon > 0$ 和任意 $n = 1, 2, \dots$,

$$P(|X_n - X| > \varepsilon) = P(2|X| > \varepsilon)$$

$$= P(|X| > \frac{\varepsilon}{2})$$

$$\neq 0$$

$$\text{因此 } \lim_{n \rightarrow \infty} P(|X_n - X| > \varepsilon) = P(|X| > \frac{\varepsilon}{2}) \neq 0$$

说明 $X_n \not\xrightarrow{p} X$

- 当极限随机变量 X 退化为单点分布时, 依分布收敛等价于依概率收敛.

即若 c 为常数, 则 $X_n \xrightarrow{d} c$ 等价于 $X_n \xrightarrow{p} c$

证明:

必要性已由上一个命题给出, 下证充分性:

记随机变量序列 $\{X_n\}$ 的分布函数序列为 $\{F_n\}$

假设 $X_n \xrightarrow{d} c$, 则根据定义可知 $F_n \xrightarrow{w} F$, 其中 $F(x) = \begin{cases} 0, & x < c \\ 1, & x \geq c \end{cases}$

所有对于任意 $\varepsilon > 0$ 都有:

$$\begin{aligned} P(|X_n - c| > \varepsilon) &= P(X_n > c + \varepsilon) + P(X_n < c - \varepsilon) \\ &\leq P(X_n > c + \frac{\varepsilon}{2}) + P(X_n \leq c - \frac{\varepsilon}{2}) \\ &= 1 - F_n(c + \frac{\varepsilon}{2}) + F_n(c - \frac{\varepsilon}{2}) \end{aligned}$$

由于 $c + \frac{\varepsilon}{2}$ 和 $c - \frac{\varepsilon}{2}$ 均为 F 的连续点,

因此根据 $F_n \xrightarrow{w} F$ 有 $\begin{cases} \lim_{n \rightarrow \infty} F_n(c + \frac{\varepsilon}{2}) = F(c + \frac{\varepsilon}{2}) = 1 \\ \lim_{n \rightarrow \infty} F_n(c - \frac{\varepsilon}{2}) = F(c - \frac{\varepsilon}{2}) = 0 \end{cases}$

于是 $\lim_{n \rightarrow \infty} P(|X_n - c| > \varepsilon) = 0$

即有 $X_n \xrightarrow{p} c$, 命题得证.

(3) k -阶矩收敛 (Convergence in the k -th Moment)

(k -阶矩收敛)

若随机变量序列 $\{X_n\}$ 和随机变量 X 满足 $\lim_{n \rightarrow \infty} \mathbb{E}[|X_n - X|^k] = 0$ (其中 $k \in \mathbb{N}_+$),

则称 $\{X_n\}$ k -阶矩收敛于 X , 记为 $X_n \xrightarrow{L_k} X$

特殊地, 若 $k = 2$, 则称为均方收敛, 记为 $X_n \xrightarrow{L_2} X$

- **k -阶矩收敛**是一种比**依概率收敛**更强的收敛性, 即 $X_n \xrightarrow{L_k} X \Rightarrow X_n \xrightarrow{p} X$

证明:

假设 $X_n \xrightarrow{L_k} X$ 成立

对于任意给定的 $\varepsilon > 0$, 根据 Markov 不等式可知:

$$\begin{aligned} P(|X_n - X| > \varepsilon) &= P(|X_n - X|^k > \varepsilon^k) \\ &\leq \frac{\mathbb{E}[|X_n - X|^k]}{\varepsilon^k} \rightarrow 0 \quad (n \rightarrow \infty) \end{aligned}$$

说明有 $X_n \xrightarrow{p} X$ 成立, 命题得证.

- **上述命题的逆命题不成立**, 即 $X_n \xrightarrow{p} X \not\Rightarrow X_n \xrightarrow{L_k} X$

这说明**一般情况下, k -阶矩收敛、依概率收敛是不等价的**.

一个具体的例子:

设 $U \sim \text{Uniform}(0, 1)$, 记 $X_n = \sqrt{n} I_{(0, \frac{1}{n})}(U) = \begin{cases} \sqrt{n}, & U \in (0, \frac{1}{n}) \\ 0, & \text{otherwise} \end{cases} \quad (\forall n = 1, 2, \dots)$

对于任意给定的 $\varepsilon > 0$, 都存在正整数 $N = \lceil \varepsilon^2 \rceil$ 使得对于任意 $n \geq N$ 都有:

$$\begin{aligned} P(|X_n| > \varepsilon) &= P(\sqrt{n} I_{(0, \frac{1}{n})}(U) > \varepsilon) \\ &= P(0 < U < \frac{1}{n}) \\ &= \frac{1}{n} \rightarrow 0 \quad (n \rightarrow \infty) \end{aligned}$$

因此 $\lim_{n \rightarrow \infty} P(|X_n| > \varepsilon) = 0$, 说明 $X_n \xrightarrow{p} 0$

但是对于任意 $n = 1, 2, \dots$ 都有 $\mathbb{E}[|X_n|^k] = \int_0^{\frac{1}{n}} (\sqrt{n})^k dx = n^{\frac{k}{2}} \cdot \frac{1}{n} = n^{\frac{k}{2}-1}$

因此 $\lim_{n \rightarrow \infty} \mathbb{E}[|X_n|^k] = \lim_{n \rightarrow \infty} n^{\frac{k}{2}-1} = \begin{cases} 0, & \text{if } k = 1 \\ 1, & \text{if } k = 2 \\ \infty, & \text{if } k = 3, 4, \dots \end{cases}$

说明除了 $X_n \xrightarrow{L_1} X$ 成立以外, 对于任意 $k = 2, 3, \dots$, k -阶矩收敛都不成立, 即 $X_n \not\xrightarrow{L_k} X \quad (k \geq 2)$

- (**k -阶矩收敛的性质**)

- 若 $\begin{cases} X_n \xrightarrow{p} X \\ X_n \xrightarrow{p} Y \end{cases}$, 则有 $X \stackrel{\text{a.s.}}{=} Y$

根据上一个命题得到推论: 若 $\begin{cases} X_n \xrightarrow{L_k} X \\ X_n \xrightarrow{L_k} Y \end{cases}$, 则有 $X \stackrel{\text{a.s.}}{=} Y$

- 若 $X_n \xrightarrow{p} X$, 且存在常数 $M > 0$ 使得 $|X_n| \stackrel{\text{a.s.}}{\leq} M$, 则有 $X_n \xrightarrow{L_k} X$ 成立.
- 若 $X_n \xrightarrow{L_k} X$, 则 $\lim_{n \rightarrow \infty} \mathbb{E}[X_n] = \mathbb{E}[X]$

- (**随机变量序列收敛性的变换规则**)

设 $\{X_n\}, \{Y_n\}$ 为随机变量序列, X, Y 为随机变量.

- ① **加减:**

- 若 $\begin{cases} X_n \xrightarrow{L_k} X \\ Y_n \xrightarrow{L_k} Y \end{cases}$, 则 $X_n \pm Y_n \xrightarrow{L_k} X \pm Y$

- 若 $\begin{cases} X_n \xrightarrow{p} X \\ Y_n \xrightarrow{p} Y \end{cases}$, 则 $X_n \pm Y_n \xrightarrow{p} X \pm Y$

- 若 $\begin{cases} X_n \xrightarrow{d} X \\ Y_n \xrightarrow{d} c \quad (\text{i.e. } Y_n \xrightarrow{p} c) \end{cases}$, 则 $X_n \pm Y_n \xrightarrow{d} X \pm c$ (Slutzky)

一般来说, 对于依分布收敛, $\begin{cases} X_n \xrightarrow{d} X \\ Y_n \xrightarrow{d} Y \end{cases} \not\Rightarrow X_n \pm Y_n \xrightarrow{d} X \pm Y$

◦ ② 乘除:

- 若 $\begin{cases} X_n \xrightarrow{p} X \\ Y_n \xrightarrow{p} Y \end{cases}$, 则 $X_n Y_n \xrightarrow{p} XY$
当 $Y \neq 0$ 时, 进一步成立 $\frac{X_n}{Y_n} \xrightarrow{p} \frac{X}{Y}$
- 若 $\begin{cases} X_n \xrightarrow{d} X \\ Y_n \xrightarrow{d} c \text{ (i.e. } Y_n \xrightarrow{p} c) \end{cases}$, 则 $X_n Y_n \xrightarrow{d} cX$ (Slutzky)
当 $c \neq 0$ 时, 进一步成立 $\frac{X_n}{Y_n} \xrightarrow{d} \frac{X}{c}$
一般来说, 对于依分布收敛, $\begin{cases} X_n \xrightarrow{d} X \\ Y_n \xrightarrow{d} Y \end{cases} \not\Rightarrow X_n Y_n \xrightarrow{d} XY$

◦ ③ 对于连续函数 g :

- 若 $X_n \xrightarrow{p} X$, 则 $g(X_n) \xrightarrow{p} g(X)$
- 若 $X_n \xrightarrow{d} X$, 则 $g(X_n) \xrightarrow{d} g(X)$

(4) 几乎处处收敛 (Almost Sure Convergence)

(几乎处处收敛)

若随机变量序列 $\{X_n\}$ 和随机变量 X 满足 $\lim_{n \rightarrow \infty} P(X_n = X) = 1$,

则称 $\{X_n\}$ **几乎处处收敛** 于 X , 记作 $X_n \xrightarrow{\text{a.s.}} X$ (又称为**依概率 1 收敛**)

• **等价定义:**

若存在零概率事件 $\Omega_0 \in \Omega$ ($P(\Omega_0) = 0$),

使得对于任意事件 $\omega \in \Omega \setminus \Omega_0$ 都有 $\lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)$ (数列收敛) 成立,

则称 $\{X_n\}$ **几乎处处收敛** 于 X , 记作 $X_n \xrightarrow{\text{a.s.}} X$

(几乎处处收敛的充要条件)

$X_n \xrightarrow{\text{a.s.}} X$ 当且仅当对于任意 $\varepsilon > 0$

都有 $\lim_{N \rightarrow \infty} P\{\omega \in \Omega : \sup_{n \geq N} |X_n(\omega) - X(\omega)| > \varepsilon\} = \lim_{N \rightarrow \infty} P\{\bigcup_{n=N}^{\infty} \{|X_n - X| > \varepsilon\}\} = 0$ 成立.

证明:

- 对于任意给定的 $\omega \in \Omega$, $\lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)$ (收敛) 意味着:
对于任意 $\varepsilon > 0$, 都存在 $N \in \mathbb{N}_+$ 使得对于任意 $n > N$ 都有 $|X_n(\omega) - X(\omega)| \leq \varepsilon$ 成立
即事件 $\bigcap_{\varepsilon > 0} \bigcup_{N \in \mathbb{N}_+} \bigcap_{n > N} \{|X_n(\omega) - X(\omega)| \leq \varepsilon\}$ 成立
- 相反地, 对于任意给定的 $\omega \in \Omega$, $\{X_n(\omega)\}$ **不收敛** 到 $X(\omega)$ 意味着:
存在 $\varepsilon_0 > 0$, 对于任意 $N \in \mathbb{N}_+$ 都存在 $n_0 > N$ 使得 $|X_{n_0}(\omega) - X(\omega)| > \varepsilon_0$ 成立
即事件 $\bigcup_{\varepsilon > 0} \bigcap_{N \in \mathbb{N}_+} \bigcup_{n > N} \{|X_n(\omega) - X(\omega)| > \varepsilon\}$ 成立
- 因此 $X_n \xrightarrow{\text{a.s.}} X$ 等价于 $P\{\omega \in \Omega : \bigcup_{\varepsilon > 0} \bigcap_{N \in \mathbb{N}_+} \bigcup_{n > N} \{|X_n(\omega) - X(\omega)| > \varepsilon\}\} = 0$
 - 对于任意给定的 $\varepsilon > 0$, 记 $E_\varepsilon = \{\omega \in \Omega : \bigcap_{N \in \mathbb{N}_+} \bigcup_{n > N} \{|X_n(\omega) - X(\omega)| > \varepsilon\}\}$
易知对于任意 $0 < \varepsilon_1 < \varepsilon_2$ 都有 $E_{\varepsilon_1} \supset E_{\varepsilon_2}$ 成立
因此 $P\{\bigcup_{\varepsilon > 0} E_\varepsilon\} = 0$ 等价于 $\lim_{\varepsilon \rightarrow 0} P\{E_\varepsilon\} = 0$
也就是说, 对于任意 $\varepsilon > 0$ 都有 $P\{E_\varepsilon\} = P\{\omega \in \Omega : \bigcap_{N \in \mathbb{N}_+} \bigcup_{n > N} \{|X_n(\omega) - X(\omega)| > \varepsilon\}\} = 0$
 - 对于任意给定的 $N \in \mathbb{N}_+$, 记 $E_N = \{\omega \in \Omega : \bigcup_{n > N} \{|X_n(\omega) - X(\omega)| > \varepsilon\}\}$
易知对于任意 $N_1 < N_2 \in \mathbb{N}_+$ 都有 $E_{N_1} \supset E_{N_2}$ 成立
因此 $P\{E_\varepsilon\} = P\{\bigcap_{N \in \mathbb{N}_+} E_N\} = 0$ 等价于:

$$\begin{aligned} \lim_{N \rightarrow \infty} P\{E_N\} &= P\{\omega \in \Omega : \bigcup_{n > N} \{|X_n(\omega) - X(\omega)| > \varepsilon\}\} \\ &= \lim_{N \rightarrow \infty} P\{\bigcup_{n=N}^{\infty} \{|X_n - X| > \varepsilon\}\} \\ &= 0 \end{aligned}$$

这就说明了 $X_n \xrightarrow{\text{a.s.}} X$ 等价于对于任意 $\varepsilon > 0$ 都有 $\lim_{N \rightarrow \infty} P\{\bigcup_{n=N}^{\infty} \{|X_n - X| > \varepsilon\}\} = 0$ 成立.

命题得证.

推论: (几乎处处收敛的充分条件)

若对于任意 $\varepsilon > 0$, 正项级数 $\sum_{n=1}^{\infty} P(|X_n - X| > \varepsilon) < +\infty$, 则 $X_n \xrightarrow{\text{a.s.}} X$

证明:

对于任意 $\varepsilon > 0$, 正项级数 $\sum_{n=1}^{\infty} P(|X_n - X| > \varepsilon) < +\infty$

等价于 $\lim_{N \rightarrow \infty} \sum_{n=N}^{\infty} P\{|X_n - X| > \varepsilon\} = 0$

注意到: 对于任意 $N \in \mathbb{N}_+$ 都有 $P\{\bigcup_{n=N}^{\infty} \{|X_n - X| > \varepsilon\}\} \leq \sum_{n=N}^{\infty} P\{|X_n - X| > \varepsilon\}$ 成立

因此有 $\lim_{N \rightarrow \infty} P\{\bigcup_{n=N}^{\infty} \{|X_n - X| > \varepsilon\}\} = 0$ 成立.

根据几乎处处收敛的充要条件可知 $X_n \xrightarrow{\text{a.s.}} X$, 推论得证.

1.6.3 极限定理

(独立同分布 Bernoulli 随机变量序列的极限定理)

设 $\{X_n\}$ 是一列独立同分布的 Bernoulli 随机变量, 即 $\{X_n\} \stackrel{\text{iid}}{\sim} B(1, p)$ (其中 $0 < p < 1$)

记它们的部分和为 $S_n = \sum_{i=1}^n X_i \sim B(n, p)$, 记样本均值 $\bar{X}_n = \frac{S_n}{n}$, 则有:

- ① (Borel 强大数定律):

部分和 S_n 的样本均值 $\bar{X}_n = \frac{S_n}{n} \xrightarrow{\text{a.s.}} p$ (频率收敛到概率)

◦ **证明:**

我们利用几乎处处收敛的充分条件进行证明, 即要证 $\sum_{n=1}^{\infty} P(|\frac{S_n}{n} - p| > \varepsilon) < +\infty$

也即要证 $\sum_{n=1}^{\infty} P(|\sum_{i=1}^n (X_i - p)| > n\varepsilon) < +\infty$

令 $Z_i := X_i - p$ (中心化), 则 $Z_1, Z_2, \dots$ 独立同分布, 且 $Z_i = \begin{cases} 1-p, & p \\ -p, & (1-p) \end{cases}$

于是问题转化为证明 $\sum_{n=1}^{\infty} P(|\sum_{i=1}^n Z_i| > n\varepsilon) < +\infty$

中心化的 Bernoulli 随机变量 Z_i 的性质相当好, 其任意阶中心矩都是有限的,

即对于任意 $k = 1, 2, \dots$ 都有:

$$\mathbb{E}[Z_i^k] \leq \mathbb{E}[|Z_i|^k] = (1-p)^k p + p^k (1-p) < p + (1-p) = 1$$

在这里, 我们只需要使用 **Chebyshev 不等式** 将上界放到四阶中心矩即可:

对于任意 $n = 1, 2, \dots$ 都有:

$$\begin{aligned} P(|\sum_{i=1}^n Z_i| > n\varepsilon) &\leq \frac{\mathbb{E}[|\sum_{i=1}^n Z_i - 0|^4]}{(n\varepsilon)^4} \quad (\text{Chebyshev Inequality}) \\ &= \frac{1}{n^4 \varepsilon^4} \mathbb{E}[(\sum_{i=1}^n Z_i)^4] \\ &= \frac{1}{n^4 \varepsilon^4} \mathbb{E}[\sum_{i,j,k,l}^n Z_i Z_j Z_k Z_l] \\ &= \frac{1}{n^4 \varepsilon^4} \sum_{i,j,k,l}^n \mathbb{E}[Z_i Z_j Z_k Z_l] \quad (\mathbb{E}[Z_i] = 0 \text{ for all } i = 1, \dots, n) \\ &= \frac{1}{n^4 \varepsilon^4} \{0 + \sum_{i \neq j}^n \mathbb{E}[Z_i^2] \cdot \mathbb{E}[Z_j^2] + \sum_{i=1}^n \mathbb{E}[Z_i^4]\} \\ &< \frac{1}{n^4 \varepsilon^4} \{2 \binom{n}{2} (1 \cdot 1) + n \cdot 1\} \\ &= O(\frac{1}{n^2}) \end{aligned}$$

这说明 $P(|\sum_{i=1}^n Z_i| > n\varepsilon)$ 是一个 $O(\frac{1}{n^2})$ 的量,

因此有 $\sum_{n=1}^{\infty} P(|\sum_{i=1}^n Z_i| > n\varepsilon) = O(\frac{1}{n}) < +\infty$ 成立

这就证明了 $\frac{S_n}{n} \xrightarrow{a.s.} p$ (频率收敛到概率)

• ② (De Moivre-Laplace 中心极限定理):

部分和 S_n 经过中心化、标准化后有 $\frac{S_n - np}{\sqrt{np(1-p)}} \xrightarrow{d} N(0, 1)$ (即 $\frac{\bar{X}_n - p}{\sqrt{p(1-p)/n}} \xrightarrow{d} N(0, 1)$)

(其证明过程包含在 Feller-Lévy 中心极限定理的证明之中)

(小概率事件的 Poisson 极限定理)

- 若实数序列 $\{p_n\}$ 满足
$$\begin{cases} p_n \in [0, 1] & (\forall n = 1, 2, \dots) \\ \lim_{n \rightarrow \infty} p_n = 0 \\ \lim_{n \rightarrow \infty} n \cdot p_n = \lambda > 0 \end{cases}$$

则对于任意整数 $0 \leq k \leq n$, 都有 $\lim_{n \rightarrow \infty} \binom{n}{k} p_n^k (1 - p_n)^{n-k} = e^{-\lambda} \frac{\lambda^k}{k!}$ 成立.

- 推广:** 对于任意给定的 $n = 1, 2, \dots$

设 n 个相互独立的 Bernoulli 随机变量 $X_1^{(n)}, \dots, X_n^{(n)}$ 分别服从 $B(1, p_1^{(n)}), \dots, B(1, p_n^{(n)})$

记 $S_n = \sum_{k=1}^n X_k^{(n)}$

若有
$$\begin{cases} \lim_{n \rightarrow \infty} \sup_{1 \leq k \leq n} p_k^{(n)} = 0 \\ \lim_{n \rightarrow \infty} \sum_{k=1}^n p_k^{(n)} = \lambda > 0 \end{cases}$$

则有 $S_n \xrightarrow{d} \text{Poisson}(\lambda)$ 成立.

(弱相关随机变量序列的 Markov 弱大数定律)

给定随机变量序列 $\{X_n\}$, 记部分和 $S_n = \sum_{i=1}^n X_i$

若 Markov 条件成立, 即 $\lim_{n \rightarrow \infty} \frac{\text{Var}(S_n)}{n^2} = 0$,

则有 $\frac{S_n - \mathbb{E}[S_n]}{n} \xrightarrow{P} 0$ (即 $\frac{S_n}{n} \xrightarrow{P} \frac{\mathbb{E}(S_n)}{n}$)

• 证明:

要证明 $\frac{S_n - \mathbb{E}[S_n]}{n} \xrightarrow{P} 0$, 即要证对于任意 $\varepsilon > 0$ 都有 $\lim_{n \rightarrow \infty} P\{|\frac{S_n - \mathbb{E}[S_n]}{n}| > \varepsilon\} = 0$ 成立.

对于任意 $\varepsilon > 0$ 都有:

$$\begin{aligned} P\{|\frac{S_n - \mathbb{E}[S_n]}{n}| > \varepsilon\} &= P\{|S_n - \mathbb{E}[S_n]| > n\varepsilon\} \\ &\leq \frac{\mathbb{E}[|S_n - \mathbb{E}[S_n]|^2]}{(n\varepsilon)^2} \\ &= \frac{\text{Var}(S_n)}{n^2 \varepsilon^2} \rightarrow 0 \quad (n \rightarrow \infty) \end{aligned}$$

命题得证.

• 理解 Markov 条件:

$$\begin{aligned} \frac{\text{Var}(S_n)}{n^2} &= \frac{1}{n^2} \text{Var}\left(\sum_{i=1}^n X_i\right) \\ &= \frac{1}{n^2} \left\{ \sum_{i=1}^n \text{Var}(X_i) + \sum_{i \neq j}^n \text{Cov}(X_i, X_j) \right\} \end{aligned}$$

因此 $\lim_{n \rightarrow \infty} \frac{\text{Var}(S_n)}{n^2} = 0$ 意味着:

如果我们限定随机变量序列 $\{X_i\}$ 每一项的方差都有限,

(即 $\text{Var}(X_i) < \infty$ for all $i = 1, 2, \dots$, 也即 $\begin{cases} \mathbb{E}[X_i^2] < \infty \\ -\infty < \mathbb{E}[X_i] < \infty \end{cases}$ for all $i = 1, 2, \dots$)

那么 Markov 条件将限制协方差 $\text{Cov}(X_i, X_j) = o(1) < \infty$ for all $i \neq j = 1, 2, \dots$

也就是说, 任意两个不同项之间的协方差都比常数阶小, 即所谓 "弱相关性"

(独立同分布随机变量序列的极限定理)

设 $X_1, X_2, \dots$ 是一列独立同分布的随机变量,

记部分和为 $S_n = \sum_{i=1}^n X_i$, 记样本均值 $\bar{X}_n = \frac{S_n}{n}$, 则有:

• ① (Khinchin 弱大数定律):

当且仅当对于任意 $i = 1, 2, \dots$ 都有 $\mathbb{E}[X_i] = \mu < \infty$ 时, 有 $\bar{X}_n = \frac{S_n}{n} \xrightarrow{P} \mu = \mathbb{E}[\frac{S_n}{n}]$ 成立

◦ 证明:

要证明 $\frac{S_n}{n} \xrightarrow{P} \mu$, 等价于证明 $\frac{S_n}{n} \xrightarrow{d} \mu$ 成立,

即等价于证明当 $n \rightarrow \infty$ 时,

$\frac{S_n}{n}$ 的特征函数 $\varphi_n(t) = \mathbb{E}[e^{it\frac{S_n}{n}}]$ 弱收敛于单点分布 μ 的特征函数 $\mathbb{E}[e^{it\mu}] = e^{it\mu}$

即要说明对于任意 $t \in \mathbb{R}$ (特征函数在整个 $\mathbb{R}$ 上连续) 都有 $\lim_{n \rightarrow \infty} \varphi_n(t) = e^{it\mu}$ 成立.

$$\begin{aligned}\varphi_n(t) &= \mathbb{E}[e^{it\frac{S_n}{n}}] \\ &= \mathbb{E}\left[\exp\left\{i\frac{t}{n}\sum_{j=1}^n X_j\right\}\right] \quad (X_i \perp X_j \text{ for all } i \neq j = 1, 2, \dots) \\ &= \prod_{j=1}^n \mathbb{E}\left[\exp\left\{i\frac{t}{n}X_j\right\}\right]\end{aligned}$$

由于 $\{X_n\}$ 独立同分布, 故它们拥有相同的特征函数, 记为 $\varphi(t)$, 于是有 $\varphi_n(t) = [\varphi(\frac{t}{n})]^n$

下面计算 $\varphi(t) = \mathbb{E}[e^{itX}]$ 在 $t = 0$ 处的一阶 Taylor 展开式:

根据 $\begin{cases} \varphi(0) = \mathbb{E}[e^{itX}]|_{t=0} = \mathbb{E}[0] = 0 \\ \varphi'(0) = \mathbb{E}[e^{itX}iX]|_{t=0} = i\mathbb{E}[X] = i\mu \end{cases}$ 可知 $\varphi(t) = 1 + i\mu t + o(t)$

因此对于任意 $t \in \mathbb{R}$ 都有:

$$\begin{aligned}\lim_{n \rightarrow \infty} \varphi_n(t) &= \lim_{n \rightarrow \infty} \left[\varphi\left(\frac{t}{n}\right)\right]^n \\ &= \lim_{n \rightarrow \infty} \left[1 + i\mu\frac{t}{n} + o\left(\frac{t}{n}\right)\right]^n \\ &= \lim_{n \rightarrow \infty} \left(1 + \frac{i\mu t}{n}\right)^n \\ &= e^{i\mu t}\end{aligned}$$

命题得证.

• ② (Kolmogorov 强大数定律):

当且仅当对于任意 $i = 1, 2, \dots$ 都有 $\begin{cases} \mathbb{E}[|X_i|] < \infty \\ \mathbb{E}[X_i] = \mu \end{cases}$ 时, 有 $\bar{X}_n = \frac{S_n}{n} \xrightarrow{\text{a.s.}} \mu = \mathbb{E}[\frac{S_n}{n}]$ 成立

• ③ (Feller-Lévy 中心极限定理):

当且仅当对于任意 $n = 1, 2, \dots$ 都有 $\begin{cases} 0 < \text{Var}[X_n] = \sigma^2 < \infty \\ -\infty < \mathbb{E}[X_n] = \mu < \infty \end{cases}$ 时,

有 $\frac{S_n - \mathbb{E}[S_n]}{\sqrt{\text{Var}(S_n)}} = \frac{S_n - n\mu}{\sqrt{n\sigma^2}} \xrightarrow{d} N(0, 1)$ 成立 (即 $\frac{\bar{X}_n - \mu}{\sqrt{\sigma^2/n}} \xrightarrow{d} N(0, 1)$)

◦ 证明:

要证明 $\frac{S_n - n\mu}{\sqrt{n\sigma^2}} \xrightarrow{d} N(0, 1)$, 等价于证明当 $n \rightarrow \infty$ 时,

$\frac{S_n - n\mu}{\sqrt{n\sigma^2}}$ 的特征函数 $\varphi_n(t) = \mathbb{E}[e^{it\frac{S_n - n\mu}{\sqrt{n\sigma^2}}}]$ 弱收敛于标准正态分布 $N(0, 1)$ 的特征函数 $e^{\frac{1}{2}(it)^2} = e^{-\frac{1}{2}t^2}$

即要说明对于任意 $t \in \mathbb{R}$ (特征函数在整个 $\mathbb{R}$ 上连续) 都有 $\lim_{n \rightarrow \infty} \varphi_n(t) = e^{-\frac{1}{2}t^2}$ 成立.

记 $Z_i := \frac{X_i - \mu}{\sigma}$, 则有 $\frac{S_n - n\mu}{\sqrt{n\sigma^2}} = \frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n\sigma^2}} = \frac{1}{\sqrt{n}} \sum_{i=1}^n \frac{X_i - \mu}{\sigma} = \frac{1}{\sqrt{n}} \sum_{i=1}^n Z_i$

易知 $\{Z_i\}$ 独立同分布, 且 $\begin{cases} \mathbb{E}[Z_i] = 0 \\ \text{Var}[Z_i] = 1 \\ \mathbb{E}[Z_i^2] = 1 \end{cases}$ 它们拥有相同的特征函数, 记为 $\varphi(t)$

下面计算 $\varphi(t) = \mathbb{E}[e^{itZ}]$ 的二阶 Taylor 展开式:

根据 $\begin{cases} \varphi(0) = \mathbb{E}[e^0] = 1 \\ \varphi'(0) = \mathbb{E}[e^{itZ}iZ]|_{t=0} = i\mathbb{E}[Z] = 0 \\ \varphi''(0) = \mathbb{E}[e^{itZ}(iZ)^2]|_{t=0} = i^2\mathbb{E}[Z^2] = -1 \end{cases}$ 可知 $\varphi(t) = 1 - \frac{1}{2}t^2 + o(t^2)$

因此对于任意 $t \in \mathbb{R}$ 都有:

$$\begin{aligned}
\varphi_n(t) &= \mathbb{E}[e^{it \frac{S_n - n\mu}{\sqrt{n\sigma^2}}}] \\
&= \mathbb{E}[\exp\{i \frac{t}{\sqrt{n}} \sum_{i=1}^n Z_i\}] \quad (Z_i \perp Z_j \text{ for all } i \neq j = 1, 2, \dots) \\
&= \prod_{i=1}^n \mathbb{E}[e^{i \frac{t}{\sqrt{n}} Z_i}] \\
&= [\varphi(\frac{t}{\sqrt{n}})]^n \\
&= [1 - \frac{1}{2}(\frac{t}{\sqrt{n}})^2 + o((\frac{t}{\sqrt{n}})^2)]^n \\
&= [1 - \frac{t^2}{2n} + o(\frac{1}{n})]^n \rightarrow e^{-\frac{1}{2}t^2} \quad (n \rightarrow \infty)
\end{aligned}$$

命题得证.

(独立不同分布随机变量序列的极限定理)

设 $X_1, X_2, \dots$ 是一列独立的随机变量,

记部分和为 $S_n = \sum_{i=1}^n X_i$, 记样本均值 $\bar{X}_n = \frac{S_n}{n}$, 则有:

- ① (Kolmogorov 强大数定律的推广):

若 $\begin{cases} \mathbb{E}[X_k^2] < \infty \quad (\forall k = 1, 2, \dots) \\ \sum_{k=1}^{\infty} \frac{1}{k^2} \text{Var}[X_k] < \infty \end{cases}$, 则有 $\bar{X}_n - \mathbb{E}[\bar{X}_n] = \bar{X}_n - \frac{1}{n} \sum_{k=1}^n \mathbb{E}[X_k] \xrightarrow{\text{a.s.}} 0$

- ② (Lindeberg-Feller 中心极限定理):

记 $\begin{cases} \mu_i = \mathbb{E}(X_i) \quad (\forall i = 1, \dots, n) \\ \sigma_i^2 = \text{Var}(X_i) \quad (\forall i = 1, \dots, n) \\ V_n = \sqrt{\text{Var}(S_n)} = \sqrt{\sum_{i=1}^n \sigma_i^2} \end{cases}$

若 $\{X_n\}$ 满足 Lindeberg 条件,

即对于任意 $\varepsilon > 0$ 都有 $\lim_{n \rightarrow \infty} \frac{1}{(\varepsilon V_n)^2} \sum_{i=1}^n \int_{|x - \mu_i| > \varepsilon V_n} (x - \mu_i)^2 f_{X_i}(x) dx = 0$

则有 $\frac{S_n - \mathbb{E}(S_n)}{V_n} = \frac{S_n - \sum_{i=1}^n \mu_i}{\sqrt{\sum_{i=1}^n \sigma_i^2}} \xrightarrow{d} N(0, 1)$

- Lindeberg 条件的理解:

S_n 经过中心化、标准化后得到 $\frac{S_n - \mathbb{E}(S_n)}{V_n} = \sum_{i=1}^n \frac{X_i - \mu_i}{V_n}$

我们要求每一项 $\frac{X_i - \mu_i}{V_n}$ 均匀地小,

即对于任意 $\varepsilon > 0$, 要求 $\lim_{n \rightarrow \infty} P\{\sup_{1 \leq i \leq n} \frac{|X_i - \mu_i|}{V_n} > \varepsilon\} = \lim_{n \rightarrow \infty} P\{\sup_{1 \leq i \leq n} |X_i - \mu_i| > \varepsilon V_n\} = 0$

由于:

$$\begin{aligned}
P\{\sup_{1 \leq i \leq n} |X_i - \mu_i| > \varepsilon V_n\} &= P\{\bigcup_{i=1}^n (|X_i - \mu_i| > \varepsilon V_n)\} \\
&\leq \sum_{i=1}^n P\{|X_i - \mu_i| > \varepsilon V_n\} \\
&= \sum_{i=1}^n \int_{|x - \mu_i| > \varepsilon V_n} f_{X_i}(x) dx \\
&\leq \frac{1}{(\varepsilon V_n)^2} \sum_{i=1}^n \int_{|x - \mu_i| > \varepsilon V_n} (x - \mu_i)^2 f_{X_i}(x) dx
\end{aligned}$$

因此我们只要求 $\lim_{n \rightarrow \infty} \frac{1}{(\varepsilon V_n)^2} \sum_{i=1}^n \int_{|x - \mu_i| > \varepsilon V_n} (x - \mu_i)^2 f_{X_i}(x) dx = 0$

这就是 Lindeberg 条件.

Lindeberg 条件虽然比较一般, 但难以验证,

下面的 Lyapunov 条件则比较容易验证, 它只对矩提要求, 因而便于应用.

- ③ (Lyapunov 中心极限定理):

记 $\begin{cases} \mu_i = \mathbb{E}(X_i) \quad (\forall i = 1, \dots, n) \\ \sigma_i^2 = \text{Var}(X_i) \quad (\forall i = 1, \dots, n) \\ V_n = \sqrt{\text{Var}(S_n)} = \sqrt{\sum_{i=1}^n \sigma_i^2} \end{cases}$

若 $\{X_n\}$ 满足 Lyapunov 条件,

即存在 $\delta > 0$ 满足 $\lim_{n \rightarrow \infty} \frac{1}{V_n^{2+\delta}} \sum_{i=1}^n \mathbb{E}(|X_i - \mu_i|^{2+\delta}) = 0$

则有 $\frac{S_n - \mathbb{E}(S_n)}{V_n} = \frac{S_n - \sum_{i=1}^n \mu_i}{\sqrt{\sum_{i=1}^n \sigma_i^2}} \xrightarrow{d} N(0, 1)$

(其中 $\delta > 0$ 确保随机变量的高阶绝对中心矩 (比方差高的矩) 相对于它们方差的和增长得足够慢)

1.7 条件概率与条件期望

1.7.1 离散情形

对于任意两个事件 $E_1, E_2 \subseteq \Omega$

当 E_2 给定且 $P(E_2) > 0$ 时, E_1 的**条件概率**定义为 $P(E_1|E_2) = \frac{P(E_1 E_2)}{P(E_2)}$

若 X, Y 都是离散随机变量, 且具有联合概率质量函数 $p(x, y)$,

则对于所有使 $P(Y = y) > 0$ 的 y 值, 在 $Y = y$ 给定的条件下:

- 定义 X 的**条件概率质量函数**为:

$$\begin{aligned} p_{X|Y}(x|y) &= P\{X = x|Y = y\} \\ &= \frac{P\{X = x, Y = y\}}{P\{Y = y\}} \\ &= \frac{p(x, y)}{p_Y(y)} \end{aligned}$$

- 定义 X 的**条件概率分布函数**为:

$$\begin{aligned} F_{X|Y}(x|y) &= P\{X \leq x | Y = y\} \\ &= \sum_{a \leq x} p_{X|Y}(a|y) \end{aligned}$$

- 定义 X 的**条件期望**为:

$$\begin{aligned} \mathbb{E}[X|Y = y] &= \sum_x x \cdot P\{X = x|Y = y\} \\ &= \sum_x x \cdot p_{X|Y}(x|y) \end{aligned}$$

条件期望具有一般期望的一切性质, 诸如 $\begin{cases} \mathbb{E}[\sum_{i=1}^n X_i|Y = y] = \sum_{i=1}^n \mathbb{E}[X_i|Y = y] \\ \mathbb{E}[h(X)|Y = y] = \sum_x h(x) \cdot p_{X|Y}(x|y) \end{cases}$

- 定义 X 的**条件方差**为:

$$\begin{aligned} \text{Var}(X|Y = y) &= \mathbb{E}[(X - \mathbb{E}[X|Y = y])^2|Y = y] \\ &= \mathbb{E}[X^2|Y = y] - (\mathbb{E}[X|Y = y])^2 \end{aligned}$$

换句话说, 除了给定事件 $Y = y$ 以外, 定义恰如以前所述.

如果 X, Y 独立, 那么条件概率质量函数、条件概率分布函数、条件期望、条件方差都与无条件时一样.

两个具体的例子:

- 给定 $\begin{cases} X_1 \sim B(n_1, p) \\ X_2 \sim B(n_2, p) \\ X_1 \perp X_2 \end{cases}$, 计算在 $X_1 + X_2 = m$ 给定条件下 X_1 的条件概率质量函数.

记 $q = 1 - p$

易知 $X_1 + X_2 \sim B(n_1 + n_2, p)$

则对于任意 $0 \leq k \leq m$, 我们有:

$$\begin{aligned} P\{X_1 = k|X_1 + X_2 = m\} &= \frac{P\{X_1 = k, X_1 + X_2 = m\}}{P\{X_1 + X_2 = m\}} \\ &= \frac{P\{X_1 = k, X_2 = m - k\}}{P\{X_1 + X_2 = m\}} \\ &= \frac{P\{X_1 = k\}P\{X_2 = m - k\}}{P\{X_1 + X_2 = m\}} \\ &= \frac{\binom{n_1}{k} p^k q^{n_1-k} \binom{n_2}{m-k} p^{m-k} q^{n_2-m+k}}{\binom{n_1+n_2}{m} p^m q^{n_1+n_2-m}} \\ &= \frac{\binom{n_1}{k} \binom{n_2}{m-k}}{\binom{n_1+n_2}{m}} \end{aligned}$$

这个分布首次见于 1.3.4(2) 中, 名为**超几何分布**

直观地看为什么此条件是超几何分布:

即使限定总成功次数为 m , $n_1 + n_2$ 次独立试验依然具有相同的成功概率,

因此前 n_1 次试验的成功次数是**超几何随机变量**.

我们也可以直观地得到**条件期望** $\mathbb{E}[X_1|X_1 + X_2 = m] = n_1 \cdot \frac{m}{n_1 + n_2}$ 的结论,

这一点可由定义式 $\mathbb{E}[X_1|X_1 + X_2 = m] = \sum_{k=0}^m \frac{\binom{n_1}{k} \binom{n_2}{m-k}}{\binom{n_1+n_2}{m}}$ 验证.

- 给定 $\begin{cases} X_1 \sim \text{Poisson}(\lambda_1) \\ X_2 \sim \text{Poisson}(\lambda_2), \text{ 计算在 } X_1 + X_2 = n \text{ 给定条件下 } X_1 \text{ 的条件概率质量函数.} \\ X_1 \perp X_2 \end{cases}$

易知 $X_1 + X_2 \sim \text{Poisson}(\lambda_1 + \lambda_2)$

则对于任意 $k = 0, 1, \dots$, 我们有:

$$\begin{aligned} \mathbb{P}\{X_1 = k | X_1 + X_2 = n\} &= \frac{\mathbb{P}\{X_1 = k, X_1 + X_2 = n\}}{\mathbb{P}\{X_1 + X_2 = n\}} \\ &= \frac{\mathbb{P}\{X_1 = k, X_2 = n - k\}}{\mathbb{P}\{X_1 + X_2 = n\}} \\ &= \frac{\mathbb{P}\{X_1 = k\} \mathbb{P}\{X_2 = n - k\}}{\mathbb{P}\{X_1 + X_2 = n\}} \\ &= \frac{e^{-\lambda_1} \lambda_1^k}{k!} \frac{e^{-\lambda_2} \lambda_2^{n-k}}{(n-k)!} \left[\frac{e^{-(\lambda_1 + \lambda_2)} (\lambda_1 + \lambda_2)^n}{n!} \right]^{-1} \\ &= \frac{n!}{(n-k)! k!} \frac{\lambda_1^k \lambda_2^{n-k}}{(\lambda_1 + \lambda_2)^n} \\ &= \binom{n}{k} \left(\frac{\lambda_1}{\lambda_1 + \lambda_2} \right)^k \left(\frac{\lambda_2}{\lambda_1 + \lambda_2} \right)^{n-k} \end{aligned}$$

因此在 $X_1 + X_2 = n$ 给定条件下 X_1 的条件分布是 $B(n, \frac{\lambda_1}{\lambda_1 + \lambda_2})$

进而可直接得到 $\mathbb{E}\{X_1|X_1 + X_2 = n\} = n \frac{\lambda_1}{\lambda_1 + \lambda_2}$

1.7.2 连续情形

若 X, Y 都是连续随机变量, 且具有联合概率密度函数 $f(x, y)$,

则对于所有使 $f_Y(y) > 0$ 的 y 值, 在 $Y = y$ 给定的条件下:

- 定义 X 的**条件概率密度函数**定义为 $f_{X|Y}(x|y) = \frac{f(x, y)}{f_Y(y)}$
上述定义的动机如下:

$$\begin{aligned} f_{X|Y}(x|y) dx &= \frac{f(x, y) dx dy}{f_Y(y) dy} \\ &\approx \frac{\mathbb{P}\{x \leq X \leq x + dx, y \leq Y \leq y + dy\}}{\mathbb{P}\{y \leq Y \leq y + dy\}} \\ &= \mathbb{P}\{x \leq X \leq x + dx | y \leq Y \leq y + dy\} \end{aligned}$$

换句话说, 对于小的值 dx, dy ,

$f_{X|Y}(x|y) dx$ 近似地是 $y \leq Y \leq y + dy$ 给定条件下 $x \leq X \leq x + dx$ 的条件概率.

- 定义 X 的**条件概率分布函数**为:

$$\begin{aligned} F_{X|Y}(a|y) &= \mathbb{P}\{X \leq a | Y = y\} \\ &= \int_{-\infty}^a f_{X|Y}(x|y) dx \end{aligned}$$

- 定义 X 的**条件期望**为:

$$\mathbb{E}[X|Y = y] = \int_{-\infty}^{\infty} x f_{X|Y}(x|y) dx$$

- 定义 X 的**条件方差**为:

$$\begin{aligned} \text{Var}(X|Y = y) &= \mathbb{E}[(X - \mathbb{E}[X|Y = y])^2 | Y = y] \\ &= \mathbb{E}[X^2 | Y = y] - (\mathbb{E}[X|Y = y])^2 \end{aligned}$$

一些具体的例子:

- 设 X 和 Y 有联合密度 $f(x, y) = \begin{cases} 6xy(2 - x - y), & 0 < x, y < 1 \\ 0, & \text{otherwise} \end{cases}$

对于 $0 < y < 1$, 计算条件期望 $\mathbb{E}[X|Y = y]$:

首先计算条件密度:

$$\begin{aligned}
 f_{X|Y}(x|y) &= \frac{f(x,y)}{f_Y(y)} \\
 &= \frac{6xy(2-x-y)}{\int_0^1 6xy(2-x-y)dx} \\
 &= \frac{6xy(2-x-y)}{y(4-3y)} \\
 &= \frac{6x(2-x-y)}{4-3y}
 \end{aligned}$$

其次计算条件期望:

$$\begin{aligned}
 \mathbb{E}[X|Y=y] &= \int_0^1 \frac{6x(2-x-y)}{4-3y} dx \\
 &= \frac{1}{4-3y} [(2-y)2 - \frac{6}{4}] \\
 &= \frac{5-4y}{8-6y}
 \end{aligned}$$

- 设 X 和 Y 有联合密度 $f(x,y) = \begin{cases} \frac{1}{2}ye^{-xy}, & 0 < x < \infty, 0 < y < 2 \\ 0, & \text{otherwise} \end{cases}$

对于 $0 < y < 2$, 计算 $e^{X/2}$ 的条件期望 $\mathbb{E}[e^{X/2}|Y=y]$:

首先计算条件密度:

$$\begin{aligned}
 f_{X|Y}(x|y) &= \frac{f(x,y)}{f_Y(y)} \\
 &= \frac{\frac{1}{2}ye^{-xy}}{\int_0^\infty \frac{1}{2}ye^{-xy}dx} \\
 &= \frac{ye^{-xy}}{-e^{-t}|_0^\infty} \quad (t := xy) \\
 &= ye^{-xy}
 \end{aligned}$$

(这里可以看出 Y 的边缘分布是 $(0, 2)$ 上的均匀分布)

其次计算条件期望:

$$\begin{aligned}
 \mathbb{E}[e^{X/2}|Y=y] &= \int_0^\infty e^{x/2} f_{X|Y}(x|y) dx \\
 &= \int_0^\infty e^{x/2} \cdot ye^{-xy} dx \\
 &= y \int_0^\infty e^{(\frac{1}{2}-y)x} dx \\
 &= \begin{cases} \frac{1}{2} \int_0^\infty 1 dx = \infty, & \text{if } y = \frac{1}{2} \\ \frac{y}{\frac{1}{2}-y} \int_0^\infty e^{(\frac{1}{2}-y)x} d(\frac{1}{2}-y)x = \begin{cases} \frac{2y}{1-2y} e^t|_0^\infty = \infty, & \text{if } 0 < y < \frac{1}{2} \\ \frac{2y}{1-2y} e^t|_0^{-\infty} = \frac{2y}{2y-1}, & \text{if } \frac{1}{2} < y < 2 \end{cases} \end{cases} \\
 &= \begin{cases} \infty, & \text{if } 0 < y \leq \frac{1}{2} \\ \frac{2y}{2y-1}, & \text{if } \frac{1}{2} < y < 2 \end{cases}
 \end{aligned}$$

- (t 分布)

若 $\begin{cases} X \sim N(0, 1) \\ Y \sim \chi^2(n) = \text{Gamma}(\frac{n}{2}, \frac{1}{2}) \\ X \perp Y \end{cases}$

则称 $T = \frac{X}{\sqrt{Y/n}} = \sqrt{n} \frac{X}{\sqrt{Y}} \sim t(n)$ 为具有 n 个自由度的 t 随机变量.

为计算 T 的概率密度函数, 我们首先推导给定 $Y=y$ 时 T 的条件分布:

由于给定 $Y=y$ 时 T 的条件分布是 $T_{Y=y} = \sqrt{\frac{n}{y}} X \sim N(0, \frac{n}{y})$

因此 $f_{T|Y}(t|y) = \sqrt{\frac{y}{2\pi n}} \exp\{-\frac{t^2 y}{2n}\} \quad (\forall t \in \mathbb{R})$

而卡方随机变量 Y 的概率密度函数为 $f_Y(y) = \frac{e^{-y/2} y^{n/2-1}}{2^{n/2} \Gamma(n/2)} \quad (\forall y > 0)$

于是有:

$$\begin{aligned}
f_T(t) &= \int_0^\infty f_{T,Y}(t,y) dy \\
&= \int_0^\infty f_{T|Y}(t|y) f_Y(y) dy \\
&= \int_0^\infty \sqrt{\frac{y}{2\pi n}} \exp\left\{-\frac{t^2 y}{2n}\right\} \cdot \frac{e^{-y/2} y^{n/2-1}}{2^{n/2} \Gamma(n/2)} dy
\end{aligned}$$

记 $\begin{cases} K = \frac{1}{\sqrt{\pi n 2^{(n+1)/2} \Gamma(n/2)}} \\ c = \frac{t^2}{2n} + \frac{1}{2} \end{cases}$ 则有:

$$\begin{aligned}
f_T(t) &= \frac{1}{K} \int_0^\infty e^{-cy} y^{(n-1)/2} dy \\
&= \frac{c^{-(n-1)/2+1}}{K} \int_0^\infty e^{-s} s^{(n-1)/2} ds \quad (s := cy) \\
&= \frac{c^{-(n+1)/2}}{K} \Gamma\left(\frac{n+1}{2}\right) \\
&= \frac{\Gamma(\frac{n+1}{2})}{\Gamma(\frac{n}{2}) \sqrt{n\pi}} \left(1 + \frac{t^2}{n}\right)^{-(n+1)/2} \quad (\forall t \in \mathbb{R})
\end{aligned}$$

- (例 3.8 待补充)

1.7.3 通过取条件计算期望和方差

值得注意的是, 条件期望 $\mathbb{E}[X|Y]$ 本身是一个随机变量.

我们可以将 $\mathbb{E}[X|Y]$ 看作随机变量 Y 的函数,

它在 $Y = y$ 处的取值是 $\mathbb{E}[X|Y = y]$

条件期望的一个重要性质是 $\mathbb{E}[X] = \mathbb{E}[\mathbb{E}(X|Y)]$, 称为**全期望公式** (Law of Total Expectation)

用于在给定随机变量的某些条件分布的情况下, 计算该随机变量的期望值.

下面我们证明 $\mathbb{E}[X] = \mathbb{E}[\mathbb{E}[X|Y]] = \begin{cases} \sum_y \mathbb{E}[X|Y = y] P\{Y = y\}, & \text{若 } Y \text{ 离散} \\ \int_{-\infty}^\infty \mathbb{E}[X|Y = y] f_Y(y) dy, & \text{若 } Y \text{ 连续} \end{cases}$

- ① 若 Y 是离散随机变量,

则有 $\mathbb{E}[X] = \mathbb{E}[\mathbb{E}(X|Y)] = \sum_y \mathbb{E}[X|Y = y] P\{Y = y\}$

证明:

$$\begin{aligned}
\sum_y \mathbb{E}[X|Y = y] P\{Y = y\} &= \sum_y \left\{ \sum_x x P\{X = x|Y = y\} \right\} P\{Y = y\} \\
&= \sum_y \sum_x x \frac{P\{X = x, Y = y\}}{P\{Y = y\}} P\{Y = y\} \\
&= \sum_y \sum_x x P\{X = x, Y = y\} \\
&= \sum_x x \sum_y P\{X = x, Y = y\} \\
&= \sum_x x P\{X = x\} \\
&= \mathbb{E}[X]
\end{aligned}$$

- ② 若 Y 是连续随机变量,

则有 $\mathbb{E}[X] = \mathbb{E}[\mathbb{E}(X|Y)] = \int_{-\infty}^\infty \mathbb{E}[X|Y = y] f_Y(y) dy$

证明:

$$\begin{aligned}
\int_{-\infty}^\infty \mathbb{E}[X|Y = y] f_Y(y) dy &= \int_{-\infty}^\infty \left\{ \int_{-\infty}^\infty x \cdot f_{X|Y}(x|y) dx \right\} f_Y(y) dy \\
&= \int_{-\infty}^\infty \int_{-\infty}^\infty x \frac{f(x,y)}{f_Y(y)} f_Y(y) dx dy \\
&= \int_{-\infty}^\infty \int_{-\infty}^\infty x f(x,y) dx dy \\
&= \int_{-\infty}^\infty x \int_{-\infty}^\infty f(x,y) dy dx \\
&= \int_{-\infty}^\infty x f_X(x) dx \\
&= \mathbb{E}[X]
\end{aligned}$$

条件期望也可以用于计算随机变量的方差:

全方差公式 (Law of Total Variance): $\text{Var}(X) = \mathbb{E}(\text{Var}(X|Y)) + \text{Var}(\mathbb{E}(X|Y))$

证明:

- 计算 $\mathbb{E}(\text{Var}(X|Y))$:

$$\begin{aligned}\mathbb{E}(\text{Var}(X|Y)) &= \mathbb{E}[\mathbb{E}(X^2|Y) - (\mathbb{E}(X|Y))^2] \\ &= \mathbb{E}[\mathbb{E}(X^2|Y)] - \mathbb{E}[(\mathbb{E}(X|Y))^2] \\ &= \mathbb{E}(X^2) - \mathbb{E}[(\mathbb{E}(X|Y))^2]\end{aligned}$$

- 计算 $\text{Var}(\mathbb{E}(X|Y))$:

$$\begin{aligned}\text{Var}(\mathbb{E}(X|Y)) &= \mathbb{E}[(\mathbb{E}(X|Y))^2] - (\mathbb{E}[\mathbb{E}(X|Y)])^2 \\ &= \mathbb{E}[(\mathbb{E}(X|Y))^2] - (\mathbb{E}(X))^2\end{aligned}$$

- 因此有:

$$\begin{aligned}\mathbb{E}(\text{Var}(X|Y)) + \text{Var}(\mathbb{E}(X|Y)) &= \mathbb{E}(X^2) - \mathbb{E}[(\mathbb{E}(X|Y))^2] + \mathbb{E}[(\mathbb{E}(X|Y))^2] - (\mathbb{E}(X))^2 \\ &= \mathbb{E}(X^2) - (\mathbb{E}(X))^2 \\ &= \text{Var}(X)\end{aligned}$$

一些具体的例子:

(复合随机变量的期望与方差)

设 $X_1, X_2, \dots$ 是一列独立同分布的随机变量, 具有均值 $\mathbb{E}[X] = \mu$ 和方差 $\text{Var}(X) = \sigma^2$

假设它们与取非负整数值的随机变量 N 独立.

我们称 $S = \sum_{i=1}^N X_i$ 为**复合随机变量**

- ① 计算 $S = \sum_{i=1}^N X_i$ 的**期望**:

注意到:

$$\begin{aligned}\mathbb{E}[S|N=n] &= \mathbb{E}\left[\sum_{i=1}^N X_i | N=n\right] \\ &= \mathbb{E}\left[\sum_{i=1}^n X_i | N=n\right] \\ &= \mathbb{E}\left[\sum_{i=1}^n X_i\right] \quad (N \perp X_i, \forall i = 1, 2, \dots) \\ &= \sum_{i=1}^n \mathbb{E}[X_i] \\ &= n\mu\end{aligned}$$

因此有:

$$\begin{aligned}\mathbb{E}[S] &= \mathbb{E}\left[\sum_{i=1}^N X_i\right] \\ &= \mathbb{E}\left[\mathbb{E}\left[\sum_{i=1}^N X_i | N\right]\right] \\ &= \mathbb{E}[N\mu] \\ &= \mu \mathbb{E}[N]\end{aligned}$$

- ② 计算 $S = \sum_{i=1}^N X_i$ 的**方差**:

注意到:

$$\begin{aligned}\text{Var}(S|N=n) &= \text{Var}\left(\sum_{i=1}^N X_i | N=n\right) \\ &= \text{Var}\left(\sum_{i=1}^n X_i | N=n\right) \\ &= \text{Var}\left(\sum_{i=1}^n X_i\right) \quad (N \perp X_i, \forall i = 1, 2, \dots) \\ &= \sum_{i=1}^n \text{Var}(X_i) \\ &= n\sigma^2\end{aligned}$$

因此有:

$$\begin{aligned}\text{Var}(S) &= \mathbb{E}(\text{Var}(S|N)) + \text{Var}(\mathbb{E}(S|N)) \\ &= \mathbb{E}[N\sigma^2] + \text{Var}(N\mu) \\ &= \sigma^2\mathbb{E}[N] + \mu^2\text{Var}(N)\end{aligned}$$

- 特殊地, 如果 $N \sim \text{Poisson}(\lambda)$

则我们称 $S = \sum_{i=1}^N X_i$ 为**复合 Poisson 随机变量**

$$\begin{aligned}\text{根据} \quad & \begin{cases} \mathbb{E}[S] = \mu\mathbb{E}[N] \\ \text{Var}(S) = \sigma^2\mathbb{E}[N] + \mu^2\text{Var}(N) \\ \mathbb{E}[N] = \text{Var}[N] = \lambda \\ \mathbb{E}[X^2] = \text{Var}(X) + (\mathbb{E}[X])^2 = \sigma^2 + \mu^2 \end{cases} \\ \text{可知} \quad & \begin{cases} \mathbb{E}[S] = \mu\lambda = \lambda\mathbb{E}[X] \\ \text{Var}(S) = (\sigma^2 + \mu^2)\lambda = \lambda\mathbb{E}[X^2] \end{cases}\end{aligned}$$

(匹配轮数问题)

设有 N 个人将帽子混杂后各自抽取一顶帽子,

取到自己帽子的人离开, 而其余的人将帽子混杂后重新抽取,

这个过程持续进行到所有人都取到了自己的帽子为止.

- ① 首先我们证明, 无论有多少人, 平均每轮抽取都有一次匹配:

不失一般性地, 考虑第一轮抽取, 暂时将 N 视为一个确定的数.

记 $X = \sum_{i=1}^N X_i$ 为第一轮抽取的总匹配数, 其中 $X_i = \begin{cases} 1, & \text{第 } i \text{ 人取到了自己的帽子} \\ 0, & \text{otherwise} \end{cases}$

对于任意 $i = 1, \dots, N$ 都有:

$$\begin{aligned}\mathbb{E}[X_i] &= 1 \cdot \text{P}\{X_i = 1\} + 0 \cdot \text{P}\{X_i = 0\} \\ &= 1 \cdot \frac{1}{N} + 0 \cdot (1 - \frac{1}{N}) \\ &= \frac{1}{N}\end{aligned}$$

因此有 $\mathbb{E}[X] = \mathbb{E}[\sum_{i=1}^N X_i] = \sum_{i=1}^N \mathbb{E}[X_i] = N \cdot \frac{1}{N} = 1$

说明对于任一轮抽取, 无论有多少人, 平均每轮抽取都有一次匹配.

- ② 其次我们证明, 无论有多少人, 总匹配数的方差都是 1:

对于任意 $i = 1, \dots, N$ 都有 $\text{P}\{X_i = 1\} = \frac{1}{N}$, 因此有 $\text{Var}(X_i) = \frac{1}{N}(1 - \frac{1}{N})$

对于任意 $i \neq j \in \{1, \dots, N\}$ 都有 $\text{P}\{X_i = 1 | X_j = 1\} = \frac{1}{N-1}$,

于是有:

$$\begin{aligned}\mathbb{E}[X_i X_j] &= 1^2 \cdot \text{P}\{X_i = 1, X_j = 1\} \\ &= \text{P}\{X_j = 1\} \text{P}\{X_i = 1 | X_j = 1\} \\ &= \frac{1}{N} \frac{1}{N-1} \\ &= \frac{1}{N(N-1)}\end{aligned}$$

因此有:

$$\begin{aligned}\text{Cov}(X_i, X_j) &= \mathbb{E}[X_i X_j] - \mathbb{E}[X_i] \mathbb{E}[X_j] \\ &= \frac{1}{N(N-1)} - \frac{1}{N} \frac{1}{N} \\ &= \frac{1}{N^2(N-1)}\end{aligned}$$

综上所述:

$$\begin{aligned}\text{Var}(X) &= \sum_{i=1}^N \text{Var}(X_i) + 2 \sum_{i < j} \text{Cov}(X_i, X_j) \\ &= N \cdot \frac{1}{N} (1 - \frac{1}{N}) + 2 \binom{N}{2} \frac{1}{N^2(N-1)} \\ &= (1 - \frac{1}{N}) + \frac{1}{N} \\ &= 1\end{aligned}$$

说明对于任一轮抽取, 无论有多少人, 总匹配数的方差都是 1.

综合①②我们知道, 无论 N 为多大, 都有 $\begin{cases} \mathbb{E}[X] = \text{Var}(X) = 1 \\ \mathbb{E}[X^2] = 2 \end{cases}$

• ③ 记 R_n 为最开始有 n 个人时, 完成全部匹配所需的总轮数

◦ 计算 $\mathbb{E}[R_n]$:

根据 ① 的结论, 直觉上我们能够猜到 $\mathbb{E}[R_n] = n$.

这个猜测是正确的, 现在给出一个归纳性的证明:

- 对于 $n = 1$ 的情况, 显然有 $\mathbb{E}[R_1] = 1$
- 对于 $n \geq 2$ 的情况, 假定对于任意 $k = 1, \dots, n-1$ 都有 $\mathbb{E}[R_k] = k$
记第一轮匹配数为 X , 我们对 X 取条件, 则有:

$$\begin{aligned} \mathbb{E}[R_n] &= \sum_{i=0}^n \mathbb{E}[R_n | X = i] \cdot \text{P}\{X = i\} \\ &= \sum_{i=0}^n (1 + \mathbb{E}[R_{n-i}]) \cdot \text{P}\{X = i\} \\ &= 1 + \mathbb{E}[R_n] \text{P}\{X = 0\} + \sum_{i=1}^n (n-i) \text{P}\{X = i\} \quad (\text{代入归纳假设}) \\ &= 1 + \mathbb{E}[R_n] \text{P}\{X = 0\} + n(1 - \text{P}\{X = 0\}) - \mathbb{E}[X] \quad (\text{note that } \mathbb{E}[X] = 1) \\ &= \mathbb{E}[R_n] \text{P}\{X = 0\} + n(1 - \text{P}\{X = 0\}) \end{aligned}$$

于是我们解出 $\mathbb{E}[R_n] = n$

根据数学归纳法, 我们证明了 $\mathbb{E}[R_n] = n$

◦ 计算 $\text{Var}(R_n)$:

根据 ② 的结论, 直觉上我们能够猜到 $\text{Var}[R_n] = n$ ($n \geq 2$).

这个猜测是正确的, 现在给出一个归纳性的证明:

- 对于 $n = 0, 1$ 的情况, 我们设 $\text{Var}(R_0) = \text{Var}(R_1) = 0$
- 对于 $n = 2$ 的情况, 完全匹配所需的轮数 R_2 服从几何分布 $\text{Geo}(\frac{1}{2})$
(这很好理解, 当 $n = 2$ 时, 首次成功匹配就代表着完全匹配, 成功概率为 $\frac{1}{2}$)
因此 $\text{Var}[R_2] = \frac{1 - \frac{1}{2}}{(\frac{1}{2})^2} = 2$
- 对于 $n \geq 3$ 的情况, 假定对于任意 $k = 1, \dots, n-1$ 都有 $\text{Var}(R_k) = k$
记第一轮匹配数为 X , 我们对 X 取条件, 则有:

$$\begin{aligned} \text{Var}(R_n) &= \mathbb{E}[\text{Var}(R_n | X)] + \text{Var}(\mathbb{E}[R_n | X]) \\ &= \mathbb{E}[\text{Var}(R_{n-X})] + \text{Var}(1 + \mathbb{E}[R_{n-X}]) \\ &= \sum_{i=0}^n \text{Var}(R_{n-i}) \text{P}\{X = i\} + \text{Var}(1 + n - X) \\ &= \text{Var}(R_n) \text{P}\{X = 0\} + \sum_{i=1}^n \text{Var}(R_{n-i}) \text{P}\{X = i\} + \text{Var}(X) \quad (\text{代入归纳假设}) \\ &= \text{Var}(R_n) \text{P}\{X = 0\} + \sum_{i=1}^n (n-i) \text{P}\{X = i\} + \text{Var}(X) \\ &\quad (\text{对于 } i = n-1 \text{ 的情况我们注意到 } \text{P}\{X = n-1\} = 0, \text{ 因此对应系数可以取为 } n-i \text{ 的通式形式}) \\ &= \text{Var}(R_n) \text{P}\{X = 0\} + n(1 - \text{P}\{X = 0\}) - \mathbb{E}[X] + \text{Var}(X) \quad (\text{代入 } \mathbb{E}[X] = \text{Var}(X) = 1) \\ &= \text{Var}(R_n) \text{P}\{X = 0\} + n(1 - \text{P}\{X = 0\}) \end{aligned}$$

于是我们解出 $\text{Var}(R_n) = n$

根据数学归纳法, 我们证明了 $\text{Var}[R_n] = n$ ($n \geq 2$)

• ④ 记 S_n 为最开始有 n ($n \geq 2$) 个人时, 完成全部匹配所需的总抽取次数

◦ 计算 $\mathbb{E}[S_n]$:

根据 ① 的结论, 直觉上我们能够猜到 $\mathbb{E}[S_n] = \sum_{i=2}^{n-2} i = \frac{n(n+2)}{2} = \frac{n^2}{2} + n$

这个猜测是正确的, 现在给出一个归纳性的证明:

- 对于 $n = 0, 1$ 的情况, 我们设 $\mathbb{E}[S_0] = \mathbb{E}[S_1] = 0$
- 对于 $n = 2$ 的情况, 完全匹配所需的轮数 R_2 服从几何分布 $\text{Geo}(\frac{1}{2})$
(这很好理解, 当 $n = 2$ 时, 首次成功匹配就代表着完全匹配, 成功概率为 $\frac{1}{2}$)
因此 $\mathbb{E}[S_2] = \mathbb{E}[2R_2] = 2\mathbb{E}[R_2] = 2 \cdot 2 = 4$, 命题成立.
- 对于 $n \geq 3$ 的情况, 假定对于任意 $k = 1, \dots, n-1$ 都有 $\mathbb{E}[S_k] = \frac{k^2}{2} + k$
记第一轮匹配数为 X , 我们对 X 取条件, 则有:

$$\begin{aligned}
\mathbb{E}[S_n] &= \sum_{i=0}^n \mathbb{E}[S_n | X = i] \cdot \mathbb{P}\{X = i\} \\
&= \sum_{i=0}^n (n + \mathbb{E}[S_{n-i}]) \cdot \mathbb{P}\{X = i\} \\
&= n + \mathbb{E}[S_n] \mathbb{P}\{X = 0\} + \sum_{i=1}^n \mathbb{E}[S_{n-i}] \mathbb{P}\{X = i\} \quad (\text{代入归纳假设}) \\
&= n + \mathbb{E}[S_n] \mathbb{P}\{X = 0\} + \sum_{i=1}^n \left[\frac{(n-i)^2}{2} + (n-i) \right] \mathbb{P}\{X = i\} \\
&\quad (\text{对于 } i = n-1 \text{ 的情况我们注意到 } \mathbb{P}\{X = n-1\} = 0, \text{ 因此对应系数可以取为 } \frac{(n-i)^2}{2} + (n-i) \text{ 的通式形式}) \\
&= n + \mathbb{E}[S_n] \mathbb{P}\{X = 0\} + \left(\frac{n^2}{2} + n \right) (1 - \mathbb{P}\{X = 0\}) - (n+1) \mathbb{E}[X] + \frac{1}{2} \mathbb{E}[X^2] \\
&= n + \mathbb{E}[S_n] \mathbb{P}\{X = 0\} + \left(\frac{n^2}{2} + n \right) (1 - \mathbb{P}\{X = 0\}) - (n+1) \cdot 1 + \frac{1}{2} \cdot 2 \\
&= \mathbb{E}[S_n] \mathbb{P}\{X = 0\} + \left(\frac{n^2}{2} + n \right) (1 - \mathbb{P}\{X = 0\})
\end{aligned}$$

于是我们解出 $\mathbb{E}[S_n] = \frac{n^2}{2} + n$

根据数学归纳法, 我们证明了 $\mathbb{E}[S_n] = \frac{n^2}{2} + n \quad (n \geq 2)$

1.7.4 通过取条件计算概率

我们不仅可以通过对合适的随机变量先取条件得到期望和方差, 而且也可用此方法计算概率.

具体来说, 记 E 为一个任意事件且定义**示性随机变量** $X = \begin{cases} 1, & \text{若 } E \text{ 发生} \\ 0, & \text{若 } E \text{ 不发生} \end{cases}$

由 X 的定义推出 $\begin{cases} \mathbb{E}[X] = \mathbb{P}(E) \\ \mathbb{E}[X|Y = y] = \mathbb{P}(E|Y = y) \end{cases}$ (对于任意随机变量 Y)

因此根据**全期望公式** $\mathbb{E}[X] = \mathbb{E}[\mathbb{E}[X|Y]] = \begin{cases} \sum_y \mathbb{E}[X|Y = y] \mathbb{P}\{Y = y\}, & \text{若 } Y \text{ 离散} \\ \int_{-\infty}^{\infty} \mathbb{E}[X|Y = y] f_Y(y) dy, & \text{若 } Y \text{ 连续} \end{cases}$

可知有 $\mathbb{P}[E] = \begin{cases} \sum_y \mathbb{P}[E|Y = y] \mathbb{P}\{Y = y\}, & \text{若 } Y \text{ 离散} \\ \int_{-\infty}^{\infty} \mathbb{P}[E|Y = y] f_Y(y) dy, & \text{若 } Y \text{ 连续} \end{cases}$

一些具体的例子:

- 设 X, Y 为独立的连续随机变量, 分别具有密度 f_X, f_Y , 计算 $\mathbb{P}\{X < Y\}$:
对 Y 取条件得:

$$\begin{aligned}
\mathbb{P}\{X < Y\} &= \int_{-\infty}^{\infty} \mathbb{P}\{X < Y | Y = y\} f_Y(y) dy \\
&= \int_{-\infty}^{\infty} \mathbb{P}\{X < y | Y = y\} f_Y(y) dy \quad (X \perp Y) \\
&= \int_{-\infty}^{\infty} \mathbb{P}\{X < y\} f_Y(y) dy \\
&= \int_{-\infty}^{\infty} F_X(y) f_Y(y) dy
\end{aligned}$$

其中 $F_X(y) = \int_{-\infty}^y f_X(x) dx$

- (Poisson 均值的随机性)**

设 $\begin{cases} Y \sim \text{Poisson}(X) \\ X \sim \exp(1) = \text{Gamma}(1, 1) \end{cases}$ 计算 $\mathbb{P}\{Y = n\}$:

首先, Poisson 均值 X 的概率密度函数为 $f_X(x) = xe^{-x} \quad (x \geq 0)$

其次, 对 X 取条件可得: $(\forall n = 0, 1, \dots)$

$$\begin{aligned}
P\{Y = n\} &= \int_{-\infty}^{\infty} P\{Y = n|X = x\}f_X(x)dx \\
&= \int_{-\infty}^{\infty} P\{\text{Poisson}(x) = n\}f_X(x)dx \\
&= \int_0^{\infty} e^{-x} \frac{x^n}{n!} \cdot xe^{-x}dx \\
&= \frac{1}{n!} \int_0^{\infty} x^{n+1}e^{-2x}dx \\
&= \frac{n+1}{2^{n+2}} \int_0^{\infty} \frac{2e^{-2x}(2x)^{n+1}}{(n+1)!}dx \quad (\text{凑出 } \text{Gamma}(n+2, 2) \text{ 的概率密度函数}) \\
&= \frac{n+1}{2^{n+2}}
\end{aligned}$$

• (相互独立的 Poisson 随机事件的分类)

记 $N \sim \text{Poisson}(\lambda)$ 为每天参与训练的人数, 假定每个人是否参加是相互独立的,

其中是女性的概率为 p , 是男性的概率为 $1-p$

求今天恰有 n 个女性和 m 个男性参与训练的联合概率:

记今天参加的女、男性人数分别为 N_1, N_2 , 满足 $N = N_1 + N_2$

对 N 取条件可得: $(\forall n, m = 0, 1, \dots)$

$$\begin{aligned}
P\{N_1 = n, N_2 = m\} &= \sum_{i=0}^{\infty} P\{N_1 = n, N_2 = m|N = i\}P\{N = i\} \\
&= 0 + P\{N_1 = n, N_2 = m|N = n+m\}P\{N = n+m\} \\
&= \binom{n+m}{n} p^n (1-p)^m \cdot e^{-\lambda} \frac{\lambda^n \lambda^m}{(n+m)!} \\
&= \frac{(n+m)!}{n!m!} p^n (1-p)^m e^{-\lambda p} e^{-\lambda(1-p)} \frac{\lambda^n \lambda^m}{(n+m)!} \\
&= e^{-\lambda p} \frac{(\lambda p)^n}{n!} \cdot e^{-\lambda(1-p)} \frac{(\lambda(1-p))^m}{m!} \\
&= P\{\text{Poisson}(\lambda p) = n\} \cdot P\{\text{Poisson}(\lambda(1-p)) = m\}
\end{aligned}$$

这说明 $\begin{cases} N_1 \sim \text{Poisson}(\lambda p) \\ N_2 \sim \text{Poisson}(\lambda(1-p)) \\ N_1 \perp N_2 \end{cases}$

这是一个重要的结论:

当每一个均值为 λ 的 Poisson 随机事件**独立地**以概率 p 分入第一类, 或以概率 $1-p$ 分入第二类时,

第一类与第二类中的事件数是独立的 Poisson 随机变量, 且 Poisson 均值分别为 λp 和 $\lambda(1-p)$

这个结论的推广形式:

N 个均值为 λ 的 Poisson 随机事件**独立地**分为 k 类,

其中分入第 i 类的概率是 p_i , 满足 $\sum_{i=1}^k p_i = 1$.

记 N_i 为分入第 i 类的事件数, 满足 $\sum_{i=1}^k N_i = N$

则 $N_1, \dots, N_k$ 是独立的 Poisson 随机变量, 均值分别为 $\lambda p_1, \dots, \lambda p_k$

证明:

对于 $n = \sum_{i=1}^k n_i$:

$$\begin{aligned}
P\{N_1 = n_1, \dots, N_k = n_k\} &= P\{N_1 = n_1, \dots, N_k = n_k|N = n\} \cdot P\{N = n\} \\
&= \frac{n!}{n_1! \dots n_k!} p_1^{n_1} \dots p_k^{n_k} \cdot e^{-\lambda} \frac{\lambda^n}{n!} \\
&= \prod_{i=1}^k e^{-\lambda p_i} \frac{(\lambda p_i)^{n_i}}{n_i!} \\
&= \prod_{i=1}^k P\{\text{Poisson}(\lambda p_i) = n_i\}
\end{aligned}$$

说明 $\begin{cases} N_i \sim \text{Poisson}(\lambda p_i) & (\forall i = 1, \dots, k) \\ N_i \perp N_j & (\forall i \neq j = 1, \dots, k) \end{cases}$

The End